



เอกสารเค้าโครงโครงการ 1

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท

Category-Specific News Classification and NLP Analytics
Pipeline

โดย

663380214-4 นายนราวิชญ์ ศิริพล

663380028-1 นายอัสดาภูมิ เอื้อวงศ์

อาจารย์ที่ปรึกษา

อ.ดร.พบพร ด้านวิรุทย์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา

วิชา CP354 771 โครงงานคอมพิวเตอร์ 1

หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

ปีการศึกษา 2569

นราวิชญ์ ศิริพล และ อัสตาวุฒิ เอื้อวงศ์. 2569. **ระบบ จำแนก และ วิเคราะห์ ข่าวสาร
อัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท.** โครงการ
คอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการ
คอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.พพพร ด้านวิรัช

บทคัดย่อ

โครงการนี้มีวัตถุประสงค์เพื่อศึกษาและพัฒนา ระบบ จำแนก และ วิเคราะห์ ข่าวสาร
อัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific
NLP Analytics) โดยระบบพัฒนาด้วยภาษา Python ร่วมกับเฟรมเวิร์ค FastAPI สำหรับส่วน
Backend และภาษา JavaScript ร่วมกับ Tailwind CSS และ Socket.IO สำหรับส่วน Fron-
tend ระบบทำการรวบรวมข่าวจากเว็บไซต์ข่าวไทยด้วยเทคนิคเว็บสแครปปิง การอ่าน RSS Feed
และการจำลองเบราว์เซอร์ด้วย Playwright จากนั้นส่งเนื้อหาข่าวในรูปแบบ Markdown ไปยัง
โมเดลภาษาขนาดใหญ่ผ่านบริการ KGU Gen.AI เพื่อสร้างบทสรุป ประเด็นสำคัญ อารมณ์ของ
ข่าว และคำสำคัญในภาษาเดียวกับต้นฉบับ พร้อมจำแนกหมวดหมู่ข่าวออกเป็นหมวดหมู่เฉพาะ
ทางด้วยการตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับกฎคำสำคัญและโมเดล SVM และแสดงผล
ข่าวพร้อมสรุปบนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket ระบบยังมีกลไกการจัดการ
แคชและคุกกี้เพื่อปรับแต่งประสบการณ์ผู้ใช้และป้องกันข้อมูลให้อัลกอริทึมแนะนำข่าว โครงการนี้เป็น
ประโยชน์ต่อการลดภาระของผู้อ่านในการติดตามข่าวจากหลายเว็บไซต์ และเป็นแนวทางใน
การประยุกต์ใช้เทคนิค NLP และโมเดลภาษาขนาดใหญ่สำหรับการวิเคราะห์ข่าวสารอัตโนมัติ

คำสำคัญ: การจำแนกข่าว, การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เว็บส
แครปปิง, โมเดลภาษาขนาดใหญ่, อัลกอริทึมแนะนำข่าว

Narawit Siripol and Ausadawut Aueawong. 2026. **Category-Specific News Classification and NLP Analytics Pipeline**. Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Dr. Pobporn Danvirutai

ABSTRACT

This project aims to study and develop a Category-Specific News Classification and NLP Analytics Pipeline for automatic news processing. The system is developed with Python and the FastAPI framework for the backend, and JavaScript with Tailwind CSS and Socket.IO for the frontend. News articles are collected from Thai news websites using web scraping, RSS feed parsing, and Playwright browser automation for JavaScript-rendered pages. The collected article content in Markdown format is then sent to a large language model through the KKU Gen.AI service to generate a summary, key points, sentiment, and keywords in the same language as the original article. The system also classifies news into specific categories using Thai word segmentation with PyThaiNLP combined with keyword-based rules and a Support Vector Machine model, and presents the news with summaries on a web application in real time through WebSocket. Additionally, the system incorporates a cache and cookie management mechanism — including personalize cookies for user preferences and algorithm cookies for tracking reading behavior — to feed a recommendation algorithm that tailors news delivery to individual users. This project is beneficial for reducing the effort of readers who need to follow news across multiple websites, and serves as a guideline for applying NLP techniques and large language models to automatic news analytics.

Keywords: News classification, Text analytics, Natural language processing, Web scraping, Large language model, Recommendation algorithm

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อ.ดร.พบพร ด้านวิรุทธ อาจารย์ที่ปรึกษาโครงการ ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงการฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงการนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอขอบพระคุณคณาจารย์ในสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่นทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงการนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจ ตลอดระยะเวลาของการศึกษา

ผู้จัดทำ
นราวิชญ์ ศิริพล
อัสดาภูมิ เอื้อวงศ์

สารบัญ

บทคัดย่อ	ก
ABSTRACT	ข
กิตติกรรมประกาศ	ค
สารบัญ	ง
สารบัญภาพ	ฉ
สารบัญตาราง	ช
1 บทนำ	1
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์	1
1.3 ขอบเขตและข้อจำกัดของระบบ	2
1.3.1 ขอบเขต	2
1.3.2 ข้อจำกัดของโครงการ	3
1.4 ประโยชน์ที่คาดว่าจะได้รับ	3
2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	5
2.1 ทฤษฎีที่เกี่ยวข้อง	5
2.1.1 เว็บสแครปปิง (Web Scraping)	5
2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่	5
2.1.3 การจำแนกข้อความภาษาไทย	5
2.1.4 การจัดการแคชและคุกกี้	6
2.1.5 อัลกอริทึมการกำหนดคุกกี้ (Assign Cookies Algorithm)	6
2.2 งานวิจัยที่เกี่ยวข้อง	7
2.2.1 งานสกัดเนื้อหาบทความจากเว็บ	8
2.2.2 งานสรุปข้อความอัตโนมัติ	8
2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย	8
2.2.4 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง	8
2.2.5 เทคโนโลยีและเครื่องมือที่เกี่ยวข้อง	9
3 วิธีการดำเนินโครงการ	11
3.1 ขั้นตอนการดำเนินงาน	11
3.1.1 ศึกษาปัญหาและรวบรวมความต้องการ	11

3.1.2	วิเคราะห์และออกแบบระบบ	11
3.1.3	พัฒนาระบบ	11
3.1.4	ทดสอบและประเมินผล	12
3.1.5	ปรับปรุงและสรุปผล	12
3.2	เครื่องมือที่ใช้ในการดำเนินงาน	12
3.2.1	ฮาร์ดแวร์	12
3.2.2	ซอฟต์แวร์	12
3.3	แผนการดำเนินงาน	13
เอกสารอ้างอิง		15
ภาคผนวก ก: ตัวอย่าง UI หรือ Prototype		17

สารบัญภาพ

ภาพที่ 1	หน้าจอเข้าสู่ระบบ (Login)	17
ภาพที่ 2	หน้าจอหลัก (Dashboard)	18

สารบัญตาราง

ตารางที่ 1	เปรียบเทียบงานวิจัยที่เกี่ยวข้อง	8
ตารางที่ 2	รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา	12
ตารางที่ 3	รายการซอฟต์แวร์ที่ใช้ในการพัฒนา	13
ตารางที่ 4	แผนการดำเนินงานและไทม์ไลน์ของโครงการ (Gantt Chart)	14

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน ข่าวสารเป็นข้อมูลสำคัญที่ช่วยให้ประชาชนรับรู้และติดตามเหตุการณ์ได้อย่างทันทั่วถึง โดยเฉพาะอย่างยิ่งในยุคที่ข้อมูลมีการเปลี่ยนแปลงตลอดเวลา อย่างไรก็ตาม ผู้อ่านที่ต้องการติดตามข่าวสารจากหลายแหล่งมักประสบปัญหาหลายประการ ได้แก่ ต้องเปิดเว็บไซต์หรือแอปพลิเคชันหลายแห่งเพื่อเปรียบเทียบข่าวเดียวกัน ทำให้เสียเวลาและเกิดความยุ่งยากในการติดตามสถานการณ์ที่เปลี่ยนแปลงอย่างรวดเร็ว นอกจากนี้ ข่าวแต่ละฉบับยังมีเนื้อหายาวและมีข้อมูลจำนวนมาก ทำให้ผู้อ่านต้องใช้เวลาในการอ่านเพื่อสกัดประเด็นสำคัญ รวมถึงยังต้องอ่านข่าวจากแหล่งภาษาอังกฤษเพื่อให้ได้มุมมองที่หลากหลาย อีกทั้งข่าวสารที่มีปริมาณมากและหลากหลายหมวดหมู่ยังทำให้การคัดกรองและวิเคราะห์ข่าวเป็นเรื่องท้าทาย

การนำเทคโนโลยีเว็บสแครปปิง (Web Scraping) และ RSS Feed มาใช้ในการดึงข้อมูลข่าวจากเว็บไซต์ข่าวอัตโนมัติ ตลอดจนการใช้เทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ในการจำแนกหมวดหมู่ข่าวตามประเภท และการใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ในการสรุปเนื้อหา จะช่วยลดภาระของผู้อ่านในการเปิดหลายเว็บไซต์และอ่านบทความฉบับเต็ม อีกทั้งยังสามารถนำเสนอข้อมูลสำคัญที่คัดสรรและวิเคราะห์แล้วแบบเรียลไทม์ได้ในทีเดียว

จากปัญหาดังกล่าว โครงการนี้จึงมีแนวคิดในการพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) โดยระบบจะทำการดึงข่าวจากแหล่งข่าวเป็นระยะแบบอัตโนมัติ จำแนกหมวดหมู่ข่าวด้วยเทคนิค NLP และโมเดลแมชชีนเลิร์นนิง สรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ และแสดงผลข่าวพร้อมการวิเคราะห์บนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket เพื่อให้ผู้ใช้สามารถติดตามข่าวสารได้อย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

1.2 วัตถุประสงค์

- 1) เพื่อศึกษา และ วิเคราะห์ เทคนิค การ ดึง ข้อมูล ข่าว จาก เว็บไซต์ ข่าว ด้วย วิธี เว็บ สแครปปิงและการอ่าน RSS Feed รวมถึงเทคนิคการประมวลผลภาษาธรรมชาติ สำหรับการจำแนกหมวดหมู่ข่าวตามประเภท
- 2) เพื่อออกแบบ และ พัฒนาระบบ จำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) ครอบคลุมการดึงข่าว การจำแนกหมวดหมู่ การสรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ อัลกอริทึมแนะนำข่าว และการแสดงผลแบบเรียลไทม์
- 3) เพื่อ ทดสอบ และ ประเมิน ประสิทธิภาพ ของ ระบบ ใน ด้าน ความ ถูก ต้อง ของ การจำแนกหมวดหมู่ข่าว ความถูกต้องของการสรุปข่าว ความแม่นยำของอัลกอริทึม

แนะนำข่าว และความสามารถในการแสดงผลข่าวแบบเรียลไทม์

1.3 ขอบเขตและข้อจำกัดของระบบ

1.3.1 ขอบเขต

ระบบเป็นเว็บแอปพลิเคชันแบบเต็มรูปแบบ (Full-stack) ที่มีขอบเขตการทำงาน ดังนี้

- 1) **การ รวบรวม ข่าว อัตโนมัติ:** ระบบ สามารถ ดึง ข่าว จาก แหล่ง ข่าว ออนไลน์หลายแห่ง โดยใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed และ การ จำลอง เบราร์เซอร์ ด้วย Playwright สำหรับ เว็บไซต์ ที่ ใช้ JavaScript
- 2) **การสรุปข่าว:** ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้โมเดล ภาษาขนาดใหญ่ผ่าน API ของมหาวิทยาลัยขอนแก่น (KKU Gen.AI) เพื่อสร้างบทสรุป ประเด็นสำคัญ อารมณ์ของข่าว (Sentiment) และ คำสำคัญ โดยสรุปเป็นภาษาเดียวกับต้นฉบับข่าว
- 3) **การ จำแนก หมวด หมู่:** ระบบ จำแนก ข่าว ออกเป็น หมวด หมู่ เฉพาะ ทาง โดยใช้การตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับกฎคำสำคัญ (Keyword-based Rules) และโมเดล SVM ที่ได้รับการฝึกไว้แล้ว
- 4) **การ แสดง ผล แบบ รี ยล ไทม์:** ระบบ แสดง รายการ ข่าว บน เว็บ แอปพลิเคชันพร้อมสรุปเนื้อหา ภาพประกอบ และหมวดหมู่ และแจ้ง เตือนข่าวใหม่ทันทีผ่าน WebSocket โดยไม่ต้องรีเฟรชหน้าเว็บ
- 5) **การจัดเก็บข้อมูล:** ระบบ จัดเก็บ ข้อมูล ข่าว ที่รวบรวมได้ในรูปแบบ JSON บนเครื่องเซิร์ฟเวอร์
- 6) **การ ตั้ง ค่า และ ความ ยืดหยุ่น:** ระบบ รองรับ การ เพิ่ม แหล่ง ข่าว ใหม่ ได้โดยไม่ต้องแก้ไขโครงสร้างหลัก ผ่านการลงทะเบียน Source ด้วย Decorator และกำหนดค่าต่าง ๆ ได้ผ่านไฟล์กำหนดค่า เช่น ช่วงเวลา ในการดึงข่าว จำนวนข่าวต่อแหล่ง และจำนวนประโยคที่ใช้สรุป
- 7) **ระบบแคช (Cache):** ระบบมีกลไกจัดเก็บข้อมูลข่าวและเนื้อหาที่ดึง มาแล้วไว้ในแคช โดยใช้ตัวระบุเฉพาะของข่าว เช่น URL เป็นกุญแจแคช เพื่อหลีกเลี่ยงการดึงข้อมูลซ้ำจากเว็บไซต์ต้นทางในรอบการทำงานถัดไป ซึ่งช่วยลดภาระของเซิร์ฟเวอร์และเพิ่มความรวดเร็วในการแสดงผล
- 8) **ระบบคุกกี้ (Cookies):** ระบบจัดการและจัดเก็บคุกกี้ของเบราว์เซอร์ ร่วมกับ Playwright Service เพื่อคงสถานะเซสชัน (Session) ในการ ดึงข้อมูลจากเว็บไซต์ข่าวที่แสดงผลเนื้อหาผ่าน JavaScript หรือมีกลไก ตรวจสอบเบราว์เซอร์ เช่น Cloudflare ให้สามารถดึงข่าวได้อย่างถูกต้องและต่อเนื่อง

- 9) **คุกกี้เพื่อการปรับแต่งเฉพาะบุคคล (Personalize Cookies):** ระบบใช้คุกกี้ในการจัดเก็บค่ากำหนดของผู้ใช้ เช่น หมวดหมู่ข่าวที่สนใจ ภาษาที่ต้องการแสดงผล และการตั้งค่าส่วนติดต่อผู้ใช้ เพื่อให้ผู้ใช้ได้รับประสบการณ์ที่ปรับแต่งตามความต้องการของแต่ละบุคคล
- 10) **คุกกี้เพื่ออัลกอริทึม (Algorithm Cookies):** ระบบใช้คุกกี้ในการบันทึกพฤติกรรมการอ่านข่าวของผู้ใช้ เช่น หมวดหมู่ที่เข้าชมบ่อย ข่าวที่ใช้เวลาอ่านนาน หรือข่าวที่ผู้ใช้กดบันทึกหรือแชร์ ข้อมูลพฤติกรรมเหล่านี้จะถูกส่งให้อัลกอริทึมแนะนำข่าว (Recommendation Algorithm) เพื่อวิเคราะห์ความสนใจและคัดสรรข่าวที่เกี่ยวข้องมากที่สุดมาแสดงเป็นลำดับแรกบนหน้าเว็บ ซึ่งช่วยเพิ่มความเกี่ยวข้องของเนื้อหาและประสบการณ์การใช้งานที่ดียิ่งขึ้นสำหรับผู้ใช้แต่ละคน

1.3.2 ข้อจำกัดของโครงการ

- 1) ระบบรองรับการสรุปและแสดงผลข่าวในภาษาไทยและภาษาอังกฤษเท่านั้น ตามภาษาเดิมของเนื้อหาข่าวแต่ละฉบับ
- 2) ระบบครอบคลุมแหล่งข่าวออนไลน์ที่กำหนด และโครงสร้าง HTML หรือ RSS Feed ของเว็บไซต์แหล่งข่าวอาจเปลี่ยนแปลงได้ ทำให้ระบบต้องได้รับการปรับปรุงให้สอดคล้อง
- 3) การสรุปข่าวต้องอาศัยการเชื่อมต่ออินเทอร์เน็ตและ API ของโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) หากบริการขัดข้องหรือหมดโควตาการใช้งาน ระบบจะไม่สามารถสรุปข่าวใหม่ได้
- 4) ด้วยข้อจำกัดด้านระยะเวลาและงบประมาณ ระบบจึงถูกติดตั้งและทดสอบ บน เครื่อง คอมพิวเตอร์ ภายใน มหาวิทยาลัย เท่านั้น ยัง ไม่ ครอบคลุมการใช้งานแบบผู้ใช้พร้อมกันจำนวนมาก
- 5) รอบแรกของการดึงข่าวอาจใช้เวลา 2-5 นาที เนื่องจากต้องดึงเนื้อหาบทความของแต่ละข่าวเพื่อใช้ในการสรุป

1.4 ประโยชน์ที่คาดว่าจะได้รับ

- 1) ได้ระบบเว็บแอปพลิเคชันจำแนกและวิเคราะห์ข่าวสารอัตโนมัติแบบเรียลไทม์ ที่ช่วยให้ผู้ใช้ติดตามข่าวสารจากหลายแหล่งได้ในที่เดียวอย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล
- 2) ได้แนวทางในการประยุกต์ใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed โมเดลภาษาขนาดใหญ่ อัลกอริทึมการกำหนดคุกกี้เพื่อการปรับแต่งเฉพาะบุคคล และอัลกอริทึมแนะนำข่าว เพื่อสร้างระบบวิเคราะห์ข้อมูลข่าวอัตโนมัติ ซึ่งสามารถนำไปพัฒนาต่อยอดกับข้อมูลประเภทอื่น

- 3) ได้องค์ความรู้ด้านการประมวลผลภาษาธรรมชาติ การจำแนกข้อความด้วยกฎ คำสำคัญร่วมกับโมเดลแมชชีนเลิร์นนิง เทคนิคการสรุปข้อความด้วยโมเดลภาษา ขนาดใหญ่ และการพัฒนาระบบเว็บแบบเรียลไทม์

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 เว็บสแครปปิง (Web Scraping)

เว็บสแครปปิงคือกระบวนการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ แทนการคัดลอกข้อมูลด้วยมือ โดยทั่วไปจะส่งคำขอ HTTP ไปยังเว็บเซิร์ฟเวอร์แล้ววิเคราะห์โครงสร้าง HTML ของหน้าเว็บเพื่อสกัดข้อมูลที่ต้องการ [1] เครื่องมือที่นิยมใช้ ได้แก่ ไลบรารี BeautifulSoup สำหรับวิเคราะห์และค้นหาองค์ประกอบในเอกสาร HTML ด้วย CSS Selector และไลบรารี httpx สำหรับส่งคำขอ HTTP แบบอะซิงโครนัส อย่างไรก็ตาม เว็บไซต์บางแห่งแสดงผลเนื้อหาผ่าน JavaScript ต้องใช้เครื่องมือจำลองเบราว์เซอร์ เช่น Playwright เพื่อให้ได้ข้อมูลที่แสดงผลสมบูรณ์

นอกจากนี้ เว็บไซต์หลายแห่งยังเผยแพร่ข่าวผ่าน RSS Feed ซึ่งเป็นรูปแบบ XML มาตรฐานที่ใช้แจกจ่ายเนื้อหาที่อัปเดตเป็นประจำ ทำให้สามารถดึงหัวข้อข่าว ลิงก์ และบทสรุปสั้น ๆ ได้โดยไม่ต้องวิเคราะห์โครงสร้าง HTML โดยตรง [2] ในระบบนี้ใช้ทั้งสองเทคนิคร่วมกันตามความเหมาะสมของแต่ละสำนักข่าว

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่

การสรุปข้อความ (Text Summarization) คือ กระบวนการย่อข้อความต้นฉบับให้สั้นลงโดยยังคงประเด็นสำคัญไว้ โดยแบ่งเป็น 2 แนวทางหลัก ได้แก่ การสรุปแบบ Extract (เลือกประโยคสำคัญจากต้นฉบับ) และการสรุปแบบ Abstractive (เขียนข้อความสรุปขึ้นใหม่ด้วยคำของตนเอง) [3] โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) เช่น GPT และ Gemini ได้รับการฝึกบนคลังข้อมูลจำนวนมาก จึงมีความสามารถในการสรุปแบบ Abstractive ที่เป็นธรรมชาติและแม่นยำ [4]

ในระบบนี้ใช้โมเดลภาษาขนาดใหญ่ผ่านบริการ KGU Gen.AI โดยกำหนด System Prompt ให้โมเดลอ่านเนื้อหาข่าวในรูปแบบ Markdown แล้วส่งคืนบทสรุป ประเด็นสำคัญ อารมณ์ของข่าว และคำสำคัญในรูปแบบ JSON ที่มีโครงสร้างแน่นอน ทำให้ระบบสามารถแปลงผลลัพธ์ไปเก็บในฐานข้อมูลได้โดยตรง [5]

2.1.3 การจำแนกข้อความภาษาไทย

การจำแนกข้อความ (Text Classification) เป็นงานประมวลผลภาษาธรรมชาติที่จัดกลุ่มข้อความตามเนื้อหา ภาษาไทยเป็นภาษาที่ไม่มีการเว้นวรรคระหว่างคำ จึงจำเป็นต้องใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP ซึ่งเป็นไลบรารีประมวลผลภาษาธรรมชาติภาษาไทย [6]

ระบบใช้แนวทางไสบริตรระหว่างกฎคำสำคัญ (Keyword-based Rules) กับการเรียนรู้ของเครื่อง โดยกฎคำสำคัญให้คะแนนตามการพบคำที่เกี่ยวข้องในแต่ละหมวดหมู่

พร้อมนำหน้าของคำที่ยาวและกฎเชิงบริบทร่วม (Compound Rules) ในขณะที่โมเดล SVM ที่ได้รับการฝึกด้วยชุดข้อมูลข้อความภาษาไทยโดยใช้ TF-IDF ทำหน้าที่ตรวจสอบบริบทของข้อความ และระบบจะตัดสินใจใช้ผลจากวิธีที่เหมาะสมที่สุด [7]

2.1.4 การจัดการแคชและคุกกี้

แคช (Cache) คือกลไกการจัดเก็บสำเนาข้อมูลที่ได้จากการดึงหรือคำนวณไว้ชั่วคราว เพื่อให้การเรียกใช้ครั้งถัดไปสามารถตอบสนองได้รวดเร็วขึ้นโดยไม่ต้องทำงานซ้ำ สำหรับระบบรวบรวมข่าวอัตโนมัติที่ทำงานเป็นรอบ การใช้แคชช่วยให้ระบบไม่ต้องดึงหน้าเว็บและบทความเดิมซ้ำในแต่ละรอบ โดยตรวจสอบจากตัวระบุเฉพาะของข่าว เช่น URL ก่อนตัดสินใจว่าจะต้องดึงเนื้อหาใหม่หรือใช้ข้อมูลเดิมจากแคช ทำให้ลดภาระของเว็บไซต์ต้นทางและประหยัดทรัพยากรของเซิร์ฟเวอร์

คุกกี้ (Cookie) คือข้อมูลขนาดเล็กที่เว็บเซิร์ฟเวอร์ส่งให้เบราว์เซอร์เพื่อใช้จดจำสถานะของผู้ใช้หรือเซสชันการเชื่อมต่อ เว็บไซต์ข่าวบางแห่งกำหนดให้เบราว์เซอร์ต้องมีคุกกี้ที่ถูกต้องหรือผ่านการตรวจสอบ เช่น หน้าเพจตรวจสอบของ Cloudflare ก่อนจึงจะแสดงเนื้อหาให้ ระบบนี้จึงต้องจัดการคุกกี้ของเบราว์เซอร์ผ่านการจำลองเบราว์เซอร์ด้วย Playwright [8] และจัดเก็บคุกกี้ไว้ใช้ในการดึงข้อมูลครั้งถัดไป เพื่อให้สามารถดึงข่าวจากเว็บไซต์ดังกล่าวได้อย่างถูกต้องและต่อเนื่องโดยไม่ต้องเริ่มต้นเซสชันใหม่ทุกครั้ง

นอกจาก การ จัดการ คุกกี้ เพื่อ การ ดึง ข้อมูล แล้ว ระบบ ยัง ใช้ คุกกี้ เพื่อวัตถุประสงค์ในการปรับแต่งประสบการณ์ของผู้ใช้อีกสองประการ ประการแรกคือ **คุกกี้เพื่อการปรับแต่งเฉพาะบุคคล (Personalize Cookies)** ซึ่งใช้จัดเก็บค่ากำหนดของผู้ใช้ เช่น หมวดหมู่ข่าวที่ต้องการติดตามเป็นพิเศษ ภาษาในการแสดงผล รูปแบบการแสดงผลข่าว หรือรายการข่าวที่ผู้ใช้บันทึกไว้ เพื่อให้ผู้ใช้แต่ละคนได้รับมุมมองและเนื้อหาที่ตรงกับความต้องการของตนเองเมื่อเข้าใช้งานระบบในครั้งถัดไป ประการที่สองคือ **คุกกี้เพื่ออัลกอริทึม (Algorithm Cookies)** ซึ่งใช้บันทึกพฤติกรรมการอ่านข่าว เช่น หมวดหมู่ข่าวที่ผู้ใช้คลิกอ่านบ่อย ข่าวที่ใช้เวลาอ่านนาน หรือข่าวที่ผู้ใช้กดบันทึกหรือแชร์ ข้อมูลพฤติกรรมเหล่านี้จะถูกส่งให้อัลกอริทึมแนะนำข่าว (Recommendation Algorithm) เพื่อวิเคราะห์ความสนใจและคัดสรรข่าวที่เกี่ยวข้องมากที่สุดมาแสดงเป็นลำดับแรกบนหน้าเว็บ ซึ่งช่วยเพิ่มความเกี่ยวข้องของเนื้อหาและประสบการณ์การใช้งานที่ดียิ่งขึ้นสำหรับผู้ใช้แต่ละคน

2.1.5 อัลกอริทึมการกำหนดคุกกี้ (Assign Cookies Algorithm)

เพื่อให้คุกกี้สามารถสะท้อนความสนใจของผู้ใช้ได้อย่างเป็นปัจจุบัน ระบบจึงออกแบบอัลกอริทึมการกำหนดคุกกี้ที่ทำงานเป็นลำดับขั้นตอน ดังนี้

- 1) **สร้างคุกกี้เริ่มต้น (Initialization):** เมื่อผู้ใช้เข้าใช้งานครั้งแรก ระบบสร้างตัวระบุเฉพาะของผู้ใช้ (Anonymous Cookie ID) และกำหนดคุกกี้เริ่มต้น โดยค่าเริ่มต้นของความสนใจแต่ละหมวดหมู่ถูกตั้งไว้เท่ากัน เพื่อให้ผลการแนะนำไม่เอนเอียง

- 2) **บันทึกพฤติกรรมการอ่าน (Logging):** ทุกครั้งที่ผู้ใช้คลิกเปิดข่าว ใช้เวลาในการอ่าน กดบันทึก หรือแชร์ข่าว ระบบจะบันทึกเหตุการณ์ (Event) พร้อมข้อมูลหมวดหมู่ของข่าวนั้น และเพิ่มข้อมูลที่สะสมของแต่ละหมวดหมู่ลงในคุกกี้เพื่ออัลกอริทึม
- 3) **คำนวณคะแนนความสนใจ (Interest Score):** อัลกอริทึมคำนวณคะแนนความสนใจของแต่ละหมวดหมู่โดยถ่วงน้ำหนักจากข้อมูลที่เข้าชม เวลารวมที่ใช้ในการอ่าน และการกระทำที่แสดงความสนใจสูง เช่น การกดบันทึกหรือแชร์ โดยหมวดหมู่ที่ถูกอ่านถี่และใช้เวลานานจะได้รับคะแนนสูง
- 4) **กำหนดคุกกี้ปรับแต่งเฉพาะบุคคล (Assign Personalize Cookie):** เมื่อคะแนนความสนใจของหมวดหมู่ใดถึงเกณฑ์ที่กำหนด อัลกอริทึมจะอัปเดตคุกกี้ปรับแต่งให้รวมหมวดหมู่ดังกล่าวไว้ในรายการหมวดหมู่ที่ผู้ใช้สนใจเป็นพิเศษ และปรับลำดับการนำเสนอข่าวและภาษาที่เหมาะสมให้สอดคล้องกับค่ากำหนดของผู้ใช้
- 5) **กำหนดคุกกี้อัลกอริทึมแนะนำข่าว (Assign Algorithm Cookie):** ระบบนำคะแนนความสนใจที่คำนวณได้ทั้งหมดไปเข้ารหัสและจัดเก็บลงในคุกกี้เพื่ออัลกอริทึม โดยคุกกี้ทำหน้าที่เป็นข้อมูลนำเข้าของบริการแนะนำข่าว (Recommendation) ใช้เรียงลำดับข่าวจากหมวดหมู่ที่มีความสนใจสูงไปต่ำก่อนแสดงบนหน้าเว็บ และใช้เป็นน้ำหนักในการจัดอันดับข่าวแบบเรียลไทม์ในครั้งถัดไป
- 6) **ป้องกันการเอนเอียงของข้อมูล (□□ Filter Bubble):** เพื่อไม่ให้ผู้ใช้เห็นเฉพาะข่าวที่ระบบคิดว่าชอบจนเกิดปรากฏการณ์ Filter Bubble อัลกอริทึมจะนำเสนอข่าวจากหมวดหมู่อื่นในสัดส่วนที่กำหนดไว้ด้วย พร้อมทั้งกำหนดอายุการหมดอายุของคุกกี้ให้สั้น (Session Expiry) เพื่อไม่ให้คุกกี้คงอยู่ตลอดไปและลดความเสี่ยงด้านความเป็นส่วนตัว

การทำงานของอัลกอริทึมการกำหนดคุกกี้ข้างต้นเป็นการประสานระหว่างคุกกี้เพื่อการปรับแต่งเฉพาะบุคคล คุกกี้เพื่ออัลกอริทึม และบริการแนะนำข่าวเข้าไว้ด้วยกัน เพื่อให้ระบบสามารถปรับเปลี่ยนประสบการณ์การอ่านข่าวให้ตรงกับความต้องการของผู้ใช้แต่ละคนได้อย่างต่อเนื่องและปลอดภัย

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้จะนำเสนองานวิจัยหรือระบบที่มีลักษณะ คล้ายคลึงกับโครงงานนี้ เพื่อเป็นแนวทางในการพัฒนา โดยพิจารณาครอบคลุมในด้านการสกัดเนื้อหาจากเว็บ การสรุปข้อความ และการจำแนกหมวดหมู่ข่าว

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ

Barbaresi [1] ได้พัฒนาไลบรารี Trafilatura สำหรับสกัดข้อความหลักออกจากหน้าเว็บโดยอัตโนมัติ โดยไม่ขึ้นกับเว็บไซต์ใดเว็บไซต์หนึ่ง ไลบรารีนี้รองรับการจัดรูปแบบ HTML ที่หลากหลายและคืนข้อความในรูปแบบ Markdown ซึ่งเป็นประโยชน์โดยตรงต่อการนำเนื้อหาไปใช้กับโมเดลภาษาขนาดใหญ่ อย่างไรก็ตาม วิธีนี้มีข้อจำกัดเมื่อเนื้อหาถูกรบกวนด้วย JavaScript บางกรณี ทำให้ระบบนี้ต้องเสริมด้วยการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์กลุ่มดังกล่าว

2.2.2 งานสรุปข้อความอัตโนมัติ

Allahyari และคณะ [3] ได้สำรวจเทคนิคการสรุปข้อความอย่างเป็นระบบทั้งแบบ Extract และ Abstractive และชี้ให้เห็นว่าการสรุปแบบ Abstractive ที่ใช้การเรียนรู้เชิงลึกให้ผลลัพธ์ที่เป็นธรรมชาติกว่าอย่างมีนัยสำคัญ แต่ต้องใช้ทรัพยากรในการคำนวณสูง ด้วยความก้าวหน้าของโมเดลภาษาขนาดใหญ่ [4] การสรุปแบบ Abstractive จึงเข้าถึงได้ง่ายผ่าน API โดยไม่ต้องฝึกโมเดลเอง โครงการนี้จะเลือกใช้แนวทางดังกล่าวเพื่อสรุปข่าวเป็นภาษาไทยด้วยต้นฉบับโดยไม่ต้องใช้ทรัพยากรฝึกโมเดลของตนเอง

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย

งานวิจัยด้านการจำแนกข้อความภาษาไทยมักประสบปัญหาการเว้นวรรคคำ จึงนิยมใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP [6] ร่วมกับโมเดลแมชชีนเลิร์นนิง เช่น SVM กับคุณลักษณะ TF-IDF ซึ่งเป็นแนวทางที่มีประสิทธิภาพและใช้ทรัพยากรต่ำ โครงการนี้ประยุกต์ใช้แนวทางไฮบริด โดยใช้กฎคำสำคัญที่มีน้ำหนักและลำดับความสำคัญของ URL สำหรับการจำแนกแบบรวดเร็ว และใช้โมเดล SVM เป็นตัวตรวจสอบบริบทสำหรับหมวดหมู่ที่กฎคำสำคัญมีความแม่นยำไม่เพียงพอ

2.2.4 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จาก การ ทบทวน วรรณกรรม ข้าง ต้น สามารถ สรุป ผล การ เปรียบ เทียบ คุณสมบัติได้ดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง

งานวิจัย	สกัดเนื้อหา	สรุป LLM	จำแนกหมวด	Realtime	แคช/คุกกี้	อัล
Trafilatura [1]	✓	—	—	—	—	
งานสรุปข้อความ [3]	—	✓	—	—	—	
งานจำแนกข้อความภาษาไทย [6]	—	—	✓	—	—	
โครงการนี้	✓	✓	✓	✓	✓	

จากตารางที่ 1 พบว่ายังไม่มีงานใดที่ผสมผสานการสกัดเนื้อหา การสรุปด้วยโมเดลภาษาขนาดใหญ่ การจำแนกหมวดหมู่ การแสดงผลแบบเรียลไทม์ การจัดการแคชและคุกกี้ และอัลกอริทึมแนะนำข่าวในระบบเดียวครบทุกด้าน โครงการนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่รวบรวมคุณสมบัติทั้งหมดไว้ในระบบเดียวอย่างครบถ้วน

2.2.5 เทคโนโลยีและเครื่องมือที่เกี่ยวข้อง

(1) FastAPI

FastAPI เป็นเฟรมเวิร์คภาษา Python สำหรับพัฒนา REST API ที่มีประสิทธิภาพสูง รองรับการเขียนแบบอะซิงโครนัส (Asynchronous) และสร้างเอกสาร API อัตโนมัติ ใช้สำหรับสร้าง REST API และให้บริการไฟล์ด้านหน้าเว็บในระบบนี้

(2) Playwright

Playwright เป็น เครื่องมือ สำหรับ ควบคุม เบราร์เซอร์ Chromium ผ่านโปรแกรม ใช้สำหรับดึงข้อมูลจากเว็บไซต์ที่แสดงผลเนื้อหาผ่าน JavaScript ซึ่งวิธี HTTP ทั่วไปไม่สามารถเข้าถึงได้

(3) PyThaiNLP

PyThaiNLP เป็นไลบรารีประมวลผลภาษาธรรมชาติภาษาไทย ประกอบด้วยเครื่องมือตัดคำ แปลงตัวเลข และข้อมูลพจนานุกรมภาษาไทย ใช้ในการตัดคำภาษาไทยเพื่อการจำแนกหมวดหมู่ข่าว

(4) Socket.IO

Socket.IO เป็นไลบรารีสำหรับการสื่อสารแบบเรียลไทม์แบบสองทิศทางระหว่างเว็บเบราว์เซอร์และเซิร์ฟเวอร์ผ่าน WebSocket ใช้สำหรับแจ้งเตือนและแสดงผลข่าวใหม่ทันทีที่ระบบดึงข่าวได้

(5) KKU Gen.AI

KKU Gen.AI เป็น บริการ โมเดล ภาษา ขนาด ใหญ่ ของมหาวิทยาลัยขอนแก่นที่ให้ บริการ ผ่าน API แบบ รองรับ OpenAI-compatible ใช้สำหรับการสรุปเนื้อหาข่าวและสกัดประเด็นสำคัญของระบบ

(6) กลไกแคช (Cache Mechanism)

กลไกแคชใช้สำหรับจัดเก็บสำเนาข้อมูลข่าวและเนื้อหาที่ดึงมาแล้ว โดยใช้ตัวระบุเฉพาะของข่าว เช่น URL เป็นกุญแจแคช เพื่อหลีกเลี่ยงการดึงข้อมูลซ้ำจากเว็บไซต์ต้นทางในรอบการทำงานถัดไป ช่วยลดภาระของเว็บไซต์ต้นทางและประหยัดทรัพยากรของเซิร์ฟเวอร์

(7) ระบบคุกกี้ (Cookie System)

ระบบคุกกี้ใช้สำหรับจัดเก็บข้อมูลสถานะของผู้ใช้และเซสชันการเชื่อมต่อ ทั้งเพื่อกงสถานะการดึงข้อมูลจากเว็บไซต์ที่ต้องใช้คุกกี้หรือการตรวจสอบเบราว์เซอร์และเพื่อจัดเก็บค่ากำหนดเฉพาะบุคคลและข้อมูลพฤติกรรมกรรมการอ่านสำหรับอัลกอริทึมแนะนำข่าว

(8) อัลกอริทึมแนะนำข่าว (Recommendation Algorithm)

อัลกอริทึมแนะนำข่าวใช้ข้อมูลความสนใจที่บันทึกไว้ในคุกกี้เพื่อวิเคราะห์และคัดสรรข่าวที่เกี่ยวข้องมากที่สุดมาแสดงเป็นลำดับแรกบนหน้าเว็บ โดยคำนวณ

คะแนนความสนใจของแต่ละหมวดหมู่จากความถี่การเข้าชม เวลาที่ใช้อ่าน และการกระทำที่แสดงความสนใจ เช่น การกดบันทึกหรือแชร์

บทที่ 3

วิธีการดำเนินโครงการ

3.1 ขั้นตอนการดำเนินงาน

โครงการนี้ดำเนินงานตามหลักการวิศวกรรมซอฟต์แวร์ โดยแบ่งขั้นตอนการดำเนินงานเป็น 5 ขั้นตอนหลัก ดังนี้

3.1.1 ศึกษาปัญหาและรวบรวมความต้องการ

ศึกษาและวิเคราะห์ปัญหาในการติดตามข่าวสารจากหลายสำนักข่าวไทย รวบรวมความต้องการเชิงฟังก์ชันและไม่ใช้เชิงฟังก์ชันของระบบ ศึกษาโครงสร้างเว็บไซต์และ RSS Feed ของสำนักข่าวเป้าหมาย กำหนดชุดหมวดหมู่ข่าว และเลือกใช้โมเดลภาษาขนาดใหญ่ผ่านบริการ KKU Gen.AI

3.1.2 วิเคราะห์และออกแบบระบบ

วิเคราะห์ความต้องการ และ ออกแบบ สถาปัตยกรรมของระบบแบบแบ่งชั้น (Layered Architecture) ตามหลักการ SOLID และ GRASP ประกอบด้วยชั้น Routers, Services, Scrapers, Repository และ Core โดยกำหนดแผนภาพ Use Case Diagram สำหรับผู้ใช้งานและระบบ ออกแบบโครงสร้างข้อมูลข่าวด้วย Pydantic Model และกำหนดโปรโตคอล Repository ด้วย Python Protocol เพื่อความยืดหยุ่นในการเปลี่ยนวิธีจัดเก็บข้อมูล พร้อมทั้งออกแบบโครงสร้างอัลกอริทึมการกำหนดคุกกี้ (Assign Cookies Algorithm) เพื่อใช้เป็นกลไกหลักในการคำนวณความสนใจและปรับเปลี่ยนเนื้อหาให้สอดคล้องกับพฤติกรรมผู้ใช้แต่ละคน

3.1.3 พัฒนาระบบ

พัฒนาระบบตามทีออกแบบไว้ โดยใช้ภาษา Python ร่วมกับเฟรมเวิร์ค FastAPI สำหรับฝั่ง Backend พัฒนา Scraper สำหรับแต่ละสำนักข่าวด้วยการลงทะเบียนแบบ Decorator พัฒนาบริการสรุปข่าวโดยส่งเนื้อหา Markdown ไปยังโมเดลภาษาขนาดใหญ่ พัฒนาบริการจำแนกหมวดหมู่ด้วย PyThaiNLP ร่วมกับโมเดล SVM และพัฒนา Frontend ด้วย JavaScript แบบ Vanilla ร่วมกับ Tailwind CSS และ Socket.IO สำหรับการแสดงผลแบบเรียลไทม์

นอกจากนี้ ยังพัฒนา กลไก แคช เพื่อจัดเก็บ ข่าว และ เนื้อหาที่ดึงมาแล้ว โดยใช้ URL เป็นกุญแจแคช เพื่อหลีกเลี่ยงการดึงข้อมูลซ้ำในแต่ละรอบการทำงาน และ พัฒนาระบบจัดการคุกกี้สามประเภท ได้แก่ (1) คุกกี้เพื่อการดึงข้อมูล ร่วมกับ Playwright Service เพื่อคงสถานะเซสชันของเบราว์เซอร์สำหรับการดึงข้อมูลจากเว็บไซต์ที่แสดงผลเนื้อหาผ่าน JavaScript หรือมีกลไกตรวจสอบเบราว์เซอร์ (2) คุกกี้เพื่อการปรับแต่งเฉพาะบุคคล (Personalize Cookies) สำหรับจัดเก็บค่ากำหนดของผู้ใช้ เช่น หมวดหมู่ที่สนใจและการตั้งค่าการแสดงผล และ (3) คุกกี้เพื่ออัลกอริทึม (Algorithm Cookies) สำหรับบันทึกพฤติกรรมการอ่านเพื่อป้อนข้อมูลให้อัลกอริทึมแนะนำข่าว

3.1.4 ทดสอบและประเมินผล

ทดสอบแต่ละส่วนของระบบด้วยการตรวจสอบโค้ดด้วย Ruff และตรวจสอบชนิดข้อมูลด้วย mypy ทดสอบการทำงานของ Repository และ Service ด้วยหน่วยทดสอบ (Unit Test) ทดสอบการดึงข่าวของแต่ละสำนักข่าวว่าสามารถดึงข้อมูลได้ครบถ้วน และประเมินความถูกต้องของบทสรุปจากโมเดลภาษาขนาดใหญ่และความถูกต้องของการจำแนกหมวดหมู่ข่าว รวมถึงทดสอบการแจ้งเตือนข่าวแบบเรียลไทม์ผ่าน WebSocket

3.1.5 ปรับปรุงและสรุปผล

ปรับปรุงระบบตามผลการทดสอบ จัดทำเอกสารรายงานโครงการและคู่มือการใช้งาน และสรุปผลการดำเนินงานเทียบกับวัตถุประสงค์ที่กำหนดไว้

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาโครงการแสดงดังตารางที่ 2

ตารางที่ 2 รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา

ลำดับ	รายการ	รายละเอียด
1	คอมพิวเตอร์ส่วนบุคคล	CPU Intel Core Ultra 5, RAM 16 GB, SSD 512 GB
2	จอภาพ	ขนาด 16 นิ้ว
3	การเชื่อมต่ออินเทอร์เน็ต	ความเร็วไม่น้อยกว่า 30 Mbps ใช้ดึงข่าวและเรียกใช้บริการ KKU Gen.AI

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์ที่ใช้ในการพัฒนาโครงการแสดงดังตารางที่ 3

ตารางที่ 3 รายการซอฟต์แวร์ที่ใช้ในการพัฒนา

ลำดับ	ซอฟต์แวร์	เวอร์ชัน	วัตถุประสงค์
1	Windows/Linux	...	สภาพแวดล้อมการพัฒนา
2	Python	3.10 ขึ้นไป	พัฒนาระบบ Backend
3	FastAPI + Uvicorn	...	พัฒนา REST API และเว็บเซิร์ฟเวอร์
4	httpx + BeautifulSoup4	...	ดึงและวิเคราะห์หน้าเว็บ
5	Trafilatura	...	สกัด เนื้อหา บทความ เป็น Mark-down
6	Playwright	...	ดึงข้อมูลเว็บไซต์ที่ใช้ JavaScript
7	PyThaiNLP	...	ตัด คำ ภาษา ไทย สำหรับ จำแนกหมวดหมู่
8	scikit-learn, joblib	...	โมเดล SVM/TF-IDF จำแนกหมวด
9	OpenAI SDK	...	เรียกใช้โมเดล LLM สรุปข่าว
10	python-socketio	...	แจ้งเตือนข่าวแบบเรียลไทม์
11	Node.js + Tailwind CSS	18+ / ...	พัฒนา Frontend
12	Git + GitHub	...	จัดการเวอร์ชันของซอฟต์แวร์
13	Docker	...	จัดการบริการ Playwright Service
14	กลไกแคช (Cache)	...	จัดเก็บข้อมูลที่ดึงแล้ว ลดการดึงข้อมูลซ้ำ และเพิ่มความเร็วในการแสดงผล
15	ระบบคุกกี้และอัลกอริทึมแนะนำ	...	จัด เก็บ ค่า กำหนด ผู้ ใช้ บันทึกพฤติกรรมกรรมการอ่าน และแนะนำข่าวเฉพาะบุคคล

3.3 แผนการดำเนินงาน

แผนการดำเนินงานตลอดระยะเวลาการทำงานตั้งแต่วันที่เดือนมิถุนายนถึงตุลาคม แบ่งออกเป็นช่วงการพัฒนาวิศวกรรมระบบจริง (มิถุนายน – สิงหาคม) และช่วงการประเมินผล แบบสำรวจความพึงพอใจ และสรุปผลโครงการ (กันยายน – ตุลาคม) แสดงดังตารางที่ 4

ตารางที่ 4 แผนการดำเนินงานและไทม์ไลน์ของโครงการ (Gantt Chart)

ลำดับ	กิจกรรม / ขั้นตอนการดำเนินงาน	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
ส่วนที่ 1: การศึกษา ออกแบบ และพัฒนาวิศวกรรมระบบ (ดำเนินการแล้วเสร็จ)						
1	ศึกษาปัญหา รวบรวมความต้องการ และออกแบบสถาปัตยกรรมระบบ	●				
2	พัฒนาระบบ Scraper Pipeline, Playwright Service และ Multi-tier Cache	●	●			
3	ฝึกสอน/ปรับปรุงโมเดลจำแนกข่าว 9 หมวดหมู่ และเชื่อมต่อ KKU Gen.AI API		●	●		
4	พัฒนาเว็บแอปพลิเคชัน Single Page Application (SPA), PWA และ WebSocket		●	●		
5	พัฒนาระบบ จัดอันดับ Trending/ Hot News, ความปลอดภัย และ PDPA			●		
6	ทดสอบระบบเชิงเทคนิคอัตโนมัติ (Automated Unit Tests, Stress Tests)			●		
ส่วนที่ 2: การประเมินผล แบบสำรวจ และจัดทำเอกสารปิดโครงการ (แผนการดำเนินงาน)						
7	ออกแบบและจัดทำแบบสำรวจความพึงพอใจการใช้งาน (User Survey / Questionnaire)				●	
8	ดำเนินการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing: UAT) และเก็บข้อมูล				●	●
9	วิเคราะห์ข้อมูลสถิติผลการประเมิน สรุปข้อเสนอแนะ และปรับแต่งระบบขั้นสุดท้าย					●
10	จัดทำเอกสารรายงานโครงการฉบับสมบูรณ์และเตรียมการนำเสนอโครงการ					●

เอกสารอ้างอิง

- [1] A. Barbaresi, “Trafilatura: A python package for text and web scraping,” in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations*, pp. 105–112, Association for Computational Linguistics, 2021.
- [2] D. Winer, “Rss 2.0 specification.” <https://www.rssboard.org/rss-specification>, 2009. Accessed: 2025-01-10.
- [3] M. Allahyari, S. Pouriyeh, M. Assefi, S. Safaei, E. D. Trippe, J. B. Gutierrez, and K. Kochut, “Text summarization techniques: A brief survey,” *arXiv preprint arXiv:1707.02268*, 2017.
- [4] G. D. G. Team, “Gemini: A family of highly capable multimodal models,” *arXiv preprint arXiv:2312.11805*, 2024.
- [5] OpenAI, “Openai platform documentation.” <https://platform.openai.com/docs>, 2024. Accessed: 2025-01-10.
- [6] W. Phatthiyaphaibun, K. Chaovavanich, *et al.*, “Pythainlp: Thai natural language processing in python framework.” <https://doi.org/10.5281/zenodo.3519354>, 2021. Accessed: 2025-01-10.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [8] Microsoft, “Playwright: Fast and reliable cross-browser testing.” <https://playwright.dev>, 2024. Accessed: 2025-01-10.

ภาคผนวก ก
ตัวอย่าง UI หรือ Prototype

ภาพหน้าจอระบบ

ภาคผนวกนี้แสดงตัวอย่างหน้าจอของระบบที่พัฒนาขึ้น เพื่อให้เห็นภาพรวมของการออกแบบส่วนติดต่อกับผู้ใช้

หน้าจอเข้าสู่ระบบ (Login) แสดงดังภาพที่ 1



ภาพที่ 1 หน้าจอเข้าสู่ระบบ (Login)

หน้าจอหลัก (Dashboard) แสดงดังภาพที่ 2



ภาพที่ 2 หน้าจอหลัก (Dashboard)

คู่มือการใช้งาน

อธิบายขั้นตอนการใช้งานระบบโดยสังเขป...