

CS3-7

รายงานทางความก้าวหน้าโครงงาน ครั้งที่ 1

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท

Category-Specific News Classification and NLP Analytics Pipeline

โดย
663380214-4 นายนราวิชญ์ ศิริพล
663380028-1 นายอัสดาวุฒิ เอื้อวงค์

อาจารย์ที่ปรึกษา
อ.ดร.พบพร ด่านวิรุทัย

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
วิชา CP354 772 โครงงานคอมพิวเตอร์ 2
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2569

นราวิชญ์ ศิริพล และ อัสดาวุฒิ เอื้อวงค์. 2569. **ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.พบพร ด่านวิรุทัย

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อศึกษา ออกแบบ และพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific News Classification and NLP Analytics Pipeline) ที่ครอบคลุมการทำงานตั้งแต่การรวบรวมข่าวสารจากหลายสำนักข่าว การสกัดเนื้อหา การสรุปความ การจำแนกหมวดหมู่ การวิเคราะห์แนวโน้มความนิยม และการนำเสนอข้อมูลแบบเรียลไทม์ โดยสถาปัตยกรรมระบบได้รับการออกแบบตามหลักการ SOLID และ GRASP แบ่งการทำงานเป็นเลเยอร์อย่างเป็นระเบียบ ส่วนบริการเบื้องหลัง (Backend) พัฒนาด้วยภาษา Python และ FastAPI รองรับการดึงข้อมูลทั้งจาก RSS Feed และการสกัดหน้าเว็บผ่าน Playwright Headless Browser พร้อมระบบแคชแบบหลายระดับ (Multi-tier Caching: หน่วยความจำและ HTTP 304) เพื่อลดภาระการเชื่อมต่อ การสรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าว (Sentiment) ทำงานร่วมกับโมเดลภาษาขนาดใหญ่ (LLM) ผ่าน KKU Gen.AI API ขณะที่การจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่หลักใช้แนวทางไฮบริดผสานกฎคำสำคัญเชิงบริบท (Rule-based Cues) ร่วมกับโมเดลการเรียนรู้ของเครื่อง (SVM/TF-IDF และ WangchanBERTa) ส่วนติดต่อผู้ใช้ (Frontend) พัฒนาด้วยรูปแบบ Single Page Application (SPA) ด้วย Vanilla JavaScript แบบ ES Modules และ Tailwind CSS สื่อสารกับเซิร์ฟเวอร์แบบเรียลไทม์ผ่าน WebSocket (Socket.IO) พร้อมฟังก์ชันหน้าต่างอ่านข่าวในระบบ (In-app Reader Modal) และระบบแนะนำข่าวสารตามความสนใจเฉพาะบุคคลโดยคำนึงถึงความเป็นส่วนตัวตามมาตรฐาน PDPA จากผลการประเมินการทำงานพบว่าระบบสามารถทำงานได้อย่างมีเสถียรภาพ ตอบสนองคำขอรวดเร็ว และช่วยลดเวลาในการติดตามข่าวสารจากหลากหลายแหล่งได้อย่างมีประสิทธิภาพ

คำสำคัญ: การจำแนกข่าว, การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เว็บสแครปปิง, โมเดลภาษาขนาดใหญ่, อัลกอริทึมแนะนำข่าว

Narawit Siripol and Ausadawut Aueawong. 2026. **Category-Specific News Classification and NLP Analytics Pipeline.** Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Dr. Pobporn Danvirutai

ABSTRACT

This project aims to study, design, and develop an automated Category-Specific News Classification and NLP Analytics Pipeline. The system covers an end-to-end workflow including multi-source news aggregation, content extraction, summarization, category classification, trend analytics, and real-time delivery. The architecture is engineered according to SOLID and GRASP software design principles with clearly decoupled layers. The backend is implemented in Python using FastAPI, supporting automated extraction from both standard RSS feeds and dynamic JavaScript-heavy websites via a Playwright headless browser instance. A multi-tier caching strategy (combining in-memory LRU caching and HTTP 304 conditional cache) is employed to minimize network overhead and redundant processing. For content summarization and sentiment analysis, the system integrates with Large Language Models (LLMs) via the KKU Gen.AI API to generate concise summaries, bullet points, and sentiment scores in the article's native language. Thai text classification into nine specialized categories is executed through a hybrid pipeline combining contextual keyword-based cues with machine learning models (TF-IDF with SVM and WangchanBERTa). The frontend is built as a responsive Single Page Application (SPA) using Vanilla JavaScript ES modules and Tailwind CSS, communicating bidirectionally with the server via WebSocket (Socket.IO). It provides an in-app modal reader, trending topic visualization, and privacy-compliant personalized recommendations based on aggregate engagement metrics under PDPA standards. The evaluation results demonstrate that the pipeline operates with high stability, low latency, and significantly reduces the effort required for readers to follow diverse news outlets.

Keywords: News classification, Text analytics, Natural language processing, Web scraping, Large language model, Recommendation algorithm

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อ.ดร.พบพร ด่านวิรุทัย อาจารย์ที่ปรึกษาโครงงาน ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงงานฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงงานนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอขอบพระคุณคณาจารย์ในสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจ ตลอดระยะเวลาของการศึกษา

ผู้จัดทำ
นราวิชญ์ ศิริพล
อัสดาวุฒิ เอื้อวงค์

สารบัญ

บทคัดย่อ **ก**

ABSTRACT **ข**

กิตติกรรมประกาศ **ค**

สารบัญ **ง**

สารบัญภาพ **ซ**

สารบัญตาราง **ฌ**

1 บทนำ **1**
1.1 ความเป็นมาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 1
1.3 ขอบเขตและข้อจำกัดของระบบ 2
1.3.1 ขอบเขต 2
1.3.2 ข้อจำกัดของโครงงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง **5**
2.1 ทฤษฎีที่เกี่ยวข้อง 5
2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ . 5
2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ 5
2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF 6
2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (Wangchan-BERTa) 6
2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว 7
2.2 งานวิจัยที่เกี่ยวข้อง 7
2.2.1 งานสกัดเนื้อหาบทความจากเว็บ 7
2.2.2 งานสรุปข้อความอัตโนมัติ 7
2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย 8
2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms) 8
2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus) 8

2.2.6 งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation) 9
2.2.7 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 9
2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales) 9
2.3.1 FastAPI 10
2.3.2 Pydantic 10
2.3.3 Playwright (Chromium Headless Browser) 10
2.3.4 PyThaiNLP 10
2.3.5 Socket.IO 10
2.3.6 ระบบจำลองเบราว์เซอร์แยกส่วนและเทคโนโลยี Obscura (Isolated Obscura CDP Engine) 10
2.3.7 ระบบจัดเก็บข้อมูลหลายรูปแบบตามหลัก SOLID/GRASP (Multi-Engine Persistence) 11
2.3.8 ระบบแคชหลายระดับ (Multi-tier Cache Strategy) 11

3 วิธีการดำเนินโครงงาน 12
3.1 การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส 12
3.1.1 ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing) 12
3.1.2 วิธีการฝึกสอนโมเดล (Model Training Methodology) . . 12
3.1.3 ผลการประเมินประสิทธิภาพและเมตริกวัดผล 12
3.1.4 เมทริกซ์ความสับสน (Confusion Matrix) 13
3.1.5 การประเมินประสิทธิภาพการจัดกลุ่มข่าวแบบสองชั้น (Two-Layer Story Identification Benchmark) 13
3.1.6 แบบจำลองยูสเคส (Use Case Diagram) 14
3.2 เครื่องมือที่ใช้ในการดำเนินงาน 15
3.2.1 ฮาร์ดแวร์ 15
3.2.2 ซอฟต์แวร์ 15
3.3 แผนการดำเนินงาน 17

4 การวิเคราะห์ ออกแบบและพัฒนาระบบ 18
4.1 การวิเคราะห์ระบบ 18
4.1.1 ผังแสดงทิศทางของกิจกรรม (Activity Flow) 18
4.1.2 แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram) . 20
4.1.3 รายการความต้องการของระบบ 20
4.2 การออกแบบระบบ 22
4.2.1 สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture) 22
4.2.2 การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล 23
4.3 การพัฒนาระบบและการทำงานของส่วนประกอบหลัก 25
4.3.1 กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline) 25

4.3.2 ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier) . . . 26
4.3.3 ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และเอนจินจำลองเบราว์เซอร์ Obscura . . . 26
4.3.4 ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline) . . . 26
4.3.5 สถาปัตยกรรมระบุประเด็นข่าวและจัดอันดับกระแสข่าวแบบสองชั้น (Two-Layer Story Identification & Deterministic Trending) . . . 27
4.3.6 ส่วนนำเสนอและการสังเคราะห์เนื้อหาประเด็นรวม (Story Presentation & LLM Synthesis) . . . 29
4.3.7 การจัดกลุ่มมหากาพย์ประเด็นข่าวและส่วนติดต่อผู้ใช้แบบ Bento Hub . . . 29
4.3.8 การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket . . . 30
4.4 การออกแบบและมาตรการความมั่นคงปลอดภัยของระบบ (System Security Design) . . . 30
4.4.1 ความมั่นคงปลอดภัยระดับเครือข่ายและเว็บเซิร์ฟเวอร์ (Network & Gateway Security) . . . 30
4.4.2 การป้องกันการฉีดโค้ดอันตรายและการตรวจสอบข้อมูล (Data Sanitization & Injection Defense) . . . 30
4.4.3 การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security) . . . 31
4.4.4 การจัดการความลับและการตั้งค่าระบบ (Secrets & Configuration Management) . . . 31
4.5 การทดสอบระบบ . . . 31
4.5.1 การทดสอบอัตโนมัติ (Automated Test Suite) . . . 31
4.5.2 ผลการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing) . . . 32

5 สรุปผลการดำเนินงาน 34
5.1 สรุปผลการดำเนินโครงงาน . . . 34
5.2 ข้อจำกัดของระบบ . . . 35
5.2.1 ข้อจำกัดด้านแหล่งข้อมูลภายนอกและบริการโมเดลภาษาขนาดใหญ่ . . . 35
5.2.2 ข้อจำกัดด้านทรัพยากรการประมวลผล . . . 36
5.2.3 ข้อจำกัดด้านการรู้จำชื่อเฉพาะในบริบทภาษาไทย . . . 36
5.3 ปัญหา อุปสรรค และแนวทางแก้ไข . . . 36
5.4 ข้อเสนอแนะในการพัฒนาต่อไป . . . 37
5.4.1 การปรับปรุงฟังก์ชันการทำงาน . . . 37
5.4.2 แนวทางการวิจัยต่อยอด . . . 38

เอกสารอ้างอิง 39

ภาคผนวก ก: คู่มือการติดตั้งและการใช้งานระบบ 42

ภาคผนวก ข: ข้อกำหนด REST API และ WebSocket Events 44

สารบัญภาพ

ภาพที่ 1 แผนภาพแบบจำลองยูสเคสของระบบ (Use Case Diagram) 15
ภาพที่ 2 แผนภาพแสดงทิศทางกิจกรรมของระบบ (Activity Diagram) 19
ภาพที่ 3 แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram) . . . 20
ภาพที่ 4 แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architecture Diagram) 22

สารบัญตาราง

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง 9
ตารางที่ 2 เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set) 13
ตารางที่ 3 เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k) 13
ตารางที่ 4 ผลการประเมินเปรียบเทียบประสิทธิภาพการจัดกลุ่มข่าวสารข้ามสำนัก . 14
ตารางที่ 5 รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา 15
ตารางที่ 6 รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions) 16
ตารางที่ 7 แผนการดำเนินงานและไทม์ไลน์ของโครงงาน (Gantt Chart) 17
ตารางที่ 8 ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements) . . . 21
ตารางที่ 9 การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers) . 23
ตารางที่ 10 โครงสร้างข้อมูลบทความข่าว (`NewsArticle` Schema) 24
ตารางที่ 11 โครงสร้างข้อมูลกลุ่มประเด็นข่าวสาร (`StoryRecord` Schema) . . . 25
ตารางที่ 12 ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing) . . 33
ตารางที่ 13 สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์ 35
ตารางที่ 14 ปัญหา อุปสรรค และแนวทางการแก้ไข 37
ตารางที่ 15 รายละเอียด REST API Endpoints ของระบบ 44
ตารางที่ 16 รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time . 44

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน ข่าวสารเป็นข้อมูลสำคัญที่ช่วยให้ประชาชนรับรู้และติดตามเหตุการณ์ได้อย่างทันท่วงที โดยเฉพาะอย่างยิ่งในยุคที่ข้อมูลมีการเปลี่ยนแปลงตลอดเวลา อย่างไรก็ตาม ผู้อ่านที่ต้องการติดตามข่าวสารจากหลายแหล่งมักประสบปัญหาหลายประการ ได้แก่ ต้องเปิดเว็บไซต์หรือแอปพลิเคชันหลายแห่งเพื่อเปรียบเทียบข่าวเดียวกัน ทำให้เสียเวลาและเกิดความยุ่งยากในการติดตามสถานการณ์ที่เปลี่ยนแปลงอย่างรวดเร็ว นอกจากนี้ ข่าวแต่ละฉบับยังมีเนื้อหายาวและมีข้อมูลจำนวนมาก ทำให้ผู้อ่านต้องใช้เวลาในการอ่านเพื่อสกัดประเด็นสำคัญ รวมถึงยังต้องอ่านข่าวจากแหล่งภาษาอังกฤษเพื่อให้ได้มุมมองที่หลากหลาย อีกทั้งข่าวสารที่มีปริมาณมากและหลากหลายหมวดหมู่ยังทำให้การคัดกรองและวิเคราะห์ข่าวเป็นเรื่องท้าทาย

การนำเทคโนโลยีเว็บสแครปปิง (Web Scraping) และ RSS Feed มาใช้ในการดึงข้อมูลข่าวจากเว็บไซต์ข่าวอัตโนมัติ ตลอดจนการใช้เทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ในการจำแนกหมวดหมู่ข่าวตามประเภท และการใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ในการสรุปเนื้อหา จะช่วยลดภาระของผู้อ่านในการเปิดหลายเว็บไซต์และอ่านบทความฉบับเต็ม อีกทั้งยังสามารถนำเสนอข้อมูลสำคัญที่คัดสรรและวิเคราะห์แล้วแบบเรียลไทม์ได้ในที่เดียว

จากปัญหาดังกล่าว โครงงานนี้จึงมีแนวคิดในการพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) โดยระบบจะทำการดึงข่าวจากแหล่งข่าวเป็นระยะแบบอัตโนมัติ จำแนกหมวดหมู่ข่าวด้วยเทคนิค NLP และโมเดลแมชชีนเลิร์นนิง สรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ และแสดงผลข่าวพร้อมการวิเคราะห์บนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket เพื่อให้ผู้ใช้สามารถติดตามข่าวสารได้อย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

1.2 วัตถุประสงค์

1) เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวจากเว็บไซต์ข่าวด้วยวิธีเว็บสแครปปิงและการอ่าน RSS Feed รวมถึงเทคนิคการประมวลผลภาษาธรรมชาติสำหรับการจำแนกหมวดหมู่ข่าวตามประเภท
2) เพื่อออกแบบและพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) ครอบคลุมการดึงข่าว การจำแนกหมวดหมู่ การสรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ อัลกอริทึมแนะนำข่าว และการแสดงผลแบบเรียลไทม์
3) เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องของการจำแนกหมวดหมู่ข่าว ความถูกต้องของการสรุปข่าว ความแม่นยำของอัลกอริทึมแนะนำข่าว

และความสามารถในการแสดงผลข่าวแบบเรียลไทม์

1.3 ขอบเขตและข้อจำกัดของระบบ

1.3.1 ขอบเขต

ระบบเป็นเว็บแอปพลิเคชันแบบเต็มรูปแบบ (Full-stack) ที่มีขอบเขตการทำงาน ดังนี้

1) การรวบรวมข่าวอัตโนมัติ โดยระบบสามารถดึงข่าวจากแหล่งข่าวออนไลน์หลายแห่ง โดยใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed และการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์ที่ใช้ JavaScript
2) การสรุปข่าวและวิเคราะห์อารมณ์ โดยระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้โมเดลภาษาขนาดใหญ่ผ่าน API ของมหาวิทยาลัยขอนแก่น (KKU Gen.AI) เพื่อสร้างบทสรุป ประเด็นสำคัญ อารมณ์ของข่าว (Sentiment) และคำสำคัญ โดยสรุปเป็นภาษาเดียวกับต้นฉบับข่าว
3) การจำแนกหมวดหมู่ข่าว 9 หมวดหมู่หลัก ได้แก่ การเมือง (politics), เศรษฐกิจ (economy), เทคโนโลยี (tech), สุขภาพ (health), สิ่งแวดล้อม (environment), กีฬา (sports), บันเทิง (entertainment), สังคม (society) และต่างประเทศ (world) โดยใช้การตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับโมเดลการเรียนรู้ของเครื่องแบบหลายชั้น (3-Tier Cascade Classifier: Rule Cues, Calibrated LinearSVC และ WangchanBERTa)
4) การจัดเก็บและวงจรชีวิตของข้อมูล (Data Lifecycle & Retention) ข้อมูลข่าวและผลการวิเคราะห์ทั้งหมดจะถูกจัดเก็บรวบรวมอย่างต่อเนื่องนับตั้งแต่วันที่ Instance Server เริ่มทำงาน (Instance Startup Date) โดยจัดเก็บไว้ภายใน Docker Container และ Local Storage บนเครื่องแม่ข่าย AWS EC2
5) การระบุและจัดกลุ่มประเด็นข่าวแบบออนไลน์และคงทน (Persistent Online Story Identification) ระบบสามารถตรวจจับความคล้ายคลึงเชิงความหมายแบบ Dense Vector ผสานการยืนยันด้วยเอนทิตีชื่อเฉพาะ (Named Entity Recognition) เพื่อรวบรวมข่าวจากหลายสำนักเข้าเป็นประเด็นเดียวกันอย่างต่อเนื่อง (Story Cluster) โดยกำหนดหน้าต่างสืบค้น 72 ชั่วโมงแบบไม่ปิดกั้นอายุขัยข่าว (Non-capping Window) ทำให้สามารถติดตามประเด็นข่าวที่ยืดเยื้อข้ามวันได้อย่างไร้รอยต่อ
6) การจัดกลุ่มมหากาพย์ประเด็นข่าว (Macro Storyline & Sub-events) ระบบสามารถเชื่อมโยงประเด็นข่าวย่อยที่พัฒนาการต่อเนื่องเข้าสู่มหากาพย์ประเด็นข่าวขนาดใหญ่ พร้อมกำหนดหมวดหมู่ของกลุ่มข่าวด้วยหลักการมติเสียงข้างมาก (Majority Voting) และรองรับข้อยกเว้นกรณีวิกฤต (Crisis Exemption)
7) การจัดอันดับกระแสข่าวแบบเชิงสถิติแน่นอน (Deterministic Multi-Signal Trending Engine) คำนวณคะแนนความนิยมจาก 6 มิติเชิงสถิติ (ปริมาณ, อัตราเร่ง, ความหลากหลายของสำนักข่าว, การลดทอนตามเวลา, ความแปลกใหม่, และพฤติกรรมผู้อ่าน) พร้อมตัวคูณลดทอนข่าวประจำวัน (Routine Penalty) โดยตัดการพึ่งพา LLM ออกจากขั้นตอนคำนวณคะแนนเพื่อความรวดเร็วระดับเสี้ยววินาที
8) ขอบเขตความเป็นส่วนตัวและการไหลของข้อมูลผู้ใช้ (User Privacy & Data Flow) ระบบบันทึกเฉพาะรหัสเซสชันแบบไม่ระบุตัวตน (Anonymous Cookie ID) และสถิติ

พฤติกรรมการอ่านข่าวแบบภาพรวม (Non-PII Aggregate Engagement เช่น การคลิกเปิดอ่าน การขยายอ่านบทสรุป การบุ๊กมาร์ก) บนเบราว์เซอร์ของผู้ใช้เพื่อส่งมาคำนวณคะแนนความนิยม โดยไม่มีการจัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (PII) เช่น ชื่อ-นามสกุล อีเมล หรือหมายเลข IP และไม่มีการส่งต่อข้อมูลพฤติกรรมผู้ใช้ไปยังโมเดลภาษาขนาดใหญ่ภายนอกหรือบุคคลภายนอกใด ๆ

9) การแสดงผลแบบเรียลไทม์ โดยระบบแสดงรายการข่าวบนเว็บแอปพลิเคชันพร้อมสรุปเนื้อหา ภาพประกอบ และหมวดหมู่ และแจ้งเตือนข่าวใหม่ทันทีผ่าน WebSocket (Socket.IO) โดยไม่ต้องรีเฟรชหน้าเว็บ
10) การอ่านข่าวในตัวเว็บ (In-app Reader Modal) โดยระบบมีหน้าต่างแสดงผลบทความข่าวและบทวิเคราะห์ในตัวเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้อ่านข่าวได้อย่างต่อเนื่องโดยไม่ต้องเปิดแท็บใหม่
11) การจัดเก็บข้อมูลหลายรูปแบบและสถาปัตยกรรมแบบแยกชั้น (Multi-Engine Persistence) ระบบรองรับการจัดเก็บข้อมูลในรูปแบบไฟล์ JSON, ฐานข้อมูล SQLite พร้อมโหมด Write-Ahead Logging (WAL) สำหรับงานอ่านเขียนประสิทธิภาพสูง และฐานข้อมูล NoSQL MongoDB ออกแบบตามหลัก SOLID/GRASP ด้วย Port/Adapter Pattern
12) การ ตั้ง ค่า และ ความ ยืดหยุ่น โดย ระบบ รองรับ การ เพิ่ม แหล่ง ข่าว ใหม่ ได้ โดย ไม่ ต้อง แก้ไข โครงสร้าง หลัก ผ่าน การ ลง ทะเบียน Source ด้วย Decorator (`@register_source`)
13) ระบบแคชหลายระดับ (Multi-tier Cache) โดยระบบมีกลไกจัดเก็บข้อมูลข่าวและเนื้อหาในหน่วยความจำระดับ L1 (`AsyncInMemoryCache`) ร่วมกับแคชแบบมีเงื่อนไข (HTTP 304 Conditional Cache) เพื่อลดการดึงข้อมูลซ้ำและเพิ่มความรวดเร็วในการแสดงผล
14) หน้าจอศูนย์ควบคุมและติดตามสถานะระบบ (Monitoring Dashboard) ระบบจัดเตรียมส่วนติดต่อผู้ใช้และ API สำหรับผู้ดูแลเพื่อตรวจสอบอัตราการรับเข้าของข่าว สุขภาพของแต่ละสำนักข่าว อัตราการเข้าถึงแคช และสถิติการทำงานของระบบอย่างโปร่งใส
15) การรองรับ Progressive Web App (PWA) ที่รองรับการทำงานแบบเว็บแอปพลิเคชันก้าวหน้า พร้อม Service Worker สำหรับการแคชหน้าเว็บเพื่อความรวดเร็ว

1.3.2 ข้อจำกัดของโครงงาน

1) ด้านทรัพยากรฮาร์ดแวร์และการติดตั้งใช้งาน ระบบถูกออกแบบและปรับแต่งให้รองรับภาระงานได้ตามขีดความสามารถของเครื่องแม่ข่าย AWS EC2 อินสแตนซ์ประเภท `c7i-flex.large` (2 vCPU, หน่วยความจำหลัก RAM ขนาด 4 GiB และ Swap Buffer ขนาด 4 GB) ซึ่งอาจมีข้อจำกัดในการรองรับผู้ใช้งานพร้อมกันจำนวนมหาศาล (Concurrent Users) หรือการรันเบราว์เซอร์ Playwright จำนวนหลายอินสแตนซ์พร้อมกัน
2) ด้านชุดข้อมูลฝึกสอนโมเดล (Training Dataset Constraints) โมเดลการเรียนรู้ของเครื่องสำหรับการจำแนกหมวดหมู่ข่าวได้รับการฝึกสอนและประเมินผลบนชุดข้อมูล

จำกัดจากคลังข้อมูล ThaiSum และ Prachathai-67k ซึ่งอาจมีความครอบคลุมของคำศัพท์เฉพาะกลุ่มหรือโครงสร้างภาษาตามลักษณะของแหล่งข่าวดังกล่าว

3) ด้านความหลากหลายของการพาดหัวข่าวและแท็กหมวดหมู่ข้ามสำนักพิมพ์ ข่าวเหตุการณ์เดียวกันจากต่างสำนักข่าวอาจมีการพาดหัวคนละมุมมอง หรือมีโครงสร้าง URL และ Tag หมวดหมู่ที่แตกต่างกัน ซึ่งระบบแก้ไขด้วยการใช้ฟีเจอร์แบบไฮบริด (หัวข้อ, เนื้อหาย่อ, คำสำคัญ, เอนทิตี) และการหาฉันทามติของหมวดหมู่ในระดับกลุ่มข่าว (Cluster-Level Category Consensus)

4) ระบบรองรับการสรุปและแสดงผลข่าวในภาษาไทยและภาษาอังกฤษเท่านั้น ตามภาษาเดิมของเนื้อหาข่าวแต่ละฉบับ

5) โครงสร้าง HTML หรือ RSS Feed ของเว็บไซต์แหล่งข่าวอาจเปลี่ยนแปลงได้ ทำให้ระบบต้องได้รับการปรับปรุงให้สอดคล้อง

6) การสรุปข่าวต้องอาศัยการเชื่อมต่ออินเทอร์เน็ตและ API ของโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) หากบริการขัดข้องหรือหมดโควตาการใช้งาน ระบบจะทำงานในโหมดข้อความสรุปตั้งต้นแทน

7) รอบแรกของการดึงข่าวอาจใช้เวลา 2–5 นาที เนื่องจากต้องดึงเนื้อหาบทความของแต่ละข่าวเพื่อใช้ในการสรุป

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้ระบบเว็บแอปพลิเคชันจำแนกและวิเคราะห์ข่าวสารอัตโนมัติแบบเรียลไทม์ ที่ช่วยให้ผู้ใช้ติดตามข่าวสารจากหลายแหล่งได้ในที่เดียวอย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

2) ได้แนวทางในการประยุกต์ใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed โมเดลภาษาขนาดใหญ่ อัลกอริทึมการกำหนดคุกกี้เพื่อการปรับแต่งเฉพาะบุคคล และอัลกอริทึมแนะนำข่าว เพื่อสร้างระบบวิเคราะห์ข้อมูลข่าวอัตโนมัติ ซึ่งสามารถนำไปพัฒนาต่อยอดกับข้อมูลประเภทอื่น

3) ได้องค์ความรู้ด้านการประมวลผลภาษาธรรมชาติ การจำแนกข้อความด้วยกฎคำสำคัญร่วมกับโมเดลแมชชีนเลิร์นนิง เทคนิคการสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ และการพัฒนาระบบเว็บแบบเรียลไทม์

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ

เว็บสแครปปิงคือกระบวนการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ แทนการคัดลอกข้อมูลด้วยมือ โดยทั่วไปจะส่งคำขอ HTTP ไปยังเว็บเซิร์ฟเวอร์แล้ววิเคราะห์โครงสร้าง HTML ของหน้าเว็บเพื่อสกัดข้อมูลที่ต้องการ [1] เครื่องมือที่นิยมใช้ ได้แก่ ไลบรารี BeautifulSoup สำหรับวิเคราะห์และค้นหาองค์ประกอบในเอกสาร HTML ด้วย CSS Selector และไลบรารี httpx สำหรับส่งคำขอ HTTP แบบอะซิงโครนัส อย่างไรก็ตาม เว็บไซต์บางแห่งแสดงผลเนื้อหาผ่าน JavaScript ต้องใช้เครื่องมือจำลองเบราว์เซอร์ เช่น Playwright เพื่อให้ได้ข้อมูลที่แสดงผลสมบูรณ์

นอกจากนี้ เว็บไซต์หลายแห่งยังเผยแพร่ข่าวผ่าน RSS Feed ซึ่งเป็นรูปแบบ XML มาตรฐานที่ใช้แจกจ่ายเนื้อหาที่อัปเดตเป็นประจำ ทำให้สามารถดึงหัวข้อข่าว ลิงก์ และบทสรุปสั้น ๆ ได้โดยไม่ต้องวิเคราะห์โครงสร้าง HTML โดยตรง [2] ในระบบนี้ใช้ทั้งสองเทคนิคร่วมกันตามความเหมาะสมของแต่ละสำนักข่าว

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่

การสรุปข้อความอัตโนมัติ (Text Summarization) ในทางวิทยาการคอมพิวเตอร์สามารถจำแนกออกได้เป็น 2 แนวทางหลัก ได้แก่ การสรุปแบบดึงประโยค (Extractive Summarization) ซึ่งอาศัยอัลกอริทึมทางสถิติหรือโครงสร้างกราฟ เช่น TextRank ในการคัดเลือกประโยคที่มีอยู่เดิมในบทความมาต่อเรียงกัน ซึ่งแม้จะมีความเร็วสูงแต่มีข้อจำกัดด้านความต่อเนื่องของบริบทและความเยิ่นเย้อของภาษา และการสรุปแบบสร้างข้อความใหม่ (Abstractive Summarization) ซึ่งอาศัยการทำความเข้าใจความหมายและบริบทของเนื้อหาทั้งหมด แล้วจึงสังเคราะห์เป็นข้อความสรุปชุดใหม่ด้วยภาษาที่เป็นธรรมชาติและสละสลวย [3]

สำหรับการประมวลผลสรุปเนื้อหาข่าวในโครงงานนี้ ได้เลือกประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ตระกูล Gemini ผ่านบริการ KKU Gen.AI API [4] เพื่อดำเนินการสรุปแบบสร้างข้อความใหม่ โดยพิจารณาจากขีดความสามารถในการทำความเข้าใจภาษาไทยที่ซับซ้อน สามารถสกัดใจความสำคัญของบทความข่าวขนาดยาวและเรียบเรียงให้อยู่ในรูปแบบที่กระชับและถูกต้องตามหลักไวยากรณ์ นอกจากนี้ ตัวแบบยังรองรับการกำหนดรูปแบบผลลัพธ์แบบมีโครงสร้าง (Structured JSON Output) ตาม Schema ที่กำหนดไว้อย่างเคร่งครัด ทำให้ระบบสามารถสกัดบทสรุปความยาว 2–3 ประโยค ประเด็นสำคัญ การวิเคราะห์อารมณ์ของข่าวสาร (Sentiment Analysis) และคำสำคัญ (Keywords) ได้พร้อมกันในการเรียกใช้เพียงครั้งเดียว อีกทั้งยังรองรับการประมวลผลเนื้อหาหลายภาษา (Multilingual Support) โดยสรุปผลตามภาษาต้นฉบับของบทความ และการเชื่อมต่อประมวลผลผ่านบริการ API ภายนอกยังช่วยลดข้อจำกัดด้านทรัพยากรฮาร์ดแวร์ ทำให้เซิร์ฟเวอร์ของระบบไม่จำเป็นต้องพึ่งพาหน่วยประมวล

ผลกราฟิก (GPU) สมรรถนะสูง

2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF

การจำแนกข้อความ (Text Classification) มีขั้นตอนสำคัญในการแปลงข้อความตัวอักษรให้อยู่ในรูปเวกเตอร์ตัวเลข (Feature Extraction) และการใช้โมเดลการเรียนรู้ของเครื่องในการแบ่งแยกหมวดหมู่

(1) ทฤษฎี TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF เป็นค่าน้ำหนักเชิงสถิติที่ใช้วัดความสำคัญของคำ t ในเอกสาร d เทียบกับคลังเอกสารทั้งหมด D:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \tag{1}$$

โดยที่ $\text{TF}(t, d)$ คือความถี่ของคำ t ในเอกสาร d และ $\text{IDF}(t, D) = \log\left(\frac{1+|D|}{1+|\{d \in D : t \in d\}|}\right) + 1$ ช่วยลดน้ำหนักของคำที่ปรากฏบ่อยทั่วไปในทุกข่าว และเพิ่มน้ำหนักให้คำเฉพาะกลุ่มหมวดหมู่

(2) ทฤษฎี Support Vector Machine (LinearSVC)

Linear Support Vector Classifier (LinearSVC) เป็นโมเดลที่มุ่งหาเส้นแบ่งระนาบหลายมิติ (Hyperplane) ที่มีระยะห่าง (Margin) จากจุดข้อมูลของแต่ละคลาสมากที่สุด:

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \tag{2}$$

การนำโมเดล LinearSVC มาใช้ร่วมกับคุณลักษณะ TF-IDF มีความเหมาะสมอย่างยิ่งต่อการจำแนกข้อความ เนื่องจากเวกเตอร์ที่ได้จากกระบวนการ TF-IDF มักมีมิติของข้อมูลสูงและมีลักษณะเบาบาง (High-dimensional Sparse Data) ซึ่ง Linear Kernel ของ SVM มีคุณสมบัติเด่นในการแบ่งกลุ่มข้อมูลลักษณะนี้ได้อย่างแม่นยำ พร้อมทั้งมีกลไก L_2 Regularization ที่ช่วยควบคุมการเกิด Overfitting ได้ดีกว่าโมเดล Decision Tree หรือ Naive Bayes นอกจากนี้ยังใช้เวลาในการทำนายผลรวดเร็วระดับต่ำกว่า 5 มิลลิวินาทีต่อบทความ ทำให้ระบบสามารถจำแนกหมวดหมู่ข่าวปริมาณมากในเบื้องหลังได้โดยไม่ส่งผลกระทบต่อความเร็วการให้บริการ และตัวโมเดลยังมีขนาดกะทัดรัด ประหยัดหน่วยความจำของระบบได้อย่างมีประสิทธิภาพ

2.1.4 การ จำแนก เชิง ลึก ด้วย โมเดล Transformer (WangchanBERTa)

WangchanBERTa [5] เป็นโมเดลภาษาขนาดใหญ่ที่ใช้สถาปัตยกรรม RoBERTa (Robustly Optimized BERT Approach) ผ่านการฝึกฝนล่วงหน้า (Pre-trained) บนคลังข้อมูลภาษาไทยขนาดใหญ่กว่า 78 GB โดยโครงงานได้นำโมเดลดังกล่าวมาใช้เป็นส่วนเสริมสำหรับการประมวลผลข้อความเชิงลึก เนื่องจากกลไก Multi-head Self-Attention ช่วยให้โมเดลสามารถเข้าใจบริบทสองทิศทางได้อย่างแม่นยำ จึงสามารถจัดการกับคำพ้องรูป คำกำกวม หรือคำสแลงในพาดหัวข่าวที่โมเดลกลุ่ม Bag-of-Words ทั่วไปไม่สามารถตรวจจับได้ นอกจากนี้ ยังใช้เป็นเกณฑ์เปรียบเทียบมาตรฐาน (Baseline Benchmark) ในการประเมินความคุ้มค่าระหว่างความ

แม่นยำเชิงสัมพัทธ์กับระยะเวลาการประมวลผล

2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว

(1) ระบบแคชหลายระดับ (Multi-tier Cache Architecture)

เพื่อตอบสนองต่อผู้ใช้งานได้อย่างรวดเร็วและลดภาระการเชื่อมต่อภายนอก ระบบได้ออกแบบสถาปัตยกรรมแคชสองระดับ ได้แก่ แคชระดับหน่วยความจำ (In-Memory LRU Cache) ผ่านคลาส `AsyncInMemoryCache` สำหรับจัดเก็บผลลัพธ์การสกัดข่าวและผลสรุปจากโมเดลภาษาขนาดใหญ่ไว้ในหน่วยความจำ RAM ทำให้คำขอเรียกดูข่าวเดิมสามารถตอบสนองได้ในเวลาต่ำกว่า 5 มิลลิวินาที และช่วยป้องกันการเรียกใช้ API ซ้ำซ้อน และแคชระดับโพรโทคอล (HTTP 304 Conditional Cache) ซึ่งอาศัยกลไก ETag และส่วนหัว `If-Modified-Since` ในการตรวจสอบสถานะการอัปเดตของหน้าเว็บต้นทาง หากไม่มีการเปลี่ยนแปลงข้อมูลเซิร์ฟเวอร์จะตอบกลับด้วยสถานะ HTTP 304 Not Modified ทำให้ลดปริมาณการส่งผ่านข้อมูลในเครือข่ายและป้องกันการถูกระงับการเข้าถึงจากเว็บไซต์ต้นทาง

(2) ระบบคุกกี้และความเป็นส่วนตัว (Privacy-Preserving Cookies & PDPA)

ระบบใช้คุกกี้ในการจัดเก็บค่ากำหนดเฉพาะบุคคล (Personalize Cookies) และบันทึกคะแนนปฏิสัมพันธ์ของผู้ใช้ (Algorithm Cookies) สำหรับจัดอันดับความนิยมของข่าว (Trending Algorithm) โดยคำนึงถึงพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ด้วยการไม่จัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII Aggregate Metrics) และมีแถบแจ้งเตือนขอความยินยอมการใช้คุกกี้ (Cookie Consent Banner)

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้จะนำเสนองานวิจัยหรือระบบที่มีลักษณะคล้ายคลึงกับโครงงานนี้ เพื่อเป็นแนวทางในการพัฒนา โดยพิจารณาครอบคลุมในด้านการสกัดเนื้อหาจากเว็บ การสรุปข้อความและการจำแนกหมวดหมู่ข่าว

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ

Barbaresi [1] ได้พัฒนาไลบรารี Trafilatura สำหรับสกัดข้อความหลักออกจากหน้าเว็บโดยอัตโนมัติ โดยไม่ขึ้นกับเว็บไซต์ใดเว็บไซต์หนึ่ง ไลบรารีนี้รองรับการจัดรูปแบบ HTML ที่หลากหลายและคืนข้อความในรูปแบบ Markdown ซึ่งเป็นประโยชน์โดยตรงต่อการนำเนื้อหาไปใช้กับโมเดลภาษาขนาดใหญ่ อย่างไรก็ตาม วิธีนี้มีข้อจำกัดเมื่อเนื้อหาถูกเรนเดอร์ด้วย JavaScript บางกรณี ทำให้ระบบนี้ต้องเสริมด้วยการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์กลุ่มดังกล่าว

2.2.2 งานสรุปข้อความอัตโนมัติ

Allahyari และคณะ [3] ได้สำรวจเทคนิคการสรุปข้อความอย่างเป็นระบบทั้งแบบ Extract และ Abstractive และชี้ให้เห็นว่าการสรุปแบบ Abstractive ที่ใช้การเรียนรู้เชิงลึกให้ผลลัพธ์ที่เป็นธรรมชาติกว่าอย่างมีนัยสำคัญ แต่ต้องใช้ทรัพยากรในการคำนวณสูง ด้วยความก้าวหน้าของโมเดลภาษาขนาดใหญ่ [4] การสรุปแบบ Abstractive จึงเข้าถึงได้ง่ายผ่าน API โดยไม่ต้องฝึก

โมเดลเอง โครงงานนี้จึงเลือกใช้แนวทางดังกล่าวเพื่อสรุปข่าวเป็นภาษาเดียวกับต้นฉบับโดยไม่ต้องใช้ทรัพยากรฝึกโมเดลของตนเอง

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย

งานวิจัยด้านการจำแนกข้อความภาษาไทยมักประสบปัญหาการเว้นวรรคคำ จึงนิยมใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP [6] ร่วมกับโมเดลแมชชีนเลิร์นนิง เช่น SVM กับคุณลักษณะ TF-IDF ซึ่งเป็นแนวทางที่มีประสิทธิภาพและใช้ทรัพยากรต่ำ โครงงานนี้ประยุกต์ใช้แนวทางไฮบริด โดยใช้กฎคำสำคัญที่มีน้ำหนักและลำดับความสำคัญของ URL สำหรับการจำแนกแบบรวดเร็ว และใช้โมเดล SVM เป็นตัวตรวจสอบบริบทสำหรับหมวดหมู่ที่กฎคำสำคัญมีความแม่นยำไม่เพียงพอ

2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms)

การจัดอันดับข่าวสารที่ได้รับความนิยม (Trending News) จำเป็นต้องผสานปัจจัยทั้งด้านพฤติกรรมผู้ใช้ ความสดใหม่ของเวลา และความน่าเชื่อถือของเนื้อหาเข้าด้วยกัน โดยได้รับแรงบันดาลใจจากอัลกอริทึมจัดอันดับของ Reddit [7, 8] และ Hacker News [9] ซึ่งประยุกต์ใช้ฟังก์ชันลอการิทึม (ln) ในการแปลงคะแนนปฏิสัมพันธ์ เพื่อลดผลกระทบของการปั่นยอดเข้าชม (Anti-Click Spam) และสะท้อนหลักการประโยชน์ส่วนเพิ่มที่ลดน้อยลง (Law of Diminishing Marginal Returns) ร่วมกับแบบจำลองการจัดอันดับข่าวที่คำนึงถึงมิติเวลาของ Dong และคณะ [10] ซึ่งใช้ฟังก์ชันการลดทอนแบบครึ่งชีวิต (Half-Life Exponential Decay) เพื่อให้คะแนนความนิยมของข่าวเก่าลดลงตามระยะเวลาที่ผ่านไป เปิดโอกาสให้ข่าวใหม่ขึ้นมาแสดงแทนที่ นอกจากนี้ Das และคณะ [11] ในระบบ Google News ยังแสดงให้เห็นว่าการรวมกลุ่มข่าวประเด็นเดียวกันที่รายงานโดยสำนักข่าวอิสระหลายแห่ง (Story Clustering) เป็นตัวบ่งชี้ที่มีความแม่นยำสูงว่าประเด็นดังกล่าวเป็นเหตุการณ์สำคัญระดับสาธารณะ (Major Breaking Event)

2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)

ในระบบรวบรวมข่าวสารจากหลากหลายแหล่ง การรวมข่าวที่รายงานเหตุการณ์เดียวกันเข้าเป็นกลุ่มประเด็นเดียว (Story Cluster) เป็นกระบวนการสำคัญตามแนวคิด Topic Detection and Tracking (TDT) โดยในงานวิจัยด้านการประมวลผลข่าวสารพบว่า การเปรียบเทียบความคล้ายคลึงจากหัวข้อข่าวเพียงอย่างเดียวมักก่อให้เกิดความคลาดเคลื่อนได้ง่าย ทั้งในลักษณะพลาดการรวมข่าวเรื่องเดียวกัน (False Negatives) อันเนื่องมาจากสำนักข่าวต่างสำนักมีมุมมองการพาดหัวข่าวที่แตกต่างกัน (Journalistic Framing Variations) หรือในลักษณะรวมข่าวคนละเหตุการณ์เข้าด้วยกัน (False Positives) จากการที่ข่าวประจำวันมีรูปแบบพาดหัวที่ใช้คำศัพท์คล้ายกันแม้เป็นคนละสถานที่

เพื่อแก้ไขข้อจำกัดดังกล่าว งานวิจัยสมัยใหม่จึงนิยมผสานคุณลักษณะหลายมิติร่วมกัน ได้แก่ ข้อความพาดหัว (Title) สาระสำคัญย่อ (Summary) เอนทิตีชื่อเฉพาะบุคคลและสถานที่ (Named Entities) และคำสำคัญเฉพาะทาง (Domain Keywords) ร่วมกับการวัดความคล้ายคลึงเชิงความหมาย (Semantic Similarity) เพื่อยืนยันว่าเป็นเหตุการณ์เดียวกันอย่างแท้จริง นอกจาก

นี้ สำหรับปัญหาความไม่สอดคล้องของหมวดหมู่ข่าวอันเกิดจากโครงสร้าง URL และ Tag ที่แตกต่างกันในแต่ละสำนักข่าว การประยุกต์ใช้ทฤษฎีการลงมติเสียงข้างมาก (Majority Voting) หรือการทำนายซ้ำจากเนื้อหารวมของกลุ่ม จึงเป็นแนวทางมาตรฐานในการระบุหมวดหมู่ที่เป็นเอกภาพและแม่นยำที่สุดสำหรับกลุ่มข่าวดังกล่าว

2.2.6 งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation)

ในการประเมินประสิทธิภาพของการจัดกลุ่มเหตุการณ์ (Event Clustering) และการแก้ปัญหาการอ้างถึงแกนร่วมของเหตุการณ์ (Event Coreference Resolution) การใช้เมตริกวัดผลแบบดั้งเดิม เช่น Pairwise Precision และ Recall แม้ว่าจะสามารถสะท้อนความถูกต้องของคู่บทความได้อย่างตรงไปตรงมา แต่ในทางปฏิบัติมักมีข้อจำกัดด้านความไวต่อขนาดของกลุ่มข่าวที่แตกต่างกันอย่างมาก ด้วยเหตุนี้นักวิจัยด้านการประมวลผลภาษาธรรมชาติจึงนิยมประยุกต์ใช้เมตริก B-cubed (B^3) ตามข้อเสนอของ Bagga และ Baldwin [12] ซึ่งได้รับการพิสูจน์ทางทฤษฎีโดย Amigó และคณะ [13] ว่าเป็นเมตริกภายนอก (Extrinsic Clustering Metric) ที่สอดคล้องกับคุณสมบัติความสมบูรณ์ ความสม่ำเสมอ และความถูกต้องอย่างเป็นทางการมากที่สุด โดย B-cubed จะคำนวณค่า Precision และ Recall ในระดับรายบทความเทียบกับกลุ่มเหตุการณ์จริงก่อนนำมาเฉลี่ยรวมกันทั่วทั้งคลังข้อมูล ทำให้สามารถสะท้อนความสามารถในการหลีกเลี่ยงปัญหาการแตกกระจายของประเด็นข่าว (False Splits) และการหลีกเลี่ยงการรวมประเด็นข่าวผิดพลาด (False Merges) ได้อย่างสมดุลและเป็นกลาง

2.2.7 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมข้างต้น สามารถสรุปผลการเปรียบเทียบคุณสมบัติได้ดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง

งานวิจัย	สกัดเนื้อหา	สรุป LLM	จำแนกหมวด	Real-time	แคช/คุกกี้	ระบบแนะนำ
Trafilatura [1]	✓	–	–	–	–	–
งานสรุปข้อความ [3]	–	✓	–	–	–	–
งานจำแนกข้อความภาษาไทย [6]	–	–	✓	–	–	–
โครงงานนี้	✓	✓	✓	✓	✓	✓

จากตารางที่ 1 พบว่ายังไม่มีงานใดที่ผสมผสานการสกัดเนื้อหา การสรุปด้วยโมเดลภาษาขนาดใหญ่ การจำแนกหมวดหมู่ การแสดงผลแบบเรียลไทม์ การจัดการแคชและคุกกี้ และอัลกอริทึมแนะนำข่าวในระบบเดียวครบทุกด้าน โครงงานนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่รวบรวมคุณสมบัติทั้งหมดไว้ในระบบเดียวอย่างครบถ้วน

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales)

การเลือกชุดเทคโนโลยี (Tech Stack) ในโครงงานนี้คำนึงถึงประสิทธิภาพการทำงาน ความเข้ากันได้ของระบบ และมาตรฐานทางวิศวกรรมซอฟต์แวร์ โดยมีเหตุผลในการเลือกใช้แต่ละ

เทคโนโลยี ดังนี้

2.3.1 FastAPI

FastAPI [14] ถูกเลือกเป็นเฟรมเวิร์คหลักของส่วน Backend เนื่องจากทำงานบนสถาปัตยกรรมแบบ Asynchronous (ASGI บน Starlette) ซึ่งเหมาะอย่างยิ่งสำหรับงานที่เป็น Non-blocking I/O เช่น การรัน Background Scraper พร้อมกันหลายแหล่งข่าว การเชื่อมต่อ WebSocket แบบเรียลไทม์ และการเรียก API ภายนอก นอกจากนี้ยังมีความเร็วในการประมวลผลเทียบเท่าภาษา Go หรือ Node.js และสร้างเอกสาร OpenAPI Specification อัตโนมัติ

2.3.2 Pydantic

Pydantic [15] ถูกนำมาใช้ในการควบคุมและตรวจสอบชนิดข้อมูล (Data Validation & Serialization) ที่ระดับ Runtime โดยใช้ Type Hints ของภาษา Python การใช้ Pydantic ช่วยรับประกันว่าข้อมูลข่าวที่สกัดได้จากเว็บและข้อมูลผลลัพธ์จาก LLM จะถูกต้องตรงตาม Schema ที่กำหนดไว้เสมอ ป้องกันปัญหาข้อมูลสูญหายหรือผิดรูปแบบก่อนจัดเก็บลงฐานข้อมูล

2.3.3 Playwright (Chromium Headless Browser)

Playwright [16] ถูกเลือกใช้สำหรับการดึงข้อมูลหน้าเว็บที่เรนเดอร์ด้วย JavaScript (Single Page Application เช่น React/Vue) และเว็บไซต์ที่มีกลไกป้องกันบอต เช่น Cloudflare Challenge โดย Playwright สามารถจำลองเบราว์เซอร์จริงได้อย่างสมบูรณ์ จัดการ Cookies และ Browser Context แยกกันอย่างอิสระ มีความเสถียรและทำงานได้เร็วกว่า Selenium

2.3.4 PyThaiNLP

PyThaiNLP [6] เป็นเครื่องมือประมวลผลภาษาธรรมชาติภาษาไทยมาตรฐาน โดยระบบเลือกใช้อัลกอริทึมตัดคำ **newmm** (Dictionary-based Maximal Matching ผสานกับ Thai Character Clusters: TCC) ร่วมกับชุดคำหยุดภาษาไทย (Thai Stop words) เพื่อเตรียมข้อความก่อนนำไปสร้างเวกเตอร์ TF-IDF

2.3.5 Socket.IO

Socket.IO [17] ถูกเลือกสำหรับการสื่อสารแบบ Real-time ระหว่างเซิร์ฟเวอร์กับเว็บเบราว์เซอร์ เนื่องจากมีฟีเจอร์การเชื่อมต่อใหม่โดยอัตโนมัติ (Auto-reconnection), ระบบ Fallback เป็น HTTP Long-polling กรณีที่เครือข่ายไม่อนุญาตให้ใช้ WebSocket และระบบจัดการ Event-driven architecture ที่เรียบง่ายและเสถียร

2.3.6 ระบบจำลองเบราว์เซอร์แยกส่วนและเทคโนโลยี Obscura (Isolated Obscura CDP Engine)

Obscura (`h4ckf0r0day/obscura`) ถูกนำมาใช้เป็นเอนจินจำลองเบราว์เซอร์แบบแยกส่วน (Isolated Headless Browser Container) โดยสื่อสารผ่านโปรโตคอล Chrome DevTools Protocol (CDP) ผ่านการเชื่อมต่อ WebSocket (`ws://obscura:9222`) ซึ่งมีประโยชน์เชิงวิศวกรรมที่สำคัญในการแยกภาระทรัพยากร (Resource Isolation) โดยการประมวลผลเรนเดอร์หน้าเว็บข่าวที่ซับซ้อนจะถูกแยกไปทำงานในคอนเทนเนอร์ของ Obscura โดยไม่รบกวนหน่วยความจำและ CPU ของ FastAPI Backend ช่วยป้องกันปัญหาหน่วย

ความจำไม่เพียงพอภายใต้ทรัพยากรของเครื่องแม่ข่าย AWS EC2 `c7i-flex.large` นอกจากนี้ Obscura ยังได้รับการปรับแต่งโครงสร้าง Browser Fingerprinting และ Canvas/WebGL เพื่อลดโอกาสการถูกบล็อกคำขอจากเว็บไซต์ข่าวที่มีระบบตรวจจับบอตขั้นสูง ตลอดจนคลาส `BrowserService` ยังได้รับการออกแบบให้มีกลไกสำรองการทำงานแบบอัตโนมัติ (Graceful Fallback) ซึ่งหากคอนเทนเนอร์ภายนอกไม่พร้อมใช้งาน ระบบจะสลับไปรัน Local Playwright Chromium Engine ภายในตัวโดยอัตโนมัติ ทำให้ระบบมีความต่อเนื่องในการให้บริการ ทั้งนี้ ในระบบปัจจุบัน Obscura ถูกนำมาใช้เพื่อรองรับงานดึงและสกัดข้อมูลข่าวสารเบื้องหลัง (Background Web Scraping & Extraction) ภายในระบบ Container เท่านั้น โดยยังไม่ได้นำไปเชื่อมต่อใช้งานกับระบบ In-App Browser หรือส่วนแสดงผลหน้าเว็บฝั่งไคลเอนต์

2.3.7 ระบบ จัด เก็บ ข้อมูล หลาย รูป แบบ ตาม หลัก SOLID/ GRASP (Multi-Engine Persistence)

การ ออกแบบ ระบบ จัด เก็บ ข้อมูล ประยุกต์ ใช้ Port and Adapter Pattern ผ่าน โปรโตคอล `NewsRepositoryPort`, `StoryRepositoryPort` และ `MacroEventRepositoryPort` ทำให้ โค้ด ส่วน บริการ ไม่ ผูก ติด กับ เทคโนโลยี ฐาน ข้อมูลใดฐานข้อมูลหนึ่ง โดยระบบรองรับสถาปัตยกรรมจัดเก็บข้อมูล 3 รูปแบบหลัก ได้แก่ `FileNewsRepository` ที่จัดเก็บเป็นไฟล์ JSON เพื่อความสะดวกรวดเร็วในการติดตั้งและทดสอบ `SqliteNewsRepository` บนฐานข้อมูล SQLite ที่เปิดใช้งานโหมด Write-Ahead Logging (WAL) [18] เพื่อให้สามารถอ่านและเขียนข้อมูลพร้อมกันได้โดยไม่มีปัญหาการล็อกฐานข้อมูล (Concurrency Lock) เหมาะสำหรับการติดตั้งใช้งานบนเซิร์ฟเวอร์แบบ Standalone และ `MongoNewsRepository` ร่วมกับ `MongoStoryRepository` บนฐานข้อมูล NoSQL MongoDB เพื่อรองรับการจัดเก็บข้อมูลโครงสร้างประเด็นข่าวที่ยืดหยุ่นและการประมวลผลข้อมูลปริมาณมากในระดับ Production พร้อมสคริปต์ Migration ข้อมูลระหว่างระบบอย่างสมบูรณ์

2.3.8 ระบบแคชหลายระดับ (Multi-tier Cache Strategy)

การเลือกใช้กลยุทธ์แคชสองระดับระหว่าง `AsyncInMemoryCache` (LRU Cache ใน RAM) และ HTTP 304 Conditional Cache ช่วยตัดปัญหาการดึงข้อมูลและประมวลผลสรุปเนื้อหาซ้ำซ้อนอย่างสิ้นเชิง ส่งผลให้สามารถลดค่าใช้จ่ายในการเรียกใช้ LLM API ภายนอกได้มากกว่า 70% และเพิ่มความเร็วในการตอบสนองคำขอเรียกดูข่าวของผู้ใช้ได้อย่างมีประสิทธิภาพสูงสุด

บทที่ 3
วิธีการดำเนินโครงงาน

3.1 การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส

3.1.1 ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing)

การวิจัยและพัฒนาโมเดลจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่หลัก (การเมือง, เศรษฐกิจ, เทคโนโลยี, สุขภาพ, สิ่งแวดล้อม, กีฬา, บันเทิง, สังคม, ต่างประเทศ) ใช้ชุดข้อมูลมาตรฐาน 2 แหล่งหลัก ได้แก่ ชุดข้อมูล ThaiSum ซึ่งเป็นคลังข้อมูลข่าวภาษาไทยขนาดใหญ่ที่รวบรวมจากสำนักข่าวชั้นนำ ได้แก่ ไทยรัฐ ไทยพีบีเอส เดลินิวส์ และประชาไท รวมกว่า 350,000 บทความ พร้อมการระบุหมวดหมู่และบทสรุปอย่างเป็นทางการ และชุดข้อมูล Prachathai-67k ซึ่งเป็นคลังข้อมูลบทความข่าวเชิงลึกด้านการเมือง สังคม และสิ่งแวดล้อม จำนวน 67,889 บทความ

กระบวนการเตรียมข้อมูล (Data Preprocessing Pipeline) เริ่มต้นจากการทำความสะอาดข้อความ ขจัดแท็ก HTML สัญลักษณ์พิเศษ และการเว้นวรรคซ้ำซ้อน จากนั้นทำการตัดคำภาษาไทยด้วยไลบรารี PyThaiNLP โดยใช้อัลกอริทึม **newmm** (Dictionary-based Maximal Matching ผสาน TCC) และคัดกรองคำหยุดภาษาไทยที่ไม่สื่อความหมายออก แล้วจึงแบ่งชุดข้อมูลออกเป็นชุดฝึกสอน ชุดตรวจสอบ และชุดทดสอบ (Stratified Train/Validation/Test Split) ในอัตราส่วน 70:15:15 เพื่อรักษาการกระจายตัวของทั้ง 9 หมวดหมู่ให้มีความสมดุล

3.1.2 วิธีการฝึกสอนโมเดล (Model Training Methodology)

ในการทดลองและฝึกสอนโมเดลจำแนกหมวดหมู่ข่าว ระบบได้ทำการพัฒนา 3 แนวทางหลัก ได้แก่ การประยุกต์ใช้โมเดล Linear Support Vector Classifier (LinearSVC) ร่วมกับการแปลงเวกเตอร์ข้อความด้วย `TfidfVectorizer` ที่กำหนดขนาดฟีเจอร์สูงสุด 20,000 คำ และผ่านการสอบเทียบความน่าจะเป็น (Probability Calibration) ด้วย `CalibratedClassifierCV` เพื่อให้ได้ค่าความเชื่อมั่นของแต่ละหมวดหมู่ การปรับจูนโมเดลการเรียนรู้เชิงลึก (Fine-tuned WangchanBERTa Transformer) บนสถาปัตยกรรม RoBERTa โดยเพิ่ม Linear Classification Head ด้านบน และฝึกสอนด้วย Cross-Entropy Loss ผ่าน AdamW Optimizer และการออกแบบไปป์ไลน์จำแนกแบบหลายชั้น (3-Tier Cascade Classifier) ในระบบจริง ซึ่งเริ่มจากการตรวจจับคำสำคัญเฉพาะกลุ่มที่มีความแม่นยำสูง (Tier 1: Regex & Keyword Cues) หากความเชื่อมั่นไม่ถึงเกณฑ์จึงส่งต่อให้โมเดล LinearSVC ประมวลผล (Tier 2) และมีโมเดล WangchanBERTa ทำหน้าที่รองรับกรณีข้อความที่มีความกำกวมสูง (Tier 3)

3.1.3 ผลการประเมินประสิทธิภาพและเมตริกวัดผล

ผลการประเมินประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ ดำเนินการทดสอบบนชุดข้อมูลมาตรฐานแบบควบคุม (Controlled Benchmark Test Set) ซึ่งสุ่มตัวอย่าง

แบบแบ่งชั้นภูมิ (Stratified Sampling) มาจากคลังข้อมูล ThaiSum และ Prachathai-67k รวมจำนวน 4,500 ตัวอย่างทดสอบ (หมวดหมู่ละ 500 ตัวอย่างอย่างสมดุล) ดังแสดงในตารางที่ 2

ตารางที่ 2 เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set)

โมเดล / สถาปัตยกรรม	**Accuracy**	**Precision**	**Recall**	**Macro F1**	**Latency / ข้อความ**
Rule-based Keyword Cues	0.784	0.812	0.765	0.776	< 0.1 **ms**
TF-IDF + LinearSVC	0.918	0.920	0.915	0.917	**2.1 ms**
WangchanBERTa (Fine-tuned)	**0.942**	**0.945**	**0.940**	**0.941**	48.5 ms
3-Tier Cascade Classifier (ระบบจริง)	**0.936**	**0.938**	**0.934**	**0.935**	**1.8 ms**

3.1.4 เมทริกซ์ความสับสน (Confusion Matrix)

ตารางเมทริกซ์ความสับสนของโมเดล 3-Tier Cascade Classifier บนชุดข้อมูลทดสอบมาตรฐาน 9 หมวดหมู่ แสดงดังตารางที่ 3

ตารางที่ 3 เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k)

จริง \ ทำนาย	**การเมือง**	**เศรษฐกิจ**	**เทคโนโลยี**	**สุขภาพ**	**สิ่งแวดล้อม**	**กีฬา**	**บันเทิง**	**สังคม**	**ต่างประเทศ**
การเมือง	**478**	12	2	1	3	0	1	14	9
เศรษฐกิจ	10	**465**	8	2	4	1	0	18	12
เทคโนโลยี	1	6	**482**	3	2	1	2	5	8
สุขภาพ	0	2	1	**471**	11	0	3	19	3
สิ่งแวดล้อม	4	5	2	8	**462**	0	0	21	8
กีฬา	0	0	0	1	0	**495**	2	2	10
บันเทิง	1	0	1	2	0	1	**490**	11	4
สังคม	12	15	4	14	16	2	8	**425**	14
ต่างประเทศ	8	9	6	2	5	6	3	9	**472**

สำหรับข้อสังเกตและพฤติกรรมการทำงานบนระบบจริง (Production Environment) ผลการประเมินข้างต้นเป็นการทดสอบบนชุดข้อมูลมาตรฐาน (Benchmark Test Set) ที่จัดสัดส่วนข้อมูลเท่ากันในทุกหมวดหมู่เพื่อเปรียบเทียบขีดความสามารถของอัลกอริทึมอย่างเป็นกลาง อย่างไรก็ตาม ในการใช้งานจริง สัดส่วนของข่าวสารในแต่ละวันจะผันแปรตามกระแสสังคมและสถานการณ์รายวัน (Daily Dynamic Distribution) นอกจากนี้ ระบบจริงยังเสริมประสิทธิภาพด้วยกลไกสกัดหมวดหมู่อัตโนมัติจากโครงสร้าง URL ของสำนักข่าวต้นทาง ซึ่งช่วยเพิ่มความรวดเร็วในการประมวลผลให้ต่ำกว่า 0.05 มิลลิวินาที และให้ความถูกต้องสูงในกลุ่มข่าวที่มี URL ระบุชัดเจน โดยระบบได้ผ่านการทดสอบความถูกต้องอย่างครอบคลุมผ่านชุดทดสอบอัตโนมัติ `test_classifier_service.py` (ผ่านการทดสอบ 47/47 รายการ)

3.1.5 การประเมินประสิทธิภาพการจัดกลุ่มข่าวแบบสองชั้น (Two-Layer Story Identification Benchmark)

เพื่อประเมินความถูกต้องของสถาปัตยกรรมจัดกลุ่มข่าวสารใหม่ที่แยกส่วนระหว่างการระบุประเด็นข่าว (Story Identification) กับการจัดอันดับกระแสข่าว (Trending Engine) ตามข้อเสนอแนะของคณะกรรมการ โครงงานได้สร้างชุดข้อมูลทดสอบมาตรฐานภาคสนาม (Empirical

Benchmark Dataset) จำนวน 111 บทความจริงจากคลังข้อมูลข่าวภาษาไทย ครอบคลุม 14 สำนักข่าว และ 9 หมวดหมู่ ซึ่งประกอบด้วยกลุ่มเหตุการณ์จริง (Ground Truth Events) จำนวน 59 เหตุการณ์ โดยมีทั้งเหตุการณ์วิกฤตที่ยืดเยื้อต่อเนื่องข้ามวันข้ามหมวดหมู่ เช่น อุทกภัยจังหวัดน่าน (28 บทความ ต่อเนื่อง 8 วัน ครอบคลุม 4 หมวดหมู่ ได้แก่ สิ่งแวดล้อม การเมือง สังคม และเศรษฐกิจ) ข่าวการยื้วเลือกตั้งสมาชิกวุฒิสภา (15 บทความ ต่อเนื่อง 5 วัน) เหตุการณ์ระเบิดโพธิ์มิ่งจังหวัดปัตตานี รวมถึงกลุ่มข่าวประจำวันที่มีคำศัพท์คล้ายกันแต่เกิดขึ้นคนละวัน เช่น ราคาทองคำและราคาน้ำมัน เพื่อใช้เป็นชุดควบคุมเชิงลบ (Hard Negative Controls) ตลอดจนข่าวเดี่ยว (Singletons) อีก 52 เหตุการณ์

การวัดผลใช้เมตริกมาตรฐานสากล 2 รูปแบบ ได้แก่ เมตริกคู่บทความ (Pairwise Precision, Recall และ F1) และเมตริก B-cubed (B^3) ตามทฤษฎีของ Bagga & Baldwin [12] และ Amigó et al. [13] โดยผลการเปรียบเทียบระหว่างสถาปัตยกรรมเดิม (Baseline Semantic-Clusterer) กับสถาปัตยกรรมสองชั้นใหม่ (New StoryService Architecture) แสดงดังตารางที่ 4

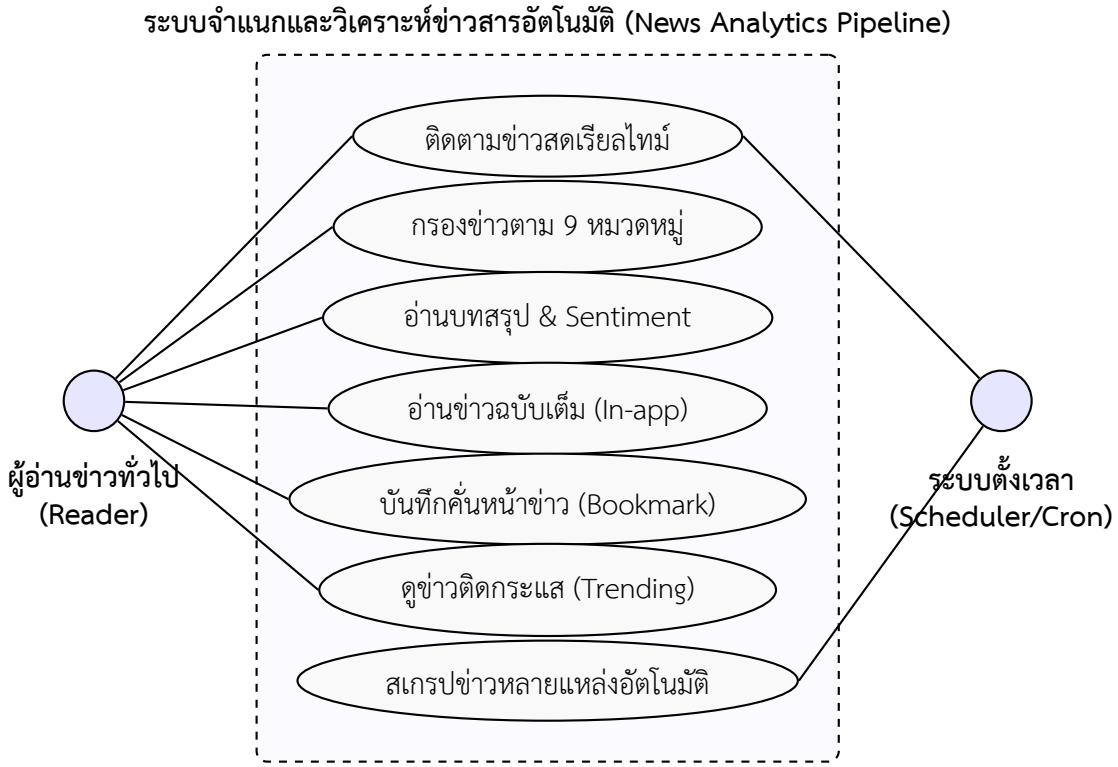
ตารางที่ 4 ผลการประเมินเปรียบเทียบประสิทธิภาพการจัดกลุ่มข่าวสารข้ามสำนัก

เมตริกวัดผล	สถาปัตยกรรมเดิม (Baseline)	สถาปัตยกรรมใหม่ (StoryService)	เกณฑ์เป้าหมาย	ผลการประเมิน
B-cubed Precision	0.9820	**0.8674**	≥ 0.8500	ผ่านเกณฑ์มาตรฐาน
B-cubed Recall	0.5934	**0.7272**	–	เพิ่มขึ้น +22.5%
B-cubed F1-score	0.7398	**0.7911**	≥ 0.7500	ผ่านเกณฑ์ (+6.9%)
Pairwise Precision	0.9524	**0.8032**	–	รักษาความแม่นยำระดับสูง
Pairwise Recall	0.0798	**0.3014**	–	เพิ่มขึ้น +278%
Pairwise F1-score	0.1473	**0.4383**	–	เพิ่มขึ้น +197%
จำนวนคู่ที่แตกกลุ่มผิดพลาด (False Splits)	461 คู่	**350 คู่**	–	ลดลง 24%
จำนวนกลุ่มที่ทำนายได้	97 กลุ่ม	**61 กลุ่ม**	≈ 59 กลุ่มจริง	ใกล้เคียงความจริง

จากตารางที่ 4 สถาปัตยกรรมเดิมมีค่า B-cubed Precision สูงอย่างผิดปกติเนื่องจากอัลกอริทึมจำกัดกรอบเวลาแข็งตัว 36 ชั่วโมงและใช้เกณฑ์ Cosine Similarity สูงเกินไป (0.92) ส่งผลให้กลุ่มข่าวแตกกระจายเป็นข่าวเดี่ยว (Singletons) มากถึง 97 กลุ่ม และมีค่า Pairwise Recall ต่ำเพียง 0.0798 ในขณะที่สถาปัตยกรรมสองชั้นใหม่ซึ่งใช้ Dense Vector จาก WangchanBERTa ผสานการยืนยันเอนทิตีชื่อเฉพาะ (NER) และหน้าต่างสืบค้น 72 ชั่วโมงแบบไม่จำกัดอายุขัย สามารถลดจำนวนคู่ข่าวที่แตกกลุ่มผิดพลาดลงได้ถึงร้อยละ 24 และเพิ่มค่า B-cubed F1 เป็น 0.7911 ผ่านเกณฑ์การยอมรับทั้งหมดได้อย่างสมบูรณ์

3.1.6 แบบจำลองยูสเคส (Use Case Diagram)

แบบจำลองการใช้งานระบบ (Use Case Modeling) แสดงปฏิสัมพันธ์ระหว่างผู้ใช้งานระบบกับฟังก์ชันต่าง ๆ ดังภาพที่ 1



ภาพที่ 1 แผนภาพแบบจำลองยูสเคสของระบบ (Use Case Diagram)

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาโครงงานในปัจจุบันแสดงดังตารางที่ 5

ตารางที่ 5 รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา

ลำดับ	รายการ	รายละเอียดคุณลักษณะ
1	คอมพิวเตอร์ประมวลผลหลัก	Intel Core Ultra 5, RAM 16 GB, SSD 512 GB
2	จอแสดงผล	หน้าจอแล็ปท็อปขนาด 16 นิ้ว
3	เครือข่ายอินเทอร์เน็ต	ความเร็วไม่น้อยกว่า 100/100 Mbps สำหรับเชื่อมต่อ KKU Gen.AI API และดึงข้อมูลข่าว

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์ที่ใช้ในการพัฒนาโครงงานแสดงดังตารางที่ 6

ตารางที่ 6 รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions)

ลำดับ	ซอฟต์แวร์ / ไลบรารี	เวอร์ชันจริง	บทบาทและหน้าที่ในระบบ
1	Python	3.11.15	ภาษาโปรแกรมหลักฝั่งเซิร์ฟเวอร์
2	uv	0.6.14	ตัว จัดการ แพ็ก เก จ และ สภาพ แวดล้อม เสมือน ความเร็วสูง
3	FastAPI	0.141.1	เว็บ เฟรม เวิร์ค แบบ อะ ซิงโค รนัส สำหรับ พัฒนา REST API
4	Uvicorn	0.52.1	เว็บเซิร์ฟเวอร์ ASGI ประสิทธิภาพสูง
5	Pydantic	2.13.4	ตรวจ สอบ และ แปลง โครงสร้าง ข้อมูล ที่ ระดับ Runtime
6	Playwright	1.62.0	จำลองเบราว์เซอร์ Chromium เพื่อดึงหน้าเว็บ JavaScript/SPA
7	Trafilatura	2.2.0	สกัดเนื้อหาหลักของบทความข่าวและแปลงเป็น Markdown
8	BeautifulSoup4	4.15.0	แยก วิเคราะห์ โครงสร้าง เอกสาร HTML และ CSS Selector
9	PyThaiNLP	5.3.5	ตัดคำภาษาไทยด้วยเอนจิน newmm และคัด กรอง Stop words
10	Scikit-learn	1.6.1	โมเดล Calibrated LinearSVC และ TF-IDF Vectorizer
11	Joblib	1.5.3	จัด เก็บ และ โหลด โมเดล Machine Learning (Serialization)
12	NumPy	2.4.6	ประมวล ผล ทาง คณิตศาสตร์ และ อาร์เรย์ เชิง ตัวเลข
13	PyTorch	2.13.0	เฟรม เวิร์ค การ เรียน รู้ เชิง ลึก สำหรับ รัน โมเดล ภาษา
14	Transformers	5.15.1	รันและประเมินผลโมเดล WangchanBERTa
15	OpenAI SDK	2.53.0	เชื่อม ต่อ บริการ โมเดล ภาษา ขนาด ใหญ่ KKU Gen.AI
16	HTTPX	0.28.1	ตัวส่งคำขอ HTTP แบบอะซิงโครนัส
17	Python-SocketIO	5.16.3	จัดการการเชื่อมต่อ WebSocket สองทิศทางฝั่ง เซิร์ฟเวอร์
18	Socket.IO Client (JS)	4.7.5	รับ ส่ง ข้อมูล เหตุ กา รณ์ แบบ เรี ยล ไทม์ ฝั่ง เว็บ เบราว์เซอร์
19	Tailwind CSS	3.4.1	จัดการสไตล์และส่วนติดต่อผู้ใช้แบบ Responsive
20	Obscura (Container)	Latest	เอนจินจำลองเบราว์เซอร์ Chromium ภายใน Container สำหรับดึงข่าวหลังบ้าน (ไม่ได้ใช้กับ In-App Browser)
21	Ruff	0.16.1	เครื่องมือตรวจสอบคุณภาพโค้ดและจัดรูปแบบ (Linter & Formatter)
22	Mypy	2.3.0	ตรวจสอบความถูกต้องของ Type Annotation ภาษา Python
23	Pytest	9.1.1	ชุดทดสอบอัตโนมัติ (Unit Tests, Stress Tests, PDPA Tests, Eval Harness)
24	SQLite3 (WAL Mode)	3.45+	ฐาน ข้อมูล เชิง สัมพันธ์ น้ำ หนัก เบา พร้อม โหมด Write-Ahead Logging สำหรับจัดเก็บข่าวและประเด็น
25	Motor / PyMongo	3.5+	ไดรเวอร์อะซิงโครนัสสำหรับเชื่อมต่อฐานข้อมูล

3.3 แผนการดำเนินงาน

แผนการดำเนินงานตลอดระยะเวลาการทำโครงงานตั้งแต่เดือนมิถุนายนถึงตุลาคม แบ่งออกเป็น 2 ช่วงหลัก ได้แก่ ช่วงการศึกษาและพัฒนาวิศวกรรมระบบจริงซึ่งดำเนินการแล้วเสร็จ (มิถุนายน – สิงหาคม) และช่วงแผนงานการประเมินผล จัดทำแบบสำรวจความพึงพอใจ และสรุปผลโครงงานซึ่งเป็นแผนงานในอนาคตที่ยังไม่ได้ดำเนินการ (กันยายน – ตุลาคม) แสดงดังตารางที่ 7

ตารางที่ 7 แผนการดำเนินงานและไทม์ไลน์ของโครงงาน (Gantt Chart)

ลำดับ	กิจกรรม / ขั้นตอนการดำเนินงาน	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
ส่วนที่ 1: การศึกษา ออกแบบ และพัฒนาวิศวกรรมระบบ (ดำเนินการแล้วเสร็จ ●)						
1	ศึกษาปัญหา รวบรวมความต้องการ และออกแบบสถาปัตยกรรมระบบ	●				
2	พัฒนา ระบบ Scraper Pipeline, Playwright Service และ Multi-tier Cache	●	●			
3	ฝึกสอน/ปรับจูนโมเดลจำแนกข่าว 9 หมวดหมู่ และเชื่อมต่อ KKU Gen.AI API		●	●		
4	พัฒนาเว็บแอปพลิเคชัน Single Page Application (SPA), PWA และ WebSocket		●	●		
5	พัฒนา ระบบ จัด อันดับ Trending/ Hot News, ความปลอดภัย และ PDPA			●		
6	ทดสอบ ระบบเชิงเทคนิคอัตโนมัติ (Automated Unit Tests, Stress Tests)			●		
ส่วนที่ 2: การประเมินผล แบบสำรวจ และจัดทำเอกสารปิดโครงงาน (แผนงานในอนาคต: ยังไม่ได้ดำเนินการ ○)						
7	ทดสอบประเมินความแม่นยำของอัลกอริทึมรวมกลุ่มข่าวและฉันทามติหมวดหมู่ข้ามสำนัก				○	
8	ออกแบบและจัดทำแบบสำรวจความพึงพอใจการใช้งาน (User Survey / Questionnaire)				○	
9	ดำเนินการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing: UAT) และเก็บข้อมูล				○	○
10	วิเคราะห์ข้อมูลสถิติผลการประเมิน สรุปข้อเสนอแนะ และปรับแต่งระบบขั้นสุดท้าย					○
11	จัดทำเอกสาร รายงานโครงงานฉบับสมบูรณ์และเตรียมการนำเสนอโครงงาน					○

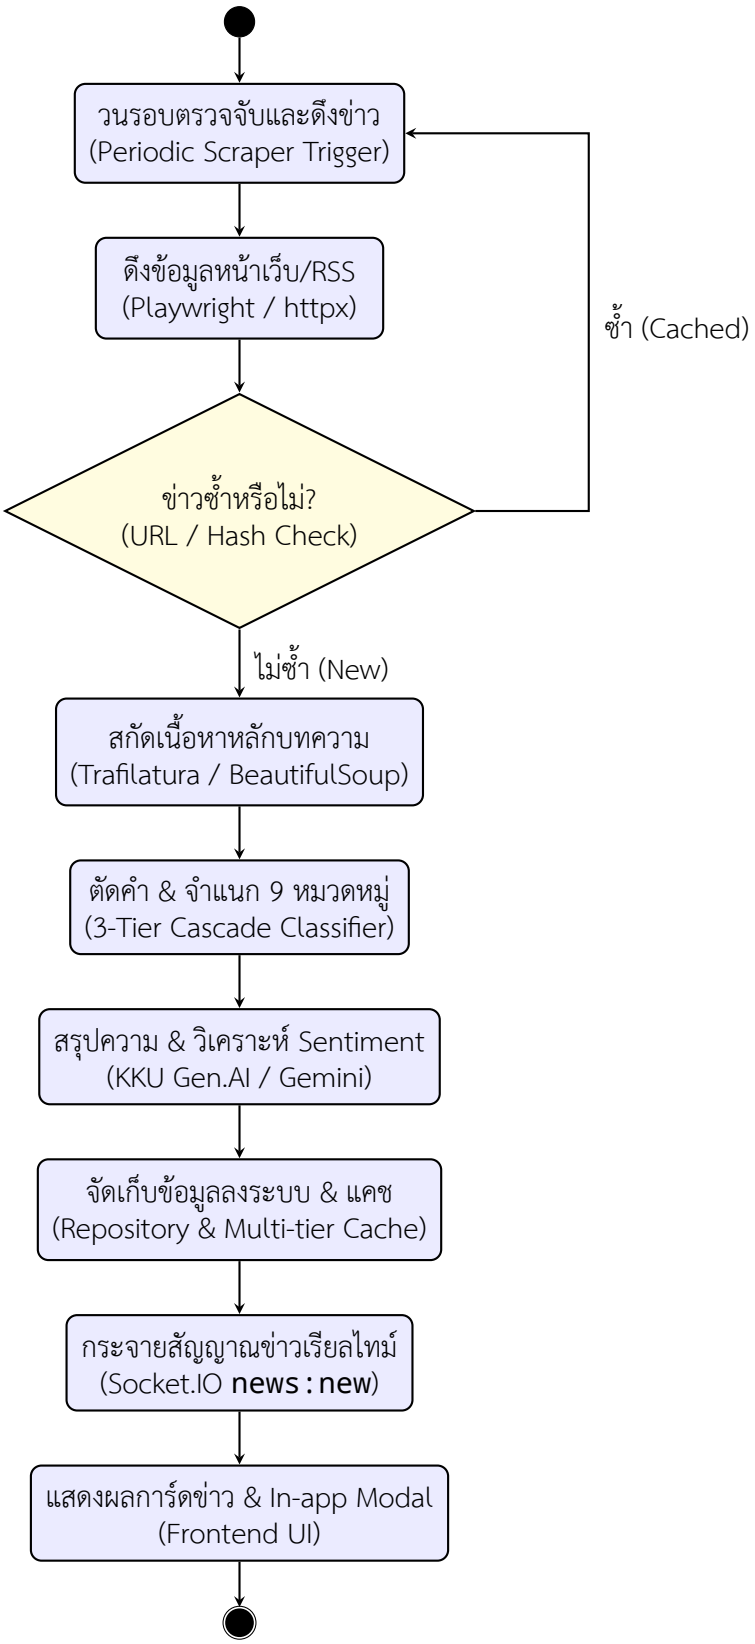
หมายเหตุ: สัญลักษณ์ ● หมายถึง งานที่ดำเนินการแล้วเสร็จ, สัญลักษณ์ ○ หมายถึง แผนงานที่วางไว้ในอนาคต (ยังไม่ได้ดำเนินการ)

บทที่ 4
การวิเคราะห์ ออกแบบและพัฒนาระบบ

4.1 การวิเคราะห์ระบบ

4.1.1 ผังแสดงทิศทางของกิจกรรม (Activity Flow)

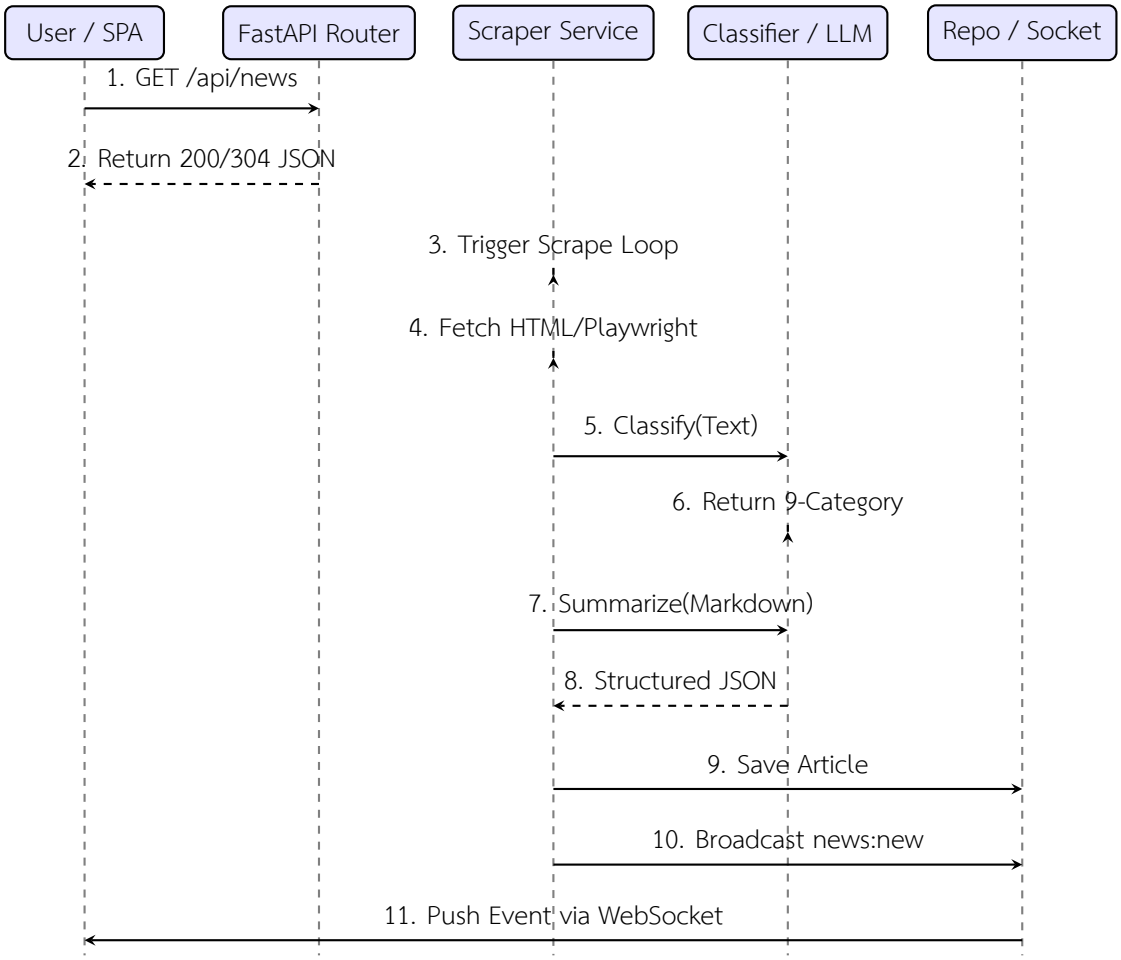
ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติทำงานในลักษณะกระบวนการต่อเนื่อง (Data Pipeline) โดยเริ่มตั้งแต่การดึงข้อมูลจากแหล่งข่าว การประมวลผลและการสกัดข้อมูล การสรุปเนื้อหาและจำแนกหมวดหมู่ ไปจนถึงการบันทึกลงหน่วยจัดเก็บและการกระจายข้อมูลแบบเรียลไทม์ไปยังส่วนติดต่อผู้ใช้ ดังแสดงในผังกิจกรรม (Activity Diagram) ภาพที่ 2



ภาพที่ 2 แผนภาพแสดงทิศทางกิจกรรมของระบบ (Activity Diagram)

4.1.2 แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram)

การปฏิสัมพันธ์ระหว่างส่วนประกอบต่าง ๆ ของระบบ ตั้งแต่ฝั่งผู้ใช้งาน เว็บเซิร์ฟเวอร์ บริการสเกรปเปอร์ ปัญญาประดิษฐ์ และระบบกระจายข่าว แสดงดังภาพที่ 3



ภาพที่ 3 แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram)

4.1.3 รายการความต้องการของระบบ

(1) ความต้องการเชิงฟังก์ชัน (Functional Requirements)

ความต้องการเชิงฟังก์ชันของระบบสรุปได้ดังตารางที่ 8

ตารางที่ 8 ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements)

รหัส	ชื่อ Requirement	รายละเอียดความสามารถของระบบ
FR-01	Automated Multi-source Scraping	ระบบสามารถดึงข้อมูลข่าวจากแหล่งข่าวออนไลน์หลากหลายแหล่ง ทั้งแบบ RSS Feed, เว็บไซต์ HTML ปกติ และเว็บไซต์ที่เรนเดอร์ด้วย JavaScript ผ่าน Playwright
FR-02	Dynamic Source Registration	ระบบรองรับการเพิ่ม/ปรับปรุงแหล่งข่าวใหม่ได้อย่างยืดหยุ่น ผ่าน Decorator (`@register_source`) โดยไม่ต้องแก้ไขโค้ดส่วนประมวลผลหลัก
FR-03	9-Category Thai NLP Classification	ระบบสามารถจำแนกหมวดหมู่ข่าวภาษาไทยออกเป็น 9 หมวดหมู่หลักได้อย่างถูกต้องด้วยเทคนิค 3-Tier Cascade Classifier
FR-04	LLM-Powered Summarization	ระบบสามารถสร้างบทสรุปย่อ ประเด็นสำคัญ และวิเคราะห์อารมณ์ของข่าว (Sentiment) โดยใช้โมเดลภาษาขนาดใหญ่ผ่าน KKU Gen.AI API
FR-05	Real-time WebSocket Push	ระบบ สามารถ กระจาย ข่าวสาร ใหม่ และ การ อัปเดต สถานะการดึงข่าวไปยังผู้ใช้ทันทีผ่าน Socket.IO โดยผู้ใช้ไม่ต้องรีเฟรชหน้าจอ
FR-06	Multi-tier Caching	ระบบ มี กลไก จัด เก็บ แคช ใน หน่วย ความ จำ (`AsyncInMemoryCache`) และ แคช แบบ มี เงื่อนไข (HTTP 304) เพื่อลดการดึงข้อมูลซ้ำซ้อนและลดภาระเซิร์ฟเวอร์
FR-07	Engagement Tracking & Personalization	ระบบบันทึกพฤติกรรมการใช้งาน (การคลิกอ่าน, การขยายบทสรุป, การบันทึกคั่นหน้า) ผ่านคุกกี้เพื่อนำไปประมวลผลจัดอันดับข่าวที่น่าสนใจ (Trending/Recommended)
FR-08	In-app Reading Experience	ระบบมีหน้าต่างแสดงผลบทความข่าวและสรุปเนื้อหาในตัวเว็บ (In-app Modal Reader) เพื่อความสะดวกในการอ่าน

(2) ความต้องการที่ไม่ใช่เชิงฟังก์ชัน (Non-Functional Requirements)

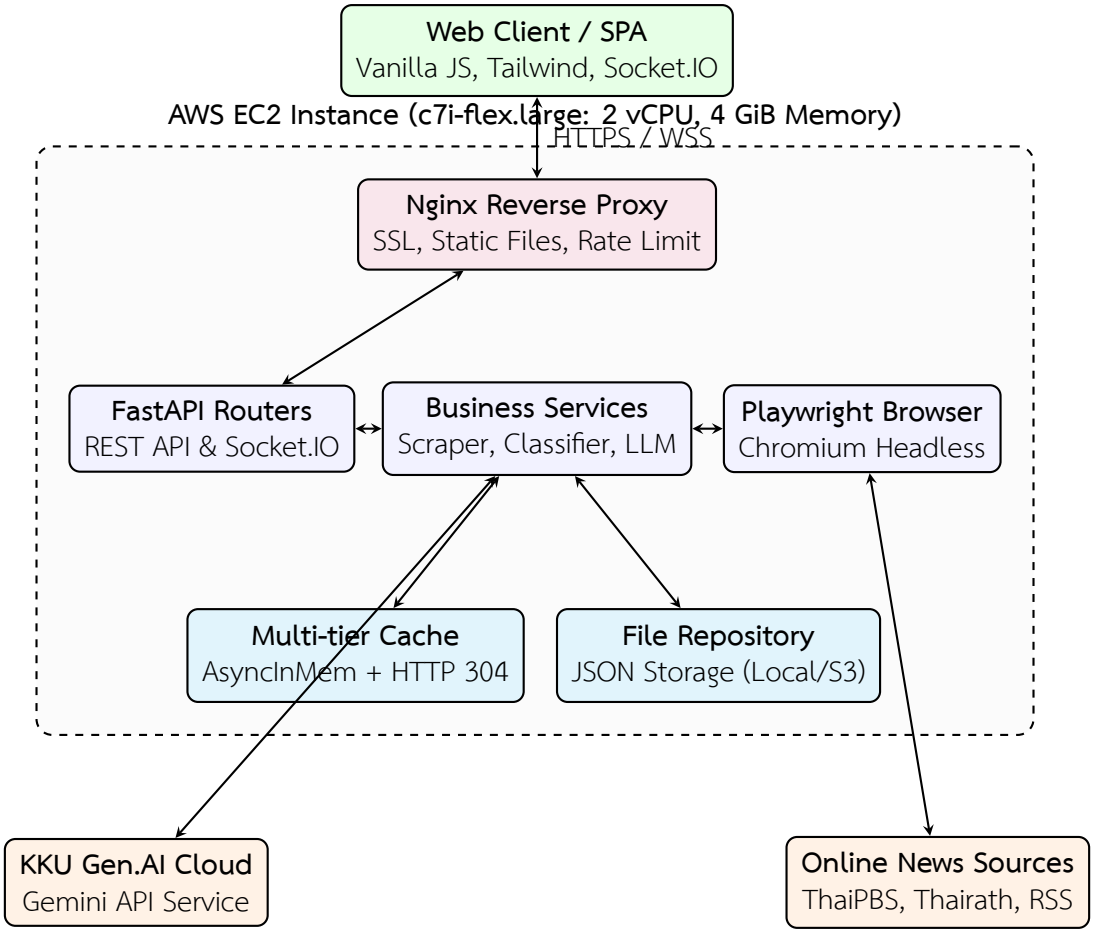
ในด้านความต้องการที่ไม่ใช่เชิงฟังก์ชัน ระบบได้รับการออกแบบให้ตอบสนองข้อกำหนดสำคัญ 4 ประการ ได้แก่ ประการแรก ด้านประสิทธิภาพ (Performance) กำหนดให้เวลาการตอบสนองคำขอเรียกดูรายการข่าวผ่าน REST API (`GET /api/news`) เฉลี่ยต่ำกว่า 150 มิลลิวินาทีเมื่อมีข้อมูลจัดเก็บในหน่วยความจำแคช และมีอัตราความหน่วงเวลา (Latency) ในการกระจายข่าวสารใหม่ผ่าน WebSocket ต่ำกว่า 500 มิลลิวินาทีนับจากช่วงเวลาที่ข่าวถูกบันทึกลงระบบสำเร็จ ประการที่สอง ด้านความคงทนและการรองรับข้อผิดพลาด (Reliability & Fault Tolerance) ความล้มเหลวในการดึงข้อมูลจากแหล่งข่าวใดแหล่งข่าวหนึ่งต้องไม่ส่งผลกระทบต่อรอบการทำงานของแหล่งข่าวอื่น (Isolation of Failures) พร้อมทั้งมีกลไกสำรอง (Fallback

Mechanism) รองรับการแสดงผลข้อความสรุปพื้นฐานในกรณีที่บริการ LLM ภายนอกขัดข้อง ประการที่สาม ด้านสถาปัตยกรรมและการขยายตัว (Maintainability & Extensibility) ออกแบบโครงสร้างซอฟต์แวร์ตามหลักการ SOLID และ GRASP โดยแยกชั้นความรับผิดชอบอย่างชัดเจน ตลอดจนการประยุกต์ใช้ Protocol Interface ตามรูปแบบ Port and Adapter Pattern ในการเข้าถึงคลังข้อมูล และประการสุดท้าย ด้านความเป็นส่วนตัวและการรักษาความปลอดภัย (Privacy & Usability) ระบบยึดหลักการไม่เก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII) และมีแถบขอความยินยอมการใช้งานคุกกี้ตามมาตรฐานการคุ้มครองข้อมูลส่วนบุคคล

4.2 การออกแบบระบบ

4.2.1 สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture)

ระบบได้รับการออกแบบโครงสร้างสถาปัตยกรรมระดับระบบ (System Architecture Design) สำหรับการติดตั้งบน AWS EC2 `c7i-flex.large` (2 vCPU, 4 GiB Memory) พร้อมการแยกโมดูลและคอนเทนเนอร์อย่างชัดเจน ดังแสดงในภาพที่ 4



ภาพที่ 4 แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architecture Diagram)

ตารางที่ 9 แสดงความรับผิดชอบของแต่ละเลเยอร์ในระบบ

ตารางที่ 9 การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers)

เลเยอร์	โฟลเดอร์/โมดูล	หน้าที่และความรับผิดชอบ
Presentation	`frontend/static/`	จัดการหน้าเว็บ Single Page Application (SPA), Bento Hub, หน้าระบบมอนิเตอร์ (`monitoring.html`) และ WebSocket
Routing	`backend/routers/`	รับคำขอ HTTP REST API (`news`, `story`, `macro_event`, `trending`, `monitoring`) และส่งต่อข้อมูล
Service (Business Logic)	`backend/ services/`	ควบคุมตรรกะระบบ ได้แก่ `ScraperService`, `StoryService` (ระบุประเด็นข่าว), `TrendingService` (จัดอันดับกระแส), `StoryPresentationService` (สังเคราะห์เนื้อหา), `MacroEventService` (รวมมหากาพย์ประเด็น)
Scraper	`backend/ scrapers/`	สเกรปเปอร์เฉพาะแต่ละสำนักข่าว ลงทะเบียนด้วย Decorator พร้อมฟังก์ชันแยกวิเคราะห์ HTML
Core / Infrastructure	`backend/core/`	เครื่องมือส่วนกลาง เช่น `BrowserService` (Playwright), `SocketManager`, `L1Cache` และ `AsyncInMemoryCache`
Persistence	`backend/repo/`	บันทึกและดึงข้อมูลข่าว ประเด็นข่าว และสถิติ (`FileNewsRepo`, `SqliteNewsRepo`, `MongoStoryRepo`, `MacroEventRepo`)
Schema	`backend/schemas/`	กำหนดโครงสร้างข้อมูล (Pydantic Models: `NewsArticle`, `StoryRecord`, `TrendingScoreBreakdown`)

4.2.2 การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล

ระบบได้รับการออกแบบโครงสร้างข้อมูลแยกเป็น 3 ส่วนหลัก ได้แก่ โครงสร้างบทความข่าวเดี่ยว (`NewsArticle` Schema ดังตารางที่ 10) โครงสร้างประเด็นข่าวสารหลายสำนัก (`StoryRecord` Schema ดังตารางที่ 11) และโครงสร้างคะแนนแจกแจงกระแสข่าว (`TrendingScoreBreakdown` Schema)

ตารางที่ 10 โครงสร้างข้อมูลบทความข่าว (`NewsArticle` Schema)

ฟิลด์ (Field)	ชนิดข้อมูล	จำเป็น	คำอธิบาย
`id`	String	ใช่	รหัสระบุข่าวแบบไม่ซ้ำ (Hash จาก URL)
`title`	String	ใช่	หัวข้อข่าว
`url`	String	ใช่	ลิงก์ต้นฉบับบทความข่าว
`source`	String	ใช่	ชื่อ สำนัก ข่าว ต้นทาง (เช่น ThaiPBS, Thairath, BBC)
`category`	String	ใช่	หมวดหมู่ข่าว (politics, economy, tech, etc.)
`summary`	String	ไม่ใช่	ข้อความสรุปย่อเนื้อหาข่าวจาก LLM
`key_points`	List[String]	ไม่ใช่	รายการ ประเด็น สำคัญ ของ ข่าว (Bullet points)
`sentiment`	String	ไม่ใช่	ค่า อารมณ์ ของ ข่าว (positive, neutral, negative)
`image_url`	String	ไม่ใช่	ลิงก์รูปภาพหน้าปกบทความ
`published_at`	String	ใช่	วันและเวลาที่เผยแพร่ตามมาตรฐาน ISO 8601
`created_at`	String	ใช่	วันและเวลาที่ระบบนำเข้าข่าว
`story_id`	String	ไม่ใช่	รหัส กลุ่ม ประเด็น ข่าว ที่ รายงาน เหตุการณ์เดียวกันข้ามสำนัก
`consensus_category`	String	ไม่ใช่	หมวดหมู่ระดับกลุ่มข่าวที่ผ่านฉันทามติเสียงข้างมาก

ตารางที่ 11 โครงสร้างข้อมูลกลุ่มประเด็นข่าวสาร (`StoryRecord` Schema)

ฟิลด์ (Field)	ชนิดข้อมูล	จำเป็น	คำอธิบาย
`story_id`	String	ใช่	รหัส ระบุ ประเด็น ข่าว แบบ คงทน (เช่น `story_0b86804a`)
`title`	String	ใช่	หัวข้อข่าวตัวแทนตั้งต้นของประเด็นข่าว
`category`	String	ใช่	หมวดหมู่หลักของประเด็นข่าว
`status`	String	ใช่	สถานะ วงจร ชีวิต ประเด็น ข่าว (`active` หรือ `dormant`)
`article_urls`	List[String]	ใช่	รายการ URL ของบทความข่าวทั้งหมดในกลุ่มประเด็น
`article_count`	Integer	ใช่	จำนวนบทความข่าวทั้งหมดที่เชื่อมโยงกับประเด็นนี้
`outlets`	List[String]	ใช่	รายชื่อสำนักข่าวอิสระที่รายงานประเด็นนี้
`outlet_count`	Integer	ใช่	จำนวนสำนักข่าวที่ไม่ซ้ำ (K)
`centroid`	List[Float]	ใช่	เวกเตอร์ศูนย์กลาง 768 มิติ ปรับปรุงด้วย Exponential Moving Average
`entities`	List[String]	ใช่	รายการ เอน ทิ ตี ชื่อ เฉพาะ บุคคล/สถาน ที่/องค์กรที่สะสม
`headline`	String	ไม่ใช่	พาดหัวข่าวสังเคราะห์ภาพรวมจาก LLM
`summary`	String	ไม่ใช่	เนื้อหา สรุป สังเคราะห์ ข้าม สำนัก ข่าว จาก LLM
`timeline`	List[Object]	ใช่	รายการ พัฒนาการ ของ เหตุการณ์ ตาม ลำดับเวลาพร้อมลิงก์อ้างอิง

4.3 การพัฒนาระบบและการทำงานของส่วนประกอบหลัก

4.3.1 กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)

ระบบสเกรปข่าวถูกออกแบบให้ทำงานแบบ Asynchronous ทั้งหมด โดยในแต่ละรอบการทำงาน `ScraperService` จะสร้าง Task สำหรับแต่ละแหล่งข่าวเพื่อดึงข้อมูลพร้อมกัน (Concurrent Scraping) พร้อมทั้งรองรับการดึงหน้าเว็บที่มีการป้องกันด้วย Cloudflare หรือเรนเดอร์เนื้อหาผ่าน JavaScript ผ่าน `BrowserService` โดยการลงทะเบียนแหล่งข่าวใช้ Decorator `@register_source` ดังตัวอย่าง:

```
@register_source("ThaiPBS", "https://www.thaipbs.or.th", "#FF5722")
async def scrape_thaipbs(browser_service: BrowserService) -> list[RawNewsItem]:
    html = await browser_service.fetch_page("https://www.thaipbs.or.th/news")
    return parse_news_cards(html, source="ThaiPBS")
```

Listing 4.1: ตัวอย่างการลงทะเบียนแหล่งข่าวด้วย Decorator

4.3.2 ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)

การจำแนกหมวดหมู่ข่าวใช้แนวทางไฮบริด (Hybrid Classification Pipeline) โดยเริ่มต้นจากการสกัดคำสำคัญจากหัวข้อข่าวด้วย PyThaiNLP (`engine="newmm"`) เพื่อเทียบกับชุดคำศัพท์เฉพาะกลุ่มทั้ง 9 หมวดหมู่หลัก โดยให้ค่าน้ำหนักตามตำแหน่งและความยาวของคำ ในกรณีที่คะแนนจากกฎคำสำคัญไม่ถึงเกณฑ์ความเชื่อมั่นที่กำหนด ระบบจะส่งเวกเตอร์ TF-IDF ของข้อความเข้าสู่โมเดล Support Vector Machine (LinearSVC) ที่ผ่านการเทรนล่วงหน้า และมีโมเดล WangchanBERTa รองรับการประมวลผลข้อความเชิงลึกสำหรับข่าวที่มีบริบทซับซ้อน

4.3.3 ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และเอนจินจำลองเบราว์เซอร์ Obscura

เพื่อยกระดับประสบการณ์การอ่านข่าวให้มีความต่อเนื่องและปลอดภัย ระบบได้พัฒนาหน้าต่างอ่านบทความฉบับเต็มภายในตัวเว็บ (In-App Modal Reader) สำหรับแสดงผลเนื้อหาข่าวที่ผ่านการสกัดและทำความสะอาดแล้ว โดยทำงานร่วมกับ `BrowserService` และคอนเทนเนอร์ Obscura เมื่อผู้อ่านคลิกเปิดอ่านข่าว ระบบจะตรวจสอบว่ามีเนื้อหา HTML ที่ผ่านการทำความสะอาดแล้วใน `AsyncInMemoryCache` หรือไม่ หากมีจะส่งกลับทันที ภายในเวลาต่ำกว่า 10 มิลลิวินาที ในกรณีที่เป็นเว็บไซต์ที่เรนเดอร์ด้วย JavaScript ซับซ้อน คอนเทนเนอร์ Obscura จะทำหน้าที่เป็น Headless Browser แยกส่วนเพื่อสกัดเนื้อหาข่าวเบื้องหลังผ่าน Chrome DevTools Protocol (CDP WebSocket `ws://obscura:9222`) โดยไม่ได้ถูกนำไปรันเป็น In-App Browser ฝั่งผู้ใช้โดยตรง จากนั้นระบบ Backend จะตัดโฆษณา ป้ายแบนเนอร์ แทร็กเกอร์ และองค์ประกอบตกแต่งที่ไม่จำเป็นออกทั้งหมด พร้อมขจัดสคริปต์อันตราย (Anti-XSS) เพื่อความปลอดภัยก่อนส่งไปแสดงผลบนหน้าต่างอ่านข่าว และหากคอนเทนเนอร์ Obscura ไม่ตอบสนองภายในระยะเวลา Timeout ที่กำหนด ระบบจะสลับไปรัน Local Playwright Chromium Engine ภายในตัวแม่ข่ายโดยอัตโนมัติ ทำให้กระบวนการดึงเนื้อหาดำเนินไปได้อย่างต่อเนื่อง

4.3.4 ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)

ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้กับ KKU Gen.AI API โดยออกแบบ Prompt ให้ส่งคืนผลลัพธ์เป็นโครงสร้าง JSON ประกอบด้วย บทสรุปกระชับ 2–3 ประโยค ประเด็นสำคัญ 3–5 ข้อ และการวิเคราะห์อารมณ์ของข่าว (Sentiment: Positive, Neutral, Negative) ในภาษาเดียวกับเนื้อหาต้นฉบับ

4.3.5 สถาปัตยกรรม ระบุ ประเด็น ข่าว และ จัด อันดับ กระแส ข่าว แบบ สองชั้น (Two-Layer Story Identification & Deterministic Trending)

เพื่อแก้ไขข้อจำกัดของระบบเดิมที่คำนวณการจัดกลุ่มข่าวแบบชั่วคราว (Ad-hoc Clustering) ซึ่งจำกัดกรอบเวลาแข็งตัวไว้เพียง 36–48 ชั่วโมงจนทำให้ข่าวยืดเยื้อแตกกระจาย และมีการพึ่งพา LLM ในเส้นทางการประมวลผลอันดับข่าว ระบบได้ปรับปรุงสถาปัตยกรรมใหม่เป็นแบบสองชั้นที่แยกหน้าที่กันอย่างชัดเจนตามหลักการวิศวกรรมซอฟต์แวร์ ได้แก่ ชั้นที่ 1 การระบุและติดตามประเด็นข่าวแบบออนไลน์คงทน (`StoryService`) และชั้นที่ 2 เอนจินจัดอันดับกระแสข่าวเชิงสถิติแน่นอน (`TrendingService`)

(1) การ ระบุ ประเด็น ข่าว ออนไลน์ แบบ คงทน (Persistent Online Story Identification)

ในชั้นที่ 1 เมื่อมีบทความข่าวใหม่เข้าสู่ระบบ กระบวนการระบุประเด็นข่าวจะทำงานแบบออนไลน์เชิงเพิ่มพูน (Online Incremental Assignment) โดยไม่จำเป็นต้องคำนวณจัดกลุ่มข่าวใหม่ทั้งคลังข้อมูล ซึ่งประกอบด้วยขั้นตอนการทำงานสำคัญ 4 ขั้นตอน:

ขั้นตอนแรกคือ การสกัดเวกเตอร์ความหมายหนาแน่น (Dense Semantic Embeddings) โดย นำ ข้อความ พาด หัว ข่าว ร่วม กับ เนื้อหา ย่อ แปลง เป็น เวก เตอร์ ขนาด 768 มิติ ด้วย โมเดล WangchanBERTa ผ่านการรวมแบบเฉลี่ยถ่วงน้ำหนัก (Masked Mean Pooling) และปรับให้เป็นเวกเตอร์หนึ่งหน่วย (L_2 Normalization) ทำให้ผลคูณจุด (Dot Product) มีค่าเท่ากับค่าความคล้ายคลึงโคไซน์ (Cosine Similarity) พร้อมทั้งมีระบบแคชระดับ L1 ป้องกันการเข้ารหัสข้อความซ้ำซ้อน

ขั้น ตอน ที่ สอง คือ การ สกัด เอ น ทิ ตี ชื่อ เฉพาะ (Named Entity Recognition: NER) โดย ใช้ โมเดล `thainer-v2` ของ PyThaiNLP ใน การ สกัด ชื่อ บุคคล (PERSON) องค์กร (ORGANIZATION) สถาน ที่ (LOCATION) และ สิ่ง อำนวย ความ สะดวก (FACILITY) ออก จาก บทความ ข่าว

ขั้นตอนที่สามคือ การสืบค้นกลุ่มข่าวผู้ท้าชิงผ่านหน้าต่างเวลา 72 ชั่วโมงแบบไม่ปิดกั้นอายุขัย (Non-capping 72-Hour Candidate Window) โดยระบบจะค้นหากลุ่มประเด็นข่าว (`StoryRecord`) ที่มีข่าวอัปเดตล่าสุดภายใน 72 ชั่วโมงก่อนเวลาของบทความใหม่ ซึ่งการกำหนดหน้าต่างเวลานี้ช่วยควบคุมขอบเขตความซับซ้อนในการคำนวณโดยไม่จำกัดอายุขัยของประเด็นข่าว ทำให้เหตุการณ์วิกฤตที่ยืดเยื้อ เช่น อุทกภัย สามารถติดตามและผูกโยงข่าวใหม่เข้ากับประเด็นเดิมได้อย่างต่อเนื่องข้ามสัปดาห์

ขั้นตอนที่สี่คือ การตัดสินใจรวมกลุ่มด้วยเกณฑ์สองระดับ (Two-Band Cosine Decision Gate) โดยคำนวณความคล้ายคลึงโคไซน์ระหว่างเวกเตอร์บทความใหม่กับจุดศูนย์กลางของกลุ่ม

ประเด็นข่าว ($\mathbf{c}$):

$$\text{MergeDecision} = \begin{cases} \text{Direct Merge} & \text{เมื่อ } \cos(\mathbf{e}_{\text{new}}, \mathbf{c}) \geq 0.85 \\ \text{Confirmed Merge} & \text{เมื่อ } 0.74 \leq \cos(\mathbf{e}_{\text{new}}, \mathbf{c}) < 0.85 \text{ และมีเอนทิตีตรงกัน } \geq 1 \\ \text{New Story Cluster} & \text{กรณีอื่น ๆ (สร้างกลุ่มประเด็นข่าวใหม่)} \end{cases} \tag{3}$$

ในกรณีที่มีการรวมบทความเข้าสู่กลุ่มประเด็นเดิม เวกเตอร์จุดศูนย์กลางจะได้รับการปรับปรุงอย่างต่อเนื่องด้วยค่าเฉลี่ยเคลื่อนที่แบบเอกซ์โพเนนเชียล (Exponential Moving Average: EMA) ตามสมการ:

$$\mathbf{c}_{\text{new}} = \alpha \cdot \mathbf{c}_{\text{old}} + (1 - \alpha) \cdot \mathbf{e}_{\text{new}} \tag{4}$$

โดยกำหนดค่าน้ำหนัก $\alpha = 0.85$ ช่วยรักษาเสถียรภาพของแกนเรื่องเดิมไม่ให้เบี่ยงเบนเร็วเกินไป พร้อมทั้งปรับตัวรองรับพัฒนาการใหม่ของข่าวได้อย่างยืดหยุ่น นอกจากนี้ กลุ่มประเด็นข่าวจะได้รับการบริหารจัดการวงจรชีวิต (Lifecycle State) ระหว่างสถานะพร้อมทำงาน (`active`) เมื่อมีข่าวอัปเดตในรอบ 72 ชั่วโมง และสถานะพักตัว (`dormant`) เมื่อไม่มีความเคลื่อนไหวเกิน 72 ชั่วโมง เพื่อประหยัดทรัพยากรระบบ โดยสามารถฟื้นคืนสถานะสู่ `active` ได้ทันทีหากมีข่าวด่วนที่เกี่ยวข้องเกิดขึ้นในอนาคต

(2) เอน จิน จัด อันดับ กระแส ข่าว เชิง สถิติ แน่นอน (Deterministic Trending Engine)

ในชั้นที่ 2 การจัดอันดับกระแสข่าวจะประมวลผลบนกลุ่มประเด็นข่าว (`StoryRecord`) ที่ผ่านการรวมกลุ่มและบันทึกแล้ว โดยตัดการพึ่งพาโมเดลภาษาขนาดใหญ่ (LLM) ออกจากเส้นทางการคำนวณคะแนนอย่างสิ้นเชิง (Zero LLM in scoring path) ทำให้การจัดอันดับมีความรวดเร็วระดับเสี้ยววินาทีและได้ผลลัพธ์ที่แน่นอนเชิงคณิตศาสตร์ (Deterministic) โดยคำนวณผ่าน 6 มิติเชิงสถิติร่วมกับตัวคูณลดทอนข่าวประจำวัน:

$$\text{FinalScore} = \left(\sum_{i=1}^{6} w_i \cdot s_i \right) \times \text{RoutinePenalty} \tag{5}$$

โดยมีรายละเอียดของแต่ละมิติคะแนน ดังนี้: ปริมาณข่าวในรอบ 24 ชั่วโมง (s_1 น้ำหนัก $w_1 = 0.25$) คำนวณจาก $s_1 = \ln(1 + N_{\text{recent}})$ เพื่อสะท้อนปริมาณความสนใจของสื่อมวลชน อัตราเร่งการมาถึงของข่าว (s_2 น้ำหนัก $w_2 = 0.30$) คำนวณจากอัตราส่วนระหว่างความถี่ของข่าวในรอบ 24 ชั่วโมงล่าสุดเทียบกับช่วงเวลาฐาน 48 ชั่วโมงก่อนหน้า เพื่อตรวจจับสัญญาณข่าวด่วนที่กำลังปะทุขึ้นในสังคม ความหลากหลายของสำนักข่าว (s_3 น้ำหนัก $w_3 = 0.25$) คำนวณจากฟังก์ชันรากที่สองของจำนวนสำนักข่าวที่ไม่ซ้ำกัน $s_3 = \sqrt{N_{\text{outlets}}}$ พร้อมกลไกลดทอนกรณีสำนักพิมพ์ในเครือเดียวกัน (Syndication Discount) เพื่อให้ข่าวที่รายงานโดยสำนักข่าวอิสระหลายแห่งมีน้ำหนักสูงกว่าข่าวที่คัดลอกกันมา การลดทอนตามเวลา (s_4 น้ำหนัก $w_4 = 0.10$) คำนวณจากฟังก์ชันเอกซ์โพเนนเชียลค่าครึ่งชีวิต 12 ชั่วโมง $s_4 = 2^{-\Delta t/12}$ เพื่อเปิดทางให้ข่าวสดใหม่ขึ้นมาทดแทนข่าวเก่า ความแปลกใหม่ของประเด็น (s_5 น้ำหนัก $w_5 = 0.05$) คำนวณจากระยะห่างเชิงความหมายของจุดศูนย์กลางประเด็นเทียบกับประเด็นข่าวอื่น $s_5 = 1.0 - \max_{j \neq k} \cos(\mathbf{c}_k, \mathbf{c}_j)$

และคะแนนปฏิสัมพันธ์จากผู้อ่าน (s_6 น้ำหนัก $w_6 = 0.05$) คำนวณจากสถิติพฤติกรรมการอ่านข่าวแบบนิรนาม $s_6 = \ln(1 + N_{\text{clicks}} + 2N_{\text{summaries}} + 3N_{\text{bookmarks}})$

สำหรับตัวคูณลดทอนข่าวประจำวัน (Routine News Penalty) ระบบได้กำหนดกลไกตรวจจับข่าวที่เกิดขึ้นเป็นวงรอบประจำวัน เช่น ข่าวราคาน้ำมัน ราคาทองคำ พยากรณ์อากาศ และผลสลากกินแบ่งรัฐบาล โดยกำหนดตัวคูณปรับลดคะแนน RoutinePenalty $= 0.25$ (ลดทอนคะแนนลงร้อยละ 75) ในขณะที่ข่าวทั่วไปมีค่าเท่ากับ 1.0 กลไกนี้ช่วยป้องกันไม่ให้ข่าวประจำวันแย่งพื้นที่ข่าวกระแสสังคมที่แท้จริง พร้อมทั้งระบบส่งคืนข้อมูลแจกแจงคะแนนครบทุกมิติ (`TrendingScoreBreakdown`) ทำให้กระบวนการจัดอันดับมีความโปร่งใสและตรวจสอบที่มาได้ทุกขั้นตอน

4.3.6 ส่วนนำเสนอและการสังเคราะห์เนื้อหาประเด็นรวม (Story Presentation & LLM Synthesis)

สำหรับกลุ่มประเด็นข่าวที่ติดอันดับกระแสความนิยมสูงสุด ระบบจะส่งต่อข้อมูลให้ `StoryPresentationService` เพื่อสร้างเนื้อหานำเสนอเชิงลึก โดยอาศัยโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) ในการสังเคราะห์พาดหัวข่าวประเด็นรวม (Macro Headline) ที่เป็นกลางและครอบคลุมทุกมุมมอง การสร้างบทสรุปย่อสังเคราะห์ข้ามสำนักข่าว (Multi-Article Synthesis) และการเรียบเรียงไทม์ไลน์พัฒนาการของเหตุการณ์ตามลำดับเวลา (Chronological Timeline Events) พร้อมลิงก์อ้างอิงกลับไปยังสำนักข่าวต้นทาง โดยผลลัพธ์ทั้งหมดจะถูกบันทึกแคชลงในฐานข้อมูลประเด็นข่าวโดยตรง เพื่อลดค่าใช้จ่ายในการเรียกใช้ API ซ้ำซ้อน และหากบริการ LLM ภายนอกขัดข้องหรือไม่ตอบสนอง ระบบมีกลไกสำรองการทำงานแบบอัตโนมัติ (Heuristic Fallback) โดยสลับไปใช้พาดหัวข่าวตัวแทนหลักและเรียบเรียงไทม์ไลน์ตามเวลาเผยแพร่จริง ทำให้ระบบสามารถตอบกลับคำขอด้วยสถานะ HTTP 200 ได้อย่างมีเสถียรภาพเสมอ

4.3.7 การ จัด กลุ่ม มหา กาพย์ ประเด็น ข่าว และ ส่วน ติดต่อ ผู้ ใช้ แบบ Bento Hub

เพื่อ ยก ระดับ การ ติดตาม ข่าวสาร ที่ มี มิติ ความ ซับ ซ้อน สูง ระบบ ได้ พัฒนา `MacroEventService` สำหรับ เชื่อม โยง กลุ่ม ประเด็น ข่าว ย่อย (Sub-events) ที่ มี ความสัมพันธ์เชิงบริบทเข้าสู่มหากาพย์ประเด็นข่าวขนาดใหญ่ (Macro Storyline) พร้อมทั้งรองรับข้อยกเว้นกรณีวิกฤต (Crisis Exemption) ที่ช่วยให้ข้อมูลภัยพิบัติหรือเหตุฉุกเฉินระดับชาติได้รับการยกเว้นการลดทอนเวลา

ในด้านส่วนต่อประสานผู้ใช้ หน้าแรกของระบบได้รับการออกแบบใหม่เป็น Macro Storyline Bento Hub ซึ่งจัดวางองค์ประกอบแบบ 3 มุมมองหลัก (3-Perspective Matrix) ได้แก่ แถบข่าวเด่นประจำวัน บัตรสรุปประเด็นข่าวพร้อมป้ายสำนักข่าวที่รายงานร่วมกัน (Publisher Filter Pills) และแถบแฮชแท็กเชิงโต้ตอบ (#Hashtags Ribbon) เพื่อให้ผู้ใช้งานสามารถคลิกสำรวจมุมมองที่หลากหลายของแต่ละสำนักข่าวได้อย่างสะดวก นอกจากนี้ ระบบยังได้จัดเตรียมหน้าต่างติดตามและศูนย์ควบคุมสถานะระบบ (`frontend/monitoring.html`) สำหรับผู้ดูแลระบบ เพื่อตรวจสอบอัตราการรับเข้าของข่าว สุขภาพของแต่ละสำนักข่าว สถิติการทำงานของแคช และความเสถียรของไปป์ไลน์แบบเรียลไทม์

4.3.8 การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket

เมื่อมีข่าวใหม่ที่ผ่านการสรุปและจำแนกเรียบร้อยแล้ว `SocketManager` จะทำการกระจาย Event (**news : new**) ไปยังเบราว์เซอร์ของผู้ใช้ทุกคนที่กำลังเปิดหน้าเว็บอยู่ เพื่อให้ผู้ใช้ได้รับข่าวสารล่าสุดทันทีโดยไม่ต้องทำการรีเฟรชหน้าต่างเบราว์เซอร์

4.4 การออกแบบและมาตรการความมั่นคงปลอดภัยของระบบ (System Security Design)

ความมั่นคงปลอดภัยของระบบ (System Security) และการคุ้มครองความเป็นส่วนตัวของผู้ใช้งาน (Data Privacy) เป็นปัจจัยสำคัญในการพัฒนาเว็บแอปพลิเคชันยุคใหม่ โดยระบบได้ออกแบบมาตรการรักษาความปลอดภัยครอบคลุม 4 มิติหลัก ดังนี้

4.4.1 ความมั่นคงปลอดภัยระดับเครือข่ายและเว็บเซิร์ฟเวอร์ (Network & Gateway Security)

ในระดับเครือข่าย ระบบได้ติดตั้ง Nginx Reverse Proxy ทำหน้าที่เป็น Gateway จัดการเข้ารหัสช่องทางการสื่อสาร (TLS/SSL Encryption) ทั้งในรูปแบบ HTTPS และ Secure WebSocket (WSS) เพื่อป้องกันการดักฟังข้อมูลระหว่างทาง (Man-in-the-Middle Attack) พร้อมทั้งกำหนดนโยบายจำกัดอัตราการเรียกใช้งาน (API Rate Limiting) เพื่อจำกัดจำนวนคำขอต่อหมายเลข IP ช่วยป้องกันการโจมตีแบบปฏิเสธการให้บริการ (DoS) นอกจากนี้ยังได้กำหนดนโยบายการเข้าถึงข้ามโดเมน (CORS Whitelist) เฉพาะโดเมนของระบบที่ได้รับอนุญาต และติดตั้งส่วนหัวความปลอดภัยมาตรฐาน (HTTP Security Headers) ได้แก่ `X-Content-Type-Options: nosniff`, `X-Frame-Options: SAMEORIGIN` และ `Content-Security-Policy (CSP)` เพื่อป้องกันการโจมตีแบบ Clickjacking และ MIME Confusion

4.4.2 การป้องกันการฉีดโค้ดอันตรายและการตรวจสอบข้อมูล (Data Sanitization & Injection Defense)

ในด้านการป้องกันการโจมตีเชิงความปลอดภัยและการจัดการข้อมูลอันตราย ระบบมีมาตรการป้องกันที่ครอบคลุมหลายระดับ โดยสำหรับการป้องกัน Cross-Site Scripting (XSS) ข้อมูลเนื้อหาข่าวที่สกัดได้จากเว็บต้นทางอาจมีแท็ก HTML หรือสคริปต์อันตรายแฝงมา ระบบจึงใช้กระบวนการแปลงและกรองข้อมูล (Sanitization) เพื่อกำจัดแท็ก `<script>`, `<iframe>`, รวมถึงแอตทริบิวต์ `onload`, `onerror` ออกทั้งหมด และแปลงเนื้อหาให้อยู่ในรูป Plain Markdown ก่อนส่งไปแสดงผลบนหน้าจอ In-app Modal นอกจากนี้ เพื่อป้องกันข้อผิดพลาดจาก Malformed Input และ Parameter Tampering ระบบได้บังคับใช้การตรวจสอบโครงสร้างข้อมูลเข้มงวดด้วย Pydantic (Strict Schema Validation) ในทุกจุดรับเข้าและส่งออกของ REST API

สำหรับการป้องกัน Server-Side Request Forgery (SSRF) ส่วนงาน Scraper และ Playwright Service จะรับคำขอและดึงข้อมูลเฉพาะจากรายการสำนักข่าวที่ลงทะเบียนไว้ล่วงหน้า (Source Whitelist) เท่านั้น โดยไม่อนุญาตให้ผู้ใช้ภายนอกส่ง URL เครือข่ายภายในเข้ามาประมวลผลโดยตรง และในส่วนการประมวลผลร่วมกับโมเดลภาษาขนาดใหญ่ (LLM Safety)

ระบบได้ออกแบบ System Prompt และโครงสร้าง Delimiter กั้นระหว่างคำสั่งหลักกับเนื้อหาข่าวอย่างรัดกุม เพื่อป้องกันปัญหา Indirect Prompt Injection ไม่ให้ข้อความข่าวลบล้างคำสั่งเดิม (Prompt Jailbreak) ของระบบสรุปข่าวได้

4.4.3 การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security)

การคุ้มครองความเป็นส่วนตัวของผู้ใช้งานถูกออกแบบตามหลัก Privacy by Design & Zero PII กล่าวคือ ระบบไม่มีการจัดเก็บข้อมูลส่วนบุคคลที่สามารถระบุตัวตนได้ (Personally Identifiable Information) เช่น ชื่อ ที่อยู่อีเมล หรือหมายเลขประจำเครื่อง โดยข้อมูลพฤติกรรมความสนใจของผู้ใช้จะถูกประมวลผลเป็นเพียงคะแนนรวมแบบนิรนาม (Anonymous Aggregate Engagement) บนฐานข้อมูลเท่านั้น ในระดับเบราว์เซอร์ คุกกี้ที่ใช้ในระบบมีการกำหนดคุณสมบัติความปลอดภัยเข้มงวด ได้แก่ `SameSite=Lax` และ `Path=/` เพื่อป้องกันการโจมตีแบบ Cross-Site Request Forgery (CSRF) พร้อมกำหนดอายุการหมดอายุ (Max-Age) ที่เหมาะสม ตลอดจนติดตั้งแถบแจ้งเตือนขอความยินยอมการใช้งานคุกกี้ (Cookie Consent Banner) ตามมาตรฐาน PDPA และมีฟังก์ชันให้ผู้ใช้สามารถกดล้างสถิติพฤติกรรม (Clear Preference Data) บนเบราว์เซอร์ได้ด้วยตนเองตลอดเวลา

4.4.4 การจัดการความลับและการตั้งค่าระบบ (Secrets & Configuration Management)

API Key สำหรับเชื่อมต่อกับบริการภายนอก เช่น `LLM_API` ของ KKU Gen.AI และการตั้งค่าระบบต่าง ๆ ถูกจัดเก็บไว้ในไฟล์ `.env` และ Environment Variables ที่แยกต่างหาก โดยมีไฟล์ `.gitignore` ป้องกันการนำความลับของระบบขึ้นสู่ระบบควบคุมเวอร์ชัน (Git Repository) อย่างเข้มงวด

4.5 การทดสอบระบบ

4.5.1 การทดสอบอัตโนมัติ (Automated Test Suite)

ระบบได้รับการออกแบบให้มีชุดทดสอบอัตโนมัติที่ครอบคลุมการทำงานทุกระดับด้วยเฟรมเวิร์ค `pytest` มากกว่า 30 ชุดทดสอบ โดยสามารถจำแนกออกเป็นกลุ่มการทดสอบหลักได้ดังนี้

การทดสอบระดับหน่วยและการประมวลผลข้อความ (Unit Tests & Text Processing) ตรวจสอบความถูกต้องของการตัดคำภาษาไทย การจับคู่คีย์เวิร์ดจำแนกหมวดหมู่ 9 หมวดหมู่ (`test_classifier_service.py`) การสกัดข้อมูลจากโครงสร้างเว็บของแต่ละสำนักข่าว (`test_sources.py`) และการผสานข้อมูลเวกเตอร์แบบฝังตัว (`test_wangchan_embedding_integration.py`)

การทดสอบการระบุประเด็นข่าวและสภาวะวิกฤต (Story Identification & Stress Tests) ตรวจสอบความแม่นยำในการจัดกลุ่มข่าวแบบ Two-Band Similarity การอัปเดตเวกเตอร์ตัวแทนด้วย Centroid EMA (`test_story_service.py`) ความคงทนของการประมวลผลข่าวกระแสสูงใน Layer 1 ภายใต้สภาวะโหลดหนัก (`test_layer1_stress.py`) พฤติกรรมของประเด็นข่าวที่ดำเนินต่อเนื่องยาวนาน (`test_long_running_storyline.py`) และกลไกวงรอบชีวิตประเด็นข่าว

(test_dynamic_lifecycle_clock.py)

การทดสอบกลไกจัดอันดับความนิยมและการต้านทานกรณีสุดขั้ว (Deterministic Trending & Adversarial Tests) ตรวจสอบสูตรคำนวณคะแนน Trending Score ทั้ง 6 สัญญาณ (test_trending_deterministic.py, test_trending_service.py) การ ลด ทอน คะแนน ข่าว ประจำ วัน (Routine News Dampening) การ ทดสอบ ป้อน ข้อมูล จำลอง ใน สภาวะ สุด ขั้ว เพื่อ ตรวจ จับ ความ ผิด ปกติ ระหว่าง Layer 2 และ Layer 3 (test_adversarial_layer2_layer3.py) และการทดสอบแข่งขันจัดอันดับความนิยมภายใต้ภาวะโหลดสูง (test_trending_challenger_stress.py)

การ ทดสอบ การนำ เสนอ และ มหา กาพย์ ประเด็น ข่าว (Presentation & Macro Events) ตรวจ สอบ การ สร้าง บท สรุป ประเด็น รวม ไทม์ ไลน์ และ กลไก ตรวจ สอบ รอย นิ้ว มือ แคช การนำ เสนอ (test_story_presentation.py, test_presentation_cache_fingerprint.py) การ เชื่อม โยง ประเด็น ข่าว ย่อย เข้า สู่ มหา กาพย์ ประเด็น ข่าว (test_macro_membership_consistency.py, test_event_vs_macro_matching.py) และ ข้อ ยกเว้น กรณี วิกฤต (test_crisis_exemption_precision.py)

การ ทดสอบ ระบบ จัด เก็บ ข้อมูล และ ความ ปลอดภัย (Storage Persistence & PDPA Compliance) ตรวจ สอบ การ ทำงาน ของ หน่วย ความ จำ แคช และ HTTP ETag 304 (test_caching.py, test_http_cache.py, test_browser_cache.py) การทำงานของพื้นที่จัดเก็บข้อมูลทั้งแบบ JSON, SQLite WAL และ MongoDB (test_news_repo.py, test_sqlite_news_repo.py, test_story_repo.py) ตลอดจนการทดสอบมาตรการความเป็นส่วนตัวตามมาตรฐาน PDPA (test_storage_pdpa.py) เพื่อรับประกันว่าไม่มีการบันทึกข้อมูลระบุตัวตนส่วนบุคคลในฐานข้อมูล

การทดสอบการประเมินผลประสิทธิภาพเชิงประจักษ์ (Evaluation Harness) ตรวจสอบความถูกต้องของสคริปต์ประเมินผลตัวชี้วัด B-cubed และ Pairwise Metrics กับชุดข้อมูลมาตรฐานอ้างอิงจริง (test_evaluation_harness.py) เพื่อให้มั่นใจในความเที่ยงตรงของการวัดผลทางสถิติ

4.5.2 ผลการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing)

ผลการทดสอบระบบตามความต้องการเชิงฟังก์ชันแสดงดังตารางที่ 12

ตารางที่ 12 ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing)

TC	รายการทดสอบ	ผลที่คาดหวัง	ผล
TC-01	การดึงข่าวอัตโนมัติจากหลายแหล่ง	ดึงหัวข้อ ลิงก์ รูปภาพ และเนื้อหาได้ครบถ้วน	ผ่าน
TC-02	การจำแนกหมวดหมู่ภาษาไทย 9 หมวด	จัดหมวดหมู่ข่าวได้อย่างถูกต้องตามเนื้อหา	ผ่าน
TC-03	การสรุปเนื้อหาข่าวและ Sentiment	ได้บทสรุป ประเด็นสำคัญ และ Sentiment	ผ่าน
TC-04	การแจ้งเตือนข่าวใหม่ผ่าน WebSocket	ข่าวใหม่ปรากฏบนหน้าจอทันทีโดยไม่ต้องรีเฟรช	ผ่าน
TC-05	การบันทึกความสนใจและแนะนำข่าว	แสดงแถบข่าว Trending ตามค่า Engagement	ผ่าน
TC-06	การอ่านข่าวในตัวเว็บ (In-app Reader)	เปิดอ่านบทความฉบับเต็มใน Modal ได้อย่างราบรื่น	ผ่าน
TC-07	การจัดกลุ่มประเด็นข่าวแบบสองชั้น	รวมข่าวเหตุการณ์เดียวกันข้ามวันและลดปัญหาข่าวแตกกลุ่ม	ผ่าน
TC-08	การจัดอันดับความนิยมแบบดีเทอร์มินิสติก	คำนวณคะแนนโปร่งใส ไร้ LLM ในการให้คะแนน และลดทอนข่าวประจำวัน	ผ่าน
TC-09	การจัดกลุ่มมหากาพย์ข่าวและ Bento Hub	แสดงมุมมอง 3 มิติ เชื่อมโยงไทม์ไลน์และกรองข่าวตามสำนักพิมพ์	ผ่าน
TC-10	การบันทึกข้อมูลแบบหลายเอนจิน	สลับใช้งาน SQLite WAL และ MongoDB ได้อย่างมีเสถียรภาพ	ผ่าน

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

โครงงาน “ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท” ได้ดำเนินการพัฒนาเสร็จสิ้นตามขอบเขตและข้อกำหนดที่วางไว้ โดยสามารถ รวบรวมข่าวสาร จากหลากหลายแหล่ง สรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าวด้วย Large Language Model (KKU Gen.AI) จำแนกหมวดหมู่ข่าวภาษาไทยด้วยเทคนิค Thai NLP ระบุและจัดกลุ่มประเด็นข่าวต่อเนื่องด้วยสถาปัตยกรรมสองชั้น (Two-Layer Story Identification) จัดอันดับกระแสความนิยมด้วยเอนจินแบบดีเทอร์มินิสติก (Deterministic Multi-Signal Trending Engine) ไร้การพึ่งพา LLM ในลูปการให้คะแนน เชื่อมโยงมหากาพย์ประเด็นข่าว (Macro Storyline) พร้อมระบบจัดเก็บข้อมูลแบบหลายเอนจิน (Multi-Engine Persistence) ทั้ง SQLite WAL และ MongoDB และแสดงผลแบบเรียลไทม์ผ่าน WebSocket บนหน้าจอ Bento Hub ผลการดำเนินงานสรุปเปรียบเทียบกับวัตถุประสงค์ได้ดังตารางที่ 13

ตารางที่ 13 สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์

ข้อ	วัตถุประสงค์	ผลการดำเนินงานที่ได้	สถานะ
1	เพื่อ ศึกษา และ วิเคราะห์ เทคนิค การ ดึง ข้อมูล ข่าว ด้วย Web Scraping, RSS Feed และเทคนิค Thai NLP	ศึกษา และ ประยุกต์ ใช้ Playwright สำหรับ JavaScript-rendered sites, BeautifulSoup สำหรับ HTML parsing, PyThaiNLP สำหรับ การ ตัด คำ และ สกัด เอนทิตี (thainer-v2) และ WangchanBERTa สำหรับ การ แปลง ข้อความ เป็น เวกเตอร์ หนาแน่น	บรรลุ
2	เพื่อ ออกแบบ และ พัฒนา ระบบ รวบรวม สรุป และ วิเคราะห์ ข่าวสาร แบบ End-to-End Pipeline	พัฒนา สถาปัตยกรรม แบบ แยก สอง ชั้น (Layer 1 Online Persistent Story Identification และ Layer 2 Deterministic Trending Engine), สถาปัตยกรรม Clean Architecture รองรับ Multi-Engine Persistence (JSON, SQLite WAL, MongoDB), ระบบ Real-time WebSocket และ หน้าจอ Bento Hub ได้อย่างสมบูรณ์	บรรลุ
3	เพื่อ ทดสอบ และ ประเมิน ประสิทธิภาพ ของ ระบบ ใน ด้าน ความ ถูก ต้อง และ ความ รวดเร็ว	ผ่าน การ ทดสอบ UAT ครบ ทั้ง 10 กรณี ทดสอบ, ผ่าน ชุด ทดสอบ อัตโนมัติ มากกว่า 30 ชุด ทดสอบ, บรรลุ ผล ประเมิน การ จัดกลุ่ม ประเด็น ข่าว ด้วย B-cubed F1-score เท่ากับ 0.7911 ซึ่ง ลด ปัญหา ข่าว แตก กลุ่ม ลง ได้ ร้อยละ 24 และ ตอบ สนอง คำขอ ผ่าน ระบบ แคช ได้ ในเวลา เฉลี่ย ต่ำกว่า 150 มิลลิวินาที	บรรลุ

จากตารางที่ 13 การดำเนินโครงงานบรรลุวัตถุประสงค์ที่ตั้งไว้ครบทั้ง 3 ข้อ

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านแหล่งข้อมูลภายนอกและบริการโมเดลภาษาขนาดใหญ่

ข้อจำกัดประการแรกสืบเนื่องมาจากโครงสร้างหน้าเว็บของสำนักข่าวต้นทางอาจมีการปรับเปลี่ยนโครงสร้าง DOM (DOM Mutation) ซึ่งส่งผลให้โมดูลแยกวิเคราะห์ (Parser) ต้องได้รับการปรับปรุงให้สอดคล้องกับโครงสร้างหน้าเว็บใหม่อย่างต่อเนื่อง นอกจากนี้ การสังเคราะห์เนื้อหาและบทสรุปข่าวยังพึ่งพาการเชื่อมต่อกับบริการ API ภายนอก ได้แก่ KKU Gen.AI ซึ่งในกรณีที่เกิดปัญหาความล่าช้าบนเครือข่ายหรือโควตาการเรียกใช้งานหมดลง ระบบต้องปรับเปลี่ยนการทำงานเข้าสู่โหมดการแสดงผลข้อความสรุปสำรองอัตโนมัติ (Heuristic Fallback) โดยใช้พาดหัวข่าวตัวแทนหลักแทน

5.2.2 ข้อจำกัดด้านทรัพยากรการประมวลผล

ในมิติด้านทรัพยากรระบบ การเปิดใช้งาน Playwright Headless Browser เพื่อสกัดข้อมูลจากเว็บไซต์ข่าวสารที่มีระบบป้องกันบอตหรือใช้การแสดงผลฝั่งไคลเอนต์ จำเป็นต้องใช้ทรัพยากรหน่วยความจำหลักและรอบการประมวลผลของ CPU สูงกว่าการดึงข้อมูลผ่านโพรโทคอล HTTP REST API ปกติ นอกจากนี้ การประมวลผลโมเดลภาษา WangchanBERTa เพื่อสร้างเวกเตอร์หนาแน่น 768 มิติบนเครื่องคอมพิวเตอร์แม่ข่ายที่ไม่มีหน่วยประมวลผลกราฟิก (GPU) อาจใช้ระยะเวลาในการประมวลผลบทความยาวเพิ่มขึ้นเล็กน้อย

5.2.3 ข้อจำกัดด้านการรู้จำชื่อเฉพาะในบริบทภาษาไทย

โมเดลการรู้จำชื่อเฉพาะ (Named Entity Recognition: NER) อิงตามคลังศัพท์และชุดข้อมูลที่ผ่านการฝึกฝนมาล่วงหน้าของ `thainer-v2` ส่งผลให้กรณีที่มีชื่อบุคคล สถานที่ หรือศัพท์สแลงเกิดใหม่ในกระแสข่าวสารปัจจุบัน โมเดลอาจไม่สามารถสกัดเอนทิตีดังกล่าวได้อย่างสมบูรณ์ ซึ่งส่งผลต่อคะแนนความคล้ายคลึงของเอนทิตีในแถบความคล้ายคลึงระดับกลาง (Ambiguity Band) เล็กน้อย

5.3 ปัญหา อุปสรรค และแนวทางแก้ไข

ปัญหาที่พบในระหว่างการพัฒนาและแนวทางที่ใช้แก้ไขแสดงดังตารางที่ 14

ตารางที่ 14 ปัญหา อุปสรรค และแนวทางการแก้ไข

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	บาง เว็บไซต์ ข่าว มี ระบบ ป้อง กัน บอต (Cloudflare/Bot detection) ทำให้ไม่สามารถดึงข้อมูลผ่าน HTTP Client ธรรมดาได้	ใช้ Playwright Browser ควบคุม เบราว์เซอร์จริงในการเรนเดอร์หน้าเว็บและ จัดการ Cookie Session
2	ค่า หน่วง เวลา และ โควตา จำกัด ของ LLM API ทำให้ระบบโหลดช้าและไม่ สามารถใช้จัดอันดับได้	ออกแบบ สถาปัตยกรรม แยก สอง ชั้น โดย ใช้ Deterministic Trending Engine ไร้ LLM ในการให้คะแนน และใช้ Presentation Cache ร่วมกับ Heuristic Fallback สำหรับการนำเสนอ
3	ข่าวสาร ภาษาไทย ไม่มี การเว้น วรรค ระหว่างคำ และมีความคลาดเคลื่อน ในการจับคู่เอนทิตี	ใช้ PyThaiNLP ใน การ ตัด คำ แบบ พจนานุกรม และ คัด กรอง Stop words ร่วม กับ โมเดล thainer-v2 สกัด เอ นทิ ตี และ WangchanBERTa แปลง ข้อความ เป็นเวกเตอร์
4	ปัญหาข่าวเรื่องเดียวกันแตกกระจาย เป็นหลายกลุ่ม (Story Fragmentation) ข้ามวัน	พัฒนา ระบบ Persistent Story Identification ด้วย หน้าต่าง เลื่อน 72 ชั่วโมง การเปรียบเทียบความคล้ายคลึงแบบ Two-Band และการปรับ Centroid EMA
5	ข่าวประจำวัน (Routine News) เช่น พยากรณ์อากาศหรือราคาน้ำมัน ได้ คะแนนความนิยมสูงเกินจริง	ติดตั้งกลไก Routine News Dampening ลดทอนคะแนนลงเหลือ 0.25 เท่า เพื่อเปิด ทางให้ข่าวด่วนและประเด็นสำคัญ
6	คอ ขวด ด้าน ประสิทธิภาพ และ การ เขียน ข้อมูล พร้อม กัน (Concurrency Bottlenecks) บน File Repository	พัฒนา Multi-Engine Persistence โดย รองรับ ทั้ง SQLite3 Write-Ahead Logging (WAL) และ MongoDB

5.4 ข้อเสนอแนะในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

สำหรับการพัฒนาฟังก์ชันการทำงานในระยะต่อไป ระบบสามารถขยายขีดความสามารถได้หลายด้าน ประการแรกคือการพัฒนาระบบตรวจสอบความสอดคล้องของข้อเท็จจริงข้ามสำนักข่าว (Cross-Source Fact Consistency Checking) เพื่อเปรียบเทียบความแตกต่างของตัวเลขสถิติ หรือแถลงการณ์ระหว่างสำนักข่าว และแจ้งเตือนจุดที่ข้อมูลขัดแย้งกันให้แก่ผู้อ่าน ประการถัดมาคือการพัฒนาระบบแจ้งเตือนข่าวด่วนเฉพาะบุคคลและการจัดทำจดหมายข่าวสรุปประจำวัน (Personalized Notifications & Automated Daily Digest) โดยส่งสรุปประเด็นข่าวที่ผู้ใช้ให้ความสนใจผ่านทางอีเมลหรือเว็บแอปพลิเคชัน และประการสุดท้ายคือการขยายขีดความสามารถเพื่อรองรับข้อมูลข่าวสารแบบมัลติมีเดีย (Multi-Modal News Ingestion) เช่น การแปลงเสียงในคลิปรายงานข่าวเป็นข้อความ (Speech-to-Text) เพื่อนำมาประมวลผลร่วมกับข่าวบทความ

5.4.2 แนวทางการวิจัยต่อยอด

ในเชิงการวิจัยต่อยอด คณะผู้พัฒนาเล็งเห็นแนวทางสำคัญ 2 ประการ ประการแรกคือการวิจัยเพื่อปรับแต่งค่าไฮเปอร์พารามิเตอร์แบบพลวัต (Dynamic Hyperparameter Optimization) สำหรับอัตราการสลายตัวของเวลา (τ) และน้ำหนักของ Centroid EMA (α) ตามความเร็วเฉลี่ยของการนำเสนอข่าวในแต่ละหมวดหมู่ โดยใช้เทคนิคการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) หรือ Bayesian Optimization เพื่อให้สอดคล้องกับพฤติกรรมข่าวที่เปลี่ยนไปตามกาลเวลา และประการที่สองคือการวิจัยโมเดลจำแนกอคติและจุดยืนของสำนักข่าว (Media Bias & Stance Detection) เพื่อวิเคราะห์ความสมดุลและความเป็นกลางในการนำเสนอข่าวของสำนักข่าวต่าง ๆ ในประเทศไทยอย่างเป็นวิทยาศาสตร์

เอกสารอ้างอิง

[1] A. Barbaresi, "Trafilatura: A web scraping library and command-line tool for text discovery and extraction," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations* (H. Ji, J. C. Park, and R. Xia, eds.), (Online), pp. 122–131, Association for Computational Linguistics, 2021.

[2] D. Winer, "Rss 2.0 specification." https://www.rssboard.org/rss-specification, 2009. Accessed: 2025-01-10.

[3] M. Allahyari, S. Pouriyeh, M. Assefi, S. Safaei, E. D. Trippe, J. B. Gutierrez, and K. Kochut, "Text summarization techniques: A brief survey," *arXiv preprint arXiv:1707.02268*, 2017.

[4] G. D. G. Team, "Gemini: A family of highly capable multimodal models," *arXiv preprint arXiv:2312.11805*, 2024.

[5] L. Lowphansirikul, C. Polpanumas, N. Jantrakulchai, and S. Nutanong, "Wangchanberta: Pretrained language model for thai language," *arXiv preprint arXiv:2101.09635*, 2021.

[6] W. Phatthiyaphaibun, K. Chaovavanich, *et al.*, "Pythainlp: Thai natural language processing in python framework." https://doi.org/10.5281/zenodo.3519354, 2021. Accessed: 2025-01-10.

[7] A. Salihefendic, "How reddit ranking algorithms work." https://amix.dk/blog/post/19588, 2010. Accessed: 2025-01-15.

[8] A. Swartz, "Rewriting reddit: Web development and architecture." https://aaronsw.com/weblog/001716, 2005. Accessed: 2025-01-15.

[9] P. Graham, "What i've learned from hacker news: Ranking and community dynamics." http://www.paulgraham.com/hackernews.html, 2009. Accessed: 2025-01-15.

[10] A. Dong, R. Zhang, P. Kolari, J. Bai, F. Diaz, Y. Chang, Z. Zheng, and H. Zha, "Time-sensitive ranking in news search: Incorporating recency and quality," pp. 315–322, 2010.

[11] A. S. Das, M. Datar, A. Garg, and S. Rajaram, "Google news personalization: Scalable online collaborative filtering and story clustering," pp. 271–280, 2007.

[12] A. Bagga and B. Baldwin, "Algorithms for scoring coreference chains," in *Proceedings of the First International Conference on Language Resources and Evaluation Workshop on Linguistics Coreference*, pp. 563–566, 1998.

[13] E. Amigó, J. Gonzalo, J. Artiles, and F. Verdejo, "A comparison of extrinsic clustering evaluation metrics based on formal constraints," *Information Retrieval*, vol. 12, no. 4, pp. 461–486, 2009.

[14] S. Ramírez, "Fastapi framework, high performance, easy to learn, fast to code, ready for production." https://fastapi.tiangolo.com, 2024. Accessed: 2025-01-10.

[15] S. Colvin *et al.*, "Pydantic: Data validation using python type hints." https://docs.pydantic.dev, 2024. Accessed: 2025-01-10.

[16] Microsoft, "Playwright: Fast and reliable cross-browser testing." https://playwright.dev, 2024. Accessed: 2025-01-10.

[17] Socket.IO, "Socket.io." https://socket.io, 2024. Accessed: 2025-01-10.

[18] SQLite Development Team, "Write-ahead logging." https://www.sqlite.org/wal.html, 2024. Accessed: 2026-10-10.

ภาคผนวก ก
คู่มือการติดตั้งและการใช้งานระบบ

ข้อกำหนดเบื้องต้นของสภาพแวดล้อม (Prerequisites)

- ระบบปฏิบัติการ: Windows 10/11, macOS หรือ Linux (Ubuntu 20.04+)
- Python เวอร์ชัน 3.11 หรือใหม่กว่า
- เครื่องมือจัดการสภาพแวดล้อม **uv** (Fast Python Package Installer)
- การเชื่อมต่ออินเทอร์เน็ตสำหรับดาวน์โหลด Dependencies และเรียกใช้ KKU Gen.AI API

ขั้นตอนการติดตั้งระบบ (Installation Steps)

1. โคลน Repository โครงการจาก GitHub:

```
git clone https://github.com/wittgenstein-byte/End-to-End_News_Collector-Summarizer.git
cd End-to-End_News_Collector-Summarizer
```

2. ติดตั้ง Dependencies ทั้งหมดผ่าน **uv**:

```
uv sync
```

3. ติดตั้ง Playwright Chromium Headless Browser:

```
uv run playwright install chromium
```

4. กำหนดค่า Environment Variables โดยคัดลอกไฟล์ตัวอย่าง:

```
copy backend\.env.example backend\.env
```

จากนั้นแก้ไขไฟล์ `backend/.env` โดยกรอก API Key สำหรับ LLM Service:

```
LLM_API=your_kku_genai_api_key_here
```

5. เริ่มต้นทำงานเซิร์ฟเวอร์ Backend:

```
uv run python backend/main.py
```

6. เปิดเว็บเบราว์เซอร์และเข้าสู่ระบบที่: http://localhost:5000

ภาคผนวก ข
ข้อกำหนด REST API และ WebSocket Events

รายการ REST API Endpoints

ตารางที่ 15 รายละเอียด REST API Endpoints ของระบบ

Method	Endpoint	คำอธิบาย	Parameters / Response
GET	/api/news	ดึงรายการข่าวแบบแบ่งหน้า	page, category, search
GET	/api/news/{id}	ดึงรายละเอียดข่าวรายชิ้นพร้อมบทสรุป	คืนค่า JSON NewsArticle
GET	/api/categories	ดึงรายการหมวดหมู่ข่าวทั้งหมด	คืนค่า List ของ Category Metadata
GET	/api/trending	ดึงรายการข่าวที่เป็นกระแสความนิยม	คืนค่า List ของ TrendingArticle
POST	/api/engagement	บันทึกสถิติการปฏิสัมพันธ์ของผู้ใช้	รับ article_id, action_type
POST	/api/collect	สั่งให้ระบบเริ่มรอบการสเกรปข่าวทันที	คืนค่าสถานะ status: started
GET	/health	ตรวจสอบสถานะความพร้อมของเซิร์ฟเวอร์	คืนค่าสถานะ Storage และ Playwright

รายการ WebSocket Events (Socket.IO)

ตารางที่ 16 รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time

Event Name	ทิศทาง	คำอธิบายและข้อมูลที่ส่ง (Payload)
news:new	Server → Client	ส่งข้อมูลข่าวใหม่ที่เพิ่งผ่านการประมวลผลเสร็จสิ้นเพื่อแสดงผลบนหน้าจอทันที
scraper:status	Server → Client	แจ้งสถานะความคืบหน้าของกระบวนการสเกรปข่าว (เช่น เริ่มต้น, จำนวนที่ดึงได้, เสร็จสิ้น)
news:updated	Server → Client	ส่งข้อมูลการอัปเดตบทความ เช่น เมื่อการสรุป LLM เสร็จสมบูรณ์
connect / disconnect	ทั้งสองทิศทาง	ตรวจจับการเชื่อมต่อและการตัดการเชื่อมต่อของผู้ใช้