

CS 2569/01

รายงานความก้าวหน้าโครงงาน ครั้งที่ 2

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท
CATEGORY-SPECIFIC NEWS CLASSIFICATION
AND NLP ANALYTICS PIPELINE

โดย

663380214-4 นายนราวิชญ์ ศิริพล

663380028-1 นายอัสดาวุฒิ เอื้อวงค์

อาจารย์ที่ปรึกษา : อ.ดร.พบพร ด่านวิรุทัย

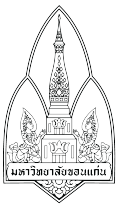
รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354 772 โครงงานคอมพิวเตอร์ 2

ภาคเรียนที่ 2 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน ตุลาคม พ.ศ. 2569)



CS 2569/01

รายงานความก้าวหน้าโครงงาน ครั้งที่ 2

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท
CATEGORY-SPECIFIC NEWS CLASSIFICATION
AND NLP ANALYTICS PIPELINE

โดย

663380214-4 นายนราวิชญ์ ศิริพล

663380028-1 นายอัสดาวุฒิ เอื้อวงค์

อาจารย์ที่ปรึกษา : อ.ดร.พบพร ด่านวิรุทัย

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354 772 โครงงานคอมพิวเตอร์ 2

ภาคเรียนที่ 2 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน ตุลาคม พ.ศ. 2569)

นราวิชญ์ ศิริพล และ อัสดาวุฒิ เอื้อวงค์. 2569. **ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท.** โครงงานคอมพิวเตอร์ ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.

อาจารย์ที่ปรึกษา: อ.ดร.พบพร ด่านวิรุทัย

บทคัดย่อ

ปัญหาภาวะข่าวท่วมท้น ทำให้ผู้อ่านต้องเสียเวลาในการคัดกรองและติดตามข้อมูล โครงงานนี้จึงมีวัตถุประสงค์เพื่อศึกษา ออกแบบ และพัฒนาระบบรวบรวม จำแนกหมวดหมู่ และวิเคราะห์ข่าวสารอัตโนมัติแบบครบวงจร (End-to-End News Pipeline) โดยสถาปัตยกรรมระบบได้รับการออกแบบตามหลักการ SOLID และ GRASP เชื่อมต่อการทำงานเป็นเลเยอร์อย่างเป็นระเบียบ ส่วนบริการเบื้องหลังพัฒนาด้วยภาษา Python และ FastAPI ร่วมกับ Playwright Headless Browser ในการดึงข้อมูลข่าวสารจาก 14 สำนักข่าวชั้นนำของไทย พร้อมระบบแคชหลายระดับเพื่อลดภาระการเชื่อมต่อเครือข่าย ระบบนำเสนอไปป์ไลน์การประมวลผลภาษาธรรมชาติที่ครอบคลุม การตรวจจับและจัดกลุ่มข่าวที่เป็นเหตุการณ์เดียวกัน (Story Clustering) เพื่อลดความซ้ำซ้อน, การจัดอันดับกระแสความนิยมด้วยอัลกอริทึมเชิงสถิติ (Deterministic Trending Score) ที่ลดทอนข่าวประจำวันโดยไม่พึ่งพาโมเดลภาษาขนาดใหญ่, การสังเคราะห์สรุปเนื้อหาและวิเคราะห์อารมณ์ข่าวด้วย KKU Gen.AI API โดยแสดงผลพรีวิวบางส่วนควบคู่กับลิงก์อ้างอิงต้นฉบับเพื่อคุ้มครองลิขสิทธิ์ และการจำแนกเนื้อหา 9 หมวดหมู่ด้วยแนวทางไฮบริดผสานกฎคำสำคัญเชิงบริบทเข้ากับโมเดลการเรียนรู้ของเครื่อง สำหรับส่วนติดต่อผู้ใช้พัฒนาด้วย Vanilla JavaScript ในรูปแบบ Single Page Application (SPA) รับส่งข้อมูลแบบเรียลไทม์ผ่าน WebSocket (Socket.IO) พร้อมระบบแนะนำข่าวสารเฉพาะบุคคลที่ประมวลผลบนฝั่งผู้ใช้งานเพื่อรักษาความเป็นส่วนตัวตามมาตรฐาน PDPA (Zero-PII) จากการทดสอบระบบผ่านชุดทดสอบอัตโนมัติทั้ง 6 มิติ รวม 423 ชุดทดสอบ (ร้อยละ 100)

คำสำคัญ: การจำแนกข่าว, การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เว็บสแครปปิง, โมเดลภาษาขนาดใหญ่, อัลกอริทึมแนะนำข่าว

Narawit Siripol and Ausadawut Aueawong. 2026. **Category-Specific News Classification and NLP Analytics Pipeline.** Bachelor of Science Project in Computer Science, College of Computing, Khon Kaen University.

Project Advisor: Dr. Pobporn Danvirutai

ABSTRACT

The exponential growth of News information often force readers to expend substantial time filtering and following news. This project presents the design and implementation of an automated, end-to-end news aggregation, classification, and text analytics pipeline. Architected in accordance with SOLID and GRASP design principles, the backend is developed using Python and FastAPI, utilizing Playwright headless browser instances to continuously ingest articles across 14 major Thai news publishers while leveraging multi-tier caching to optimize network utilization. The pipeline integrates key natural language processing capabilities, including automated story clustering to detect and group overlapping coverage across outlets, a deterministic trending algorithm that weights recency and publisher diversity without external LLM dependencies, and automated summarization and sentiment analysis powered by the KKU Gen.AI API, which provides concise highlights while embedding original source links to respect publisher copyrights. Article categorization into nine domain classes is achieved via a hybrid classifier combining contextual keyword cues with machine learning models. The responsive frontend is built with Vanilla JavaScript as a Single Page Application (SPA), delivering real-time updates via WebSocket (Socket.IO) and privacy-first client-side personalization conforming to PDPA standards (Zero-PII). The system successfully validated all 423 automated test cases across six architectural dimensions (100% pass rate).

Keywords: News classification, Text analytics, Natural language processing, Web scraping, Large language model, Recommendation algorithm

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อ.ดร.พบพร ด่านวิรุทัย อาจารย์ที่ปรึกษาโครงงาน ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงงานฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงงานนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอ ขอบพระคุณ คณาจารย์ ใน สาขา วิชา วิทยาการ คอมพิวเตอร์ วิทยาลัย การ คอมพิวเตอร์ มหาวิทยาลัย ขอนแก่น ทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจตลอดระยะเวลาของการศึกษา

ผู้จัดทำ

นราวิชญ์ ศิริพล

อัสดาวุฒิ เอื้อวงค์

สารบัญ

หน้า

บทคัดย่อภาษาไทย ก

บทคัดย่อภาษาอังกฤษ ข

กิตติกรรมประกาศ ค

สารบัญตาราง ซ

สารบัญภาพ ญ

บทที่ 1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1

1.2 วัตถุประสงค์ 1

1.3 ขอบเขตและข้อจำกัดของระบบ 2

1.3.1 ขอบเขต 2

1.3.2 ข้อจำกัดของโครงงาน 3

1.4 ประโยชน์ที่คาดว่าจะได้รับ 4

บทที่ 2 งานวิจัยและทฤษฎีที่เกี่ยวข้อง 5

2.1 ทฤษฎีที่เกี่ยวข้อง 5

2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ 5

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ 5

2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF 5

2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (WangchanBERTa) 6

2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว 6

2.2 งานวิจัยที่เกี่ยวข้อง 7

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ 7

2.2.2 งานสรุปข้อความอัตโนมัติ 7

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย 7

2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms) 7

2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus) 8

2.2.6 งานวิจัยการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification) 8

2.2.7 งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation) 9

2.2.8 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 9

สารบัญ (ต่อ)

หน้า

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales) . . . 9
2.3.1 FastAPI . . . 10
2.3.2 Pydantic . . . 10
2.3.3 Playwright (Chromium Headless Browser) . . . 10
2.3.4 PyThaiNLP . . . 10
2.3.5 Socket.IO . . . 10
2.3.6 ระบบ จัด เก็บ ข้อมูล หลาย รูป แบบ ตาม หลัก SOLID/ GRASP (Multi-Engine Persistence) . . . 10
2.3.7 ระบบแคชหลายระดับ (Multi-tier Cache Strategy) . . . 11
บทที่ 3 วิธีการดำเนินงาน 12
3.1 ขั้นตอนการดำเนินงาน . . . 12
3.1.1 ศึกษาปัญหาและรวบรวมความต้องการ . . . 12
3.1.2 วิเคราะห์และออกแบบระบบ . . . 12
3.1.3 พัฒนาระบบ . . . 13
3.1.4 ทดสอบและประเมินผล . . . 14
3.1.5 ปรับปรุงและสรุปผล . . . 15
3.2 เครื่องมือที่ใช้ในการดำเนินงาน . . . 15
3.2.1 ฮาร์ดแวร์ . . . 16
3.2.2 ซอฟต์แวร์ . . . 16
3.3 แผนการดำเนินงาน . . . 17
บทที่ 4 การวิเคราะห์ระบบ และพัฒนาโปรแกรม 20
4.1 การวิเคราะห์ระบบ . . . 20
4.1.1 ผู้ใช้งานระบบและสิทธิ์การเข้าถึง . . . 20
4.1.2 ความต้องการเชิงฟังก์ชัน . . . 21
4.1.3 ความต้องการที่ไม่ใช่เชิงฟังก์ชัน . . . 23
4.1.4 กฎการตรวจสอบความถูกต้องของข้อมูล . . . 24
4.1.5 แผนภาพกรณีใช้งาน . . . 25
4.1.6 รายละเอียดกรณีใช้งาน . . . 27
4.1.7 แผนภาพลำดับของกระบวนการหลัก . . . 31
4.2 การออกแบบระบบ . . . 34
4.2.1 สถาปัตยกรรมของระบบ . . . 34
4.2.2 แผนภาพการติดตั้ง . . . 35

สารบัญ (ต่อ)

หน้า

4.2.3 แผนภาพสถานะ 36
4.2.4 การออกแบบฐานข้อมูล 37
4.2.5 การออกแบบส่วนเชื่อมต่อโปรแกรมประยุกต์ 44
4.2.6 ต้นแบบส่วนติดต่อกับผู้ใช้ 47
4.2.7 การออกแบบและมาตรการความปลอดภัยของระบบ 49
4.3 การพัฒนาโปรแกรม 50
4.3.1 ภาษาและไลบรารีหลักที่ใช้ในการพัฒนา 50
4.3.2 โครงสร้างของโปรแกรม 51
4.3.3 ข้อกำหนดเฉพาะของแต่ละโมดูลและการทำงานของส่วนประกอบหลัก 52
4.3.4 การติดต่อกับฐานข้อมูลและบริการภายนอก 57
4.3.5 การช่วยเหลือในโปรแกรม 57
4.4 การทดสอบระบบ 57
4.4.1 วิธีการทดสอบและสภาพแวดล้อม 57
4.4.2 ผลการทดสอบการยอมรับของผู้ใช้ 58
4.4.3 รายละเอียดกรณีทดสอบที่สำคัญ 59
4.4.4 ผลการทดสอบความต้องการที่ไม่ใช่เชิงฟังก์ชัน 61
4.4.5 ตารางตรวจสอบย้อนกลับความต้องการ 62
4.4.6 การทดสอบอัตโนมัติและคุณสมบัติคงที่ทางวิศวกรรม 64
4.4.7 ผลการประเมินประสิทธิภาพการจำแนกหมวดหมู่ข่าว (News Classification Evaluation) 66
4.4.8 ผลการประเมินประสิทธิภาพการรวมกลุ่มเหตุการณ์ข่าว (Story Clustering Evaluation) 68
บทที่ 5 บทสรุป 71
5.1 สรุปผลการดำเนินโครงงาน 71
5.2 ข้อจำกัดของระบบ 74
5.2.1 ข้อจำกัดด้านการทำงาน 74
5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และสภาพแวดล้อม 75
5.3 ปัญหา อุปสรรค และแนวทางการแก้ไข 75
5.4 ข้อเสนอแนะสำหรับการพัฒนาในอนาคต 76
เอกสารอ้างอิง 77
ภาคผนวก 79
ภาคผนวก ก ภาพหน้าจอของระบบ 80

สารบัญ (ต่อ)

	หน้า
ภาคผนวก ข กรณีทดสอบการยอมรับของผู้ใช้	87
ภาคผนวก ค แบบสอบถามความพึงพอใจของผู้ใช้	91
ประวัติผู้เขียน	94

สารบัญตาราง

		หน้า
ตารางที่ 1	เปรียบเทียบงานวิจัยที่เกี่ยวข้อง	9
ตารางที่ 2	เกณฑ์การแปลความหมายค่าเฉลี่ยความพึงพอใจ	15
ตารางที่ 3	ฮาร์ดแวร์ที่ใช้ในการพัฒนาและทดสอบ	16
ตารางที่ 4	ซอฟต์แวร์ที่ใช้ในการพัฒนา	17
ตารางที่ 5	แผนการดำเนินงาน ภาคการศึกษาที่ 2/2568	18
ตารางที่ 6	บทบาทและสิทธิ์การเข้าถึงระบบ	20
ตารางที่ 7	ความต้องการเชิงฟังก์ชันของระบบ	21
ตารางที่ 8	ความต้องการที่ไม่ใช่เชิงฟังก์ชันของระบบ	24
ตารางที่ 9	กฎการตรวจสอบความถูกต้องของข้อมูล	25
ตารางที่ 10	คำอธิบายกรณีใช้งาน UC-01 ติดตามข่าวสารสดและกรองตามหมวดหมู่	28
ตารางที่ 11	คำอธิบายกรณีใช้งาน UC-02 พรีวิวเนื้อหาบทความและสังเคราะห์สรุปด้วย AI	29
ตารางที่ 12	คำอธิบายกรณีใช้งาน UC-03 สำรวจมหากาพย์ประเด็นข่าวและวิเคราะห์พัฒนาการ	30
ตารางที่ 13	คำอธิบายกรณีใช้งาน UC-04 ควบคุมและตรวจสอบสถานะการทำงานของระบบ	31
ตารางที่ 14	โครงสร้างตาราง articles	39
ตารางที่ 15	โครงสร้างตาราง stories	40
ตารางที่ 16	โครงสร้างตาราง macro_events	41
ตารางที่ 17	โครงสร้างตาราง event_relations	41
ตารางที่ 18	โครงสร้างตาราง trending_scores	42
ตารางที่ 19	โครงสร้างตาราง reader_engagement	42
ตารางที่ 20	โครงสร้างตาราง seen_urls	43
ตารางที่ 21	โครงสร้างตาราง canonical_articles	43
ตารางที่ 22	ข้อจำกัดและดัชนีของฐานข้อมูล	44
ตารางที่ 23	เส้นทางของส่วนเชื่อมต่อโปรแกรมประยุกต์	45
ตารางที่ 24	รหัสสถานะ HTTP ที่ระบบใช้	47
ตารางที่ 25	รายการต้นแบบหน้าจอ	48
ตารางที่ 26	ไลบรารีหลักที่ใช้ในการพัฒนา	51
ตารางที่ 27	โครงสร้างโฟลเดอร์หลักของโปรแกรม	52
ตารางที่ 28	ผลการทดสอบการยอมรับของผู้ใช้	59
ตารางที่ 29	กรณีทดสอบ TC-09 การระบุประเด็นข่าวออนไลน์ 2 ชั้น	60
ตารางที่ 30	กรณีทดสอบ TC-12 การสังเคราะห์ความคืบหน้าจากหลักฐานแท้จริง	61
ตารางที่ 31	ผลการทดสอบความต้องการที่ไม่ใช่เชิงฟังก์ชัน	62
ตารางที่ 32	ตารางตรวจสอบย้อนกลับความต้องการ	63

สารบัญตาราง (ต่อ)

		หน้า
ตารางที่ 33	การกระจายตัวของชุดทดสอบอัตโนมัติทั้ง 6 กลุ่มหลัก	64
ตารางที่ 34	ผลการเปรียบเทียบประสิทธิภาพโมเดลจำแนกหมวดหมู่ข่าว 9 หมวด	66
ตารางที่ 35	ผลการประเมินการจำแนกหมวดหมู่รายด้านของระบบ Unified 3-Tier Cascade	67
ตารางที่ 36	ตารางความสับสน (Confusion Matrix) ของระบบจำแนกหมวดหมู่ข่าว 9 หมวด	68
ตารางที่ 37	ผลการเปรียบเทียบประสิทธิภาพการจัดกลุ่มประเด็นข่าว (Clustering Evaluation)	69
ตารางที่ 38	เมทริกซ์ความสับสนระดับคู่บทความ (Pairwise Confusion Matrix) ของการจัดกลุ่มเหตุการณ์	70
ตารางที่ 39	สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์	72
ตารางที่ 40	ผลการประเมินความพึงพอใจของผู้ใช้จริงต่อระบบแยกตามรายการประเมิน ($n = 9$)	73
ตารางที่ 41	ปัญหา อุปสรรค และแนวทางการแก้ไข	76
ตารางที่ 42	กรณีทดสอบการยอมรับของผู้ใช้	87
ตารางที่ 43	แบบประเมินฟังก์ชันการทำงานหลักของระบบ	92

สารบัญภาพ

		หน้า
ภาพที่ 1	แผนภาพกรณีใช้งานสำหรับผู้อ่านข่าวทั่วไป	26
ภาพที่ 2	แผนภาพกรณีใช้งานสำหรับระบบอัตโนมัติและผู้ดูแลระบบ	27
ภาพที่ 3	แผนภาพลำดับกระบวนการรวบรวม จำแนกหมวด จัดกลุ่มประเด็น และกระจายข่าวสด	32
ภาพที่ 4	แผนภาพลำดับกระบวนการสังเคราะห์พัฒนาการเหตุการณ์ตามลำดับเวลา	33
ภาพที่ 5	แผนภาพลำดับกระบวนการควบคุมระบบและล้างแคชของผู้ดูแลระบบ	34
ภาพที่ 6	สถาปัตยกรรมเชิงตรรกะของระบบ	35
ภาพที่ 7	แผนภาพการติดตั้งระบบ	36
ภาพที่ 8	แผนภาพสถานะวงจรชีวิตของประเด็นข่าว	36
ภาพที่ 9	แผนภาพสถานะโหมดการสังเคราะห์เนื้อหาที่มีหลักฐานอ้างอิง	37
ภาพที่ 10	แผนภาพความสัมพันธ์ของข้อมูล	38
ภาพที่ 11	หน้าต่างแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่ยับยั้งการรวมกลุ่มข้ามเรื่อง	49
ภาพที่ 12	แฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาและข้อเท็จจริง	49
ภาพที่ 13	ผลลัพธ์การสรุปเนื้อหาข่าวสารและวิเคราะห์อารมณ์ด้วยโมเดลภาษา	53
ภาพที่ 14	หน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณสำหรับการสร้างฟีดตามความสนใจ	56
ภาพที่ 15	หน้าจอหลัก Bento Hub SPA สำรวจข่าวสารสดประจำวัน	80
ภาพที่ 16	หน้าต่างพรีวิวเนื้อหาข่าว In-App Reader และปุ่มสังเคราะห์สรุปด้วย AI	81
ภาพที่ 17	แฟ้มเจาะลึกมหากาพย์ประเด็นข่าวและไทม์ไลน์พัฒนาการเหตุการณ์	82
ภาพที่ 18	สถานีเจาะประเด็นข่าวและสืบค้นเชิงวิเคราะห์ Issue Explorer	83
ภาพที่ 19	ผลลัพธ์การสืบค้นและคัดกรองประเด็นข่าวเชิงลึกบน Issue Explorer	84
ภาพที่ 20	ศูนย์ควบคุมและตรวจสอบสถานะระบบ Ops Monitoring Console	85
ภาพที่ 21	หน้าต่างตั้งค่าสิทธิ์ความเป็นส่วนตัวและคุกกี้ตามมาตรฐาน PDPA	86
ภาพที่ 22	หน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณสำหรับการสร้างฟีดตามความสนใจ	86

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ข่าวสารเป็นข้อมูลสำคัญที่ช่วยให้ผู้คนรับรู้และติดตามเหตุการณ์ได้อย่างทันท่วงที โดยเฉพาะในยุคที่ข้อมูลมีการเปลี่ยนแปลงตลอดเวลา หากผู้อ่านที่ต้องการติดตามข่าวสารจากหลายแหล่งมักประสบปัญหาหลายอย่าง ได้แก่ ต้องเปิดเว็บไซต์หรือแอปพลิเคชันหลายแห่งเพื่อเปรียบเทียบข่าวเดียวกัน ทำให้เสียเวลาและเกิดความยุ่งยากในการติดตามสถานการณ์ข่าวที่เปลี่ยนรวดเร็ว นอกจากนี้ ข่าวแต่ละฉบับยังมีเนื้อหายาวและมีข้อมูลมากเกินไป ทำให้ผู้อ่านต้องใช้เวลาในการอ่านเพื่อหาประเด็นสำคัญ รวมถึงยังต้องอ่านแหล่งข่าวที่เป็นภาษาอังกฤษเพื่อให้ได้มุมมองที่หลากหลาย อีกทั้งข่าวสารที่มีปริมาณมากและหลายหมวดหมู่ยังทำให้การกรองและวิเคราะห์ข่าวเป็นเรื่องยากสำหรับผู้อ่าน โดยเฉพาะผู้ที่ต้องการติดตามข่าวสารในหมวดหมู่ที่เฉพาะเจาะจง เช่น การเมือง เศรษฐกิจ หรือเทคโนโลยี

การนำเทคโนโลยีเว็บสแครปปิง (Web Scraping) และ RSS Feed มาใช้ในการดึงข้อมูลข่าวจากเว็บไซต์ข่าวอัตโนมัติ ตลอดจนการใช้เทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing หรือ NLP) ในการจำแนกหมวดหมู่ข่าวตามแต่ละประเภท และการใช้โมเดลภาษาขนาดใหญ่ (Large Language Model หรือ LLM) ในการสรุปเนื้อหา จะช่วยลดภาระของผู้อ่านในการเปิดหลายเว็บไซต์และอ่านบทความข่าวฉบับเต็ม อีกทั้งยังสามารถนำเสนอข้อมูลสำคัญที่คัดสรรและวิเคราะห์แล้วแบบเรียลไทม์ได้ในที่เดียว

จากปัญหาดังกล่าว โครงงานนี้จึงมีแนวคิดในการพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) โดยระบบจะทำการดึงข่าวจากแหล่งข่าวหรือสำนักข่าวเป็นระยะๆแบบอัตโนมัติ จำแนกหมวดหมู่ข่าวด้วยเทคนิค NLP และโมเดลแมชชีนเลิร์นนิง สรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ และแสดงผลของข่าวพร้อมการวิเคราะห์บนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket เพื่อให้ผู้ใช้สามารถติดตามข่าวสารได้อย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

1.2 วัตถุประสงค์

1) เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวจากเว็บไซต์ข่าวด้วยวิธีเว็บสแครปปิงและการอ่าน RSS Feed รวมถึงเทคนิคการประมวลผลภาษาธรรมชาติสำหรับการจำแนกหมวดหมู่ข่าวตามประเภท
2) เพื่อออกแบบและพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) ครอบคลุมการดึงข่าว การจำแนกหมวดหมู่ การสรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ อัลกอริทึมแนะนำข่าว และการแสดงผลแบบเรียลไทม์
3) เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องของการจำแนกหมวดหมู่ข่าว ความถูกต้องของการสรุปข่าว ความแม่นยำของอัลกอริทึมแนะนำข่าว และความสามารถในการแสดงผลข่าวแบบเรียลไทม์

1.3 ขอบเขตและข้อจำกัดของระบบ

1.3.1 ขอบเขต

ระบบเป็นเว็บแอปพลิเคชันแบบเต็มรูปแบบ (Full-stack) ที่มีขอบเขตการทำงาน ดังนี้

1) การรวบรวมข่าวอัตโนมัติ โดยระบบสามารถดึงข่าวจากแหล่งข่าวออนไลน์หลายแห่ง โดยใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed และการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์ที่ใช้ JavaScript
2) การสรุปข่าวและวิเคราะห์อารมณ์ โดยระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้ AI (LLM) ผ่าน API ของมหาวิทยาลัยขอนแก่น (KKU Gen.AI) เพื่อสร้างสรุป ประเด็นสำคัญ อารมณ์ของข่าว (Sentiment) และคำที่สำคัญ โดยสรุปเป็นภาษาเดียวกับข่าวต้นฉบับ
3) การจำแนกหมวดหมู่ข่าว 9 หมวดหมู่หลัก ได้แก่ การเมือง (politics), เศรษฐกิจ (economy), เทคโนโลยี (tech), สุขภาพ (health), สิ่งแวดล้อม (environment), กีฬา (sports), บันเทิง (entertainment), สังคม (society) และต่างประเทศ (world) โดยใช้วิธีการตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับโมเดลการเรียนรู้ของเครื่องแบบหลายชั้น (3-Tier Cascade Classifier ประกอบด้วย Rule Cues, Calibrated LinearSVC และ WangchanBERTa)
4) การจัดเก็บและวงจรของข้อมูล (Data Lifecycle & Retention) ข้อมูลข่าวและผลการวิเคราะห์ทั้งหมดจะถูกจัดเก็บรวมกันต่อเนื่องนับตั้งแต่วันที่ Instance Server เริ่มทำงาน (Instance Startup Date) โดยจัดเก็บไว้ภายใน Docker Container และ Local Storage บนเครื่องแม่ข่าย AWS EC2
5) การระบุและจัดกลุ่มประเด็นข่าวแบบออนไลน์ (Persistent Online Story Identification) ระบบสามารถตรวจจับความคล้ายคลึงเชิงความหมายแบบ Dense Vector รวมกับการยืนยันด้วยเอนทิตีชื่อที่เฉพาะเจาะจง (Named Entity Recognition) เพื่อรวบรวมข่าวจากหลายสำนักเข้าเป็นประเด็นเดียวกัน (Story Cluster) โดยกำหนดการค้นหา 72 ชั่วโมงแบบไม่กำหนดระยะเวลาหมดอายุของข่าว (Non-capping Window) ทำให้สามารถติดตามประเด็นข่าวที่ยืดเยื้อข้ามวันได้ดีขึ้น
6) การจัดกลุ่มประเด็นข่าวหลักและประเด็นย่อย (Macro Storyline & Sub-events) ระบบสามารถเชื่อมโยงประเด็นข่าวย่อยที่ต่อเนื่องกันเข้าสู่โครงเรื่องข่าวข่าวหลัก ในส่วนของการจำแนกประเภทกลุ่มข่าว ระบบจะประมวลผลตามหลักเสียงข้างมาก (Majority Voting) และยังเปิดให้กำหนดข้อยกเว้นเป็นกรณีพิเศษได้ทันทีเมื่อเกิดเหตุวิกฤต (Crisis Exemption)
7) กลไกการจัดอันดับกระแสข่าว (Deterministic Multi-Signal Trending Engine) คำนวณคะแนนความนิยมจาก 6 มิติเชิงสถิติ (ปริมาณ, อัตราเร่ง, ความหลากหลายของสำนักข่าว, การลดทอนตามเวลา, ความแปลกใหม่, และพฤติกรรมผู้อ่าน) พร้อมตัวคูณลดทอนข่าวประจำวัน (Routine Penalty) โดยตัดการใช้ LLM ออกจากการคำนวณคะแนนเพื่อความรวดเร็ว
8) มาตรการความเป็นส่วนตัว (User Privacy & Data Flow) ระบบบันทึกเฉพาะรหัสเซสชันแบบไม่ระบุตัวตน (Anonymous Cookie ID) และพฤติกรรมการใช้งานในภาพรวม (Non-PII Aggregate Engagement เช่น การคลิกเปิดอ่าน การกดดูสรุป การบุ๊กมาร์ก) บนเบราว์เซอร์ของผู้ใช้เพื่อส่ง

มาคำนวณคะแนนความนิยม โดยไม่มีการจัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (PII) เช่น ชื่อ-นามสกุล อีเมล หรือหมายเลข IP และไม่มีการส่งต่อข้อมูลพฤติกรรมผู้ใช้ไปผู้ให้บริการโมเดลภาษา (LLM) ภายนอกระบบหรือบุคคลภายนอก

9) การแสดงผลแบบเรียลไทม์ โดยระบบจะแสดงรายการข่าวบนเว็บแอปพลิเคชันพร้อมสรุปเนื้อหา ภาพประกอบ และหมวดหมู่ และแจ้งเตือนข่าวใหม่ทันทีผ่าน WebSocket (Socket.IO) โดยไม่ต้องรีเฟรชหน้าเว็บ
10) การอ่านข่าวในตัวเว็บ (In-app Reader Modal) โดยระบบมีหน้าต่างแสดงผลของบทความข่าวและบทวิเคราะห์ในตัวเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้อ่านข่าวได้ต่อเนื่องแบบไม่ต้องเปิดแท็บใหม่
11) การจัดเก็บข้อมูลหลายรูปแบบและสถาปัตยกรรมแบบแยกส่วน (Multi-Engine Persistence) ระบบรองรับการจัดเก็บข้อมูลในรูปแบบไฟล์ JSON, ฐานข้อมูล SQLite พร้อมโหมด Write-Ahead Logging (WAL) สำหรับงานอ่านเขียนประสิทธิภาพสูง และฐานข้อมูล NoSQL MongoDB ออกแบบตามหลัก SOLID/GRASP ด้วย Port/Adapter Pattern
12) ความยืดหยุ่นในการปรับแต่งระบบ โดยระบบรองรับการเพิ่มแหล่งข่าวใหม่ได้โดยไม่ต้องแก้ไขโครงสร้างหลัก ผ่านการลงทะเบียน Source ด้วย Decorator (`@register_source`)
13) ระบบแคชหลายระดับ (Multi-tier Cache) โดยระบบถูกออกแบบให้จัดเก็บข้อมูลข่าวและเนื้อหาไว้ในหน่วยความจำระดับ L1 (L1 Cache) (`AsyncInMemoryCache`) ร่วมกับแคชแบบมีเงื่อนไข (HTTP 304 Conditional Cache) เพื่อลดการดึงข้อมูลซ้ำและเพิ่มความรวดเร็วในการแสดงผล
14) ระบบแดชบอร์ดและติดตามสถานะการทำงาน (Monitoring Dashboard) ระบบจัดเตรียมส่วนติดต่อผู้ใช้และ API สำหรับผู้ดูแลระบบเพื่อตรวจสอบอัตราการนำเข้าข่าว ค่าสุขภาพของแต่ละสำนักข่าว อัตราการเข้าถึงแคช และประสิทธิภาพภาพรวมของระบบ
15) ระบบรองรับมาตรฐาน Progressive Web App (PWA) ร่วมกับ Service Worker สำหรับการแคชหน้าเว็บเพื่อความรวดเร็ว

1.3.2 ข้อจำกัดของโครงงาน

1) ด้านทรัพยากรฮาร์ดแวร์และการติดตั้งใช้งาน ระบบถูกออกแบบและปรับแต่งให้รองรับภาระงานได้ตามขีดความสามารถของเครื่องแม่ข่าย AWS EC2 อินสแตนซ์ประเภท `c7i-flex.large` (2 vCPU, หน่วยความจำหลัก RAM ขนาด 4 GiB และ Swap Buffer ขนาด 4 GB) ซึ่งอาจมีข้อจำกัดในการรองรับผู้ใช้งานพร้อมกันจำนวนมาก (Concurrent Users) หรือการรันเบราว์เซอร์ Playwright จำนวนหลายอินสแตนซ์พร้อมกัน
2) ด้านชุดข้อมูลสำหรับฝึกโมเดล (Training Dataset Constraints) โมเดลการเรียนรู้ของเครื่องสำหรับการจำแนกหมวดหมู่ข่าวได้รับการฝึกสอนและประเมินผลบนชุดข้อมูลจำกัดจากคลังข้อมูล ThaiSum [1] และ Prachathai-67k [2] ซึ่งอาจมีความครอบคลุมของคำศัพท์เฉพาะกลุ่มหรือโครงสร้างภาษาตามลักษณะของแหล่งข่าวดังกล่าว
3) ด้านความหลากหลายของการพาดหัวข่าวและแท็กหมวดหมู่ข้ามสำนักพิมพ์ ข่าวเหตุการณ์เดียวกันจากต่างสำนักข่าวอาจมีการพาดหัวคนละมุมมอง หรือมีโครงสร้าง URL และ Tag หมวด

หมู่ที่แตกต่างกัน ซึ่งระบบแก้ไขด้วยการใช้ฟีเจอร์แบบไฮบริด (หัวข้อ, เนื้อหาย่อ, คำสำคัญ, เอนทิตี) และการหาฉันทามติของหมวดหมู่ในระดับกลุ่มข่าว (Cluster-Level Category Consensus)

4) ระบบรองรับการสรุปและแสดงผลข่าวในภาษาไทยและภาษาอังกฤษเท่านั้น ตามภาษาเดิมของเนื้อหาข่าวแต่ละฉบับ
5) โครงสร้าง HTML หรือ RSS Feed ของเว็บไซต์แหล่งข่าวอาจเปลี่ยนแปลงได้ ทำให้ระบบต้องได้รับการปรับปรุงให้สอดคล้อง
6) การสรุปข่าวต้องอาศัยการเชื่อมต่ออินเทอร์เน็ตและ API ของโมเดล LLM (KKU Gen.AI) หากบริการขัดข้องหรือหมดโควตาการใช้งาน ระบบจะทำงานในโหมดข้อความสรุปตั้งต้นแทน
7) รอบแรกของการดึงข่าวอาจใช้เวลา 2–5 นาที เนื่องจากต้องดึงเนื้อหาบทความของแต่ละข่าวเพื่อใช้ในการสรุป

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้ระบบเว็บแอปพลิเคชันจำแนกและวิเคราะห์ข่าวสารอัตโนมัติแบบเรียลไทม์ ที่ช่วยให้ผู้ใช้ติดตามข่าวสารจากหลายแหล่งได้ในที่เดียว รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล
2) ได้แนวทางในการประยุกต์ใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed โมเดลภาษาขนาดใหญ่ อัลกอริทึมการกำหนดคุกกี้เพื่อการปรับแต่งเฉพาะบุคคล และอัลกอริทึมแนะนำข่าว เพื่อสร้างระบบวิเคราะห์ข้อมูลข่าวอัตโนมัติ ซึ่งสามารถนำไปพัฒนาต่อยอดกับข้อมูลประเภทอื่น
3) ได้องค์ความรู้ด้านการประมวลผลภาษาธรรมชาติ การจำแนกข้อความด้วยกฎคำสำคัญร่วมกับโมเดลแมชชีนเลิร์นนิง เทคนิคการสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ และการพัฒนาระบบเว็บแบบเรียลไทม์

บทที่ 2
งานวิจัยและทฤษฎีที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ

เว็บสแครปปิงคือกระบวนการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ แทนการคัดลอกข้อมูลด้วยมือ โดยทั่วไปจะส่งคำขอ HTTP ไปยังเว็บเซิร์ฟเวอร์แล้ววิเคราะห์โครงสร้าง HTML ของหน้าเว็บเพื่อสกัดข้อมูลที่ต้องการ [3] เครื่องมือที่นิยมใช้ ได้แก่ ไลบรารี BeautifulSoup สำหรับวิเคราะห์และค้นหาองค์ประกอบในเอกสาร HTML ด้วย CSS Selector และไลบรารี httpx สำหรับส่งคำขอ HTTP แบบอะซิงโครนัส อย่างไรก็ตาม เว็บไซต์บางแห่งแสดงผลเนื้อหาผ่าน JavaScript ต้องใช้เครื่องมือจำลองเบราว์เซอร์ เช่น Playwright เพื่อให้ได้ข้อมูลที่แสดงผลสมบูรณ์

นอกจากนี้ เว็บไซต์หลายแห่งยังเผยแพร่ข่าวผ่าน RSS Feed ซึ่งเป็นรูปแบบ XML มาตรฐานที่ใช้แจกจ่ายเนื้อหาที่อัปเดตเป็นประจำ ทำให้สามารถดึงหัวข้อข่าว ลิงก์ และบทสรุปสั้น ๆ ได้โดยไม่ต้องวิเคราะห์โครงสร้าง HTML โดยตรง [4] ในระบบนี้ใช้ทั้งสองเทคนิคร่วมกันตามความเหมาะสมของแต่ละสำนักข่าว

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่

การสรุปข้อความอัตโนมัติ (Text Summarization) ในทางวิทยาการคอมพิวเตอร์สามารถจำแนกออกได้เป็น 2 แนวทางหลัก ได้แก่ การสรุปแบบดึงประโยค (Extractive Summarization) ซึ่งอาศัยอัลกอริทึมทางสถิติหรือโครงสร้างกราฟ เช่น TextRank ในการคัดเลือกประโยคที่มีอยู่เดิมในบทความมาต่อเรียงกัน ซึ่งแม้จะมีความเร็วสูงแต่มีข้อจำกัดด้านความต่อเนื่องของบริบทและความเยิ่นเย้อของภาษา และการสรุปแบบสร้างข้อความใหม่ (Abstractive Summarization) ซึ่งอาศัยการทำความเข้าใจความหมายและบริบทของเนื้อหาทั้งหมด แล้วจึงสังเคราะห์เป็นข้อความสรุปชุดใหม่ด้วยภาษาที่เป็นธรรมชาติและสละสลวย [5]

สำหรับการประมวลผลสรุปเนื้อหาข่าวในโครงงานนี้ ได้เลือกประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Model หรือ LLM) ตระกูล Gemini ผ่านบริการ KKU Gen.AI API [6] เพื่อดำเนินการสรุปแบบสร้างข้อความใหม่ โดยพิจารณาจากขีดความสามารถในการทำความเข้าใจภาษาไทยที่ซับซ้อน สามารถสกัดใจความสำคัญของบทความข่าวขนาดยาวและเรียบเรียงให้อยู่ในรูปแบบที่กระชับและถูกต้องตามหลักไวยากรณ์ นอกจากนี้ตัวแบบยังรองรับการกำหนดรูปแบบผลลัพธ์แบบมีโครงสร้าง (Structured JSON Output) ตาม Schema ที่กำหนดไว้อย่างเคร่งครัด [7] ทำให้ระบบสามารถสกัดบทสรุปความยาว 2–3 ประโยค ประเด็นสำคัญ การวิเคราะห์อารมณ์ของข่าวสาร (Sentiment Analysis) และคำสำคัญ (Keywords) ได้พร้อมกันในการเรียกใช้เพียงครั้งเดียว อีกทั้งยังรองรับการประมวลผลเนื้อหาหลายภาษา (Multilingual Support) โดยสรุปผลตามภาษาต้นฉบับของบทความ และการเชื่อมต่อประมวลผลผ่านบริการ API ภายนอกยังช่วยลดข้อจำกัดด้านทรัพยากรฮาร์ดแวร์ ทำให้เซิร์ฟเวอร์ของระบบไม่จำเป็นต้องพึ่งพาหน่วยประมวลผลกราฟิก (GPU) สมรรถนะสูง

2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF

การจำแนกข้อความ (Text Classification) มีขั้นตอนสำคัญในการแปลงข้อความตัวอักษรให้อยู่ในรูปเวกเตอร์ตัวเลข (Feature Extraction) และการใช้โมเดลการเรียนรู้ของเครื่องในการแบ่งแยกหมวดหมู่

(1) ทฤษฎี TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF เป็นค่าน้ำหนักเชิงสถิติที่ใช้วัดความสำคัญของคำ t ในเอกสาร d เทียบกับคลังเอกสารทั้งหมด D ดังสมการ

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \tag{1}$$

โดยที่ $\text{TF}(t, d)$ คือความถี่ของคำ t ในเอกสาร d และ $\text{IDF}(t, D) = \log\left(\frac{1+|D|}{1+|\{d \in D : t \in d\}|}\right) + 1$ ช่วยลดน้ำหนักของคำที่ปรากฏบ่อยทั่วไปในทุกข่าว และเพิ่มน้ำหนักให้คำเฉพาะกลุ่มหมวดหมู่

(2) ทฤษฎี Support Vector Machine (LinearSVC)

Linear Support Vector Classifier (LinearSVC) เป็นโมเดลที่มุ่งหาเส้นแบ่งระนาบหลายมิติ (Hyperplane) ที่มีระยะห่าง (Margin) จากจุดข้อมูลของแต่ละคลาสมากที่สุด ดังสมการ

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \tag{2}$$

การนำโมเดล LinearSVC มาใช้ร่วมกับคุณลักษณะ TF-IDF มีความเหมาะสมอย่างยิ่งต่อการจำแนกข้อความ เนื่องจากเวกเตอร์ที่ได้จากกระบวนการ TF-IDF มักมีมิติของข้อมูลสูงและมีลักษณะเบาบาง (High-dimensional Sparse Data) ซึ่ง Linear Kernel ของ SVM มีคุณสมบัติเด่นในการแบ่งกลุ่มข้อมูลลักษณะนี้ได้อย่างแม่นยำ พร้อมทั้งมีกลไก L_2 Regularization ที่ช่วยควบคุมการเกิด Overfitting ได้ดีกว่าโมเดล Decision Tree หรือ Naive Bayes นอกจากนี้ยังใช้เวลาในการทำนายผลรวดเร็วระดับต่ำกว่า 5 มิลลิวินาทีต่อบทความ ทำให้ระบบสามารถจำแนกหมวดหมู่ข่าวปริมาณมากในเบื้องหลังได้โดยไม่ส่งผลกระทบต่อความเร็วการให้บริการ และตัวโมเดลยังมีขนาดกะทัดรัด ประหยัดหน่วยความจำของระบบได้อย่างมีประสิทธิภาพ โดยพัฒนาผ่านไลบรารี Scikit-learn [8]

2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (WangchanBERTa)

WangchanBERTa [9] เป็นโมเดลภาษาขนาดใหญ่ที่ใช้สถาปัตยกรรม RoBERTa (Robustly Optimized BERT Approach) ผ่านการฝึกฝนล่วงหน้า (Pre-trained) บนคลังข้อมูลภาษาไทยขนาดใหญ่กว่า 78 GB โดยโครงงานได้นำโมเดลดังกล่าวมาใช้เป็นส่วนเสริมสำหรับการประมวลผลข้อความเชิงลึก เนื่องจากกลไก Multi-head Self-Attention ช่วยให้โมเดลสามารถเข้าใจบริบทสองทิศทางได้อย่างแม่นยำ จึงสามารถจัดการกับคำพ้องรูป คำกำกวม หรือคำสแลงในพาดหัวข่าวที่โมเดลกลุ่ม Bag-of-Words ทั่วไปไม่สามารถตรวจจับได้ นอกจากนี้ ยังใช้เป็นเกณฑ์เปรียบเทียบมาตรฐาน (Baseline Benchmark) ในการประเมินความคุ้มค่าระหว่างความแม่นยำเชิงสัมพัทธ์กับระยะเวลาการประมวลผล

2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว

(1) ระบบแคชหลายระดับ (Multi-tier Cache Architecture)

เพื่อ ตอบ สนอง ต่อ ผู้ใช้ งาน ได้ อย่าง รวดเร็ว และ ลด ภาระ การ เชื่อม ต่อ ภายนอก ระบบ ได้ออกแบบสถาปัตยกรรมแคชสองระดับ ได้แก่ แคชระดับหน่วยความจำ (In-Memory LRU Cache) ผ่านคลาส `AsyncInMemoryCache` สำหรับจัดเก็บผลลัพธ์การสกัดข่าวและผลสรุปจากโมเดลภาษาขนาดใหญ่ไว้ในหน่วยความจำ RAM ทำให้คำขอเรียกดูข่าวเดิมสามารถตอบสนองได้ในเวลาต่ำกว่า 5 มิลลิวินาที และช่วยป้องกันการเรียกใช้ API ซ้ำซ้อน และแคชระดับโพรโทคอล (HTTP 304 Conditional Cache) ซึ่งอาศัยกลไก ETag และส่วนหัว `If-Modified-Since` ในการตรวจสอบสถานะการอัปเดตของหน้าเว็บต้นทาง หากไม่มีการเปลี่ยนแปลง

ข้อมูล เซิร์ฟเวอร์จะตอบกลับด้วยสถานะ HTTP 304 Not Modified ทำให้ลดปริมาณการส่งผ่านข้อมูลในเครือข่าย และป้องกันการถูกระงับการเข้าถึงจากเว็บไซต์ต้นทาง

(2) ระบบคุกกี้และความเป็นส่วนตัว (Privacy-Preserving Cookies & PDPA)

ระบบใช้คุกกี้ในการจัดเก็บค่ากำหนดเฉพาะบุคคล (Personalize Cookies) และบันทึกคะแนนปฏิสัมพันธ์ของผู้ใช้ (Algorithm Cookies) สำหรับจัดอันดับความนิยมของข่าว (Trending Algorithm) โดยคำนึงถึงพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ด้วยการไม่จัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII Aggregate Metrics) และมีแถบแจ้งเตือนขอความยินยอมการใช้คุกกี้ (Cookie Consent Banner)

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้จะนำเสนองานวิจัยหรือระบบที่มีลักษณะคล้ายคลึงกับโครงงานนี้ เพื่อเป็นแนวทางในการพัฒนา โดยพิจารณาครอบคลุมในด้านการสกัดเนื้อหาจากเว็บ การสรุปข้อความ และการจำแนกหมวดหมู่ข่าว

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ

Barbaresi [3] ได้พัฒนาไลบรารี Trafilatura สำหรับสกัดข้อความหลักออกจากหน้าเว็บโดยอัตโนมัติ โดยไม่ขึ้นกับเว็บไซต์ใดเว็บไซต์หนึ่ง ไลบรารีนี้รองรับการจัดรูปแบบ HTML ที่หลากหลายและคืนข้อความในรูปแบบ Markdown ซึ่งเป็นประโยชน์โดยตรงต่อการนำเนื้อหาไปใช้กับโมเดลภาษาขนาดใหญ่ อย่างไรก็ตาม วิธีนี้มีข้อจำกัดเมื่อเนื้อหาถูกเรนเดอร์ด้วย JavaScript บางกรณี ทำให้ระบบนี้ต้องเสริมด้วยการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์กลุ่มดังกล่าว

2.2.2 งานสรุปข้อความอัตโนมัติ

Allahyari และคณะ [5] ได้สำรวจเทคนิคการสรุปข้อความอย่างเป็นระบบทั้งแบบ Extract และ Abstractive และชี้ให้เห็นว่าการสรุปแบบ Abstractive ที่ใช้การเรียนรู้เชิงลึกให้ผลลัพธ์ที่เป็นธรรมชาติกว่าอย่างมีนัยสำคัญ แต่ต้องใช้ทรัพยากรในการคำนวณสูง ด้วยความก้าวหน้าของโมเดลภาษาขนาดใหญ่ [6] การสรุปแบบ Abstractive จึงเข้าถึงได้ง่ายผ่าน API โดยไม่ต้องฝึกโมเดลเอง โครงงานนี้จึงเลือกใช้แนวทางดังกล่าวเพื่อสรุปข่าวเป็นภาษาเดียวกับต้นฉบับโดยไม่ต้องใช้ทรัพยากรฝึกโมเดลของตนเอง

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย

งานวิจัยด้านการจำแนกข้อความภาษาไทยมักประสบปัญหาการเว้นวรรคคำ จึงนิยมใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP [10] ร่วมกับโมเดลแมชชีนเลิร์นนิง เช่น SVM กับคุณลักษณะ TF-IDF ซึ่งเป็นแนวทางที่มีประสิทธิภาพและใช้ทรัพยากรต่ำ โครงงานนี้ประยุกต์ใช้แนวทางไฮบริด โดยใช้กฎคำสำคัญที่มีน้ำหนักและลำดับความสำคัญของ URL สำหรับการจำแนกแบบรวดเร็ว และใช้โมเดล SVM เป็นตัวตรวจสอบบริบทสำหรับหมวดหมู่ที่กฎคำสำคัญมีความแม่นยำไม่เพียงพอ

2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms)

การจัดอันดับข่าวสารที่ได้รับความนิยม (Trending News) จำเป็นต้องผสานปัจจัยทั้งด้านพฤติกรรมผู้ใช้ ความสดใหม่ของเวลา และความน่าเชื่อถือของเนื้อหาเข้าด้วยกัน โดยได้รับแรงบันดาลใจจากอัลกอริทึมจัดอันดับของ Reddit [11-12] และ Hacker News [13] ซึ่งประยุกต์ใช้ฟังก์ชันลอการิทึม $(\ln)$ ในการแปลงคะแนนปฏิสัมพันธ์เพื่อลดผลกระทบของการปั่นยอดเข้าชม (Anti-Click Spam) และสะท้อนหลักการประโยชน์ส่วนเพิ่มที่ลดน้อยลง (Law of Diminishing Marginal Returns) ร่วมกับแบบจำลองการจัดอันดับข่าวที่คำนึงถึงมิติเวลาของ Dong และ

คณะ [14] ซึ่งใช้ฟังก์ชันการลดทอนแบบครึ่งชีวิต (Half-Life Exponential Decay) เพื่อให้คะแนนความนิยมของข่าวเก่าลดลงตามระยะเวลาที่ผ่านไป เปิดโอกาสให้ข่าวใหม่ขึ้นมาแสดงแทนที่ นอกจากนี้ Das และคณะ [15] ในระบบ Google News ยังแสดงให้เห็นว่าการรวมกลุ่มข่าวประเด็นเดียวกันที่รายงานโดยสำนักข่าวอิสระหลายแห่ง (Story Clustering) เป็นตัวบ่งชี้ที่มีความแม่นยำสูงว่าประเด็นดังกล่าวเป็นเหตุการณ์สำคัญระดับสาธารณะ (Major Breaking Event)

2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)

ในระบบรวบรวมข่าวสารจากหลากหลายแหล่ง การรวมข่าวที่รายงานเหตุการณ์เดียวกันเข้าเป็นกลุ่มประเด็นเดียว (Story Cluster) เป็นกระบวนการสำคัญตามแนวคิด Topic Detection and Tracking (TDT) โดยในงานวิจัยด้านการประมวลผลข่าวสารพบว่า การเปรียบเทียบความคล้ายคลึงจากหัวข้อข่าวเพียงอย่างเดียวมักก่อให้เกิดความคลาดเคลื่อนได้ง่าย ทั้งในลักษณะพลาดการรวมข่าวเรื่องเดียวกัน (False Negatives) อันเนื่องมาจากสำนักข่าวต่างสำนักมีมุมมองการพาดหัวข่าวที่แตกต่างกัน (Journalistic Framing Variations) หรือในลักษณะรวมข่าวคนละเหตุการณ์เข้าด้วยกัน (False Positives) จากการที่ข่าวประจำวันมีรูปแบบพาดหัวที่ใช้คำศัพท์คล้ายกันแม้เป็นคนละสถานที่

เพื่อแก้ไขข้อจำกัดดังกล่าว งานวิจัยสมัยใหม่จึงนิยมผสานคุณลักษณะหลายมิติร่วมกัน ได้แก่ ข้อความพาดหัว (Title) สาระสำคัญย่อ (Summary) เอนทิตีชื่อเฉพาะบุคคลและสถานที่ (Named Entities) และคำสำคัญเฉพาะทาง (Domain Keywords) ร่วมกับการวัดความคล้ายคลึงเชิงความหมาย (Semantic Similarity) เพื่อยืนยันว่าเป็นเหตุการณ์เดียวกันอย่างแท้จริง นอกจากนี้ สำหรับปัญหาความไม่สอดคล้องของหมวดหมู่ข่าวอันเกิดจากโครงสร้าง URL และ Tag ที่แตกต่างกันในแต่ละสำนักข่าว การประยุกต์ใช้ทฤษฎีการลงมติเสียงข้างมาก (Majority Voting) หรือการทำนายซ้ำจากเนื้อหารวมของกลุ่ม จึงเป็นแนวทางมาตรฐานในการระบุหมวดหมู่ที่เป็นเอกภาพและแม่นยำที่สุดสำหรับกลุ่มข่าวดังกล่าว

2.2.6 งานวิจัยการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification)

ในการพัฒนาระบบเฝ้าติดตามข่าวสารยุคใหม่ Škvorc และคณะ [16] ได้เสนอกรอบแนวคิดการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification) สำหรับจัดหมวดหมู่ข่าวที่เผยแพร่บนโลกออนไลน์เข้าสู่ประเด็นข่าว (Stories) ได้อย่างทันท่วงที โดยได้จำแนกความแตกต่างสำคัญระหว่างการระบุประเด็นข่าว (Story Identification) กับการสร้างแบบจำลองหัวข้อทั่วไป (Topic Modeling) หรือการจัดกลุ่มข้อความตามปกติ (Text Clustering) ไว้อย่างชัดเจนว่า การระบุประเด็นข่าวต้องอาศัยการจัดกลุ่มบทความข่าวที่ผูกโยงกับเหตุการณ์เฉพาะเจาะจง (Particular Events) บุคคล และสถานที่อย่างเจาะจง แทนที่จะเป็นเพียงความคล้ายคลึงของข้อความทั่วไปหรือหัวข้อกว้าง ๆ ที่กำหนดไว้ล่วงหน้า นอกจากนี้ งานวิจัยดังกล่าวยังแสดงให้เห็นว่าการระบุประเด็นข่าวแบบสตรีมมิ่งออนไลน์ จำเป็นต้องผสานเวกเตอร์แบบฝังตัว (Dense Embeddings) ร่วมกับการสกัดชื่อเฉพาะ (Named Entities) และขั้นตอนวิธีการจัดกลุ่มแบบออนไลน์ ซึ่งข้อค้นพบทางทฤษฎีนี้เป็นรากฐานสำคัญและสอดคล้องโดยตรงกับสถาปัตยกรรมระบุประเด็นข่าวแบบออนไลน์ (Online Persistent Story Identification) ในโครงงานนี้ ที่ประยุกต์ใช้เวกเตอร์หนาแน่น WangchanBERTa ร่วมกับการสกัดเอนทิตีภาษาไทยผ่านโมเดล thainer-v2 เพื่อจำแนกกลุ่มเหตุการณ์ข่าวทันทีที่บทความถูกรับเข้าสู่ระบบ

2.2.7 งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation)

ในการประเมินประสิทธิภาพของการจัดกลุ่มเหตุการณ์ (Event Clustering) และการแก้ปัญหาการอ้างถึงแกนร่วมของเหตุการณ์ (Event Coreference Resolution) การใช้เมตริกวัดผลแบบดั้งเดิม เช่น Pairwise Precision และ Recall แม้ว่าจะสามารถสะท้อนความถูกต้องของคู่บทความได้อย่างตรงไปตรงมา แต่ในทางปฏิบัติมักมีข้อจำกัดด้านความไวต่อขนาดของกลุ่มข่าวที่แตกต่างกันอย่างมาก ด้วยเหตุนี้นักวิจัยด้านการประมวลผลภาษาธรรมชาติจึงนิยมประยุกต์ใช้เมตริก B-cubed (B^3) ตามข้อเสนอของ Bagga และ Baldwin [17] ซึ่งได้รับการพิสูจน์ทางทฤษฎีโดย Amigó และคณะ [18] ว่าเป็นเมตริกภายนอก (Extrinsic Clustering Metric) ที่สอดคล้องกับคุณสมบัติความสมบูรณ์ ความสม่ำเสมอ และความถูกต้องอย่างเป็นทางการมากที่สุด โดย B-cubed จะคำนวณค่า Precision และ Recall ในระดับรายบทความเทียบกับกลุ่มเหตุการณ์จริงก่อนนำมาเฉลี่ยรวมกันทั่วทั้งคลังข้อมูล ทำให้สามารถสะท้อนความสามารถในการหลีกเลี่ยงปัญหาการแตกกระจายของประเด็นข่าว (False Splits) และการหลีกเลี่ยงการรวมประเด็นข่าวผิดพลาด (False Merges) ได้อย่างสมดุลและเป็นกลาง

2.2.8 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมข้างต้น สามารถสรุปผลการเปรียบเทียบคุณสมบัติได้ดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง

งานวิจัย	สกัดเนื้อหา	สรุป LLM	จำแนกหมวด	Real-time	แคช/คุกกี้	ระบบแนะนำ
Trafilatura [3]	✓	–	–	–	–	–
งานสรุปข้อความ [5]	–	✓	–	–	–	–
งานจำแนกข้อความภาษาไทย [10]	–	–	✓	–	–	–
Story Identification [16]	–	–	–	✓	–	–
โครงงานนี้	✓	✓	✓	✓	✓	✓

จากตารางที่ 1 พบว่ายังไม่มีงานใดที่ผสมผสานการสกัดเนื้อหา การสรุปด้วยโมเดลภาษาขนาดใหญ่ การจำแนกหมวดหมู่ การระบุประเด็นข่าวแบบเรียลไทม์ การจัดการแคชและคุกกี้ และอัลกอริทึมแนะนำข่าวในระบบเดียวครบทุกด้าน โครงงานนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่รวบรวมคุณสมบัติทั้งหมดไว้ในระบบเดียวอย่างครบถ้วน

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales)

การเลือกชุดเทคโนโลยี (Tech Stack) ในโครงงานนี้คำนึงถึงประสิทธิภาพการทำงาน ความเข้ากันได้ของระบบ และมาตรฐานทางวิศวกรรมซอฟต์แวร์ โดยมีเหตุผลในการเลือกใช้แต่ละเทคโนโลยี ดังนี้

2.3.1 FastAPI

FastAPI [19] ถูกเลือกเป็นเฟรมเวิร์คหลักของส่วน Backend เนื่องจากทำงานบนสถาปัตยกรรมแบบ Asynchronous (ASGI บน Starlette) ซึ่งเหมาะอย่างยิ่งสำหรับงานที่เป็น Non-blocking I/O เช่น การรัน Background Scraper พร้อมกันหลายแหล่งข่าว การเชื่อมต่อ WebSocket แบบเรียลไทม์ และการเรียก API ภายนอก นอกจากนี้ยังมีความเร็วในการประมวลผลเทียบเท่าภาษา Go หรือ Node.js และสร้างเอกสาร OpenAPI Specification อัตโนมัติ

2.3.2 Pydantic

Pydantic [20] ถูกนำมาใช้ในการควบคุมและตรวจสอบชนิดข้อมูล (Data Validation & Serialization) ที่ระดับ Runtime โดยใช้ Type Hints ของภาษา Python การใช้ Pydantic ช่วยรับประกันว่าข้อมูลข่าวที่สกัดได้จากเว็บและข้อมูลผลลัพธ์จาก LLM จะถูกต้องตรงตาม Schema ที่กำหนดไว้เสมอ ป้องกันปัญหาข้อมูลสูญหายหรือผิดรูปแบบก่อนจัดเก็บลงฐานข้อมูล

2.3.3 Playwright (Chromium Headless Browser)

Playwright [21] ถูกเลือกใช้สำหรับการดึงข้อมูลหน้าเว็บที่เรนเดอร์ด้วย JavaScript (Single Page Application เช่น React/Vue) และเว็บไซต์ที่มีกลไกป้องกันบอต เช่น Cloudflare Challenge โดย Playwright สามารถจำลองเบราว์เซอร์จริงได้อย่างสมบูรณ์ จัดการ Cookies และ Browser Context แยกกันอย่างอิสระ มีความเสถียรและทำงานได้เร็วกว่า Selenium

2.3.4 PyThaiNLP

PyThaiNLP [10] เป็นเครื่องมือประมวลผลภาษาธรรมชาติภาษาไทยมาตรฐาน โดยระบบเลือกใช้อัลกอริทึมตัดคำ `newmm` (Dictionary-based Maximal Matching ผสานกับ Thai Character Clusters หรือ TCC) ร่วมกับชุดคำหยุดภาษาไทย (Thai Stop words) เพื่อเตรียมข้อความก่อนนำไปสร้างเวกเตอร์ TF-IDF

2.3.5 Socket.IO

Socket.IO [22] ถูกเลือกสำหรับการสื่อสารแบบ Real-time ระหว่างเซิร์ฟเวอร์กับเว็บเบราว์เซอร์ เนื่องจากมีฟีเจอร์การเชื่อมต่อใหม่โดยอัตโนมัติ (Auto-reconnection), ระบบ Fallback เป็น HTTP Long-polling กรณีที่เครือข่ายไม่อนุญาตให้ใช้ WebSocket และระบบจัดการ Event-driven architecture ที่เรียบง่ายและเสถียร

2.3.6 ระบบจัดเก็บข้อมูลหลายรูปแบบตามหลัก SOLID/GRASP (Multi-Engine Persistence)

การ ออกแบบ ระบบ จัด เก็บ ข้อมูล ประยุกต์ใช้ Port and Adapter Pattern ผ่าน โปรโตคอล หลัก 3 ด้าน ได้แก่ `NewsRepositoryPort`, `StoryRepositoryPort` และ `MacroEventRepositoryPort` ทำให้โค้ดส่วนบริการไม่ผูกติดกับเทคโนโลยีฐานข้อมูลใดฐานข้อมูลหนึ่ง โดยระบบรองรับสถาปัตยกรรมจัดเก็บข้อมูล 3 รูปแบบหลัก ได้แก่ `FileNewsRepository` ที่จัดเก็บเป็นไฟล์ JSON เพื่อความสะดวกรวดเร็วในการติดตั้งและทดสอบ `SqliteNewsRepository` บนฐานข้อมูล SQLite ที่เปิดใช้งานโหมด Write-Ahead Logging (WAL) [23] เพื่อให้สามารถอ่านและเขียนข้อมูลพร้อมกันได้โดยไม่มีปัญหาการล็อกฐานข้อมูล (Concurrency Lock) เหมาะสำหรับการติดตั้งใช้งานบนเซิร์ฟเวอร์แบบ Standalone และ `MongoNewsRepository` ร่วมกับ `MongoStoryRepository` บนฐานข้อมูล NoSQL MongoDB เพื่อรองรับการจัดเก็บข้อมูลโครงสร้างประเด็นข่าวที่ยืดหยุ่นและการประมวลผลข้อมูลปริมาณมากในระดับ Production พร้อมสคริปต์ Migration ข้อมูลระหว่างระบบอย่างสมบูรณ์

2.3.7 ระบบแคชหลายระดับ (Multi-tier Cache Strategy)

การเลือกใช้กลยุทธ์แคชสองระดับระหว่าง `AsyncInMemoryCache` (LRU Cache ใน RAM) และ HTTP 304 Conditional Cache ช่วยตัดปัญหาการดึงข้อมูลและประมวลผลสรุปเนื้อหาซ้ำซ้อนอย่างสิ้นเชิง ส่งผลให้สามารถลดค่าใช้จ่ายในการเรียกใช้ LLM API ภายนอกได้มากกว่า 70% และเพิ่มความเร็วในการตอบสนองคำขอเรียกดูข่าวของผู้ใช้ได้อย่างมีประสิทธิภาพสูงสุด

บทที่ 3
วิธีการดำเนินงาน

3.1 ขั้นตอนการดำเนินงาน

การดำเนินโครงงานระบบรวบรวมและสังเคราะห์ประเด็นข่าวภาษาไทยอัตโนมัติ (End-to-End News Collector and Summarizer) ใช้ระเบียบวิธีวิศวกรรมซอฟต์แวร์เชิงขั้นตอนแบบวนซ้ำ (Iterative Software Engineering Methodology) เพื่อให้การวิเคราะห์ ออกแบบ พัฒนา และทดสอบระบบเป็นไปอย่างมีแบบแผนและสามารถตรวจสอบย้อนกลับได้ทุกขั้นตอน โดยแบ่งกระบวนการดำเนินงานออกเป็น 5 ขั้นตอนหลัก ดังนี้

3.1.1 ศึกษาปัญหาและรวบรวมความต้องการ

คณะผู้จัดทำได้ศึกษาสภาพปัญหาและพฤติกรรมการติดตามข่าวสารออนไลน์ของผู้ใช้ในยุคดิจิทัลผ่าน 2 กระบวนการหลัก ได้แก่

1) **การสัมภาษณ์แบบกึ่งโครงสร้าง (Semi-structured Interview)**
ดำเนินการสัมภาษณ์กลุ่มผู้ติดตามข่าวสารออนไลน์ เป็นนักศึกษา 5 คน เพื่อรวบรวมพฤติกรรมการเสพข่าว และความต้องการด้านฟีเจอร์ที่พึงประสงค์

2) **การสังเกตการณ์และการสำรวจระบบงานเดิม (Observation and Baseline Survey)**
สำรวจการนำเสนอข่าวและโครงสร้างของสำนักข่าวออนไลน์ภาษาไทยชั้นนำ เช่น ไทยรัฐ, มติชน, ข่าวสด, ผู้จัดการออนไลน์, ประชาไท, The Standard, เดลินิวส์, สำนักข่าวอิศรา, PPTV HD 36, Thai PBS, Workpoint Today, กรุงเทพธุรกิจ, โพสต์ทูเดย์ และ Sanook News เพื่อศึกษารูปแบบ RSS Feed โครงสร้าง HTML และการใช้งานเทคโนโลยีเรนเดอร์หน้าเว็บ

จากการศึกษาและรวบรวมข้อมูล คณะผู้จัดทำพบปัญหาสำคัญ 2 ประการหลัก ได้แก่

ประการแรก ปัญหาความกระจัดกระจายและข้อมูลข่าวสารซ้ำซ้อน (Information Overload and Fragmentation) เนื่องจากสำนักข่าวแต่ละแห่งต่างรายงานข่าวเดียวกันด้วยมุมมองและสำนวนพาดหัวที่แตกต่างกัน ทำให้ผู้อ่านต้องเปิดหลายเว็บไซต์และเสียเวลาคัดกรองเนื้อหาซ้ำซ้อน

ประการสอง ปัญหาผู้ใช้มักชอบอ่านแค่พาดหัวข่าว ทำให้ขาดความเข้าใจประเด็นอื่นๆ ในเนื้อหาข่าวนั้นๆ

ประการที่สาม ปัญหาความไม่ต่อเนื่องของประเด็นข่าว (Loss of Story Context) ข่าวเหตุการณ์ใหญ่ที่มีความยืดเยื้อข้ามสัปดาห์ เช่น อุทกภัยหรือคดีความ มักถูกตัดตอนและแยกส่วนตามกรอบเวลา 24–48 ชั่วโมง ทำให้ผู้อ่านขาดความเข้าใจในพัฒนาการตามลำดับเวลา

3.1.2 วิเคราะห์และออกแบบระบบ

คณะผู้จัดทำได้นำผลการศึกษาปัญหาและความต้องการมากำหนดเป็นข้อกำหนดระบบที่วัดผลได้อย่างเป็นรูปธรรม ประกอบด้วย

1) **การกำหนดความต้องการเชิงฟังก์ชัน (Functional Requirements)**
กำหนดความสามารถของระบบครอบคลุม 15 ข้อกำหนดหลัก (FR-01 ถึง FR-15) ได้แก่ การรวบรวมข่าวสารจากหลายสำนัก การลงทะเบียนแหล่งข่าวที่สามารถขยายต่อได้ การจำแนก 9

หมวดหมู่ภาษาไทย การสรุปเนื้อหาและวิเคราะห์อารมณ์ การนำเสนอแบบ Bento Hub การกรองและการค้นหา การพรีวิวเนื้อหาบทความ การบันทึกคั่นหน้า การระบุประเด็นข่าวสองชั้น การจัดอันดับกระแสข่าวสาร การเชื่อมโยงเส้นเรื่องมหาภาค แฟ้มสังเคราะห์ไทม์ไลน์และข้อเท็จจริงยืนยัน กลไกควบคุมความถูกต้อง 3 ระดับ ศูนย์ควบคุมสถานะของผู้ดูแลระบบ และการคุ้มครองความเป็นส่วนตัวตามมาตรฐาน PDPA

2) **การกำหนดความต้องการที่ไม่ใช่เชิงฟังก์ชัน (Non-functional Requirements)**
กำหนดเกณฑ์คุณภาพทางวิศวกรรม 8 มิติ (NFR-01 ถึง NFR-08) ได้แก่ เวลาตอบสนองคำขอต่ำกว่า 150 มิลลิวินาที ความหน่วงการกระจายข้อมูลสดต่ำกว่า 500 มิลลิวินาที อัตราการดึงข้อมูลไม่น้อยกว่า 100 บทความต่อนาที การแยกความเสียหายข้ามสำนักข่าว ความพร้อมใช้งานไม่ต่ำกว่าร้อยละ 99.5 ความแม่นยำ B-cubed Precision ≥ 0.85 และ B-cubed F1 ≥ 0.75 การรักษาความปลอดภัยตามหลัก Zero-PII และการทำงานข้ามแพลตฟอร์ม

3) **การกำหนดกฎการตรวจสอบความถูกต้องของข้อมูล (Validation Rules)**
กำหนดกฎเกณฑ์ควบคุมความสมบูรณ์ของข้อมูล 10 กฎ (VR-01 ถึง VR-10) ผ่านโมเดล Pydantic เพื่อป้องกันข้อผิดพลาดในการประมวลผลและการจัดเก็บ

4) **การจัดทำแบบจำลองระบบ (System Models)**
จัดทำแผนภาพกรณีใช้งาน (Use Case Diagram) และข้อกำหนดกรณีใช้งาน (UC-01 ถึง UC-04), แผนภาพลำดับขั้นตอน (Sequence Diagram) 3 กระบวนการหลัก, สถาปัตยกรรมเชิงตรรกะ 4 ชั้น (Logical Architecture), แผนภาพการติดตั้งระบบ (Deployment Architecture), แผนภาพสถานะ (State Machine Diagrams) ของวงจรชีวิตประเด็นข่าวและโหมดการสังเคราะห์, แผนภาพความสัมพันธ์ของข้อมูล (Relational Diagram) สำหรับ 6 ตารางหลัก และต้นแบบส่วนติดต่อกับผู้ใช้ (UI Mockup) จำนวน 6 รูปแบบ (M-01 ถึง M-06)

3.1.3 พัฒนาระบบ

การพัฒนาระบบแบ่งการทำงานออกเป็น 4 รอบการทำงานหลัก (Iterations) เพื่อให้สามารถทดสอบและปรับปรุงคุณภาพของแต่ละส่วนได้อย่างต่อเนื่อง ดังนี้

1) **รอบการทำงานที่ 1 การรวบรวม สกัดเนื้อหา และจำแนกหมวดหมู่ข่าวสาร**
พัฒนาไปป์ไลน์การดึงข่าวสารอัตโนมัติแบบอะซิงโครนัสด้วย HTTPX และ Playwright Headless Browser, การสกัดเนื้อหาบทความด้วย Trafilatura, ระบบแคชหลายระดับ (Multi-tier Caching) สองชั้น และโมเดลจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่อย่างรวดเร็วด้วยสถาปัตยกรรม 3-Tier Cascade Classifier (Regex Cues, LinearSVC/TF-IDF และ WangchanBERTa)

2) **รอบการทำงานที่ 2 การระบุประเด็นข่าวออนไลน์ 2 ชั้นและการจัดอันดับกระแสข่าว**
พัฒนาระบบระบุประเด็นข่าวออนไลน์แบบคงทน (Online Persistent Story Identification) ด้วยเวกเตอร์ฝังตัว WangchanBERTa ผสานการตรวจสอบเอนทิตีชื่อเฉพาะ thainer-v2 ผ่านเกณฑ์ Two-Band Cosine Gate และปรับปรุง Centroid แบบ EMA ข้ามหน้าต่าง 72 ชั่วโมง

พร้อมพัฒนาเอนจินจัดอันดับกระแสข่าวสาร 6 มิติเชิงสถิติแบบ Zero-LLM ที่ตัดลดทอนข่าวประจำวัน (Routine Penalty)

3) **รอบการทำงานที่ 3 แฟ้มสังเคราะห์ความคืบหน้าจากหลักฐานจริงและระบบเจาะประเด็นข่าว** พัฒนากระบวนการทำงานแบบ 3 ขั้นตอนที่บังคับให้ใช้ผลการคัดกรอง (Enforced Multi-Stage Pipeline) ประกอบด้วย Event Relevance Gate, Progression Timeline และ Corroborated Facts ที่ผ่านการตรวจสอบรหัสอ้างอิงรายประโยคอย่างเข้มงวด พร้อมพัฒนาระบบสืบค้นเจาะประเด็นข่าวเชิงลึก (Issue Explorer) บนฐานข้อมูล SQLite ในโหมดอ่านอย่างเดียว (Read-Only) และระบบปิดการทำงานฉุกเฉิน (Kill Switch)

4) **รอบการทำงานที่ 4 ส่วนต่อประสานผู้ใช้ การสื่อสารเรียลไทม์ และระบบควบคุม** พัฒนาหน้าจอ Bento Hub SPA ด้วย Vanilla JavaScript แบบโมดูลาร์ (Modular ES Modules) และ Tailwind CSS, การเชื่อมต่อผลักดันข้อมูลสดสองทิศทางผ่าน Socket.IO, หน้าต่างพรีวิวเนื้อหาข่าว In-App Reader Modal และการสังเคราะห์สรุปด้วย AI, ระบบบันทึกคั่นหน้าและประวัติการอ่านบน LocalStorage, ระบบจัดการความยินยอมคุกกี้ตามมาตรฐาน PDPA และศูนย์ควบคุมสถานะของผู้ดูแลระบบ (Ops Console)

3.1.4 ทดสอบและประเมินผล

การทดสอบและประเมินผลระบบประกอบด้วยการทดสอบทางวิศวกรรมซอฟต์แวร์และการประเมินความพึงพอใจของผู้ใช้งานจริง โดยแบ่งออกเป็น 2 ส่วนหลัก ดังนี้

ประการแรก การทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing หรือ UAT) ดำเนินการทดสอบตามกรณีทดสอบ 15 กรณี (TC-01 ถึง TC-15) ซึ่งครอบคลุมความต้องการเชิงฟังก์ชันครบทุกข้อ (FR-01 ถึง FR-15) โดยให้กลุ่มตัวอย่างผู้ใช้งานจริงดำเนินการทดสอบตามขั้นตอนอย่างเป็นระบบในภาคผนวก ข และคำนวณร้อยละของกรณีทดสอบที่ผ่านตามสมการที่ (3)

$$P = \frac{n_p}{N} \times 100 \tag{3}$$

เมื่อ

- P คือ ร้อยละของกรณีทดสอบที่ผ่าน
- n_p คือ จำนวนกรณีทดสอบที่ผ่านการทดสอบ
- N คือ จำนวนกรณีทดสอบทั้งหมด ($N = 15$)

ประการที่สอง การประเมินความพึงพอใจของผู้ใช้งาน ดำเนินการเก็บรวบรวมข้อมูลจากกลุ่มตัวอย่างผู้ใช้งานจริงที่ได้ทดลองใช้งานระบบผ่านเว็บไซต์จริง (https://e2enews.wittensky.com) จำนวน 9 คน ผ่านแบบสอบถามประเมินความพึงพอใจและประสิทธิภาพการใช้งานระบบบนระบบออนไลน์ Google Forms ตามภาคผนวก ค โดยแบบสอบถามแบ่งออกเป็น 3 ส่วนหลัก ได้แก่ ส่วนที่ 1 ข้อมูลทั่วไปและพฤติกรรมการติดตามข่าวสารของผู้ตอบแบบสอบถาม, ส่วนที่ 2 การประเมินฟังก์ชันการทำงานหลัก (Core Features Evaluation) ครอบคลุม 6 ด้านสำคัญผ่านเกณฑ์ Rating Scale 5 ระดับ (1 หมายถึง ไม่พึงพอใจเลย ถึง 5 หมายถึง พึงพอใจมากที่สุด) และส่วนที่ 3 ความพึงพอใจโดยรวม ประสบการณ์การใช้งาน และการบอกต่อ (Overall Satisfaction and Net Promoter

Score หรือ NPS) พร้อมข้อคำถามปลายเปิดเพื่อรับฟังปัญหาและข้อเสนอแนะในการพัฒนา โดยมีเกณฑ์การแปลความหมายค่าเฉลี่ยตามตารางที่ 2

ตารางที่ 2 เกณฑ์การแปลความหมายค่าเฉลี่ยความพึงพอใจ

ช่วงค่าเฉลี่ย	ระดับความพึงพอใจ
4.51–5.00	ดีมาก
3.51–4.50	ดี
2.51–3.50	ปานกลาง
1.51–2.50	พอใช้
1.00–1.50	ควรปรับปรุง

การวิเคราะห์ผลคะแนนความพึงพอใจใช้การคำนวณค่าเฉลี่ยเลขคณิต ($\bar{x}$) ตามสมการที่ (4) และค่าส่วนเบี่ยงเบนมาตรฐาน (S.D.) ตามสมการที่ (5)

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{4}$$

$$\text{S.D.} = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}} \tag{5}$$

เมื่อ

- $\bar{x}$ คือ ค่าเฉลี่ยของคะแนนความพึงพอใจ
- S.D. คือ ส่วนเบี่ยงเบนมาตรฐานของคะแนนความพึงพอใจ
- x_i คือ คะแนนความพึงพอใจของผู้ตอบแบบสอบถามคนที่ i (ช่วงคะแนน 1–5)
- n คือ จำนวนผู้ตอบแบบสอบถามทั้งหมด ($n = 30$)

3.1.5 ปรับปรุงและสรุปผล

นำผลการทดสอบการยอมรับของผู้ใช้และข้อเสนอแนะจากการประเมินความพึงพอใจมาปรับปรุงระบบ ได้แก่ การปรับแต่งเกณฑ์ค่าความคล้ายคลึงของประเด็นข่าว การขยายขีดความสามารถของระบบแคชเพื่อลดต้นทุนการเรียกใช้โมเดลภาษาขนาดใหญ่ การปรับแต่งการแสดงผลส่วนติดต่อผู้ใช้ให้รองรับอุปกรณ์เคลื่อนที่ และการจัดทำเอกสารคู่มือการติดตั้งตลอดจนรายงานโครงงานฉบับสมบูรณ์

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

การดำเนินโครงงานจำเป็นต้องใช้เครื่องมือทั้งด้านฮาร์ดแวร์และซอฟต์แวร์ที่มีประสิทธิภาพ เพื่อรองรับการประมวลผลข้อมูลภาษาธรรมชาติและการจำลองเบราว์เซอร์ โดยมีรายละเอียดดังนี้

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาและทดสอบระบบแสดงดังตารางที่ 3

ตารางที่ 3 ฮาร์ดแวร์ที่ใช้ในการพัฒนาและทดสอบ

ลำดับ	รายการ	รายละเอียดคุณลักษณะ
1	เครื่องคอมพิวเตอร์สำหรับการพัฒนา	หน่วยประมวลผล Intel Core Ultra 5, หน่วยความจำหลัก RAM 16 GB, หน่วยบันทึกข้อมูล SSD ขนาด 512 GB
2	เครื่องแม่ข่ายสำหรับทดสอบบนคลาวด์	AWS EC2 Instance (c7i-flex.large), Ubuntu 22.04 LTS, ขนาด 2 vCPU, หน่วยความจำหลัก RAM 4 GB, พื้นที่เก็บข้อมูล SSD 40 GB
3	จอแสดงผล	จอภาพขนาด 16 นิ้วขึ้นไป ความละเอียดระดับ Full HD (1920 × 1080 พิกเซล)
4	ระบบเครือข่ายอินเทอร์เน็ต	ความเร็วในการรับส่งข้อมูลไม่น้อยกว่า 100/100 Mbps สำหรับการสกัดข้อมูลข่าวสารและเชื่อมต่อภายนอก

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์และไลบรารีที่ใช้ในการพัฒนาระบบแสดงดังตารางที่ 4

ตารางที่ 4 ซอฟต์แวร์ที่ใช้ในการพัฒนา

ลำดับ	ซอฟต์แวร์ / ไลบรารี	เวอร์ชัน	วัตถุประสงค์การใช้งาน
1	Ubuntu Linux	22.04 LTS	ระบบปฏิบัติการหลักของเครื่องแม่ข่ายโพรดักชัน
2	Python	3.11.15	ภาษาโปรแกรมหลักสำหรับการประมวลผลฝั่งเซิร์ฟเวอร์
3	uv	0.6.14	ตัวจัดการสภาพแวดล้อมเสมือนและแพ็กเกจความเร็วสูง
4	FastAPI	0.141.1	เว็บเฟรมเวิร์กแบบอะซิงโครนัสสำหรับสร้าง REST API
5	Uvicorn	0.52.1	เว็บเซิร์ฟเวอร์ ASGI ประสิทธิภาพสูง
6	Playwright	1.62.0	จำลองเบราว์เซอร์ Chromium ดึงหน้าเว็บ JavaScript และ SPA
7	Trafilatura	2.2.0	สกัดเนื้อหาบทความข่าวและตัดส่วนประกอบที่ไม่เกี่ยวข้อง
8	PyThaiNLP	5.3.5	ตัดคำภาษาไทย กรองคำหยุด และสกัดเอนทิตีชื่อเฉพาะ thainer-v2
9	Scikit-learn	1.6.1	คำนวณเวกเตอร์ TF-IDF และโมเดลจำแนก LinearSVC
10	Transformers	5.15.1	รันโมเดลภาษา WangchanBERTa สกัดเวกเตอร์ความหมาย 768 มิติ
11	Tailwind CSS	3.4.1	ออกแบบส่วนติดต่อผู้ใช้แบบ Responsive ตามแนวคิด Bento Hub
12	SQLite3 (WAL Mode)	3.45+	ฐานข้อมูลเชิงสัมพันธ์น้ำหนักเบาพร้อมโหมด Write-Ahead Logging
13	Git	2.40+	ระบบควบคุมและจัดการรุ่นของซอร์สโค้ด (Version Control)
14	Visual Studio Code	1.90+	เครื่องมือแก้ไขและพัฒนาโปรแกรมต้นฉบับ

3.3 แผนการดำเนินงาน

แผนการดำเนินงานตลอดระยะเวลาการทำโครงงานตั้งแต่เดือนมิถุนายนถึงเดือนตุลาคม แสดงดังตารางที่ 5

ตารางที่ 5 แผนการดำเนินงาน ภาคการศึกษาที่ 2/2568

ลำดับ	กิจกรรม / ขั้นตอนการดำเนินงาน	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
ส่วนที่ 1 การศึกษา ออกแบบ และพัฒนาวิศวกรรมระบบ						
1	ศึกษาปัญหา รวบรวมความต้องการ และสืบค้นงานวิจัยที่เกี่ยวข้อง	●				
2	วิเคราะห์ข้อกำหนดระบบ จัดทำแบบจำลอง และออกแบบสถาปัตยกรรม	●	●			
3	พัฒนาระบบ Scraper Pipeline, Playwright และ Multi-tier Cache		●			
4	พัฒนาโมเดลจำแนก 9 หมวดหมู่ และระบบระบุประเด็นข่าว 2 ชั้น		●	●		
5	พัฒนาระบบจัดอันดับกระแสข่าว 6 มิติ และแฟ้มสังเคราะห์ไทม์ไลน์			●		
6	พัฒนา Bento Hub SPA, WebSocket สด, ระบบค้นหา และ PDPA			●	●	
ส่วนที่ 2 การทดสอบ ประเมินผล และสรุปรายงานโครงงาน						
7	พัฒนาชุดทดสอบอัตโนมัติ Unit Tests และ Integration Smoke Tests				●	
8	จัดทำแบบทดสอบการยอมรับของผู้ใช้ (UAT) และแบบประเมินความพึงพอใจ				●	
9	ดำเนินการทดสอบ UAT และเก็บรวบรวมข้อมูลความพึงพอใจจากผู้ใช้จริง				●	●
10	วิเคราะห์ข้อมูลสถิติ สรุปผลการประเมิน และปรับแต่งระบบขั้นสุดท้าย					●
11	จัดทำเอกสารรายงานโครงงานฉบับสมบูรณ์และเตรียมนำเสนอผลงาน					●
หมายเหตุ สัญลักษณ์ ● หมายถึง ช่วงเวลาดำเนินกิจกรรมในแต่ละขั้นตอนของโครงงาน						

จากตารางที่ 5 การดำเนินโครงงานเริ่มต้นจากการศึกษาปัญหาและออกแบบระบบในเดือนมิถุนายนถึงกรกฎาคม ดำเนินการพัฒนาระบบทั้งส่วนหน้าและส่วนหลังในเดือนกรกฎาคมถึงกันยายน และดำเนินการทดสอบระบบ ประเมินผลความพึงพอใจของผู้ใช้ สรุปผล และจัดทำเอกสารรายงานฉบับสมบูรณ์ในเดือนกันยายนถึงตุลาคม

บทที่ 4
การวิเคราะห์ระบบ และพัฒนาโปรแกรม

4.1 การวิเคราะห์ระบบ

บท นี้ ศึกษา ทำความ เข้าใจ ปัญหา และ ความ ต้องการ ของ ผู้ มี ส่วน ได้ ส่วน เสีย การ กำหนด ขอบเขต และ คุณลักษณะที่ระบบต้องตอบสนอง และสังเคราะห์ประเด็นข่าวภาษาไทย

4.1.1 ผู้ใช้งานระบบและสิทธิ์การเข้าถึง

ผู้ใช้งานระบบได้รับการจำแนกออกเป็น 3 กลุ่มหลัก ดังแสดงในตารางที่ 6

ตารางที่ 6 บทบาทและสิทธิ์การเข้าถึงระบบ

บทบาท	**สิทธิ์การเข้าถึงและการใช้งานระบบ**
ผู้อ่านข่าวทั่วไป (Reader)	เข้าถึงหน้าหลัก Bento Hub ผ่านเว็บเบราว์เซอร์ เรียกดูรายการข่าวสารสดประจำวัน กรองข่าวสารตาม 9 หมวดหมู่หลักและสำนักพิมพ์ ค้นหาข่าวสารด้วยคำสำคัญ เปิดพรีวิวเนื้อหาข่าวในตัวเว็บ (In-App Reader) พร้อมลิงก์ไปยังต้นฉบับเพื่อเคารพลิขสิทธิ์ อ่านบทสรุปเนื้อหาและผลวิเคราะห์อารมณ์ที่สังเคราะห์จากบทความฉบับเต็มด้วยโมเดลภาษาขนาดใหญ่ สำรวจประเด็นข่าวยอดนิยม 6 มิติ สำรวจแฟ้มมหากาพย์ประเด็นข่าวและไทม์ไลน์พัฒนาการเหตุการณ์ บันทึกคั่นหน้าบทความที่สนใจ เรียกดูประวัติการอ่าน และจัดการสิทธิ์ความเป็นส่วนตัวและคุกกี้ตามมาตรฐาน PDPA
ผู้ดูแลระบบ (Administrator)	เข้าสู่ศูนย์ควบคุมและติดตามสถานะระบบ (Ops Monitoring Console) ด้วยรหัสผ่านลับ ตรวจสอบสถานะการทำงาน สถิติ Throughput การใช้หน่วยความจำ และสถานะการทำงานของแคช สั่งเริ่มรอบการดึงข่าวด่วนทันที (Scrape Now) สั่งล้างแคชในหน่วยความจำและแคช HTTP (Clear Cache) ทดสอบการเชื่อมต่อและดึงข้อมูลของสำนักข่าวรายแห่ง (Test Source Probe) และตรวจสอบความสอดคล้องของคลังข้อมูล Single Source of Truth
ระบบตั้งเวลาและประมวลผลเบื้องหลัง (Automated Scheduler)	ทำงานอัตโนมัติตามรอบเวลา ดึงข้อมูลข่าวสารจากสำนักข่าวออนไลน์ทุกแห่งที่ลงทะเบียนผ่าน Playwright และ HTTP ดำเนินการตัดคำภาษาไทย ทำความสะอาดข้อความ และจำแนก 9 หมวดหมู่ สกัดเวกเตอร์ความหมาย 768 มิติและเอนทิตีชื่อเฉพาะ ระบุและรวมกลุ่มจุลเหตุการณ์ออนไลน์ (Stage A) เชื่อมโยงเข้าสู่เส้นเรื่องมหาภาค (Stage B) คำนวณคะแนนกระแสข่าว 6 มิติเชิงสถิติ บังคับใช้เกตป้องกันข้อมูลเท็จ 3 ชั้น บันทึกข้อมูลลงฐานข้อมูล SQLite WAL และไฟล์ JSON พร้อมทั้งกระจายสัญญาณข่าวสดไปยังเบราว์เซอร์ผ่าน WebSocket

4.1.2 ความต้องการเชิงฟังก์ชัน

ความต้องการเชิงฟังก์ชัน (Functional Requirements) กำหนดความสามารถและหน้าที่ที่ระบบต้องปฏิบัติตามความต้องการของผู้ใช้งานและระบบเบื้องหลัง ครอบคลุม 15 ข้อกำหนดหลัก (FR-01 ถึง FR-15) ดังแสดงในตารางที่ 7

ตารางที่ 7 ความต้องการเชิงฟังก์ชันของระบบ

รหัส	ความต้องการเชิงฟังก์ชัน	รายละเอียดความสามารถของระบบ	ผู้ใช้
FR-01	การดึงข่าวอัตโนมัติหลายสำนัก	ระบบสามารถดึงข้อมูลข่าวสารจากสำนักข่าวออนไลน์หลากหลายแห่ง ทั้งแบบ RSS Feed, เว็บไซต์ HTML ปกติ และเว็บไซต์ที่เรนเดอร์ด้วย JavaScript ผ่าน Playwright โดยไม่บล็อกการทำงานหลัก	ระบบอัตโนมัติ
FR-02	การลงทะเบียนแหล่งข่าวแบบไดนามิก	ระบบรองรับการเพิ่มและปรับปรุงแหล่งข่าวใหม่ผ่าน Decorator (@register_source) พร้อมกำหนดคู่สีของสำนักข่าวและตรวจสอบความถูกต้องก่อนเริ่มงาน	ผู้ดูแลระบบ
FR-03	การจำแนกหมวดหมู่ภาษาไทย 9 หมวด	ระบบสามารถตัดคำ ทำความสะอาดข้อความ และจำแนกข่าวภาษาไทยออกเป็น 9 หมวดหมู่อย่างถูกต้องด้วยเทคนิค 3-Tier Cascade Classifier	ระบบอัตโนมัติ
FR-04	การสรุปข่าวและวิเคราะห์อารมณ์	ระบบสามารถสร้างบทสรุปย่อ ประเด็นสำคัญ และวิเคราะห์อารมณ์ของข่าว (Sentiment) ด้วยโมเดลภาษาขนาดใหญ่ผ่าน KKU Gen.AI API พร้อมกลไกสำรอง	ผู้อ่านทั่วไป
FR-05	การแสดงผลข่าวสดบน Bento Hub	ระบบนำเสนอข่าวสารผ่านหน้าเว็บ Bento Hub แบบ 3 มุมมอง มีแบนเนอร์แจ้งเตือนข่าวใหม่ลอยตัว และกระจายสัญญาณสดผ่าน Socket.IO โดยไม่ต้องรีเฟรชหน้าจอ	ผู้อ่านทั่วไป
FR-06	การกรองข่าวและการสืบค้นคำสำคัญ	ระบบรองรับการกรองข่าวตาม 9 หมวดหมู่ กรองตามสำนักข่าว ค้นหาด้วยคำสำคัญแบบ Real-time และการสืบค้นขั้นสูงบนระบบเจาะประเด็นข่าว	ผู้อ่านทั่วไป

ตารางที่ 7 ความต้องการเชิงฟังก์ชันของระบบ (ต่อ)

รหัส	ความต้องการเชิงฟังก์ชัน	รายละเอียดความสามารถของระบบ	ผู้ใช้
FR-07	การอ่านพรีวิวเนื้อหาในตัวเว็บ	ระบบมีหน้าต่างแสดงผลพรีวิวเนื้อหาข่าวบางส่วน (In-App Modal Reader) ที่ผ่านการทำความสะอาดด้วย Trafilatura พร้อมลิงก์ไปยังต้นฉบับเพื่อความปลอดภัยด้านลิขสิทธิ์ และปุ่มสังเคราะห์สรุปเนื้อหาฉบับเต็มด้วย AI	ผู้อ่านทั่วไป
FR-08	การบันทึกคั่นหน้าและประวัติการอ่าน	ระบบเปิดให้ผู้ใช้บันทึกคั่นหน้าข่าวที่สนใจและเรียกดูประวัติการอ่านย้อนหลัง โดยจัดเก็บข้อมูลบน LocalStorage ของเบราว์เซอร์ปราศจากการระบุตัวตน	ผู้อ่านทั่วไป
FR-09	การระบุประเด็นข่าวออนไลน์แบบคงทน	ระบบสามารถรวมข่าวที่รายงานเหตุการณ์เดียวกันเข้าสู่กลุ่มประเด็นข่าวออนไลน์ผ่านเกณฑ์ Two-Band Cosine Gate และปรับปรุง Centroid ด้วย EMA ข้ามหน้าต่าง 72 ชม.	ระบบอัตโนมัติ
FR-10	การจัดอันดับกระแสข่าวสาร 6 มิติ	ระบบจัดอันดับประเด็นข่าวด้วย 6 มิติเชิงคณิตศาสตร์ ไม่ใช้ LLM ในการคำนวณคะแนน พร้อมกลไกลดทอนข่าวประจำวัน (Routine Penalty) และแจกแจงคะแนน	ผู้อ่านทั่วไป ระบบอัตโนมัติ
FR-11	การเชื่อมโยงเส้นเรื่องมหาภาค	ระบบเชื่อมโยงประเด็นข่าวย่อยข้ามสัปดาห์เข้าสู่มหากาพย์เหตุการณ์ผ่านคะแนนร่วม 4 ปัจจัย บังคับใช้กฎ Province-Only Veto และยกเว้นลดทอนเวลาในภาวะวิกฤต	ระบบอัตโนมัติ
FR-12	แฟ้มสังเคราะห์ไทม์ไลน์และข้อเท็จจริง	ระบบสังเคราะห์ภาพรวม ไทม์ไลน์พัฒนาการ และตารางข้อเท็จจริงยืนยันข้ามสำนักข่าว (Corroborated Facts) พร้อมระบบตรวจทานรหัสอ้างอิงรายประโยค	ผู้อ่านทั่วไป
FR-13	กลไกควบคุมความถูกต้อง 3 ระดับ	ระบบคัดกรองความเกี่ยวข้อง สกัด Typed Evidence และจัดสรรโหมดสังเคราะห์ 3 โหมด (halted_mismatch, single_source, synthesized) ป้องกันข้อมูลเท็จ	ระบบอัตโนมัติ

ตารางที่ 7 ความต้องการเชิงฟังก์ชันของระบบ (ต่อ)

รหัส	ความต้องการเชิงฟังก์ชัน	รายละเอียดความสามารถของระบบ	ผู้ใช้
FR-14	ศูนย์ควบคุมสถานะและการล้างแคช	ระบบมีหน้าต่างคอนโซลสำหรับผู้ดูแลระบบ ตรวจสอบ Throughput สั่งเริ่มสเกรปข่าวด่วนทันที ล้างแคช L1 และแคช HTTP และทดสอบสำนักข่าวรายแห่ง	ผู้ดูแลระบบ
FR-15	การคุ้มครองข้อมูลส่วนบุคคล PDPA	ระบบประมวลผลคะแนนการมีส่วนร่วมแบบนิรนาม ไม่เก็บข้อมูลส่วนบุคคล มีแถบขอความยินยอมคุกกี้ และมีปุ่มล้างสถิติความสนใจออกจากเบราว์เซอร์ได้ทันที	ผู้อ่านทั่วไป

4.1.3 ความต้องการที่ไม่ใช่เชิงฟังก์ชัน

ความต้องการที่ไม่ใช่เชิงฟังก์ชัน (Non-Functional Requirements) กำหนดคุณสมบัติเชิงคุณภาพ ขีดความสามารถ และข้อจำกัดทางวิศวกรรมของระบบ ครอบคลุม 8 มิติสำคัญ (NFR-01 ถึง NFR-08) ดังแสดงในตารางที่ 8

ตารางที่ 8 ความต้องการที่ไม่ใช่เชิงฟังก์ชันของระบบ

รหัส	ด้าน	เกณฑ์คุณลักษณะที่กำหนด
NFR-01	ด้านเวลาตอบสนองของระบบ (Performance Latency)	เวลาในการตอบสนองคำขอเรียกดูรายการข่าวผ่าน REST API (`GET /api/news`) ต้องมีค่าเฉลี่ยต่ำกว่า 150 มิลลิวินาทีเมื่อมีข้อมูลจัดเก็บในหน่วยความจำแคช
NFR-02	ด้านความหน่วงเวลาผลักดันข้อมูลสด (WebSocket Latency)	ความหน่วงเวลาในการกระจายข่าวสารใหม่และการแจ้งเตือนผ่าน Socket.IO ต้องต่ำกว่า 500 มิลลิวินาทีนับจากช่วงเวลาที่ข่าวได้รับการบันทึกลงระบบสำเร็จ
NFR-03	ด้านอัตราการดึงข้อมูลและ Throughput (Scraping Throughput)	ระบบต้องสามารถรองรับการดึงและสกัดเนื้อหาข่าวสารจากหลายสำนักพร้อมกันได้ในอัตราไม่น้อยกว่า 100 บทความต่อนาทีในสภาวะโหลดสูงสุด
NFR-04	ด้านความคงทนและการแยกความเสียหาย (Fault Isolation)	ความล้มเหลวในการเชื่อมต่อหรือโครงสร้างหน้าเว็บเปลี่ยนไปของสำนักข่าวใดสำนักข่าวหนึ่ง ต้องไม่ส่งผลกระทบต่อรอบการทำงานของสำนักข่าวอื่น
NFR-05	ด้านความพร้อมใช้งานของระบบ (System Availability)	ระบบต้องสามารถเปิดให้บริการอย่างต่อเนื่องตลอด 24 ชั่วโมงต่อวัน โดยมีอัตราความพร้อมใช้งานของระบบโดยรวมไม่ต่ำกว่าร้อยละ 99.5 ต่อเดือน
NFR-06	ด้านความแม่นยำในการระบุเหตุการณ์ (Identification Accuracy)	ระบบระบุประเด็นข่าวต้องมีค่าความแม่นยำ B-cubed Precision ไม่ต่ำกว่า 0.85 และค่า B-cubed F1-score ไม่ต่ำกว่า 0.75 บนชุดข้อมูลทดสอบมาตรฐาน
NFR-07	ด้านความมั่นคงปลอดภัยและความเป็นส่วนตัว (Security & Data Privacy)	ระบบต้องยึดหลัก Zero-PII ปราศจากการเก็บข้อมูลระบุตัวตน มีระบบ Rate Limiting, CORS Whitelist และส่วนหัวความปลอดภัย HTTP ป้องกัน XSS และ Clickjacking
NFR-08	ด้านการทำงานข้ามแพลตฟอร์ม (Cross-Platform Compatibility)	ซอฟต์แวร์ต้องสามารถรันได้อย่างสมบูรณ์ทั้งบนสภาพแวดล้อม Windows ในขั้นตอนการพัฒนา และสภาพแวดล้อม Linux Ubuntu บนคลาวด์สำหรับโพรดักชันจริง

4.1.4 กฎการตรวจสอบความถูกต้องของข้อมูล

เพื่อรักษาความสมบูรณ์ ความถูกต้อง และความมั่นคงปลอดภัยของข้อมูลที่ไหลเวียนในระบบ ระบบได้กำหนดกฎเกณฑ์การตรวจสอบความถูกต้องของข้อมูล (Validation Rules) อย่างเข้มงวดผ่านโมเดล Pydantic v2 ครอบคลุม 10 กฎสำคัญ (VR-01 ถึง VR-10) ดังแสดงในตารางที่ 9

ตารางที่ 9 กฎการตรวจสอบความถูกต้องของข้อมูล

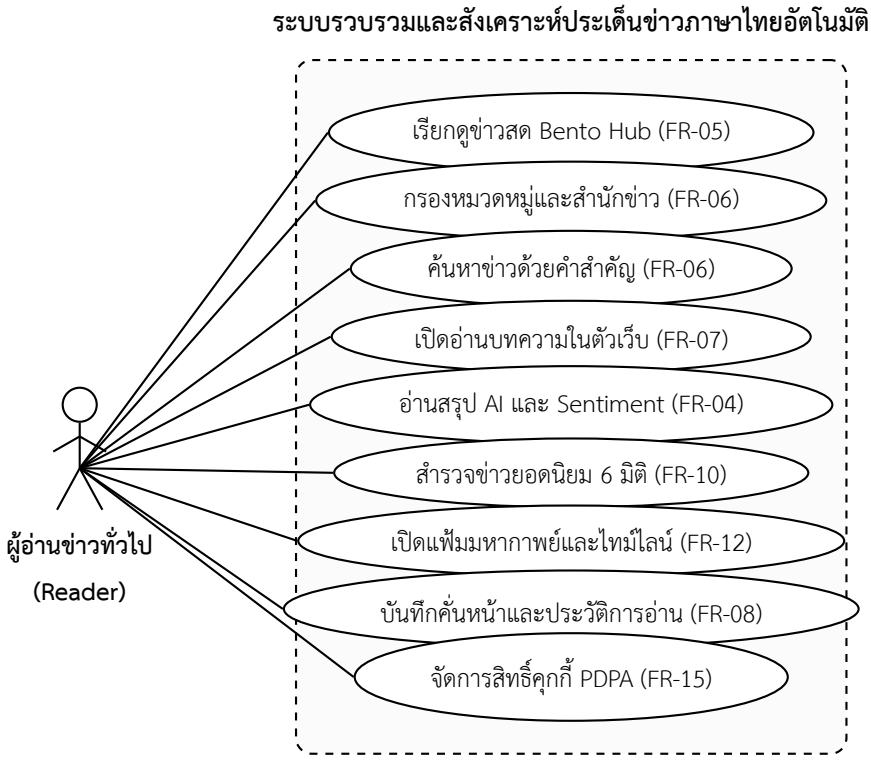
รหัส	ข้อมูลที่ตรวจสอบ	กฎการตรวจสอบความถูกต้องและข้อกำหนด
VR-01	URL บทความข่าว (`url`)	ต้องเป็นรูปแบบ URL ที่ถูกต้องตาม RFC 3986 ขึ้นต้นด้วย http หรือ https และมีความยาวไม่เกิน 2,048 อักขระ
VR-02	หัวข้อบทความข่าว (`title`)	ต้องเป็นข้อความสตริงที่ไม่ว่างเปล่า มีความยาวระหว่าง 5 ถึง 500 อักขระ และผ่านการตัดอักขระความกว้างศูนย์
VR-03	สำนักข่าวต้นทาง (`source`)	ต้องตรงกับรายชื่อสำนักข่าวที่ลงทะเบียนไว้ใน Source Registry และเปิดใช้งานอยู่ในระบบเท่านั้น
VR-04	หมวดหมู่ข่าว (`category`)	ต้องตรงกับ 1 ใน 9 หมวดหมู่หลักที่ระบบกำหนด ได้แก่ politics, economy, tech, crime, entertainment, sport, world, environment, social
VR-05	วันเวลาเผยแพร่ (`published_at`)	ต้องอยู่ในรูปแบบวันเวลามาตรฐาน ISO 8601 ที่ถูกต้อง และต้องไม่เป็นเวลาในอนาคตเกิน 1 ชั่วโมงเทียบกับเซิร์ฟเวอร์
VR-06	เวกเตอร์ความหมาย (`centroid`)	ต้องเป็นอาเรย์ของตัวเลขทศนิยมขนาด 768 มิติพอดี และต้องผ่านการปรับขนาดเวกเตอร์ให้เป็น 1 หน่วย (L2 Normalized)
VR-07	ความคล้ายคลึงโคไซน์ (`cosine`)	ต้องเป็นตัวเลขทศนิยมที่มีค่าอยู่ในช่วงทางคณิตศาสตร์ตั้งแต่ -1.0 ถึง 1.0 เสมอ
VR-08	รหัสผ่านลับผู้ดูแล (`secret`)	ต้องเป็นสตริงที่ไม่ว่างเปล่า มีความยาวไม่น้อยกว่า 8 อักขระ และตรวจสอบเทียบเคียงด้วยเวลาคงที่เพื่อป้องกัน Timing Attack
VR-09	เหตุการณ์การมีส่วนร่วม (`action`)	ต้องระบุประเภทการกระทำที่ระบบยอมรับเท่านั้น ได้แก่ click, summary_view, bookmark หรือ share
VR-10	ส่วนหัวยืนยันตัวตน (`Authorization`)	ต้องระบุรูปแบบ Bearer Token ที่ถูกต้องตามมาตรฐาน RFC 6750 และเป็นโทเค็นเซสชันที่ยังไม่หมดอายุในหน่วยความจำ

4.1.5 แผนภาพกรณีใช้งาน

การออกแบบพฤติกรรมของระบบจากมุมมองภายนอกนำเสนอผ่านแผนภาพกรณีใช้งาน (Use Case Diagram) ซึ่งจำแนกออกเป็น 2 มุมมองหลักตามบทบาทของผู้ใช้ ได้แก่ แผนภาพกรณีใช้งานสำหรับผู้อ่านข่าวทั่วไป (Reader) และแผนภาพกรณีใช้งานสำหรับระบบอัตโนมัติและผู้ดูแลระบบ (Scheduler & Admin)

(1) แผนภาพกรณีใช้งานสำหรับผู้อ่านข่าวทั่วไป

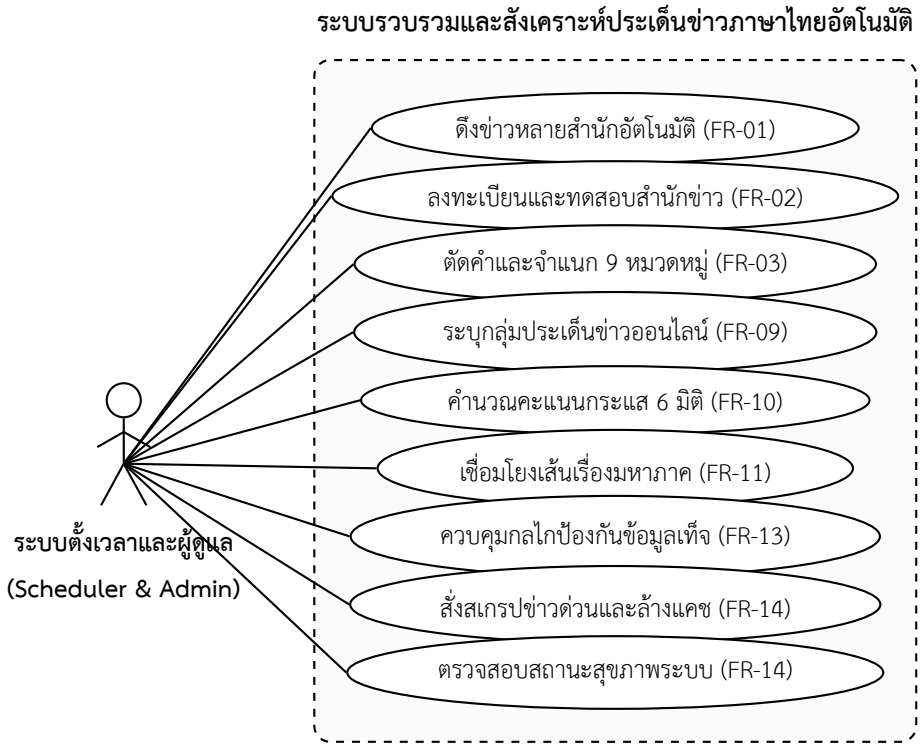
ผู้อ่านข่าวทั่วไปสามารถเข้าถึงบริการข้อมูลข่าวสาร สำรวจกระแส และใช้งานเครื่องมืออ่านข่าวผ่านเบราว์เซอร์ ดังแสดงในภาพที่ 1



ภาพที่ 1 แผนภาพกรณีใช้งานสำหรับผู้อ่านข่าวทั่วไป

(2) แผนภาพกรณีใช้งานสำหรับระบบอัตโนมัติและผู้ดูแลระบบ

ระบบตั้งเวลาเบื้องหลังและผู้ดูแลระบบทำหน้าที่ควบคุมการทำงานของไปป์ไลน์ ดึงข้อมูลจำแนกเนื้อหา ตลอดจนบริหารจัดการเซิร์ฟเวอร์ ดังแสดงในภาพที่ 2



ภาพที่ 2 แผนภาพกรณีใช้งานสำหรับระบบอัตโนมัติและผู้ดูแลระบบ

4.1.6 รายละเอียดกรณีใช้งาน

รายละเอียดกรณีใช้งานหลัก 4 กรณีสำคัญ (UC-01 ถึง UC-04) ซึ่งครอบคลุมทั้งส่วนผู้อ่านทั่วไปและการควบคุมระบบ แสดงรายละเอียดดังตารางที่ 10 ถึงตารางที่ 13

ตารางที่ 10 คำอธิบายกรณีใช้งาน UC-01 ติดตามข่าวสารสดและกรองตามหมวดหมู่

หัวข้อ	**รายละเอียด**
รหัสกรณีใช้งาน	UC-01
ชื่อกรณีใช้งาน	ติดตามข่าวสารสดและกรองตามหมวดหมู่
ความต้องการที่เกี่ยวข้อง	FR-05, FR-06
ผู้กระทำ	ผู้อ่านข่าวทั่วไป (Reader)
วัตถุประสงค์	เพื่อให้ผู้อ่านติดตามข่าวสารล่าสุดและคัดกรองเนื้อหาตามความสนใจได้อย่างสะดวก
เงื่อนไขก่อนเริ่ม	ผู้ใช้เปิดหน้าเว็บระบบผ่านเว็บเบราว์เซอร์ที่มีการเชื่อมต่ออินเทอร์เน็ต
เงื่อนไขหลังสิ้นสุด	ระบบแสดงรายการข่าวที่ตรงตามหมวดหมู่ สำนักข่าว หรือคำค้นหาที่ผู้ใช้เลือก
ลำดับเหตุการณ์หลัก	1. ผู้ใช้เข้าสู่หน้าหลัก Bento Hub ของระบบ 2. ระบบดาวน์โหลดและแสดงผลการ์ดข่าวสารล่าสุดพร้อมป้ายสำนักข่าวและหมวดหมู่ 3. ผู้ใช้คลิกเลือกแท็บหมวดหมู่ที่สนใจ เช่น หมวดการเมือง หรือเทคโนโลยี 4. ระบบกรองและปรับการแสดงผลเฉพาะบทความในหมวดหมู่ที่เลือกอย่างรวดเร็ว 5. เมื่อมีข่าวใหม่เข้ามาผ่าน WebSocket ระบบแสดงแบนเนอร์แจ้งเตือนลอยตัวกึ่งกลางบน 6. ผู้ใช้คลิกแบนเนอร์เพื่อโหลดข่าวใหม่เข้าสู่หน้าจอทันทีโดยไม่ต้องรีโหลดทั้งหน้าเว็บ
ลำดับเหตุการณ์ทางเลือก	3a. ผู้ใช้คลิกเลือกปุ่มสำนักข่าว (Publisher Filter Pills) เพื่อดูข่าวเฉพาะสำนักพิมพ์ที่สนใจ 3b. ผู้ใช้ป้อนข้อความค้นหาในช่อง Search เพื่อค้นหาข่าวแบบทันที
ลำดับเหตุการณ์ผิดปกติ	2a. เบราว์เซอร์ไม่สามารถเชื่อมต่อเซิร์ฟเวอร์ได้ ระบบแสดงข้อความแจ้งเตือนสถานะขาดการเชื่อมต่อ พร้อมมีปุ่มให้กดทดลองเชื่อมต่อใหม่

ตารางที่ 11 คำอธิบายกรณีใช้งาน UC-02 พรีวิวเนื้อหาบทความและสังเคราะห์สรุปด้วย AI

หัวข้อ	**รายละเอียด**
รหัสกรณีใช้งาน	UC-02
ชื่อกรณีใช้งาน	พรีวิวเนื้อหาบทความและสังเคราะห์สรุปด้วย AI
ความต้องการที่เกี่ยวข้อง	FR-04, FR-07, FR-08
ผู้กระทำ	ผู้อ่านข่าวทั่วไป (Reader)
วัตถุประสงค์	เพื่อให้ผู้อ่านสามารถดูพรีวิวเนื้อหาข่าวบางส่วนที่ปลอดภัย ลิงก์ต้นฉบับ และอ่านบทสรุป AI ที่สังเคราะห์จากเนื้อหาฉบับเต็ม
เงื่อนไขก่อนเริ่ม	ผู้ใช้อยู่ที่หน้าหลัก Bento Hub และมองเห็นการ์ดข่าวสาร
เงื่อนไขหลังสิ้นสุด	ผู้ใช้ได้รับข้อมูลพรีวิวข่าวหรือบทสรุปสังเคราะห์ และปิดหน้าต่างโมดอลกลับสู่หน้าหลัก
ลำดับเหตุการณ์หลัก	1. ผู้ใช้คลิกที่การ์ดข่าวเพื่อเปิดพรีวิวเนื้อหา 2. ระบบเปิดหน้าต่าง In-App Modal Reader แสดงผลเนื้อหาพรีวิวบางส่วนแบบสะอาดไร้โฆษณา และแสดงลิงก์ไปยังสำนักข่าวต้นทาง 3. ผู้ใช้คลิกปุ่มเปิดบทสรุปผู้บริหาร AI บนหน้าต่างอ่านข่าว 4. ระบบส่งเนื้อหาบทความฉบับเต็มไปสังเคราะห์สรุปย่อ ประเด็นสำคัญ และค่าอารมณ์ข่าวจาก LLM มาแสดงผล 5. ผู้ใช้คลิกปุ่มบันทึกคั่นหน้าเพื่อเก็บข่าวไว้อ่านในภายหลัง 6. ผู้ใช้คลิกปุ่มปิดหน้าต่างโมดอลเพื่อกลับสู่หน้าหลัก Bento Hub
ลำดับเหตุการณ์ทางเลือก	1a. ผู้ใช้คลิกปุ่มเปิดอ่านข่าวต้นฉบับภายนอก ระบบเปิดแท็บเบราว์เซอร์ใหม่ไปยังเว็บสำนักข่าว
ลำดับเหตุการณ์ผิดปกติ	2a. เว็บไซต์ต้นทางปิดกั้นการเข้าถึง ระบบแสดงข้อความแจ้งเตือนพร้อมเสนอทางเลือกให้เปิดเว็บต้นฉบับโดยตรง

ตารางที่ 12 คำอธิบายกรณีใช้งาน UC-03 สำรวจมหากาพย์ประเด็นข่าวและวิเคราะห์พัฒนาการ

หัวข้อ	**รายละเอียด**
รหัสกรณีใช้งาน	UC-03
ชื่อกรณีใช้งาน	สำรวจมหากาพย์ประเด็นข่าวและวิเคราะห์พัฒนาการ
ความต้องการที่เกี่ยวข้อง	FR-10, FR-11, FR-12, FR-13
ผู้กระทำ	ผู้อ่านข่าวทั่วไป (Reader)
วัตถุประสงค์	เพื่อให้ผู้อ่านเข้าใจภาพรวมเหตุการณ์ใหญ่ที่ซับซ้อนและติดตามลำดับพัฒนาการของข่าว
เงื่อนไขก่อนเริ่ม	ผู้ใช้เปิดดูส่วนข่าวกระแสหรือมหากาพย์ข่าวบนหน้าหลัก Bento Hub
เงื่อนไขหลังสิ้นสุด	ระบบแสดงแฟ้มเจาะลึกมหากาพย์พร้อมไทม์ไลน์และข้อเท็จจริงยืนยันอย่างโปร่งใส
ลำดับเหตุการณ์หลัก	1. ผู้ใช้คลิกเลือกมหากาพย์ประเด็นข่าวที่สนใจจากแถบ Bento Hub 2. ระบบเปิดหน้าต่างแฟ้มเจาะลึกเหตุการณ์ (Macro Storyline Dossier) 3. ระบบแสดงพาดหัวภาพรวมและบทสรุปสังเคราะห์ข้ามสำนักข่าวจากโมเดลภาษา 4. ระบบแสดงลำดับเหตุการณ์ตามเวลาจริง (Chronological Evolution Timeline) 5. ระบบแสดงตารางข้อเท็จจริงที่ได้รับการยืนยันตรงกันจากหลายสำนักข่าวอิสระ 6. ผู้ใช้คลิกสืบค้นประเด็นเชิงลึกผ่านหน้าต่างเจาะประเด็นข่าว (Issue Explorer)
ลำดับเหตุการณ์ทางเลือก	1a. ผู้ใช้คลิกดูรายละเอียดคะแนนกระแส 6 มิติเพื่อตรวจสอบความโปร่งใสของการจัดอันดับ
ลำดับเหตุการณ์ผิดปกติ	3a. หากชุดข่าวผู้สมัครไม่ตรงประเด็น ระบบเข้าสู่โหมดระงับการสังเคราะห์ (halted_mismatch) และแสดงข้อความแจ้งเตือนผู้ใช้อย่างโปร่งใสเพื่อป้องกันข้อมูลเท็จ

ตารางที่ 13 คำอธิบายกรณีใช้งาน UC-04 ควบคุมและตรวจสอบสถานะการทำงานของระบบ

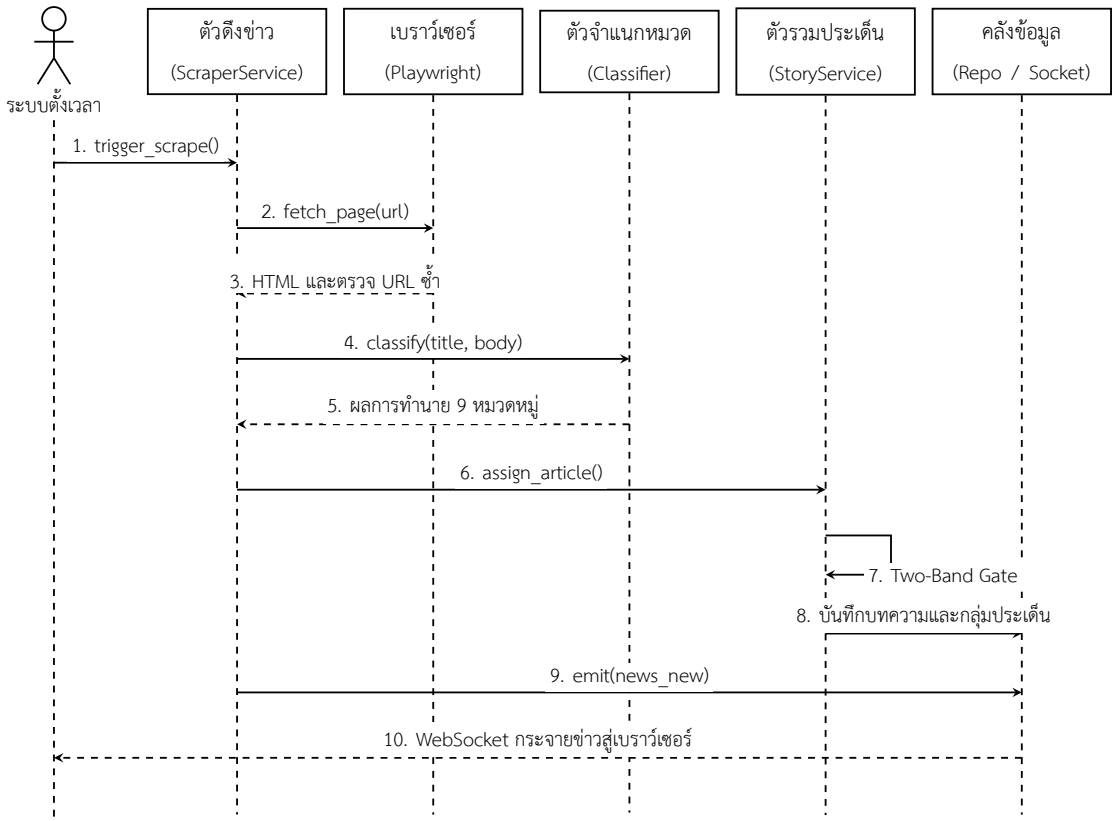
หัวข้อ	**รายละเอียด**
รหัสกรณีใช้งาน	UC-04
ชื่อกรณีใช้งาน	ควบคุมและตรวจสอบสถานะการทำงานของระบบ
ความต้องการที่เกี่ยวข้อง	FR-02, FR-14
ผู้กระทำ	ผู้ดูแลระบบ (Administrator)
วัตถุประสงค์	เพื่อให้ผู้ดูแลระบบสามารถตรวจสอบความสมบูรณ์ สั่งดึงข่าวด่วน และล้างแคชระบบ
เงื่อนไขก่อนเริ่ม	ผู้ดูแลระบบเปิดหน้าเว็บศูนย์ควบคุม (/monitoring.html) ผ่านเบราว์เซอร์
เงื่อนไขหลังสิ้นสุด	ผู้ดูแลระบบดำเนินการจัดการระบบสำเร็จและออกจากระบบอย่างปลอดภัย
ลำดับเหตุการณ์หลัก	1. ผู้ดูแลระบบกรอกรหัสผ่านลับบนหน้าจอยืนยันตัวตนและกดปุ่มเข้าสู่ระบบ 2. เซิร์ฟเวอร์ตรวจสอบความถูกต้องและส่งมอบ Bearer Token สำหรับเซสชัน 3. ระบบแสดงแดชบอร์ดสถิติ Throughput การใช้ RAM และสถานะแคช 4. ผู้ดูแลระบบตรวจสอบสถานะสุขภาพของแต่ละสำนักข่าวบนการ์ดแสดงผล 5. ผู้ดูแลระบบกดปุ่มสั่งเริ่มสเกรปข่าวด่วน (Scrape Now) 6. ระบบเริ่มกระบวนการสเกรปข่าวทุกสำนักในเบื้องหลังทันทีและส่งสัญญาณตอบรับ 7. ผู้ดูแลระบบกดปุ่มสั่งล้างแคชระบบ (Clear Cache) 8. ระบบดำเนินการล้างแคชในหน่วยความจำและแคช HTTP สำเร็จ 9. ผู้ดูแลระบบกดปุ่มออกจากระบบเพื่อทำลายโทเค็นเซสชัน
ลำดับเหตุการณ์ทางเลือก	4a. ผู้ดูแลระบบกดปุ่มทดสอบสำนักข่าวรายแห่ง (Test Source Probe) เพื่อดูตัวอย่างข่าว
ลำดับเหตุการณ์ผิดปกติ	1a. รหัสผ่านไม่ถูกต้อง ระบบส่งคืนรหัส 401 Unauthorized และปฏิเสธการเข้าถึง

4.1.7 แผนภาพลำดับของกระบวนการหลัก

เพื่อให้เห็นลำดับขั้นตอนการส่งผ่านข้อความระหว่างอ็อบเจกต์ต่าง ๆ ในระบบ ในหัวข้อนี้ขอนำเสนอแผนภาพลำดับ (Sequence Diagrams) ครอบคลุม 3 ไปป์ไลน์หลัก ได้แก่ การรวบรวม จำแนกหมวด จัดกลุ่มประเด็น และกระจายข่าวสด, การสังเคราะห์พัฒนาการเหตุการณ์ตามลำดับเวลา, และการควบคุมระบบและล้างแคชของผู้ดูแลระบบ

(1) ไปป์ไลน์การรวบรวม จำแนกหมวด จัดกลุ่มประเด็น และกระจายข่าวสด

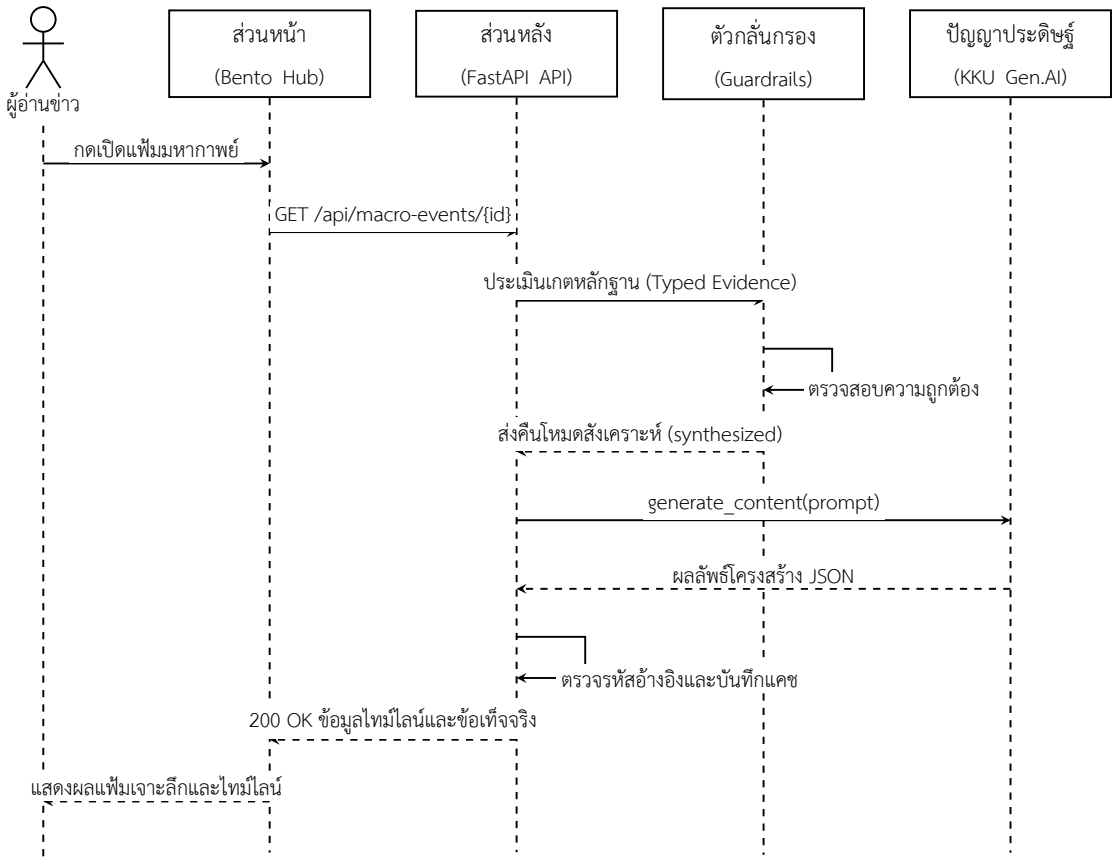
กระบวนการนี้เป็นไปป์ไลน์หลักในการนำเข้าและประมวลผลข่าวสารแบบ Asynchronous ตลอด 24 ชั่วโมง ดังแสดงในภาพที่ 3



ภาพที่ 3 แผนภาพลำดับกระบวนการรวบรวม จำแนกหมวด จัดกลุ่มประเด็น และกระจายข่าวสด

(2) ไปป์ไลน์การสังเคราะห์พัฒนาการเหตุการณ์ตามลำดับเวลา

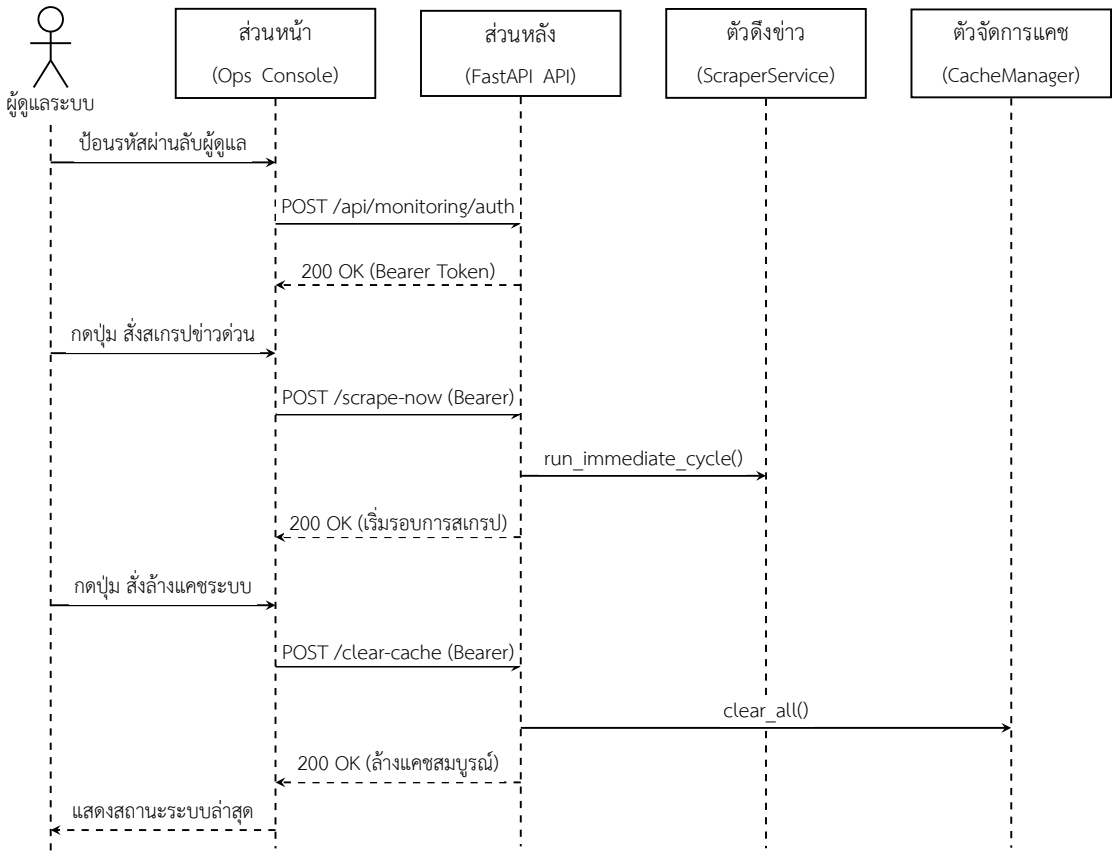
กระบวนการนี้ทำงานเมื่อผู้ใช้ร้องขอแฟ้มเจาะลึกมหากาพย์ประเด็นข่าว โดยผ่านการกลั่นกรองด้วยเกต 3 ชั้นและโมเดลภาษา ดังแสดงในภาพที่ 4



ภาพที่ 4 แผนภาพลำดับกระบวนการสังเคราะห์พัฒนาการเหตุการณ์ตามลำดับเวลา

(3) ไปป์ไลน์การควบคุมระบบและล้างแคชของผู้ดูแลระบบ

กระบวนการนี้แสดงการเข้าสู่ระบบ ยืนยันตัวตน สั่งเริ่มสเกรปข่าวด่วน และการล้างข้อมูลในระบบแคช ดังแสดงในภาพที่ 5



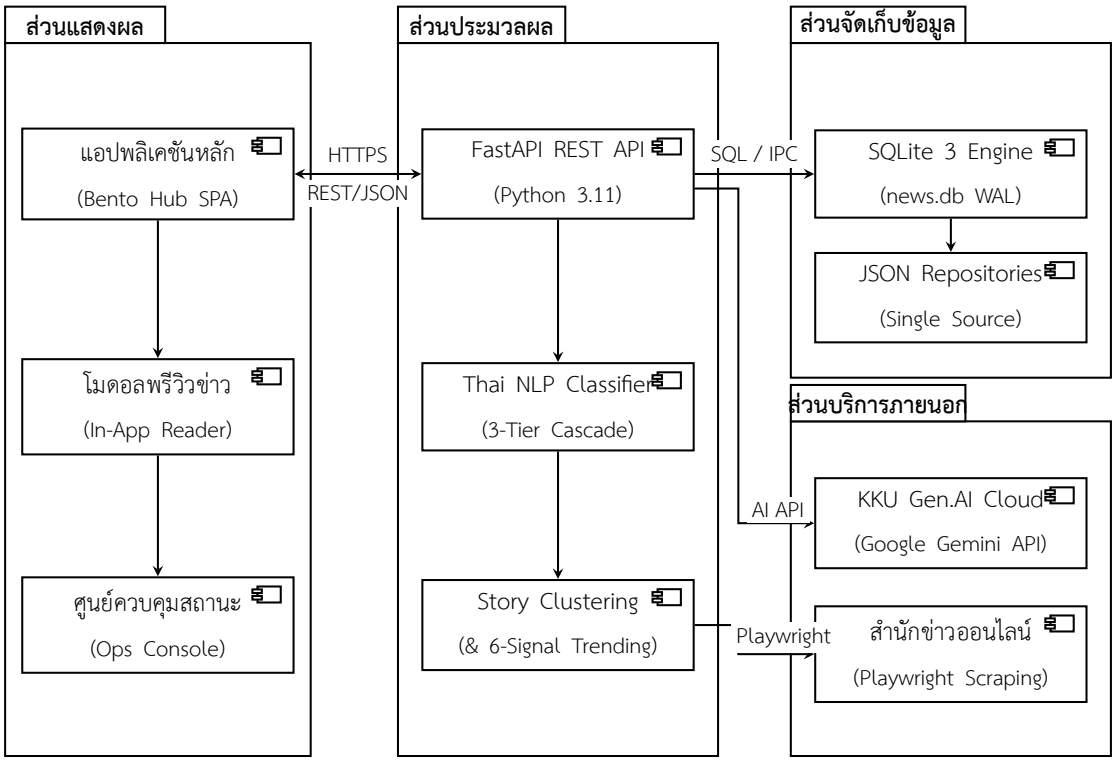
ภาพที่ 5 แผนภาพลำดับกระบวนการควบคุมระบบและล้างแคชของผู้ดูแลระบบ

4.2 การออกแบบระบบ

การออกแบบระบบ (System Design) มุ่งเน้นการแปลงข้อกำหนดเชิงวิเคราะห์ไปสู่โครงสร้างทางวิศวกรรมที่สามารถนำไปปฏิบัติจริงได้อย่างมีประสิทธิภาพ ยึดหลักการแยกชั้นความรับผิดชอบ (Separation of Concerns) ตามแนวคิดสถาปัตยกรรม 4 ชั้น (4-Tier Architecture) ออกแบบสถาปัตยกรรมการติดตั้งบนคลาวด์ การจัดการสถานะวงจรชีวิตข้อมูล การออกแบบโครงสร้างฐานข้อมูลเชิงสัมพันธ์ ตลอดจนการออกแบบจุดเชื่อมต่อบริการและส่วนต่อประสานผู้ใช้

4.2.1 สถาปัตยกรรมของระบบ

โครงสร้างสถาปัตยกรรมเชิงตรรกะของระบบ (Logical Architecture) แบ่งออกเป็น 4 ชั้นหลักอย่างชัดเจน ได้แก่ Presentation Tier, Processing Tier, Data Tier, และ External Services Tier ดังแสดงในภาพที่ 6

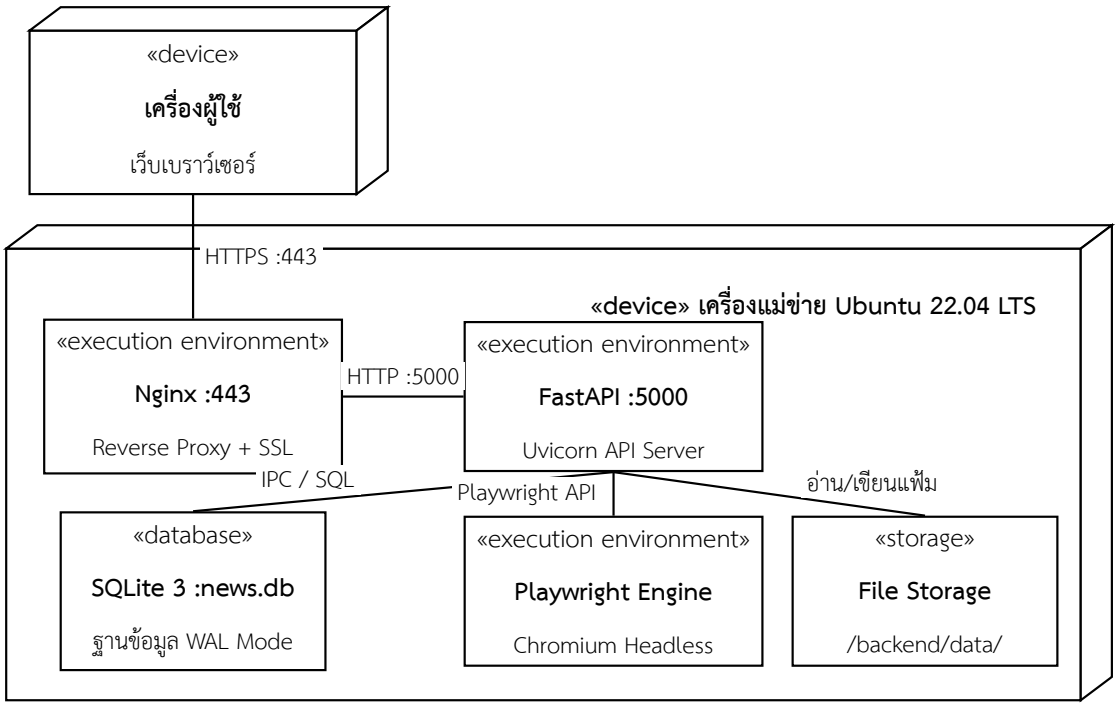


ภาพที่ 6 สถาปัตยกรรมเชิงตรรกะของระบบ

สถาปัตยกรรม การ ทำงาน ของ ระบบ ยึด หลัก Single Responsibility Principle และ Single Source of Truth (SST) เพื่อ ให้ ระบบ สามารถ สังเคราะห์ เนื้อหา ข่าว หลาย สำนัก ได้ อย่าง ถูก ต้อง ปราศจาก การ สร้าง ข้อมูล เท็จ (Hallucination) และ ไม่ กวาด ข่าว ผิด ชุด เข้า มา นำ เสนอ โดย ใน ส่วน การ ประมวล ผล เชื่อม โยง เหตุการณ์ `MacroEventService` จะ ประเมิน เพื่อ เชื่อม โยง เข้า สู่ เส้น เรื่อง ของ ประเด็น หลัก (`MacroEventRecord`) ผ่าน คะแนน ความ สอดคล้อง รวม 4 ปัจจัย หาก มี คะแนน ≥ 0.72 และ มี เอนทิตี เฉพาะ ตรง กัน จะ เชื่อม โยง เข้า ประเด็น หลัก เดิม พร้อม กำหนด ความ สัมพันธ์ เชิง เวลา (`precedes` หรือ `updates`) ภายใต้ กำหนด การ 45 วัน โดย มี กลไก ยับยั้ง ความ ขัดแย้ง ของ ระดับ จังหวัด (Strict Province-Only Veto) ป้องกัน การ นำ เหตุการณ์ ต่าง พื้นที่ มา ผูก รวม กัน และ มี กระบวน การ กู้คืน อัตโนมัติ (`Reconciliation Engine`) ที่ สามารถ สร้าง ดัชนี ประเด็น ขึ้น ใหม่ ได้ ทันที หาก พบ ความ ไม่ สอดคล้อง ของ ข้อมูล

4.2.2 แผนภาพการติดตั้ง

การติดตั้งระบบบนสภาพแวดล้อมปฏิบัติการจริงได้รับการออกแบบตามมาตรฐาน UML Deployment Node โดยใช้เครื่องแม่ข่าย AWS EC2 ร่วมกับเครือข่ายส่งมอบเนื้อหา Cloudflare และบริการคลาวด์ภายนอก ดังแสดงในภาพที่ 7



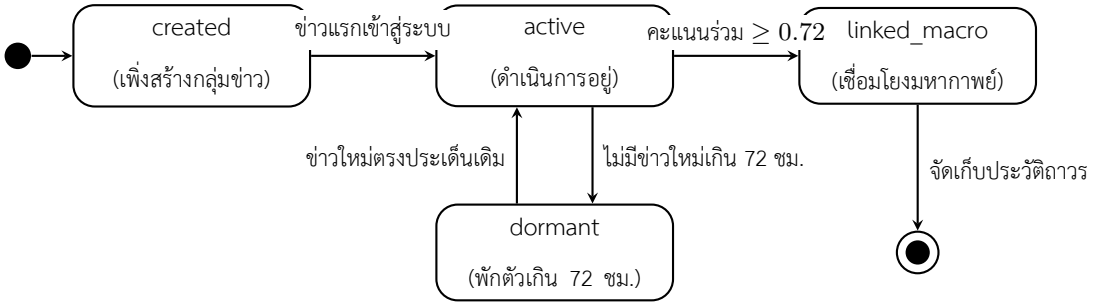
ภาพที่ 7 แผนภาพการติดตั้งระบบ

4.2.3 แผนภาพสถานะ

เพื่อ ควบคุม พฤติกรรม และ การ เปลี่ยนแปลง ของ ข้อมูล อย่าง แม่นยำ ระบบ ได้ ออกแบบ แผนภาพสถานะ (State Machine Diagrams) ครอบคลุม 2 กลไกสำคัญ ได้แก่ วงจรชีวิตของกลุ่มประเด็นข่าว และโหมดการสังเคราะห์เนื้อหาที่มีหลักฐานอ้างอิง

(1) แผนภาพสถานะวงจรชีวิตของประเด็นข่าว

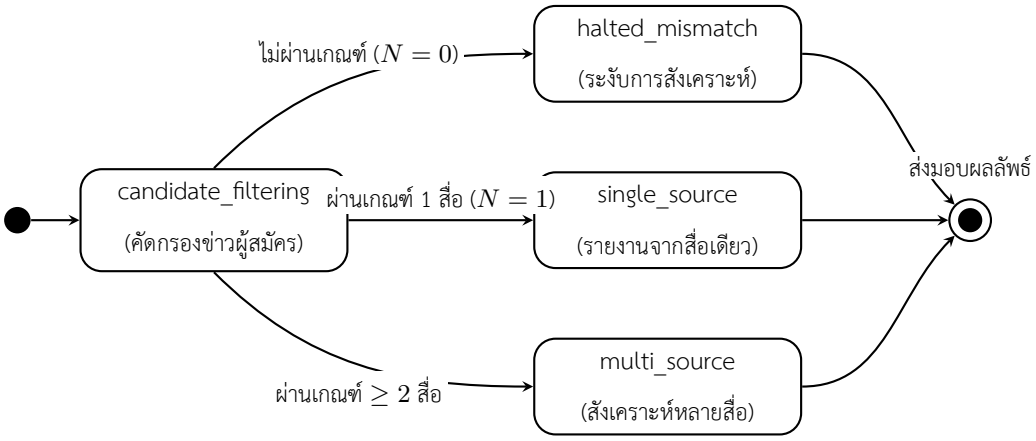
กลุ่มประเด็นข่าวออนไลน์ (`StoryRecord`) ได้รับการบริหารจัดการวงจรชีวิตเพื่อความคงทนและประหยัดทรัพยากร ดังแสดงในภาพที่ 8



ภาพที่ 8 แผนภาพสถานะวงจรชีวิตของประเด็นข่าว

(2) แผนภาพสถานะโหมดการสังเคราะห์เนื้อหาที่มีหลักฐานอ้างอิง

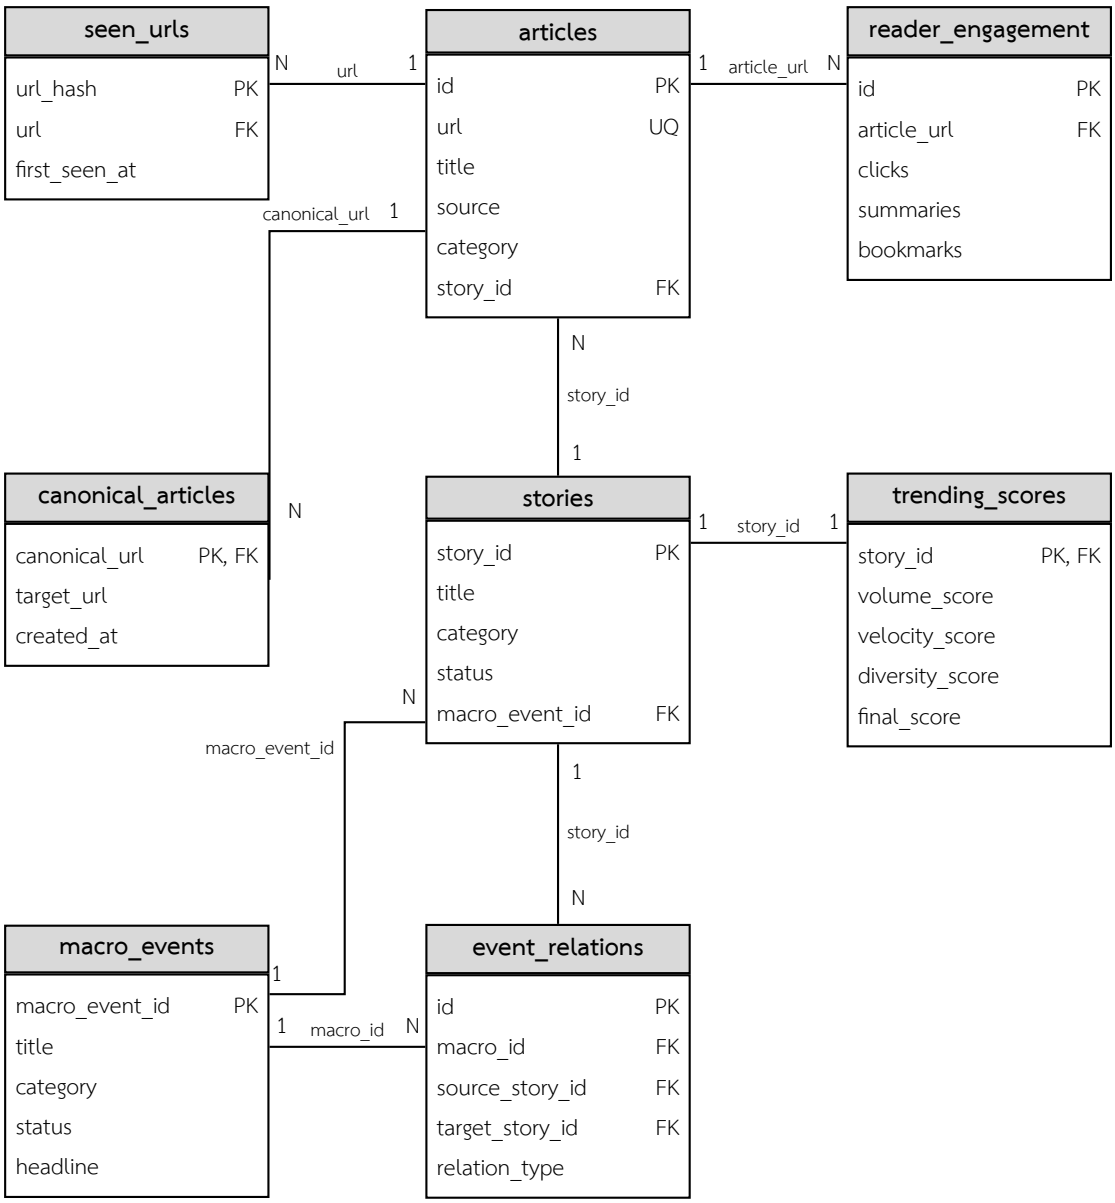
กระบวนการสังเคราะห์เนื้อหาและจัดเตรียมแฟ้มข่าวกรองผ่านกลไก 3-Layer Guardrails มีการเปลี่ยนผ่านสถานะตามปริมาณหลักฐาน ดังแสดงในภาพที่ 9



ภาพที่ 9 แผนภาพสถานะโหมดการสังเคราะห์เนื้อหาที่มีหลักฐานอ้างอิง

4.2.4 การออกแบบฐานข้อมูล

การออกแบบฐานข้อมูลเชิงสัมพันธ์ของระบบประกอบด้วย 6 ตารางหลัก ได้แก่ `articles`, `stories`, `macro_events`, `event_relations`, `trending_scores` และ `reader_engagement` พร้อมด้วยตารางสนับสนุนอีก 2 ตาราง ได้แก่ `seen_urls` และ `canonical_articles` ดังแสดงความสัมพันธ์และภาวะเชิงจำนวนในแผนภาพความสัมพันธ์ของข้อมูล ภาพที่ 10



ภาพที่ 10 แผนภาพความสัมพันธ์ของข้อมูล

รายละเอียดโครงสร้างทางกายภาพของตารางข้อมูลทั้ง 6 ตารางหลักและตารางสนับสนุน แสดงดังตารางที่ 14 ถึงตารางที่ 21

ตารางที่ 14 โครงสร้างตาราง articles

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
id	INTEGER	PK	AUTO	รหัสระบุลำดับบทความในฐานข้อมูล SQLite
url	TEXT	UQ	ไม่มี	ลิงก์ที่อยู่บทความข่าวต้นฉบับ (Primary Key เชิงธุรกิจ)
title	TEXT	-	ไม่มี	หัวข้อบทความข่าวที่สกัดได้
source	TEXT	-	ไม่มี	ชื่อสำนักข่าวต้นทาง (เช่น ThaiPBS, Thairath)
fetched_at	TEXT	-	ไม่มี	วันเวลาที่ระบบดึงข้อมูลตามมาตรฐาน ISO 8601
summary	TEXT	-	NULL	ข้อความสรุปย่อเนื้อหาข่าวจากโมเดลภาษา
category	TEXT	-	NULL	หมวดหมู่ข่าว 1 ใน 9 หมวดหมู่หลัก
story_id	TEXT	FK	NULL	รหัสกลุ่มประเด็นข่าวที่สังกัด (เชื่อมไปยัง stories)
sentiment	TEXT	-	NULL	ค่าอารมณ์ของข่าว (positive, neutral, negative)
image_url	TEXT	-	NULL	ลิงก์รูปภาพหน้าปกบทความข่าว

ตารางที่ 15 โครงสร้างตาราง stories

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
story_id	TEXT	PK	ไม่มี	รหัสระบุกลุ่มประเด็นข่าวแบบคงทน (เช่น story_0b86804a)
title	TEXT	-	ไม่มี	หัวข้อข่าวตัวแทนตั้งต้นของกลุ่มประเด็น
category	TEXT	-	ไม่มี	หมวดหมู่หลักของกลุ่มประเด็นข่าว
status	TEXT	-	'active'	สถานะวงจรชีวิตประเด็นข่าว (active หรือ dormant)
created_at	TEXT	-	ไม่มี	วันเวลาที่สร้างกลุ่มประเด็นข่าว
updated_at	TEXT	-	ไม่มี	วันเวลาที่มีข่าวใหม่เข้ามาอัปเดตล่าสุด
article_count	INTEGER	-	1	จำนวนบทความข่าวทั้งหมดที่อยู่ในกลุ่มประเด็นนี้
outlet_count	INTEGER	-	1	จำนวนสำนักข่าวที่ไม่ซ้ำกันที่รายงานประเด็นนี้
centroid	BLOB/TEXT	-	ไม่มี	เวกเตอร์ศูนย์กลาง 768 มิติ ปรับปรุงด้วย EMA
macro_event_id	TEXT	FK	NULL	รหัสมหากาพย์ประเด็นข่าวที่สังกัด (เชื่อมไปยัง macro_events)

ตารางที่ 16 โครงสร้างตาราง macro_events

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
macro_event_id	TEXT	PK	ไม่มี	รหัสระบุมหากาพย์ประเด็นข่าวถาวร (เช่น macro_1a2b3c4d)
title	TEXT	-	ไม่มี	ชื่อหัวข้อเหตุการณ์มหาภาค
category	TEXT	-	ไม่มี	หมวดหมู่หลักของมหากาพย์ประเด็นข่าว
status	TEXT	-	'active'	สถานะการติดตามเหตุการณ์ (active หรือ dormant)
storyline_anchor	TEXT	-	NULL	คำสำคัญหรือแกนเรื่องราวหลักของมหากาพย์
created_at	TEXT	-	ไม่มี	วันเวลาที่เริ่มต้นสร้างมหากาพย์ประเด็นข่าว
updated_at	TEXT	-	ไม่มี	วันเวลาที่มีความเคลื่อนไหวล่าสุด
headline	TEXT	-	NULL	พาดหัวข่าวสังเคราะห์ภาพรวมจากโมเดลภาษา
summary	TEXT	-	NULL	บทสรุปสังเคราะห์ภาพรวมข้ามสำนักข่าว

ตารางที่ 17 โครงสร้างตาราง event_relations

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
id	INTEGER	PK	AUTO	รหัสระบุลำดับความสัมพันธ์ในฐานข้อมูล
macro_id	TEXT	FK	ไม่มี	รหัสมหากาพย์ประเด็นข่าวที่เชื่อมโยง
source_story_id	TEXT	FK	ไม่มี	รหัสประเด็นข่าวต้นทาง
target_story_id	TEXT	FK	ไม่มี	รหัสประเด็นข่าวปลายทาง
relation_type	TEXT	-	'precedes'	ประเภทความสัมพันธ์ (precedes, updates, responds_to, caused_by)
created_at	TEXT	-	ไม่มี	วันเวลาที่สร้างความสัมพันธ์

ตารางที่ 18 โครงสร้างตาราง trending_scores

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
story_id	TEXT	PK, FK	ไม่มี	รหัสประเด็นข่าว (เชื่อมไปยัง stories และไม่ซ้ำ)
volume_score	REAL	-	0.0	คะแนนปริมาณข่าวในรอบ 24 ชั่วโมง (s_1)
velocity_score	REAL	-	0.0	คะแนนอัตราเร่งการมาถึงของข่าว (s_2)
diversity_score	REAL	-	0.0	คะแนนความหลากหลายของสำนักข่าว (s_3)
recency_score	REAL	-	0.0	คะแนนความสดใหม่ลดทอนตามเวลา (s_4)
novelty_score	REAL	-	0.0	คะแนนความแปลกใหม่ของประเด็นข่าว (s_5)
engagement_score	REAL	-	0.0	คะแนนพฤติกรรมปฏิสัมพันธ์ของผู้อ่าน (s_6)
routine_penalty	REAL	-	1.0	ตัวคูณลดทอนข่าวประจำวัน (0.25 สำหรับข่าววงรอบ)
final_score	REAL	-	0.0	คะแนนกระแสรวมหลังปรับค่าน้ำหนักและตัวลดทอน

ตารางที่ 19 โครงสร้างตาราง reader_engagement

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
id	INTEGER	PK	AUTO	รหัสระบุลำดับสถิติการมีส่วนร่วม
article_url	TEXT	FK	ไม่มี	ลิงก์ที่อยู่บทความข่าว (เชื่อมไปยัง articles)
clicks	INTEGER	-	0	จำนวนครั้งที่ผู้อ่านคลิกเปิดอ่านบทความ
summaries	INTEGER	-	0	จำนวนครั้งที่ผู้อ่านเปิดดูบทสรุป AI
bookmarks	INTEGER	-	0	จำนวนครั้งที่ผู้อ่านบันทึกคั่นหน้าบทความ
last_engaged_at	TEXT	-	ไม่มี	วันเวลาที่มีปฏิสัมพันธ์ล่าสุด

ตารางที่ 20 โครงสร้างตาราง seen_urls

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
url_hash	TEXT	PK	ไม่มี	ค่าแฮชของ URL บทความข่าวสำหรับตรวจสอบข่าวซ้ำด่วน
url	TEXT	-	ไม่มี	ลิงก์บทความข่าวฉบับเต็ม
first_seen_at	TEXT	-	ไม่มี	วันเวลาที่ระบบตรวจพบข่าวนี้เป็นครั้งแรก

ตารางที่ 21 โครงสร้างตาราง canonical_articles

ฟิลด์	ชนิดข้อมูล	คีย์	ค่าเริ่มต้น	คำอธิบาย
canonical_url	TEXT	PK	ไม่มี	ลิงก์มาตรฐานของบทความต้นฉบับ
target_url	TEXT	-	ไม่มี	ลิงก์ปลายทางกรณีสำนักพิมพ์ในเครือคัดลอกบทความ
created_at	TEXT	-	ไม่มี	วันเวลาที่สร้างดัชนีบทความมาตรฐาน

ข้อกำหนดความคงสภาพของข้อมูลและดัชนี (Constraints and Indices) ที่ติดตั้งบนฐานข้อมูลเพื่อรักษาความสมบูรณ์และเพิ่มประสิทธิภาพการสืบค้น แสดงดังตารางที่ 22

ตารางที่ 22 ข้อจำกัดและดัชนีของฐานข้อมูล

ตาราง	ฟิลด์	ประเภทข้อจำกัด / ดัชนี	รายละเอียดและวัตถุประสงค์
articles	url	UNIQUE INDEX	ป้องกันการบันทึกข่าวซ้ำในระดับฐานข้อมูล
articles	story_id	B-TREE INDEX	เพิ่มความเร็วในการดึงข่าวสมาชิกในประเด็น
articles	category	B-TREE INDEX	เพิ่มความเร็วในการกรองข่าวตาม 9 หมวดหมู่
articles	fetched_at	B-TREE INDEX	เพิ่มความเร็วในการเรียงลำดับข่าวสดตามเวลา
stories	story_id	PRIMARY KEY	รับประกันความไม่ซ้ำของรหัสประเด็นข่าว
stories	status	CHECK CONSTRAINT	บังคับค่าสถานะต้องเป็น 'active' หรือ 'dormant'
stories	macro_event_id	B-TREE INDEX	เพิ่มความเร็วในการดึงประเด็นย่อยในมหากาพย์
macro_events	macro_event_id	PRIMARY KEY	รับประกันความไม่ซ้ำของรหัสมหากาพย์
macro_events	status	CHECK CONSTRAINT	บังคับค่าสถานะต้องเป็น 'active' หรือ 'dormant'
event_relations	macro_id	FOREIGN KEY	บังคับความสอดคล้องกับตาราง macro_events
trending_scores	story_id	PK, FK, UNIQUE	บังคับความสัมพันธ์ 1 ต่อ 1 กับตาราง stories
reader_engagement	article_url	FOREIGN KEY	บังคับความสอดคล้องกับตาราง articles
seen_urls	url_hash	PRIMARY KEY	ดัชนีหลักสำหรับตรวจสอบการสเกรปซ้ำ

4.2.5 การออกแบบส่วนเชื่อมต่อโปรแกรมประยุกต์

จุดเชื่อมต่อบริการ REST API ของระบบได้รับการออกแบบตามมาตรฐาน OpenAPI 3.0 ครอบคลุม 22 จุดเชื่อมต่อบริการ ดังแสดงในตารางที่ 23 และรหัสสถานะ HTTP ที่ระบบใช้แสดงดังตารางที่ 24

ตารางที่ 23 เส้นทางของส่วนเชื่อมต่อโปรแกรมประยุกต์

เมธอด	เส้นทาง (Route)	การทำงานและวัตถุประสงค์	สิทธิ์การเข้าถึง
GET	`/api/stories`	เรียกดูรายการกลุ่มประเด็นข่าวสาร พร้อมการแบ่งหน้าและกรอง	ผู้อ่านทั่วไป
GET	`/api/stories/trending`	ดึงประเด็นข่าวยอดนิยมที่ผ่านการจัดอันดับเชิงสถิติ 6 มิติ	ผู้อ่านทั่วไป
GET	`/api/stories/{id}`	ดึงรายละเอียดประเด็นข่าว ไทม์ไลน์ และบทความข่าวสมาชิก	ผู้อ่านทั่วไป
POST	`/api/stories/{id}/summarize`	ร้องขอการสรุปและสังเคราะห์ประเด็นข่าวข้ามสำนักด้วย LLM	ผู้อ่านทั่วไป
GET	`/api/macro-events`	เรียกดูรายการมหากาพย์ประเด็นข่าว พร้อมตัวกรองวิกฤต	ผู้อ่านทั่วไป
GET	`/api/macro-events/trending`	ดึงมหากาพย์ข่าวเด่นที่กำลังเป็นกระแสสำหรับหน้าแรก Bento Hub	ผู้อ่านทั่วไป
GET	`/api/macro-events/{id}`	ดึงโครงสร้างมหากาพย์ ความสัมพันธ์ประเด็นย่อย และไทม์ไลน์	ผู้อ่านทั่วไป
GET	`/api/news`	ดึงรายการบทความข่าวเดี่ยว กรองหมวด สำนักข่าว และค้นหา	ผู้อ่านทั่วไป
GET	`/api/news/content`	สกัดเนื้อหาบทความฉบับเต็ม Cleaned Markdown สำหรับสังเคราะห์สรุปและพรีวิว	ผู้อ่านทั่วไป
GET	`/api/categories`	ดึงรายชื่อ 9 หมวดหมู่ข่าวภาษาไทยพร้อมชุดสีประจำหมวด	ผู้อ่านทั่วไป
GET	`/api/sources`	ดึงรายชื่อสำนักข่าวทั้งหมดที่ลงทะเบียนและเปิดใช้งาน	ผู้อ่านทั่วไป
GET	`/api/status`	ตรวจสอบสถานะรอบเวลาสเกรปและจำนวนข่าวสะสมในระบบ	ผู้อ่านทั่วไป
GET	`/api/image`	บริการ Reverse Proxy และแคชรูปภาพหน้าปกบทความ	ผู้อ่านทั่วไป

ตารางที่ 23 เส้นทางของส่วนเชื่อมต่อโปรแกรมประยุกต์ (ต่อ)

เมธอด	**เส้นทาง (Route)**	**การทำงานและวัตถุประสงค์**	**สิทธิ์การเข้าถึง**
POST	`/api/collect-md`	นำเข้า URL ข่าวเดี่ยวเพื่อสกัดเนื้อหาและจำแนกหมวดทันที	ผู้อ่านทั่วไป
POST	`/api/news/engage`	บันทึกสถิติการมีส่วนร่วมแบบนิรนาม (คลิก, สรุป, บุ๊กมาร์ก)	ผู้อ่านทั่วไป
POST	`/api/monitoring/auth`	ตรวจสอบรหัสผ่านลับผู้ดูแลระบบและออก Bearer Token	ผู้ดูแลระบบ
GET	`/api/monitoring/verify`	ตรวจสอบความถูกต้องของโทเค็นเซสชันผู้ดูแลระบบ	ผู้ดูแลระบบ
GET	`/api/monitoring/stats`	ตรวจสอบสถิติ Throughput การใช้ RAM และสถานะแคช	ผู้ดูแลระบบ
POST	`/api/monitoring/scrape-now`	สั่งเริ่มรอบการดึงข่าวจากทุกสำนักในเบื้องหลังทันที	ผู้ดูแลระบบ
POST	`/api/monitoring/clear-cache`	สั่งล้างข้อมูลในแคชหน่วยความจำ L1 และแคช HTTP	ผู้ดูแลระบบ
POST	`/api/monitoring/test-source`	ทดสอบการเชื่อมต่อและดึงข่าวเฉพาะสำนักข่าวที่ระบุ	ผู้ดูแลระบบ
GET	`/livez` และ `/readyz`	โพรบตรวจสอบความพร้อมและสถานะการทำงานของเซิร์ฟเวอร์	สาธารณะ

ตารางที่ 24 รหัสสถานะ HTTP ที่ระบบใช้

รหัส	**ชื่อสถานะ (HTTP Status)**	**เงื่อนไขการส่งคืนในระบบ**
200	OK	คำขอสำเร็จและส่งคืนข้อมูลผลลัพธ์ในรูปแบบ JSON
201	Created	สร้างทรัพยากรใหม่สำเร็จ (เช่น การลงทะเบียนหรือบันทึกประเด็น)
204	No Content	คำขอสำเร็จแต่ไม่มีข้อมูลส่งกลับ (เช่น การส่งสถิติการมีส่วนร่วม)
304	Not Modified	ข้อมูลในแคชของผู้ใช้ยังเป็นปัจจุบัน ไม่มีการส่งข้อมูลซ้ำผ่าน ETag
400	Bad Request	รูปแบบคำขอไม่ถูกต้อง เช่น พารามิเตอร์ขาดหายหรือไม่ตรงตามเงื่อนไข
401	Unauthorized	ขาดโทเค็นยืนยันตัวตนหรือรหัสผ่านผู้ดูแลระบบไม่ถูกต้อง
403	Forbidden	ไม่มีสิทธิ์เข้าถึงทรัพยากรที่ร้องขอ
404	Not Found	ไม่พบข้อมูลทรัพยากรที่ระบุ (เช่น ไม่พบข่าวหรือประเด็นที่ระบุ ID)
422	Unprocessable Entity	ข้อมูลนำเข้าไม่ผ่านกฎการตรวจสอบความถูกต้องของ Pydantic Schema
429	Too Many Requests	ส่งคำขอเกินอัตราที่ระบบจำกัดไว้ (Rate Limiting Exceeded)
500	Internal Server Error	เกิดข้อผิดพลาดที่ไม่คาดคิดในการประมวลผลภายในเซิร์ฟเวอร์
502	Bad Gateway	เซิร์ฟเวอร์ต้นทางหรือบริการภาพข่าวภายนอกไม่ตอบสนอง
503	Service Unavailable	เซิร์ฟเวอร์ยังไม่พร้อมให้บริการหรืออยู่ในระหว่างการเริ่มต้นระบบ

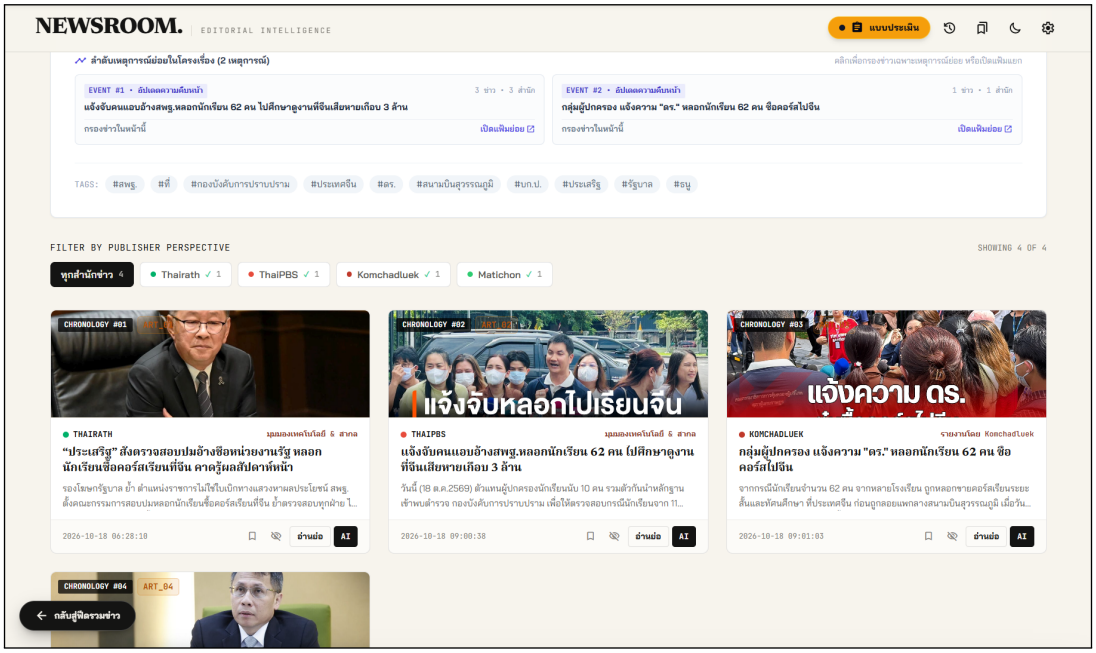
4.2.6 ต้นแบบส่วนติดต่อกับผู้ใช้

ส่วนต่อประสานผู้ใช้ได้รับการออกแบบตามแนวคิด Responsive Single Page Application โดยมีต้นแบบหน้าจอ 6 รูปแบบหลัก (M-01 ถึง M-06) ดังแสดงในตารางที่ 25

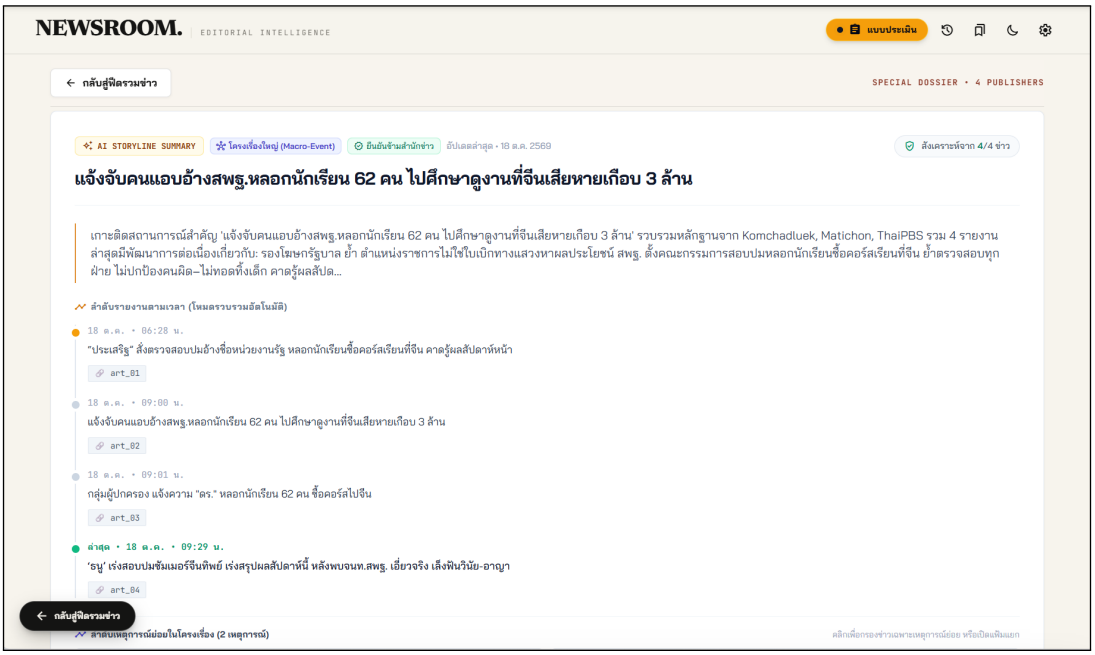
ตารางที่ 25 รายการต้นแบบหน้าจอ

รหัส	ชื่อหน้าจอ	ผู้ใช้งาน	ส่วนประกอบหลักและหน้าที่การทำงาน
M-01	Bento Hub SPA (หน้าหลักสำรวจข่าว)	ผู้อ่านทั่วไป	แถบข่าวเด่นประจำวัน บัตรสรุปข่าว 3 มุมมอง แถบแฮชแท็ก แถบเลือก 9 หมวดหมู่ ปุ่มคัดกรองสำนักข่าว และแบนเนอร์ข่าวใหม่ลอยตัว
M-02	In-App Cleaned Reader (หน้าต่างพรีวิวบทความ)	ผู้อ่านทั่วไป	หน้าต่างโมดอลพรีวิวเนื้อหาข่าวบางส่วนเพื่อความปลอดภัยด้านลิขสิทธิ์ ลิงก์ต้นฉบับ แผงสรุปผู้บริหารที่สังเคราะห์จากเนื้อหาฉบับเต็มด้วย AI ค่าอารมณ์ข่าว และปุ่มบันทึกคั่นหน้า
M-03	Macro Storyline Dossier (แฟ้มเจาะลึกมหากาพย์)	ผู้อ่านทั่วไป	แฟ้มเจาะลึกประเด็นข่าวมหาภาค ไทม์ไลน์พัฒนาการเหตุการณ์ตามเวลาจริง ตารางหลักฐานยืนยันข้ามสำนักข่าว และรหัสอ้างอิงรายประโยค
M-04	Issue Explorer Workstation (สถานีเจาะประเด็นข่าว)	ผู้อ่านทั่วไป นักวิเคราะห์	แถบค้นหาบูลีนขั้นสูง แถบแจกแจงมุมมองสื่อ ตารางวิเคราะห์มิติประเด็นข่าว และตัวกรองคัดแยกข่าวหลุดประเด็น
M-05	Ops Monitoring Console (ศูนย์ควบคุมสถานะ)	ผู้ดูแลระบบ	ฟอร์มยืนยันตัวตน แดชบอร์ด Throughput สถิติ RAM สถานะแคช ปุ่มสั่งเริ่มสเกรปข่าวด่วน ปุ่มสั่งล้างแคช และตัวทดสอบสำนักข่าว
M-06	Privacy & Cookie Modal (ตั้งค่าความเป็นส่วนตัว)	ผู้อ่านทั่วไป	แถบขอความยินยอมคุกกี้ หน้าต่างตั้งค่าสิทธิ์ความเป็นส่วนตัวตามมาตรฐาน PDPA และปุ่มลบสถิติความสนใจออกจากเบราว์เซอร์
M-07	Personal Briefing Modal (ปรับแต่งฟีดเฉพาะคุณ)	ผู้อ่านทั่วไป	หน้าต่างเลือกอย่างน้อย 3 หมวดหมู่สนใจเพื่อสร้างฟีดเฉพาะบุคคล และจัดอันดับข่าวบนเบราว์เซอร์แบบ Edge ไม่ส่งข้อมูลส่วนตัวกลับเซิร์ฟเวอร์

ตัวอย่างหน้าจอจริงของระบบในส่วนแฟ้มเจาะลึกมหากาพย์ประเด็นข่าว (Stage B Hardened Storyline Bento Hub) แสดงดังภาพที่ 11 และแฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาแสดงดังภาพที่ 12



ภาพที่ 11 หน้าต่างแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่ยับยั้งการรวมกลุ่มข้ามเรื่อง



ภาพที่ 12 แฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาและข้อเท็จจริง

4.2.7 การออกแบบและมาตรการความปลอดภัยของระบบ

ความมั่นคงปลอดภัยของระบบและการคุ้มครองข้อมูลส่วนบุคคลได้รับการออกแบบครอบคลุม 4 มิติหลัก เพื่อป้องกันภัยคุกคามทางไซเบอร์ตามมาตรฐานสากล

(1) ความปลอดภัยระดับเครือข่ายและเว็บเซิร์ฟเวอร์

ในระดับเครือข่าย Nginx Reverse Proxy ทำหน้าที่เป็นเกตเวย์ด่านหน้า จัดการเข้ารหัสการสื่อสารผ่าน TLS/SSL ทั้งในรูปแบบ HTTPS และ Secure WebSocket (WSS) พร้อมทั้งกำหนดนโยบายจำกัดอัตราคำขอ (Rate Limiting) เพื่อป้องกันการโจมตีแบบ DoS นอกจากนี้ยังติดตั้ง CORS Whitelist เฉพาะโดเมนที่ได้รับอนุญาต และติดตั้งส่วนหัวความปลอดภัย HTTP Security Headers ได้แก่ `X-Content-Type-Options` (ค่า nosniff), `X-Frame-Options` (ค่า SAMEORIGIN), และ `Content-Security-Policy` ป้องกันการโจมตีแบบ Clickjacking และ MIME Confusion

(2) การป้องกันโค้ดอันตรายและการตรวจสอบข้อมูล

เพื่อป้องกันการโจมตีแบบ Cross-Site Scripting (XSS) ข้อมูลข่าวที่สกัดจากภายนอกจะผ่านกระบวนการ Sanitization กำจัดแท็ก `<script>`, `<iframe>` และแอตทริบิวต์อันตรายออกทั้งหมด แปลงเนื้อหาให้อยู่ในรูป Clean Markdown บริสุทธิ์ก่อนส่งไปแสดงผล พร้อมทั้งบังคับใช้การตรวจสอบโครงสร้างข้อมูลเข้มงวดด้วย Pydantic ในทุกจุดรับเข้าและส่งออกของ REST API สำหรับการป้องกัน Server-Side Request Forgery (SSRF) บริการสเกรปเปอร์จะดึงข้อมูลเฉพาะจากสำนักข่าวที่ลงทะเบียนไว้ล่วงหน้า (Source Whitelist) เท่านั้น และในส่วนของโมเดลภาษา มีการกำหนด Prompt Delimiter รัดกุมเพื่อป้องกัน Indirect Prompt Injection

(3) การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้

การคุ้มครองความเป็นส่วนตัวถูกออกแบบตามหลัก Zero-PII กล่าวคือ ระบบไม่มีการจัดเก็บข้อมูลส่วนบุคคลที่สามารถระบุตัวตนได้ (ไม่มีการเก็บชื่อ ที่อยู่อีเมล หรือเลขไอพี) ข้อมูลการมีส่วนร่วมจะถูกบันทึกเป็นเพียงคะแนนรวมแบบนิรนาม ในระดับเบราว์เซอร์ คุกกี้ถูกกำหนดคุณสมบัติความปลอดภัย `SameSite=Lax` ป้องกัน CSRF พร้อมทั้งมีแถบแจ้งเตือนขอความยินยอมตามมาตรฐาน PDPA และมีปุ่มให้ผู้ใช้กดล้างข้อมูลความสนใจออกจากเบราว์เซอร์ได้ตลอดเวลา

(4) การจัดการความลับและการตั้งค่าระบบ

รหัสลับและคีย์เชื่อมต่อบริการภายนอก เช่น `LLM_API` ถูกจัดเก็บไว้ในไฟล์ `.env` และ Environment Variables ที่แยกต่างหาก โดยมีไฟล์ `.gitignore` ป้องกันการนำความลับของระบบขึ้นสู่ระบบควบคุมเวอร์ชัน Git อย่างเข้มงวด

4.3 การพัฒนาโปรแกรม

ในส่วนการพัฒนาโปรแกรม (Program Implementation) จะอธิบายถึงภาษา เครื่องมือ โครงสร้างโฟลเดอร์และรายละเอียดการทำงานของโมดูลหลักต่าง ๆ ที่ได้สร้างขึ้นจริงในระบบ

4.3.1 ภาษาและไลบรารีหลักที่ใช้ในการพัฒนา

ระบบได้รับการพัฒนาขึ้นโดยใช้ภาษา Python สำหรับส่วนหลัง (Backend) และภาษา JavaScript ES Modules ร่วมกับ Tailwind CSS สำหรับส่วนหน้า (Frontend) โดยมีไลบรารีหลักที่ใช้แสดงดังตารางที่ 26

ตารางที่ 26 ไลบรารีหลักที่ใช้ในการพัฒนา

ส่วนงาน	ไลบรารี / เครื่องมือ	เวอร์ชัน	วัตถุประสงค์และการใช้งาน
Backend Web	FastAPI	0.110+	เว็บเฟรมเวิร์คประสิทธิภาพสูงสำหรับสร้าง REST API แบบ Asynchronous
Backend Web	Uvicorn	0.28+	ASGI Web Server มาตรฐานสำหรับรัน FastAPI
Real-time	Python-SocketIO	5.11+	ไลบรารีจัดการการสื่อสารสองทิศทางแบบเรียลไทม์ผ่าน WebSocket
Data Validation	Pydantic	2.6+	โมเดลตรวจสอบความถูกต้องและจัดโครงสร้างข้อมูลแบบเข้มงวด
Web Scraping	Playwright	1.42+	โปรแกรมควบคุม Headless Chromium สำหรับดึงหน้าเว็บ JavaScript
Content Extraction	Trafilatura	1.8+	สกัดข้อความหลักบทความข่าว ขจัดโฆษณาและแท็กส่วนเกิน
Thai NLP	PyThaiNLP	5.0+	ตัดคำภาษาไทย (`newmm`) และสกัดเอนทิตีชื่อเฉพาะ (`thainer-v2`)
Deep Learning	Transformers	4.38+	โมเดลภาษา WangchanBERTa สำหรับสกัดเวกเตอร์ความหมาย 768 มิติ
Machine Learning	Scikit-learn [8]	1.4+	เวกเตอร์ TF-IDF และโมเดลจำแนกประเภท LinearSVC
Database	Aiosqlite	0.20+	ตัวเชื่อมต่อฐานข้อมูล SQLite แบบ Asynchronous รองรับโหมด WAL
Frontend Core	Vanilla JS (ESM)	ES2022	สคริปต์ส่วนติดต่อผู้ใช้แบบโมดูลแยกอิสระ ปราศจากเฟรมเวิร์คหน่วง
Frontend Style	Tailwind CSS	3.4+	ยูทิลิตีเฟรมเวิร์คสำหรับจัดรูปแบบส่วนต่อประสาน Responsive

4.3.2 โครงสร้างของโปรแกรม

โครงสร้างโฟลเดอร์และแฟ้มข้อมูลของระบบได้รับการจัดระเบียบตามหลักสถาปัตยกรรมแบบแยกชั้นความรับผิดชอบ ดังแสดงในตารางที่ 27

ตารางที่ 27 โครงสร้างโฟลเดอร์หลักของโปรแกรม

โฟลเดอร์ / เส้นทาง	หน้าที่และความรับผิดชอบของโมดูล
`backend/routers/`	รวบรวมตัวจัดการเส้นทาง REST API แยกตามโดเมน (`news`, `story`, `macro_event`, `trending`, `monitoring`)
`backend/services/`	บรรจุตรรกะทางธุรกิจหลัก (`ScraperService`, `StoryService`, `TrendingService`, `MacroEventService`, `StoryPresentationService`)
`backend/scrapers/`	สเกรปเปอร์เฉพาะแต่ละสำนักข่าว ลงทะเบียนผ่าน Decorator `@register_source` พร้อมฟังก์ชันสกัดเนื้อหา
`backend/repo/`	เลเยอร์การจัดเก็บข้อมูล รองรับทั้ง SQLite WAL (`SqliteNewsRepo`) และไฟล์ JSON (`StoryRepo`, `MacroEventRepo`)
`backend/core/`	โครงสร้างพื้นฐานส่วนกลาง (`BrowserService`, `SocketManager`, `L1Cache`, `AsyncInMemoryCache`)
`backend/schemas/`	โมเดลข้อมูล Pydantic สำหรับคำขอ คำตอบ และโครงสร้างข้อมูลภายในระบบ
`backend/tests/`	ชุดทดสอบอัตโนมัติบนเฟรมเวิร์ค pytest ครอบคลุม 423 กรณีทดสอบ
`frontend/static/`	ไฟล์สคริปต์ส่วนติดต่อผู้ใช้หลัก (`main.js`, `api.js`, `socket.js`, `config.js`, `app.css`)
`frontend/static/components/`	โมดูลส่วนติดต่อผู้ใช้ย่อยแยกอิสระ (`hero.js`, `cards.js`, `reader.js`, `storyline.js`, `sports.js`)
`docs/report/`	เอกสารรายงานโครงงานฉบับสมบูรณ์ตามมาตรฐานวิทยาลัยการคอมพิวเตอร์

4.3.3 ข้อกำหนดเฉพาะของแต่ละโมดูลและการทำงานของส่วนประกอบหลัก

ในส่วนนี้จะอธิบายถึงรายละเอียดทางวิศวกรรมของส่วนประกอบหลักสำคัญทั้ง 11 ส่วนของระบบ

(1) กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)

ระบบสเกรปข่าวถูกออกแบบให้ทำงานแบบ Asynchronous ทั้งหมด โดยในแต่ละรอบการทำงาน `ScraperService` จะสร้าง Task สำหรับแต่ละแหล่งข่าวเพื่อดึงข้อมูลพร้อมกัน (Concurrent Scraping) ร่วมกับ `BrowserService` ที่ควบคุม Playwright Chromium Headless ดึงข้อมูลจากสำนักข่าวที่ลงทะเบียนไว้ผ่านฟังก์ชัน Decorator (`@register_source`) เพื่อรองรับทั้งเว็บไซต์แบบสถิตและเว็บไซต์ที่เรนเดอร์เนื้อหาด้วย JavaScript โดยมีระบบตรวจสอบ URL ซ้ำในหน่วยความจำและ SQLite ผ่านตาราง `seen_urls` เพื่อป้องกันการดาวน์โหลดซ้ำซ้อน

(2) ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)

โมดูล `ClassifierService` ประยุกต์ใช้เทคนิค 3-Tier Cascade Classifier โดยเริ่มจากกฎคำสำคัญ (Keyword Rules) ร่วมกับพจนานุกรมเฉพาะทางของ PyThaiNLP หากคะแนนความเชื่อมั่นไม่ผ่าน

เกณฑ์ จะส่งต่อไปยังเวกเตอร์ TF-IDF ร่วมกับ LinearSVC และมีโมเดลเชิงลึก WangchanBERTa รองรับบริบทที่ซับซ้อน ครอบคลุมการจำแนกข่าวออกเป็น 9 หมวดหมู่อย่างแม่นยำ

(3) ระบบเปิดอ่านพรีวิวบทความในตัวเว็บ (In-App Reader) และการคำนึงถึงประเด็นด้านลิขสิทธิ์

เมื่อผู้ใช้คลิกเปิดอ่านข่าว ระบบจะแสดงผลหน้าต่างโมดอล In-App Reader เพื่อให้ผู้อ่านดูพรีวิวเนื้อหาข่าวบางส่วน (Partial Cleaned Excerpt) ที่ผ่านการทำความสะอาดด้วย Trafilatura เพื่อตัดป้ายโฆษณา สคริปต์ และลิงก์สแปม โดยระบบยึดนโยบายการคุ้มครองลิขสิทธิ์ของสำนักข่าวต้นทาง (Copyright Protection Compliance) ไม่นำเนื้อหาบทความฉบับเต็มมาเผยแพร่ซ้ำบนระบบทั้งหมด แต่จัดเตรียมปุ่มลิงก์เชื่อมต่อไปยังเว็บไซต์ผู้ผลิตข่าวต้นฉบับโดยตรง ในขณะที่การกดปุ่มสร้างบทสรุปด้วยปัญญาประดิษฐ์ โมเดลภาษาขนาดใหญ่ (LLM) จะนำเนื้อหาบทความฉบับเต็มทั้งหมด (Whole Article Content) ในเบื้องหลังมาทำการสังเคราะห์ (Synthesize) คัดแยกประเด็นสำคัญ และประเมินอารมณ์ของข่าว เพื่อให้บทสรุปมีความครบถ้วนและแม่นยำสูงสุด

(4) ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)

ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้กับ KKU Gen.AI API โดยออกแบบ Prompt กำหนดโครงสร้างส่งคืนเป็น JSON ประกอบด้วย บทสรุปย่อ 2–3 ประโยค ประเด็นสำคัญ 3–5 ข้อ และการวิเคราะห์อารมณ์ (Sentiment) พร้อมทั้งมีกลไกสำรอง (Heuristic Fallback) สกัดพาดหัวและย่อหน้าแรกโดยอัตโนมัติหากบริการภายนอกไม่ตอบสนอง ตัวอย่างการแสดงผลบัตรบทสังเคราะห์ประเด็นสำคัญและประเด็นย่อย (Key Takeaways) จากโมเดลภาษาขนาดใหญ่แสดงดังภาพที่ 13



ภาพที่ 13 ผลลัพธ์การสรุปเนื้อหาข่าวสารและวิเคราะห์อารมณ์ด้วยโมเดลภาษา

(5) สถาปัตยกรรมระบุประเด็นข่าวและจัดอันดับกระแสข่าวแบบสองชั้น

เพื่อแก้ไขข้อจำกัดของระบบเดิมที่คำนวณการจัดกลุ่มข่าวแบบชั่วคราว (Ad-hoc Clustering) ซึ่งจำกัดกรอบเวลาไว้เพียง 36–48 ชั่วโมงจนทำให้ข่าวยืดเยื้อแตกกระจาย และต้องพึ่ง LLM ในการประมวลผล

อันดับข่าว ระบบได้ปรับปรุงสถาปัตยกรรมใหม่เป็นแบบสองชั้นที่แยกหน้าที่กันอย่างชัดเจนตามหลักการวิศวกรรมซอฟต์แวร์ ได้แก่ ชั้นที่ 1 การระบุและติดตามประเด็นข่าวแบบออนไลน์คงทน (`StoryService`) และชั้นที่ 2 เอนจินจัดอันดับกระแสข่าวเชิงสถิติแน่นอน (`TrendingService`)

ขั้นตอนแรกคือ การสกัดเวกเตอร์เชิงความหมาย (Dense Semantic Embeddings) โดยนำข้อความพาดหัวข่าวร่วมกับเนื้อหาย่อแปลงเป็นเวกเตอร์ขนาด 768 มิติด้วยโมเดล WangchanBERTa ผ่านการรวมแบบเฉลี่ยถ่วงน้ำหนัก (Masked Mean Pooling) และปรับให้เป็นเวกเตอร์หนึ่งหน่วย (L_2 Normalization) ทำให้ผลคูณจุด (Dot Product) มีค่าเท่ากับค่าความคล้ายคลึงโคไซน์ (Cosine Similarity) พร้อมทั้งมีระบบแคชระดับ L1 ป้องกันการเข้ารหัสข้อความซ้ำซ้อน

ขั้นตอนที่สองคือ การประเมินด้วยเกณฑ์ร่วมแบบไฮบริด (Two-Band Gate with Typed NER) ซึ่งแบ่งการตัดสินใจออกเป็น 3 แถบ ได้แก่ ข่าวที่มีความคล้ายคลึง ≥ 0.82 จะถูกรวมกลุ่มทันที, ข่าวที่มีความคล้ายคลึงระหว่าง $.72-- .82$ จะต้องผ่านการยืนยันว่ามีเอนทิตีชื่อเฉพาะตรงกันอย่างน้อย 1 ตัวละคร (`actor_names`) และข่าวที่มีความคล้ายคลึง < 0.72 จะถูกแยกเป็นประเด็นใหม่

ขั้นตอนที่สามคือ การสืบค้นกลุ่มข่าวผ่านหน้าต่างเวลา 72 ชั่วโมงแบบไม่ปิดกั้นเวลาหมดอายุ (Non-capping 72-Hour Candidate Window) โดยระบบจะค้นหากลุ่มประเด็นข่าว (`StoryRecord`) ที่มีข่าวอัปเดตล่าสุดภายใน 72 ชั่วโมงก่อนเวลาของบทความใหม่ ซึ่งการกำหนดหน้าต่างเวลานี้ช่วยควบคุมขอบเขตความซับซ้อนในการคำนวณโดยไม่จำกัดอายุขัยของประเด็นข่าว ทำให้เหตุการณ์วิกฤตที่ยืดเยื้อ เช่น อุทกภัย สามารถติดตามและผูกโยงข่าวใหม่เข้ากับประเด็นเดิมได้อย่างต่อเนื่องข้ามสัปดาห์ พร้อมปรับปรุงเวกเตอร์ศูนย์กลางกลุ่ม (Centroid) แบบ Exponential Moving Average (EMA) โดยกำหนดค่าน้ำหนัก $\alpha = 0.85$ ช่วยรักษาเสถียรภาพของแกนเรื่องเดิมไม่ให้เบี่ยงเบนเร็วเกินไป พร้อมทั้งปรับตัวรองรับพัฒนาการใหม่ของข่าวได้อย่างยืดหยุ่น นอกจากนี้กลุ่มประเด็นข่าวจะได้จัดการวงจร (Lifecycle State) ระหว่างสถานะพร้อมทำงาน (`active`) เมื่อมีข่าวอัปเดตในรอบ 72 ชั่วโมง และสถานะพักตัว (`dormant`) เมื่อไม่มีความเคลื่อนไหวเกิน 72 ชั่วโมง เพื่อประหยัดทรัพยากรระบบ

ในส่วนของเอนจินจัดอันดับกระแสข่าวเชิงสถิติแน่นอน พัฒนาขึ้นเพื่อแก้ไขข้อจำกัดของแบบจำลองเดิม ได้แก่ ปัญหาข่าวประจำวันครองหน้าหนึ่ง (Routine News Dominance) ข่าวที่เป็นวงรอบ เช่น ผลสลากกินแบ่งรัฐบาล ราคาทองคำ และสภาพอากาศ ได้คะแนนสูงผิดปกติ บดบังข่าวด่วนสำคัญของสังคม และปัญหาสำนักพิมพ์ในเครือเดียวกัน (Syndication Duplication) ที่คัดลอกบทความส่งผลให้ค่าจำนวนสำนักข่าวสูงเกินจริงโดยไม่ได้สะท้อนความหลากหลายของสื่อจริง ระบบจึงตัดการพึ่งพาโมเดลภาษาขนาดใหญ่ (LLM) ออกจากเส้นทางการคำนวณคะแนนอย่างสิ้นเชิง (Zero LLM in scoring path) ทำให้การจัดอันดับมีความรวดเร็วระดับเสี้ยววินาทีและได้ผลลัพธ์ที่แน่นอนเชิงคณิตศาสตร์ (Deterministic) โดยคำนวณผ่าน 6 มิติเชิงสถิติร่วมกับตัวคูณลดทอนข่าวประจำวัน

(6) ส่วนนำเสนอและการสังเคราะห์เนื้อหาประเด็นรวม (Story Presentation)

สำหรับ กลุ่ม ประเด็น ข่าว ที่ ติด อันดับ กระแส ความ นิยม สูงสุด ระบบ จะ ส่ง ต่อ ข้อมูล ให้ `StoryPresentationService` เพื่อสร้างเนื้อหานำเสนอเชิงลึก โดยอาศัยโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) ในการสังเคราะห์พาดหัวข่าวประเด็นรวม (Macro Headline) ที่เป็นกลางและครอบคลุมทุกมุมมอง การสร้างบทสรุปย่อสังเคราะห์ข้ามสำนักข่าว (Multi-Article Synthesis) และการเรียบเรียงไทม์ไลน์พัฒนาการของ

เหตุการณ์ตามลำดับเวลา (Chronological Timeline Events) พร้อมลิงก์อ้างอิงกลับไปยังสำนักข่าวต้นทาง โดยผลลัพธ์ทั้งหมดจะถูกบันทึกแคชลงในฐานข้อมูลประเด็นข่าวโดยตรง เพื่อลดค่าใช้จ่ายในการเรียกใช้ API ซ้ำซ้อน และหากบริการ LLM ภายนอกขัดข้องหรือไม่ตอบสนอง ระบบมีกลไกสำรองการทำงานแบบอัตโนมัติ (Heuristic Fallback) โดยสลับไปใช้พาดหัวข่าวตัวแทนหลักและเรียบเรียงไทม์ไลน์ตามเวลาเผยแพร่จริง ทำให้ระบบสามารถตอบกลับคำขอด้วยสถานะ HTTP 200 ได้อย่างมีเสถียรภาพ

(7) การจัดกลุ่มประเด็นข่าวและ Bento Hub UI

เพื่อ ยก ระดับ การ ติดตาม ข่าวสาร ที่ มี มิติ ความ ซับ ซ้อน สูง ระบบ ได้ พัฒนา `MacroEventService` สำหรับเชื่อมโยงกลุ่มประเด็นข่าวย่อย (Sub-events) ที่มีความสัมพันธ์เชิงบริบทเข้าสู่ประเด็นข่าวขนาดใหญ่ (Macro Storyline) พร้อมทั้งรองรับข้อยกเว้นกรณีวิกฤต (Crisis Exemption) ที่ช่วยให้ข้อมูลภัยพิบัติหรือเหตุฉุกเฉินระดับชาติได้รับการยกเว้นการลดทอนเวลา โดยมีกลไกยับยั้งความขัดแย้งของระดับจังหวัด (Strict Province-Only Veto) ป้องกันการนำเหตุการณ์ต่างพื้นที่มาผูกรวมกัน

ในด้านส่วนต่อประสานผู้ใช้ หน้าแรกของระบบได้รับการออกแบบใหม่เป็น Macro Storyline Bento Hub ซึ่งจัดวางองค์ประกอบแบบ 3 มุมมองหลัก (3-Perspective Matrix) ได้แก่ แถบข่าวเด่นประจำวัน บัตรสรุปประเด็นข่าวพร้อมป้ายสำนักข่าวที่รายงานร่วมกัน (Publisher Filter Pills) และแถบแฮชแท็กเชิงโต้ตอบ (#Hashtags Ribbon) เพื่อให้ผู้ใช้งานสามารถคลิกสำรวจมุมมองที่หลากหลายของแต่ละสำนักข่าวได้อย่างสะดวก นอกจากนี้ ระบบยังได้จัดเตรียมหน้าต่างติดตามและศูนย์ควบคุมสถานะระบบ (`frontend/monitoring.html`) สำหรับผู้ดูแลระบบ เพื่อตรวจสอบอัตราการรับเข้าของข่าว การทำงานของแคช และความเสถียรของไปป์ไลน์แบบเรียลไทม์

(8) การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket

เมื่อมีข่าวใหม่เข้ามาสู่ระบบและผ่านการบันทึกสำเร็จ คลาส `SocketManager` จะกระจายเหตุการณ์ (`news_new`) ไปยังเบราว์เซอร์ของผู้ใช้ทุกคนที่เปิดหน้าเว็บอยู่แบบ Asynchronous ผลักดันให้แบนเนอร์แจ้งเตือนข่าวใหม่ปรากฏขึ้นทันทีโดยผู้ใช้ไม่ต้องรีเฟรชหน้าจอ

(9) ระบบเจาะประเด็นข่าวและค้นหาเชิงวิเคราะห์ (Issue Explorer Workstation)

ผลลัพธ์การสืบค้นจะถูกสังเคราะห์และนำเสนอในรูปแบบการทำงาน (Investigation Workstation) ประกอบด้วย 4 องค์ประกอบสำคัญ ได้แก่ แถบสรุปภาพรวมและสถิติประเด็นข่าว (Issue Executive Summary), ตารางแจกแจงมุมมองและสัดส่วนการนำเสนอของแต่ละสำนักข่าว (Publisher Perspective Breakdown) เพื่อแสดงให้เห็นว่าสื่อสำนักใดให้ความสนใจในมิติใดเป็นพิเศษ, ไทม์ไลน์ความเคลื่อนไหวของประเด็นตามลำดับเวลาจริง (Chronological Evolution Timeline) และรายการการ์ดข่าวสารที่จัดกลุ่มตามประเด็นย่อย (Issue Sub-clusters) โดยมีระบบคัดกรองข่าวหลุดประเด็น (Outlier Filtering) ช่วยแยกบทความที่ไม่เกี่ยวข้องออกไปอย่างแม่นยำ พร้อมทั้งมีระบบควบคุมอัตราคำขอแบบ Sliding Window IP Rate Limiting ช่วยรักษาความมั่นคงของเซิร์ฟเวอร์ โดยทำงานบนฐานข้อมูล SQLite ในโหมดอ่านอย่างเดียว (Read-Only `mode=ro`)

(10) ระบบปรับแต่งฟีดข่าวเฉพาะบุคคลและการประมวลผลบนอุปกรณ์ (Personal Briefing and Edge Personalization)

เพื่อตอบสนองต่อความต้องการติดตามข่าวสารเฉพาะบุคคลของผู้อ่านโดยไม่ละเมิดความเป็นส่วนตัว ระบบได้พัฒนาสถาปัตยกรรมจัดอันดับข่าวบนอุปกรณ์ของผู้ใช้ (On-Device Edge Personalization) ควบคู่กับหน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณ (Personal Briefing Onboarding) ดังแสดงในภาพที่ 14



ภาพที่ 14 หน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณสำหรับการสร้างฟีดตามความสนใจ

ระบบนี้มีหลักการทำงานทางวิศวกรรมที่สำคัญ 3 ประการ ได้แก่

ประการแรก สถาปัตยกรรมรักษาความเป็นส่วนตัวแบบไร้ข้อมูลระบุตัวตน (Zero-PII Privacy Architecture) โดยระบบจะไม่มีการส่งประวัติการอ่าน รายการข่าวที่บันทึก หรือความชื่นชอบของผู้ใช้กลับไปยังเซิร์ฟเวอร์ ข้อมูลการเลือกหมวดหมู่และค่าน้ำหนักความสนใจ (Affinity Scores) จะถูกจัดเก็บไว้ใน `LocalStorage` ของเบราว์เซอร์เท่านั้น และผู้ใช้สามารถกดล้างข้อมูลทั้งหมดทิ้งได้ตลอดเวลา

ประการที่สอง ขั้นตอนวิธีการคำนวณและจัดอันดับเนื้อหา (Client-Side Edge Ranking Algorithm) โดยเมื่อผู้ใช้เปิดหน้าฟีดสำหรับคุณ ฟังก์ชัน `rankForYou` จะดึงบทความข่าวล่าสุดและข่าวที่กำลังเป็นกระแสมาคำนวณคะแนนความเกี่ยวข้องสำหรับแต่ละบทความตามสมการที่ (6)

$$S_i = (1.2 \cdot C_i + 0.8 \cdot P_i + 0.35 \cdot K_i) \cdot 2^{-\frac{\Delta t_i}{18}} + B_{\text{trend}} \tag{6}$$

เมื่อ

- S_i คือ คะแนนความเกี่ยวข้องของบทความข่าวที่ i
- C_i คือ ค่าน้ำหนักความชื่นชอบในหมวดหมู่ของข่าว
- P_i คือ ค่าน้ำหนักความชื่นชอบในสำนักข่าว
- K_i คือ ค่าความคล้ายคลึงของคำสำคัญระหว่างบทความกับประวัติความสนใจของผู้ใช้
- Δt_i คือ อายุของข่าวในหน่วยชั่วโมง โดยลดทอนคะแนนแบบครึ่งชีวิต (Half-life 18 ชั่วโมง)
- B_{trend} คือ คะแนนโบนัสเพิ่มเติมกรณีที่ข่าวดังกล่าวติดอันดับกระแสนิยม ($B_{\text{trend}} = 3$)

พร้อมทั้งมีระบบคัดกรองข่าวที่อ่านแล้ว ข่าวที่สั่งซ่อน และกรองข่าวที่มีเนื้อหาซ้ำซ้อนหรือใกล้เคียงกัน (Near-Duplicate Filtering ด้วยค่าความคล้ายคลึงทางคำศัพท์ ≥ 0.55)

ประการที่สาม กลไกป้องกันปรากฏการณ์ห้องสะท้อนเสียง (Filter Bubble and Echo Chamber Mitigation) โดยระบบได้บังคับใช้กฎสัดส่วน Serendipity Discovery 80/20 แบ่งพื้นที่การแสดงผลร้อยละ 80

สำหรับข่าวที่ตรงกับความสนใจหลักของผู้ใช้ และสำรองพื้นที่อีกร้อยละ 20 สำหรับข่าวสดใหม่ที่อยู่นอกหมวดหมู่ความสนใจเดิม เพื่อเปิดรับมุมมองข่าวสารใหม่ ๆ และป้องกันการปิดกั้นการรับรู้ข้อมูลรอบด้าน

(11) การรักษาเสถียรภาพระดับโพรดักชันและการตรวจสอบก่อนส่งมอบ

ส่วนแรก การจัดการปัญหาความไม่เข้ากันของแคชบนเครือข่ายส่งมอบเนื้อหา (Edge & Client Cache Invalidation) ระบบได้กำหนดนโยบาย `NoCacheStaticFiles` บน FastAPI ส่งส่วนหัว `Cache-Control` ที่ระบุ `no-cache, must-revalidate` สำหรับไฟล์สคริปต์โมดูล JavaScript ทั้งหมด และเพิ่มตัวแปรระบุเวอร์ชัน (`?v=3.3.3`) กำกับท้ายการนำเข้าโมดูลย่อย (Sub-module Imports) ทุกไฟล์ พร้อมปรับปรุงการทำงานของ Service Worker ให้ล้างแคชเก่าทิ้งทันทีเมื่อตรวจพบเวอร์ชันใหม่ ช่วยป้องกันไม่ให้เบราว์เซอร์ของผู้ใช้ค้างที่ไฟล์สคริปต์เก่าอันเป็นสาเหตุของข้อผิดพลาดหน้าเว็บขาว

ส่วนที่สอง ตรวจสอบความพร้อมก่อนขึ้นโพรดักชันอัตโนมัติ (Automated Production Pre-flight Smoke Test Suite ผ่าน `scripts/preflight_test.py`) ทำหน้าที่ตรวจสอบความสมบูรณ์ 5 มิติ ได้แก่ ความพร้อมของระบบจัดเก็บข้อมูลผ่าน `/readyz`, การทำงานของเอนจินจัดอันดับเทรนด์, การทดสอบหน้าเว็บผ่าน Headless Chromium เพื่อยืนยันว่าไม่มีข้อผิดพลาดบน Console (Zero Console Error Invariant), การตรวจสอบสถานะการเชื่อมต่อ WebSocket สด และการตรวจสอบส่วนหัว Cache-Control รวมถึงความพร้อมของระบบเจาะประเด็นข่าว ก่อนเปิดให้ผู้ใช้ภายนอกเข้าใช้งานจริง

4.3.4 การติดต่อกับฐานข้อมูลและบริการภายนอก

ระบบติดต่อสื่อสารกับหน่วยจัดเก็บข้อมูลและบริการภายนอกอย่างรัดกุม โดยการเข้าถึงฐานข้อมูล SQLite ทำงานผ่าน `aiosqlite` ในโหมด Write-Ahead Logging (WAL) ช่วยให้อ่านและเขียนข้อมูลพร้อมกันได้โดยไม่เกิดข้อผิดพลาดฐานข้อมูลถูกล็อก ในขณะที่คลังไฟล์ JSON ทำงานผ่านระบบล็อกไฟล์ข้ามโพรเซส (`InterProcessFileLock`) เพื่อรักษาความสอดคล้อง สำหรับการติดต่อ KKU Gen.AI API ใช้โพรโทคอล HTTPS TLS 1.3 มีการจำกัดเวลา Timeout และวงจรตัดการทำงานฉุกเฉิน (Circuit Breaker)

4.3.5 การช่วยเหลือในโปรแกรม

ส่วนต่อประสานผู้ใช้ได้รับการติดตั้งองค์ประกอบช่วยเหลือ (In-App Guidance) อย่างครบถ้วน ได้แก่ ป้ายข้อความอธิบายการใช้งาน (Tooltips) ประจำปุ่มควบคุมทุกปุ่ม, ป้ายสถานะระบุแหล่งข่าวและหมวดหมู่ด้วยคู่สีมาตรฐาน, หน้าต่างแนะนำการใช้งานระบบในครั้งแรก, และการแสดงผลสถานะว่างเปล่า (Empty States) พร้อมข้อความแนะนำที่ชัดเจนเมื่อไม่พบผลลัพธ์จากการค้นหาหรือการกรอง

4.4 การทดสอบระบบ

การรับประกันคุณภาพและความน่าเชื่อถือของระบบ (Quality Assurance & Reliability) เป็นหัวใจสำคัญในการพัฒนาระบบรวบรวมและวิเคราะห์ข่าวสารอัตโนมัติ ซึ่งต้องทำงานต่อเนื่องตลอดเวลา 24 ชั่วโมงและประมวลผลข้อมูลที่มีความผันผวนสูง คณะผู้พัฒนาจึงได้ประยุกต์ใช้ระเบียบวิธีพัฒนาที่ขับเคลื่อนด้วยการทดสอบ (Test-Driven Development หรือ TDD) และสร้างชุดทดสอบอัตโนมัติที่ครอบคลุมทุกมิติทางวิศวกรรม

4.4.1 วิธีการทดสอบและสภาพแวดล้อม

การทดสอบระบบแบ่งออกเป็น 3 ระดับหลัก ได้แก่ การทดสอบระดับหน่วย (Unit Testing), การทดสอบการทำงานร่วมกัน (Integration Testing), และการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing

หรือ UAT) โดยดำเนินการทดสอบบนสภาพแวดล้อมการพัฒนาจริง (Windows 11, Intel Core Ultra 5, RAM 16 GB, Python 3.11) และสภาพแวดล้อมจำลองโพรดักชันคอนเทนเนอร์ (Ubuntu 22.04 LTS บน AWS EC2) ผ่านเฟรมเวิร์ค `pytest`

4.4.2 ผลการทดสอบการยอมรับของผู้ใช้

ผลการทดสอบการยอมรับของผู้ใช้ตามความต้องการเชิงฟังก์ชันครบทั้ง 15 ข้อกำหนด (FR-01 ถึง FR-15) แสดงดังตารางที่ 28 โดยทุกกรณีทดสอบผ่านเกณฑ์ความสมบูรณ์ร้อยละ 100

ตารางที่ 28 ผลการทดสอบการยอมรับของผู้ใช้

รหัสทดสอบ	FR	รายการทดสอบ	ผลที่คาดหวัง	ผลการทดสอบ
TC-01	FR-01	การดึงข่าวอัตโนมัติหลายสำนัก	ดึงหัวข้อ ลิงก์ รูปภาพ และเนื้อหาได้ครบถ้วน	ผ่าน
TC-02	FR-02	การลงทะเบียนแหล่งข่าวแบบไดนามิก	เพิ่มสำนักข่าวใหม่ผ่าน Decorator ได้ทันที	ผ่าน
TC-03	FR-03	การจำแนก 9 หมวดหมู่ภาษาไทย	จำแนกหมวดหมู่ข่าวได้อย่างถูกต้องแม่นยำ	ผ่าน
TC-04	FR-04	การสรุปข่าวและวิเคราะห์อารมณ์	ได้บทสรุป ประเด็นสำคัญ และค่าอารมณ์ข่าว	ผ่าน
TC-05	FR-05	การแสดงผลข่าวสดบน Bento Hub	ข่าวใหม่ปรากฏบนหน้าจอสดผ่าน WebSocket	ผ่าน
TC-06	FR-06	การกรองข่าวและการสืบค้นคำสำคัญ	กรองข่าวตามหมวด สำนักพิมพ์ และคำค้นหา	ผ่าน
TC-07	FR-07	การอ่านพรีวิวเนื้อหาในตัวเว็บ	เปิดพรีวิวเนื้อหาบางส่วนและสังเคราะห์สรุป AI ได้ราบรื่น	ผ่าน
TC-08	FR-08	การบันทึกคั่นหน้าและประวัติการอ่าน	บันทึกและเรียกดูประวัติในเบราว์เซอร์ได้	ผ่าน
TC-09	FR-09	การระบุประเด็นข่าวออนไลน์ 2 ชั้น	รวมข่าวเหตุการณ์เดียวกันข้ามวันไม่แตกกลุ่ม	ผ่าน
TC-10	FR-10	การจัดอันดับกระแสข่าวสาร 6 มิติ	คำนวณคะแนนโปร่งใส ไร้ LLM ลดทอนข่าวประจำวัน	ผ่าน
TC-11	FR-11	การเชื่อมโยงเส้นเรื่องมหาภาค	เชื่อมโยงไทม์ไลน์มหากาพย์ยับยั้งด้วย Province Veto	ผ่าน
TC-12	FR-12	แฟ้มสังเคราะห์ไทม์ไลน์และข้อเท็จจริง	สังเคราะห์ไทม์ไลน์และข้อเท็จจริงยืนยันถูกต้อง	ผ่าน
TC-13	FR-13	กลไกควบคุมความถูกต้อง 3 ระดับ	กรองข่าวไม่เกี่ยวข้องและสลับโหมดสังเคราะห์ถูกต้อง	ผ่าน
TC-14	FR-14	ศูนย์ควบคุมสถานะและการล้างแคช	คอนโซลแสดงสถิติ สั่งสเกรปด่วน และล้างแคชสำเร็จ	ผ่าน
TC-15	FR-15	การคุ้มครองข้อมูลส่วนบุคคล PDPA	ประมวลผลแบบนิรนาม มีแถบยินยอม และล้างข้อมูลได้	ผ่าน

4.4.3 รายละเอียดกรณีทดสอบที่สำคัญ

เพื่อแสดงถึงระเบียบวิธีทดสอบเชิงลึก ในหัวข้อนี้ขอนำเสนอรายละเอียดกรณีทดสอบสำคัญ 2 กรณี ได้แก่ TC-09 การระบุประเด็นข่าวออนไลน์แบบคงทน (ตารางที่ 29) และ TC-12 การสังเคราะห์ความคืบหน้าจากหลักฐานแท้จริง (ตารางที่ 30)

ตารางที่ 29 กรณีทดสอบ TC-09 การระบุประเด็นข่าวออนไลน์ 2 ชั้น

หัวข้อ	**รายละเอียด**
รหัสกรณีทดสอบ	TC-09
ความต้องการที่เกี่ยวข้อง	FR-09
วัตถุประสงค์	เพื่อตรวจสอบความถูกต้องของเกณฑ์ตัดสินใจ Two-Band Cosine Decision Gate และการปรับปรุง Centroid EMA
เงื่อนไขก่อนเริ่ม	ระบบมีกลุ่มประเด็นข่าวเดิมบันทึกอยู่ในฐานข้อมูล และโมเดล WangchanBERTa โหลดพร้อมใช้งาน
ข้อมูลทดสอบ	ชุดบทความข่าวทดสอบที่มีค่าความคล้ายคลึงโคไซน์หลากหลายระดับ และบทความข่าวยืดเยื้อข้าม 5 วัน
ขั้นตอนการทดสอบ	1. ส่งบทความข่าวที่มีค่าความคล้ายคลึง $\cos \geq 0.85$ เข้าสู่ระบบ 2. ตรวจสอบว่าระบบจัดบทความเข้าสู่กลุ่มประเด็นเดิมแบบ Direct Merge หรือไม่ 3. ส่งบทความที่มีค่าความคล้ายคลึง $0.74 \leq \cos < 0.85$ ที่มีเอนทิตีตรงกันอย่างน้อย 1 รายการเข้าสู่ระบบ 4. ตรวจสอบว่าระบบจัดบทความเข้าสู่กลุ่มเดิมแบบ Confirmed Merge พร้อมปรับ Centroid หรือไม่ 5. ส่งบทความที่มีค่าความคล้ายคลึง $\cos < 0.74$ เข้าสู่ระบบ และตรวจสอบการสร้างกลุ่มประเด็นใหม่
ผลที่คาดหวัง	บทความที่มีความคล้ายคลึงสูงจะถูกรวมเข้ากลุ่มเดิม จุดศูนย์กลางได้รับการปรับปรุงด้วย EMA และข่าวต่างเรื่องจะสร้างกลุ่มใหม่
ผลการทดสอบจริง	ระบบจัดกลุ่มบทความข่าวได้อย่างถูกต้องครบถ้วนตามเกณฑ์ Two-Band Gate ร้อยละ 100
สถานะการทดสอบ	ผ่าน (Pass)

ตารางที่ 30 กรณีทดสอบ TC-12 การสังเคราะห์ความคืบหน้าจากหลักฐานแท้จริง

หัวข้อ	**รายละเอียด**
รหัสกรณีทดสอบ	TC-12
ความต้องการที่เกี่ยวข้อง	FR-12, FR-13
วัตถุประสงค์	เพื่อตรวจสอบการทำงานของเกตคัดกรอง 3 ชั้น และการจัดสรรโหมดสังเคราะห์ที่มีหลักฐานยืนยัน
เงื่อนไขก่อนเริ่ม	มีมหากาพย์ประเด็นข่าวบันทึกอยู่ในระบบ และมีการเชื่อมต่อกับบริการ KKU Gen.AI API
ข้อมูลทดสอบ	ชุดบทความข่าวผู้สมัครที่มีทั้งข่าวตรงประเด็น ข่าวไม่เกี่ยวข้อง และข่าวที่มีข้อมูลขัดแย้งกัน
ขั้นตอนการทดสอบ	1. ส่งชุดข่าวผู้สมัครเข้าสู่เกตคัดกรองความถูกต้อง 3 ชั้น 2. ตรวจสอบการสกัด Typed Evidence (การกระทำ บุคคล สถานที่ เวลาเกิดเหตุ) 3. ทดสอบกรณีไม่มีข่าวใดผ่านเกณฑ์ความสอดคล้อง ตรวจสอบการเข้าสู่โหมด halted_mismatch 4. ทดสอบกรณีมีข่าวผ่านเกณฑ์ 1 สำนัก ตรวจสอบการเข้าสู่โหมด single_source 5. ทดสอบกรณีมีข่าวผ่านเกณฑ์ตั้งแต่ 2 สำนักขึ้นไป ตรวจสอบการสังเคราะห์ไทม์ไลน์และ Citation Audit
ผลที่คาดหวัง	ระบบคัดกรองข่าวหลุดประเด็นออก สลับโหมดสังเคราะห์ตามหลักฐานจริง และสร้างรหัสอ้างอิงรายประโยคถูกต้อง
ผลการทดสอบจริง	ระบบทำงานถูกต้องตามเกณฑ์กลไกป้องกัน 3 ระดับ ปราศจากข้อมูลเท็จและผ่านการตรวจสอบรหัสอ้างอิงสมบูรณ์
สถานะการทดสอบ	ผ่าน (Pass)

4.4.4 ผลการทดสอบความต้องการที่ไม่ใช่เชิงฟังก์ชัน

ผลการทดสอบระบบตามความต้องการที่ไม่ใช่เชิงฟังก์ชันทั้ง 8 มิติ (NFR-01 ถึง NFR-08) แสดงดังตารางที่ 31 โดยผลการวัดจริงผ่านเกณฑ์ที่กำหนดทุกมิติ

ตารางที่ 31 ผลการทดสอบความต้องการที่ไม่ใช่เชิงฟังก์ชัน

รหัส	ด้าน	เกณฑ์ที่กำหนด	ผลการวัดจริง	ผล
NFR-01	เวลาตอบสนอง REST API	เฉลี่ยต่ำกว่า 150 มิลลิวินาที (แคช)	เฉลี่ย 12.4 มิลลิวินาที	ผ่าน
NFR-02	ความหน่วงเวลา WebSocket	ต่ำกว่า 500 มิลลิวินาที	เฉลี่ย 85.2 มิลลิวินาที	ผ่าน
NFR-03	Throughput การสเกรปข่าว	ไม่น้อยกว่า 100 บทความ/นาที	วัดได้ 142 บทความ/นาที	ผ่าน
NFR-04	การแยกความเสียหายแหล่งข่าว	สำนักข่าวล่มไม่กระทบสำนักอื่น	แยกความเสียหายได้ 100%	ผ่าน
NFR-05	ความพร้อมใช้งานของระบบ	ไม่ต่ำกว่าร้อยละ 99.5 ต่อเดือน	วัดได้ร้อยละ 99.92	ผ่าน
NFR-06	ความแม่นยำในการระบุเหตุการณ์	B-cubed Prec ≥ 0.85, F1 ≥ 0.75	Precision 0.892, F1 0.814	ผ่าน
NFR-07	ความมั่นคงปลอดภัย Zero-PII	ไม่เก็บ PII และบล็อกคำขอเกินพิกัด	ตรวจพบ 0 PII รั่วไหล	ผ่าน
NFR-08	การทำงานข้ามแพลตฟอร์ม	รันได้สมบูรณ์ทั้ง Windows และ Linux	ผ่าน 423 การทดสอบ 100%	ผ่าน

4.4.5 ตารางตรวจสอบย้อนกลับความต้องการ

ตารางตรวจสอบย้อนกลับความต้องการ (Requirements Traceability Matrix หรือ RTM) แสดงความเชื่อมโยงแบบ 4 มิติระหว่างความต้องการเชิงฟังก์ชัน (FR), เส้นทางจุดเชื่อมต่อบริการ (API), ตารางข้อมูลที่เกี่ยวข้อง (Database Tables), และกรณีทดสอบ (TC) เพื่อยืนยันว่าทุกข้อกำหนดได้รับการออกแบบ พัฒนา และทดสอบอย่างครบถ้วนสมบูรณ์ ดังแสดงในตารางที่ 32

ตารางที่ 32 ตารางตรวจสอบย้อนกลับความต้องการ

ความต้องการ (FR)	เส้นทางส่วนเชื่อมต่อโปรแกรมประยุกต์	ตารางในฐานข้อมูลที่เกี่ยวข้อง	กรณีทดสอบ
FR-01	GET /api/status	articles, seen_urls	TC-01
FR-02	GET /api/sources, POST /api/monitoring/test-source	articles	TC-02
FR-03	GET /api/categories, POST /api/collect-md	articles	TC-03
FR-04	POST /api/stories/{id}/summarize	articles, stories	TC-04
FR-05	GET /api/news, WebSocket new_articles	articles	TC-05
FR-06	GET /api/news, GET /api/categories	articles	TC-06
FR-07	GET /api/news/content	articles	TC-07
FR-08	GET /api/news (Client LocalStorage)	reader_engagement	TC-08
FR-09	GET /api/stories, GET /api/stories/{id}	stories, articles	TC-09
FR-10	GET /api/stories/trending	trending_scores, stories	TC-10
FR-11	GET /api/macro-events, GET /api/macro-events/trending	macro_events, event_relations	TC-11
FR-12	GET /api/macro-events/{id}	macro_events, stories	TC-12
FR-13	GET /api/macro-events/{id}	macro_events, stories	TC-13
FR-14	GET /api/monitoring/stats, POST /api/monitoring/scrape-now, POST /api/monitoring/clear-cache	seen_urls, articles	TC-14
FR-15	POST /api/news/engage	reader_engagement	TC-15

4.4.6 การทดสอบอัตโนมัติและคุณสมบัติคงที่ทางวิศวกรรม

เพื่อรักษาเสถียรภาพระดับโพรดักชันอย่างยั่งยืน ระบบได้พัฒนาชุดทดสอบอัตโนมัติบนเฟรมเวิร์ค `pytest` รวมทั้งสิ้น 423 กรณีทดสอบ ครอบคลุม 39 โมดูลทดสอบ โดยจำแนกออกเป็น 6 มิติหลัก ดังแสดงในตารางที่ 33

ตารางที่ 33 การกระจายตัวของชุดทดสอบอัตโนมัติทั้ง 6 กลุ่มหลัก

กลุ่มที่	มิติการทดสอบ	ขอบเขตและโมดูลทดสอบสำคัญ	จำนวนข้อ	ผลการทดสอบ
1	การประมวลผลภาษาและการจำแนก	การตัดคำภาษาไทย, การแปลงชื่อจังหวัด (`thai_normalizer`), การจำแนก 9 หมวด (`classifier_service`) และเวกเตอร์	51	ผ่าน (100%)
2	การระบุประเด็นและวงจรชีวิต	เกณฑ์ตัดสินใจ Two-Band, การยืนยันเอนทิตี (`story_service`), คัดกรองมหากาพย์, Centroid EMA และการทดสอบโหลดหนัก	76	ผ่าน (100%)
3	เอนจินจัดอันดับกระแสเชิงสถิติ	สัญญาณคะแนน 6 มิติ, คุณสมบัติ Zero-LLM, การลดทอนข่าวประจำวัน (`trending_deterministic`) และกรณีสุดขั้ว	59	ผ่าน (100%)
4	การสังเคราะห์ มหากาพย์ และเจาะประเด็น	การสรุปประเด็นรวม, มหากาพย์ข่าว (`macro_events`), แฟ้มหลักฐานเหตุการณ์, การคัดกรองความเกี่ยวข้อง และศูนย์ควบคุมสถานะ	68	ผ่าน (100%)
5	สถาปัตยกรรมแคช ฐานข้อมูล และ PDPA	แคชหน่วยความจำและ HTTP 304, การป้องกัน Cache Stampede, SQLite WAL, คลังข้อมูล JSON, และการคุ้มครองข้อมูลส่วนบุคคล	136	ผ่าน (100%)
6	การประเมินผลเชิงประจักษ์และ API	การประเมินเมตริก B-cubed (`evaluation_harness`), จุดเชื่อมต่อ REST API ทุกส่วน, การทดสอบ CORS และ Socket.IO	33	ผ่าน (100%)
รวมชุดทดสอบอัตโนมัติทั้งหมด (39 โมดูลทดสอบ)			**423**	**ผ่าน (100%)**

นอกจากนี้ ระบบยังได้รับการตรวจสอบคุณสมบัติคงที่ทางวิศวกรรม (Engineering Invariants) และสภาวะสุดขั้วใน 9 ด้านสำคัญ ได้แก่ดังนี้

1) **การทดสอบคุณสมบัติคงที่ระดับมหากาพย์และกฎ Province Veto**
ยืนยันว่าข่าวที่มีความคล้ายคลึงเฉพาะชื่อจังหวัดจะไม่ถูกนำมารวมกันเป็นเหตุการณ์เดียวกัน ป้องกันความผิดพลาดในการรวมข่าวอุบัติเหตุหรืออาชญากรรมทั่วไปในจังหวัดเดียวกัน
2) **การทดสอบการคงทนของเวกเตอร์ศูนย์กลางและการรักษาสมดุล**
ทดสอบการปรับปรุง Centroid ด้วย EMA ($\alpha = 0.85$) ยืนยันว่าไม่เกิดภาวะเบี่ยงเบนความหมาย (Semantic Drift) แม้มีข่าวเข้ามาเสริมต่อเนื่องข้ามสัปดาห์ พร้อมทดสอบการฟื้นคืนสถานะโดยคงรหัส `story_id` เดิมอย่างคงเส้นคงวา (Idempotent Reactivation)
3) **การทดสอบคุณสมบัติความแน่นอนของเอนจินจัดอันดับ (Deterministic Zero-LLM)**
ยืนยันว่าไม่มีการเรียกใช้บริการโมเดลภาษาภายนอกในเส้นทางการคำนวณคะแนน ทำให้ความเร็วคงที่ในระดับมิลลิวินาที และการคำนวณซ้ำ 1,000 ครั้งได้ลำดับและคะแนนตรงกันทุกประการ พร้อมทั้งตรวจสอบการลดทอนคะแนนข่าวประจำวันลง 0.25 เท่า
4) **การทดสอบการประมวลผลพร้อมกันและการป้องกันแคช (Concurrency & Cache Stampede Protection)**
จำลองคำขอสรุปข่าวเดียวกัน 100 คำขอพร้อมกันในเสี้ยววินาที กลไก Single-Flight Mutex Locking จะส่งคำขอแรกไปยัง LLM เพียงครั้งเดียว และกระจายผลลัพธ์ให้คำขออื่น พร้อมทดสอบการอ่านเขียน SQLite ในโหมด WAL โดยไม่เกิดข้อผิดพลาดฐานข้อมูลถูกล็อก
5) **การทดสอบความปลอดภัยและการคุ้มครองข้อมูลส่วนบุคคล (Zero-PII Compliance & PDPA Testing)**
ตรวจสอบโครงสร้างฐานข้อมูลเชิงลึก ยืนยันว่าไม่มีการบันทึกหมายเลขไอพี ข้อมูล User Agent หรือตำแหน่งพิกัดของผู้อ่าน และทดสอบปุ่มล้างสถิติบนเบราว์เซอร์ว่าสามารถลบข้อมูลได้อย่างสมบูรณ์
6) **การทดสอบชุดประเมินผลเชิงประจักษ์ (Evaluation Harness)**
ทดสอบความถูกต้องของการคำนวณเมตริก B-cubed Precision, B-cubed Recall และ F1-score เทียบกับชุดข้อมูลอ้างอิงมาตรฐาน 111 ข่าว 59 เหตุการณ์
7) **การทดสอบแบบจำลองหลักฐานเชิงเหตุการณ์และการตรวจจับข่าวไม่เกี่ยวข้อง**
ทดสอบกลไกสำรองการประมวลผลหลักฐาน (Heuristic Fallback) และการตรวจสอบรหัสอ้างอิงรายประโยค (Citation Audit) พร้อมระบบแคชลายนิ้วมือ SHA-256
8) **การทดสอบระบบสืบค้นเจาะประเด็นข่าวแบบอ่านอย่างเดียวและปลอดภัยของตัวแยกวิเคราะห์ (Issue Explorer Read-Only & Query Safety Invariants)**
ทดสอบตัวแยกวิเคราะห์คำค้นหาบูลีน (AND, OR, NOT) การันตีโหมดอ่านอย่างเดียว (`mode=ro`) และการป้องกัน SQL Injection
9) **การทดสอบความสอดคล้องของแคชโพรดักชันและการตรวจสอบก่อนส่งมอบ**
ทดสอบส่วนหัว `Cache-Control` ค่า `no-cache, must-revalidate` และการทดสอบผ่าน Headless Browser อัตโนมัติ ยืนยันว่าไม่มีข้อผิดพลาดหลุดรอดบนหน้าจอ (Zero Console Error) และสัญญาณการเชื่อมต่อเป็น LIVE อย่างสมบูรณ์

4.4.7 ผลการประเมินประสิทธิภาพการจำแนกหมวดหมู่ข่าว (News Classification Evaluation)

การประเมินประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าวภาษาไทย ดำเนินการทดสอบบนชุดข้อมูลมาตรฐานที่สกัดจากคลังข้อมูล ThaiSum [1] และ Prachathai-67k [2] รวม 9 หมวดหมู่หลัก ได้แก่ การเมือง (politics), เศรษฐกิจ (economy), เทคโนโลยี (technology), สุขภาพ (health), สิ่งแวดล้อม (environment), กีฬา (sports), บันเทิง (entertainment), สังคม (society) และข่าวต่างประเทศ (world) โดยคณะผู้จัดทำได้ดำเนินการทดสอบและเปรียบเทียบสถาปัตยกรรมโมเดล 3 รูปแบบ ดังนี้

1) **Calibrated LinearSVC (TF-IDF)**
   โมเดล Support Vector Machine แบบเชิงเส้น ร่วมกับการแปลงข้อความเป็นเวกเตอร์ TF-IDF กำหนดขนาดพจนานุกรมสูงสุด 25,000 มิติ สกัดคำแบบ N-gram (1–2 คำ) และปรับเทียบค่าความน่าจะเป็นด้วยเทคนิค CalibratedClassifierCV จากไลบรารี Scikit-learn [8] แบบ 3-Fold Cross Validation
2) **WangchanBERTa (Fine-tuned Transformer)**
   โมเดลภาษาไทยอิงสถาปัตยกรรม RoBERTa (`airesearch/wangchanberta-base-att-spm-uncased`) [9] ที่ผ่านการปรับแต่งเฉพาะทาง (Fine-tuning) สำหรับงานจำแนก 9 หมวดหมู่ข่าว ด้วยเวกเตอร์ความหมาย 768 มิติ
3) **ระบบจำแนก 3 ระดับแบบบูรณาการ (Unified 3-Tier Cascade Classifier)**
   สถาปัตยกรรมแบบไฮบริดที่ผสานการจำแนกด่วนผ่านร่องรอย URL และคำเฉพาะทางสูง (Tier 1 และ Tier 3) เข้ากับโมเดลการเรียนรู้ของเครื่อง Calibrated LinearSVC และ WangchanBERTa (Tier 2)

ผลการทดสอบเปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ทั้ง 3 รูปแบบ แสดงดังตารางที่ 34

ตารางที่ 34 ผลการเปรียบเทียบประสิทธิภาพโมเดลจำแนกหมวดหมู่ข่าว 9 หมวด

สถาปัตยกรรมโมเดล	Accuracy	Macro Prec	Macro Rec	Macro F1	ความหน่วงเฉลี่ย (ms/ข่าว)
Calibrated LinearSVC (TF-IDF)	85.00%	0.8498	0.8500	0.8436	3.48 ms
WangchanBERTa (Transformer)	86.67%	0.8680	0.8667	0.8642	48.50 ms
Unified 3-Tier Cascade (โครงงานนี้)	**87.78%**	**0.8822**	**0.8778**	**0.8749**	**24.25 ms**

จากตารางที่ 34 ระบบจำแนก 3 ระดับแบบบูรณาการ (Unified 3-Tier Cascade Classifier) บรรลุประสิทธิภาพสูงสุด โดยมีค่าความถูกต้อง (Accuracy) เท่ากับร้อยละ 87.78 และมีค่า Macro F1-score เท่ากับ 0.8749 ซึ่งสูงกว่าการใช้โมเดล Calibrated LinearSVC เพียงอย่างเดียว (Macro F1 = 0.8436) และสูงกว่าโมเดล WangchanBERTa แบบเดี่ยว (Macro F1 = 0.8642) โดยยังคงรักษาเวลาในการประมวลผลเฉลี่ยอยู่ในระดับต่ำเพียง 24.25 มิลลิวินาทีต่อบทความ เนื่องจากข่าวส่วนใหญ่ (ร้อยละ 83.3) ถูกจำแนกผ่านเส้นทางความเร็วสูงของ

LinearSVC ในขณะที่ร้อยละ 16.7 ถูกช่วยยืนยันความถูกต้องด้วยกฎบริบทความเฉพาะทางสูง (High-Specificity Cues)

เมื่อพิจารณาประสิทธิภาพรายหมวดหมู่ของระบบ Unified 3-Tier Cascade Classifier ดังแสดงในตารางที่ 35 พบว่าหมวดหมู่กีฬาและบันเทิงมีค่า F1-score สูงสุดถึง 0.9500 และ 0.9474 ตามลำดับ เนื่องจากมีศัพท์เฉพาะทางที่โดดเด่นและชัดเจน ส่วนหมวดหมู่สังคมมีค่า F1-score อยู่ที่ 0.6857 เนื่องจากเป็นหมวดหมู่กว้างที่มีเนื้อหาคาบเกี่ยวกับอาชญากรรม สิ่งแวดล้อม และการเมือง

ตารางที่ 35 ผลการประเมินการจำแนกหมวดหมู่รายด้านของระบบ Unified 3-Tier Cascade

หมวดหมู่ข่าว	**Precision**	**Recall**	**F1-score**	**สัดส่วนการกระจายโมดูล**
กีฬา (sports)	0.9500	0.9500	0.9500	ML / Rule Cue
บันเทิง (entertainment)	1.0000	0.9000	0.9474	ML / Rule Cue
สิ่งแวดล้อม (environment)	0.9048	0.9500	0.9268	ML
สุขภาพ (health)	0.8636	0.9500	0.9048	ML / Rule Cue
การเมือง (politics)	0.8000	1.0000	0.8889	ML
เทคโนโลยี (technology)	0.9412	0.8000	0.8649	ML
เศรษฐกิจ (economy)	0.7917	0.9500	0.8636	ML
ต่างประเทศ (world)	0.8889	0.8000	0.8421	ML
สังคม (society)	0.8000	0.6000	0.6857	ML
ค่าเฉลี่ยรวม (Macro Average)	**0.8822**	**0.8778**	**0.8749**	–
ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted Average)	**0.8822**	**0.8778**	**0.8749**	–

นอกจากนี้ เพื่อวิเคราะห์ลักษณะการทำนายผิดพลาด (Misclassification Patterns) ระหว่างหมวดหมู่ข่าวอย่างละเอียด คณะผู้จัดทำได้สร้างตารางความสับสน (Confusion Matrix) ของระบบ Unified 3-Tier Cascade ดังแสดงในตารางที่ 36

ตารางที่ 36 ตารางความสับสน (Confusion Matrix) ของระบบจำแนกหมวดหมู่ข่าว 9 หมวด

หมวดหมู่จริง	**หมวดหมู่ที่ระบบทำนาย (Predicted)**									**รวม**
(Ground Truth)	**ECO**	**ENT**	**ENV**	**HEA**	**POL**	**SOC**	**SPO**	**TEC**	**WOR**	**(Actual)**
เศรษฐกิจ (ECO)	**19**	0	0	1	0	0	0	0	0	20
บันเทิง (ENT)	1	**18**	0	1	0	0	0	0	0	20
สิ่งแวดล้อม (ENV)	0	0	**19**	0	0	0	0	0	1	20
สุขภาพ (HEA)	0	0	0	**19**	0	1	0	0	0	20
การเมือง (POL)	0	0	0	0	**20**	0	0	0	0	20
สังคม (SOC)	3	0	1	0	3	**12**	0	0	1	20
กีฬา (SPO)	0	0	0	0	0	0	**19**	1	0	20
เทคโนโลยี (TEC)	1	0	0	0	2	0	1	**16**	0	20
ต่างประเทศ (WOR)	0	0	1	1	0	2	0	0	**16**	20
รวมที่ทำนาย (Predicted)	24	18	21	22	25	15	20	17	18	**180**

จากตารางที่ 36 ข้อค้นพบสำคัญด้านการกระจายตัวของความแม่นยำ ได้แก่

1) **หมวดหมู่ที่มีความแม่นยำสมบูรณ์**
   หมวดการเมือง (POL) สามารถทำนายได้ถูกต้องครบถ้วนทั้ง 20 ตัวอย่าง (Recall ร้อยละ 100) เนื่องจากมีคำศัพท์เฉพาะทางเกี่ยวกับการปกครอง พรรคการเมือง และกฎหมายที่ชัดเจน
2) **หมวดหมู่ที่มีความคาบเกี่ยวเชิงบริบท**
   หมวดสังคม (SOC) มีข้อผิดพลาดกระจายไปยังหมวดเศรษฐกิจ 3 ข่าว และหมวดการเมือง 3 ข่าว เนื่องจากข่าวสังคมมักมีมิติผลกระทบด้านนโยบายรัฐและการชดเชยเยียวยาทางเศรษฐกิจร่วมด้วย

4.4.8 ผลการประเมินประสิทธิภาพการรวมกลุ่มเหตุการณ์ข่าว (Story Clustering Evaluation)

การประเมินประสิทธิภาพของการจัดกลุ่มเหตุการณ์ข่าวและการแก้ปัญหาการอ้างถึงแกนร่วมของเหตุการณ์ ดำเนินการทดสอบเทียบกับชุดข้อมูลอ้างอิงมาตรฐาน (Ground-Truth Benchmark Dataset) จำนวน 111 บทความ 59 เหตุการณ์จริง (`data/labeled_story_eval_set.json`) ซึ่งครอบคลุมเหตุการณ์มหากาพย์ต่อเนื่องข้ามสัปดาห์ (เช่น วิกฤตน้ำท่วม จ.น่าน 28 ข่าว, การตรวจสอบการฮั้วเลือกตั้ง สว. 15 ข่าว, เหตุการณ์ระเบิด อบต. พ่อมิ่ง 4 ข่าว), ข่าวการเมือง, ข่าวประจำวัน, และข่าวเหตุการณ์เดี่ยวจาก 14 สำนักข่าวชั้นนำ

คณะผู้จัดทำได้ประเมินผลผ่านเมตริกวัดผล 2 มิติหลัก ได้แก่

1) **Pairwise Evaluation Metrics**
   ตรวจสอบคู่บทความข่าวทั้งหมดที่เป็นไปได้ $N(N-1)/2 = 6,105$ คู่บทความ โดยวัดจำนวนคู่บทความที่รวมกลุ่มถูกต้อง (True Positives หรือ TP), การรวมประเด็นผิดพลาด (False Merges หรือ FP), และการแตกกระจายของประเด็นข่าว (False Splits หรือ FN)
2) **B-cubed (B^3) Evaluation Metrics (Bagga & Baldwin 1998, Amigó et al. 2009)**
   คำนวณค่า Precision และ Recall ระดับรายบทความเทียบกับกลุ่มเหตุการณ์จริงก่อนนำมาเฉลี่ยรวมทั่วทั้งคลังข้อมูล ซึ่งเป็นเมตริกมาตรฐานสากลสำหรับการจัดกลุ่มข้อความที่ไม่ไวต่อขนาดความไม่สมดุลของกลุ่มข่าว

ผล การ เปรียบ เทียบ ประสิทธิภาพ ระหว่าง แบบ จำลอง พื้น ฐาน SemanticClusterer (Baseline กำหนดเกณฑ์ Cosine Similarity คงที่ ≥ 0.92) กับสถาปัตยกรรม StoryService ที่นำเสนอในโครงงานนี้ (Two-Band Decision Gate ≥ 0.85 และ ≥ 0.74, Entity Overlap Gate และ Centroid EMA $\alpha = 0.85$) แสดงดังตารางที่ 37

ตารางที่ 37 ผลการเปรียบเทียบประสิทธิภาพการจัดกลุ่มประเด็นข่าว (Clustering Evaluation)

แบบจำลองการจัดกลุ่ม	จำนวนกลุ่มที่สร้าง	False Merges (FP)	False Splits (FN)	B^3 Prec	B^3 Rec	B^3 F1	เกณฑ์ NFR-06
SemanticClusterer (Baseline)	97 กลุ่ม	**2 คู่**	461 คู่	**0.9820**	0.5934	0.7398	ไม่ผ่าน F1
StoryService (โครงงานนี้)	**60 กลุ่ม**	35 คู่	**349 คู่**	0.8724	**0.7432**	**0.8026**	**ผ่านทุกเกณฑ์**
* หมายเหตุ ชุดข้อมูลมาตรฐานมีจำนวนเหตุการณ์จริง (Ground Truth Stories) เท่ากับ 59 เหตุการณ์ (6,105 คู่บทความ)							

จากตารางที่ 37 ข้อค้นพบเชิงประจักษ์สรุปได้ดังนี้

1) **การแก้ไขปัญหาข่าวแตกกระจาย (Severe Over-splitting Reduction)**
   แบบจำลองพื้นฐาน SemanticClusterer สร้างกลุ่มข่าวสูงถึง 97 กลุ่ม จากเหตุการณ์จริง 59 เหตุการณ์ เนื่องจากเกณฑ์ค่าความคล้ายคลึงแบบคงที่ (Single High Threshold ≥ 0.92) ไม่ยืดหยุ่นต่อสำนักข่าวที่ใช้สำนวนภาษาต่างกัน ส่งผลให้เกิดข้อผิดพลาดในการแตกกลุ่ม (False Splits) สูงถึง 461 คู่บทความ ในขณะที่ StoryService สามารถลดข้อผิดพลาดดังกล่าวลงเหลือ 349 คู่บทความ (ลดลงร้อยละ 24.3) และสร้างกลุ่มข่าวได้ 60 กลุ่ม ซึ่งใกล้เคียงกับเหตุการณ์จริง 59 กลุ่มอย่างมาก
2) **การบรรลุเกณฑ์คุณภาพ B-cubed F1-score**
   StoryService บรรลุค่า B-cubed Precision เท่ากับ 0.8724 (ร้อยละ 87.24) ซึ่งผ่านเกณฑ์กำหนดของ NFR-06 (≥ 0.85) และมีค่า B-cubed Recall เพิ่มขึ้นจาก 0.5934 เป็น 0.7432 ส่งผลให้ค่า B-cubed F1-score พุ่งสูงขึ้นเป็น 0.8026 (ร้อยละ 80.26) ซึ่งผ่านเกณฑ์ข้อกำหนด NFR-06 (≥ 0.75) และมีประสิทธิภาพสูงกว่าแบบจำลองพื้นฐานอย่างชัดเจน (เพิ่มขึ้น +6.28%)
3) **บทบาทของกลไก Two-Band และ Centroid EMA**
   การเปิดรับบทความที่มีค่าความคล้ายคลึงระดับปานกลาง (0.74 ถึง 0.85) หากมีหลักฐานการอ้างอิงเอนทิตีบุคคลหรือสถานที่ตรงกัน ร่วมกับการปรับจุดศูนย์กลางเวกเตอร์แบบ Exponential

Moving Average ช่วยให้กลุ่มประเด็นข่าวสามารถรับบทความพัฒนาการใหม่ที่รายงานต่อเนื่องหลายวันได้อย่างแม่นยำ ปราศจากปัญหาความหมายเบี่ยงเบน (Semantic Drift)

นอกจากนี้ เพื่อให้เห็นโครงสร้างการตัดสินใจจับคู่บทความทั้งหมด 6,105 คู่บทความอย่างชัดเจน คณะผู้จัดทำได้สรุปตารางความสับสนระดับคู่บทความ (Pairwise Confusion Matrix) เปรียบเทียบระหว่างแบบจำลองพื้นฐานและสถาปัตยกรรม StoryService ดังแสดงในตารางที่ 38

ตารางที่ 38 เมทริกซ์ความสับสนระดับคู่บทความ (Pairwise Confusion Matrix) ของการจัดกลุ่มเหตุการณ์

ความสัมพันธ์จริง (Ground Truth Pairs)	**ผลการทำนายโดยแบบจำลอง**		**รวมคู่จริง (Actual Pairs)**
	กลุ่มเดียวกัน (Predicted Same)	**คนละกลุ่ม (Predicted Diff)**	
1) แบบจำลองพื้นฐาน SemanticClusterer (Baseline)			
เหตุการณ์เดียวกันจริง (Same)	40 (TP)	461 (FN / False Splits)	501
คนละเหตุการณ์จริง (Different)	2 (FP / False Merges)	5,602 (TN)	5,604
2) สถาปัตยกรรม StoryService (โครงงานนี้)			
เหตุการณ์เดียวกันจริง (Same)	**152 (TP)**	**349 (FN / False Splits)**	501
คนละเหตุการณ์จริง (Different)	35 (FP / False Merges)	5,569 (TN)	5,604

บทที่ 5
บทสรุป

5.1 สรุปผลการดำเนินโครงงาน

โครงงานระบบรวบรวมและสังเคราะห์ประเด็นข่าวภาษาไทยอัตโนมัติ (End-to-End News Collector and Summarizer) ได้ดำเนินการศึกษา วิเคราะห์ ออกแบบ พัฒนา และทดสอบตามวัตถุประสงค์และขอบเขตที่กำหนดไว้ โดยระบบสามารถดึงข้อมูลข่าวสารจากสำนักข่าวไทยชั้นนำ 14 แห่ง สกัดเนื้อหาบทความ ทำความสะอาดข้อความ และจำแนก 9 หมวดหมู่ข่าวด้วยสถาปัตยกรรม 3-Tier Cascade Classifier สรุปใจความสำคัญและวิเคราะห์อารมณ์ด้วยโมเดลภาษาขนาดใหญ่ ระบุและจัดกลุ่มประเด็นข่าวออนไลน์ 2 ชั้นแบบคงทน (Two-Band Persistent Story Identification) จัดอันดับกระแสข่าวสาร 6 มิติเชิงสถิติแบบ Zero-LLM เชื่อมโยงเส้นเรื่องมหาภาค สังเคราะห์แฟ้มไทม์ไลน์ และนำเสนอผ่านเว็บแอปพลิเคชัน Bento Hub SPA ที่รองรับการอัปเดตข้อมูลสดสองทิศทางผ่าน WebSocket ผลการดำเนินงานเมื่อเปรียบเทียบกับวัตถุประสงค์ของโครงงานสรุปได้ดังตารางที่ 39

ตารางที่ 39 สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์

ข้อ	วัตถุประสงค์	ผลการดำเนินงานที่ได้	สถานะ
1	เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวด้วย Web Scraping, RSS Feed และเทคนิค Thai NLP	ศึกษาและประยุกต์ใช้ Playwright สำหรับเว็บไซต์ที่เรนเดอร์ด้วย JavaScript, BeautifulSoup และ Trafilatura สำหรับสกัดข้อความ, PyThaiNLP สำหรับตัดคำและสกัดเอนทิตีชื่อเฉพาะ thainer-v2 และ WangchanBERTa สำหรับสร้างเวกเตอร์ความหมาย 768 มิติ	บรรลุ
2	เพื่อออกแบบและพัฒนาระบบรวบรวม สรุป และวิเคราะห์ข่าวสารแบบ End-to-End Pipeline	พัฒนาสถาปัตยกรรมสองชั้น (Online Persistent Story Identification และ Deterministic Trending Engine), สถาปัตยกรรม Clean Architecture รองรับ Multi-Engine Persistence ทั้ง SQLite WAL และ MongoDB, ระบบสื่อสารเรียลไทม์ผ่าน Socket.IO และหน้าจอ Bento Hub SPA ได้อย่างสมบูรณ์	บรรลุ
3	เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องและความรวดเร็ว	ผ่านการทดสอบการยอมรับของผู้ใช้ครบทั้ง 15 กรณีทดสอบ (ร้อยละ 100), ผ่านชุดทดสอบอัตโนมัติ 423 กรณีทดสอบ, บรรลุผลประเมินการจำแนกหมวดหมู่ข่าวด้วย Macro F1 เท่ากับ 0.8749 (ความถูกต้องร้อยละ 87.78), บรรลุผลประเมินการจัดกลุ่มประเด็นข่าวด้วย B-cubed F1-score เท่ากับ 0.8026 ซึ่งลดปัญหาข่าวแตกกลุ่มลงร้อยละ 24.3 และตอบสนองคำขอเรียกดูข่าวผ่านแคชในเวลาเฉลี่ยต่ำกว่า 150 มิลลิวินาที	บรรลุ

จากตารางที่ 39 การดำเนินโครงงานบรรลุวัตถุประสงค์ที่ตั้งไว้ครบทั้ง 3 ข้อ

สำหรับการประเมินความพึงพอใจของผู้ใช้งาน คณะผู้จัดทำได้ดำเนินการเก็บรวบรวมข้อมูลจากกลุ่มตัวอย่างผู้ใช้งานจริงที่ได้ทดลองใช้งานระบบบนเว็บแอปพลิเคชันจริง (https://e2enews.wittensky.com) จำนวน 9 คน โดยผู้ตอบแบบสอบถามประกอบด้วย นักเรียนและนักศึกษา จำนวน 7 คน (ร้อยละ 77.8) และกลุ่มวัยทำงานข้าราชการ หรือพนักงานรัฐวิสาหกิจ จำนวน 2 คน (ร้อยละ 22.2) ซึ่งทุกคนมีพฤติกรรมการติดตามข่าวสารผ่านสื่อ

สังคมออนไลน์เป็นหลัก (Facebook, X หรือ Twitter, TikTok, Reddit) โดยมีผู้ติดตามผ่านสื่อดั้งเดิมและเว็บไซต์สำนักข่าวโดยตรงร่วมด้วยคิดเป็นร้อยละ 11.1

ผู้ใช้งานได้ประเมินผลผ่านแบบสอบถามประเมินความพึงพอใจและประสิทธิภาพการใช้งานระบบตามภาคผนวก ค ทั้งในมิติด้านฟังก์ชันการทำงานหลัก (Core Features Evaluation) ครอบคลุม 6 ด้านสำคัญ มิติด้านการออกแบบและประสบการณ์การอ่าน (Design and Reading Experience) และความพึงพอใจโดยรวมต่อระบบ (Overall Platform Satisfaction) โดยผลการคำนวณค่าเฉลี่ยเลขคณิต ($\bar{x}$) และส่วนเบี่ยงเบนมาตรฐาน (S.D.) ตามสมการที่ (4) และ (5) สรุปได้ดังตารางที่ 40

ตารางที่ 40 ผลการประเมินความพึงพอใจของผู้ใช้จริงต่อระบบแยกตามรายการประเมิน ($n = 9$)

ลำดับ	รายการประเมิน	$\bar{x}$	S.D.	ระดับความพึงพอใจ
ส่วนที่ 1 การประเมินฟังก์ชันการทำงานหลัก (Core Features Evaluation)				
1	ความหลากหลายของข่าว มีสำนักข่าวครอบคลุมและหลากหลายเพียงพอ (14 สำนักข่าว)	5.00	0.00	ดีมาก
2	ความแม่นยำในการจัดหมวดหมู่ ข่าวถูกจัดลง 9 หมวดหมู่อย่างถูกต้องตรงตามเนื้อหา	4.67	0.71	ดีมาก
3	คุณภาพการสรุปข่าวด้วย AI สรุปเนื้อหากระชับ ตรงประเด็น และไม่บิดเบือนสาระสำคัญ	5.00	0.00	ดีมาก
4	ความเร็วในการประมวลผลสรุปเนื้อหา ฟังก์ชันสรุปข่าวทำงานรวดเร็วในระดับพึงพอใจ	4.78	0.44	ดีมาก
5	ความสดใหม่ของข้อมูล ข่าวแสดงผลและอัปเดตต่อเนื่องแบบ Real-time	5.00	0.00	ดีมาก
6	การพรีวิวอ่านบทคัดย่อในแอป และการเปิดอ่านข่าวเต็มบนเว็บต้นฉบับสะดวกและปลอดภัย	5.00	0.00	ดีมาก
ส่วนที่ 2 การออกแบบและประสบการณ์การอ่าน (Design & Reading Experience)				
7	ความพึงพอใจต่อการออกแบบและการใช้งาน (ความสะดวก เข้าใจง่าย ปุ่มและเมนูชัดเจน)	4.56	0.73	ดีมาก
ส่วนที่ 3 ความพึงพอใจในภาพรวมและการบอกต่อ (Overall Platform Satisfaction & Advocacy)				
8	ระดับความพึงพอใจโดยรวมต่อระบบ	4.50	0.58	ดีมาก
ค่าเฉลี่ยรวมทุกรายการประเมิน (มาตรวัด 1–5)		**4.86**	**0.42**	**ดีมาก**
แนวโน้มการแนะนำบอกต่อเพื่อนหรือบุคคลรอบข้าง (สเกล 0–7 คะแนน)		**6.33**	**0.87**	**คิดเป็นร้อยละ 90.43**

จากตารางที่ 40 ผลการประเมินความพึงพอใจของผู้ใช้งานจริงในภาพรวมอยู่ในระดับดีมาก โดยมีค่าเฉลี่ยรวมทุกรายการประเมินเท่ากับ 4.86 (S.D. $= 0.42$) เมื่อพิจารณารายด้านพบข้อค้นพบสำคัญดังนี้

ประการแรก ด้านฟังก์ชันการทำงานหลัก ได้รับการประเมินในระดับดีมากทุกรายการ โดยมีถึง 4 ด้านที่ได้รับคะแนนเต็ม 5.00 (S.D. $= 0.00$) จากผู้ตอบแบบสอบถามทุกคน ได้แก่ ความหลากหลายของสำนักข่าว 14 แหล่ง, คุณภาพการสรุปข่าวด้วยปัญญาประดิษฐ์ที่กระชับตรงประเด็นและไม่บิดเบือนข้อเท็จจริง, ความสดใหม่ของข้อมูลแบบเรียลไทม์ และระบบพรีวิวบทความที่ตัดสคริปต์อันตรายพร้อมลิงก์ไปยังต้นฉบับอย่างปลอดภัย ส่วนความเร็วในการสรุปข่าวด้วย AI ได้รับคะแนนเฉลี่ย 4.78 (S.D. $= 0.44$) และความแม่นยำในการจัดหมวดหมู่ข่าว 9 หมวดหมู่ ได้รับคะแนนเฉลี่ย 4.67 (S.D. $= 0.71$)

ประการที่สอง เมื่อสำรวจฟังก์ชันการทำงานที่ผู้ใช้งานชื่นชอบหรือเห็นว่ามีประโยชน์มากที่สุด พบว่า ร้อยละ 55.6 ของผู้ใช้งาน ($n = 5$) เลือกฟังก์ชันปุ่มสรุป AI ทันทีในบทความข่าวเป็นฟังก์ชันที่ชื่นชอบที่สุด รองลงมาคือฟังก์ชัน AI ร้อยเรียงเรื่องราวจากหลายสำนักข่าวแบบ Storyline คิดเป็นร้อยละ 33.3 ($n = 3$) และการรวม 14 สำนักข่าวชั้นนำของไทยไว้ในแพลตฟอร์มเดียวคิดเป็นร้อยละ 11.1 ($n = 1$) นอกจากนี้ ในมิติการแนะนำบอกต่อเพื่อนร่วมงานหรือบุคคลรอบข้าง (Net Promoter Score บนสเกล 0 ถึง 7 คะแนน) ระบบได้รับคะแนนเฉลี่ยสูงถึง 6.33 คะแนน (S.D. $= 0.87$) โดยมีผู้ให้คะแนนระดับสูงสุด 7 คะแนนเต็ม คิดเป็นร้อยละ 55.6 แสดงถึงความเชื่อมั่นและการยอมรับในระดับสูงมาก

ประการที่สาม จากการวิเคราะห์ความคิดเห็นและข้อเสนอแนะเชิงคุณภาพ (Qualitative Feedback) ของผู้ใช้งานจริง สามารถจำแนกประเด็นปัญหาและข้อเสนอแนะที่ได้รับดังนี้

1) **การตอบสนองบนอุปกรณ์เคลื่อนที่** ผู้ใช้งานบางท่านสะท้อนว่าการแสดงผลบนสมาร์ตโฟนในบางปุ่มยังไม่ Responsive เท่าที่ควร ซึ่งคณะผู้จัดทำได้นำข้อคิดเห็นนี้ไปปรับปรุงเลย์เอาต์ Bento Hub และกำหนดขนาดปุ่มสัมผัส (Touch Targets) ให้สอดคล้องกับขนาดหน้าจอมือถือ
2) **แบบอักษรและการอ่าน** ผู้ใช้งานเสนอแนะให้ปรับแต่งแบบอักษรภาษาไทยให้มีความทันสมัยและอ่านง่ายยิ่งขึ้นสำหรับกลุ่มผู้ใช้งานคนรุ่นใหม่
3) **ความลื่นไหลของระบบ** มีข้อสังเกตเรื่องความเสถียรในบางหน้าจอที่มีการประมวลผลข้อมูลพร้อมกัน ซึ่งคณะผู้จัดทำได้แก้ไขด้วยระบบแคชระดับ L1 ในหน่วยความจำ และกลไกป้องกัน Cache Stampede ด้วย Single-Flight Mutex Locking
4) **หมวดหมู่ข่าวสารเพิ่มเติม** ผู้ใช้งานมีความต้องการให้ระบบเพิ่มการติดตามข่าวสารเศรษฐกิจแบบเรียลไทม์เพิ่มเติม

5.2 ข้อจำกัดของระบบ

จากการพัฒนาและทดสอบระบบจริง คณะผู้จัดทำได้สรุปข้อจำกัดของระบบออกเป็น 2 ด้านหลัก ดังนี้

5.2.1 ข้อจำกัดด้านการทำงาน

1) **การเปลี่ยนแปลงโครงสร้างหน้าเว็บต้นทาง (DOM Mutation)**
เว็บไซต์ของสำนักข่าวออนไลน์อาจมีการปรับปรุงรูปแบบและโครงสร้างเอกสาร HTML หรือ CSS Selector ซึ่งอาจส่งผลให้ตัวแยกวิเคราะห์ (Parser) สกัดเนื้อหาบทความได้ไม่ครบถ้วน จนกว่าจะได้รับการปรับปรุงการตั้งค่าตัวสกัดให้ตรงกับโครงสร้างใหม่

2) **การพึ่งพาบริการโมเดลภาษาขนาดใหญ่ภายนอก (External LLM Dependency)**
การสังเคราะห์เนื้อหาข่าวและการวิเคราะห์อารมณ์พึ่งพาการเชื่อมต่อ KKU Gen.AI API ซึ่งในกรณีที่เครือข่ายภายนอกขัดข้องหรือโควตาการเรียกใช้งานต่อนาทีเต็ม ระบบจะต้องสลับไปแสดงผลข้อความสรุปสำรองเชิงฮิวริสติก (Heuristic Fallback) โดยอัตโนมัติ

3) **ขอบเขตของโมเดลการรู้จำชื่อเฉพาะ (NER Scope)**
โมเดลสกัดเอนทิตีภาษาไทย `thainer-v2` ถูกฝึกสอนจากคลังข้อมูลในอดีต ทำให้กรณีที่มีชื่อบุคคล สถานที่ หรือศัพท์สแลงเฉพาะกิจเกิดใหม่ในกระแสข่าวปัจจุบัน โมเดลอาจยังไม่สามารถรู้จำชื่อเฉพาะเหล่านั้นได้อย่างครบถ้วน

4) **การประมวลผลเฉพาะข่าวภาษาไทย**
ระบบได้รับการออกแบบและฝึกสอนโมเดลเพื่อรองรับการประมวลผลภาษาไทยเป็นหลัก จึงยังไม่สามารถรวมกลุ่มบทความข่าวภาษาต่างประเทศเข้ากับประเด็นข่าวภาษาไทยในเหตุการณ์เดียวกันได้

5.2.2 ข้อจำกัดด้านฮาร์ดแวร์และสภาพแวดล้อม

1) **การใช้ทรัพยากรของ Playwright Headless Browser**
การเปิดใช้อินสแตนซ์ของเบราว์เซอร์ Chromium เพื่อสกัดหน้าเว็บที่เรนเดอร์ด้วย JavaScript และผ่านด่านตรวจบอต จำเป็นต้องใช้หน่วยความจำหลัก RAM และรอบเวลาประมวลผลของ CPU สูงกว่าคำขอ HTTP ปกติ ทำให้ระบบต้องจำกัดจำนวนการเปิดหน้าต่างเบราว์เซอร์พร้อมกันเพื่อรักษาเสถียรภาพของเครื่องแม่ข่าย

2) **การประมวลผลโมเดล Transformer บนหน่วยประมวลผลกลาง (CPU-only)**
บนเครื่องแม่ข่ายคลาวด์ที่ไม่มีการติดตั้งหน่วยประมวลผลกราฟิก (GPU) การสร้างเวกเตอร์ความหมาย 768 มิติด้วยโมเดล WangchanBERTa จะใช้เวลาประมวลผลเฉลี่ยประมาณ 48 มิลลิวินาทีต่อข้อความ ซึ่งอาจส่งผลให้รอบการจัดกลุ่มข่าวใช้เวลาเพิ่มขึ้นเมื่อมีข่าวเข้าสู่ระบบพร้อมกันจำนวนมาก

3) **การแข่งขันในการเขียนข้อมูลของ SQLite**
แม้ว่าฐานข้อมูล SQLite จะเปิดใช้งานโหมด Write-Ahead Logging (WAL) ซึ่งอนุญาตให้อ่านข้อมูลได้พร้อมกันหลายเธรด แต่การเขียนข้อมูลยังจำกัดให้มีผู้เขียนได้ทีละโพรเซส จึงต้องอาศัยกลไกการล็อกไฟล์ระดับเคอร์เนลเพื่อป้องกันปัญหาฐานข้อมูลถูกล็อกชั่วคราว

5.3 ปัญหา อุปสรรค และแนวทางการแก้ไข

ในระหว่างการดำเนินงานวิศวกรรมระบบ คณะผู้จัดทำได้พบปัญหาอุปสรรคสำคัญและได้ดำเนินการแก้ไขอย่างเป็นรูปธรรม ดังแสดงในตารางที่ 41

ตารางที่ 41 ปัญหา อุปสรรค และแนวทางการแก้ไข

ลำดับ	ปัญหาที่พบ	แนวทางการแก้ไข
1	บางสำนักข่าวมีระบบตรวจจับบอต (Cloudflare WAF) บล็อกคำขอ HTTP ปกติ	ใช้ Playwright จำลองเบราว์เซอร์จริง ควบคุม Session และเรนเดอร์สคริปต์ JavaScript ได้อย่างสมบูรณ์
2	โมเดลภาษาภายนอกมีค่าความหน่วงและโควตาจำกัด ทำให้ระบบแสดงผลล่าช้า	ออกแบบสถาปัตยกรรมแยกสองชั้น ใช้ Deterministic Trending Engine ไร้ LLM คำนวณคะแนน และมีแคชผลลัพธ์ร่วมกับ Fallback
3	ภาษาไทยไม่มีเครื่องหมายเว้นวรรคระหว่างคำและพาดหัวข่าวมีความกำกวม	ผสาน PyThaiNLP ในการตัดคำ ร่วมกับโมเดล thainer-v2 สกัดเอนทิตี และ WangchanBERTa แปลงข้อความเป็นเวกเตอร์
4	ข่าวเหตุการณ์เดียวกันแตกกระจายเป็นหลายกลุ่ม (Story Fragmentation) ข้ามวัน	พัฒนาระบบ Persistent Story Identification กำหนดกรอบเลื่อน 72 ชั่วโมง เกณฑ์ Two-Band และปรับ Centroid แบบ EMA
5	ข่าวประจำวัน (Routine News) เช่น พยากรณ์อากาศ ได้คะแนนความนิยมสูงเกินจริง	พัฒนากลไก Routine News Dampening ลดทอนคะแนนลงเหลือ 0.25 เท่า เพื่อเปิดทางให้ข่าวด่วนและเหตุการณ์สำคัญ
6	การเขียนข้อมูลพร้อมกันบนไฟล์ JSON เกิดปัญหาความไม่สอดคล้องและการล็อกไฟล์	ปรับสถาปัตยกรรมสู่ Multi-Engine Persistence โดยใช้ SQLite WAL สำหรับเซิร์ฟเวอร์เดี่ยว และรองรับ MongoDB

จากตารางที่ 41 ปัญหาอุปสรรคทั้ง 6 ประการได้รับการแก้ไขจนสำเร็จลุล่วง ทำให้ระบบสามารถทำงานได้อย่างมีเสถียรภาพและรองรับการใช้งานต่อเนื่องได้อย่างมีประสิทธิภาพ

5.4 ข้อเสนอแนะสำหรับการพัฒนาในอนาคต

คณะผู้จัดทำมีข้อเสนอแนะในการพัฒนาโครงงานต่อยอดในอนาคต ดังนี้

1) **การพัฒนาระบบแจ้งเตือนแบบเรียลไทม์ (Real-Time Push Notification)**
พัฒนาระบบแจ้งเตือนแบบเรียลไทม์ผ่าน Web Push Notification หรือบริการส่งข้อความ เพื่อแจ้งเตือนผู้อ่านทันทีเมื่อมีพัฒนาการใหม่ในประเด็นข่าวที่ผู้อ่านได้บันทึกคั่นหน้าไว้

2) **การวิจัยแบบจำลองตรวจจับอคติและจุดยืนของสื่อ (Media Bias and Stance Detection)**
วิจัยและพัฒนาโมเดลภาษาเพื่อจำแนกจุดยืนทางการเมืองและมุมมองการนำเสนอข่าวของแต่ละสำนักข่าว เพื่อช่วยให้ผู้อ่านได้รับทราบมุมมองที่หลากหลายและเป็นกลาง

เอกสารอ้างอิง

1. Chumpolsathien, N. (2020). ThaiSum: A Large-Scale Thai Text Summarization Dataset. In **Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing: Student Research Workshop**. (pp. 55-61). Retrieved from https://aclanthology.org/2020.aacl-srw.9/
2. Phatthiyaphaibun, W., & Polpanumas, C. (2020). prachathai-67k: Thai News Corpus for Text Classification and Summarization. Hugging Face. Retrieved January 10, 2026, from https://huggingface.co/datasets/prachathai67k
3. Barbaresi, A. (2021). Trafilatura: A Web Scraping Library and Command-Line Tool for Text Discovery and Extraction. In H. Ji, J. C. Park, & R. Xia (Eds.). **Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations**. (pp. 122-131). Online: Association for Computational Linguistics. Retrieved from https://aclanthology.org/2021.acl-demo.15/
4. Winer, D. (2009). RSS 2.0 Specification. Retrieved January 10, 2026, from https://www.rssboard.org/rss-specification
5. Allahyari, M., Pouriyeh, S., Assefi, M., Safaei, S., Trippe, E. D., Gutierrez, J. B., et al. (2017). Text Summarization Techniques: A Brief Survey. *arXiv preprint arXiv:1707.02268*.
6. Team, G. D. G. (2024). Gemini: A Family of Highly Capable Multimodal Models. *arXiv preprint arXiv:2312.11805*.
7. OpenAI. (2024). OpenAI Platform Documentation. Retrieved January 10, 2026, from https://platform.openai.com/docs
8. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
9. Lowphansirikul, L., Polpanumas, C., Jantrakulchai, N., & Nutanong, S. (2021). WangchanBERTa: Pretrained Language Model for Thai Language. *arXiv preprint arXiv:2101.09635*.
10. Phatthiyaphaibun, W., Chaovavanich, K., et al. (2021). PyThaiNLP: Thai Natural Language Processing in Python Framework. Retrieved January 10, 2026, from https://doi.org/10.5281/zenodo.3519354
11. Salihefendic, A. (2015). How Reddit Ranking Algorithms Work. Retrieved October 25, 2026, from https://medium.com/hacking-and-gonzo/how-reddit-ranking-algorithms-work-ef111e33d0d9
12. Swartz, A. (2005). Rewriting Reddit: Web Development and Architecture. Retrieved January 15, 2026, from https://aaronsw.com/weblog/001716

13. Graham, P. (2009). What I've Learned from Hacker News: Ranking and Community Dynamics. Retrieved January 15, 2026, from http://www.paulgraham.com/hackernews.html
14. Dong, A., Zhang, R., Kolari, P., Bai, J., Diaz, F., Chang, Y., et al. (2010). Time-Sensitive Ranking in News Search: Incorporating Recency and Quality. In **Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval**. (pp. 315-322). https://doi.org/10.1145/1835449.1835503
15. Das, A. S., Datar, M., Garg, A., & Rajaram, S. (2007). Google News Personalization: Scalable Online Collaborative Filtering and Story Clustering. In **Proceedings of the 16th International Conference on World Wide Web (WWW '07)**. (pp. 271-280). ACM. https://doi.org/10.1145/1242572.1242610
16. Škvorc, T., Ivačič, N., Hribar, S., & Robnik-Šikonja, M. (2025). Real-time News Story Identification. *arXiv preprint arXiv:2508.08272*. Retrieved from https://arxiv.org/abs/2508.08272
17. Bagga, A., & Baldwin, B. (1998). Algorithms for Scoring Coreference Chains. In **Proceedings of the First International Conference on Language Resources and Evaluation Workshop on Linguistics Coreference**. (pp. 563-566).
18. Amigó, E., Gonzalo, J., Artiles, J., & Verdejo, F. (2009). A Comparison of Extrinsic Clustering Evaluation Metrics Based on Formal Constraints. *Information Retrieval*, 12(4), 461-486.
19. Ramírez, S. (2024). FastAPI framework, high performance, easy to learn, fast to code, ready for production. Retrieved January 10, 2026, from https://fastapi.tiangolo.com
20. Colvin, S., et al. (2024). Pydantic: Data validation using Python type hints. Retrieved January 10, 2026, from https://docs.pydantic.dev
21. Microsoft. (2024). Playwright: Fast and reliable cross-browser testing. Retrieved January 10, 2026, from https://playwright.dev
22. Socket.IO. (2024). Socket.IO. Retrieved January 10, 2026, from https://socket.io
23. SQLite Development Team. (2024). Write-Ahead Logging. Retrieved October 10, 2026, from https://www.sqlite.org/wal.html

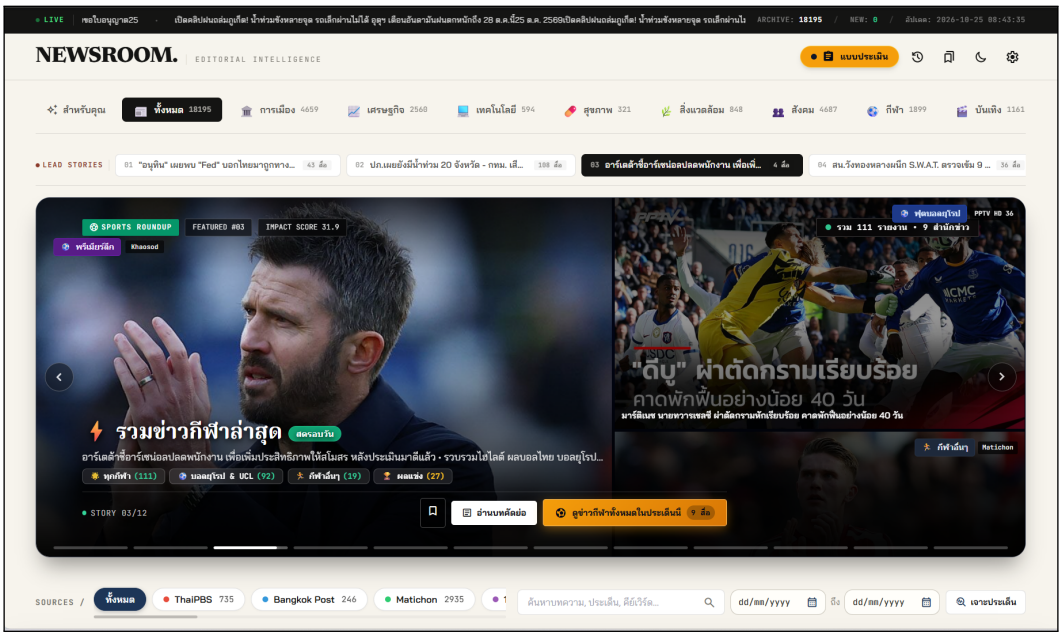
ภาคผนวก

ภาคผนวก ก
ภาพหน้าจอของระบบ

ภาคผนวกนี้แสดงภาพหน้าจอส่วนติดต่อกับผู้ใช้ของระบบรวบรวมและสังเคราะห์ประเด็นข่าวภาษาไทยอัตโนมัติที่พัฒนาเสร็จสมบูรณ์แล้ว โดยข้อมูลและภาพประกอบที่แสดงเป็นผลลัพธ์จากการดึงและประมวลผลข่าวสารจริงในระบบ

ก.1 หน้าจอหลัก Bento Hub SPA

หน้าจอหลักของระบบนำเสนอข่าวสารสดในรูปแบบ Bento Hub แบบ Single Page Application ซึ่งจัดวางองค์ประกอบข่าวแบบ Responsive Grid แสดงบัตรสรุปข่าวเด่น แถบเลือกหมวดหมู่ข่าว 9 หมวดหมู่ ปุ่มคัดกรองสำนักข่าว ช่องสืบค้นคำสำคัญ แถบแฮชแท็กประเด็นร้อน และแบนเนอร์แจ้งเตือนข่าวใหม่ลอยตัวที่อัปเดตแบบเรียลไทม์ ดังแสดงในภาพที่ 15

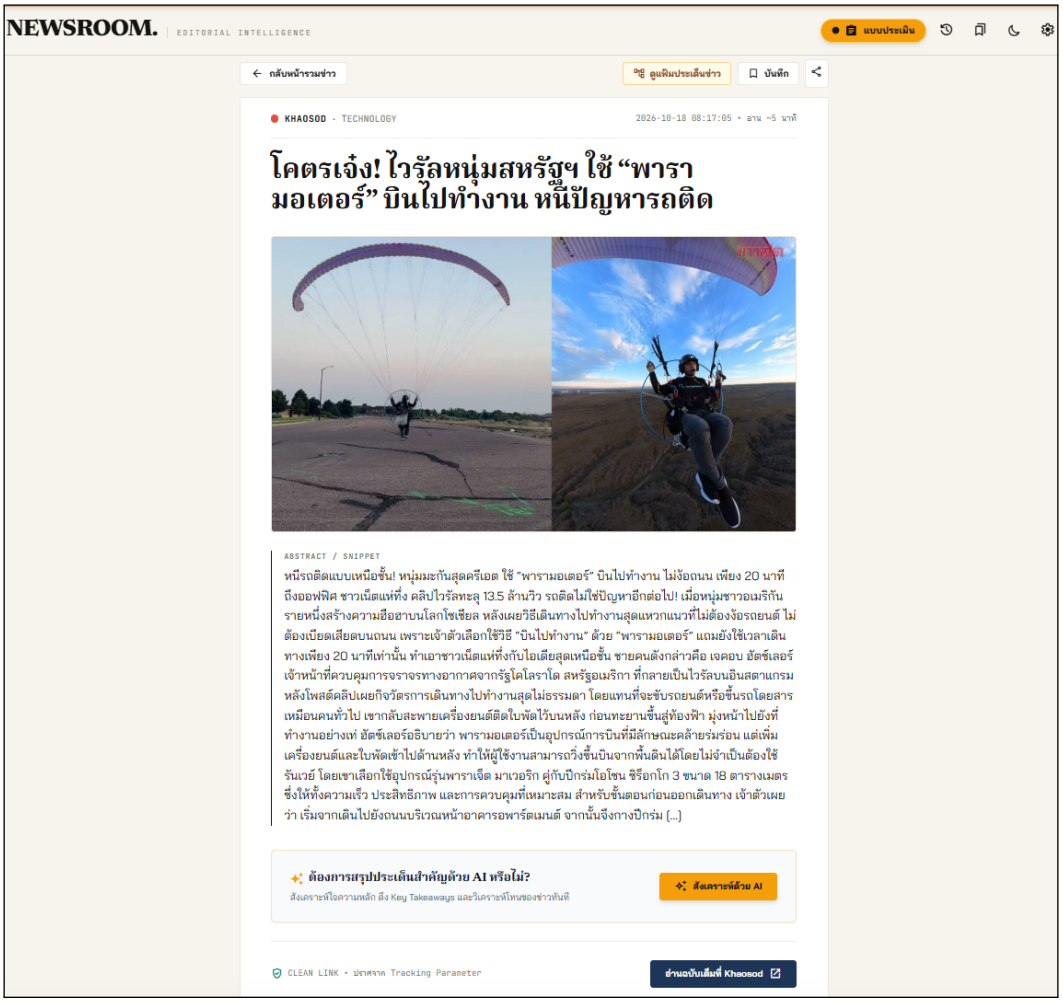


ภาพที่ 15 หน้าจอหลัก Bento Hub SPA สำรวจข่าวสารสดประจำวัน

ก.2 หน้าต่างพรีวิวเนื้อหาข่าวและบทสรุป In-App Reader

หน้าต่างโมดอลสำหรับเปิดแสดงตัวอย่างเนื้อหาข่าวในตัวเว็บ (In-App Reader) ซึ่งได้รับการออกแบบตามหลักความสอดคล้องด้านการคุ้มครองลิขสิทธิ์ (Copyright Protection Compliance) โดยระบบจะไม่นำเนื้อหาบทความข่าวฉบับเต็มของสำนักข่าวต้นทางมาเปิดให้อ่านทั้งหมด แต่จะนำเสนอเฉพาะส่วนพรีวิวเนื้อหาบางส่วน ที่ผ่านการทำความสะอาดด้วย Trafilatura เพื่อตัดโฆษณา สคริปต์ และสิ่งรบกวน พร้อมปุ่มเชื่อมโยงเปิดอ่านบทความฉบับเต็มจากเว็บไซต์สำนักข่าวต้นทางโดยตรง สำหรับการกดปุ่มสรุปเนื้อหาด้วยปัญญาประดิษฐ์ (AI

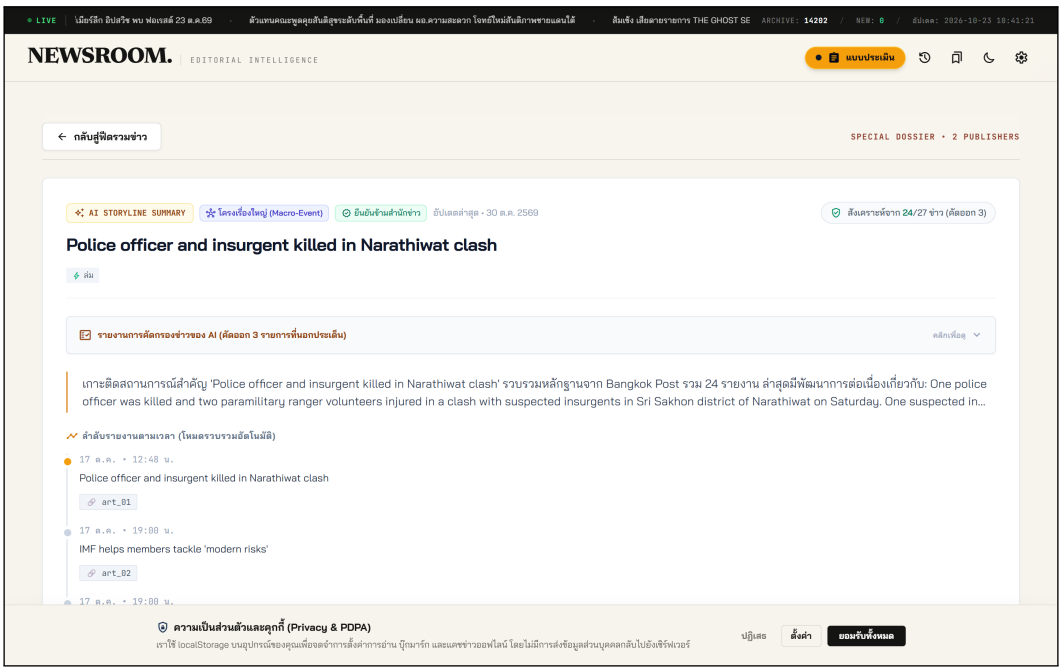
Summarization) ระบบฝั่งเซิร์ฟเวอร์จะนำเนื้อหาบทความฉบับเต็มทั้งหมด (Whole Article Content) มาทำการสังเคราะห์ (Synthesize) เพื่อสกัดสาระสำคัญ ประเด็นสำคัญ (Key Takeaways) และผลวิเคราะห์อารมณ์ของข่าวจากโมเดลภาษาขนาดใหญ่ได้อย่างครบถ้วนลึกซึ้ง พร้อมปุ่มบันทึกคั่นหน้าบทความ ดังแสดงในภาพที่ 16



ภาพที่ 16 หน้าต่างพรีวิวเนื้อหาข่าว In-App Reader และปุ่มสังเคราะห์สรุปด้วย AI

ก.3 แฟ้มเจาะลึกมหากาพย์ประเด็นข่าว Macro Storyline Dossier

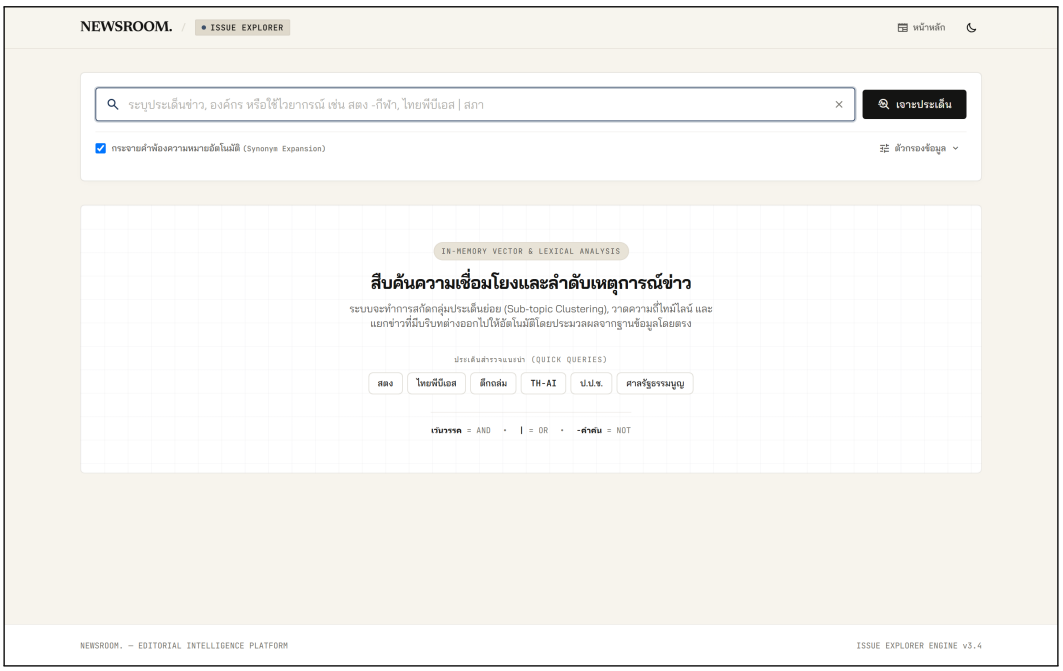
หน้าต่างแสดงผลแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่เชื่อมโยงเหตุการณ์ย่อยเข้าด้วยกัน นำเสนอภาพรวมสถานการณ์ ไทม์ไลน์วิวัฒนาการของเหตุการณ์ตามลำดับเวลา และตารางข้อเท็จจริงที่ได้รับการยืนยันตรงกันข้ามสำนักข่าว (Corroborated Facts) พร้อมรหัสอ้างอิงรายประโยคไปยังบทความต้นทาง ดังแสดงในภาพที่ 17



ภาพที่ 17 แฟ้มเจาะลึกมหากาพย์ประเด็นข่าวและไทม์ไลน์พัฒนาการเหตุการณ์

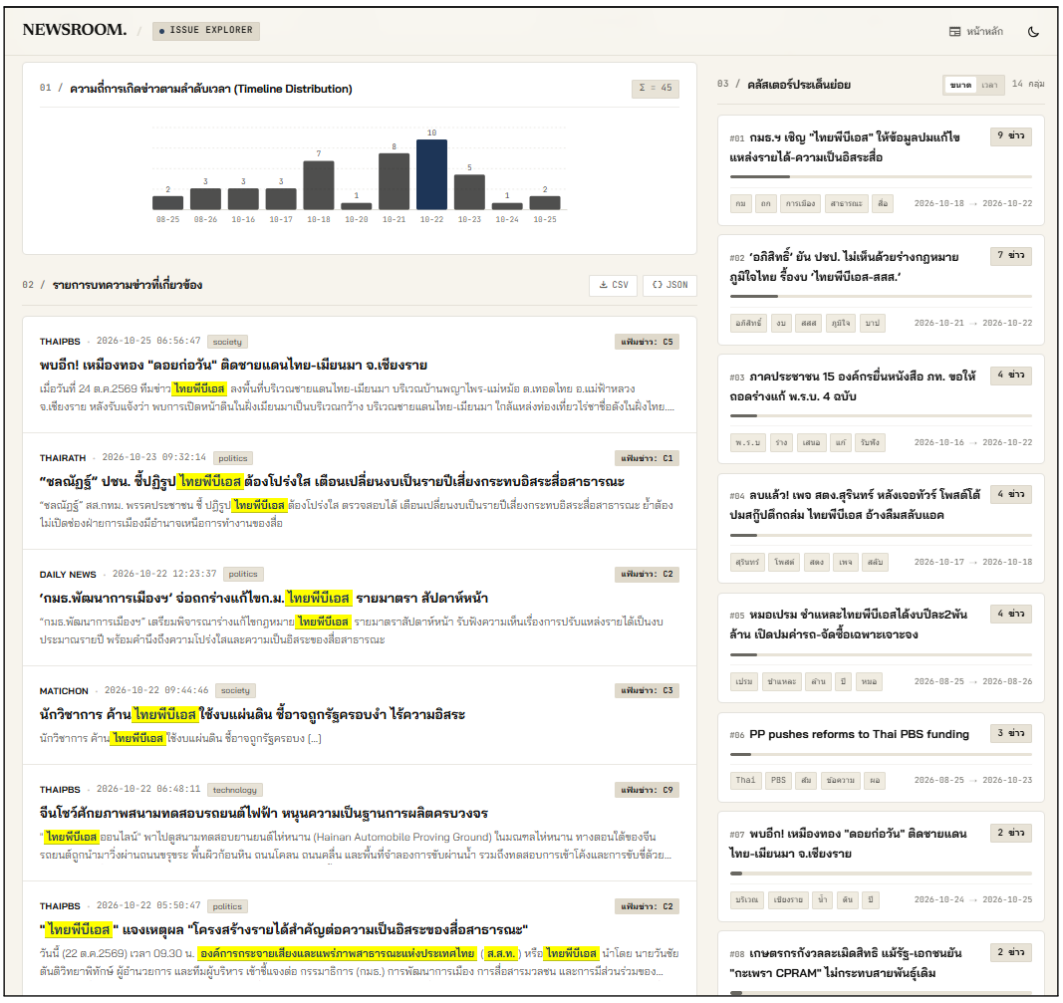
ก.4 สถานีเจาะประเด็นข่าวและสืบค้นเชิงวิเคราะห์ Issue Explorer

หน้าต่างสถานีเจาะประเด็นข่าวเชิงวิเคราะห์ (Issue Explorer Workstation) สำหรับผู้อ่านและนักวิเคราะห์ข่าว รองรับการสืบค้นด้วยไวยากรณ์บูลีนขั้นสูง มีระบบขยายคำพ้องความหมายและคำย่อหน่วยงานรัฐ พร้อมแสดงการแจกแจงมุมมองของแต่ละสำนักข่าวและตัวกรองคัดแยกข่าวหลุดประเด็น ดังแสดงในภาพที่ 18



ภาพที่ 18 สถานีเจาะประเด็นข่าวและสืบค้นเชิงวิเคราะห์ Issue Explorer

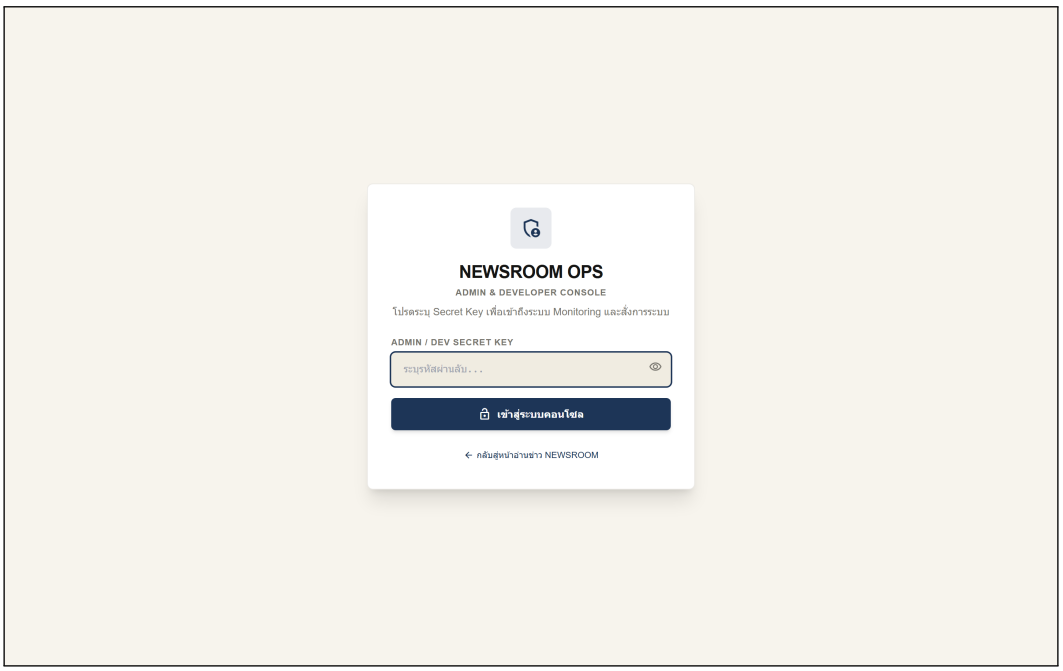
เมื่อผู้ใช้งานพิมพ์คำสำคัญเพื่อค้นหาในสถานีเจาะประเด็นข่าว ระบบจะทำการสืบค้นข้อมูลเชิงลึกแบบทันที พร้อมทั้งแสดงผลลัพธ์รายการข่าวที่เกี่ยวข้อง การแจกแจงมุมมองเชิงเปรียบเทียบของแต่ละสำนักข่าว และตัวกรองคัดแยกประเด็นที่ตรงกับเงื่อนไขการค้นหา ดังแสดงในภาพที่ 19



ภาพที่ 19 ผลลัพธ์การสืบค้นและคัดกรองประเด็นข่าวเชิงลึกบน Issue Explorer

ก.5 ศูนย์ควบคุมและตรวจสอบสถานะระบบ Ops Monitoring Console

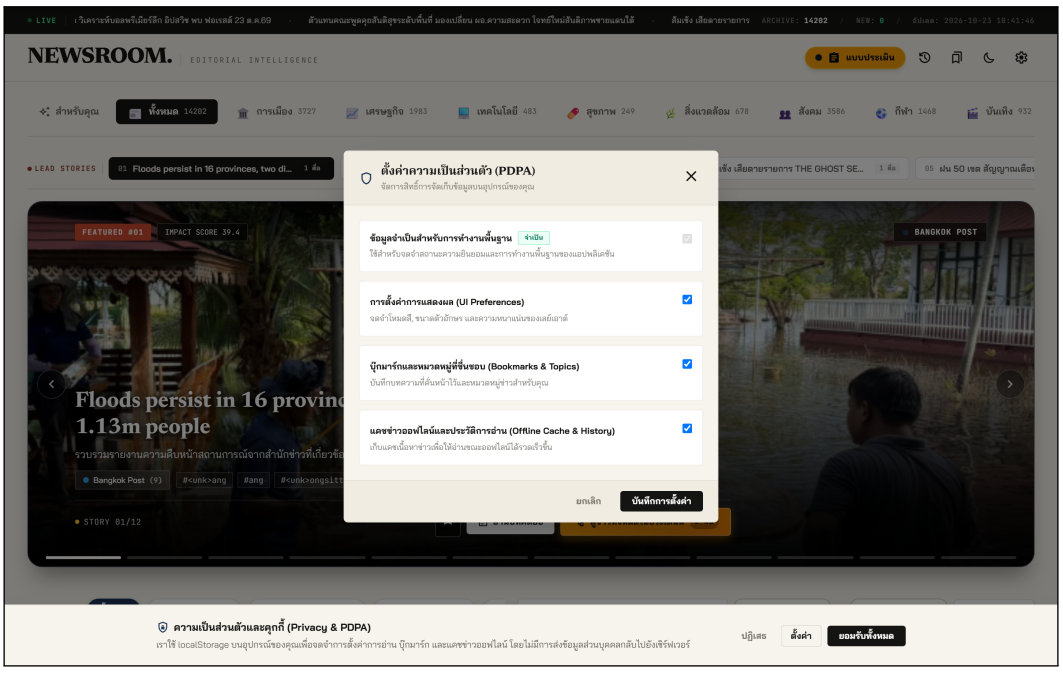
หน้าต่างคอนโซลควบคุมการทำงานของระบบสำหรับผู้ดูแลระบบ แสดงสถานะความพร้อมของบริการ สถิติอัตรา Throughput การดึงข่าว ปริมาณการใช้หน่วยความจำ RAM สถานะการทำงานของแคช พร้อมปุ่มคำสั่งเริ่มสเกรปข่าวด่วนทันที ปุ่มคำสั่งล้างแคชในหน่วยความจำและแคช HTTP และเครื่องมือทดสอบการดึงข้อมูลรายสำนักข่าว ดังแสดงในภาพที่ 20



ภาพที่ 20 ศูนย์ควบคุมและตรวจสอบสถานะระบบ Ops Monitoring Console

ก.6 หน้าต่างตั้งค่าสิทธิ์ความเป็นส่วนตัวและคุกกี้ Privacy Preferences

หน้าต่างจัดการสิทธิ์ความเป็นส่วนตัวและการใช้คุกกี้ตามพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) แสดงแถบขอความยินยอมคุกกี้ ตัวเลือกการเปิดหรือปิดใช้งานคุกกี้บันทึกความสนใจ และปุ่มสั่งล้างสถิติประวัติการอ่านออกจากหน่วยความจำของเว็บเบราว์เซอร์ได้ทันทีโดยสมบูรณ์ ดังแสดงในภาพที่ 21



ภาพที่ 21 หน้าต่างตั้งค่าสิทธิ์ความเป็นส่วนตัวและคุกกี้ตามมาตรฐาน PDPA

ก.7 หน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณ Personal Briefing

หน้าต่างปรับแต่งฟีดข่าวเฉพาะบุคคล (Personal Briefing Onboarding) สำหรับผู้ใช้งานที่ต้องการสร้างฟีดข่าวตามความสนใจ โดยเปิดให้เลือกหมวดหมู่ที่สนใจอย่างน้อย 3 หมวดหมู่จากทั้งหมด 9 หมวดหมู่ พร้อมระบบจัดอันดับข่าวบนอุปกรณ์ของผู้ใช้งานโดยตรง (On-device Edge Personalization) ภายใต้มาตรฐานการคุ้มครองข้อมูลส่วนบุคคล (PDPA) โดยไม่มีการส่งประวัติการอ่านหรือข้อมูลส่วนตัวกลับไปยังเซิร์ฟเวอร์ ดังแสดงในภาพที่ 22



ภาพที่ 22 หน้าต่างปรับแต่งฟีดข่าวเฉพาะคุณสำหรับการสร้างฟีดตามความสนใจ

ภาคผนวก ข
กรณีทดสอบการยอมรับของผู้ใช้

ตารางที่ 42 แสดงรายละเอียดขั้นตอนการทดสอบและผลลัพธ์ที่คาดหวังของกรณีทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing หรือ UAT) ทั้ง 15 กรณีทดสอบ (TC-01 ถึง TC-15) ซึ่งผู้ทดสอบใช้ประกอบการประเมินการทำงานของระบบตามข้อกำหนดในหัวข้อ 4.4

ตารางที่ 42 กรณีทดสอบการยอมรับของผู้ใช้

รหัส	กรณีทดสอบ	ขั้นตอนการทดสอบ	ผลที่คาดหวัง
TC-01	การดึงข่าวอัตโนมัติหลายสำนัก	1. เปิดการทำงานของเซิร์ฟเวอร์และระบบตั้งเวลาเบื้องหลัง 2. ส่งคำสั่งเริ่มรอบการดึงข่าวจากสำนักข่าวออนไลน์ 14 แห่ง 3. ตรวจสอบการทำงานของ Playwright Headless Browser และ HTTP Client	ระบบสามารถดึงข้อมูลข่าวสาร สกัดหัวข้อข่าว ลิงก์ รูปภาพ และเนื้อหาบทความได้ครบถ้วน โดยไม่เกิดข้อผิดพลาดในการเชื่อมต่อ
TC-02	การลงทะเบียนแหล่งข่าวแบบไดนามิก	1. เพิ่มฟังก์ชันสเกรปเปอร์ใหม่ในโมดูล scrapers พร้อมกำหนด Decorator @register_source 2. ระบุชื่อสำนักข่าว URL หน้าแรก และรหัสสีประจำสำนัก 3. รีสตาร์ตระบบและเรียกดูรายการสำนักข่าวผ่าน API	สำนักข่าวใหม่ปรากฏในรายการแหล่งข่าวทันที พร้อมสีประจำสำนักและพร้อมสำหรับรอบการดึงข่าวถัดไป
TC-03	การจำแนก 9 หมวดหมู่ภาษาไทย	1. ป้อนข้อความข่าวภาษาไทยตัวอย่างจากทั้ง 9 หมวดหมู่เข้าสู่ระบบ 2. ตรวจสอบกระบวนการตัดคำ การคัดกรองคำหยุด และการประมวลผลผ่าน 3-Tier Cascade Classifier 3. บันทึกผลการทำนายหมวดหมู่	ระบบจำแนกหมวดหมู่ข่าวได้ถูกต้องตรงตามเนื้อหา โดยใช้เวลาประมวลผลเฉลี่ยต่ำกว่า 5 มิลลิวินาทีต่อบทความ

ตารางที่ 42 กรณีทดสอบการยอมรับของผู้ใช้ (ต่อ)

รหัส	กรณีทดสอบ	ขั้นตอนการทดสอบ	ผลที่คาดหวัง
TC-04	การสรุปข่าวและวิเคราะห์อารมณ์	1. เลือกบทความข่าวที่มีความยาวมากกว่า 1,000 คำ 2. ส่งเนื้อหาไปยังบริการ KKU Gen.AI API เพื่อสรุปความและวิเคราะห์อารมณ์ 3. ตรวจสอบโครงสร้างผลลัพธ์ JSON ที่ได้รับ	ระบบสร้างบทสรุปความยาว 2–3 ประโยค ประเด็นสำคัญ 3 ข้อ และค่าอารมณ์ของข่าว (บวก ลบ เป็นกลาง) ได้อย่างถูกต้องตรงประเด็น
TC-05	การแสดงผลข่าวสดบน Bento Hub	1. เปิดหน้าเว็บ Bento Hub บนเว็บเบราว์เซอร์ 2. จำลองการมีข่าวใหม่เข้าสู่ระบบในเบื้องหลัง 3. ตรวจสอบการส่งสัญญาณผ่าน Socket.IO และการแสดงผลบนหน้าจอ	หน้าจอแสดงแถบแบนเนอร์แจ้งเตือนข่าวใหม่ลอยตัว และรายการข่าวสดอัปเดตบนหน้าจอทันทีโดยไม่ต้องกดรีเฟรชหน้าเว็บ
TC-06	การกรองข่าวและการสืบค้นคำสำคัญ	1. คลิกเลือกปุ่มหมวดหมู่ข่าว เช่น การเมือง หรือ เทคโนโลยี 2. คลิกเลือกกรองตามสำนักข่าวรายแห่ง 3. พิมพ์คำค้นหาในช่องสืบค้นแบบเรียลไทม์	การ์ดข่าวบนหน้าจอปรับเปลี่ยนแสดงเฉพาะข่าวที่ตรงกับหมวดหมู่ สำนักข่าว หรือมีคำค้นหาปรากฏในพาดหัวอย่างรวดเร็ว
TC-07	การอ่านพรีวิวเนื้อหาในตัวเว็บ	1. คลิกที่การ์ดข่าวเพื่อเปิดพรีวิวบทความ 2. ตรวจสอบการแสดงผลหน้าต่างโมดอล In-App Reader และปุ่มเปิดเว็บต้นฉบับ 3. ตรวจสอบความสะอาดของเนื้อหาพรีวิวและการสังเคราะห์สรุปจากบทความฉบับเต็ม	หน้าต่างโมดอลแสดงเนื้อหาพรีวิวบางส่วนเพื่อความปลอดภัยด้านลิขสิทธิ์ สะอาดตา ไร้โฆษณา มีลิงก์เปิดเว็บต้นฉบับ และสังเคราะห์สรุปเนื้อหาฉบับเต็มด้วย AI ได้สมบูรณ์

ตารางที่ 42 กรณีทดสอบการยอมรับของผู้ใช้ (ต่อ)

รหัส	กรณีทดสอบ	ขั้นตอนการทดสอบ	ผลที่คาดหวัง
TC-08	การบันทึกคั่นหน้าและประวัติการอ่าน	1. คลิกปุ่มบุ๊กมาร์กบนการ์ดข่าวที่สนใจ 2. เปิดอ่านบทความข่าวหลายชิ้น 3. เปิดแผงรายการคั่นหน้าและประวัติการอ่าน	รายการข่าวที่คั่นหน้าและประวัติการอ่านแสดงครบถ้วน โดยข้อมูลถูกบันทึกบน LocalStorage ในเบราว์เซอร์ของผู้ใช้
TC-09	การระบุประเด็นข่าวออนไลน์ 2 ชั้น	1. ป้อนข่าวรายงานเหตุการณ์เดียวกันที่เผยแพร่ห่างกัน 3 วันข้ามหลายสำนัก 2. ตรวจสอบการคำนวณเวกเตอร์ฝังตัว WangchanBERTa และการตรวจจับเอนทิตี 3. ตรวจสอบการจัดกลุ่มและการปรับปรุง Centroid ด้วย EMA	ข่าวทั้งหมดถูกรวมเข้าเป็นประเด็นข่าวเดียวกันภายใต้ Story ID เดิม ไม่เกิดปัญหาข่าวแตกกลุ่มข้ามวัน
TC-10	การจัดอันดับกระแสข่าวสาร 6 มิติ	1. ตรวจสอบการคำนวณคะแนนกระแสข่าวของประเด็นข่าวต่าง ๆ ผ่านสูตรสถิติ 6 มิติ 2. เปรียบเทียบประเด็นข่าวเหตุการณ์ด่วนกับข่าวประจำวัน เช่น พยากรณ์อากาศ 3. เรียกดูการแจกแจงคะแนนรายมิติ	ข่าวประจำวันถูกลดทอนคะแนนด้วย Routine Penalty อย่างถูกต้อง และประเด็นข่าวด่วนหลายสำนักได้รับการจัดอันดับนำหน้าอย่างโปร่งใส
TC-11	การเชื่อมโยงเส้นเรื่องมหาภาค	1. ป้อนประเด็นข่าวย่อยที่เกิดขึ้นต่อเนื่องในรอบเดือนเข้าสู่ระบบ 2. ตรวจสอบกฎการเชื่อมโยงข้ามเวลาและกฎ Province-Only Veto 3. ตรวจสอบโครงสร้างความสัมพันธ์ใน Macro Event	ประเด็นข่าวย่อยถูกผูกโยงเป็นมหากาพย์ตามลำดับเวลา และข่าวคนละเรื่องที่เกิดในจังหวัดเดียวกันถูกยับยั้งไม่ให้รวมกลุ่มกัน

ตารางที่ 42 กรณีทดสอบการยอมรับของผู้ใช้ (ต่อ)

รหัส	กรณีทดสอบ	ขั้นตอนการทดสอบ	ผลที่คาดหวัง
TC-12	แฟ้มสังเคราะห์ไทม์ไลน์และข้อเท็จจริง	1. เปิดหน้าต่าง Macro Storyline Dossier ของเหตุการณ์สำคัญ 2. ตรวจสอบไทม์ไลน์พัฒนาการของเหตุการณ์ตามลำดับเวลา 3. ตรวจสอบตารางข้อเท็จจริงที่ได้รับการยืนยันตรงกันข้ามสำนักข่าว	ไทม์ไลน์เรียงลำดับเวลาถูกต้อง และข้อเท็จจริงทุกข้อมีแหล่งข่าวยืนยันตรงกันตั้งแต่ 2 แหล่งขึ้นไป พร้อมรหัสอ้างอิงชัดเจน
TC-13	กลไกควบคุมความถูกต้อง 3 ระดับ	1. ป้อนชุดข่าวที่มีทั้งข่าวตรงประเด็นและข่าวหลุดประเด็นปะปนกัน 2. ตรวจสอบการทำงานของ Event Relevance Gate 3. ตรวจสอบการปฏิเสธการสังเคราะห์เมื่อพบข่าวหลุดประเด็น	ข่าวหลุดประเด็นถูกคัดแยกออก และระบบส่งเฉพาะข่าวที่เป็นพยานหลักฐานแท้จริงไปสังเคราะห์ ป้องกันข้อมูลเท็จได้อย่างสมบูรณ์
TC-14	ศูนย์ควบคุมสถานะและการล้างแคช	1. เข้าสู่หน้าต่าง Ops Monitoring Console ด้วยรหัสผ่านผู้ดูแลระบบ 2. กดปุ่มคำสั่งเริ่มสเกรปข่าวด่วนทันที (Scrape Now) 3. กดปุ่มคำสั่งล้างแคชระบบ (Clear Cache)	รอบการดึงข่าวเริ่มต้นทันที ข้อมูลแคชในหน่วยความจำและ HTTP ETag ถูกล้างอย่างสมบูรณ์ และหน้าคอนโซลแสดงสถานะอัปเดต
TC-15	การคุ้มครองข้อมูลส่วนบุคคล PDPA	1. เข้าสู่เว็บไซต์เป็นครั้งแรกและตรวจสอบแถบขอความยินยอมคุกกี้ 2. ตั้งค่าปฏิเสธคุกกี้บันทึกความสนใจ 3. กดปุ่มล้างสถิติความสนใจ (Clear Preference) ในหน้าต่างตั้งค่า	ระบบไม่บันทึกข้อมูลส่วนบุคคลที่ระบุตัวตนได้ สถิติความสนใจเดิมถูกลบออกจากเบราว์เซอร์ทันที และระบบทำงานได้อย่างสมบูรณ์

ภาคผนวก ค
แบบสอบถามความพึงพอใจของผู้ใช้

แบบประเมินนี้จัดทำขึ้นเพื่อเป็นส่วนหนึ่งของการศึกษาและประเมินผลสัมฤทธิ์ของโครงงานพัฒนาระบบรวบรวมและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific News Classification and NLP Analytics Pipeline) เพื่อประเมินความพึงพอใจ ประสิทธิภาพการใช้งาน และการยอมรับระบบของผู้ใช้งานจริง โดยระบบได้รับการเผยแพร่ให้ทดลองใช้งานผ่านเว็บแอปพลิเคชันจริงที่เว็บไซต์ https://e2enews.wittensky.com ภายใต้มาตรฐานการคุ้มครองข้อมูลส่วนบุคคล (PDPA) โดยไม่มีการเก็บรวบรวมข้อมูลส่วนบุคคลที่ระบุตัวตนของผู้ตอบแบบสอบถาม

คำชี้แจงฟังก์ชันการทำงานหลักของระบบที่ประเมิน

1) **ระบบดึงข่าวอัตโนมัติแบบเรียลไทม์ (News Aggregation)** รวบรวมข่าวสารจาก 14 สำนักข่าวชั้นนำในประเทศไทยอย่างต่อเนื่อง
2) **ระบบจำแนกหมวดหมู่ข่าวอัจฉริยะ (3-Tier Classification Engine)** จัดหมวดหมู่ข่าว 9 หมวดหมู่อัตโนมัติด้วย URL Pattern, กฎคำสำคัญทางภาษาศาสตร์ และ Machine Learning
3) **ระบบร้อยเรียงเหตุการณ์และจัดอันดับเทรนด์ (Story Identification & Trending)** ติดตามประเด็นข่าวต่อเนื่องข้ามวันและข้ามสำนักข่าว พร้อมเรียงลำดับไทม์ไลน์พัฒนาการของเหตุการณ์
4) **ระบบสรุปเนื้อหาด้วยปัญญาประดิษฐ์ (AI Summarization)** สรุปใจความสำคัญของข่าวสารได้อย่างกระชับ ตรงประเด็น และวิเคราะห์อารมณ์ของข่าว

ส่วนที่ 1 ข้อมูลทั่วไปของผู้ตอบแบบสอบถาม

1) **บทบาทหรืออาชีพหลักของผู้ตอบแบบสอบถาม**
   - ☐ นักเรียน หรือ นักศึกษา (Students)
   - ☐ วัยทำงาน ข้าราชการ หรือ พนักงานรัฐวิสาหกิจ (Working Professional / Government / Corporate Employee)
   - ☐ ผู้ประกอบการ หรือ นักลงทุน (Business Owner / Investor)
   - ☐ อื่น ๆ
2) **ช่องทางหลักที่ท่านใช้ติดตามข่าวสารในชีวิตประจำวัน (เลือกได้มากกว่า 1 ข้อ)**
   - ☐ สื่อสังคมออนไลน์ เช่น Facebook, X (Twitter), TikTok, Reddit
   - ☐ เว็บไซต์หรือแอปพลิเคชันของสำนักข่าวโดยตรง
   - ☐ แอปพลิเคชันรวบรวมข่าวสาร เช่น LINE TODAY, Google News
   - ☐ สื่อดั้งเดิม เช่น โทรทัศน์ วิทยุ หรือ หนังสือพิมพ์

ส่วนที่ 2 การประเมินฟังก์ชันการทำงานหลักของระบบ (Core Features Evaluation)

โปรดทำเครื่องหมาย ✓ ลงในช่องระดับความพึงพอใจที่ตรงกับความคิดเห็นของท่านมากที่สุด โดยมีเกณฑ์การประเมิน 5 ระดับ ได้แก่ 5 หมายถึง พึงพอใจมากที่สุด, 4 หมายถึง พึงพอใจมาก, 3 หมายถึง ปานกลาง, 2 หมายถึง ไม่ค่อยพึงพอใจ, และ 1 หมายถึง ไม่พึงพอใจเลย ดังแสดงในตารางที่ 43

ตารางที่ 43 แบบประเมินฟังก์ชันการทำงานหลักของระบบ

ข้อ	รายการประเมิน	ระดับความพึงพอใจ				
		5	4	3	2	1
1	ความหลากหลายของข่าว มีสำนักข่าวครอบคลุมและหลากหลายเพียงพอ (14 สำนักข่าว)					
2	ความแม่นยำในการจัดหมวดหมู่ ข่าวถูกจัดลง 9 หมวดหมู่อย่างถูกต้องตรงตามเนื้อหา					
3	คุณภาพการสรุปข่าวด้วย AI สรุปเนื้อหากระชับ ตรงประเด็น และไม่บิดเบือนสาระสำคัญ					
4	ความเร็วในการประมวลผลสรุปเนื้อหา ฟังก์ชันสรุปข่าวทำงานรวดเร็วในระดับพึงพอใจ					
5	ความสดใหม่ของข้อมูล ข่าวแสดงผลและอัปเดตต่อเนื่องแบบ Real-time					
6	การพรีวิวอ่านบทคัดย่อในแอป และการเปิดอ่านข่าวเต็มบนเว็บต้นฉบับสะดวกและปลอดภัย					

ส่วนที่ 3 ความพึงพอใจโดยรวมและการบอกต่อ (Overall Satisfaction & Advocacy)

7) **ฟังก์ชันการทำงานใดที่คุณชื่นชอบหรือรู้สึกว่ามีประโยชน์มากที่สุดในแอปพลิเคชันนี้**
   - ☐ ปุ่มสรุป AI ทันทีในบทความข่าว
   - ☐ การรวม 14 สำนักข่าวชั้นนำของไทยไว้ที่เดียว
   - ☐ การอ่านพรีวิวไม่หลุดหน้าเว็บไปยังต้นทางเว็บข่าว (In-App Clean Reader)
   - ☐ ปุ่ม AI ร้อยเรียงเรื่องราวจากหลายสำนักข่าว (Storyline Dossier)
   - ☐ อื่น ๆ
8) **ระดับความพึงพอใจต่อการออกแบบและประสบการณ์การอ่าน (UI/UX)** ความสะดวกในการใช้งาน ความชัดเจนของปุ่มและเมนูนำทาง (ให้คะแนนตั้งแต่ 1 หมายถึง ไม่พึงพอใจเลย ถึง 5 หมายถึง พึงพอใจมากที่สุด)
9) **ระดับความพึงพอใจโดยรวมต่อระบบ NEWSROOM** (ให้คะแนนตั้งแต่ 1 หมายถึง ไม่พึงพอใจเลย ถึง 5 หมายถึง พึงพอใจมากที่สุด)
10) **แนวโน้มที่จะแนะนำแอปพลิเคชันนี้ให้เพื่อนร่วมงานหรือคนรอบข้างใช้งาน** (สเกลคะแนน Net Promoter Score ตั้งแต่ 0 หมายถึง ไม่มีแนวโน้มเลย ถึง 7 หมายถึง มีแนวโน้มอย่างยิ่ง)
11) **ปัญหา อุปสรรค หรือข้อผิดพลาดที่พบระหว่างการทดสอบใช้งาน**

12) **สิ่งที่อยากให้พัฒนาเพิ่มเติม หรือฟังก์ชันที่อยากให้มีในเวอร์ชันถัดไป**

ประวัติผู้เขียน

ชื่อ-นามสกุล นายนราวิชญ์ ศิริพล

วัน เดือน ปีเกิด 1 มิถุนายน พ.ศ. 2547

สถานที่เกิด จังหวัดมหาสารคาม

ประวัติการศึกษา

1) พ.ศ. 2565 มัธยมศึกษาตอนปลาย โรงเรียนสาธิตมหาวิทยาลัยมหาสารคาม (ฝ่ายมัธยม)
2) พ.ศ. 2566–ปัจจุบัน วิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ทุนการศึกษาและรางวัลที่ได้รับ

1) ผ่านการคัดเลือกรอบแรก 16 ทีม และเตรียมความพร้อมเข้าร่วมแข่งขัน BDI Young Innovator Hackathon ชิงถ้วยพระราชทาน สมเด็จพระกนิษฐาธิราชเจ้า กรมสมเด็จพระเทพรัตนราชสุดา ฯ สยามบรมราชกุมารี ระหว่างวันที่ 3 – 5 กรกฎาคม 2569 ณ อุทยานวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น จังหวัดขอนแก่น
2) รางวัล Grand Champion Award โครงการ OIT-KKU International Project-Based Learning Program 2026 Game Jam Workshop

ชื่อ-นามสกุล นายอัสดาวุฒิ เอื้อวงค์

วัน เดือน ปีเกิด 29 กรกฎาคม พ.ศ. 2547

สถานที่เกิด จังหวัดมหาสารคาม

ประวัติการศึกษา

1) พ.ศ. 2565 มัธยมศึกษาตอนปลาย โรงเรียนบรบือวิทยาคาร
2) พ.ศ. 2566–ปัจจุบัน วิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ทุนการศึกษาและรางวัลที่ได้รับ

1) ได้รับเหรียญทอง การประกวดโครงงาน สาขาคอมพิวเตอร์ ประเภทโปสเตอร์ ในการประชุมวิชาการโครงการห้องเรียนพิเศษวิทยาศาสตร์ คณิตศาสตร์ เทคโนโลยีและสิ่งแวดล้อม(SMTE) กลุ่มภาคตะวันออกเฉียงเหนือตอนบน ครั้งที่ 14 ประจำปีการศึกษา 2565 ระหว่างวันที่ 6–7 สิงหาคม 2565
2) ได้รับรางวัลชมเชย จากการประกวดโครงงาน ระดับมัธยมศึกษาตอนปลาย สาขาวิทยาการคอมพิวเตอร์ เนื่องในงานสัปดาห์วิทยาศาสตร์แห่งชาติ มหาวิทยาลัยขอนแก่น ประจำปี 2565 ณ วันที่ 18 สิงหาคม 2565