

CS3-7

รายงานทางความก้าวหน้าโครงการ ครั้งที่ 1

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท

Category-Specific News Classification and NLP Analytics
Pipeline

โดย

663380214-4 นายณรวิชัย ศิริพล

663380028-1 นายอัสดาวุฒิ เอื้อวงศ์

อาจารย์ที่ปรึกษา

อ.ดร.พบพร ด้านวิรุทย์

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา

วิชา CP354 772 โครงการคอมพิวเตอร์ 2

หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

ปีการศึกษา 2569

นราวิชญ์ ศิริพล และ อัสตาวุฒิ เอื้อวงศ์. 2569. ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติ ด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท. โครงการคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.พพพร ด้านวิรัช

บทคัดย่อ

โครงการนี้มีวัตถุประสงค์เพื่อศึกษา ออกแบบ และพัฒนาระบบ จำแนกและวิเคราะห์ ข่าวสารอัตโนมัติ ด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะ ประเภท (Category-Specific News Classification and NLP Analytics Pipeline) ที่ครอบคลุมการทำงานตั้งแต่ การรวบรวมข่าวสารจากหลายสำนักข่าว การสกัดเนื้อหา การสรุปความ การจำแนกหมวดหมู่ การวิเคราะห์แนวโน้มความนิยม และการนำเสนอข้อมูลแบบเรียลไทม์ โดยสถาปัตยกรรมระบบได้ รับการออกแบบตามหลักการ SOLID และ GRASP แบ่งการทำงานเป็นเลเยอร์อย่างเป็นระเบียบ ส่วนบริการเบื้องหลัง (Backend) พัฒนาด้วยภาษา Python และ FastAPI รองรับการดึงข้อมูล ทั้งจาก RSS Feed และการสกรีนหน้าเว็บผ่าน Playwright Headless Browser พร้อมระบบ แคชแบบหลายระดับ (Multi-tier Caching: หน่วยความจำและ HTTP 304) เพื่อลดภาระการ เชื่อมต่อ การสรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าว (Sentiment) ทำงานร่วมกับโมเดลภาษา ขนาดใหญ่ (LLM) ผ่าน KGU Gen.AI API ขณะที่การจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวด หมู่หลักใช้แนวทางไฮบริดผสานกฎค่าสำคัญเชิงบริบท (Rule-based Cues) ร่วมกับโมเดลการ เรียนรู้ของเครื่อง (SVM/TF-IDF และ WangchanBERTa) ส่วนติดต่อผู้ใช้ (Frontend) พัฒนาด้วย รูปแบบ Single Page Application (SPA) ด้วย Vanilla JavaScript แบบ ES Modules และ Tailwind CSS สื่อสารกับเซิร์ฟเวอร์แบบเรียลไทม์ผ่าน WebSocket (Socket.IO) พร้อมฟังก์ชัน หน้าต่างอ่านข่าวในระบบ (In-app Reader Modal) และระบบแนะนำข่าวสารตามความสนใจ เฉพาะบุคคลโดยคำนึงถึงความเป็นส่วนตัวตามมาตรฐาน PDPA จากผลการประเมินการทำงาน พบว่าระบบสามารถทำงานได้อย่างมีประสิทธิภาพ ตอบสนองคำขอรวดเร็ว และช่วยลดเวลาในการ ติดตามข่าวสารจากหลากหลายแหล่งได้อย่างมีประสิทธิภาพ

คำสำคัญ: การจำแนกข่าว, การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เว็บส แครปปีง, โมเดลภาษาขนาดใหญ่, อัลกอริทึมแนะนำข่าว

Narawit Siripol and Ausadawut Aueawong. 2026. **Category-Specific News Classification and NLP Analytics Pipeline**. Computer Project, Bachelor of Science, Program in Computer Science, College of Computing, Khon Kaen University.
Project Advisor: Dr. Pobporn Danvirutai

ABSTRACT

This project aims to study, design, and develop an automated Category-Specific News Classification and NLP Analytics Pipeline. The system covers an end-to-end workflow including multi-source news aggregation, content extraction, summarization, category classification, trend analytics, and real-time delivery. The architecture is engineered according to SOLID and GRASP software design principles with clearly decoupled layers. The backend is implemented in Python using FastAPI, supporting automated extraction from both standard RSS feeds and dynamic JavaScript-heavy websites via a Playwright headless browser instance. A multi-tier caching strategy (combining in-memory LRU caching and HTTP 304 conditional cache) is employed to minimize network overhead and redundant processing. For content summarization and sentiment analysis, the system integrates with Large Language Models (LLMs) via the KKU Gen.AI API to generate concise summaries, bullet points, and sentiment scores in the article's native language. Thai text classification into nine specialized categories is executed through a hybrid pipeline combining contextual keyword-based cues with machine learning models (TF-IDF with SVM and WangchanBERTa). The frontend is built as a responsive Single Page Application (SPA) using Vanilla JavaScript ES modules and Tailwind CSS, communicating bidirectionally with the server via WebSocket (Socket.IO). It provides an in-app modal reader, trending topic visualization, and privacy-compliant personalized recommendations based on aggregate engagement metrics under PDPA standards. The evaluation results demonstrate that the pipeline operates with high stability, low latency, and significantly reduces the effort required for readers to follow diverse news outlets.

Keywords: News classification, Text analytics, Natural language processing, Web scraping, Large language model, Recommendation algorithm

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อ.ดร.พพร ด้านวิรุฑย์ อาจารย์ที่ปรึกษาโครงการ ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงการฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงการนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอขอบพระคุณ คณาจารย์ในสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่นทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงการนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจ ตลอดระยะเวลาของการศึกษา

ผู้จัดทำ
นราวิชญ์ ศิริพล
อัสตาดุฒิ เอื้อวงศ์

สารบัญ

บทคัดย่อ	ก
ABSTRACT	ข
กิตติกรรมประกาศ	ค
สารบัญ	ง
สารบัญภาพ	ช
สารบัญตาราง	ซ
1 บทนำ	1
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์	1
1.3 ขอบเขตและข้อจำกัดของระบบ	2
1.3.1 ขอบเขต	2
1.3.2 ข้อจำกัดของโครงการ	3
1.4 ประโยชน์ที่คาดว่าจะได้รับ	4
2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	5
2.1 ทฤษฎีที่เกี่ยวข้อง	5
2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ	5
2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่	5
2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF	6
2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (Wangchan-BERTa)	6
2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว	7
2.2 งานวิจัยที่เกี่ยวข้อง	7
2.2.1 งานสกัดเนื้อหาบทความจากเว็บ	7
2.2.2 งานสรุปข้อความอัตโนมัติ	7
2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย	8
2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms)	8
2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)	8

2.2.6	สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง	9
2.3	เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales)	9
2.3.1	FastAPI	9
2.3.2	Pydantic	9
2.3.3	Playwright (Chromium Headless Browser)	10
2.3.4	PyThaiNLP	10
2.3.5	Socket.IO	10
2.3.6	ระบบจำลองเบราว์เซอร์แยกส่วนและเทคโนโลยี Obscura (Isolated Obscura CDP Engine)	10
2.3.7	ระบบจัดเก็บข้อมูลตามหลัก SOLID/GRASP (NewsRepositoryPort)	10
2.3.8	ระบบแคชหลายระดับ (Multi-tier Cache Strategy)	11
3	วิธีการดำเนินโครงการ	12
3.1	การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส	12
3.1.1	ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing)	12
3.1.2	วิธีการฝึกสอนโมเดล (Model Training Methodology)	12
3.1.3	ผลการประเมินประสิทธิภาพและเมตริกวัดผล	12
3.1.4	เมตริกซ์ความสับสน (Confusion Matrix)	13
3.1.5	ระเบียบวิธีการประเมินความแม่นยำของการจัดกลุ่มข่าวข้ามสำนัก (Multi-Source Story Clustering Evaluation)	13
3.1.6	แบบจำลองยูสเคส (Use Case Diagram)	14
3.2	เครื่องมือที่ใช้ในการดำเนินงาน	14
3.2.1	ฮาร์ดแวร์	14
3.2.2	ซอฟต์แวร์	15
3.3	แผนการดำเนินงาน	17
4	การวิเคราะห์ ออกแบบและพัฒนาระบบ	18
4.1	การวิเคราะห์ระบบ	18
4.1.1	ผังแสดงทิศทางของกิจกรรม (Activity Flow)	18
4.1.2	แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram)	20
4.1.3	รายการความต้องการของระบบ	20
4.2	การออกแบบระบบ	22
4.2.1	สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture)	22
4.2.2	การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล	23
4.3	การพัฒนาระบบและการทำงานของส่วนประกอบหลัก	24
4.3.1	กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)	24
4.3.2	ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)	25

4.3.3	ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และ เอนจินจำลองเบราร์เซอร์ Obscura	25
4.3.4	ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)	25
4.3.5	อัลกอริทึมแนะนำข่าวและจัดอันดับความนิยม (Trending & Hot News Algorithm)	25
4.3.6	กระบวนการจัดกลุ่มข่าวจากหลายสำนักข่าวเป็นประเด็น เดียวกัน (Multi-Source Story Clustering Pipeline) . . .	28
4.3.7	การแก้ไขความขัดแย้งของหมวดหมู่ข่าวและการหาฉันทา มติระดับกลุ่ม (Cluster-Level Category Consensus) . . .	29
4.3.8	การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket	30
4.4	การออกแบบและมาตรการความมั่นคงปลอดภัยของระบบ (System Security Design)	30
4.4.1	ความ มั่นคง ปลอดภัย ระดับ เครือข่าย และ เว็บ เซิร์ฟเวอร์ (Network & Gateway Security)	30
4.4.2	การ ป้องกัน การฉีดยา ภัยคุกคาม และการ ตรวจสอบ ข้อมูล (Data Sanitization & Injection Defense)	30
4.4.3	การ คัดกรอง ข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security)	31
4.4.4	การจัดการความลับและการตั้งค่าระบบ (Secrets & Con- figuration Management)	31
4.5	การทดสอบระบบ	31
4.5.1	การทดสอบอัตโนมัติ (Automated Test Suite)	31
4.5.2	ผล การทดสอบ การยอมรับของผู้ใช้ (User Acceptance Testing)	32
5	สรุปผลการดำเนินงาน	33
5.1	สรุปผลการดำเนินโครงการ	33
5.2	ข้อจำกัดของระบบ	33
5.2.1	ข้อจำกัดด้านแหล่งข้อมูลภายนอก	33
5.2.2	ข้อจำกัดด้านทรัพยากรและการประมวลผล	34
5.3	ปัญหา อุปสรรค และแนวทางแก้ไข	34
5.4	ข้อเสนอแนะในการพัฒนาต่อไป	34
5.4.1	การปรับปรุงฟังก์ชันการทำงาน	34
5.4.2	แนวทางการวิจัยต่อยอด	35
	เอกสารอ้างอิง	36
	ภาคผนวก ก: คู่มือการติดตั้งและการใช้งานระบบ	39
	ภาคผนวก ข: ข้อกำหนด REST API และ WebSocket Events	41

สารบัญภาพ

ภาพที่ 1	แผนภาพแบบจำลองยูสเคสของระบบ (Use Case Diagram)	14
ภาพที่ 2	แผนภาพแสดงทิศทางการกิจกรรมของระบบ (Activity Diagram)	19
ภาพที่ 3	แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram) . . .	20
ภาพที่ 4	แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architec- ture Diagram)	22

สารบัญตาราง

ตารางที่ 1	เปรียบเทียบงานวิจัยที่เกี่ยวข้อง	9
ตารางที่ 2	เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set)	13
ตารางที่ 3	เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k)	13
ตารางที่ 4	รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา	15
ตารางที่ 5	รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions)	16
ตารางที่ 6	แผนการดำเนินงานและไทม์ไลน์ของโครงการ (Gantt Chart)	17
ตารางที่ 7	ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements)	21
ตารางที่ 8	การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers)	23
ตารางที่ 9	โครงสร้างข้อมูลบทความข่าว (NewsArticle Schema)	24
ตารางที่ 10	สรุปผลการเปรียบเทียบการคำนวณคะแนน Trending ระหว่างข่าวสด ใหม่และข่าวเก่า	28
ตารางที่ 11	ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing)	32
ตารางที่ 12	สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์	33
ตารางที่ 13	ปัญหา อุปสรรค และแนวทางการแก้ไข	34
ตารางที่ 14	รายละเอียด REST API Endpoints ของระบบ	41
ตารางที่ 15	รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time	41

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน ข่าวสารเป็นข้อมูลสำคัญที่ช่วยให้ประชาชนรับรู้และติดตามเหตุการณ์ได้อย่างทันทั่วถึง โดยเฉพาะอย่างยิ่งในยุคที่ข้อมูลมีการเปลี่ยนแปลงตลอดเวลา อย่างไรก็ตาม ผู้อ่านที่ต้องการติดตามข่าวสารจากหลายแหล่งมักประสบปัญหาหลายประการ ได้แก่ ต้องเปิดเว็บไซต์หรือแอปพลิเคชันหลายแห่งเพื่อเปรียบเทียบข่าวเดียวกัน ทำให้เสียเวลาและเกิดความยุ่งยากในการติดตามสถานการณ์ที่เปลี่ยนแปลงอย่างรวดเร็ว นอกจากนี้ ข่าวแต่ละฉบับยังมีเนื้อหายาวและมีข้อมูลจำนวนมาก ทำให้ผู้อ่านต้องใช้เวลาในการอ่านเพื่อสกัดประเด็นสำคัญ รวมถึงยังต้องอ่านข่าวจากแหล่งภาษาอังกฤษเพื่อให้ได้มุมมองที่หลากหลาย อีกทั้งข่าวสารที่มีปริมาณมากและหลากหลายหมวดหมู่ยังทำให้การคัดกรองและวิเคราะห์ข่าวเป็นเรื่องท้าทาย

การนำเทคโนโลยีเว็บสแครปปิง (Web Scraping) และ RSS Feed มาใช้ในการดึงข้อมูลข่าวจากเว็บไซต์ข่าวอัตโนมัติ ตลอดจนการใช้เทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ในการจำแนกหมวดหมู่ข่าวตามประเภท และการใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ในการสรุปเนื้อหา จะช่วยลดภาระของผู้อ่านในการเปิดหลายเว็บไซต์และอ่านบทความฉบับเต็ม อีกทั้งยังสามารถนำเสนอข้อมูลสำคัญที่คัดสรรและวิเคราะห์แล้วแบบเรียลไทม์ได้ในทีเดียว

จากปัญหาดังกล่าว โครงการนี้จึงมีแนวคิดในการพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) โดยระบบจะทำการดึงข่าวจากแหล่งข่าวเป็นระยะแบบอัตโนมัติ จำแนกหมวดหมู่ข่าวด้วยเทคนิค NLP และโมเดลแมชชีนเลิร์นนิง สรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ และแสดงผลข่าวพร้อมการวิเคราะห์บนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket เพื่อให้ผู้ใช้สามารถติดตามข่าวสารได้อย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

1.2 วัตถุประสงค์

- 1) เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวจากเว็บไซต์ข่าวด้วยวิธีเว็บสแครปปิง และการอ่าน RSS Feed รวมถึงเทคนิคการประมวลผลภาษาธรรมชาติสำหรับการจำแนกหมวดหมู่ข่าวตามประเภท
- 2) เพื่อออกแบบและพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) ครอบคลุมการดึงข่าว การจำแนกหมวดหมู่ การสรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ อัลกอริทึมแนะนำข่าว และการแสดงผลแบบเรียลไทม์
- 3) เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องของการจำแนกหมวดหมู่ข่าว ความถูกต้องของการสรุปข่าว ความแม่นยำของอัลกอริทึมแนะนำข่าว

และความสามารถในการแสดงผลข่าวแบบเรียลไทม์

1.3 ขอบเขตและข้อจำกัดของระบบ

1.3.1 ขอบเขต

ระบบเป็นเว็บแอปพลิเคชันแบบเต็มรูปแบบ (Full-stack) ที่มีขอบเขตการทำงาน ดังนี้

- 1) **การรวบรวมข่าวอัตโนมัติ:** ระบบสามารถดึงข่าวจากแหล่งข่าวออนไลน์หลายแห่ง โดยใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed และการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์ที่ใช้ JavaScript
- 2) **การสรุปข่าวและวิเคราะห์อารมณ์:** ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้โมเดลภาษาขนาดใหญ่ผ่าน API ของมหาวิทยาลัยขอนแก่น (KKU Gen.AI) เพื่อสร้างบทสรุป ประเด็นสำคัญ อารมณ์ของข่าว (Sentiment) และคำสำคัญ โดยสรุปเป็นภาษาเดียวกับต้นฉบับข่าว
- 3) **การจำแนกหมวดหมู่ข่าว 9 หมวดหมู่หลัก:** ระบบจำแนกข่าวออกเป็น 9 หมวดหมู่หลัก ได้แก่ การเมือง (politics), เศรษฐกิจ (economy), เทคโนโลยี (tech), สุขภาพ (health), สิ่งแวดล้อม (environment), กีฬา (sports), บันเทิง (entertainment), สังคม (society) และต่างประเทศ (world) โดยใช้การตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับโมเดลการเรียนรู้ของเครื่องแบบหลายชั้น (3-Tier Cascade Classifier: Rule Cues, Calibrated LinearSVC และ WangchanBERTa)
- 4) **การจัดเก็บและวงจรชีวิตของข้อมูล (Data Lifecycle & Retention):** ข้อมูลข่าวและผลการวิเคราะห์ทั้งหมด จะถูกจัดเก็บ รวบรวมอย่างต่อเนื่องนับตั้งแต่วันที่ Instance Server เริ่มทำงาน (Instance Startup Date) โดยจัดเก็บไว้ใน Docker Container และ Local Storage บนเครื่องแม่ข่าย AWS EC2
- 5) **การจัดกลุ่มประเด็นข่าวหลายสำนัก (Multi-Source Story Clustering):** ระบบสามารถตรวจจับ เปรียบเทียบความคล้ายคลึง และจัดกลุ่มบทความข่าวจากหลายสำนักข่าว ที่มีเนื้อหาเกี่ยวกับเหตุการณ์เดียวกันภายในกรอบเวลาไม่เกิน 36 ชั่วโมงเข้าเป็นกลุ่มประเด็นเดียวกัน (Story Cluster) เพื่อป้องกันการแสดงข่าวซ้ำซ้อน
- 6) **การคัดเลือกข่าวตัวแทนและการหาฉันทามติหมวดหมู่ระดับกลุ่ม (Cluster Representative & Category Consensus):** ในแต่ละกลุ่มข่าว ระบบจะคัดเลือกบทความที่มีคะแนนความนิยม (TrendingScore) สูงสุดขึ้นมาเป็นตัวแทนบทความหลักในการแสดงผล พร้อมแสดงตัวบ่งชี้จำนวนสำนักข่าวที่รายงานร่วมกัน และกำหนดหมวดหมู่ของกลุ่มข่าวด้วยหลักการมติเสียงข้างมาก (Majority Voting) เพื่อแก้ไขปัญหาความไม่สอดคล้องของหมวดหมู่ข่าวข้ามสำนักพิมพ์
- 7) **ขอบเขตความเป็นส่วนตัวและการไหลของข้อมูลผู้ใช้ (User Privacy & Data Flow):** ระบบบันทึกเฉพาะรหัสเซสชันแบบไม่ระบุตัวตน (Anonymous Cookie ID) และสถิติพฤติกรรมการอ่านข่าวแบบภาพรวม (Non-PII Aggregate Engagement: การคลิกเปิดอ่าน, การขยายอ่านบทสรุป, การบุ๊กมาร์ก) บนเบราว์เซอร์ของผู้ใช้เพื่อส่งมาคำนวณคะแนนความนิยม โดยไม่มีการจัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (PII)

เช่น ชื่อ-นามสกุล อีเมล หรือหมายเลข IP และไม่มีการส่งต่อข้อมูลพฤติกรรมผู้ใช้ไปยังโมเดลภาษาขนาดใหญ่ภายนอกหรือบุคคลภายนอกใด ๆ

- 8) **การแสดงผลแบบเรียลไทม์:** ระบบแสดงรายการข่าวบนเว็บแอปพลิเคชันพร้อมสรุปเนื้อหา ภาพประกอบ และหมวดหมู่ และแจ้งเตือนข่าวใหม่ทันทีผ่าน WebSocket (Socket.IO) โดยไม่ต้องรีเฟรชหน้าเว็บ
- 9) **การอ่านข่าวในตัวเว็บ (In-app Reader Modal):** ระบบมีหน้าต่างแสดงผลบทความข่าวและบทวิเคราะห์ในตัวเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้อ่านข่าวได้อย่างต่อเนื่องโดยไม่ต้องเปิดแท็บใหม่
- 10) **การจัดเก็บข้อมูลและสถาปัตยกรรมแบบแยกชั้น:** ระบบจัดเก็บข้อมูลข่าวและสถิติการใช้งานในรูปแบบ JSON บนเครื่องเซิร์ฟเวอร์ ออกแบบตามหลัก SOLID/GRASP ด้วย Port/Adapter Pattern
- 11) **การ ตั้ง ค่า และ ความ ยืดหยุ่น:** ระบบ รองรับ การ เพิ่ม แหล่ง ข่าว ใหม่ ได้ โดยไม่ต้องแก้ไขโครงสร้างหลัก ผ่าน การ ลง ทะเบียน Source ด้วย Decorator (@register_source)
- 12) **ระบบแคชหลายระดับ (Multi-tier Cache):** ระบบมีกลไกจัดเก็บข้อมูลข่าวและเนื้อหาในหน่วยความจำ (AsyncInMemoryCache) ร่วมกับแคชแบบมีเงื่อนไข (HTTP 304 Conditional Cache) เพื่อลดการดึงข้อมูลซ้ำและเพิ่มความรวดเร็วในการแสดงผล
- 13) **การ รองรับ Progressive Web App (PWA):** รองรับ การ ทำงาน แบบ เว็บ แอปพลิเคชัน ก้าวหน้า พร้อม Service Worker สำหรับ การ แคช หน้า เว็บ เพื่อความรวดเร็ว

1.3.2 ข้อจำกัดของโครงการ

- 1) **ข้อจำกัดด้านทรัพยากรฮาร์ดแวร์และการติดตั้งใช้งาน:** ระบบถูกออกแบบและปรับแต่งให้รองรับภาระงานได้ตามขีดความสามารถของเครื่องแม่ข่าย AWS EC2 อินสแตนซ์ประเภท `c7i-flex.large` (2 vCPU, หน่วยความจำหลัก RAM ขนาด 4 GiB และ Swap Buffer ขนาด 4 GB) ซึ่งอาจมีข้อจำกัดในการรองรับผู้ใช้งานพร้อมกันจำนวนมาก (Concurrent Users) หรือการรันเบราว์เซอร์ Playwright จำนวนหลายอินสแตนซ์พร้อมกัน
- 2) **ข้อจำกัดของชุดข้อมูลฝึกสอนโมเดล (Training Dataset Constraints):** โมเดลการเรียนรู้ของเครื่องสำหรับการจำแนกหมวดหมู่ข่าวได้รับการฝึกสอนและประเมินผลบนชุดข้อมูลจำกัดจากคลังข้อมูล ThaiSum และ Prachathai-67k ซึ่งอาจมีความครอบคลุมของคำศัพท์เฉพาะกลุ่มหรือโครงสร้างภาษาตามลักษณะของแหล่งข่าวดังกล่าว
- 3) **ความหลากหลายของการพาดหัวข่าวและแท็กหมวดหมู่ข้ามสำนักพิมพ์:** ข่าวเหตุการณ์เดียวกันจากต่างสำนักข่าวอาจมีการพาดหัวคนละมุมมอง หรือมีโครงสร้าง URL และ Tag หมวดหมู่ที่แตกต่างกัน ซึ่งระบบแก้ไขด้วยการใช้ฟิเจอร์แบบไฮบริด

(หัวข้อ, เนื้อหาย่อ, คำสำคัญ, เอนทิตี) และการหาฉันทามติของหมวดหมู่ในระดับกลุ่มข่าว (Cluster-Level Category Consensus)

- 4) ระบบรองรับการสรุปและแสดงผลข่าวในภาษาไทยและภาษาอังกฤษเท่านั้น ตามภาษาเดิมของเนื้อหาข่าวแต่ละฉบับ
- 5) โครงสร้าง HTML หรือ RSS Feed ของเว็บไซต์แหล่งข่าวอาจเปลี่ยนแปลงได้ ทำให้ระบบต้องได้รับการปรับปรุงให้สอดคล้อง
- 6) การสรุปข่าวต้องอาศัยการเชื่อมต่ออินเทอร์เน็ตและ API ของโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) หากบริการขัดข้องหรือหมดโควตาการใช้งาน ระบบจะทำงานในโหมดข้อความสรุปตั้งต้นแทน
- 7) รอบแรกของการดึงข่าวอาจใช้เวลา 2-5 นาที เนื่องจากต้องดึงเนื้อหาบทความของแต่ละข่าวเพื่อใช้ในการสรุป

1.4 ประโยชน์ที่คาดว่าจะได้รับ

- 1) ได้ระบบเว็บแอปพลิเคชันจำแนกและวิเคราะห์ข่าวสารอัตโนมัติแบบเรียลไทม์ ที่ช่วยให้ผู้ใช้ติดตามข่าวสารจากหลายแหล่งได้ในที่เดียวอย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล
- 2) ได้แนวทางในการประยุกต์ใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed โมเดลภาษาขนาดใหญ่ อัลกอริทึมการกำหนดคูกี้เพื่อการปรับแต่งเฉพาะบุคคล และอัลกอริทึมแนะนำข่าว เพื่อสร้างระบบวิเคราะห์ข้อมูลข่าวอัตโนมัติ ซึ่งสามารถนำไปพัฒนาต่อยอดกับข้อมูลประเภทอื่น
- 3) ได้องค์ความรู้ด้านการประมวลผลภาษาธรรมชาติ การจำแนกข้อความด้วยกฎคำสำคัญ ร่วมกับโมเดลแมชชีนเลิร์นนิง เทคนิคการสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ และการพัฒนาระบบเว็บแบบเรียลไทม์

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ

เว็บสแครปปิงคือกระบวนการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ แทนการคัดลอกข้อมูลด้วยมือ โดยทั่วไปจะส่งคำขอ HTTP ไปยังเว็บเซิร์ฟเวอร์แล้ววิเคราะห์โครงสร้าง HTML ของหน้าเว็บเพื่อสกัดข้อมูลที่ต้องการ [1] เครื่องมือที่นิยมใช้ ได้แก่ ไลบรารี BeautifulSoup สำหรับวิเคราะห์และค้นหาองค์ประกอบในเอกสาร HTML ด้วย CSS Selector และไลบรารี httpx สำหรับส่งคำขอ HTTP แบบอะซิงโครนัส อย่างไรก็ตาม เว็บไซต์บางแห่งแสดงผลเนื้อหาผ่าน JavaScript ต้องใช้เครื่องมือจำลองเบราว์เซอร์ เช่น Playwright เพื่อให้ได้ข้อมูลที่แสดงผลสมบูรณ์

นอกจากนี้ เว็บไซต์หลายแห่งยังเผยแพร่ข่าวผ่าน RSS Feed ซึ่งเป็นรูปแบบ XML มาตรฐานที่ใช้แจกจ่ายเนื้อหาที่อัปเดตเป็นประจำ ทำให้สามารถดึงหัวข้อข่าว ลิงก์ และบทสรุปสั้น ๆ ได้โดยไม่ต้องวิเคราะห์โครงสร้าง HTML โดยตรง [2] ในระบบนี้ใช้ทั้งสองเทคนิคร่วมกันตามความเหมาะสมของแต่ละสำนักข่าว

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่

การสรุปข้อความอัตโนมัติ (Text Summarization) ในทางวิทยาการคอมพิวเตอร์สามารถจำแนกออกได้เป็น 2 แนวทางหลัก ได้แก่ การสรุปแบบดึงประโยค (Extractive Summarization) ซึ่งอาศัยอัลกอริทึมทางสถิติหรือโครงสร้างกราฟ เช่น TextRank ในการคัดเลือกประโยคที่มีอยู่เดิมในบทความมาต่อเรียงกัน ซึ่งแม้จะมีความเร็วสูงแต่มีข้อจำกัดด้านความต่อเนื่องของบริบทและความเินเยื่อของภาษา และการสรุปแบบสร้างข้อความใหม่ (Abstractive Summarization) ซึ่งอาศัยการทำความเข้าใจ ความหมาย และ บริบท ของเนื้อหาทั้งหมด แล้วจึงสังเคราะห์เป็นข้อความสรุปชุดใหม่ด้วยภาษาที่เป็นธรรมชาติและสละสลวย [3]

สำหรับการประมวลผลสรุปเนื้อหาข่าวในโครงการนี้ ได้เลือกประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ตระกูล Gemini ผ่านบริการ KKU Gen.AI API [4] เพื่อดำเนินการสรุปแบบสร้างข้อความใหม่ โดยพิจารณาจากขีดความสามารถในการทำความเข้าใจภาษาไทยที่ซับซ้อน สามารถสกัดใจความสำคัญของบทความข่าวขนาดยาวและเรียบเรียงให้อยู่ในรูปแบบที่กระชับและถูกต้องตามหลักไวยากรณ์ นอกจากนี้ ตัวแบบยังรองรับการกำหนดรูปแบบผลลัพธ์แบบมีโครงสร้าง (Structured JSON Output) ตาม Schema ที่กำหนดไว้อย่างเคร่งครัด ทำให้ระบบสามารถสกัดบทสรุปความยาว 2-3 ประโยค ประเด็นสำคัญ การวิเคราะห์อารมณ์ของข่าวสาร (Sentiment Analysis) และคำสำคัญ (Keywords) ได้พร้อมกันในการเรียกใช้เพียงครั้งเดียว อีกทั้งยังรองรับการประมวลผลเนื้อหาหลายภาษา (Multilingual Support) โดยสรุปผลตามภาษาต้นฉบับของบทความ และการเชื่อมต่อประมวลผลผ่านบริการ API ภายนอกยังช่วยลดข้อจำกัดด้านทรัพยากรฮาร์ดแวร์ ทำให้เซิร์ฟเวอร์ของระบบไม่จำเป็นต้องพึ่งพาหน่วยประมวล

ผลกราฟิก (GPU) สมรรถนะสูง

2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF

การจำแนกข้อความ (Text Classification) มีขั้นตอนสำคัญในการแปลงข้อความตัวอักษรให้อยู่ในรูปเวกเตอร์ตัวเลข (Feature Extraction) และการใช้โมเดลการเรียนรู้ของเครื่องในการแบ่งแยกหมวดหมู่

(1) ทฤษฎี TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF เป็นค่าน้ำหนักเชิงสถิติที่ใช้วัดความสำคัญของคำ t ในเอกสาร d เทียบกับคลังเอกสารทั้งหมด D :

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \quad (1)$$

โดยที่ $\text{TF}(t, d)$ คือความถี่ของคำ t ในเอกสาร d และ $\text{IDF}(t, D) = \log\left(\frac{1+|D|}{1+|\{d \in D: t \in d\}|}\right) + 1$ ช่วยลดน้ำหนักของคำที่ปรากฏบ่อยทั่วไปในทุกข่าว และเพิ่มน้ำหนักให้คำเฉพาะกลุ่มหมวดหมู่

(2) ทฤษฎี Support Vector Machine (LinearSVC)

Linear Support Vector Classifier (LinearSVC) เป็นโมเดลที่มุ่งหาเส้นแบ่งระนาบหลายมิติ (Hyperplane) ที่มีระยะห่าง (Margin) จากจุดข้อมูลของแต่ละคลาสมากที่สุด:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (2)$$

การนำโมเดล LinearSVC มาใช้ร่วมกับคุณลักษณะ TF-IDF มีความเหมาะสมอย่างยิ่งต่อการจำแนกข้อความ เนื่องจากเวกเตอร์ที่ได้จากกระบวนการ TF-IDF มักมีมิติของข้อมูลสูงและมีลักษณะเบาบาง (High-dimensional Sparse Data) ซึ่ง Linear Kernel ของ SVM มีคุณสมบัติเด่นในการแบ่งกลุ่มข้อมูลลักษณะนี้ได้อย่างแม่นยำ พร้อมทั้งมีกลไก L_2 Regularization ที่ช่วยควบคุมการเกิด Overfitting ได้ดีกว่าโมเดล Decision Tree หรือ Naive Bayes นอกจากนี้ยังใช้เวลาในการทำนายผลรวดเร็วระดับต่ำกว่า 5 มิลลิวินาทีต่อบทความ ทำให้ระบบสามารถจำแนกหมวดหมู่ข่าวปริมาณมากในเบื้องหลังได้โดยไม่ส่งผลกระทบต่อความเร็วการให้บริการ และตัวโมเดลยังมีขนาดกะทัดรัด ประหยัดหน่วยความจำของระบบได้อย่างมีประสิทธิภาพ

2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (WangchanBERTa)

WangchanBERTa [5] เป็นโมเดลภาษาขนาดใหญ่ที่ใช้สถาปัตยกรรม RoBERTa (Robustly Optimized BERT Approach) ผ่านการฝึกฝนล่วงหน้า (Pre-trained) บนคลังข้อมูลภาษาไทยขนาดใหญ่กว่า 78 GB โดยโครงงานได้นำโมเดลดังกล่าวมาใช้เป็นส่วนเสริมสำหรับการประมวลผลข้อความเชิงลึก เนื่องจากกลไก Multi-head Self-Attention ช่วยให้โมเดลสามารถเข้าใจบริบทสองทิศทางได้อย่างแม่นยำ จึงสามารถจัดการกับคำพ้องรูป คำกำกวม หรือคำสแลงในพาดหัวข่าวที่โมเดลกลุ่ม Bag-of-Words ทั่วไปไม่สามารถตรวจจับได้ นอกจากนี้ ยังใช้เป็นเกณฑ์เปรียบเทียบมาตรฐาน (Baseline Benchmark) ในการประเมินความคุ้มค่าระหว่างความ

แม่นยำเชิงสัมพัทธ์กับระยะเวลาการประมวลผล

2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว

(1) ระบบแคชหลายระดับ (Multi-tier Cache Architecture)

เพื่อตอบสนองต่อผู้ใช้งานได้อย่างรวดเร็วและลดภาระการเชื่อมต่อภายนอก ระบบได้ออกแบบสถาปัตยกรรมแคชสองระดับ ได้แก่ แคชระดับหน่วยความจำ (In-Memory LRU Cache) ผ่านคลาส `AsyncInMemoryCache` สำหรับจัดเก็บผลลัพธ์การสกัดข่าวและผลสรุปจากโมเดลภาษาขนาดใหญ่ไว้ในหน่วยความจำ RAM ทำให้คำขอเรียกดูข่าวเดิมสามารถตอบสนองได้ในเวลาต่ำกว่า 5 มิลลิวินาที และช่วยป้องกันการเรียกใช้ API ซ้ำซ้อน และแคชระดับโปรโทคอล (HTTP 304 Conditional Cache) ซึ่งอาศัยกลไก ETag และส่วนหัว `If-Modified-Since` ในการตรวจสอบสถานะการอัปเดตของหน้าเว็บต้นทาง หากไม่มีการเปลี่ยนแปลงข้อมูล เซิร์ฟเวอร์จะตอบกลับด้วยสถานะ HTTP 304 Not Modified ทำให้ลดปริมาณการส่งผ่านข้อมูลในเครือข่ายและป้องกันการถูกระงับการเข้าถึงจากเว็บไซต์ต้นทาง

(2) ระบบคุกกี้และความเป็นส่วนตัว (Privacy-Preserving Cookies & PDPA)

ระบบใช้คุกกี้ในการจัดเก็บค่ากำหนดเฉพาะบุคคล (Personalize Cookies) และบันทึกคะแนนปฏิสัมพันธ์ของผู้ใช้ (Algorithm Cookies) สำหรับจัดอันดับความนิยมของข่าว (Trending Algorithm) โดยคำนึงถึงพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ด้วยการไม่จัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII Aggregate Metrics) และมีแถบแจ้งเตือนขอความยินยอมการใช้คุกกี้ (Cookie Consent Banner)

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้จะนำเสนอ งานวิจัย หรือ ระบบ ที่มีลักษณะ คล้ายคลึง กับ โครงงานนี้ เพื่อเป็นแนวทางในการพัฒนา โดยพิจารณาครอบคลุมในด้านการสกัดเนื้อหาจากเว็บ การสรุปข้อความ และการจำแนกหมวดหมู่ข่าว

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ

Barbarese [1] ได้พัฒนาไลบรารี `Trafilatura` สำหรับสกัดข้อความหลักออกจากหน้าเว็บโดยอัตโนมัติ โดยไม่ขึ้นกับเว็บไซต์ใดเว็บไซต์หนึ่ง ไลบรารีนี้รองรับการจัดรูปแบบ HTML ที่หลากหลายและคืนข้อความในรูปแบบ Markdown ซึ่งเป็นประโยชน์โดยตรงต่อการนำเนื้อหาไปใช้กับโมเดลภาษาขนาดใหญ่ อย่างไรก็ตาม วิธีนี้มีข้อจำกัดเมื่อเนื้อหาถูกเรนเดอร์ด้วย JavaScript บางกรณี ทำให้ระบบนี้ต้องเสริมด้วยการจำลองเบราว์เซอร์ด้วย `Playwright` สำหรับเว็บไซต์กลุ่มดังกล่าว

2.2.2 งานสรุปข้อความอัตโนมัติ

Allahyari และคณะ [3] ได้สำรวจเทคนิคการสรุปข้อความอย่างเป็นระบบทั้งแบบ Extract และ Abstractive และชี้ให้เห็นว่าการสรุปแบบ Abstractive ที่ใช้การเรียนรู้เชิงลึกให้ผลลัพธ์ที่เป็นธรรมชาติกว่าอย่างมีนัยสำคัญ แต่ต้องใช้ทรัพยากรในการคำนวณสูง ด้วยความก้าวหน้าของโมเดลภาษาขนาดใหญ่ [4] การสรุปแบบ Abstractive จึงเข้าถึงได้ง่ายผ่าน API โดยไม่ต้องฝึก

โมเดลเอง โครงการนี้จึงเลือกใช้แนวทางดังกล่าวเพื่อสรุปข่าวเป็นภาษาเดียวกับต้นฉบับโดยไม่ต้องใช้ทรัพยากรฝึกโมเดลของตนเอง

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย

งานวิจัยด้านการจำแนกข้อความภาษาไทยมักประสบปัญหาการเว้นวรรคคำ จึงนิยมใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP [6] ร่วมกับโมเดลแมชชีนเลิร์นนิง เช่น SVM กับคุณลักษณะ TF-IDF ซึ่งเป็นแนวทางที่มีประสิทธิภาพและใช้ทรัพยากรต่ำ โครงการนี้ประยุกต์ใช้แนวทางไฮบริด โดยใช้กฎคำสำคัญที่มีน้ำหนักและลำดับความสำคัญของ URL สำหรับการจำแนกแบบรวดเร็ว และใช้โมเดล SVM เป็นตัวตรวจสอบบริบทสำหรับหมวดหมู่ที่กฎคำสำคัญมีความแม่นยำไม่เพียงพอ

2.2.4 งานวิจัย และ ทฤษฎี การจัดอันดับ กระแส ข่าวสาร (Trending News Ranking Algorithms)

การจัดอันดับข่าวสารที่ได้รับความนิยม (Trending News) จำเป็นต้องผสานปัจจัยทั้งด้านพฤติกรรมผู้ใช้ ความสดใหม่ของเวลา และความน่าเชื่อถือของเนื้อหาเข้าด้วยกัน โดยได้รับแรงบันดาลใจจากอัลกอริทึมจัดอันดับของ Reddit [7, 8] และ Hacker News [9] ซึ่งประยุกต์ใช้ฟังก์ชันลอการิทึม (ln) ในการแปลงคะแนนปฏิสัมพันธ์ เพื่อลดผลกระทบของการบั่นยอดเข้าชม (Anti-Click Spam) และสะท้อนหลักการประโยชน์ส่วนเพิ่มที่ลดน้อยลง (Law of Diminishing Marginal Returns) ร่วมกับแบบจำลองการจัดอันดับข่าวที่คำนึงถึงมิติเวลาของ Dong และคณะ [10] ซึ่งใช้ฟังก์ชันการลดทอนแบบครึ่งชีวิต (Half-Life Exponential Decay) เพื่อให้คะแนนความนิยมของข่าวเก่าลดลงตามระยะเวลาที่ผ่านมา เปิดโอกาสให้ข่าวใหม่ขึ้นมาแสดงแทนที่ นอกจากนี้ Das และคณะ [11] ในระบบ Google News ยังแสดงให้เห็นว่าการรวมกลุ่มข่าวประเด็นเดียวกันที่รายงานโดยสำนักข่าวอิสระหลายแห่ง (Story Clustering) เป็นตัวบ่งชี้ที่มีความแม่นยำสูงว่าประเด็นดังกล่าวเป็นเหตุการณ์สำคัญระดับสาธารณะ (Major Breaking Event)

2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)

ในระบบรวบรวมข่าวสารจากหลากหลายแหล่ง การรวมข่าวที่รายงานเหตุการณ์เดียวกันเข้าเป็นกลุ่มประเด็นเดียว (Story Cluster) เป็นกระบวนการสำคัญตามแนวคิด Topic Detection and Tracking (TDT) โดยในงานวิจัยด้านการประมวลผลข่าวสารพบว่า การเปรียบเทียบความคล้ายคลึงจากหัวข้อข่าวเพียงอย่างเดียวมักก่อให้เกิดความคลาดเคลื่อนได้ง่าย ทั้งในลักษณะพลาดการรวมข่าวเรื่องเดียวกัน (False Negatives) อันเนื่องมาจากสำนักข่าวต่างสำนักมีมุมมองการพาดหัวข่าวที่แตกต่างกัน (Journalistic Framing Variations) หรือในลักษณะรวมข่าวคนละเหตุการณ์เข้าด้วยกัน (False Positives) จากการที่ข่าวประจำวันมีรูปแบบพาดหัวที่ใช้คำศัพท์คล้ายกันแม้เป็นคนละสถานที่

เพื่อแก้ไขข้อจำกัดดังกล่าว งานวิจัยสมัยใหม่จึงนิยมผสานคุณลักษณะหลายมิติร่วมกัน ได้แก่ ข้อความพาดหัว (Title) สารบัญย่อ (Summary) เอนทิตีชื่อเฉพาะบุคคลและสถานที่ (Named Entities) และคำสำคัญเฉพาะทาง (Domain Keywords) ร่วมกับการวัดความคล้ายคลึงเชิงความหมาย (Semantic Similarity) เพื่อยืนยันว่าเป็นเหตุการณ์เดียวกันอย่างแท้จริง นอกจากนี้

นี้ สำหรับปัญหาความไม่สอดคล้องของหมวดหมู่ข่าวอันเกิดจากโครงสร้าง URL และ Tag ที่แตกต่างกันในแต่ละสำนักข่าว การประยุกต์ใช้ทฤษฎีการลงมติเสียงข้างมาก (Majority Voting) หรือการทำนายซ้ำจากเนื้อหาข่าวของกลุ่ม จึงเป็นแนวทางมาตรฐานในการระบุหมวดหมู่ที่เป็นเอกภาพและแม่นยำที่สุดสำหรับกลุ่มข่าวดังกล่าว

2.2.6 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมข้างต้น สามารถสรุปผลการเปรียบเทียบคุณสมบัติได้ดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง

งานวิจัย	สกัดเนื้อหา	สรุป LLM	จำแนกหมวด	Real-time	แคช/คุกกี้	ระบบแนะนำ
Trafilatura [1]	✓	–	–	–	–	–
งานสรุปข้อความ [3]	–	✓	–	–	–	–
งานจำแนกข้อความภาษาไทย [6]	–	–	✓	–	–	–
โครงการนี้	✓	✓	✓	✓	✓	✓

จากตารางที่ 1 พบว่ายังไม่มีงานใดที่ผสมผสานการสกัดเนื้อหา การสรุปด้วยโมเดลภาษาขนาดใหญ่ การจำแนกหมวดหมู่ การแสดงผลแบบเรียลไทม์ การจัดการแคชและคุกกี้ และอัลกอริทึมแนะนำข่าวในระบบเดียวครบทุกด้าน โครงการนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่รวบรวมคุณสมบัติทั้งหมดไว้ในระบบเดียวอย่างครบถ้วน

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales)

การเลือกชุดเทคโนโลยี (Tech Stack) ในโครงการนี้คำนึงถึงประสิทธิภาพการทำงาน ความเข้ากันได้ของระบบ และมาตรฐานทางวิศวกรรมซอฟต์แวร์ โดยมีเหตุผลในการเลือกใช้แต่ละเทคโนโลยี ดังนี้

2.3.1 FastAPI

FastAPI [12] ถูกเลือกเป็นเฟรมเวิร์คหลักของส่วน Backend เนื่องจากทำงานบนสถาปัตยกรรมแบบ Asynchronous (ASGI บน Starlette) ซึ่งเหมาะสมอย่างยิ่งสำหรับงานที่เป็น Non-blocking I/O เช่น การรัน Background Scraper พร้อมกันหลายแหล่งข่าว การเชื่อมต่อ WebSocket แบบเรียลไทม์ และการเรียก API ภายนอก นอกจากนี้ยังมีความเร็วในการประมวลผลเทียบเท่าภาษา Go หรือ Node.js และสร้างเอกสาร OpenAPI Specification อัตโนมัติ

2.3.2 Pydantic

Pydantic [13] ถูกนำมาใช้ในการควบคุมและตรวจสอบชนิดข้อมูล (Data Validation & Serialization) ที่ระดับ Runtime โดยใช้ Type Hints ของภาษา Python การใช้ Pydantic ช่วยรับประกันว่าข้อมูลข่าวที่สกัดได้จากเว็บและข้อมูลผลลัพธ์จาก LLM จะถูกต้องตรงตาม Schema ที่กำหนดไว้เสมอ ป้องกันปัญหาข้อมูลสูญหายหรือผิดรูปแบบก่อนจัดเก็บลงฐานข้อมูล

2.3.3 Playwright (Chromium Headless Browser)

Playwright [14] ถูกเลือกใช้สำหรับการดึงข้อมูลหน้าเว็บที่เรนเดอร์ด้วย JavaScript (Single Page Application เช่น React/Vue) และเว็บไซต์ที่มีกลไกป้องกันบอต เช่น Cloudflare Challenge โดย Playwright สามารถจำลองเบราว์เซอร์จริงได้อย่างสมบูรณ์ จัดการ Cookies และ Browser Context แยกกันอย่างอิสระ มีความเสถียรและทำงานได้เร็วกว่า Selenium

2.3.4 PyThaiNLP

PyThaiNLP [6] เป็นเครื่องมือประมวลผลภาษาธรรมชาติภาษาไทยมาตรฐาน โดยระบบเลือกใช้อัลกอริทึมตัดคำ newmm (Dictionary-based Maximal Matching ผสานกับ Thai Character Clusters: TCC) ร่วมกับชุดคำหยุดภาษาไทย (Thai Stop words) เพื่อเตรียมข้อความก่อนนำไปสร้างเวกเตอร์ TF-IDF

2.3.5 Socket.IO

Socket.IO [15] ถูกเลือกสำหรับการสื่อสารแบบ Real-time ระหว่างเซิร์ฟเวอร์กับเว็บเบราว์เซอร์ เนื่องจากมีฟีเจอร์การเชื่อมต่อใหม่โดยอัตโนมัติ (Auto-reconnection), ระบบ Fallback เป็น HTTP Long-polling กรณีที่เครือข่ายไม่อนุญาตให้ใช้ WebSocket และระบบจัดการ Event-driven architecture ที่เรียบง่ายและเสถียร

2.3.6 ระบบจำลองเบราว์เซอร์แยกส่วนและเทคโนโลยี Obscura (Isolated Obscura CDP Engine)

Obscura (h4ckf0r0day/obscura) ถูกนำมาใช้เป็นเอนจินจำลองเบราว์เซอร์แบบแยกส่วน (Isolated Headless Browser Container) โดยสื่อสารผ่านโปรโตคอล Chrome DevTools Protocol (CDP) ผ่านการเชื่อมต่อ WebSocket (`ws://obscura:9222`) ซึ่งมีประโยชน์เชิงวิศวกรรมที่สำคัญในการแยกระบบทรัพยากร (Resource Isolation) โดยการประมวลผลเรนเดอร์หน้าเว็บข่าวที่ซับซ้อนจะถูกแยกไปทำงานในคอนเทนเนอร์ของ Obscura โดยไม่รบกวนหน่วยความจำและ CPU ของ FastAPI Backend ช่วยป้องกันปัญหาหน่วยความจำไม่เพียงพอภายใต้ทรัพยากรของเครื่องแม่ข่าย AWS EC2 `c7i-flex.large` นอกจากนี้ Obscura ยังได้รับการปรับแต่งโครงสร้าง Browser Fingerprinting และ Canvas/WebGL เพื่อลดโอกาสการถูกบล็อกคำขอจากเว็บไซต์ข่าวที่มีระบบตรวจจับบอตขั้นสูง ตลอดจนคลาส `BrowserService` ยังได้รับการออกแบบให้มีกลไกสำรองการทำงานแบบอัตโนมัติ (Graceful Fallback) ซึ่งหากคอนเทนเนอร์ภายนอกไม่พร้อมใช้งาน ระบบจะสลับไปรัน Local Playwright Chromium Engine ภายในตัวโดยอัตโนมัติ ทำให้ระบบมีความต่อเนื่องในการให้บริการ ทั้งนี้ ในระบบปัจจุบัน Obscura ถูกนำมาใช้เพื่อรองรับงานดึงและสกัดข้อมูลข่าวสารเบื้องหลัง (Background Web Scraping & Extraction) ภายในระบบ Container เท่านั้น โดยยังไม่ได้นำไปเชื่อมต่อใช้งานกับระบบ In-App Browser หรือส่วนแสดงผลหน้าเว็บฝั่งไคลเอนต์

2.3.7 ระบบจัดเก็บข้อมูลตามหลัก SOLID/GRASP (NewsRepositoryPort)

การออกแบบระบบจัดเก็บข้อมูลใช้ Port and Adapter Pattern ผ่านโปรโตคอล `NewsRepositoryPort` ทำให้โค้ดส่วนบริการไม่ผูกติดกับเทคโนโลยีฐานข้อมูลใดฐานข้อมูลหนึ่ง โดยระบบเริ่มต้นพัฒนาด้วย `FileNewsRepository` ที่จัดเก็บเป็นไฟล์ JSON เพื่อ

ความสะดวกรวดเร็วในการติดตั้งและทดสอบ และสามารถสลับไปใช้ฐานข้อมูล SQL หรือ NoSQL ได้ทันทีในอนาคตโดยไม่ต้องแก้ไข Business Logic

2.3.8 ระบบแคชหลายระดับ (Multi-tier Cache Strategy)

การเลือกใช้กลยุทธ์แคชสองระดับระหว่าง AsyncInMemoryCache (LRU Cache ใน RAM) และ HTTP 304 Conditional Cache ช่วยตัดปัญหาการดึงข้อมูลและประมวลผลสรุปเนื้อหาซ้ำซ้อนอย่างสิ้นเชิง ส่งผลให้สามารถลดค่าใช้จ่ายในการเรียกใช้ LLM API ภายนอกได้มากกว่า 70% และเพิ่มความเร็วในการตอบสนองคำขอเรียกดูข่าวของผู้ใช้ได้อย่างมีประสิทธิภาพสูงสุด

บทที่ 3

วิธีการดำเนินโครงการ

3.1 การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส

3.1.1 ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing)

การวิจัยและพัฒนาโมเดลจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่หลัก (การเมือง, เศรษฐกิจ, เทคโนโลยี, สุขภาพ, สิ่งแวดล้อม, กีฬา, บันเทิง, สังคม, ต่างประเทศ) ใช้ชุดข้อมูลมาตรฐาน 2 แหล่งหลัก ได้แก่ ชุดข้อมูล ThaiSum ซึ่งเป็นคลังข้อมูลข่าวภาษาไทยขนาดใหญ่ที่รวบรวมจากสำนักข่าวชั้นนำ ได้แก่ ไทยรัฐ ไทยพีบีเอส เดลินิวส์ และประชาไท รวมกว่า 350,000 บทความ พร้อมการระบุหมวดหมู่และบทสรุปอย่างเป็นทางการ และชุดข้อมูล Prachathai-67k ซึ่งเป็นคลังข้อมูลบทความข่าวเชิงลึกด้านการเมือง สังคม และสิ่งแวดล้อม จำนวน 67,889 บทความ

กระบวนการเตรียมข้อมูล (Data Preprocessing Pipeline) เริ่มต้นจากการทำความสะอาด ขจัดแท็ก HTML สัญลักษณ์พิเศษ และการเว้นวรรคซ้ำซ้อน จากนั้นทำการตัดคำภาษาไทยด้วยไลบรารี PyThaiNLP โดยใช้อัลกอริทึม newmm (Dictionary-based Maximal Matching ผสาน TCC) และคัดกรองคำหยุดภาษาไทยที่ไม่สื่อความหมายออก แล้วจึงแบ่งชุดข้อมูลออกเป็นชุดฝึกสอน ชุดตรวจสอบ และชุดทดสอบ (Stratified Train/Validation/Test Split) ในอัตราส่วน 70:15:15 เพื่อรักษาการกระจายตัวของทั้ง 9 หมวดหมู่ให้มีความสมดุล

3.1.2 วิธีการฝึกสอนโมเดล (Model Training Methodology)

ในการ ทดลอง และ ฝึกสอน โมเดล จำแนก หมวด หมู่ ข่าว ระบบ ได้ ทำการ พัฒนา 3 แนวทางหลัก ได้แก่ การประยุกต์ใช้โมเดล Linear Support Vector Classifier (LinearSVC) ร่วมกับการแปลงเวกเตอร์ข้อความด้วย TfidfVectorizer ที่กำหนดขนาดพิกเจอร์สูงสุด 20,000 คำ และผ่านการสอบเทียบความน่าจะเป็น (Probability Calibration) ด้วย CalibratedClassifierCV เพื่อให้ได้ค่าความเชื่อมั่นของแต่ละหมวดหมู่ การปรับจูนโมเดลการเรียนรู้เชิงลึก (Fine-tuned WangchanBERTa Transformer) บนสถาปัตยกรรม RoBERTa โดยเพิ่ม Linear Classification Head ด้านบน และฝึกสอนด้วย Cross-Entropy Loss ผ่าน AdamW Optimizer และการออกแบบไปป์ไลน์จำแนกแบบหลายชั้น (3-Tier Cascade Classifier) ในระบบจริง ซึ่งเริ่มจากการตรวจจับคำสำคัญเฉพาะกลุ่มที่มีความแม่นยำสูง (Tier 1: Regex & Keyword Cues) หากความเชื่อมั่นไม่ถึงเกณฑ์จึงส่งต่อให้โมเดล LinearSVC ประมวลผล (Tier 2) และมีโมเดล WangchanBERTa ทำหน้าที่รองรับกรณีข้อความที่มีความกำกวมสูง (Tier 3)

3.1.3 ผลการประเมินประสิทธิภาพและเมตริกวัดผล

ผลการประเมินประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ ดำเนินการทดสอบบนชุดข้อมูลมาตรฐานแบบควบคุม (Controlled Benchmark Test Set) ซึ่งสุ่มตัวอย่าง

แบบแบ่งชั้นภูมิ (Stratified Sampling) มาจากคลังข้อมูล ThaiSum และ Prachathai-67k รวมจำนวน 4,500 ตัวอย่างทดสอบ (หมวดหมู่ละ 500 ตัวอย่างอย่างสมดุล) ดังแสดงในตารางที่ 2

ตารางที่ 2 เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set)

โมเดล / สถาปัตยกรรม	Accuracy	Precision	Recall	Macro F1	Latency / ข้อความ
Rule-based Keyword Cues	0.784	0.812	0.765	0.776	< 0.1 ms
TF-IDF + LinearSVC	0.918	0.920	0.915	0.917	2.1 ms
WangchanBERTa (Fine-tuned)	0.942	0.945	0.940	0.941	48.5 ms
3-Tier Cascade Classifier (ระบบจริง)	0.936	0.938	0.934	0.935	1.8 ms

3.1.4 เมทริกซ์ความสับสน (Confusion Matrix)

ตารางเมทริกซ์ความสับสนของโมเดล 3-Tier Cascade Classifier บนชุดข้อมูลทดสอบมาตรฐาน 9 หมวดหมู่ แสดงดังตารางที่ 3

ตารางที่ 3 เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k)

จริง \ ทำนาย	การเมือง	เศรษฐกิจ	เทคโนโลยี	สุขภาพ	สิ่งแวดล้อม	กีฬา	บันเทิง	สังคม	ต่างประเทศ
การเมือง	478	12	2	1	3	0	1	14	9
เศรษฐกิจ	10	465	8	2	4	1	0	18	12
เทคโนโลยี	1	6	482	3	2	1	2	5	8
สุขภาพ	0	2	1	471	11	0	3	19	3
สิ่งแวดล้อม	4	5	2	8	462	0	0	21	8
กีฬา	0	0	0	1	0	495	2	2	10
บันเทิง	1	0	1	2	0	1	490	11	4
สังคม	12	15	4	14	16	2	8	425	14
ต่างประเทศ	8	9	6	2	5	6	3	9	472

สำหรับข้อสังเกตและพฤติกรรมการทำงานบนระบบจริง (Production Environment) ผลการประเมินข้างต้นเป็นการทดสอบบนชุดข้อมูลมาตรฐาน (Benchmark Test Set) ที่จัดสัดส่วนข้อมูลเท่ากันในทุกหมวดหมู่เพื่อเปรียบเทียบขีดความสามารถของอัลกอริทึมอย่างเป็นกลาง อย่างไรก็ตาม ในการใช้งานจริง สัดส่วนของข่าวสารในแต่ละวันจะผันแปรตามกระแสสังคมและสถานการณ์รายวัน (Daily Dynamic Distribution) นอกจากนี้ ระบบจริงยังเสริมประสิทธิภาพด้วยกลไกสกัดหมวดหมู่อัตโนมัติจากโครงสร้าง URL ของสำนักข่าวต้นทาง ซึ่งช่วยเพิ่มความเร็วในการประมวลผลให้ต่ำกว่า 0.05 มิลลิวินาที และให้ความถูกต้องสูงในกลุ่มข่าวที่มี URL ระบุชัดเจน โดยระบบได้ผ่านการทดสอบความถูกต้องอย่างครอบคลุมผ่านชุดทดสอบอัตโนมัติ `test_classifier_service.py` (ผ่านการทดสอบ 47/47 รายการ)


3.1.5 เปรียบเทียบวิธีการประเมินความแม่นยำของการจัดกลุ่มข่าวข้ามสำนัก (Multi-Source Story Clustering Evaluation)

เพื่อเตรียมการประเมินความถูกต้องของระบบการรวมข่าวหลายสำนักเป็นประเด็นเดียวกันตามข้อเสนอแนะของคณะกรรมการ โครงการได้ออกแบบระเบียบวิธีและตัวชี้วัดสำหรับการทดสอบกับชุดข่าวจริง โดยเริ่มต้นจากการสร้างชุดข้อมูลทดสอบเหตุการณ์เด่นจาก 5 สำนัก

ข่าวหลักในช่วงเวลาเดียวกัน พร้อมทั้งติดป้ายกำกับกลุ่มเหตุการณ์ (Event Cluster ID) โดยผู้เชี่ยวชาญ ครอบคลุมทั้งกรณีที่เกิดหวัคล้ายกันและกรณีที่เกิดหวัคนละมุมมอง สำหรับการวัดผล การจัดกลุ่มจะใช้ตัวชี้วัด Pairwise Precision (P_{pair}) เพื่อประเมินสัดส่วนคู่ข่าวที่ระบบจัดเข้ากลุ่มเดียวกันว่าเป็นเหตุการณ์เดียวกันจริงหรือไม่ ช่วยป้องกันความผิดพลาดจากการรวมข่าวคนละเหตุการณ์ (False Positives) และ Pairwise Recall (R_{pair}) เพื่อวัดความสามารถในการรวมคู่ข่าวที่เป็นเหตุการณ์เดียวกันได้อย่างครบถ้วน (ป้องกัน False Negatives) ร่วมกับค่า Pairwise F1-score ($F1_{\text{pair}}$) นอกจากนี้ ยังมีการประเมินความถูกต้องของฉันทามติหมวดหมู่ (Category Consensus Accuracy) โดยวัดความสอดคล้องระหว่างหมวดหมู่ระดับกลุ่มที่ได้จากอัลกอริทึม Majority Voting เปรียบเทียบกับหมวดหมู่ที่แท้จริงของเหตุการณ์ เพื่อยืนยันประสิทธิภาพในการแก้ไขปัญหาคือความไม่สอดคล้องของ Tag จากสำนักข่าวต้นทาง

3.1.6 แบบจำลองยูสเคส (Use Case Diagram)

แบบจำลองการใช้งานระบบ (Use Case Modeling) แสดงปฏิสัมพันธ์ระหว่างผู้ใช้งานระบบกับฟังก์ชันต่าง ๆ ดังภาพที่ 1



ภาพที่ 1 แผนภาพแบบจำลองยูสเคสของระบบ (Use Case Diagram)

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาโครงการในปัจจุบันแสดงดังตารางที่ 4

ตารางที่ 4 รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา

ลำดับ	รายการ	รายละเอียดคุณลักษณะ
1	คอมพิวเตอร์ประมวลผลหลัก	Intel Core Ultra 5, RAM 16 GB, SSD 512 GB
2	จอแสดงผล	หน้าจอแล็ปท็อปขนาด 16 นิ้ว
3	เครือข่ายอินเทอร์เน็ต	ความเร็วไม่น้อยกว่า 100/100 Mbps สำหรับเชื่อมต่อ KKU Gen.AI API และดึงข้อมูลข่าว

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์ที่ใช้ในการพัฒนาโครงการแสดงดังตารางที่ 5

ตารางที่ 5 รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions)

ลำดับ	ซอฟต์แวร์ / โลบารี	เวอร์ชันจริง	บทบาทและหน้าที่ในระบบ
1	Python	3.11.15	ภาษาโปรแกรมหลักฝั่งเซิร์ฟเวอร์
2	uv	0.6.14	ตัวจัดการ แพ็กเกจ และ สภาพแวดล้อม เหมือนความเร็วสูง
3	FastAPI	0.141.1	เว็บเฟรมเวิร์คแบบอะซิงโครนัสสำหรับพัฒนา REST API
4	Uvicorn	0.52.1	เว็บเซิร์ฟเวอร์ ASGI ประสิทธิภาพสูง
5	Pydantic	2.13.4	ตรวจสอบ และ แปลง โครงสร้าง ข้อมูล ที่ ระดับ Runtime
6	Playwright	1.62.0	จำลองเบราว์เซอร์ Chromium เพื่อดึงหน้าเว็บ JavaScript/SPA
7	Trafilatura	2.2.0	สกัดเนื้อหาหลักของบทความข่าวและแปลงเป็น Markdown
8	BeautifulSoup4	4.15.0	แยกวิเคราะห์โครงสร้างเอกสาร HTML และ CSS Selector
9	PyThaiNLP	5.3.5	ตัดคำภาษาไทยด้วยเอนจิน newmm และคัดกรอง Stop words
10	Scikit-learn	1.6.1	โมเดล Calibrated LinearSVC และ TF-IDF Vectorizer
11	Joblib	1.5.3	จัดเก็บ และ โหลดโมเดล Machine Learning (Serialization)
12	NumPy	2.4.6	ประมวลผลทางคณิตศาสตร์ และ อาร์เรย์เชิงตัวเลข
13	PyTorch	2.13.0	เฟรมเวิร์คการเรียนรู้เชิงลึกสำหรับรันโมเดลภาษา
14	Transformers	5.15.1	รันและประเมินผลโมเดล WangchanBERTa
15	OpenAI SDK	2.53.0	เชื่อมต่อ บริการโมเดลภาษาขนาดใหญ่ KKU Gen.AI
16	HTTPX	0.28.1	ตัวส่งคำขอ HTTP แบบอะซิงโครนัส
17	Python-SocketIO	5.16.3	จัดการการเชื่อมต่อ WebSocket สองทิศทางฝั่งเซิร์ฟเวอร์
18	Socket.IO Client (JS)	4.7.5	รับส่งข้อมูลเหตุการณ์แบบเรียลไทม์ฝั่งเว็บเบราว์เซอร์
19	Tailwind CSS	3.4.1	จัดการสไตล์และส่วนติดต่อผู้ใช้แบบ Responsive
20	Obscura (Container)	Latest	เอนจินจำลองเบราว์เซอร์ Chromium ภายใน Container สำหรับดึงข่าวหลังบ้าน (ไม่ได้ใช้กับ In-App Browser)
21	Ruff	0.16.1	เครื่องมือตรวจสอบคุณภาพโค้ดและจัดรูปแบบ (Linter & Formatter)
22	Mypy	2.3.0	ตรวจสอบความถูกต้องของ Type Annotation ภาษา Python
23	Pytest	9.1.1	ชุดทดสอบอัตโนมัติ (Unit Tests, Stress Tests, PDPA Tests)
24	Git	2.40+	ระบบควบคุมเวอร์ชันของโค้ดโครงการ


บทที่ 4

การวิเคราะห์ ออกแบบและพัฒนาระบบ

4.1 การวิเคราะห์ระบบ

4.1.1 แผนผังทิศทางของกิจกรรม (Activity Flow)


ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติทำงานในลักษณะกระบวนการต่อเนื่อง (Data Pipeline) โดยเริ่มตั้งแต่การดึงข้อมูลจากแหล่งข่าว การประมวลผลและการสกัดข้อมูล การสรุปเนื้อหาและจำแนกหมวดหมู่ ไปจนถึงการบันทึกลงหน่วยจัดเก็บและการกระจายข้อมูลแบบเรียลไทม์ไปยังส่วนติดต่อผู้ใช้ ดังแสดงในผังกิจกรรม (Activity Diagram) ภาพที่ 2



ภาพที่ 2 แผนภาพแสดงทิศทางการกิจกรรมของระบบ (Activity Diagram)

4.1.2 แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram)

การปฏิสัมพันธ์ระหว่างส่วนประกอบต่าง ๆ ของระบบ ตั้งแต่ฝั่งผู้ใช้งาน เว็บไซต์เฟรมเวิร์ก บริการสกรอปเปอร์ ปัญญาประดิษฐ์ และระบบกระจายข่าว แสดงดังภาพที่ 3



ภาพที่ 3 แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram)

4.1.3 รายการความต้องการของระบบ

(1) ความต้องการเชิงฟังก์ชัน (Functional Requirements)

ความต้องการเชิงฟังก์ชันของระบบสรุปได้ดังตารางที่ 7

ตารางที่ 7 ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements)

รหัส	ชื่อ Requirement	รายละเอียดความสามารถของระบบ
FR-01	Automated Multi-source Scraping	ระบบสามารถดึงข้อมูลข่าวจากแหล่งข่าวออนไลน์หลากหลายแหล่ง ทั้งแบบ RSS Feed, เว็บไซต์ HTML ปกติ และเว็บไซต์ที่เรนเดอร์ด้วย JavaScript ผ่าน Playwright
FR-02	Dynamic Source Registration	ระบบรองรับ การเพิ่ม/ปรับปรุง แหล่งข่าวใหม่ได้อย่างยืดหยุ่น ผ่าน Decorator (<code>@register_source</code>) โดยไม่ต้องแก้ไขโค้ดส่วนประมวลผลหลัก
FR-03	9-Category Thai NLP Classification	ระบบสามารถจำแนกหมวดหมู่ข่าวภาษาไทยออกเป็น 9 หมวดหมู่หลักได้อย่างถูกต้องด้วยเทคนิค 3-Tier Cascade Classifier
FR-04	LLM-Powered Summarization	ระบบ สามารถ สร้าง บทสรุปย่อ ประเด็นสำคัญ และ วิเคราะห์อารมณ์ของข่าว (Sentiment) โดยใช้โมเดลภาษาขนาดใหญ่ผ่าน KKU Gen.AI API
FR-05	Real-time WebSocket Push	ระบบ สามารถ กระจาย ข่าวสาร ใหม่ และการ อัปเดต สถานะการดึงข่าวไปยังผู้ใช้ทันทีผ่าน Socket.IO โดยผู้ใช้ไม่ต้องรีเฟรชหน้าจอ
FR-06	Multi-tier Caching	ระบบ มี กลไก จัด เก็บ แคช ใน หน่วย ความ จำ (<code>AsyncInMemoryCache</code>) และ แคช แบบ มี เงื่อนไข (HTTP 304) เพื่อลดการดึงข้อมูลซ้ำซ้อนและลดภาระเซิร์ฟเวอร์
FR-07	Engagement Tracking & Personalization	ระบบบันทึกพฤติกรรมการใช้งาน (การคลิกอ่าน, การขยายบทสรุป, การบันทึกหน้า) ผ่านคุกกี้เพื่อนำไปประมวลผลจัดอันดับข่าวที่น่าสนใจ (Trending/Recommended)
FR-08	In-app Reading Experience	ระบบมีหน้าต่างแสดงผลบทความข่าวและสรุปเนื้อหาในตัวเว็บ (In-app Modal Reader) เพื่อความสะดวกในการอ่าน

(2) ความต้องการที่ไม่ใช่เชิงฟังก์ชัน (Non-Functional Requirements)


ในด้านความต้องการที่ไม่ใช่เชิงฟังก์ชัน ระบบได้รับการออกแบบให้ตอบสนองข้อกำหนดสำคัญ 4 ประการ ได้แก่ ประการแรก ด้านประสิทธิภาพ (Performance) กำหนดให้เวลาการตอบสนองคำขอเรียกดูรายการข่าวผ่าน REST API (`GET /api/news`) เฉลี่ยต่ำกว่า 150 มิลลิวินาทีเมื่อมีข้อมูลจัดเก็บในหน่วยความจำแคช และมีอัตราความหน่วงเวลา (Latency) ในการกระจายข่าวสารใหม่ผ่าน WebSocket ต่ำกว่า 500 มิลลิวินาทีนับจากช่วงเวลาที่ยาถูกบันทึกลงระบบสำเร็จ ประการที่สอง ด้านความคงทนและการรองรับข้อผิดพลาด (Reliability & Fault Tolerance) ความล้มเหลวในการดึงข้อมูลจากแหล่งข่าวใดแหล่งข่าวหนึ่งต้องไม่ส่งผลกระทบต่อการทำงานของแหล่งข่าวอื่น (Isolation of Failures) พร้อมทั้งมีกลไกสำรอง (Fallback

Mechanism) รองรับการแสดงผลข้อความสรุปพื้นฐานในกรณีที่บริการ LLM ภายนอกขัดข้อง ประการที่สาม ด้านสถาปัตยกรรมและการขยายตัว (Maintainability & Extensibility) ออกแบบโครงสร้างซอฟต์แวร์ตามหลักการ SOLID และ GRASP โดยแยกชั้นความรับผิดชอบอย่างชัดเจน ตลอดจนการประยุกต์ใช้ Protocol Interface ตามรูปแบบ Port and Adapter Pattern ในการเข้าถึงคลังข้อมูล และประการสุดท้าย ด้านความเป็นส่วนตัวและการรักษาความปลอดภัย (Privacy & Usability) ระบบยึดหลักการไม่เก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII) และมีแถบขอความยินยอมการใช้งานคุกกี้ตามมาตรฐานการคุ้มครองข้อมูลส่วนบุคคล

4.2 การออกแบบระบบ

4.2.1 สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture)

ระบบได้รับการออกแบบโครงสร้างสถาปัตยกรรมระดับระบบ (System Architecture Design) สำหรับการติดตั้งบน AWS EC2 `c7i-flex.large` (2 vCPU, 4 GiB Memory) พร้อมการแยกโมดูลและคอนเทนเนอร์อย่างชัดเจน ดังแสดงในภาพที่ 4



ภาพที่ 4 แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architecture Diagram)

ตารางที่ 8 แสดงความรับผิดชอบของแต่ละเลเยอร์ในระบบ

ตารางที่ 8 การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers)

เลเยอร์	โฟลเดอร์/โมดูล	หน้าที่และความรับผิดชอบ
Presentation	frontend/static/	จัดการ หน้าเว็บ Single Page Application (SPA), จัดการ DOM และการรับส่งข้อมูลผ่าน API/WebSocket
Routing	backend/routers/	รับคำขอ HTTP REST API, ตรวจสอบข้อมูลนำเข้า และส่งต่อให้ Service ที่เกี่ยวข้อง
Service (Business Logic)	backend/services/	ควบคุม ตรรกะ ทาง ธุรกิจ เช่น การ รวบรวม ข่าว (ScraperService), การสรุปเนื้อหา (SummarizerService), การ จำแนก ประเภท (ClassifierService), การจัด อันดับความนิยม (TrendingService)
Scraper	backend/scrapers/	สกริปเปอร์เฉพาะแต่ละแหล่งข่าว ลงทะเบียน ด้วย Decorator และ ฟังก์ชัน ตัว ช่วย แยก วิเคราะห์ HTML
Core / Infrastructure	backend/core/	เครื่องมือส่วนกลาง เช่น BrowserService (Playwright), SocketManager, ระบบ แคช (AsyncInMemoryCache)
Persistence	backend/repo/	บันทึก และ ดึง ข้อมูล ข่าว และ สถิติ การ ใช้ งาน (FileNewsRepository, FileEngagementRepository) ตาม สัญญา NewsRepositoryPort
Schema	backend/schemas/	กำหนดโครงสร้างข้อมูล (Pydantic Models) สำหรับการแลกเปลี่ยนข้อมูล

4.2.2 การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล

โครงสร้างข้อมูลข่าวหลักได้รับการออกแบบให้อยู่ในรูปแบบ JSON Structure ที่กระชับ และรองรับการค้นหา ดังแสดงในตารางที่ 9

ตารางที่ 9 โครงสร้างข้อมูลบทความข่าว (NewsArticle Schema)

ฟิลด์ (Field)	ชนิดข้อมูล	จำเป็น	คำอธิบาย
id	String	ใช่	รหัสระบุข่าวแบบไม่ซ้ำ (Hash จาก URL)
title	String	ใช่	หัวข้อข่าว
url	String	ใช่	ลิงก์ต้นฉบับบทความข่าว
source	String	ใช่	ชื่อ สำนัก ข่าว ต้นทาง (เช่น ThaiPBS, Thairath, BBC)
category	String	ใช่	หมวดหมู่ข่าว (politics, economy, tech, etc.)
summary	String	ไม่ใช่	ข้อความสรุปย่อเนื้อหาข่าวจาก LLM
key_points	List[String]	ไม่ใช่	รายการ ประเด็น สำคัญ ของ ข่าว (Bullet points)
sentiment	String	ไม่ใช่	ค่าอารมณ์ของข่าว (positive, neutral, negative)
image_url	String	ไม่ใช่	ลิงก์รูปภาพหน้าปกบทความ
published_at	String	ใช่	วันและเวลาที่เผยแพร่ตามมาตรฐาน ISO 8601
created_at	String	ใช่	วันและเวลาที่ระบบนำเข้าข่าว
cluster_id	String	ไม่ใช่	รหัสกลุ่มประเด็นข่าวที่รายงานเหตุการณ์เดียวกันซ้ำกัน
consensus_category	String	ไม่ใช่	หมวดหมู่ระดับกลุ่มข่าวที่ผ่านฉันทามติเสียงข้างมาก
original_source_category	String	ไม่ใช่	หมวดหมู่ดั้งเดิมที่สำนักข่าวต้นทางระบุไว้เพื่อการตรวจสอบ
source_count	Integer	ไม่ใช่	จำนวน สำนัก ข่าว อิสระ ที่ รายงาน ข่าว ใน กลุ่มประเด็นเดียวกัน (K)

4.3 การพัฒนาระบบและการทำงานของส่วนประกอบหลัก

4.3.1 กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)

ระบบสกรปข่าวถูกออกแบบให้ทำงานแบบ Asynchronous ทั้งหมด โดยในแต่ละรอบการทำงาน **ScraperService** จะสร้าง Task สำหรับแต่ละแหล่งข่าวเพื่อดึงข้อมูลพร้อมกัน (Concurrent Scraping) พร้อมทั้งรองรับการดึงหน้าเว็บที่มีการป้องกันด้วย Cloudflare หรือเรนเดอร์เนื้อหาผ่าน JavaScript ผ่าน **BrowserService** โดยการลงทะเบียนแหล่งข่าวใช้ Decorator `@register_source` ดังตัวอย่าง:

```

1 @register_source("ThaiPBS", "https://www.thaipbs.or.th", "#
  FF5722")
2 async def scrape_thaipbs(browser_service: BrowserService) ->
  list[RawNewsItem]:
3     html = await browser_service.fetch_page("https://www.
  thaipbs.or.th/news")
4     return parse_news_cards(html, source="ThaiPBS")

```

Listing 4.1: ตัวอย่างการลงทะเบียนแหล่งข่าวด้วย Decorator

4.3.2 ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)

การจำแนกหมวดหมู่ข่าวใช้แนวทางไฮบริด (Hybrid Classification Pipeline) โดยเริ่มต้นจากการสกัดคำสำคัญจากหัวข้อข่าวด้วย PyThaiNLP (`engine="newmm"`) เพื่อเทียบกับชุดคำศัพท์เฉพาะกลุ่มทั้ง 9 หมวดหมู่หลัก โดยให้ค่าน้ำหนักตามตำแหน่งและความยาวของคำ ในกรณีที่คะแนนจากกฎคำสำคัญไม่ถึงเกณฑ์ความเชื่อมั่นที่กำหนด ระบบจะส่งเวกเตอร์ TF-IDF ของข้อความเข้าสู่โมเดล Support Vector Machine (LinearSVC) ที่ผ่านการเทรนล่วงหน้า และมีโมเดล WangchanBERTa รองรับการประมวลผลข้อความเชิงลึกสำหรับข่าวที่มีบริบทซับซ้อน

4.3.3 ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และเอนจินจำลองเบราว์เซอร์ Obscura

เพื่อยกระดับประสบการณ์การอ่านข่าวให้มีความต่อเนื่องและปลอดภัย ระบบได้พัฒนาหน้าต่างอ่านบทความฉบับเต็มภายในตัวเว็บ (In-App Modal Reader) สำหรับแสดงผลเนื้อหาข่าวที่ผ่านการสกัดและทำความสะอาดแล้ว โดยทำงานร่วมกับ **BrowserService** และคอนเทนเนอร์ Obscura เมื่อผู้อ่านคลิกเปิดอ่านข่าว ระบบจะตรวจสอบว่ามีเนื้อหา HTML ที่ผ่านการทำความสะอาดแล้วใน **AsyncInMemoryCache** หรือไม่ หากมีจะส่งกลับทันทีภายในเวลาต่ำกว่า 10 มิลลิวินาที ในกรณีที่เว็บไซต์ที่เรนเดอร์ด้วย JavaScript ชับซ้อนคอนเทนเนอร์ Obscura จะทำหน้าที่เป็น Headless Browser แยกส่วนเพื่อสกัดเนื้อหาข่าวเบื้องหลังผ่าน Chrome DevTools Protocol (CDP WebSocket `ws://obscura:9222`) โดยไม่ได้ถูกนำไปรันเป็น In-App Browser ฝั่งผู้ใช้โดยตรง จากนั้นระบบ Backend จะตัดโฆษณา ป้ายแบนเนอร์ แทร็กเกอร์ และองค์ประกอบตกแต่งที่ไม่จำเป็นออกทั้งหมด พร้อมจัดสคริปต์อันตราย (Anti-XSS) เพื่อความปลอดภัยก่อนส่งไปแสดงผลบนหน้าต่างอ่านข่าว และหากคอนเทนเนอร์ Obscura ไม่ตอบสนองภายในระยะเวลา Timeout ที่กำหนด ระบบจะสลับไปรัน Local Playwright Chromium Engine ภายในตัวแม่ข่ายโดยอัตโนมัติ ทำให้กระบวนการดึงเนื้อหาดำเนินไปได้อย่างต่อเนื่อง

4.3.4 ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)

ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้กับ KKU Gen.AI API โดยออกแบบ Prompt ให้ส่งคืนผลลัพธ์เป็นโครงสร้าง JSON ประกอบด้วย บทสรุปกระชับ 2–3 ประโยค ประเด็นสำคัญ 3–5 ข้อ และการวิเคราะห์อารมณ์ของข่าว (Sentiment: Positive, Neutral, Negative) ในภาษาเดียวกับเนื้อหาต้นฉบับ

4.3.5 อัลกอริทึมแนะนำข่าวและจัดอันดับความนิยม (Trending & Hot News Algorithm)

การจัดอันดับข่าวติดกระแส (Trending) และข่าวยอดนิยม (Hot News) คำนวณผ่านคลาส **TrendingService** โดยผสมผสาน 4 ปัจจัยหลัก ได้แก่ คะแนนปฏิสัมพันธ์ของผู้ใช้ (Reader Engagement), ตัวคูณฉันทามติของสำนักข่าว (Multi-source Publisher Consensus Multiplier), การลดทอนตามกาลเวลาแบบครึ่งชีวิต (Half-Life Exponential Time Decay) และคะแนนเร่งพิเศษสำหรับข่าวด่วน (Breaking News Boost)

(1) สูตรการคำนวณคะแนนความนิยม

$$\text{TrendingScore} = (F_E \times M(K) \times D(\Delta t)) + B \quad (3)$$

รายละเอียดองค์ประกอบย่อยและหลักการทางทฤษฎีรองรับของแต่ละพจน์ มีดังนี้
พจน์แรกคือ คะแนนปฏิสัมพันธ์ของผู้ใช้แบบลอการิทึม (F_E) คำนวณจากผลรวมถ่วงน้ำหนักของพฤติกรรมกรรมการอ่าน:

$$E = (1.0 \times N_{\text{clicks}}) + (3.0 \times N_{\text{summaries}}) + (5.0 \times N_{\text{bookmarks}}) \quad (4)$$

$$F_E = 1.0 + 2.0 \cdot \ln(1.0 + E) \quad (5)$$

การคำนวณดังกล่าวได้รับแรงบันดาลใจจากอัลกอริทึมจัดอันดับของ Reddit [7, 8] และ Hacker News [9] ซึ่งใช้ฟังก์ชันลอการิทึมบีบอัดค่าคะแนนตามกฎหมายประโยชน์ส่วนเพิ่มที่ลดน้อยถอยลง (Law of Diminishing Marginal Returns) และป้องกันการป้อนยอดคลิก ทำให้ข่าวที่มียอดคลิกสูงมากจะไม่สามารถครอบครองอันดับได้ตลอดเวลา

พจน์ที่สองคือ ตัวคูณฉันทามติหลายสำนักข่าว ($M(K)$) คำนวณจากจำนวนสำนักข่าวอิสระ K ที่รายงานข่าวในกลุ่มประเด็นเดียวกัน:

$$M(K) = 1.0 + 0.55 \times (K - 1) \quad (6)$$

ซึ่งอิงตามทฤษฎี Multi-Source Story Clustering ในระบบ Google News [11] โดยถือว่าการที่สำนักข่าวหลายแห่งรายงานตรงกันเป็นตัวบ่งชี้สำคัญว่าเป็นเหตุการณ์สำคัญระดับสาธารณะ

พจน์ที่สามคือ การลดทอนเวลาแบบเอกซ์โพเนนเชียล ($D(\Delta t)$) คำนวณจากระยะเวลา Δt ที่ผ่านไปนับจากเวลาเผยแพร่ข่าว:

$$D(\Delta t) = 2^{-\frac{\Delta t}{T_{\text{half}}}} \quad (7)$$

โดยอิงตามแบบจำลอง Time-Sensitive Ranking ในงานวิจัยด้าน News Search [10] กำหนดค่าครึ่งชีวิต $T_{\text{half}} = 12.0$ ชั่วโมง ทำให้คะแนนความสดใหม่ลดลงเหลือร้อยละ 50 ทุก 12 ชั่วโมง เพื่อเปิดทางให้ข่าวใหม่ขึ้นมาแสดงแทนที่

และพจน์ที่สี่คือ คะแนนโบนัสข่าวด่วน (B) กำหนดขึ้นเพื่อทำหน้าที่เร่งความเร็วข่าวด่วน (Breaking News Velocity Boost) ให้ขึ้นสู่แถบข่าวด่วนทันทีโดยไม่ต้องรอสะสมยอดคลิก:

$$B = \begin{cases} 4.0 & \text{ถ้า } \Delta t \leq 3.0 \text{ ชั่วโมง และ } K \geq 2 \\ 0.0 & \text{กรณีอื่น ๆ} \end{cases} \quad (8)$$

(2) เกณฑ์การกำหนดป้ายสถานะ (Badges Thresholds)

ในการแสดงผลบนส่วนต่อประสานผู้ใช้ ระบบกำหนดเกณฑ์การมอบป้ายสถานะ ได้แก่ ข่าวจะได้รับป้าย [Breaking] เมื่อมีอายุ $\Delta t \leq 3.0$ ชั่วโมง และมีสำนักข่าวรายงานตรงกันตั้งแต่ 2 แหล่งขึ้นไป ($K \geq 2$) ได้รับป้าย [Top Story] เมื่อมีสำนักข่าวรายงานตรงกันตั้งแต่ 3 แหล่งขึ้นไป ($K \geq 3$) และได้รับป้าย [Trending] หรือ Hot News เมื่อมีคะแนนรวม TrendingScore ≥ 4.5

(3) ตัวอย่างการคำนวณจริงทีละขั้นตอน (Step-by-Step Numerical Examples)

เพื่อแสดงการทำงานของอัลกอริทึมอย่างเป็นรูปธรรม จึงยกตัวอย่างการคำนวณ 2 กรณีศึกษา ดังนี้:

(3.1) กรณีศึกษาที่ 1: ข่าวด่วนที่มีผู้สนใจสูง (Breaking & Hot Trending News)

สมมติข่าวอุบัติเหตุใหญ่ที่เพิ่งเผยแพร่ได้ 1.5 ชั่วโมง ($\Delta t = 1.5$) มีรายงานตรงกันจาก 4 สำนักข่าว ($K = 4$) และผู้ใช้งานมีปฏิสัมพันธ์ดังนี้: คลิกอ่าน $N_{\text{clicks}} = 120$ ครั้ง, ขยายอ่านบทสรุป $N_{\text{summaries}} = 45$ ครั้ง, และกดบุ๊กมาร์ก $N_{\text{bookmarks}} = 20$ ครั้ง

a) *คำนวณคะแนนปฏิสัมพันธ์:*

$$E = (1.0 \times 120) + (3.0 \times 45) + (5.0 \times 20) = 120 + 135 + 100 = 355$$

$$F_E = 1.0 + 2.0 \cdot \ln(1.0 + 355) = 1.0 + 2.0 \cdot \ln(356) = 1.0 + 2.0(5.8749) = 12.75$$

b) *คำนวณตัวคูณฉันทามติ:*

$$M(4) = 1.0 + 0.55(4 - 1) = 1.0 + 1.65 = 2.65$$

c) *คำนวณอัตราการลดทอนเวลา:*

$$D(1.5) = 2^{-\frac{1.5}{12.0}} = 2^{-0.125} \approx 0.9170$$

d) *คำนวณโบนัสข่าวด่วน:* เนื่องจาก $\Delta t = 1.5 \leq 3.0$ และ $K = 4 \geq 2$ ดังนั้น $B = 4.0$

e) *รวมคะแนนสุดท้าย:*

$$\text{TrendingScore} = (12.75 \times 2.65 \times 0.9170) + 4.0 = 30.98 + 4.0 = \mathbf{34.98}$$

f) *ป้ายสถานะที่ได้รับ:* **[Breaking]**, **[Top Story]** และ **[Trending]** (เนื่องจากคะแนน $34.98 \geq 4.5$)

(3.2) กรณีศึกษาที่ 2: ข่าวเก่าที่มียอดอ่านสูงแต่เสื่อมความนิยมตามเวลา (Older High-Engagement News)

สมมติข่าวที่เผยแพร่มาแล้ว 36 ชั่วโมง ($\Delta t = 36.0$) รายงานโดยสำนักข่าวเดียว ($K = 1$) แต่สะสมยอดอ่านไว้มาก: $N_{\text{clicks}} = 300$, $N_{\text{summaries}} = 80$, $N_{\text{bookmarks}} = 30$

a) *คำนวณคะแนนปฏิสัมพันธ์:*

$$E = (1.0 \times 300) + (3.0 \times 80) + (5.0 \times 30) = 300 + 240 + 150 = 690$$

$$F_E = 1.0 + 2.0 \cdot \ln(1.0 + 690) = 1.0 + 2.0 \cdot \ln(691) = 1.0 + 2.0(6.5381) = 14.08$$

b) *คำนวณตัวคูณฉันทามติ:* $M(1) = 1.0 + 0.55(1 - 1) = 1.00$

c) **คำนวณอัตราการลดทอนเวลา:**

$$D(36.0) = 2^{-\frac{36.0}{12.0}} = 2^{-3.0} = 0.1250$$

d) **คำนวณโบนัสข่าวด่วน:** $B = 0.0$ (เนื่องจาก $\Delta t > 3.0$)

e) **รวมคะแนนสุดท้าย:**

$$\text{TrendingScore} = (14.08 \times 1.00 \times 0.1250) + 0.0 = \mathbf{1.76}$$

f) **ผลลัพธ์:** คะแนนลดลงเหลือเพียง 1.76 ทำให้อันดับตกลงและไม่ได้รับป้าย Trending ช่วยเปิดโอกาสให้ข่าวใหม่ที่มีความสดใหม่ขึ้นมาแสดงแทนที่

ตารางที่ 10 สรุปเปรียบเทียบผลลัพธ์การคำนวณของทั้งสองกรณีศึกษา

ตารางที่ 10 สรุปผลการเปรียบเทียบการคำนวณคะแนน Trending ระหว่างข่าวสดใหม่และข่าวเก่า

กรณีศึกษา	Δt (ชม.)	K	F_E	$M(K)$	$D(\Delta t)$	คะแนนสุทธิ	ป้ายสถานะที่ได้รับ
1. ข่าวด่วนประเด็นร้อน	1.5	4	12.75	2.65	0.9170	34.98	[Breaking], [Top Story], [Trending]
2. ข่าวเก่าสะสมยอดอ่าน	36.0	1	14.08	1.00	0.1250	1.76	(ไม่มีป้ายสถานะ)

4.3.6 กระบวนการ จัด กลุ่ม ข่าว จาก หลาย สำนัก ข่าว เป็น ประเด็นเดียวกัน (Multi-Source Story Clustering Pipeline)

เพื่อแก้ไขปัญหาการแสดงข่าวซ้ำซ้อนในหมวด Trending และระบุตัวคุณฉันทามติของสำนักข่าว (K) ได้อย่างแม่นยำตามข้อเสนอแนะของคณะกรรมการ ระบบได้พัฒนากลไกการรวมข่าวจากหลากหลายสำนักข่าวที่รายงานเหตุการณ์เดียวกันเข้าเป็นกลุ่มประเด็นเดียว (Story Cluster) ผ่าน 3 ขั้นตอนหลัก ดังนี้:

(1) ขั้นตอนที่ 1: การจำกัดกรอบเวลาการเกิดเหตุการณ์ (Temporal Constraint)

เนื่องจากข่าวในเหตุการณ์เดียวกันมักเกิดขึ้นและถูกรายงานในเวลาใกล้เคียงกัน บทความข่าว d_i และ d_j จะถูกนำมาพิจารณาจับคู่ก็ต่อเมื่อมีเวลาเผยแพร่ต่างกันไม่เกิน 36 ชั่วโมง:

$$|t_i - t_j| \leq 36.0 \text{ ชั่วโมง} \quad (9)$$

การจำกัดกรอบเวลาช่วยลดความซับซ้อนในการคำนวณ (Computational Complexity) จากการเปรียบเทียบคู่ข่าวทั้งหมด และตัดข่าวคนละช่วงเวลาที่มีคำศัพท์คล้ายกันออกไปตั้งแต่ขั้นตอนแรก

(2) ขั้นตอนที่ 2: การวัดความคล้ายคลึงแบบไฮบริดพหุคุณลักษณะ (Multi-Feature Hybrid Similarity)

การเปรียบเทียบจากหัวข้อข่าวเพียงอย่างเดียวอาจก่อให้เกิดความผิดพลาด เนื่องจากสำนักข่าวแต่ละแห่งอาจรายงานข่าวเดียวกันแต่เขียนคนละมุม (Journalistic Framing) หรือ

ใช้คำคล้ายกันแม้เป็นคนละเหตุการณ์ ระบบจึงใช้ฟังก์ชันความคล้ายคลึงแบบผสมผสาน 4 คุณลักษณะ:

$$\text{Sim}(d_i, d_j) = w_1 \cdot \text{Sim}_{\text{Title}} + w_2 \cdot \text{Sim}_{\text{Summary}} + w_3 \cdot \text{Sim}_{\text{Entities}} + w_4 \cdot \text{Sim}_{\text{Keywords}} \quad (10)$$

โดยกำหนดน้ำหนัก $w_1 = 0.35$ (หัวข้อข่าว), $w_2 = 0.30$ (บทสรุปย่อจาก LLM), $w_3 = 0.20$ (เอนทิตีที่ชื่อเฉพาะ) และ $w_4 = 0.15$ (คำสำคัญ) ในส่วนของ $\text{Sim}_{\text{Title}}$ และ $\text{Sim}_{\text{Summary}}$ จะคำนวณความคล้ายคลึงเชิงความหมาย (Semantic Cosine Similarity) ของเวกเตอร์ TF-IDF หรือ Sentence Embeddings เพื่อจับคู่เนื้อหาแม้จะใช้สำนวนภาษาที่แตกต่างกัน สำหรับ $\text{Sim}_{\text{Entities}}$ อาศัยการสกัดชื่อบุคคล สถานที่ และองค์กรที่เกี่ยวข้องผ่านเอนจิน NER ของ PyThaiNLP และคำนวณสัดส่วนการทับซ้อนตามสมการ:

$$\text{Sim}_{\text{Entities}} = \frac{|E_i \cap E_j|}{|E_i \cup E_j|} \quad (11)$$

หากมีชื่อบุคคลสำคัญหรือสถานที่เกิดเหตุเดียวกัน ปัจจัยนี้จะช่วยยืนยันความถูกต้องว่าเป็นเหตุการณ์เดียวกันอย่างแม่นยำ และ $\text{Sim}_{\text{Keywords}}$ เปรียบเทียบสัดส่วนของชุดคำสำคัญเฉพาะประเด็น ทั้งนี้ หากค่าความคล้ายคลึงรวม $\text{Sim}(d_i, d_j) \geq \theta_{\text{cluster}}$ (โดยกำหนดค่าขีดเริ่มเปลี่ยน $\theta_{\text{cluster}} = 0.65$) ระบบจะรวมบทความทั้งสองเข้าเป็นกลุ่มข่าวเดียวกัน

(3) ขั้นตอนที่ 3: การคัดเลือกข่าวตัวแทนกลุ่มและการแสดงผล (Representative Selection & UI Display)

เมื่อจัดกลุ่มบทความสำเร็จ ระบบจะคัดเลือกบทความข่าวที่มีคะแนน TrendingScore สูงสุดในกลุ่มขึ้นมาเป็นข่าวตัวแทนหลักสำหรับแสดงบนการ์ดข่าวหน้าแรก พร้อมทั้งแสดงป้ายระบุจำนวนสำนักข่าวที่รายงานร่วมกันอย่างเด่นชัด เช่น [รายงานโดย 4 สำนักข่าว] และระบุรายชื่อสำนักข่าวต้นทางทั้งหมด เพื่อให้ผู้ใช้สามารถคลิกเปิดอ่านมุมมองข่าวฉบับเต็มของแต่ละสำนักได้อย่างสะดวก

4.3.7 การแก้ไขความขัดแย้งของหมวดหมู่ข่าวและการหาฉันทามติระดับกลุ่ม (Cluster-Level Category Consensus)

ปัญหาสำคัญประการหนึ่งในการรวมข่าวสารจากหลายสำนัก คือความไม่สอดคล้องของหมวดหมู่ข่าว (Category Discrepancy) เนื่องจากแต่ละสำนักข่าวอาจกำหนดโครงสร้าง URL หรือ Tag หมวดหมู่ต่างกันสำหรับข่าวเหตุการณ์เดียวกัน เพื่อแก้ไขปัญหานี้ ระบบได้ออกแบบกลไกการหาฉันทามติหมวดหมู่ระดับกลุ่ม โดยเริ่มต้นจากการใช้มติเสียงข้างมาก (Majority Voting Consensus) เพื่อนับคะแนนหมวดหมู่ที่ทำนายได้จากทุกบทความภายในกลุ่มข่าวเดียวกัน:

$$C^* = \arg \max_{c \in C} \sum_{d_k \in \text{Cluster}} \mathbb{I}(\text{category}(d_k) = c) \quad (12)$$

โดยหมวดหมู่ c ที่ได้รับเสียงสนับสนุนจากสำนักข่าวมากที่สุด จะถูกกำหนดให้เป็นหมวดหมู่ทางการของกลุ่มข่าว (consensus_category) เพื่อใช้ในการจัดหมวดหมู่และกรองข่าวบน

หน้าเว็บ และในกรณีที่คะแนนเสียงข้างมากมีค่าเท่ากัน ระบบจะนำข้อความสรุปย่อรวมของทั้งกลุ่มส่งเข้าสู่โมเดล 3-Tier Cascade Classifier (TF-IDF + LinearSVC / WangchanBERTa) เพื่อวิเคราะห์บริบทของเนื้อหาทั้งหมดและตัดสินหมวดหมู่ที่แท้จริง ทั้งนี้ ระบบยังคงเก็บรักษาฟิลด์ `original_source_category` ดั้งเดิมของแต่ละสำนักข่าวไว้ในฐานข้อมูล เพื่อความโปร่งใสและสามารถตรวจสอบย้อนหลังได้ (Audit Trail)

4.3.8 การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket

เมื่อมีข่าวใหม่ที่ผ่านการสรุปและจำแนกเรียบร้อยแล้ว `SocketManager` จะทำการกระจาย Event (`news:new`) ไปยังเบราว์เซอร์ของผู้ใช้ทุกคนที่กำลังเปิดหน้าเว็บอยู่ เพื่อให้ผู้ใช้ได้รับข่าวสารล่าสุดทันทีโดยไม่ต้องทำการรีเฟรชหน้าเว็บเบราว์เซอร์

4.4 การออกแบบและมาตรการ ความมั่นคงปลอดภัย ของระบบ (System Security Design)

ความมั่นคงปลอดภัยของระบบ (System Security) และการคุ้มครองความเป็นส่วนตัวของผู้ใช้งาน (Data Privacy) เป็นปัจจัยสำคัญในการพัฒนาเว็บแอปพลิเคชันยุคใหม่ โดยระบบได้ออกแบบมาตรการรักษาความปลอดภัยครอบคลุม 4 มิติหลัก ดังนี้

4.4.1 ความมั่นคงปลอดภัย ระดับ เครือข่าย และเว็บเซิร์ฟเวอร์ (Network & Gateway Security)

ในระดับเครือข่าย ระบบได้ติดตั้ง Nginx Reverse Proxy ทำหน้าที่เป็น Gateway จัดการเข้ารหัสช่องทางการสื่อสาร (TLS/SSL Encryption) ทั้งในรูปแบบ HTTPS และ Secure WebSocket (WSS) เพื่อป้องกันการดักฟังข้อมูลระหว่างทาง (Man-in-the-Middle Attack) พร้อมทั้งกำหนดนโยบายจำกัดอัตราการเรียกใช้งาน (API Rate Limiting) เพื่อจำกัดจำนวนคำขอต่อหมายเลข IP ช่วยป้องกันการโจมตีแบบปฏิเสธการให้บริการ (DoS) นอกจากนี้ยังได้กำหนดนโยบายการเข้าถึงข้ามโดเมน (CORS Whitelist) เฉพาะโดเมนของระบบที่ได้รับอนุญาต และติดตั้งส่วนหัวความปลอดภัยมาตรฐาน (HTTP Security Headers) ได้แก่ `X-Content-Type-Options: nosniff`, `X-Frame-Options: SAMEORIGIN` และ `Content-Security-Policy (CSP)` เพื่อป้องกันการโจมตีแบบ Clickjacking และ MIME Confusion

4.4.2 การป้องกันการฉีดโค้ดอันตรายและการตรวจสอบข้อมูล (Data Sanitization & Injection Defense)

ในด้านการป้องกันการโจมตีเชิงความปลอดภัยและการจัดการข้อมูลอันตราย ระบบมีมาตรการป้องกันที่ครอบคลุมหลายระดับ โดยสำหรับการป้องกัน Cross-Site Scripting (XSS) ข้อมูลเนื้อหาข่าวที่สกัดได้จากเว็บต้นทางอาจมีแท็ก HTML หรือสคริปต์อันตรายแฝงมา ระบบจึงใช้กระบวนการแปลงและกรองข้อมูล (Sanitization) เพื่อกำจัดแท็ก `<script>`, `<iframe>`, รวมถึงแอตทริบิวต์ `onload`, `onerror` ออกทั้งหมด และแปลงเนื้อหาให้อยู่ในรูปแบบ Plain Markdown ก่อนส่งไปแสดงผลบนหน้าจอ In-app Modal นอกจากนี้ เพื่อป้องกันข้อผิดพลาดจาก Malformed Input และ Parameter Tampering ระบบได้บังคับใช้การตรวจสอบโครงสร้าง

ข้อมูลเข้มงวดด้วย Pydantic (Strict Schema Validation) ในทุกจุดรับเข้าและส่งออกของ REST API

สำหรับการป้องกัน Server-Side Request Forgery (SSRF) ส่วนงาน Scraper และ Playwright Service จะรับคำขอและดึงข้อมูลเฉพาะจากรายการสำนักข่าวที่ลงทะเบียนไว้ล่วงหน้า (Source Whitelist) เท่านั้น โดยไม่อนุญาตให้ผู้ใช้ภายนอกส่ง URL เครือข่ายภายในเข้ามาประมวลผลโดยตรง และในส่วนการประมวลผลร่วมกับโมเดลภาษาขนาดใหญ่ (LLM Safety) ระบบได้ออกแบบ System Prompt และโครงสร้าง Delimiter กันระหว่างคำสั่งหลักกับเนื้อหาข่าวอย่างรัดกุม เพื่อป้องกันปัญหา Indirect Prompt Injection ไม่ให้ข้อความข่าวลบล้างคำสั่งเดิม (Prompt Jailbreak) ของระบบสรุปข่าวได้

4.4.3 การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security)

การคุ้มครองความเป็นส่วนตัวของผู้ใช้งานถูกออกแบบตามหลัก Privacy by Design & Zero PII กล่าวคือ ระบบไม่มีการจัดเก็บข้อมูลส่วนบุคคลที่สามารถระบุตัวตนได้ (Personally Identifiable Information) เช่น ชื่อ ที่อยู่ อีเมล หรือหมายเลขประจำเครื่อง โดยข้อมูลพฤติกรรมความสนใจของผู้ใช้จะถูกประมวลผลเป็นเพียงคะแนนรวมแบบนิรนาม (Anonymous Aggregate Engagement) บนฐานข้อมูลเท่านั้น ในระดับเบราว์เซอร์ คุกกี้ที่ใช้ในระบบมีการกำหนดคุณสมบัติความปลอดภัยเข้มงวด ได้แก่ **SameSite=Lax** และ **Path=/** เพื่อป้องกันการโจมตีแบบ Cross-Site Request Forgery (CSRF) พร้อมกำหนดอายุการหมดอายุ (Max-Age) ที่เหมาะสม ตลอดจนติดตั้งแถบแจ้งเตือนขอความยินยอมการใช้งานคุกกี้ (Cookie Consent Banner) ตามมาตรฐาน PDPA และมีฟังก์ชันให้ผู้ใช้สามารถกดล้างสถิติพฤติกรรม (Clear Preference Data) บนเบราว์เซอร์ได้ด้วยตนเองตลอดเวลา

4.4.4 การจัดการความลับและการตั้งค่าระบบ (Secrets & Configuration Management)

API Key สำหรับเชื่อมต่อกับบริการภายนอก เช่น **LLM_API** ของ KGU GenAI และการตั้งค่าระบบต่าง ๆ ถูกจัดเก็บไว้ในไฟล์ **.env** และ Environment Variables ที่แยกต่างหาก โดยมีไฟล์ **.gitignore** ป้องกันการนำความลับของระบบขึ้นสู่ระบบควบคุมเวอร์ชัน (Git Repository) อย่างเข้มงวด

4.5 การทดสอบระบบ

4.5.1 การทดสอบอัตโนมัติ (Automated Test Suite)

ระบบ มี ชุด ทดสอบ อัตโนมัติ ครอบคลุม การ ทำงาน ทุก ระดับ ด้วย เฟรมเวิร์ค **pytest** โดย ประกอบ ด้วย การ ทดสอบ ระดับ หน่วย (Unit Tests เช่น **test_classifier_service.py** และ **test_sources.py**) เพื่อ ตรวจสอบ ความถูกต้องของการตัดคำภาษาไทย การจับคู่หมวดหมู่ และการสกัดฟิลด์ข้อมูลข่าว การทดสอบประสิทธิภาพของแคช (Caching & Stress Tests เช่น **test_caching.py**, **test_http_cache.py** และ **test_browser_cache.py**) เพื่อประเมินความคงทนของหน่วยความจำแคชภายใต้ภาระงานสูงและตรวจสอบการตอบสนองสถานะ HTTP 304 และการทดสอบความมั่นคงปลอดภัยและความเป็นส่วนตัว (Security & PDPA Tests เช่น

test_storage_pdpa.py) เพื่อรับประกันว่าไม่มีการบันทึกข้อมูลระบุตัวตนส่วนบุคคลลงในระบบ

4.5.2 ผลการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing)

ผลการทดสอบระบบตามความต้องการเชิงฟังก์ชันแสดงดังตารางที่ 11

ตารางที่ 11 ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing)

TC	รายการทดสอบ	ผลที่คาดหวัง	ผล
TC-01	การดึงข่าวอัตโนมัติจากหลายแหล่ง	ดึง หัวข้อ ลิงก์ รูปภาพ และเนื้อหาได้ครบถ้วน	ผ่าน
TC-02	การจำแนกหมวดหมู่ภาษาไทย 9 หมวด	จัดหมวดหมู่ข่าวได้อย่างถูกต้องตามเนื้อหา	ผ่าน
TC-03	การสรุปเนื้อหาข่าวและ Sentiment	ได้บทสรุป ประเด็นสำคัญ และ Sentiment	ผ่าน
TC-04	การแจ้งเตือนข่าวใหม่ผ่าน WebSocket	ข่าวใหม่ปรากฏบนหน้าจอทันทีโดยไม่ต้องรีเฟรช	ผ่าน
TC-05	การบันทึกความสนใจและแนะนำข่าว	แสดงแถบข่าว Trending ตามค่า Engagement	ผ่าน
TC-06	การอ่าน ข่าว ใน ตัว เว็บ (In-app Reader)	เปิด อ่าน บทความ ฉบับ เต็ม ใน Modal ได้อย่างราบรื่น	ผ่าน

บทที่ 5

สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงการ

โครงการ “ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท” ได้ดำเนินการพัฒนาเสร็จสิ้นตามขอบเขตและข้อกำหนดที่วางไว้ โดยสามารถรวบรวมข่าวสารจากหลากหลายแหล่ง สรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าวด้วย Large Language Model (KKU Gen.AI) จำแนกหมวดหมู่ข่าวภาษาไทยด้วยเทคนิค Thai NLP และแสดงผลแบบเรียลไทม์ผ่าน WebSocket พร้อมระบบแนะนำข่าวสาร ผลการดำเนินงานสรุปเปรียบเทียบกับวัตถุประสงค์ได้ดังตารางที่ 12

ตารางที่ 12 สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์

ข้อ	วัตถุประสงค์	ผลการดำเนินงานที่ได้	สถานะ
1	เพื่อ ศึกษา และ วิเคราะห์ เทคนิคการดึงข้อมูลข่าวด้วย Web Scraping, RSS Feed และเทคนิค Thai NLP	ศึกษา และ ประยุกต์ ใช้ Playwright สำหรับ JavaScript-rendered sites, ใช้ BeautifulSoup สำหรับ HTML parsing และ PyThaiNLP สำหรับการ จำแนกหมวดหมู่	บรรลุ
2	เพื่อ ออกแบบ และ พัฒนา ระบบ รวบรวม สรุป และ วิเคราะห์ ข่าวสาร แบบ End-to-End Pipeline	พัฒนาสถาปัตยกรรมแบบ Layered Architecture พร้อมระบบแคชสองระดับ, ระบบ Real-time WebSocket และ หน้าเว็บ Single Page Application ได้อย่างสมบูรณ์	บรรลุ
3	เพื่อ ทดสอบ และ ประเมิน ประสิทธิภาพ ของ ระบบ ใน ด้าน ความ ถูก ต้อง และ ความ รวดเร็ว	ระบบผ่านการทดสอบ UAT ครบทุก ข้อ และตอบสนองคำขอเรียกดูข่าวผ่าน แคชได้ในเวลาเฉลี่ยต่ำกว่า 150 มิลลิ วินาที	บรรลุ

จากตารางที่ 12 การดำเนินโครงการบรรลุวัตถุประสงค์ที่ตั้งไว้ครบทั้ง 3 ข้อ

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านแหล่งข้อมูลภายนอก

ข้อจำกัดประการแรกสืบเนื่องมาจากโครงสร้างหน้าเว็บของสำนักข่าวต้นทางอาจมีการปรับเปลี่ยน (DOM Mutation) ซึ่งส่งผลให้โมดูลแยกวิเคราะห์ (Parser) ต้องได้รับการปรับปรุงให้สอดคล้องกับโครงสร้างหน้าเว็บใหม่อย่างต่อเนื่อง นอกจากนี้ การสรุปเนื้อหาข่าวยังพึ่งพาการเชื่อมต่อกับบริการ API ภายนอก ได้แก่ KKU Gen.AI หรือ Large Language Model API ซึ่งในกรณีที่เกิดปัญหาการสื่อสารบนเครือข่ายหรือโศกนาฏการเรียกใช้งานหมดลง ระบบจะปรับเปลี่ยน

การทำงานเข้าสู่โหมดการแสดงผลข้อความสรุปตั้งต้นแทนโดยอัตโนมัติ

5.2.2 ข้อจำกัดด้านทรัพยากรและการประมวลผล

ในมิติด้านทรัพยากรระบบ การเปิดใช้งาน Playwright Headless Browser เพื่อสกัดข้อมูลจากเว็บไซต์ข่าวสารที่มีระบบป้องกันบอตหรือใช้การแสดงผลฝั่งไคลเอนต์ จำเป็นต้องใช้ทรัพยากรหน่วยความจำหลักและรอบการประมวลผลของหน่วยประมวลผลกลาง (CPU) สูงกว่าการดึงข้อมูลผ่านโปรโตคอล HTTP REST API ปกติอย่างมีนัยสำคัญ

5.3 ปัญหา อุปสรรค และแนวทางแก้ไข

ปัญหาที่พบในระหว่างการพัฒนาและแนวทางที่ใช้แก้ไขแสดงดังตารางที่ 13

ตารางที่ 13 ปัญหา อุปสรรค และแนวทางการแก้ไข

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	บาง เว็บไซต์ ข่าว มี ระบบ ป้อง กัน บอต (Cloudflare/Bot detection) ทำให้ไม่สามารถดึงข้อมูลผ่าน HTTP Client ธรรมดาได้	ใช้ Playwright Browser ควบคุม เบราวเซอร์จริงในการเรนเดอร์หน้าเว็บและจัดการ Cookie Session
2	การเรียก LLM API เพื่อสรุปข่าวทุก ครั้งทำให้การโหลดข้อมูลล่าช้าและสิ้นเปลืองโควตา	ออกแบบ ระบบ Multi-tier Cache (AsyncInMemoryCache และ Local JSON Persistence) เพื่อเก็บผลลัพธ์การสรุป
3	ข่าวสารภาษาไทยไม่มีการเว้นวรรคระหว่างคำ ทำให้การจับคู่หมวดหมู่มีความคลาดเคลื่อน	ใช้ PyThaiNLP ใน การ ตัด คำ แบบ พจนานุกรม และ คัด กรอง Stop words ก่อนนำไปจับคู่หมวดหมู่
4	ข่าวเรื่องเดียวกันจากต่างสำนักพิมพ์ มีมุมมองการพาดหัวต่างกัน และมีการกำหนด Tag หมวดหมู่ขัดแย้งกัน	ใช้ การ วัด ความ คล้าย คลึง แบบ ไฮ บริด (หัวข้อ, สรุปย่อ, เอนทิตีบุคคล/สถานที่, คำสำคัญ) ร่วมกับกลไกมติเสียงข้างมาก (Majority Voting) ในระดับกลุ่มข่าว

5.4 ข้อเสนอแนะในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

สำหรับการพัฒนาฟังก์ชันการทำงานในระยะต่อไป ระบบสามารถขยายขีดความสามารถได้หลายด้าน ประการแรกคือการพัฒนา Adapter เชื่อมต่อกับระบบจัดการฐานข้อมูลแบบกระจายศูนย์ (Distributed Database) เช่น MongoDB หรือ PostgreSQL เพิ่มเติมจาก FileNewsRepository เพื่อรองรับการจัดเก็บและสืบค้นคลังข่าวสารขนาดใหญ่ได้อย่างมีประสิทธิภาพ ประการถัดมาคือการพัฒนาระบบสมาชิกและบัญชีผู้ใช้งานเพื่ออำนวยความสะดวกในการซิงค์ข้อมูลข่าวที่ค้นหน้า (Bookmarks) และประวัติความสนใจข้ามอุปกรณ์ และประการสุดท้ายคือการพัฒนาแบบปรับค่าน้ำหนัก $w_1, \dots, w_4$ ของอัลกอริทึมจัดกลุ่มข่าวแบบอัตโนมัติตามพฤติกรรมการอ่านจริงของผู้ใช้งาน

5.4.2 แนวทางการวิจัยต่อยอด

ในเชิงการวิจัยต่อยอด คณะผู้พัฒนาเล็งเห็นแนวทางสำคัญ 3 ประการ ประการแรกคือการใช้โมเดล Transformer ภาษาไทยเฉพาะทางและ Cross-Encoder เช่น Wangchan-BERTa มาคำนวณคะแนนความคล้ายคลึงเชิงความหมาย (Semantic Similarity) เพื่อยกระดับความแม่นยำในการจัดกลุ่มข่าวสารที่มีสำนวนภาษาต่างกันอย่างลึกซึ้ง ประการที่สองคือการดำเนินการทดสอบประเมินผลกับชุดข้อมูลข่าวจริงภาคสนาม (Real-World Clustering Benchmark) โดยสร้างชุดข้อมูลข่าวข้ามสำนักข่าวพร้อมป้ายกำกับเหตุการณ์ เพื่อวัดค่า Pairwise Precision, Recall และ F1-score ตามแผนงานในอนาคต และประการที่สามคือการพัฒนาโมดูลตรวจจับและเปรียบเทียบมุมมองข่าวสารข้ามสำนักข่าว (Cross-source Fact Verification) เพื่อวิเคราะห์ความถูกต้องและความเป็นกลางของเนื้อหาข่าวสารในสังคมต่อไป

เอกสารอ้างอิง

- [1] A. Barbaresi, “Trafilatura: A web scraping library and command-line tool for text discovery and extraction,” in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations* (H. Ji, J. C. Park, and R. Xia, eds.), (Online), pp. 122–131, Association for Computational Linguistics, 2021.
- [2] D. Winer, “Rss 2.0 specification.” <https://www.rssboard.org/rss-specification>, 2009. Accessed: 2025-01-10.
- [3] M. Allahyari, S. Pouriyeh, M. Assefi, S. Safaei, E. D. Trippe, J. B. Gutierrez, and K. Kochut, “Text summarization techniques: A brief survey,” *arXiv preprint arXiv:1707.02268*, 2017.
- [4] G. D. G. Team, “Gemini: A family of highly capable multimodal models,” *arXiv preprint arXiv:2312.11805*, 2024.
- [5] L. Lowphansirikul, C. Polpanumas, N. Jantrakulchai, and S. Nutanong, “Wangchanberta: Pretrained language model for thai language,” *arXiv preprint arXiv:2101.09635*, 2021.
- [6] W. Phatthiyaphaibun, K. Chaovavanich, *et al.*, “Pythainlp: Thai natural language processing in python framework.” <https://doi.org/10.5281/zenodo.3519354>, 2021. Accessed: 2025-01-10.
- [7] A. Salihefendic, “How reddit ranking algorithms work.” <https://amix.dk/blog/post/19588>, 2010. Accessed: 2025-01-15.
- [8] A. Swartz, “Rewriting reddit: Web development and architecture.” <https://aaronsw.com/weblog/001716>, 2005. Accessed: 2025-01-15.
- [9] P. Graham, “What i’ve learned from hacker news: Ranking and community dynamics.” <http://www.paulgraham.com/hackernews.html>, 2009. Accessed: 2025-01-15.
- [10] A. Dong, R. Zhang, P. Kolari, J. Bai, F. Diaz, Y. Chang, Z. Zheng, and H. Zha, “Time-sensitive ranking in news search: Incorporating recency and quality,” pp. 315–322, 2010.
- [11] A. S. Das, M. Datar, A. Garg, and S. Rajaram, “Google news personalization: Scalable online collaborative filtering and story clustering,” pp. 271–280, 2007.
- [12] S. Ramírez, “Fastapi framework, high performance, easy to learn, fast to code, ready for production.” <https://fastapi.tiangolo.com>, 2024. Accessed: 2025-01-10.

- [13] S. Colvin *et al.*, “Pydantic: Data validation using python type hints.” <https://docs.pydantic.dev>, 2024. Accessed: 2025-01-10.
- [14] Microsoft, “Playwright: Fast and reliable cross-browser testing.” <https://playwright.dev>, 2024. Accessed: 2025-01-10.
- [15] Socket.IO, “Socket.io.” <https://socket.io>, 2024. Accessed: 2025-01-10.

ภาคผนวก ก
คู่มือการติดตั้งและใช้งานระบบ

ข้อกำหนดเบื้องต้นของสภาพแวดล้อม (Prerequisites)

- ระบบปฏิบัติการ: Windows 10/11, macOS หรือ Linux (Ubuntu 20.04+)
- Python เวอร์ชัน 3.11 หรือใหม่กว่า
- เครื่องมือจัดการสภาพแวดล้อม **uv** (Fast Python Package Installer)
- การเชื่อมต่ออินเทอร์เน็ตสำหรับดาวน์โหลด Dependencies และเรียกใช้ KGU Gen.AI API

ขั้นตอนการติดตั้งระบบ (Installation Steps)

1. โคลน Repository โครงการจาก GitHub:

```
1 git clone https://github.com/wittgenstein-byte/End-to-End_News_Collector-Summarizer.git
2 cd End-to-End_News_Collector-Summarizer
```

2. ติดตั้ง Dependencies ทั้งหมดผ่าน uv:

```
1 uv sync
```

3. ติดตั้ง Playwright Chromium Headless Browser:

```
1 uv run playwright install chromium
```

4. กำหนดค่า Environment Variables โดยคัดลอกไฟล์ตัวอย่าง:

```
1 copy backend\.env.example backend\.env
```

จากนั้นแก้ไขไฟล์ **backend/.env** โดยกรอก API Key สำหรับ LLM Service:

```
1 LLM_API=your_kku_genai_api_key_here
```

5. เริ่มต้นทำงานเซิร์ฟเวอร์ Backend:

```
1 uv run python backend/main.py
```

6. เปิดเว็บเบราว์เซอร์และเข้าสู่ระบบที่: <http://localhost:5000>

ภาคผนวก ข
ข้อกำหนด REST API และ WebSocket Events

รายการ REST API Endpoints

ตารางที่ 14 รายละเอียด REST API Endpoints ของระบบ

Method	Endpoint	คำอธิบาย	Parameters / Response
GET	/api/news	ดึงรายการข่าวแบบแบ่งหน้า	page, category, search
GET	/api/news/{id}	ดึงรายละเอียดข่าวรายชิ้นพร้อมบทสรุป	คืนค่า JSON NewsArticle
GET	/api/categories	ดึงรายการหมวดหมู่ข่าวทั้งหมด	คืนค่า List ของ Category Metadata
GET	/api/trending	ดึง รายการ ข่าว ที่ เป็นก ระ แส ความนิยม	คืนค่า List ของ TrendingArticle
POST	/api/engagement	บันทึกสถิติการปฏิสัมพันธ์ของผู้ใช้	รับ article_id, action_type
POST	/api/collect	สั่งให้ระบบเริ่มรอบการสกรปข่าวทันที	คืนค่าสถานะ status: started
GET	/health	ตรวจสอบสถานะความพร้อมของเซิร์ฟเวอร์	คืนค่าสถานะ Storage และ Playwright

รายการ WebSocket Events (Socket.IO)

ตารางที่ 15 รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time

Event Name	ทิศทาง	คำอธิบายและข้อมูลที่ส่ง (Payload)
news:new	Server → Client	ส่งข้อมูลข่าวใหม่ที่เพิ่งผ่านการประมวลผลเสร็จสิ้น เพื่อแสดงผลบนหน้าจอทันที
scraper:status	Server → Client	แจ้งสถานะความคืบหน้าของกระบวนการสกรปข่าว (เช่น เริ่มต้น, จำนวนที่ดึงได้, เสร็จสิ้น)
news:updated	Server → Client	ส่งข้อมูลการอัปเดตบทความ เช่น เมื่อการสรุป LLM เสร็จสมบูรณ์
connect / disconnect	ทั้งสองทิศทาง	ตรวจจับการเชื่อมต่อและการตัดการเชื่อมต่อของผู้ใช้