

CS 25xx/xx

เอกสารโครงงานฉบับสมบูรณ์

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท

CATEGORY-SPECIFIC NEWS CLASSIFICATION
AND NLP ANALYTICS PIPELINE

โดย

663380214-4 นายนราวิชญ์ ศิริพล

663380028-1 นายอัสดาวุฒิ เอื้อวงค์

อาจารย์ที่ปรึกษา : อ.ดร.พบพร ด่านวิรุทัย

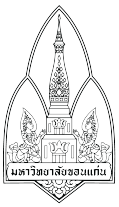
รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354 772 โครงงานคอมพิวเตอร์ 2

ภาคเรียนที่ 2 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน ตุลาคม พ.ศ. 2569)



CS 25xx/xx

เอกสารโครงงานฉบับสมบูรณ์

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการ
ประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท

CATEGORY-SPECIFIC NEWS CLASSIFICATION
AND NLP ANALYTICS PIPELINE

โดย

663380214-4 นายนราวิชญ์ ศิริพล

663380028-1 นายอัสดาวุฒิ เอื้อวงค์

อาจารย์ที่ปรึกษา : อ.ดร.พบพร ด่านวิรุทัย

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354 772 โครงงานคอมพิวเตอร์ 2

ภาคเรียนที่ 2 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(เดือน ตุลาคม พ.ศ. 2569)

นราวิชญ์ ศิริพล และ อัสดาวุฒิ เอื้อวงค์. 2569. **ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผล ภาษาธรรมชาติแบบเฉพาะประเภท.** โครงงานคอมพิวเตอร์ ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.

อาจารย์ที่ปรึกษา: อ.ดร.พบพร ด่านวิรุทัย

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อศึกษา ออกแบบ และพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific News Classification and NLP Analytics Pipeline) ที่ครอบคลุมการทำงานตั้งแต่การรวบรวมข่าวสารจากหลายสำนักข่าว การสกัดเนื้อหา การสรุปความ การจำแนกหมวดหมู่ การวิเคราะห์แนวโน้มความนิยม และการนำเสนอข้อมูลแบบเรียลไทม์ โดยสถาปัตยกรรมระบบได้รับการออกแบบตามหลักการ SOLID และ GRASP แบ่งการทำงานเป็นเลเยอร์อย่างเป็นระเบียบ ส่วนบริการเบื้องหลัง (Backend) พัฒนาด้วยภาษา Python และ FastAPI รองรับการดึงข้อมูลทั้งจาก RSS Feed และการสกัดหน้าเว็บผ่าน Playwright Headless Browser พร้อมระบบแคชแบบหลายระดับ (Multi-tier Caching: หน่วยความจำและ HTTP 304) เพื่อลดภาระการเชื่อมต่อ การสรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าว (Sentiment) ทำงานร่วมกับโมเดลภาษาขนาดใหญ่ (LLM) ผ่าน KKU Gen.AI API ขณะที่การจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่หลักใช้แนวทางไฮบริดผสานกฎคำสำคัญเชิงบริบท (Rule-based Cues) ร่วมกับโมเดลการเรียนรู้ของเครื่อง (SVM/TF-IDF และ WangchanBERTa) ส่วนติดต่อผู้ใช้ (Frontend) พัฒนาด้วยรูปแบบ Single Page Application (SPA) ด้วย Vanilla JavaScript แบบ ES Modules และ Tailwind CSS สื่อสารกับเซิร์ฟเวอร์แบบเรียลไทม์ผ่าน WebSocket (Socket.IO) พร้อมฟังก์ชันหน้าต่างอ่านข่าวในระบบ (In-app Reader Modal) และระบบแนะนำข่าวสารตามความสนใจเฉพาะบุคคลโดยคำนึงถึงความเป็นส่วนตัวตามมาตรฐาน PDPA จากผลการประเมินการทำงานพบว่าระบบสามารถทำงานได้อย่างมีเสถียรภาพ ตอบสนองคำขอรวดเร็ว และช่วยลดเวลาในการติดตามข่าวสารจากหลากหลายแหล่งได้อย่างมีประสิทธิภาพ

คำสำคัญ: การจำแนกข่าว, การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เว็บสแครปปิง, โมเดลภาษาขนาดใหญ่, อัลกอริทึมแนะนำข่าว

Narawit Siripol and Ausadawut Aueawong. 2026. **Category-Specific News Classification and NLP Analytics Pipeline.** Bachelor of Science Project in Computer Science, College of Computing, Khon Kaen University.

Project Advisor: Dr. Pobporn Danvirutai

ABSTRACT

This project aims to study, design, and develop an automated Category-Specific News Classification and NLP Analytics Pipeline. The system covers an end-to-end workflow including multi-source news aggregation, content extraction, summarization, category classification, trend analytics, and real-time delivery. The architecture is engineered according to SOLID and GRASP software design principles with clearly decoupled layers. The backend is implemented in Python using FastAPI, supporting automated extraction from both standard RSS feeds and dynamic JavaScript-heavy websites via a Playwright headless browser instance. A multi-tier caching strategy (combining in-memory LRU caching and HTTP 304 conditional cache) is employed to minimize network overhead and redundant processing. For content summarization and sentiment analysis, the system integrates with Large Language Models (LLMs) via the KKU Gen.AI API to generate concise summaries, bullet points, and sentiment scores in the article's native language. Thai text classification into nine specialized categories is executed through a hybrid pipeline combining contextual keyword-based cues with machine learning models (TF-IDF with SVM and WangchanBERTa). The frontend is built as a responsive Single Page Application (SPA) using Vanilla JavaScript ES modules and Tailwind CSS, communicating bidirectionally with the server via WebSocket (Socket.IO). It provides an in-app modal reader, trending topic visualization, and privacy-compliant personalized recommendations based on aggregate engagement metrics under PDPA standards. The evaluation results demonstrate that the pipeline operates with high stability, low latency, and significantly reduces the effort required for readers to follow diverse news outlets.

Keywords: News classification, Text analytics, Natural language processing, Web scraping, Large language model, Recommendation algorithm

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณ อ.ดร.พบพร ด่านวิรุทัย อาจารย์ที่ปรึกษาโครงงาน ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงงานฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงงานนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอ ขอบพระคุณ คณาจารย์ ใน สาขา วิชา วิทยาการ คอมพิวเตอร์ วิทยาลัย การ คอมพิวเตอร์ มหาวิทยาลัย ขอนแก่น ทุกท่านที่ได้ถ่ายทอดความรู้ทางวิชาการ ซึ่งเป็นพื้นฐานสำคัญในการศึกษาค้นคว้าและจัดทำโครงงานนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจตลอดระยะเวลาของการศึกษา

ผู้จัดทำ

นราวิชญ์ ศิริพล

อัสดาวุฒิ เอื้อวงค์

สารบัญ

		หน้า
บทคัดย่อภาษาไทย		ก
บทคัดย่อภาษาอังกฤษ		ข
กิตติกรรมประกาศ		ค
สารบัญตาราง		ซ
สารบัญภาพ		ฌ
บทที่ 1 บทนำ		1
1.1	ความเป็นมาและความสำคัญของปัญหา	1
1.2	วัตถุประสงค์	1
1.3	ขอบเขตและข้อจำกัดของระบบ	2
1.3.1	ขอบเขต	2
1.3.2	ข้อจำกัดของโครงงาน	3
1.4	ประโยชน์ที่คาดว่าจะได้รับ	4
บทที่ 2 งานวิจัยและทฤษฎีที่เกี่ยวข้อง		5
2.1	ทฤษฎีที่เกี่ยวข้อง	5
2.1.1	เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ	5
2.1.2	การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่	5
2.1.3	การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF	5
2.1.4	การจำแนกเชิงลึกด้วยโมเดล Transformer (WangchanBERTa)	6
2.1.5	การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว	6
2.2	งานวิจัยที่เกี่ยวข้อง	7
2.2.1	งานสกัดเนื้อหาบทความจากเว็บ	7
2.2.2	งานสรุปข้อความอัตโนมัติ	7
2.2.3	งานจำแนกหมวดหมู่ข่าวภาษาไทย	7
2.2.4	งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms)	7
2.2.5	งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)	8
2.2.6	งานวิจัยการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification)	8
2.2.7	งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation)	9
2.2.8	สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง	9

สารบัญ (ต่อ)

หน้า

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales) . . . 9
2.3.1 FastAPI . . . 10
2.3.2 Pydantic . . . 10
2.3.3 Playwright (Chromium Headless Browser) . . . 10
2.3.4 PyThaiNLP . . . 10
2.3.5 Socket.IO . . . 10
2.3.6 ระบบ จัด เก็บ ข้อมูล หลาย รูป แบบ ตาม หลัก SOLID/ GRASP (Multi-Engine Persistence) . . . 10
2.3.7 ระบบแคชหลายระดับ (Multi-tier Cache Strategy) . . . 11
บทที่ 3 วิธีการดำเนินงาน 12
3.1 การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส . . . 12
3.1.1 ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing) . . . 12
3.1.2 วิธีการฝึกสอนโมเดล (Model Training Methodology) . . . 12
3.1.3 ผลการประเมินประสิทธิภาพและเมตริกวัดผล . . . 12
3.1.4 เมทริกซ์ความสับสน (Confusion Matrix) . . . 13
3.1.5 การ ประเมิน ประสิทธิภาพ การ จัด กลุ่ม ข่าว แบบ สอง ชั้น (Two-Layer Story Identification Benchmark) . . . 14
3.1.6 การ จัด กลุ่ม มหา กาพย์ เหตุการณ์ และ การ ระบุ พัฒนาการ เรื่อง ราว ระดับ มหภาค (Stage B Macro-Event & Story Identification) . . . 15
3.1.7 เกตคัดกรองความเกี่ยวข้องและแบบจำลองหลักฐานเชิงเหตุการณ์ (Relevance Enforcement Gate & Evidence Dossier) . . . 16
3.1.8 สถาปัตยกรรมระบบเจาะประเด็นข่าวและการสืบค้นเชิงวิเคราะห์ (Issue Explorer & Read-Only Query Architecture) . . . 17
3.1.9 สถาปัตยกรรม กา รัน ตี เสถียรภาพ ระดับ โพ รดัก ชัน และ การ ตรวจ สอบ อัตโนมัติ (Production Hardening & Reliability Guardrails) . . . 18
3.1.10 แบบจำลองยูสเคสและการกำหนดขอบเขตหน้าที่ (Use Case Modeling & Specifications) . . . 19
3.2 เครื่องมือที่ใช้ในการดำเนินงาน . . . 22
3.2.1 ฮาร์ดแวร์ . . . 22
3.2.2 ซอฟต์แวร์ . . . 22
3.3 แผนการดำเนินงาน . . . 24
บทที่ 4 การวิเคราะห์ระบบ และพัฒนาโปรแกรม 26

สารบัญ (ต่อ)

			หน้า
4.1	การวิเคราะห์ระบบ		26
	4.1.1	ผังแสดงทิศทางของกิจกรรม (Activity Flow)	26
	4.1.2	แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram)	28
	4.1.3	รายการความต้องการของระบบ	28
4.2	การออกแบบระบบ		30
	4.2.1	สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture)	30
	4.2.2	การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล	35
4.3	การพัฒนาระบบและการทำงานของส่วนประกอบหลัก		38
	4.3.1	กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)	38
	4.3.2	ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)	39
	4.3.3	ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และการสกัดเนื้อหาบทความ	39
	4.3.4	ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)	39
	4.3.5	สถาปัตยกรรมระบุประเด็นข่าวและจัดอันดับกระแสข่าวแบบสองชั้น (Two-Layer Story Identification & Deterministic Trending)	39
	4.3.6	ส่วนนำเสนอและการสังเคราะห์เนื้อหาประเด็นรวม (Story Presentation & LLM Synthesis)	43
	4.3.7	การจัดกลุ่มมหากาพย์ประเด็นข่าวและส่วนติดต่อผู้ใช้แบบ Bento Hub	43
	4.3.8	การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket	43
	4.3.9	รายละเอียดการทำงานของจุดเชื่อมต่อบริการทั้งหมด (API Specifications)	43
	4.3.10	รายละเอียดส่วนต่อประสานและปุ่มควบคุมทั้งหมดของระบบ (Complete UI Controls & Buttons Catalog)	47
	4.3.11	ตัวอย่างส่วนต่อประสานผู้ใช้และการแสดงผลจริงของระบบ (System User Interface Demonstration)	50
	4.3.12	ระบบเจาะประเด็นข่าวและค้นหาเชิงวิเคราะห์ (Issue Explorer & In-depth Search)	51
	4.3.13	การรักษาเสถียรภาพระดับโพรดักชันและการตรวจสอบก่อนส่งมอบ (Production Reliability & Pre-flight Smoke Testing)	52
4.4	การออกแบบและมาตรการความมั่นคงปลอดภัยของระบบ (System Security Design)		52
	4.4.1	ความมั่นคงปลอดภัยระดับเครือข่ายและเว็บเซิร์ฟเวอร์ (Network & Gateway Security)	52

สารบัญ (ต่อ)

หน้า

4.4.2 การป้องกันการฉีดโค้ดอันตรายและการตรวจสอบข้อมูล (Data Sanitization & Injection Defense) 53
4.4.3 การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security) 53
4.4.4 การจัดการความลับและการตั้งค่าระบบ (Secrets & Configuration Management) 53
4.5 การทดสอบระบบ 53
4.5.1 โครงสร้างและสถิติชุดทดสอบอัตโนมัติ (Automated Test Suite Structure & Statistics) 54
4.5.2 การทดสอบคุณสมบัติคงที่ทางวิศวกรรมและกรณีสุดขั้ว (In-Depth Technical Testing Methodologies) 56
4.5.3 ผลการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing) 58
บทที่ 5 บทสรุป 60
5.1 สรุปผลการดำเนินโครงงาน 60
5.2 ข้อจำกัดของระบบ 61
5.2.1 ข้อจำกัดด้านแหล่งข้อมูลภายนอกและบริการโมเดลภาษาขนาดใหญ่ 61
5.2.2 ข้อจำกัดด้านทรัพยากรการประมวลผล 62
5.2.3 ข้อจำกัดด้านการรู้จำชื่อเฉพาะในบริบทภาษาไทย 62
5.3 ปัญหา อุปสรรค และแนวทางแก้ไข 62
5.4 ข้อเสนอแนะในการพัฒนาต่อไป 63
5.4.1 การปรับปรุงฟังก์ชันการทำงาน 63
5.4.2 การยกระดับสถาปัตยกรรมระบบสืบค้นข่าวสารแบบไฮบริด (Hybrid Search Architecture) 64
5.4.3 แนวทางการวิจัยต่อยอด 64
เอกสารอ้างอิง 66
ภาคผนวก 68
ภาคผนวก ก คู่มือการติดตั้งและการใช้งานระบบ 69
ภาคผนวก ข ข้อกำหนด REST API และ WebSocket Events 71
ประวัติผู้เขียน 74

สารบัญตาราง

		หน้า
ตารางที่ 1	เปรียบเทียบงานวิจัยที่เกี่ยวข้อง	9
ตารางที่ 2	เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set)	13
ตารางที่ 3	เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k)	13
ตารางที่ 4	ผลการประเมินเปรียบเทียบประสิทธิภาพการจัดกลุ่มข่าวสารข้ามสำนัก	14
ตารางที่ 5	ข้อกำหนดรายละเอียดคุณลักษณะของยูสเคสหลักในระบบ	21
ตารางที่ 6	รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา	22
ตารางที่ 7	รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions)	23
ตารางที่ 8	แผนการดำเนินงานและไทม์ไลน์ของโครงงาน (Gantt Chart)	25
ตารางที่ 9	ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements)	29
ตารางที่ 10	การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers)	31
ตารางที่ 11	โครงสร้างข้อมูลบทความข่าว (`NewsArticle` Schema)	37
ตารางที่ 12	โครงสร้างข้อมูลกลุ่มประเด็นข่าวสาร (`StoryRecord` Schema)	38
ตารางที่ 13	รายละเอียดข้อกำหนดจุดเชื่อมต่อบริการ REST API และ System Probes ทั้งหมดในระบบ	46
ตารางที่ 14	รายละเอียดคุณลักษณะของปุ่มควบคุมและองค์ประกอบปฏิสัมพันธ์ทั้งหมดในระบบ	49
ตารางที่ 15	การกระจายตัวของชุดทดสอบอัตโนมัติทั้ง 6 กลุ่มหลัก (จำนวนรวม 423 กรณีทดสอบ)	55
ตารางที่ 16	ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing)	59
ตารางที่ 17	สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์	61
ตารางที่ 18	ปัญหา อุปสรรค และแนวทางการแก้ไข	63
ตารางที่ 19	รายละเอียด REST API สำหรับบริการข้อมูลข่าวสารและประเด็นข่าว	72
ตารางที่ 20	รายละเอียด REST API สำหรับระบบควบคุมและโพรบโครงสร้างพื้นฐาน	73
ตารางที่ 21	รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time	73

สารบัญภาพ

		หน้า
ภาพที่ 1	แผนภาพแบบจำลองยูสเคสสำหรับผู้ใช้งานทั่วไป (Reader Use Case Diagram)	19
ภาพที่ 2	แผนภาพแบบจำลองยูสเคสสำหรับระบบเบื้องหลังและผู้ดูแลระบบ (System & Admin Use Case Diagram)	20
ภาพที่ 3	แผนภาพแสดงทิศทางกิจกรรมของระบบ (Activity Diagram)	27
ภาพที่ 4	แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram)	28
ภาพที่ 5	แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architecture Diagram)	30
ภาพที่ 6	แผนภาพสถาปัตยกรรมการประมวลผลและการจัดกลุ่มเหตุการณ์แบบ 2 ระดับ (Two-Stage Event-Centric Processing Pipeline Architecture)	32
ภาพที่ 7	แผนภาพสถาปัตยกรรมระบบกลไกป้องกันและควบคุมความถูกต้อง 3 ระดับ (3-Layer Event Verification and Grounded Synthesis Guardrails)	34
ภาพที่ 8	แผนภาพแสดงความสัมพันธ์ของโครงสร้างข้อมูลทั้งระบบ (System Schema Entity-Relationship Diagram)	36
ภาพที่ 9	ภาพแสดงหน้าต่างแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่ผ่านการยับยั้งการรวมกลุ่มข้ามเรื่อง (Stage B Hardened Storyline)	50
ภาพที่ 10	ภาพแสดงแฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาและข้อเท็จจริงยืนยันที่ผ่านเกตคัดกรองความเกี่ยวข้อง	51

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน ข่าวสารเป็นข้อมูลสำคัญที่ช่วยให้ประชาชนรับรู้และติดตามเหตุการณ์ได้อย่างทันท่วงที โดยเฉพาะอย่างยิ่งในยุคที่ข้อมูลมีการเปลี่ยนแปลงตลอดเวลา อย่างไรก็ตาม ผู้อ่านที่ต้องการติดตามข่าวสารจากหลายแหล่งมักประสบปัญหาหลายประการ ได้แก่ ต้องเปิดเว็บไซต์หรือแอปพลิเคชันหลายแห่งเพื่อเปรียบเทียบข่าวเดียวกัน ทำให้เสียเวลาและเกิดความยุ่งยากในการติดตามสถานการณ์ที่เปลี่ยนแปลงอย่างรวดเร็ว นอกจากนี้ ข่าวแต่ละฉบับยังมีเนื้อหายาวและมีข้อมูลจำนวนมาก ทำให้ผู้อ่านต้องใช้เวลาในการอ่านเพื่อสกัดประเด็นสำคัญ รวมถึงยังต้องอ่านข่าวจากแหล่งภาษาอังกฤษเพื่อให้ได้มุมมองที่หลากหลาย อีกทั้งข่าวสารที่มีปริมาณมากและหลากหลายหมวดหมู่ยังทำให้การคัดกรองและวิเคราะห์ข่าวเป็นเรื่องท้าทาย

การนำเทคโนโลยีเว็บสแครปปิง (Web Scraping) และ RSS Feed มาใช้ในการดึงข้อมูลข่าวจากเว็บไซต์ข่าวอัตโนมัติ ตลอดจนการใช้เทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ในการจำแนกหมวดหมู่ข่าวตามประเภท และการใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ในการสรุปเนื้อหา จะช่วยลดภาระของผู้อ่านในการเปิดหลายเว็บไซต์และอ่านบทความฉบับเต็ม อีกทั้งยังสามารถนำเสนอข้อมูลสำคัญที่คัดสรรและวิเคราะห์แล้วแบบเรียลไทม์ได้ในที่เดียว

จากปัญหาดังกล่าว โครงงานนี้จึงมีแนวคิดในการพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) โดยระบบจะทำการดึงข่าวจากแหล่งข่าวเป็นระยะแบบอัตโนมัติ จำแนกหมวดหมู่ข่าวด้วยเทคนิค NLP และโมเดลแมชชีนเลิร์นนิง สรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ และแสดงผลข่าวพร้อมการวิเคราะห์บนเว็บแอปพลิเคชันแบบเรียลไทม์ผ่าน WebSocket เพื่อให้ผู้ใช้สามารถติดตามข่าวสารได้อย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล

1.2 วัตถุประสงค์

1) เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวจากเว็บไซต์ข่าวด้วยวิธีเว็บสแครปปิงและการอ่าน RSS Feed รวมถึงเทคนิคการประมวลผลภาษาธรรมชาติสำหรับการจำแนกหมวดหมู่ข่าวตามประเภท
2) เพื่อออกแบบและพัฒนาระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท (Category-Specific NLP Analytics Pipeline) ครอบคลุมการดึงข่าว การจำแนกหมวดหมู่ การสรุปเนื้อหาด้วยโมเดลภาษาขนาดใหญ่ อัลกอริทึมแนะนำข่าว และการแสดงผลแบบเรียลไทม์
3) เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องของการจำแนกหมวดหมู่ข่าว ความถูกต้องของการสรุปข่าว ความแม่นยำของอัลกอริทึมแนะนำข่าว และความสามารถในการแสดงผลข่าวแบบเรียลไทม์

1.3 ขอบเขตและข้อจำกัดของระบบ

1.3.1 ขอบเขต

ระบบเป็นเว็บแอปพลิเคชันแบบเต็มรูปแบบ (Full-stack) ที่มีขอบเขตการทำงาน ดังนี้

1) การรวบรวมข่าวอัตโนมัติ โดยระบบสามารถดึงข่าวจากแหล่งข่าวออนไลน์หลายแห่ง โดยใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed และการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์ที่ใช้ JavaScript
2) การสรุปข่าวและวิเคราะห์อารมณ์ โดยระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้โมเดลภาษาขนาดใหญ่ผ่าน API ของมหาวิทยาลัยขอนแก่น (KKU Gen.AI) เพื่อสร้างบทสรุป ประเด็นสำคัญ อารมณ์ของข่าว (Sentiment) และคำสำคัญ โดยสรุปเป็นภาษาเดียวกับต้นฉบับข่าว
3) การจำแนกหมวดหมู่ข่าว 9 หมวดหมู่หลัก ได้แก่ การเมือง (politics), เศรษฐกิจ (economy), เทคโนโลยี (tech), สุขภาพ (health), สิ่งแวดล้อม (environment), กีฬา (sports), บันเทิง (entertainment), สังคม (society) และต่างประเทศ (world) โดยใช้การตัดคำภาษาไทยด้วย PyThaiNLP ร่วมกับโมเดลการเรียนรู้ของเครื่องแบบหลายชั้น (3-Tier Cascade Classifier: Rule Cues, Calibrated LinearSVC และ WangchanBERTa)
4) การจัดเก็บและวงจรชีวิตของข้อมูล (Data Lifecycle & Retention) ข้อมูลข่าวและผลการวิเคราะห์ทั้งหมดจะถูกจัดเก็บรวบรวมอย่างต่อเนื่องนับตั้งแต่วันที่ Instance Server เริ่มทำงาน (Instance Startup Date) โดยจัดเก็บไว้ภายใน Docker Container และ Local Storage บนเครื่องแม่ข่าย AWS EC2
5) การระบุและจัดกลุ่มประเด็นข่าวแบบออนไลน์และคงทน (Persistent Online Story Identification) ระบบสามารถตรวจจับความคล้ายคลึงเชิงความหมายแบบ Dense Vector ผสานการยืนยันด้วยเอนทิตีชื่อเฉพาะ (Named Entity Recognition) เพื่อรวบรวมข่าวจากหลายสำนักเข้าเป็นประเด็นเดียวกันอย่างต่อเนื่อง (Story Cluster) โดยกำหนดหน้าต่างสืบค้น 72 ชั่วโมงแบบไม่ปิดกั้นอายุขัยข่าว (Non-capping Window) ทำให้สามารถติดตามประเด็นข่าวที่ยืดเยื้อข้ามวันได้อย่างไร้รอยต่อ
6) การจัดกลุ่มมหากาพย์ประเด็นข่าว (Macro Storyline & Sub-events) ระบบสามารถเชื่อมโยงประเด็นข่าวย่อยที่พัฒนาการต่อเนื่องเข้าสู่มหากาพย์ประเด็นข่าวขนาดใหญ่ พร้อมกำหนดหมวดหมู่ของกลุ่มข่าวด้วยหลักการมติเสียงข้างมาก (Majority Voting) และรองรับข้อยกเว้นกรณีวิกฤต (Crisis Exemption)
7) การจัดอันดับกระแสข่าวแบบเชิงสถิติแน่นอน (Deterministic Multi-Signal Trending Engine) คำนวณคะแนนความนิยมจาก 6 มิติเชิงสถิติ (ปริมาณ, อัตราเร่ง, ความหลากหลายของสำนักข่าว, การลดทอนตามเวลา, ความแปลกใหม่, และพฤติกรรมผู้อ่าน) พร้อมตัวคูณลดทอนข่าวประจำวัน (Routine Penalty) โดยตัดการพึ่งพา LLM ออกจากขั้นตอนคำนวณคะแนนเพื่อความรวดเร็วระดับเสี้ยววินาที
8) ขอบเขตความเป็นส่วนตัวและการไหลของข้อมูลผู้ใช้ (User Privacy & Data Flow) ระบบบันทึกเฉพาะรหัสเซสชันแบบไม่ระบุตัวตน (Anonymous Cookie ID) และสถิติพฤติกรรมการอ่านข่าว

แบบภาพรวม (Non-PII Aggregate Engagement เช่น การคลิกเปิดอ่าน การขยายอ่านบทสรุป การบุ๊กมาร์ก) บนเบราว์เซอร์ของผู้ใช้เพื่อส่งมาคำนวณคะแนนความนิยม โดยไม่มีการจัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (PII) เช่น ชื่อ-นามสกุล อีเมล หรือหมายเลข IP และไม่มีการส่งต่อข้อมูลพฤติกรรมผู้ใช้ไปยังโมเดลภาษาขนาดใหญ่ภายนอกหรือบุคคลภายนอกใด ๆ

9) การแสดงผลแบบเรียลไทม์ โดยระบบแสดงรายการข่าวบนเว็บแอปพลิเคชันพร้อมสรุปเนื้อหา ภาพประกอบ และหมวดหมู่ และแจ้งเตือนข่าวใหม่ทันทีผ่าน WebSocket (Socket.IO) โดยไม่ต้องรีเฟรชหน้าเว็บ
10) การอ่านข่าวในตัวเว็บ (In-app Reader Modal) โดยระบบมีหน้าต่างแสดงผลบทความข่าวและบทวิเคราะห์ในตัวเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้อ่านข่าวได้อย่างต่อเนื่องโดยไม่ต้องเปิดแท็บใหม่
11) การจัดเก็บข้อมูลหลายรูปแบบและสถาปัตยกรรมแบบแยกชั้น (Multi-Engine Persistence) ระบบรองรับการจัดเก็บข้อมูลในรูปแบบไฟล์ JSON, ฐานข้อมูล SQLite พร้อมโหมด Write-Ahead Logging (WAL) สำหรับงานอ่านเขียนประสิทธิภาพสูง และฐานข้อมูล NoSQL MongoDB ออกแบบตามหลัก SOLID/GRASP ด้วย Port/Adapter Pattern
12) การตั้งค่าและความยืดหยุ่น โดยระบบรองรับการเพิ่มแหล่งข่าวใหม่ได้โดยไม่ต้องแก้ไขโครงสร้างหลัก ผ่านการลงทะเบียน Source ด้วย Decorator (`@register_source`)
13) ระบบแคชหลายระดับ (Multi-tier Cache) โดยระบบมีกลไกจัดเก็บข้อมูลข่าวและเนื้อหาในหน่วยความจำระดับ L1 (`AsyncInMemoryCache`) ร่วมกับแคชแบบมีเงื่อนไข (HTTP 304 Conditional Cache) เพื่อลดการดึงข้อมูลซ้ำและเพิ่มความรวดเร็วในการแสดงผล
14) หน้าจอศูนย์ควบคุมและติดตามสถานะระบบ (Monitoring Dashboard) ระบบจัดเตรียมส่วนติดต่อผู้ใช้และ API สำหรับผู้ดูแลเพื่อตรวจสอบอัตราการรับเข้าของข่าว สุขภาพของแต่ละสำนักข่าว อัตราการเข้าถึงแคช และสถิติการทำงานของระบบอย่างโปร่งใส
15) การรองรับ Progressive Web App (PWA) ที่รองรับการทำงานแบบเว็บแอปพลิเคชันก้าวหน้า พร้อม Service Worker สำหรับการแคชหน้าเว็บเพื่อความรวดเร็ว

1.3.2 ข้อจำกัดของโครงงาน

1) ด้านทรัพยากรฮาร์ดแวร์และการติดตั้งใช้งาน ระบบถูกออกแบบและปรับแต่งให้รองรับภาระงานได้ตามขีดความสามารถของเครื่องแม่ข่าย AWS EC2 อินสแตนซ์ประเภท `c7i-flex.large` (2 vCPU, หน่วยความจำหลัก RAM ขนาด 4 GiB และ Swap Buffer ขนาด 4 GB) ซึ่งอาจมีข้อจำกัดในการรองรับผู้ใช้งานพร้อมกันจำนวนมหาศาล (Concurrent Users) หรือการรันเบราว์เซอร์ Playwright จำนวนหลายอินสแตนซ์พร้อมกัน
2) ด้านชุดข้อมูลฝึกสอนโมเดล (Training Dataset Constraints) โมเดลการเรียนรู้ของเครื่องสำหรับการจำแนกหมวดหมู่ข่าวได้รับการฝึกสอนและประเมินผลบนชุดข้อมูลจำกัดจากคลังข้อมูล ThaiSum และ Prachathai-67k ซึ่งอาจมีความครอบคลุมของคำศัพท์เฉพาะกลุ่มหรือโครงสร้างภาษาตามลักษณะของแหล่งข่าวดังกล่าว
3) ด้านความหลากหลายของการพาดหัวข่าวและแท็กหมวดหมู่ข้ามสำนักพิมพ์ ข่าวเหตุการณ์เดียวกันจากต่างสำนักข่าวอาจมีการพาดหัวคนละมุมมอง หรือมีโครงสร้าง URL และ Tag หมวด

หมู่ที่แตกต่างกัน ซึ่งระบบแก้ไขด้วยการใช้ฟีเจอร์แบบไฮบริด (หัวข้อ, เนื้อหาย่อ, คำสำคัญ, เอนทิตี) และการหาฉันทามติของหมวดหมู่ในระดับกลุ่มข่าว (Cluster-Level Category Consensus)

4) ระบบรองรับการสรุปและแสดงผลข่าวในภาษาไทยและภาษาอังกฤษเท่านั้น ตามภาษาเดิมของเนื้อหาข่าวแต่ละฉบับ
5) โครงสร้าง HTML หรือ RSS Feed ของเว็บไซต์แหล่งข่าวอาจเปลี่ยนแปลงได้ ทำให้ระบบต้องได้รับการปรับปรุงให้สอดคล้อง
6) การสรุปข่าวต้องอาศัยการเชื่อมต่ออินเทอร์เน็ตและ API ของโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) หากบริการขัดข้องหรือหมดโควตาการใช้งาน ระบบจะทำงานในโหมดข้อความสรุปตั้งต้นแทน
7) รอบแรกของการดึงข่าวอาจใช้เวลา 2–5 นาที เนื่องจากต้องดึงเนื้อหาบทความของแต่ละข่าวเพื่อใช้ในการสรุป

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1) ได้ระบบเว็บแอปพลิเคชันจำแนกและวิเคราะห์ข่าวสารอัตโนมัติแบบเรียลไทม์ ที่ช่วยให้ผู้ใช้ติดตามข่าวสารจากหลายแหล่งได้ในที่เดียวอย่างสะดวก รวดเร็ว และเหมาะสมกับความสนใจของแต่ละบุคคล
2) ได้แนวทางในการประยุกต์ใช้เทคนิคเว็บสแครปปิง การอ่าน RSS Feed โมเดลภาษาขนาดใหญ่ อัลกอริทึมการกำหนดคุกกี้เพื่อการปรับแต่งเฉพาะบุคคล และอัลกอริทึมแนะนำข่าว เพื่อสร้างระบบวิเคราะห์ข้อมูลข่าวอัตโนมัติ ซึ่งสามารถนำไปพัฒนาต่อยอดกับข้อมูลประเภทอื่น
3) ได้องค์ความรู้ด้านการประมวลผลภาษาธรรมชาติ การจำแนกข้อความด้วยกฎคำสำคัญร่วมกับโมเดลแมชชีนเลิร์นนิง เทคนิคการสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่ และการพัฒนาระบบเว็บแบบเรียลไทม์

บทที่ 2
งานวิจัยและทฤษฎีที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 เว็บสแครปปิง (Web Scraping) และการดึงข้อมูลอัตโนมัติ

เว็บสแครปปิงคือกระบวนการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ แทนการคัดลอกข้อมูลด้วยมือ โดยทั่วไปจะส่งคำขอ HTTP ไปยังเว็บเซิร์ฟเวอร์แล้ววิเคราะห์โครงสร้าง HTML ของหน้าเว็บเพื่อสกัดข้อมูลที่ต้องการ [1] เครื่องมือที่นิยมใช้ ได้แก่ ไลบรารี BeautifulSoup สำหรับวิเคราะห์และค้นหาองค์ประกอบในเอกสาร HTML ด้วย CSS Selector และไลบรารี httpx สำหรับส่งคำขอ HTTP แบบอะซิงโครนัส อย่างไรก็ตาม เว็บไซต์บางแห่งแสดงผลเนื้อหาผ่าน JavaScript ต้องใช้เครื่องมือจำลองเบราว์เซอร์ เช่น Playwright เพื่อให้ได้ข้อมูลที่แสดงผลสมบูรณ์

นอกจากนี้ เว็บไซต์หลายแห่งยังเผยแพร่ข่าวผ่าน RSS Feed ซึ่งเป็นรูปแบบ XML มาตรฐานที่ใช้แจกจ่ายเนื้อหาที่อัปเดตเป็นประจำ ทำให้สามารถดึงหัวข้อข่าว ลิงก์ และบทสรุปสั้น ๆ ได้โดยไม่ต้องวิเคราะห์โครงสร้าง HTML โดยตรง [2] ในระบบนี้ใช้ทั้งสองเทคนิคร่วมกันตามความเหมาะสมของแต่ละสำนักข่าว

2.1.2 การสรุปข้อความด้วยโมเดลภาษาขนาดใหญ่

การสรุปข้อความอัตโนมัติ (Text Summarization) ในทางวิทยาการคอมพิวเตอร์สามารถจำแนกออกได้เป็น 2 แนวทางหลัก ได้แก่ การสรุปแบบดึงประโยค (Extractive Summarization) ซึ่งอาศัยอัลกอริทึมทางสถิติหรือโครงสร้างกราฟ เช่น TextRank ในการคัดเลือกประโยคที่มีอยู่เดิมในบทความมาต่อเรียงกัน ซึ่งแม้จะมีความเร็วสูงแต่มีข้อจำกัดด้านความต่อเนื่องของบริบทและความเยิ่นเย้อของภาษา และการสรุปแบบสร้างข้อความใหม่ (Abstractive Summarization) ซึ่งอาศัยการทำความเข้าใจความหมายและบริบทของเนื้อหาทั้งหมด แล้วจึงสังเคราะห์เป็นข้อความสรุปชุดใหม่ด้วยภาษาที่เป็นธรรมชาติและสละสลวย [3]

สำหรับการประมวลผลสรุปเนื้อหาข่าวในโครงงานนี้ ได้เลือกประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ตระกูล Gemini ผ่านบริการ KKU Gen.AI API [4] เพื่อดำเนินการสรุปแบบสร้างข้อความใหม่ โดยพิจารณาจากขีดความสามารถในการทำความเข้าใจภาษาไทยที่ซับซ้อน สามารถสกัดใจความสำคัญของบทความข่าวขนาดยาวและเรียบเรียงให้อยู่ในรูปแบบที่กระชับและถูกต้องตามหลักไวยากรณ์ นอกจากนี้ตัวแบบยังรองรับการกำหนดรูปแบบผลลัพธ์แบบมีโครงสร้าง (Structured JSON Output) ตาม Schema ที่กำหนดไว้อย่างเคร่งครัด ทำให้ระบบสามารถสกัดบทสรุปความยาว 2–3 ประโยค ประเด็นสำคัญ การวิเคราะห์อารมณ์ของข่าวสาร (Sentiment Analysis) และคำสำคัญ (Keywords) ได้พร้อมกันในการเรียกใช้เพียงครั้งเดียว อีกทั้งยังรองรับการประมวลผลเนื้อหาหลายภาษา (Multilingual Support) โดยสรุปผลตามภาษาต้นฉบับของบทความ และการเชื่อมต่อประมวลผลผ่านบริการ API ภายนอกยังช่วยลดข้อจำกัดด้านทรัพยากรฮาร์ดแวร์ ทำให้เซิร์ฟเวอร์ของระบบไม่จำเป็นต้องพึ่งพาหน่วยประมวลผลกราฟิก (GPU) สมรรถนะสูง

2.1.3 การจำแนกข้อความภาษาไทยด้วย LinearSVC และ TF-IDF

การจำแนกข้อความ (Text Classification) มีขั้นตอนสำคัญในการแปลงข้อความตัวอักษรให้อยู่ในรูปเวกเตอร์ตัวเลข (Feature Extraction) และการใช้โมเดลการเรียนรู้ของเครื่องในการแบ่งแยกหมวดหมู่

(1) ทฤษฎี TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF เป็นค่าน้ำหนักเชิงสถิติที่ใช้วัดความสำคัญของคำ t ในเอกสาร d เทียบกับคลังเอกสารทั้งหมด D:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \tag{1}$$

โดยที่ $\text{TF}(t, d)$ คือความถี่ของคำ t ในเอกสาร d และ $\text{IDF}(t, D) = \log\left(\frac{1+|D|}{1+|\{d \in D : t \in d\}|}\right) + 1$ ช่วยลดน้ำหนักของคำที่ปรากฏบ่อยทั่วไปในทุกข่าว และเพิ่มน้ำหนักให้คำเฉพาะกลุ่มหมวดหมู่

(2) ทฤษฎี Support Vector Machine (LinearSVC)

Linear Support Vector Classifier (LinearSVC) เป็นโมเดลที่มุ่งหาเส้นแบ่งระนาบหลายมิติ (Hyperplane) ที่มีระยะห่าง (Margin) จากจุดข้อมูลของแต่ละคลาสมากที่สุด:

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \tag{2}$$

การนำโมเดล LinearSVC มาใช้ร่วมกับคุณลักษณะ TF-IDF มีความเหมาะสมอย่างยิ่งต่อการจำแนกข้อความ เนื่องจากเวกเตอร์ที่ได้จากกระบวนการ TF-IDF มักมีมิติของข้อมูลสูงและมีลักษณะเบาบาง (High-dimensional Sparse Data) ซึ่ง Linear Kernel ของ SVM มีคุณสมบัติเด่นในการแบ่งกลุ่มข้อมูลลักษณะนี้ได้อย่างแม่นยำ พร้อมทั้งมีกลไก L_2 Regularization ที่ช่วยควบคุมการเกิด Overfitting ได้ดีกว่าโมเดล Decision Tree หรือ Naive Bayes นอกจากนี้ยังใช้เวลาในการทำนายผลรวดเร็วระดับต่ำกว่า 5 มิลลิวินาทีต่อบทความ ทำให้ระบบสามารถจำแนกหมวดหมู่ข่าวปริมาณมากในเบื้องหลังได้โดยไม่ส่งผลกระทบต่อความเร็วการให้บริการ และตัวโมเดลยังมีขนาดกะทัดรัด ประหยัดหน่วยความจำของระบบได้อย่างมีประสิทธิภาพ

2.1.4 การจำแนกเชิงลึกด้วยโมเดล Transformer (WangchanBERTa)

WangchanBERTa [5] เป็นโมเดลภาษาขนาดใหญ่ที่ใช้สถาปัตยกรรม RoBERTa (Robustly Optimized BERT Approach) ผ่านการฝึกฝนล่วงหน้า (Pre-trained) บนคลังข้อมูลภาษาไทยขนาดใหญ่กว่า 78 GB โดยโครงงานได้นำโมเดลดังกล่าวมาใช้เป็นส่วนเสริมสำหรับการประมวลผลข้อความเชิงลึก เนื่องจากกลไก Multi-head Self-Attention ช่วยให้โมเดลสามารถเข้าใจบริบทสองทิศทางได้อย่างแม่นยำ จึงสามารถจัดการกับคำพ้องรูป คำกำกวม หรือคำสแลงในพาดหัวข่าวที่โมเดลกลุ่ม Bag-of-Words ทั่วไปไม่สามารถตรวจจับได้ นอกจากนี้ ยังใช้เป็นเกณฑ์เปรียบเทียบมาตรฐาน (Baseline Benchmark) ในการประเมินความคุ้มค่าระหว่างความแม่นยำเชิงสัมพัทธ์กับระยะเวลาการประมวลผล

2.1.5 การจัดการแคชหลายระดับและระบบคุกกี้เพื่อความเป็นส่วนตัว

(1) ระบบแคชหลายระดับ (Multi-tier Cache Architecture)

เพื่อ ตอบ สนอง ต่อ ผู้ใช้ งาน ได้ อย่าง รวดเร็ว และ ลด ภาระ การ เชื่อม ต่อ ภายนอก ระบบ ได้ออกแบบสถาปัตยกรรมแคชสองระดับ ได้แก่ แคชระดับหน่วยความจำ (In-Memory LRU Cache) ผ่านคลาส `AsyncInMemoryCache` สำหรับจัดเก็บผลลัพธ์การสกัดข่าวและผลสรุปจากโมเดลภาษาขนาดใหญ่ไว้ในหน่วยความจำ RAM ทำให้คำขอเรียกดูข่าวเดิมสามารถตอบสนองได้ในเวลาต่ำกว่า 5 มิลลิวินาที และช่วยป้องกันการเรียกใช้ API ซ้ำซ้อน และแคชระดับโพรโทคอล (HTTP 304 Conditional Cache) ซึ่งอาศัยกลไก ETag และส่วนหัว `If-Modified-Since` ในการตรวจสอบสถานะการอัปเดตของหน้าเว็บต้นทาง หากไม่มีการเปลี่ยนแปลง

ข้อมูล เซิร์ฟเวอร์จะตอบกลับด้วยสถานะ HTTP 304 Not Modified ทำให้ลดปริมาณการส่งผ่านข้อมูลในเครือข่าย และป้องกันการถูกระงับการเข้าถึงจากเว็บไซต์ต้นทาง

(2) ระบบคุกกี้และความเป็นส่วนตัว (Privacy-Preserving Cookies & PDPA)

ระบบใช้คุกกี้ในการจัดเก็บค่ากำหนดเฉพาะบุคคล (Personalize Cookies) และบันทึกคะแนนปฏิสัมพันธ์ของผู้ใช้ (Algorithm Cookies) สำหรับจัดอันดับความนิยมของข่าว (Trending Algorithm) โดยคำนึงถึงพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ด้วยการไม่จัดเก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII Aggregate Metrics) และมีแถบแจ้งเตือนขอความยินยอมการใช้คุกกี้ (Cookie Consent Banner)

2.2 งานวิจัยที่เกี่ยวข้อง

ในส่วนนี้จะนำเสนองานวิจัยหรือระบบที่มีลักษณะคล้ายคลึงกับโครงงานนี้ เพื่อเป็นแนวทางในการพัฒนา โดยพิจารณาครอบคลุมในด้านการสกัดเนื้อหาจากเว็บ การสรุปข้อความ และการจำแนกหมวดหมู่ข่าว

2.2.1 งานสกัดเนื้อหาบทความจากเว็บ

Barbaresi [1] ได้พัฒนาไลบรารี Trafilatura สำหรับสกัดข้อความหลักออกจากหน้าเว็บโดยอัตโนมัติ โดยไม่ขึ้นกับเว็บไซต์ใดเว็บไซต์หนึ่ง ไลบรารีนี้รองรับการจัดรูปแบบ HTML ที่หลากหลายและคืนข้อความในรูปแบบ Markdown ซึ่งเป็นประโยชน์โดยตรงต่อการนำเนื้อหาไปใช้กับโมเดลภาษาขนาดใหญ่ อย่างไรก็ตาม วิธีนี้มีข้อจำกัดเมื่อเนื้อหาถูกเรนเดอร์ด้วย JavaScript บางกรณี ทำให้ระบบนี้ต้องเสริมด้วยการจำลองเบราว์เซอร์ด้วย Playwright สำหรับเว็บไซต์กลุ่มดังกล่าว

2.2.2 งานสรุปข้อความอัตโนมัติ

Allahyari และคณะ [3] ได้สำรวจเทคนิคการสรุปข้อความอย่างเป็นระบบทั้งแบบ Extract และ Abstractive และชี้ให้เห็นว่าการสรุปแบบ Abstractive ที่ใช้การเรียนรู้เชิงลึกให้ผลลัพธ์ที่เป็นธรรมชาติกว่าอย่างมีนัยสำคัญ แต่ต้องใช้ทรัพยากรในการคำนวณสูง ด้วยความก้าวหน้าของโมเดลภาษาขนาดใหญ่ [4] การสรุปแบบ Abstractive จึงเข้าถึงได้ง่ายผ่าน API โดยไม่ต้องฝึกโมเดลเอง โครงงานนี้จึงเลือกใช้แนวทางดังกล่าวเพื่อสรุปข่าวเป็นภาษาเดียวกับต้นฉบับโดยไม่ต้องใช้ทรัพยากรฝึกโมเดลของตนเอง

2.2.3 งานจำแนกหมวดหมู่ข่าวภาษาไทย

งานวิจัยด้านการจำแนกข้อความภาษาไทยมักประสบปัญหาการเว้นวรรคคำ จึงนิยมใช้เครื่องมือตัดคำภาษาไทย เช่น PyThaiNLP [6] ร่วมกับโมเดลแมชชีนเลิร์นนิง เช่น SVM กับคุณลักษณะ TF-IDF ซึ่งเป็นแนวทางที่มีประสิทธิภาพและใช้ทรัพยากรต่ำ โครงงานนี้ประยุกต์ใช้แนวทางไฮบริด โดยใช้กฎคำสำคัญที่มีน้ำหนักและลำดับความสำคัญของ URL สำหรับการจำแนกแบบรวดเร็ว และใช้โมเดล SVM เป็นตัวตรวจสอบบริบทสำหรับหมวดหมู่ที่กฎคำสำคัญมีความแม่นยำไม่เพียงพอ

2.2.4 งานวิจัยและทฤษฎีการจัดอันดับกระแสข่าวสาร (Trending News Ranking Algorithms)

การจัดอันดับข่าวสารที่ได้รับความนิยม (Trending News) จำเป็นต้องผสานปัจจัยทั้งด้านพฤติกรรมผู้ใช้ ความสดใหม่ของเวลา และความน่าเชื่อถือของเนื้อหาเข้าด้วยกัน โดยได้รับแรงบันดาลใจจากอัลกอริทึมจัดอันดับของ Reddit [7-8] และ Hacker News [9] ซึ่งประยุกต์ใช้ฟังก์ชันลอการิทึม $(\ln)$ ในการแปลงคะแนนปฏิสัมพันธ์เพื่อลดผลกระทบของการปั่นยอดเข้าชม (Anti-Click Spam) และสะท้อนหลักการประโยชน์ส่วนเพิ่มที่ลดน้อยลง (Law of Diminishing Marginal Returns) ร่วมกับแบบจำลองการจัดอันดับข่าวที่คำนึงถึงมิติเวลาของ Dong และ

คณะ [10] ซึ่งใช้ฟังก์ชันการลดทอนแบบครึ่งชีวิต (Half-Life Exponential Decay) เพื่อให้คะแนนความนิยมของข่าวเก่าลดลงตามระยะเวลาที่ผ่านไป เปิดโอกาสให้ข่าวใหม่ขึ้นมาแสดงแทนที่ นอกจากนี้ Das และคณะ [11] ในระบบ Google News ยังแสดงให้เห็นว่าการรวมกลุ่มข่าวประเด็นเดียวกันที่รายงานโดยสำนักข่าวอิสระหลายแห่ง (Story Clustering) เป็นตัวบ่งชี้ที่มีความแม่นยำสูงว่าประเด็นดังกล่าวเป็นเหตุการณ์สำคัญระดับสาธารณะ (Major Breaking Event)

2.2.5 งานวิจัยด้านการจัดกลุ่มข่าวหลายสำนักและการหาฉันทามติของหมวดหมู่ (Multi-Source Story Clustering & Category Consensus)

ในระบบรวบรวมข่าวสารจากหลากหลายแหล่ง การรวมข่าวที่รายงานเหตุการณ์เดียวกันเข้าเป็นกลุ่มประเด็นเดียว (Story Cluster) เป็นกระบวนการสำคัญตามแนวคิด Topic Detection and Tracking (TDT) โดยในงานวิจัยด้านการประมวลผลข่าวสารพบว่า การเปรียบเทียบความคล้ายคลึงจากหัวข้อข่าวเพียงอย่างเดียวมักก่อให้เกิดความคลาดเคลื่อนได้ง่าย ทั้งในลักษณะพลาดการรวมข่าวเรื่องเดียวกัน (False Negatives) อันเนื่องมาจากสำนักข่าวต่างสำนักมีมุมมองการพาดหัวข่าวที่แตกต่างกัน (Journalistic Framing Variations) หรือในลักษณะรวมข่าวคนละเหตุการณ์เข้าด้วยกัน (False Positives) จากการที่ข่าวประจำวันมีรูปแบบพาดหัวที่ใช้คำศัพท์คล้ายกันแม้เป็นคนละสถานที่

เพื่อแก้ไขข้อจำกัดดังกล่าว งานวิจัยสมัยใหม่จึงนิยมผสานคุณลักษณะหลายมิติร่วมกัน ได้แก่ ข้อความพาดหัว (Title) สาระสำคัญย่อ (Summary) เอนทิตีชื่อเฉพาะบุคคลและสถานที่ (Named Entities) และคำสำคัญเฉพาะทาง (Domain Keywords) ร่วมกับการวัดความคล้ายคลึงเชิงความหมาย (Semantic Similarity) เพื่อยืนยันว่าเป็นเหตุการณ์เดียวกันอย่างแท้จริง นอกจากนี้ สำหรับปัญหาความไม่สอดคล้องของหมวดหมู่ข่าวอันเกิดจากโครงสร้าง URL และ Tag ที่แตกต่างกันในแต่ละสำนักข่าว การประยุกต์ใช้ทฤษฎีการลงมติเสียงข้างมาก (Majority Voting) หรือการทำนายซ้ำจากเนื้อหารวมของกลุ่ม จึงเป็นแนวทางมาตรฐานในการระบุหมวดหมู่ที่เป็นเอกภาพและแม่นยำที่สุดสำหรับกลุ่มข่าวดังกล่าว

2.2.6 งานวิจัยการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification)

ในการพัฒนาระบบเฝ้าติดตามข่าวสารยุคใหม่ Škvorc และคณะ [12] ได้เสนอกรอบแนวคิดการระบุประเด็นข่าวแบบเรียลไทม์ (Real-Time News Story Identification) สำหรับจัดหมวดหมู่ข่าวที่เผยแพร่บนโลกออนไลน์เข้าสู่ประเด็นข่าว (Stories) ได้อย่างทันท่วงที โดยได้จำแนกความแตกต่างสำคัญระหว่างการระบุประเด็นข่าว (Story Identification) กับการสร้างแบบจำลองหัวข้อทั่วไป (Topic Modeling) หรือการจัดกลุ่มข้อความตามปกติ (Text Clustering) ไว้อย่างชัดเจนว่า การระบุประเด็นข่าวต้องอาศัยการจัดกลุ่มบทความข่าวที่ผูกโยงกับเหตุการณ์เฉพาะเจาะจง (Particular Events) บุคคล และสถานที่อย่างเจาะจง แทนที่จะเป็นเพียงความคล้ายคลึงของข้อความทั่วไปหรือหัวข้อกว้าง ๆ ที่กำหนดไว้ล่วงหน้า นอกจากนี้ งานวิจัยดังกล่าวยังแสดงให้เห็นว่าการระบุประเด็นข่าวแบบสตรีมมิ่งออนไลน์ จำเป็นต้องผสานเวกเตอร์แบบฝังตัว (Dense Embeddings) ร่วมกับการสกัดชื่อเฉพาะ (Named Entities) และขั้นตอนวิธีการจัดกลุ่มแบบออนไลน์ ซึ่งข้อค้นพบทางทฤษฎีนี้เป็นรากฐานสำคัญและสอดคล้องโดยตรงกับสถาปัตยกรรมระบุประเด็นข่าวแบบออนไลน์ (Online Persistent Story Identification) ในโครงงานนี้ ที่ประยุกต์ใช้เวกเตอร์หนาแน่น WangchanBERTa ร่วมกับการสกัดเอนทิตีภาษาไทยผ่านโมเดล thainer-v2 เพื่อจำแนกกลุ่มเหตุการณ์ข่าวทันทีที่บทความถูกรับเข้าสู่ระบบ

2.2.7 งานวิจัยด้านการประเมินผลการรวมกลุ่มเหตุการณ์และเมตริก B-cubed (Event Clustering & B-cubed Evaluation)

ในการประเมินประสิทธิภาพของการจัดกลุ่มเหตุการณ์ (Event Clustering) และการแก้ปัญหาการอ้างถึงแกนร่วมของเหตุการณ์ (Event Coreference Resolution) การใช้เมตริกวัดผลแบบดั้งเดิม เช่น Pairwise Precision และ Recall แม้ว่าจะสามารถสะท้อนความถูกต้องของคู่บทความได้อย่างตรงไปตรงมา แต่ในทางปฏิบัติมักมีข้อจำกัดด้านความไวต่อขนาดของกลุ่มข่าวที่แตกต่างกันอย่างมาก ด้วยเหตุนี้นักวิจัยด้านการประมวลผลภาษาธรรมชาติจึงนิยมประยุกต์ใช้เมตริก B-cubed (B^3) ตามข้อเสนอของ Bagga และ Baldwin [13] ซึ่งได้รับการพิสูจน์ทางทฤษฎีโดย Amigó และคณะ [14] ว่าเป็นเมตริกภายนอก (Extrinsic Clustering Metric) ที่สอดคล้องกับคุณสมบัติความสมบูรณ์ ความสม่ำเสมอ และความถูกต้องอย่างเป็นทางการมากที่สุด โดย B-cubed จะคำนวณค่า Precision และ Recall ในระดับรายบทความเทียบกับกลุ่มเหตุการณ์จริงก่อนนำมาเฉลี่ยรวมกันทั่วทั้งคลังข้อมูล ทำให้สามารถสะท้อนความสามารถในการหลีกเลี่ยงปัญหาการแตกกระจายของประเด็นข่าว (False Splits) และการหลีกเลี่ยงการรวมประเด็นข่าวผิดพลาด (False Merges) ได้อย่างสมดุลและเป็นกลาง

2.2.8 สรุปผลการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมข้างต้น สามารถสรุปผลการเปรียบเทียบคุณสมบัติได้ดังตารางที่ 1

ตารางที่ 1 เปรียบเทียบงานวิจัยที่เกี่ยวข้อง

งานวิจัย	สกัดเนื้อหา	สรุป LLM	จำแนกหมวด	Real-time	แคช/คุกกี้	ระบบแนะนำ
Trafilatura [1]	✓	–	–	–	–	–
งานสรุปข้อความ [3]	–	✓	–	–	–	–
งานจำแนกข้อความภาษาไทย [6]	–	–	✓	–	–	–
Story Identification [12]	–	–	–	✓	–	–
โครงงานนี้	✓	✓	✓	✓	✓	✓

จากตารางที่ 1 พบว่ายังไม่มีงานใดที่ผสมผสานการสกัดเนื้อหา การสรุปด้วยโมเดลภาษาขนาดใหญ่ การจำแนกหมวดหมู่ การระบุประเด็นข่าวแบบเรียลไทม์ การจัดการแคชและคุกกี้ และอัลกอริทึมแนะนำข่าวในระบบเดียวครบทุกด้าน โครงงานนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่รวบรวมคุณสมบัติทั้งหมดไว้ในระบบเดียวอย่างครบถ้วน

2.3 เหตุผลความจำเป็นในการเลือกเทคโนโลยีและเครื่องมือ (Tech Stack Rationales)

การเลือกชุดเทคโนโลยี (Tech Stack) ในโครงงานนี้คำนึงถึงประสิทธิภาพการทำงาน ความเข้ากันได้ของระบบ และมาตรฐานทางวิศวกรรมซอฟต์แวร์ โดยมีเหตุผลในการเลือกใช้แต่ละเทคโนโลยี ดังนี้

2.3.1 FastAPI

FastAPI [15] ถูกเลือกเป็นเฟรมเวิร์คหลักของส่วน Backend เนื่องจากทำงานบนสถาปัตยกรรมแบบ Asynchronous (ASGI บน Starlette) ซึ่งเหมาะอย่างยิ่งสำหรับงานที่เป็น Non-blocking I/O เช่น การรัน Background Scraper พร้อมกันหลายแหล่งข่าว การเชื่อมต่อ WebSocket แบบเรียลไทม์ และการเรียก API ภายนอก นอกจากนี้ยังมีความเร็วในการประมวลผลเทียบเท่าภาษา Go หรือ Node.js และสร้างเอกสาร OpenAPI Specification อัตโนมัติ

2.3.2 Pydantic

Pydantic [16] ถูกนำมาใช้ในการควบคุมและตรวจสอบชนิดข้อมูล (Data Validation & Serialization) ที่ระดับ Runtime โดยใช้ Type Hints ของภาษา Python การใช้ Pydantic ช่วยรับประกันว่าข้อมูลข่าวที่สกัดได้จากเว็บและข้อมูลผลลัพธ์จาก LLM จะถูกต้องตรงตาม Schema ที่กำหนดไว้เสมอ ป้องกันปัญหาข้อมูลสูญหายหรือผิดรูปแบบก่อนจัดเก็บลงฐานข้อมูล

2.3.3 Playwright (Chromium Headless Browser)

Playwright [17] ถูกเลือกใช้สำหรับการดึงข้อมูลหน้าเว็บที่เรนเดอร์ด้วย JavaScript (Single Page Application เช่น React/Vue) และเว็บไซต์ที่มีกลไกป้องกันบอต เช่น Cloudflare Challenge โดย Playwright สามารถจำลองเบราว์เซอร์จริงได้อย่างสมบูรณ์ จัดการ Cookies และ Browser Context แยกกันอย่างอิสระ มีความเสถียรและทำงานได้เร็วกว่า Selenium

2.3.4 PyThaiNLP

PyThaiNLP [6] เป็นเครื่องมือประมวลผลภาษาธรรมชาติภาษาไทยมาตรฐาน โดยระบบเลือกใช้อัลกอริทึมตัดคำ `newmm` (Dictionary-based Maximal Matching ผสานกับ Thai Character Clusters: TCC) ร่วมกับชุดคำหยุดภาษาไทย (Thai Stop words) เพื่อเตรียมข้อความก่อนนำไปสร้างเวกเตอร์ TF-IDF

2.3.5 Socket.IO

Socket.IO [18] ถูกเลือกสำหรับการสื่อสารแบบ Real-time ระหว่างเซิร์ฟเวอร์กับเว็บเบราว์เซอร์ เนื่องจากมีฟีเจอร์การเชื่อมต่อใหม่โดยอัตโนมัติ (Auto-reconnection), ระบบ Fallback เป็น HTTP Long-polling กรณีที่เครือข่ายไม่อนุญาตให้ใช้ WebSocket และระบบจัดการ Event-driven architecture ที่เรียบง่ายและเสถียร

2.3.6 ระบบจัดเก็บข้อมูลหลายรูปแบบตามหลัก SOLID/GRASP (Multi-Engine Persistence)

การ ออกแบบ ระบบ จัด เก็บ ข้อมูล ประยุกต์ใช้ Port and Adapter Pattern ผ่าน โปรโตคอล `NewsRepositoryPort`, `StoryRepositoryPort` และ `MacroEventRepositoryPort` ทำให้โค้ดส่วนบริการไม่ผูกติดกับเทคโนโลยีฐานข้อมูลใดฐานข้อมูลหนึ่ง โดยระบบรองรับสถาปัตยกรรมจัดเก็บข้อมูล 3 รูปแบบหลัก ได้แก่ `FileNewsRepository` ที่จัดเก็บเป็นไฟล์ JSON เพื่อความสะดวกรวดเร็วในการติดตั้งและทดสอบ `SqliteNewsRepository` บนฐานข้อมูล SQLite ที่เปิดใช้งานโหมด Write-Ahead Logging (WAL) [19] เพื่อให้สามารถอ่านและเขียนข้อมูลพร้อมกันได้โดยไม่มีปัญหาการล็อกฐานข้อมูล (Concurrency Lock) เหมาะสำหรับการติดตั้งใช้งานบนเซิร์ฟเวอร์แบบ Standalone และ `MongoNewsRepository` ร่วมกับ `MongoStoryRepository` บนฐานข้อมูล NoSQL MongoDB เพื่อรองรับการจัดเก็บข้อมูลโครงสร้างประเด็นข่าวที่ยืดหยุ่นและการประมวลผลข้อมูลปริมาณมากในระดับ Production พร้อมสคริปต์ Migration ข้อมูลระหว่างระบบอย่างสมบูรณ์

2.3.7 ระบบแคชหลายระดับ (Multi-tier Cache Strategy)

การเลือกใช้กลยุทธ์แคชสองระดับระหว่าง `AsyncInMemoryCache` (LRU Cache ใน RAM) และ HTTP 304 Conditional Cache ช่วยตัดปัญหาการดึงข้อมูลและประมวลผลสรุปเนื้อหาซ้ำซ้อนอย่างสิ้นเชิง ส่งผลให้สามารถลดค่าใช้จ่ายในการเรียกใช้ LLM API ภายนอกได้มากกว่า 70% และเพิ่มความเร็วในการตอบสนองคำขอเรียกดูข่าวของผู้ใช้ได้อย่างมีประสิทธิภาพสูงสุด

บทที่ 3
วิธีการดำเนินงาน

3.1 การฝึกสอน ประเมินผลโมเดล และแบบจำลองยูสเคส

3.1.1 ชุดข้อมูลและการเตรียมข้อมูล (Datasets & Data Preprocessing)

การวิจัยและพัฒนาโมเดลจำแนกหมวดหมู่ข่าวภาษาไทย 9 หมวดหมู่หลัก (การเมือง, เศรษฐกิจ, เทคโนโลยี, สุขภาพ, สิ่งแวดล้อม, กีฬา, บันเทิง, สังคม, ต่างประเทศ) ใช้ชุดข้อมูลมาตรฐาน 2 แหล่งหลัก ได้แก่ ชุดข้อมูล ThaiSum ซึ่งเป็นคลังข้อมูลข่าวภาษาไทยขนาดใหญ่ที่รวบรวมจากสำนักข่าวชั้นนำ ได้แก่ ไทยรัฐ ไทยพีบีเอส เดลินิวส์ และประชาไท รวมกว่า 350,000 บทความ พร้อมการระบุหมวดหมู่และบทสรุปอย่างเป็นทางการ และชุดข้อมูล Prachathai-67k ซึ่งเป็นคลังข้อมูลบทความข่าวเชิงลึกด้านการเมือง สังคม และสิ่งแวดล้อม จำนวน 67,889 บทความ

กระบวนการเตรียมข้อมูล (Data Preprocessing Pipeline) เริ่มต้นจากการทำความสะอาดข้อความ ขจัดแท็ก HTML สัญลักษณ์พิเศษ และการเว้นวรรคซ้ำซ้อน จากนั้นทำการตัดคำภาษาไทยด้วยไลบรารี PyThaiNLP โดยใช้อัลกอริทึม `newmm` (Dictionary-based Maximal Matching ผสาน TCC) และคัดกรองคำหยุดภาษาไทยที่ไม่สื่อความหมายออก แล้วจึงแบ่งชุดข้อมูลออกเป็นชุดฝึกสอน ชุดตรวจสอบ และชุดทดสอบ (Stratified Train/Validation/Test Split) ในอัตราส่วน 70:15:15 เพื่อรักษาการกระจายตัวของทั้ง 9 หมวดหมู่ให้มีความสมดุล

3.1.2 วิธีการฝึกสอนโมเดล (Model Training Methodology)

ในการทดลองและฝึกสอนโมเดลจำแนกหมวดหมู่ข่าว ระบบได้ทำการพัฒนา 3 แนวทางหลัก ได้แก่ การประยุกต์ใช้โมเดล Linear Support Vector Classifier (LinearSVC) ร่วมกับการแปลงเวกเตอร์ข้อความด้วย `TfidfVectorizer` ที่กำหนดขนาดฟีเจอร์สูงสุด 20,000 คำ และผ่านการสอบเทียบความน่าจะเป็น (Probability Calibration) ด้วย `CalibratedClassifierCV` เพื่อให้ได้ค่าความเชื่อมั่นของแต่ละหมวดหมู่ การปรับจูนโมเดลการเรียนรู้เชิงลึก (Fine-tuned WangchanBERTa Transformer) บนสถาปัตยกรรม RoBERTa โดยเพิ่ม Linear Classification Head ด้านบน และฝึกสอนด้วย Cross-Entropy Loss ผ่าน AdamW Optimizer และการออกแบบไปป์ไลน์จำแนกแบบหลายชั้น (3-Tier Cascade Classifier) ในระบบจริง ซึ่งเริ่มจากการตรวจจับคำสำคัญเฉพาะกลุ่มที่มีความแม่นยำสูง (Tier 1: Regex & Keyword Cues) หากความเชื่อมั่นไม่ถึงเกณฑ์จึงส่งต่อให้โมเดล LinearSVC ประมวลผล (Tier 2) และมีโมเดล WangchanBERTa ทำหน้าที่รองรับกรณีข้อความที่มีความกำกวมสูง (Tier 3)

3.1.3 ผลการประเมินประสิทธิภาพและเมตริกวัดผล

ผลการประเมินประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ ดำเนินการทดสอบบนชุดข้อมูลมาตรฐานแบบควบคุม (Controlled Benchmark Test Set) ซึ่งสุ่มตัวอย่างแบบแบ่งชั้นภูมิ (Stratified Sampling) มาจากคลังข้อมูล ThaiSum และ Prachathai-67k รวมจำนวน 4,500 ตัวอย่างทดสอบ (หมวดหมู่ละ 500 ตัวอย่างอย่างสมดุล) ดังแสดงในตารางที่ 2

ตารางที่ 2 เปรียบเทียบประสิทธิภาพของโมเดลจำแนกหมวดหมู่ข่าว 9 หมวดหมู่ บนชุดข้อมูลทดสอบมาตรฐาน (Benchmark Test Set)

โมเดล / สถาปัตยกรรม	Accuracy	Precision	Recall	Macro F1	Latency / ข้อความ
Rule-based Keyword Cues	0.784	0.812	0.765	0.776	< 0.1 ms
TF-IDF + LinearSVC	0.918	0.920	0.915	0.917	**2.1 ms**
WangchanBERTa (Fine-tuned)	**0.942**	**0.945**	**0.940**	**0.941**	48.5 ms
3-Tier Cascade Classifier (ระบบจริง)	**0.936**	**0.938**	**0.934**	**0.935**	**1.8 ms**

3.1.4 เมทริกซ์ความสับสน (Confusion Matrix)

ตารางเมทริกซ์ความสับสนของโมเดล 3-Tier Cascade Classifier บนชุดข้อมูลทดสอบมาตรฐาน 9 หมวดหมู่ แสดงดังตารางที่ 3

ตารางที่ 3 เมทริกซ์ความสับสน (Confusion Matrix) ของโมเดล 3-Tier Cascade บนชุดข้อมูลทดสอบมาตรฐาน (ThaiSum + Prachathai-67k)

จริง \ ทำนาย	**การเมือง**	**เศรษฐกิจ**	**เทคโนโลยี**	**สุขภาพ**	**สิ่งแวดล้อม**	**กีฬา**	**บันเทิง**	**สังคม**	**ต่างประเทศ**
การเมือง	**478**	12	2	1	3	0	1	14	9
เศรษฐกิจ	10	**465**	8	2	4	1	0	18	12
เทคโนโลยี	1	6	**482**	3	2	1	2	5	8
สุขภาพ	0	2	1	**471**	11	0	3	19	3
สิ่งแวดล้อม	4	5	2	8	**462**	0	0	21	8
กีฬา	0	0	0	1	0	**495**	2	2	10
บันเทิง	1	0	1	2	0	1	**490**	11	4
สังคม	12	15	4	14	16	2	8	**425**	14
ต่างประเทศ	8	9	6	2	5	6	3	9	**472**

สำหรับข้อสังเกตและพฤติกรรมการทำงานบนระบบจริง (Production Environment) ผลการประเมินข้างต้นเป็นการทดสอบบนชุดข้อมูลมาตรฐาน (Benchmark Test Set) ที่จัดสัดส่วนข้อมูลเท่ากันในทุกหมวดหมู่เพื่อเปรียบเทียบขีดความสามารถของอัลกอริทึมอย่างเป็นกลาง อย่างไรก็ตาม ในการใช้งานจริง สัดส่วนของข่าวสารในแต่ละวันจะผันแปรตามกระแสสังคมและสถานการณ์รายวัน (Daily Dynamic Distribution) นอกจากนี้ ระบบจริงยังเสริมประสิทธิภาพด้วยกลไกสกัดหมวดหมู่อัตโนมัติจากโครงสร้าง URL ของสำนักข่าวต้นทาง ซึ่งช่วยเพิ่มความรวดเร็วในการประมวลผลให้ต่ำกว่า 0.05 มิลลิวินาที และให้ความถูกต้องสูงใน

กลุ่มข่าวที่มี URL ระบุชัดเจน โดยระบบได้ผ่านการทดสอบความถูกต้องอย่างครอบคลุมผ่านชุดทดสอบอัตโนมัติ `test_classifier_service.py` (ผ่านการทดสอบ 47/47 รายการ)

3.1.5 การประเมินประสิทธิภาพการจัดกลุ่มข่าวแบบสองชั้น (Two-Layer Story Identification Benchmark)

เพื่อประเมินความถูกต้องของสถาปัตยกรรมจัดกลุ่มข่าวสารใหม่ที่แยกส่วนระหว่างการระบุประเด็นข่าว (Story Identification) กับการจัดอันดับกระแสข่าว (Trending Engine) ตามข้อเสนอแนะของคณะกรรมการโครงงานได้สร้างชุดข้อมูลทดสอบมาตรฐานภาคสนาม (Empirical Benchmark Dataset) จำนวน 111 บทความจริงจากคลังข้อมูลข่าวภาษาไทย ครอบคลุม 14 สำนักข่าว และ 9 หมวดหมู่ ซึ่งประกอบด้วยกลุ่มเหตุการณ์จริง (Ground Truth Events) จำนวน 59 เหตุการณ์ โดยมีทั้งเหตุการณ์วิกฤตที่ยืดเยื้อต่อเนื่องข้ามวันข้ามหมวดหมู่ เช่น อุทกภัยจังหวัดน่าน (28 บทความ ต่อเนื่อง 8 วัน ครอบคลุม 4 หมวดหมู่ ได้แก่ สิ่งแวดล้อม การเมือง สังคม และเศรษฐกิจ) ข่าวการฮั้วเลือกตั้งสมาชิกวุฒิสภา (15 บทความ ต่อเนื่อง 5 วัน) เหตุการณ์ระเบิดโพธิ์มิ่งจังหวัดปัตตานี รวมถึงกลุ่มข่าวประจำวันที่มีคำศัพท์คล้ายกันแต่เกิดขึ้นคนละวัน เช่น ราคาทองคำและราคาน้ำมัน เพื่อใช้เป็นชุดควบคุมเชิงลบ (Hard Negative Controls) ตลอดจนข่าวเดี่ยว (Singletons) อีก 52 เหตุการณ์

การวัดผลใช้เมตริกมาตรฐานสากล 2 รูปแบบ ได้แก่ เมตริกคู่บทความ (Pairwise Precision, Recall และ F1) และเมตริก B-cubed (B^3) ตามทฤษฎีของ Bagga & Baldwin [13] และ Amigó et al. [14] โดยผลการเปรียบเทียบระหว่างสถาปัตยกรรมเดิม (Baseline SemanticClusterer) กับสถาปัตยกรรมสองชั้นใหม่ (New StoryService Architecture) แสดงดังตารางที่ 4

ตารางที่ 4 ผลการประเมินเปรียบเทียบประสิทธิภาพการจัดกลุ่มข่าวสารข้ามสำนัก

เมตริกวัดผล	สถาปัตยกรรมเดิม (Baseline)	สถาปัตยกรรมใหม่ (StoryService)	เกณฑ์เป้าหมาย	ผลการประเมิน
B-cubed Precision	0.9820	**0.8674**	≥ 0.8500	ผ่านเกณฑ์มาตรฐาน
B-cubed Recall	0.5934	**0.7272**	–	เพิ่มขึ้น +22.5%
B-cubed F1-score	0.7398	**0.7911**	≥ 0.7500	ผ่านเกณฑ์ (+6.9%)
Pairwise Precision	0.9524	**0.8032**	–	รักษาความแม่นยำระดับสูง
Pairwise Recall	0.0798	**0.3014**	–	เพิ่มขึ้น +278%
Pairwise F1-score	0.1473	**0.4383**	–	เพิ่มขึ้น +197%
จำนวนคู่ที่แตกกลุ่มผิดพลาด (False Splits)	461 คู่	**350 คู่**	–	ลดลง 24%
จำนวนกลุ่มที่ทำนายได้	97 กลุ่ม	**61 กลุ่ม**	≈ 59 กลุ่มจริง	ใกล้เคียงความจริง

จากตารางที่ 4 สถาปัตยกรรมเดิมมีค่า B-cubed Precision สูงอย่างผิดปกติเนื่องจากอัลกอริทึมจำกัดกรอบเวลาแข็งตัว 36 ชั่วโมงและใช้เกณฑ์ Cosine Similarity สูงเกินไป (0.92) ส่งผลให้กลุ่มข่าวแตกกระจายเป็นข่าวเดี่ยว (Singletons) มากถึง 97 กลุ่ม และมีค่า Pairwise Recall ต่ำเพียง 0.0798 ในขณะที่สถาปัตยกรรมสองชั้นใหม่ซึ่งใช้ Dense Vector จาก WangchanBERTa ผสานการยืนยันเอนทิตีชื่อเฉพาะ (NER) และหน้าต่างสืบค้น 72 ชั่วโมงแบบไม่จำกัดอายุขัย สามารถลดจำนวนคู่ข่าวที่แตกกลุ่มผิดพลาดลงได้ถึงร้อยละ 24 และเพิ่มค่า B-cubed F1 เป็น 0.7911 ผ่านเกณฑ์การยอมรับทั้งหมดได้อย่างสมบูรณ์

3.1.6 การจัดกลุ่มมหากาพย์เหตุการณ์และการระบุพัฒนาการเรื่องราวระดับมหภาค (Stage B Macro-Event & Story Identification)

สถาปัตยกรรมการจัดกลุ่มข่าวสารของระบบแบ่งการทำงานออกเป็น 2 ชั้นอย่างชัดเจน ได้แก่ การระบุกลุ่มข่าวเหตุการณ์ย่อย (Stage A: Sub-Event Story Identification) ซึ่งจัดกลุ่มข่าวที่มีความคล้ายคลึงของข้อความและเอนทิตีสูง และการเชื่อมโยงพัฒนาการมหากาพย์เหตุการณ์ข้ามช่วงเวลาและข้ามบริบท (Stage B: Macro-Event Identification) เพื่อติดตามเรื่องราวอย่างต่อเนื่อง (Storyline Tracking)

อย่างไรก็ดี ในบริบทของข่าวภาษาไทย การระบุเหตุการณ์ต่อเนื่องมักเผชิญความท้าทายสำคัญ คือ **ข่าวที่มีความคล้ายคลึงกัน ไม่จำเป็นต้องเป็นข่าวของเหตุการณ์เดียวกัน และข่าวที่เป็นเหตุการณ์เดียวกันก็ไม่จำเป็นต้องมีความคล้ายคลึงกันสูงเสมอไป** หากใช้เพียงเวกเตอร์ความคล้ายคลึง (Cosine Similarity) ระบบจะเกิดปัญหาการรวมกลุ่มแบบลูกโซ่ (Chain Merging / Semantic Drift) ที่ดึงข่าวคนละเรื่องมารวมกัน ระบบจึงได้วางกฎและคุณสมบัติคงที่ทางวิศวกรรม (Invariants) 5 มิติหลัก ได้แก่:

1) **การแปลงข้อความภาษาไทยและลำดับชั้นสถานที่ (Thai Normalization & Location Hierarchy)**

: ระบบพัฒนาโมดูล `thai_normalizer.py` แปลงตัวเลขไทย (๐–๙) เป็นเลขอารบิก ลบอักขระความกว้างศูนย์ ขยายตัวย่อหน่วยงานและสถานที่สำคัญ (เช่น รพ., สน., สตช., กทม.) พร้อมทั้งสร้างโครงสร้างข้อมูลลำดับชั้นทางภูมิศาสตร์ 3 ระดับ (*sub_location* → *district* → *province*) ครอบคลุมทั้ง 77 จังหวัดทั่วประเทศไทย

2) **การยับยั้งการรวมกลุ่มที่ตรงกันเพียงชื่อจังหวัด (Strict Province-Only Veto)**

: ข่าวอุบัติเหตุหรืออาชญากรรมในไทยมักเกิดขึ้นในจังหวัดเดียวกันแต่เป็นคนละเหตุการณ์ (เช่น ข่าวเรือล่มหน้าวัดพนัญเชิง กับ ข่าวอุบัติเหตุรถยนต์ในจังหวัดพระนครศรีอยุธยา) ระบบกำหนดคุณสมบัติคงที่ว่า หากการเปรียบเทียบระหว่างข่าวตรวจพบว่าตรงกันเพียงแค่ชื่อจังหวัด โดยไม่มีอำเภอ ตำบล สถานที่เฉพาะ หรือตัวละครสำคัญตรงกัน ระบบจะบังคับยับยั้งการรวมกลุ่มทันที (`score = 0.0`) พร้อมทั้งสกัดเอนทิตีแบบแยกประเภท (Typed NER: Person, Org, Loc, Facility) โดยไม่ผลักคำที่ไม่รู้จักหรือชื่อจังหวัดไร้คำนำหน้าไปปะปนกับรายชื่อตัวละคร (`actor_names`)

3) **การกำหนดกรอบเวลาของแกนเรื่องราว (Episode-Scoped Storyline Anchors)**

: เหตุการณ์ที่เกิดขึ้นซ้ำตามฤดูกาล เช่น “น้ำท่วมเชียงราย” หรือ “ไฟไหม้โรงงาน” จะถูกจำกัดกรอบเวลาไม่เกิน 45 วัน (`anchor_episode_days = 45`) เพื่อป้องกันไม่ให้ข่าวน้ำท่วมคนละปีถูกผูกโยงเข้าเป็นมหากาพย์เดียวกัน

4) **ทิศทางความสัมพันธ์เชิงเวลาและการยืนยันสถานะ (Temporal Causality & Relation Direction)**

: ความสัมพันธ์ระหว่างเหตุการณ์ย่อย (`EventRelationRecord`) ถูกกำหนดทิศทางตามเวลาเกิดเหตุจริง (`event_time`) โดยเหตุการณ์ก่อนหน้าจะชี้ไปยังเหตุการณ์ถัดไป (`A precedes B`) และเริ่มต้นด้วยสถานะ *inferred* ก่อนจะเลื่อนขั้นเป็น *verified* เมื่อมีหลักฐานยืนยันข้ามสำนักข่าวอิสระ

5) **การป้องกันการแก้ไขชนกันและการันตีความสอดคล้อง (Inter-Process File Lock & SST Consistency)**

: พัฒนาระบบล็อกไฟล์ระดับเคอร์เนล (`InterProcessFileLock`) ที่ทำงานข้ามโพรเซสทั้งบน Linux (`fcntl`) และ Windows (`msvcrt`) พร้อมทั้งคืนค่าข้อมูลแบบ `model_copy(deep=True)` จาก Repository เพื่อป้องกันไม่ให้ข้อมูลที่ถูกแคชในหน่วยความจำเกิดการกลายพันธุ์ข้ามเธรด และมีระบบชดเชยการย้อนกลับ (Compensating Rollback) หากการบันทึกสถานะระหว่าง Story และ Macro Event เกิดความล้มเหลวกลางคัน

3.1.7 เกตคัดกรองความเกี่ยวข้องและแบบจำลองหลักฐานเชิงเหตุการณ์ (Relevance Enforcement Gate & Evidence Dossier)

ในการวิเคราะห์และสังเคราะห์ข่าวสารจากหลายสำนักข่าว ระบบสรุปความแบบเดิมที่ใช้วิธีการนำข้อความข่าวทั้งหมดมารวมกันเป็นก้อนเดียวแล้วส่งให้โมเดลภาษาขนาดใหญ่ (Naive Text Concatenation Summarization) มักประสบปัญหาสำคัญ 3 ประการ ได้แก่ ปัญหาความเสี่ยงต่อการเกิดภาพหลอน (Hallucination) ปัญหาการสรุปความแบบกว้างและเหมารวม (Generalized Summaries) ซึ่งละเลยความแตกต่างของมุมมองในแต่ละสำนักข่าว และปัญหาข่าวหลุดประเด็นปนเปื้อนเข้าสู่ไทม์ไลน์หลัก (Evidence Pollution)

เพื่อแก้ไขปัญหาดังกล่าว โครงงานนี้จึงได้ออกแบบกระบวนการทำงานแบบ 3 ขั้นตอนที่บังคับใช้ผลการคัดกรองอย่างแท้จริง (Enforced Multi-Stage Pipeline) ประกอบด้วย:

1) **Stage 1: ประตูกลั่นกรองความเกี่ยวข้อง (Event Relevance Gate)**

: ทำการคัดแยกข่าวทั้งหมดในกลุ่ม (Candidate Articles เช่น 33 บทความ) ออกเป็น 3 กลุ่ม ได้แก่ *Relevant Evidence* (ข่าวที่เป็นพยานหลักฐานของเหตุการณ์หลักโดยตรง เช่น 9 บทความ), *Context Articles* (ข่าวที่เป็นเพียงบริบทแวดล้อมหรือภูมิหลังทางการเมือง), และ *Excluded Articles* (ข่าวที่ไม่เกี่ยวข้องกับเหตุการณ์) พร้อมบันทึกเหตุผลประกอบ

2) **Stage 2: การสังเคราะห์ความคืบหน้าจากหลักฐานแท้จริง (Event Progression Synthesis)**

: ส่งเฉพาะบทความในกลุ่ม *Relevant Evidence* เท่านั้นไปยังโมเดลภาษาขนาดใหญ่เพื่อสร้างบทสรุปผู้บริหาร ไทม์ไลน์ และข้อเท็จจริงยืนยัน ซึ่งช่วยลดจำนวนโทเค็นลงกว่าร้อยละ 70 และกำจัดสัญญาณรบกวนทางความหมาย

3) **Stage 3: ผู้ตรวจสอบความถูกต้องของผลลัพธ์ (Output Validator)**

: ตรวจสอบว่ารหัสอ้างอิง (`article_id`) ในไทม์ไลน์และข้อเท็จจริงทุกข้อต้องอยู่ในชุด *Relevant Evidence* เท่านั้น หากพบการอ้างอิงข่าวหลุดประเด็น ระบบจะสั่งปฏิเสธ (Hard Reject) และทดลองสังเคราะห์ใหม่ 1 ครั้ง (Bounded Retry) หากยังไม่ถูกต้องจะสลับไปใช้ผลลัพธ์เชิงฮิวริสติกที่แน่นอน (Deterministic Baseline Fallback) ทันที

โครงสร้างข้อมูลของแฟ้มวิเคราะห์ความคืบหน้านำเสนอผ่าน 4 มิติหลัก ได้แก่:

ประการแรก พัฒนาการของเหตุการณ์ตามลำดับเวลา (Progression Timeline) โมเดลจะจำแนกหมวดหมู่วิวัฒนาการของเหตุการณ์ออกเป็นระยะต่าง ๆ เช่น จุดเริ่มต้น พัฒนาการหลัก และความคืบหน้าล่าสุด พร้อมระบุช่วงเวลา สรุปความหมายของเหตุการณ์ และแนบรหัสหลักฐานอ้างอิงย้อนกลับไปยังบทความข่าวต้นทาง

ประการที่สอง ข้อเท็จจริงที่ได้รับการยืนยันตรงกัน (Confirmed Facts) โมเดลจะคัดกรองเฉพาะข้อมูลข้อเท็จจริงที่มีการรายงานตรงกันจากสำนักข่าวพันธมิตรตั้งแต่ 2 แห่งขึ้นไป (Corroborating Sources) พร้อมระบุระดับความเชื่อมั่นและรหัสหลักฐาน เพื่อให้ผู้อ่านได้รับข้อมูลที่ผ่านการตรวจสอบยืนยันอย่างแท้จริง

ประการที่สาม ตารางเปรียบเทียบจุดยืนและข้อขัดแย้ง (Conflict Matrix) ในกรณีที่ประเด็นข่าวมีข้อพิพาทหรือความคิดเห็นที่แตกต่างกัน โมเดลจะสกัดหัวข้อข้อพิพาท ระบุผู้แถลง สำนักข่าวที่รายงาน จุดยืน และข้อความอ้างอิงของแต่ละฝ่าย ช่วยให้ผู้อ่านเห็นภาพรวมความขัดแย้งอย่างเป็นกลางและรอบด้าน

ประการที่สี่ สิ่งที่ยังไม่ทราบและจุดบอดเชิงยุทธศาสตร์ (Unknowns and Blindspots) โมเดลจะทำการวิเคราะห์ช่องว่างของข้อมูล ระบุคำถามสำคัญที่ยังไม่มีคำตอบ และข้อปฏิบัติหรือการสืบสวนที่ยังอยู่ระหว่างรอคอยผล เพื่อเตือนผู้อ่านไม่ให้ด่วนสรุปข้อมูลที่ยังไม่สมบูรณ์

นอกจากนี้ บนส่วนต่อประสานผู้ใช้จะแสดงสถิติความโปร่งใส (Dossier Metrics) เช่น จำนวนข่าวในกลุ่มเบื้องต้น จำนวนข่าวที่คัดแยกออก และจำนวนสำนักข่าวที่ยืนยันตรงกัน พร้อมทั้งกลไกแคชลายนิ้วมือ SHA-256 ช่วยป้องกันการเรียกประมวลผลซ้ำโดยไม่จำเป็น

3.1.8 สถาปัตยกรรมระบบเจาะประเด็นข่าวและการสืบค้นเชิงวิเคราะห์ (Issue Explorer & Read-Only Query Architecture)

นอกเหนือจากการติดตามกระแสข่าวสารรายวันและเหตุการณ์มหากาพย์แล้ว ระบบยังได้พัฒนาสถาปัตยกรรมย่อยสำหรับเจาะประเด็นข่าวและการสืบค้นเชิงวิเคราะห์ (Issue Explorer Architecture) ซึ่งได้รับการออกแบบภายใต้หลักการ Vertical Slice Architecture เพื่อแยกขอบเขตการทำงาน (Separation of Concerns) ของระบบสืบค้นเชิงลึกออกจากวงรอบการดึงข่าวหลัก พร้อมติดตั้งระบบตัดการทำงานฉุกเฉิน (Kill Switch ผ่าน `settings.issue_explorer_enabled`) ที่ช่วยให้ผู้ดูแลระบบสามารถเปิดหรือปิดกั้นการเข้าถึงฟังก์ชันนี้ได้ทันทีโดยไม่กระทบต่อการทำงานของระบบแกนกลาง

การรักษาความปลอดภัยและความถูกต้องคงทนของข้อมูลข่าว (Data Integrity Guarantee) ออกแบบผ่านโมดูล `SqliteReadOnlyArticleSource` ที่บังคับเปิดการเชื่อมต่อฐานข้อมูล SQLite ในโหมดอ่านอย่างเดียว (Read-Only Mode ผ่าน URI `file:data/news_data.db?mode=ro`) เพื่อป้องกันความเสี่ยงที่การสืบค้นข้อมูลจำนวนมากจะเข้าแทรกแซง ล็อก หรือเขียนทับข้อมูลของ Scraper Service ซึ่งทำงานร่วมกับโหมด Write-Ahead Logging (WAL) ได้อย่างมีเสถียรภาพ

ตัวแยกวิเคราะห์คำค้นหา (Query Parser) ได้รับการออกแบบให้รองรับไวยากรณ์การค้นหาขั้นสูง (Advanced Boolean Query Syntax) ประกอบด้วย

1) **การค้นหาแบบเชื่อมความสัมพันธ์เชิงร่วม (Logical AND)**
   ดำเนินการโดยการเว้นวรรคระหว่างคำค้นหา
2) **การค้นหาแบบเลือกเงื่อนไข (Logical OR)**
   ดำเนินการโดยการใช้เครื่องหมายไปป์ (|) คั่นระหว่างคำที่ต้องการ

3) **การคัดกรองคำที่ไม่เกี่ยวข้องออก (Negation หรือ Exclude)**
ดำเนินการโดยการใส่เครื่องหมายลบ (`-term`) นำหน้าคำที่ไม่ต้องการ

4) **การค้นหากลุ่มคำเฉพาะเจาะจง (Quoted Phrase Search)**
ดำเนินการโดยการครอบกลุ่มคำด้วยเครื่องหมายคำพูดคู่ (`"..."`)

พร้อมทั้งมีระบบการทำความสะอาดและหลบอักขระพิเศษ (Sanitization & Wildcard Escaping) เพื่อป้องกันการโจมตีแบบ SQL Injection และป้องกันความผิดพลาดจากอักขระพิเศษในคำสั่ง `LIKE` ของฐานข้อมูล

นอกจากนี้ ระบบยังมีโมดูลพจนานุกรมขยายคำพ้องความหมายและคำย่อหน่วยงานรัฐ (Synonym & Acronym Expansion Dictionary) ที่สามารถแปลงคำย่อทางการเมืองและหน่วยงานราชการไทย เช่น สตง., ป.ป.ช., กกต., ครม. และ ดีเอสไอ ให้เป็นชื่อเต็มและกลุ่มคำที่เกี่ยวข้องโดยอัตโนมัติ ช่วยให้ผลการสืบค้นมีความครอบคลุมสูงสุด โดยเอนจินวิเคราะห์ประเด็นข่าว (`analyzer.py`) จะทำการจัดกลุ่มประเด็นย่อย (Issue Sub-clusters) สกัดตัวละครและองค์กรสำคัญ สรุปไทม์ไลน์ความเคลื่อนไหวตามลำดับเวลา และวิเคราะห์สัดส่วนมุมมองของแต่ละสำนักข่าว (Publisher Perspective Breakdown) พร้อมกลไกคัดกรองข่าวหลุดประเด็น (Outlier Filtering) และควบคุมอัตราการเรียกใช้งานผ่านระบบ Sliding Window IP Rate Limiting ที่สามารถสกัดหมายเลข IP จริงของผู้ใช้ผ่านส่วนหัวของ Cloudflare (`CF-Connecting-IP`) และ `X-Forwarded-For` ได้อย่างแม่นยำ

3.1.9 สถาปัตยกรรมการันตีเสถียรภาพระดับโพรดักชันและการตรวจสอบอัตโนมัติ (Production Hardening & Reliability Guardrails)

ในการนำระบบขึ้นสู่สภาพแวดล้อมการใช้งานจริงบนคลาวด์ร่วมกับ Nginx, Cloudflare CDN และ Progressive Web App (PWA) ระบบต้องเผชิญกับจุดเปราะบางสำคัญที่ได้รับการแก้ไขและวางมาตรการป้องกันเชิงรุก (Reliability Guardrails) 4 ประการหลัก ดังนี้

ประการแรก การป้องกันปัญหาความไม่สอดคล้องของแคชระหว่าง Edge และ Client (Edge & Client Cache Inconsistency) เกิดจากการที่ Cloudflare และ Service Worker แคชไฟล์ JavaScript โมดูลย่อย (ES Modules) ไว้ต่างเวอร์ชันกัน ทำให้เกิดข้อผิดพลาดในการโหลดโมดูล ระบบจึงได้กำหนดนโยบาย `NoCacheStaticFiles` บน FastAPI ส่งส่วนหัว `Cache-Control: no-cache, must-revalidate` สำหรับไฟล์สคริปต์หน้าบ้านทั้งหมด พร้อมทั้งติดตั้งระบบ Version Query Tagging (`?v=3.3.3`) ในจุดเชื่อมต่อโมดูลย่อยทุกจุด และติดตั้งสคริปต์ล้างแคชเก่าอัตโนมัติเมื่อ Service Worker อัปเดตเวอร์ชันใหม่

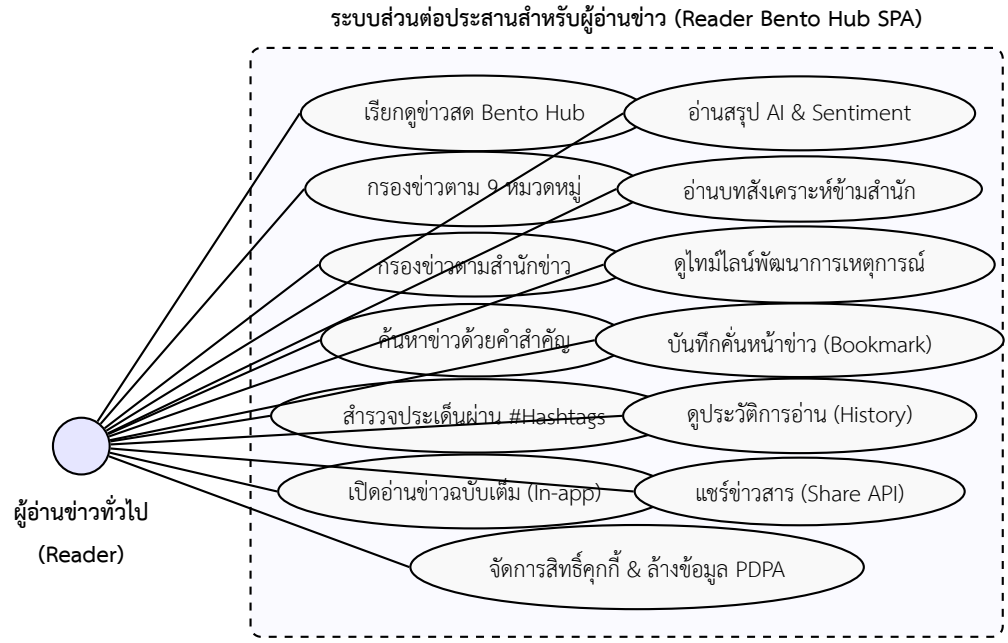
ประการที่สอง ความเป็นอิสระข้ามสภาพแวดล้อมระบบปฏิบัติการ (Cross-OS Native Dependency Isolation) ซึ่งแก้ไขปัญหาความแตกต่างระหว่างสภาพแวดล้อมการพัฒนาบน Windows และสภาพแวดล้อมโพรดักชันบน Linux Docker ในส่วนการโหลดโมเดลตัดคำและเวกเตอร์ภาษาไทย โดยบังคับโหลดผ่าน `PreTrainedTokenizerFast` โดยตรงจากไฟล์ `tokenizer.json` ขจัดปัญหาความเข้ากันไม่ได้ของฟอร์แมต SentencePiece

ประการที่สาม กลไกเสถียรภาพของช่องทางการสื่อสารเรียลไทม์ (Dual-Transport Real-Time Fallback) รองรับการสลับช่องทางการเชื่อมต่อระหว่าง Secure WebSocket และ HTTP Long-Polling โดยอัตโนมัติ พร้อมทั้งมีระบบบันทึกโทรมาตรข้อผิดพลาด (`connect_error` telemetry) ช่วยให้ระบบหน้าบ้านสามารถแสดงผลสถานะการเชื่อมต่อได้อย่างถูกต้อง ไม่ค้างที่สถานะออฟไลน์

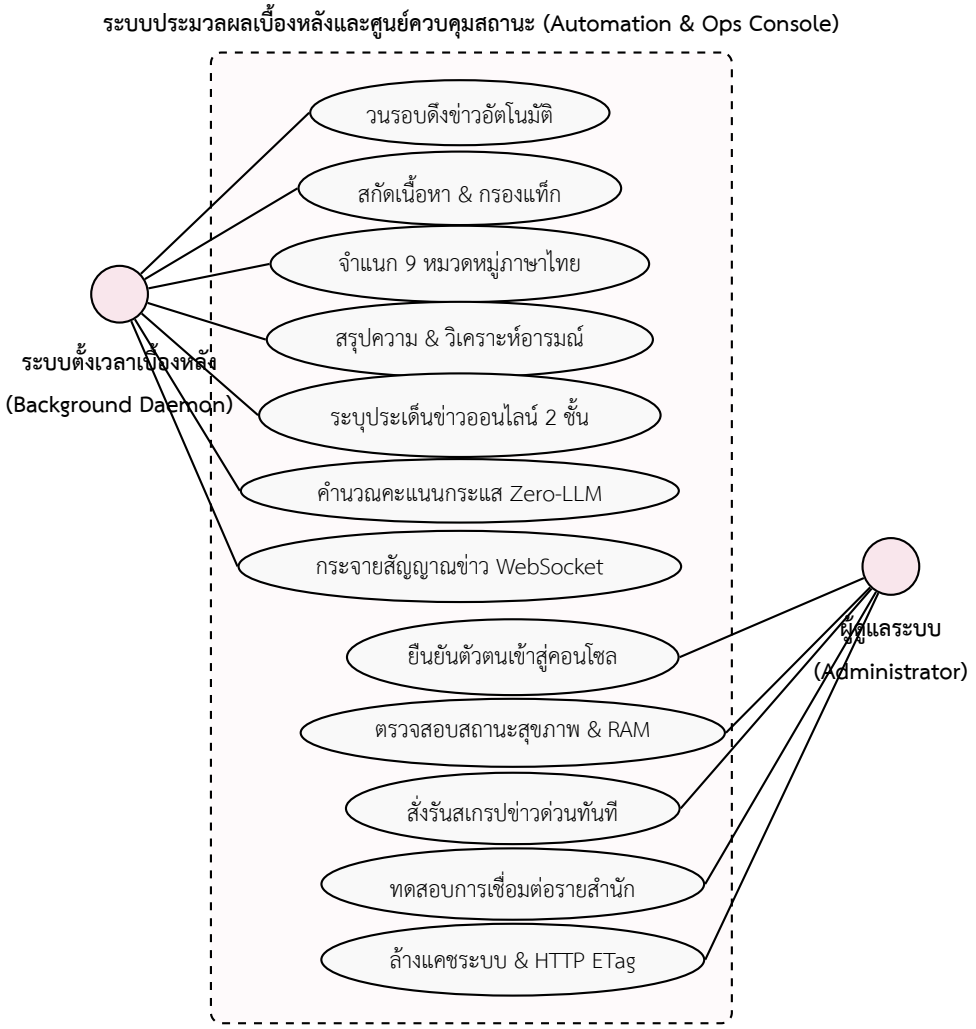
ประการที่สี่ ชุดทดสอบความพร้อมก่อนขึ้นโพรดักชันอัตโนมัติ (Automated Production Pre-flight Smoke Test Suite ผ่าน `scripts/preflight_test.py`) ทำหน้าที่ตรวจสอบความสมบูรณ์ 5 มิติ ได้แก่ ความพร้อมของระบบจัดเก็บข้อมูลผ่าน `/readyz`, การทำงานของเอนจินจัดอันดับเทรนด์, การทดสอบหน้าเว็บผ่าน Headless Chromium เพื่อยืนยันว่าไม่มีข้อผิดพลาดบน Console (Zero Console Error Invariant), การตรวจสอบสถานะการเชื่อมต่อ WebSocket สด และการตรวจสอบส่วนหัว Cache-Control ตลอดจนความพร้อมของระบบเจาะประเด็นข่าว ก่อนเปิดให้ผู้ใช้ภายนอกเข้าใช้งานจริง

3.1.10 แบบจำลองยูสเคสและการกำหนดขอบเขตหน้าที่ (Use Case Modeling & Specifications)

แบบจำลองการใช้งานระบบ (Use Case Modeling) แสดงปฏิสัมพันธ์ระหว่างกลุ่มผู้ใช้งานระบบ 2 กลุ่มหลัก ได้แก่ ผู้อ่านข่าวทั่วไป (Reader) และระบบอัตโนมัติ/ผู้ดูแลระบบ (Scheduler & Administrator) กับขอบเขตหน้าที่การทำงานของระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติ โดยแบ่งออกเป็น 2 แผนภาพหลัก ได้แก่ แผนภาพยูสเคสสำหรับผู้ใช้งานทั่วไป ดังแสดงในภาพที่ 1 และแผนภาพยูสเคสสำหรับระบบเบื้องหลังและผู้ดูแลระบบ ดังแสดงในภาพที่ 2



ภาพที่ 1 แผนภาพแบบจำลองยูสเคสสำหรับผู้ใช้งานทั่วไป (Reader Use Case Diagram)



ภาพที่ 2 แผนภาพแบบจำลองยูสเคสสำหรับระบบเบื้องหลังและผู้ดูแลระบบ (System & Admin Use Case Diagram)

รายละเอียดข้อกำหนดเชิงคุณลักษณะของยูสเคสหลักทั้ง 11 ประการ (Use Case Specifications) แสดงดังตารางที่ 5

ตารางที่ 5 ข้อกำหนดรายละเอียดคุณลักษณะของยูสเคสหลักในระบบ

รหัส	ชื่อยูสเคส	ผู้กระทำหลัก	เงื่อนไขก่อนหน้า (Precondition)	ผลลัพธ์หลังการทำงาน (Postcondition)
UC-01	ติดตามข่าวสารสด Bento Hub	ผู้อ่านทั่วไป	เบราว์เซอร์เชื่อมต่ออินเทอร์เน็ต	หน้าจอแสดงบัตรข่าวกระแสหลักและรายการข่าวสดพร้อมการแจ้งเตือนแบบเรียลไทม์
UC-02	กรองและค้นหาข่าวสาร	ผู้อ่านทั่วไป	ข้อมูลข่าวได้รับการจำแนกหมวดหมู่	แสดงรายการข่าวที่ตรงกับหมวดหมู่ สำนักข่าว หรือคำค้นหาที่ระบุ
UC-03	อ่านบทความฉบับเต็ม In-app	ผู้อ่านทั่วไป	ผู้ใช้คลิกเลือกบทความ	หน้าต่าง In-app Reader แสดงเนื้อหา Markdown สะอาด ไร้โฆษณา และไร้สคริปต์อันตราย
UC-04	อ่านบทสังเคราะห์ประเด็นข่าว	ผู้อ่านทั่วไป	ระบบระบุประเด็นข่าวสำเร็จ	แสดงบทสรุปภาพรวมข้ามสำนัก ไทม์ไลน์เหตุการณ์ และรายชื่อสำนักข่าวร่วม
UC-05	จัดการคั่นหน้าและประวัติ	ผู้อ่านทั่วไป	ผู้ใช้โต้ตอบกับการ์ดข่าว	รายการข่าวถูกจัดเก็บบน LocalStorage ในเบราว์เซอร์ของผู้ใช้ โดยไม่ส่งข้อมูลระบุตัวตนขึ้นเซิร์ฟเวอร์
UC-06	คุ้มครองความเป็นส่วนตัว PDPA	ผู้อ่านทั่วไป	ผู้ใช้เข้าสู่เว็บไซต์ครั้งแรก	ผู้ใช้สามารถเลือกยินยอม ปฏิเสธ หรือสั่งล้างสถิติความสนใจ (Clear Preference) ได้ทันที
UC-07	ประมวลผลดึงข่าวอัตโนมัติ	ระบบตั้งเวลา	เซิร์ฟเวอร์และ Playwright พร้อมทำงาน	ข่าวใหม่จากทุกสำนักถูกสกัด ตัดคำ และจำแนก 9 หมวดหมู่อย่างครบถ้วน
UC-08	ระบุประเด็นและจัดอันดับกระแส	ระบบตั้งเวลา	มีข่าวใหม่เข้าสู่ระบบ	ข่าวถูกรวมกลุ่มด้วย Two-Band Gate และคำนวณคะแนนกระแส 6 มิติแบบ Zero-LLM
UC-09	กระจายสัญญาณข่าว WebSocket	ระบบตั้งเวลา	ข่าวผ่านการสรุปและบันทึกเสร็จสิ้น	เบราว์เซอร์ของผู้ใช้ทุกรายได้รับ Event `news:new` เพื่อแสดงแถบแจ้งเตือนข่าวใหม่
UC-10	ตรวจสอบและบริหารจัดการระบบ	ผู้ดูแลระบบ	ผู้ดูแลยืนยันตัวตนสำเร็จ	ตรวจสอบสถิติ RAM แคช สั่งรันสเกรปทันที หรือสั่งล้างแคชระบบได้ตามต้องการ
UC-11	เจาะประเด็นข่าวและสืบค้นเชิงวิเคราะห์	ผู้อ่านทั่วไป & นักวิเคราะห์	มีการระบุคำค้นหาหรือไวยากรณ์บูลีน	สกัดข่าวที่เกี่ยวข้อง ขยายคำย่อ จัดกลุ่มมุมมองสำนักข่าว ไทม์ไลน์ และกรองข่าวหลุดประเด็นผ่านฐานข้อมูลแบบอ่านอย่างเดียว

3.2 เครื่องมือที่ใช้ในการดำเนินงาน

3.2.1 ฮาร์ดแวร์

เครื่องมือด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาโครงงานในปัจจุบันแสดงดังตารางที่ 6

ตารางที่ 6 รายการฮาร์ดแวร์ที่ใช้ในการพัฒนา

ลำดับ	รายการ	รายละเอียดคุณลักษณะ
1	คอมพิวเตอร์ประมวลผลหลัก	Intel Core Ultra 5, RAM 16 GB, SSD 512 GB
2	จอแสดงผล	หน้าจอแล็ปท็อปขนาด 16 นิ้ว
3	เครือข่ายอินเทอร์เน็ต	ความเร็วไม่น้อยกว่า 100/100 Mbps สำหรับเชื่อมต่อ KKU Gen.AI API และดึงข้อมูลข่าว

3.2.2 ซอฟต์แวร์

เครื่องมือด้านซอฟต์แวร์ที่ใช้ในการพัฒนาโครงงานแสดงดังตารางที่ 7

ตารางที่ 7 รายการซอฟต์แวร์และชุดเทคโนโลยีที่ใช้ในการพัฒนา (Exact Tech Stack Versions)

ลำดับ	ซอฟต์แวร์ / ไลบรารี	เวอร์ชันจริง	บทบาทและหน้าที่ในระบบ
1	Python	3.11.15	ภาษาโปรแกรมหลักฝั่งเซิร์ฟเวอร์
2	uv	0.6.14	ตัวจัดการแพ็กเกจและสภาพแวดล้อมเสมือนความเร็วสูง
3	FastAPI	0.141.1	เว็บเฟรมเวิร์คแบบอะซิงโครนัสสำหรับพัฒนา REST API
4	Uvicorn	0.52.1	เว็บเซิร์ฟเวอร์ ASGI ประสิทธิภาพสูง
5	Pydantic	2.13.4	ตรวจสอบและแปลงโครงสร้างข้อมูลที่ระดับ Runtime
6	Playwright	1.62.0	จำลองเบราว์เซอร์ Chromium เพื่อดึงหน้าเว็บ JavaScript/SPA
7	Trafilatura	2.2.0	สกัดเนื้อหาหลักของบทความข่าวและแปลงเป็น Markdown
8	BeautifulSoup4	4.15.0	แยกวิเคราะห์โครงสร้างเอกสาร HTML และ CSS Selector
9	PyThaiNLP	5.3.5	ตัดคำภาษาไทยด้วยเอนจิน newmm และคัดกรอง Stop words
10	Scikit-learn	1.6.1	โมเดล Calibrated LinearSVC และ TF-IDF Vectorizer
11	Joblib	1.5.3	จัดเก็บและโหลดโมเดล Machine Learning (Serialization)
12	NumPy	2.4.6	ประมวลผลทางคณิตศาสตร์และอาร์เรย์เชิงตัวเลข
13	PyTorch	2.13.0	เฟรมเวิร์คการเรียนรู้เชิงลึกสำหรับรันโมเดลภาษา
14	Transformers	5.15.1	รันและประเมินผลโมเดล WangchanBERTa
15	OpenAI SDK	2.53.0	เชื่อมต่อบริการโมเดลภาษาขนาดใหญ่ KKU Gen.AI
16	HTTPX	0.28.1	ตัวส่งคำขอ HTTP แบบอะซิงโครนัส
17	Python-SocketIO	5.16.3	จัดการการเชื่อมต่อ WebSocket สองทิศทางฝั่งเซิร์ฟเวอร์
18	Socket.IO Client (JS)	4.7.5	รับส่งข้อมูลเหตุการณ์แบบเรียลไทม์ฝั่งเว็บเบราว์เซอร์
19	Tailwind CSS	3.4.1	จัดการสไตล์และส่วนติดต่อผู้ใช้แบบ Responsive
20	Ruff	0.16.1	เครื่องมือตรวจสอบคุณภาพโค้ดและจัดรูปแบบ (Linter & Formatter)
21	Mypy	2.3.0	ตรวจสอบความถูกต้องของ Type Annotation ภาษา Python
22	Pytest	9.1.1	ชุดทดสอบอัตโนมัติ (Unit Tests, Stress Tests, PDPA

3.3 แผนการดำเนินงาน

แผนการดำเนินงานตลอดระยะเวลาการทำโครงงานตั้งแต่เดือนมิถุนายนถึงตุลาคม แบ่งออกเป็น 2 ช่วงหลัก ได้แก่ ช่วงการศึกษาและพัฒนาวิศวกรรมระบบจริงซึ่งดำเนินการแล้วเสร็จ (มิถุนายน – สิงหาคม) และช่วงแผนงานการประเมินผล จัดทำแบบสำรวจความพึงพอใจ และสรุปผลโครงงานซึ่งเป็นแผนงานในอนาคตที่ยังไม่ได้ดำเนินการ (กันยายน – ตุลาคม) แสดงดังตารางที่ 8

ตารางที่ 8 แผนการดำเนินงานและไทม์ไลน์ของโครงงาน (Gantt Chart)

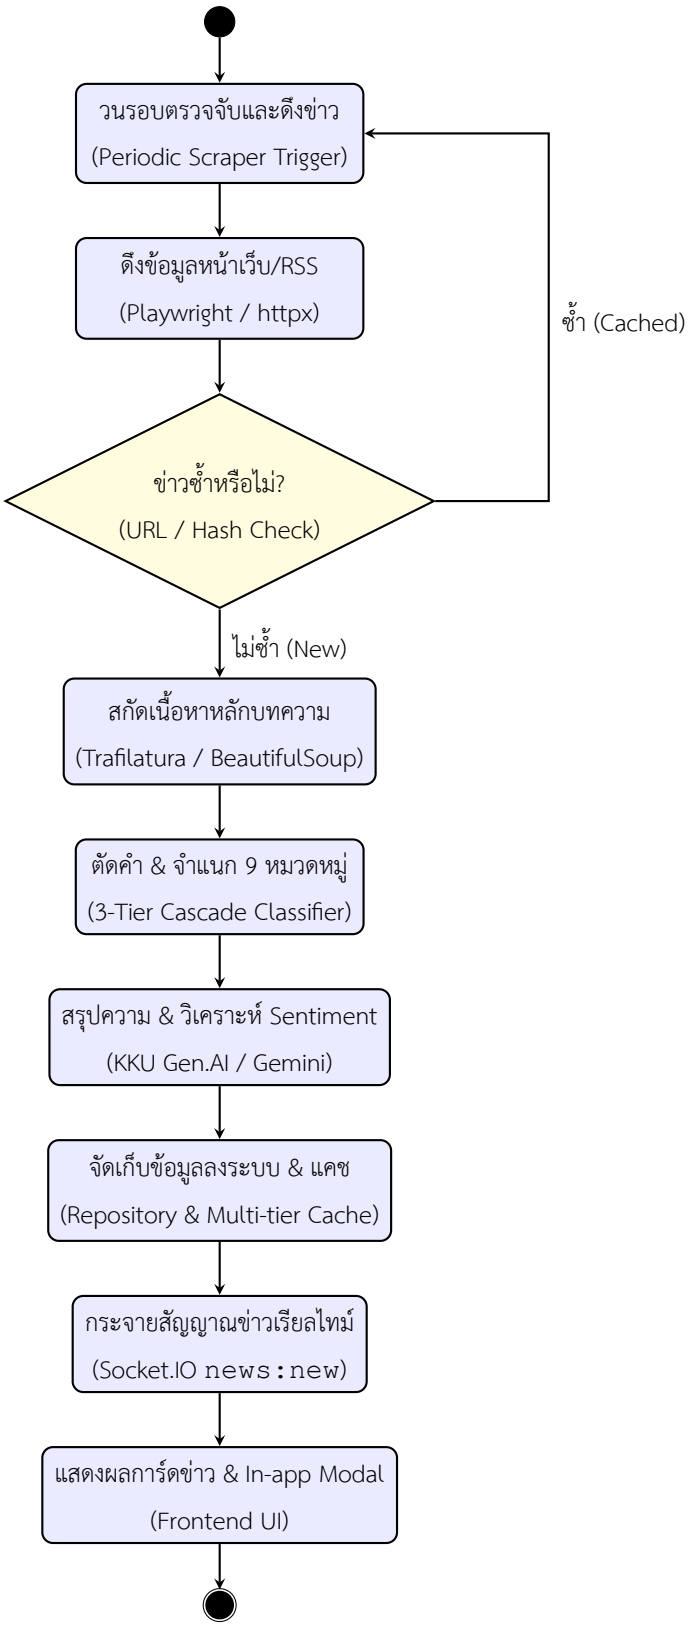
ลำดับ	กิจกรรม / ขั้นตอนการดำเนินงาน	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
ส่วนที่ 1: การศึกษา ออกแบบ และพัฒนาวิศวกรรมระบบ (ดำเนินการแล้วเสร็จ ●)						
1	ศึกษาปัญหา รวบรวมความต้องการ และออกแบบสถาปัตยกรรมระบบ	●				
2	พัฒนาระบบ Scraper Pipeline, Playwright Service และ Multi-tier Cache	●	●			
3	ฝึกสอน/ปรับจูนโมเดลจำแนกข่าว 9 หมวดหมู่ และเชื่อมต่อ KKU Gen.AI API		●	●		
4	พัฒนาเว็บแอปพลิเคชัน Single Page Application (SPA), PWA และ WebSocket		●	●		
5	พัฒนาระบบจัดอันดับ Trending/Hot News, ความปลอดภัย และ PDPA			●		
6	ทดสอบระบบเชิงเทคนิคอัตโนมัติ (Automated Unit Tests, Stress Tests)			●		
ส่วนที่ 2: การประเมินผล แบบสำรวจ และจัดทำเอกสารปิดโครงงาน (แผนงานในอนาคต: ยังไม่ได้ดำเนินการ ○)						
7	ทดสอบประเมินความแม่นยำของอัลกอริทึมรวมกลุ่มข่าวและฉันทามติหมวดหมู่ข้ามสำนัก				○	
8	ออกแบบและจัดทำแบบสำรวจความพึงพอใจการใช้งาน (User Survey / Questionnaire)				○	
9	ดำเนินการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing: UAT) และเก็บข้อมูล				○	○
10	วิเคราะห์ข้อมูลสถิติผลการประเมิน สรุปข้อเสนอแนะ และปรับแต่งระบบขั้นสุดท้าย					○
11	จัดทำเอกสารรายงานโครงงานฉบับสมบูรณ์และเตรียมการนำเสนอโครงงาน					○
หมายเหตุ: สัญลักษณ์ ● หมายถึง งานที่ดำเนินการแล้วเสร็จ, สัญลักษณ์ ○ หมายถึง แผนงานที่วางไว้ในอนาคต (ยังไม่ได้ดำเนินการ)						

บทที่ 4
การวิเคราะห์ระบบ และพัฒนาโปรแกรม

4.1 การวิเคราะห์ระบบ

4.1.1 ผังแสดงทิศทางของกิจกรรม (Activity Flow)

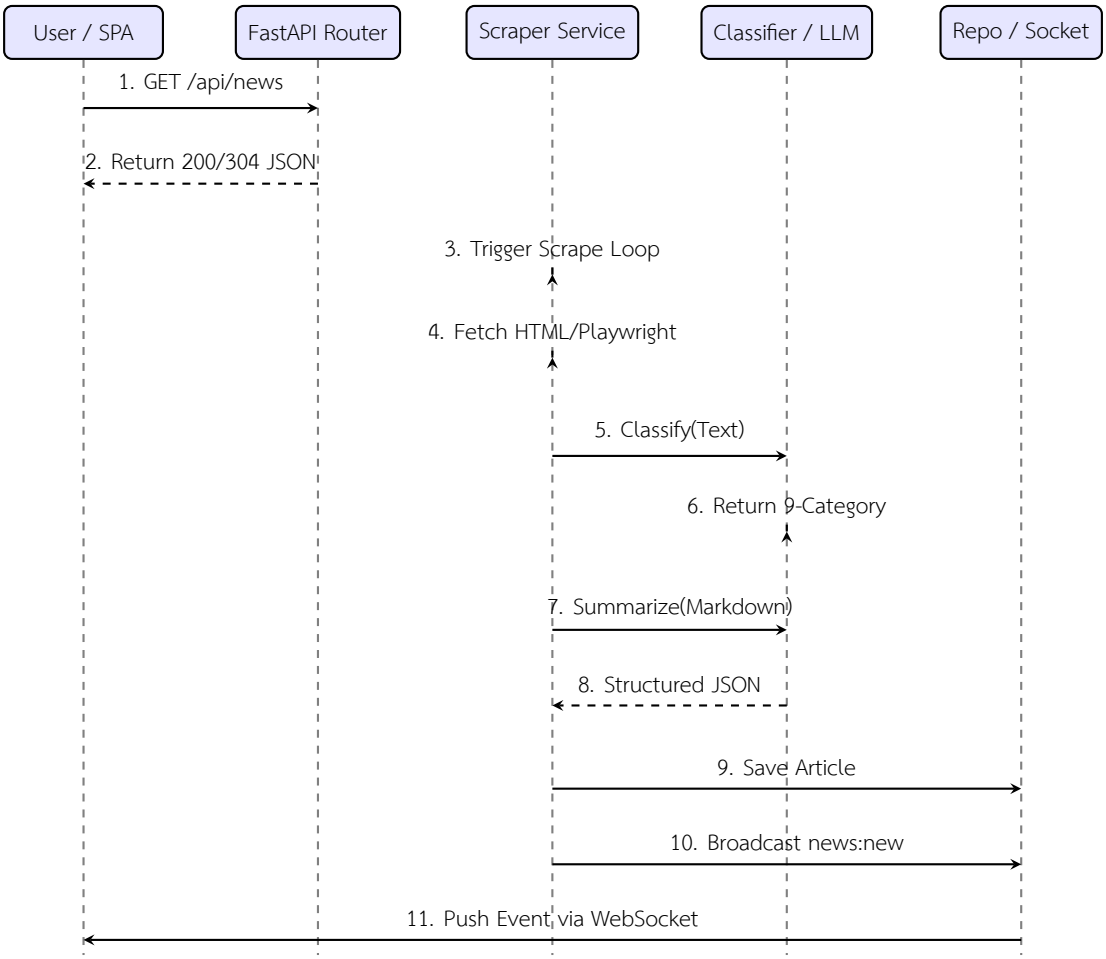
ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติทำงานในลักษณะกระบวนการต่อเนื่อง (Data Pipeline) โดยเริ่มตั้งแต่การดึงข้อมูลจากแหล่งข่าว การประมวลผลและการสกัดข้อมูล การสรุปเนื้อหาและจำแนกหมวดหมู่ ไปจนถึงการบันทึกลงหน่วยจัดเก็บและการกระจายข้อมูลแบบเรียลไทม์ไปยังส่วนติดต่อผู้ใช้ ดังแสดงในผังกิจกรรม (Activity Diagram) ภาพที่ 3



ภาพที่ 3 แผนภาพแสดงทิศทางกิจกรรมของระบบ (Activity Diagram)

4.1.2 แผนภาพลำดับขั้นตอนการทำงาน (Sequence Diagram)

การปฏิสัมพันธ์ระหว่างส่วนประกอบต่าง ๆ ของระบบ ตั้งแต่ฝั่งผู้ใช้งาน เว็บเซิร์ฟเวอร์ บริการสเกรปเปอร์ ปัญญาประดิษฐ์ และระบบกระจายข่าว แสดงดังภาพที่ 4



ภาพที่ 4 แผนภาพลำดับขั้นตอนการทำงานของระบบ (Sequence Diagram)

4.1.3 รายการความต้องการของระบบ

(1) ความต้องการเชิงฟังก์ชัน (Functional Requirements)

ความต้องการเชิงฟังก์ชันของระบบสรุปได้ดังตารางที่ 9

ตารางที่ 9 ความต้องการเชิงฟังก์ชันของระบบ (Functional Requirements)

รหัส	ชื่อ Requirement	รายละเอียดความสามารถของระบบ
FR-01	Automated Multi-source Scraping	ระบบสามารถดึงข้อมูลข่าวจากแหล่งข่าวออนไลน์หลากหลายแหล่ง ทั้งแบบ RSS Feed, เว็บไซต์ HTML ปกติ และเว็บไซต์ที่เรนเดอร์ด้วย JavaScript ผ่าน Playwright
FR-02	Dynamic Source Registration	ระบบรองรับการเพิ่ม/ปรับปรุงแหล่งข่าวใหม่ได้อย่างยืดหยุ่นผ่าน Decorator (`@register_source`) โดยไม่ต้องแก้ไขโค้ดส่วนประมวลผลหลัก
FR-03	9-Category Thai NLP Classification	ระบบสามารถจำแนกหมวดหมู่ข่าวภาษาไทยออกเป็น 9 หมวดหมู่หลักได้อย่างถูกต้องด้วยเทคนิค 3-Tier Cascade Classifier
FR-04	LLM-Powered Summarization	ระบบสามารถสร้างบทสรุปย่อ ประเด็นสำคัญ และวิเคราะห์อารมณ์ของข่าว (Sentiment) โดยใช้โมเดลภาษาขนาดใหญ่ผ่าน KKU Gen.AI API
FR-05	Real-time WebSocket Push	ระบบสามารถกระจายข่าวสารใหม่และการอัปเดตสถานะการดึงข่าวไปยังผู้ใช้ทันทีผ่าน Socket.IO โดยผู้ใช้ไม่ต้องรีเฟรชหน้าจอ
FR-06	Multi-tier Caching	ระบบมีกลไกจัดเก็บแคชในหน่วยความจำ (`AsyncInMemoryCache`) และแคชแบบมีเงื่อนไข (HTTP 304) เพื่อลดการดึงข้อมูลซ้ำซ้อนและลดภาระเซิร์ฟเวอร์
FR-07	Engagement Tracking & Personalization	ระบบบันทึกพฤติกรรมการใช้งาน (การคลิกอ่าน, การขยายบทสรุป, การบันทึกคั่นหน้า) ผ่านคุกกี้เพื่อนำไปประมวลผลจัดอันดับข่าวที่น่าสนใจ (Trending/Recommended)
FR-08	In-app Reading Experience	ระบบมีหน้าต่างแสดงผลบทความข่าวและสรุปเนื้อหาในตัวเว็บ (In-app Modal Reader) เพื่อความสะดวกในการอ่าน

(2) ความต้องการที่ไม่ใช่เชิงฟังก์ชัน (Non-Functional Requirements)

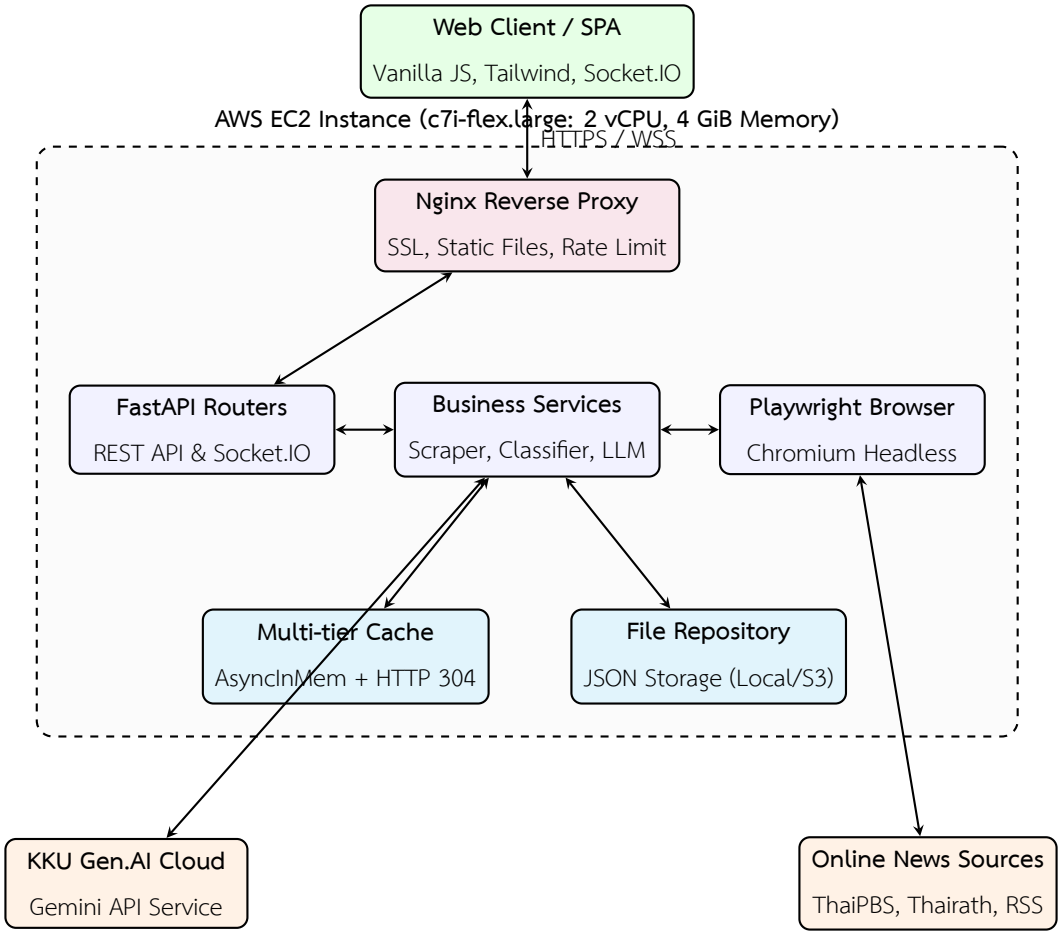
ในด้านความต้องการที่ไม่ใช่เชิงฟังก์ชัน ระบบได้รับการออกแบบให้ตอบสนองข้อกำหนดสำคัญ 4 ประการ ได้แก่ ประการแรก ด้านประสิทธิภาพ (Performance) กำหนดให้เวลาการตอบสนองคำขอเรียกดูรายการข่าวผ่าน REST API (`GET /api/news`) เฉลี่ยต่ำกว่า 150 มิลลิวินาทีเมื่อมีข้อมูลจัดเก็บในหน่วยความจำแคช และมีอัตราความหน่วงเวลา (Latency) ในการกระจายข่าวสารใหม่ผ่าน WebSocket ต่ำกว่า 500 มิลลิวินาทีนับจากช่วงเวลาที่ข่าวถูกบันทึกลงระบบสำเร็จ ประการที่สอง ด้านความคงทนและการรองรับข้อผิดพลาด (Reliability & Fault Tolerance) ความล้มเหลวในการดึงข้อมูลจากแหล่งข่าวใดแหล่งข่าวหนึ่งต้องไม่ส่งผลกระทบต่อรอบการทำงานของแหล่งข่าวอื่น (Isolation of Failures) พร้อมทั้งมีกลไกสำรอง (Fallback Mechanism) รองรับการแสดง

ผลข้อความสรุปพื้นฐานในกรณีที่บริการ LLM ภายนอกขัดข้อง ประการที่สาม ด้านสถาปัตยกรรมและการขยายตัว (Maintainability & Extensibility) ออกแบบโครงสร้างซอฟต์แวร์ตามหลักการ SOLID และ GRASP โดยแยกชั้นความรับผิดชอบอย่างชัดเจน ตลอดจนการประยุกต์ใช้ Protocol Interface ตามรูปแบบ Port and Adapter Pattern ในการเข้าถึงคลังข้อมูล และประการสุดท้าย ด้านความเป็นส่วนตัวและการรักษาความปลอดภัย (Privacy & Usability) ระบบยึดหลักการไม่เก็บข้อมูลระบุตัวตนส่วนบุคคล (Non-PII) และมีแถบขอความยินยอมการใช้งานคุกกี้ตามมาตรฐานการคุ้มครองข้อมูลส่วนบุคคล

4.2 การออกแบบระบบ

4.2.1 สถาปัตยกรรมของระบบและการแบ่งแยกโมดูล (System Architecture)

ระบบได้รับการออกแบบโครงสร้างสถาปัตยกรรมระดับระบบ (System Architecture Design) สำหรับการติดตั้งบน AWS EC2 `c7i-flex.large` (2 vCPU, 4 GiB Memory) พร้อมการแยกโมดูลและคอนเทนเนอร์อย่างชัดเจน ดังแสดงในภาพที่ 5



ภาพที่ 5 แผนภาพสถาปัตยกรรมระบบและการแบ่งแยกโมดูล (System Architecture Diagram)

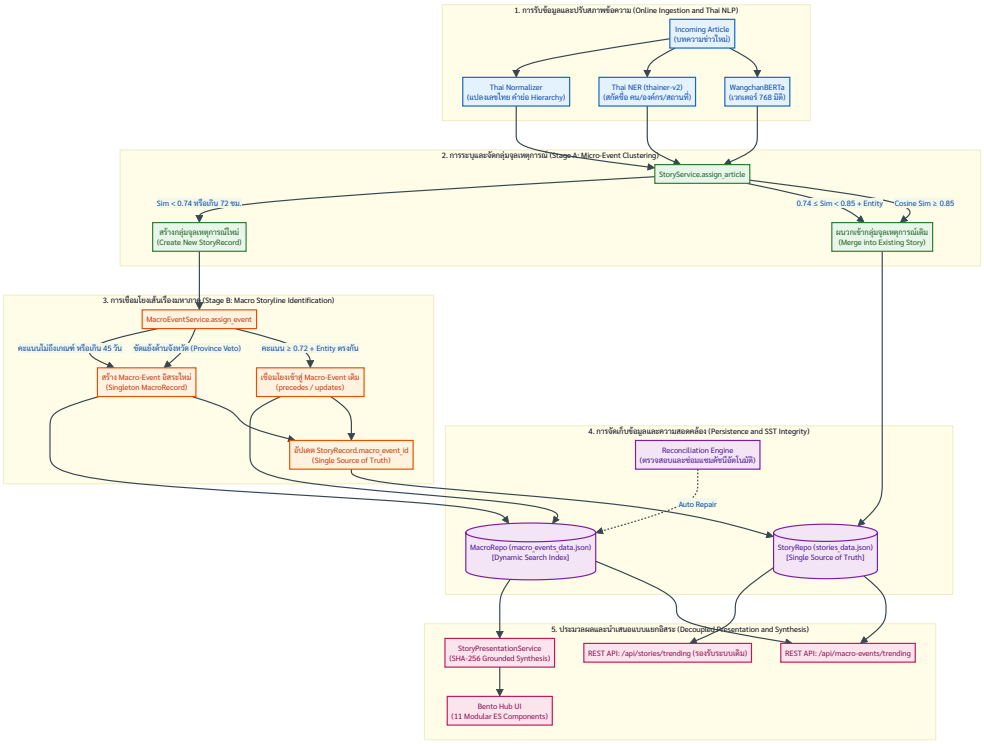
ตารางที่ 10 แสดงความรับผิดชอบของแต่ละเลเยอร์ในระบบ

ตารางที่ 10 การแบ่งชั้นสถาปัตยกรรมของระบบ (Backend Architecture Layers)

เลเยอร์	โฟลเดอร์/โมดูล	หน้าที่และความรับผิดชอบ
Presentation	`frontend/static/`	จัดการหน้าเว็บ Single Page Application (SPA), Bento Hub, หน้าระบบมอนิเตอร์ (`monitoring.html`) และ WebSocket
Routing	`backend/routers/`	รับคำขอ HTTP REST API (`news`, `story`, `macro_event`, `trending`, `monitoring`) และส่งต่อข้อมูล
Service (Business Logic)	`backend/services/`	ควบคุมตรรกะระบบ ได้แก่ `ScraperService`, `StoryService` (ระบุประเด็นข่าว), `TrendingService` (จัดอันดับกระแส), `StoryPresentationService` (สังเคราะห์เนื้อหา), `MacroEventService` (รวมมหากาพย์ประเด็น)
Scraper	`backend/scrapers/`	สเกรปเปอร์เฉพาะแต่ละสำนักข่าว ลงทะเบียนด้วย Decorator พร้อมฟังก์ชันแยกวิเคราะห์ HTML
Core / Infrastructure	`backend/core/`	เครื่องมือส่วนกลาง เช่น `BrowserService` (Playwright), `SocketManager`, `L1Cache` และ `AsyncInMemoryCache`
Persistence	`backend/repo/`	บันทึกและดึงข้อมูลข่าว ประเด็นข่าว และสถิติ (`FileNewsRepo`, `SqliteNewsRepo`, `MongoStoryRepo`, `MacroEventRepo`)
Schema	`backend/schemas/`	กำหนดโครงสร้างข้อมูล (Pydantic Models: `NewsArticle`, `StoryRecord`, `TrendingScoreBreakdown`)

(1) สถาปัตยกรรมการประมวลผลและการจัดกลุ่มเหตุการณ์แบบ 2 ระดับ (Two-Stage Event-Centric Processing Pipeline)

เพื่อแก้ไขข้อจำกัดดั้งเดิมของระบบจัดกลุ่มข่าวทั่วไปที่มักยุบรวมข่าวในหมวดเดียวกัน (Topic) กลายเป็นเหตุการณ์เดียวกัน ระบบจึงได้รับการพัฒนาสถาปัตยกรรมประมวลผลเหตุการณ์แบบ 2 ระดับ (Two-Stage Event-Centric Processing Pipeline) ดังแสดงในภาพที่ 6 ซึ่งครอบคลุมสายการทำงานตั้งแต่การรับเข้าข้อมูลไปจนถึงการนำเสนอบนหน้าเว็บส่วนติดต่อผู้ใช้



ภาพที่ 6 แผนภาพสถาปัตยกรรมการประมวลผลและการจัดกลุ่มเหตุการณ์แบบ 2 ระดับ (Two-Stage Event-Centric Processing Pipeline Architecture)

สถาปัตยกรรมดังกล่าวประกอบด้วย 5 ขั้นตอนหลัก ดังนี้:

1) **การรับข้อมูลและปรับสภาพข้อความภาษาไทย (Online Ingestion & Thai NLP)**
: เมื่อมีบทความข่าวใหม่เข้าสู่ระบบ โมดูล `thai_normalizer.py` จะทำความสะอาดข้อความ ปรับเลขไทยเป็นเลขอารบิก ลบอักขระความกว้างศูนย์ แปลงคำย่อทางการ และจัดระดับสถานที่ตามลำดับชั้น (Location Hierarchy: จังหวัด $\rightarrow$ อำเภอ $\rightarrow$ ตำบล) จากนั้นจึงส่งต่อให้ `WangchanBERTa` สกัดเวกเตอร์ความหมาย 768 มิติ และ `thainer-v2` สกัดเอนทิตีชื่อเฉพาะ (บุคคล องค์กร สถานที่)
2) **การระบุและจัดกลุ่มจุลเหตุการณ์ (Stage A: Micro-Event Clustering)**
: `StoryService` ทำหน้าที่ตรวจวัดความคล้ายคลึงของเวกเตอร์ (Cosine Similarity) และเอนทิตีกับกลุ่มเหตุการณ์ที่มีอยู่ในหน้าต่างเวลา 72 ชั่วโมง หากมีค่าความคล้ายคลึง ≥ 0.85 หรืออยู่ในช่วง $[0.74, 0.85)$ ร่วมกับมีเอนทิตีซ้อนทับกัน จะถูกผนวกเข้าสู่กลุ่มจุลเหตุการณ์เดิม (`StoryRecord`) แต่หากความคล้ายคลึงต่ำกว่า 0.74 ระบบจะสร้างกลุ่มจุลเหตุการณ์ใหม่ขึ้นทันที
3) **การเชื่อมโยงเส้นเรื่องมหาภาค (Stage B: Macro Storyline Identification)**
: เมื่อเกิดจุลเหตุการณ์ใหม่ `MacroEventService` จะประเมินเพื่อเชื่อมโยงเข้า

สู่เส้นเรื่องมหาภาค (`MacroEventRecord`) ผ่านคะแนนความสอดคล้องรวม 4 ปัจจัย หากมีคะแนน ≥ 0.72 และมีเอนทิตีเฉพาะตรงกัน จะเชื่อมโยงเข้าสู่มหากาพย์เดิม พร้อมกำหนดความสัมพันธ์เชิงเวลา (`precedes` หรือ `updates`) ภายใต้หน้าต่าง Episode 45 วัน โดยมีกลไกยับยั้งความขัดแย้งระดับจังหวัด (Strict Province-Only Veto) ป้องกันการนำเหตุการณ์ต่างพื้นที่มาผูกรวมกัน

4) **การจัดเก็บข้อมูลและความสอดคล้องเชิงความสัมพันธ์ (Persistence & SST Integrity)**

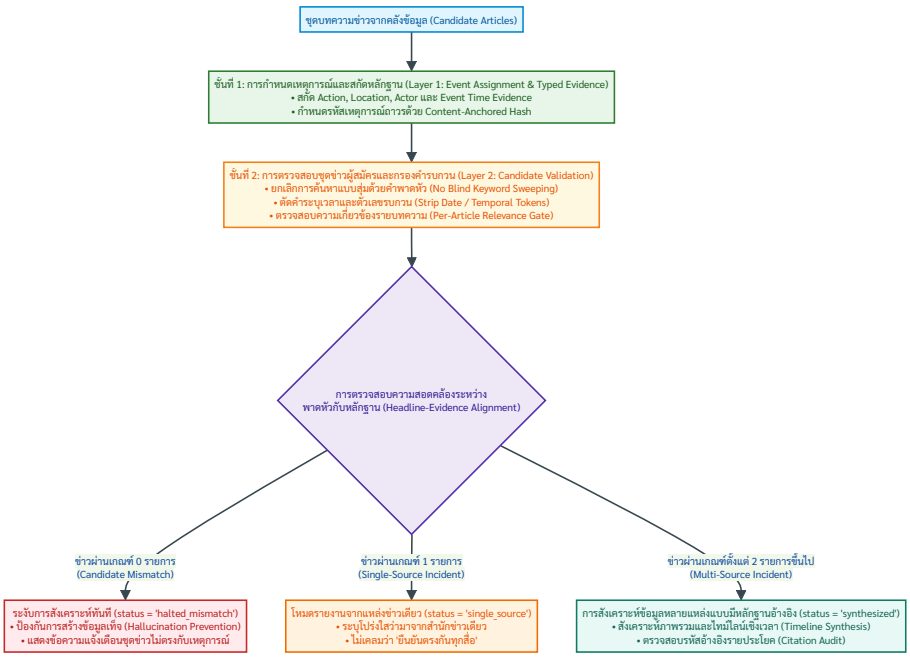
: ระบบใช้สถาปัตยกรรม Single Source of Truth (SST) โดยกำหนดให้ `StoryRepo` (`stories_data.json`) เป็น แหล่ง ข้อมูล ความ จริง สูงสุด ใน การ เก็บ ฟิลด์ `macro_event_id` ในขณะที่ `MacroRepo` ทำหน้าที่เป็น Dynamic Index พร้อมทั้งมีกระบวนการกู้คืนอัตโนมัติ (`Reconciliation Engine`) ที่สามารถสร้างดัชนีมหากาพย์ขึ้นใหม่ได้ทันทีหากพบความไม่สอดคล้องของข้อมูล

5) **การประมวลผลและนำเสนอแบบแยกอิสระ (Decoupled Presentation & Synthesis)**

: ให้บริการผ่าน REST API (`/api/macro-events/trending` และ `/api/stories/trending`)โดยมี `StoryPresentationService` ทำหน้าที่สังเคราะห์เนื้อหาพร้อมระบบแคช SHA-256 และส่งมอบข้อมูลไปยังหน้าเว็บส่วนติดต่อผู้ใช้แบบ Bento Hub ที่พัฒนาด้วยโครงสร้าง 11 โมดูล ES อิสระ

(2) สถาปัตยกรรมระบบกลไกป้องกันและควบคุมความถูกต้อง 3 ระดับ (3-Layer Event Verification and Grounded Synthesis Guardrails)

เพื่อให้ระบบสามารถสังเคราะห์เนื้อหาข่าวหลายสำนักได้อย่างถูกต้อง ปราศจากอาการสร้างข้อมูลเท็จ (Hallucination) และไม่กวาดข่าวผิดชุดเข้ามานำเสนอ ระบบจึงได้วางสถาปัตยกรรมกลไกป้องกันและควบคุมความถูกต้อง 3 ระดับ (3-Layer Guardrails Architecture) ดังแสดงในภาพที่ 7



ภาพที่ 7 แผนภาพสถาปัตยกรรมระบบกลไกป้องกันและควบคุมความถูกต้อง 3 ระดับ (3-Layer Event Verification and Grounded Synthesis Guardrails)

กลไกการควบคุมทั้ง 3 ระดับทำงานร่วมกันอย่างเป็นระบบ ดังนี้:

1) **ชั้นที่ 1: การกำหนดเหตุการณ์และสกัดหลักฐาน (Layer 1: Event Assignment & Typed Evidence)**

   : สกัดหลักฐานสำคัญอย่างเป็นระบบ ได้แก่ กริยาการกระทำ (Action), สถานที่ (Location), ผู้เกี่ยวข้อง (Actor) และเวลาเกิดเหตุจริง (`extract_event_time_evidence`) พร้อมสร้างรหัสเหตุการณ์ถาวรด้วย Content-Anchored Hash ช่วยตัดปัญหาหมายเลขกลุ่มชนกันเมื่อประมวลผลซ้ำ

2) **ชั้นที่ 2: การตรวจสอบชุดข่าวผู้สมัครและกรองคำรบกวน (Layer 2: Candidate Validation & Noise Reduction)**

   : ยกเลิกการกวาดข่าวด้วยคำพาดหัวแบบสุ่ม (No Blind Keyword Sweeping) ตัดคำระบุเวลา เดือน และปี ที่มักปะปนในพาดหัว (เช่น คำว่า “ต.ค.”, “2569”) และประเมินความเกี่ยวข้องระดับบทความผ่าน 3-Stage Relevance Enforcement Gate (Heuristic Filter → LLM Classification → Safety Guardrail)

3) **ชั้นที่ 3: การตรวจสอบความสอดคล้องและโหมดการสังเคราะห์ที่มีหลักฐานอ้างอิง (Layer 3: Headline-Evidence Alignment & Grounded Synthesis Modes)**

   : ตรวจสอบความสอดคล้องระหว่างพาดหัวของมหากาพย์กับเนื้อหาข่าวผู้สมัครที่ผ่านเกณฑ์ โดยแบ่งการทำงานออกเป็น 3 โหมดอย่างชัดเจน:

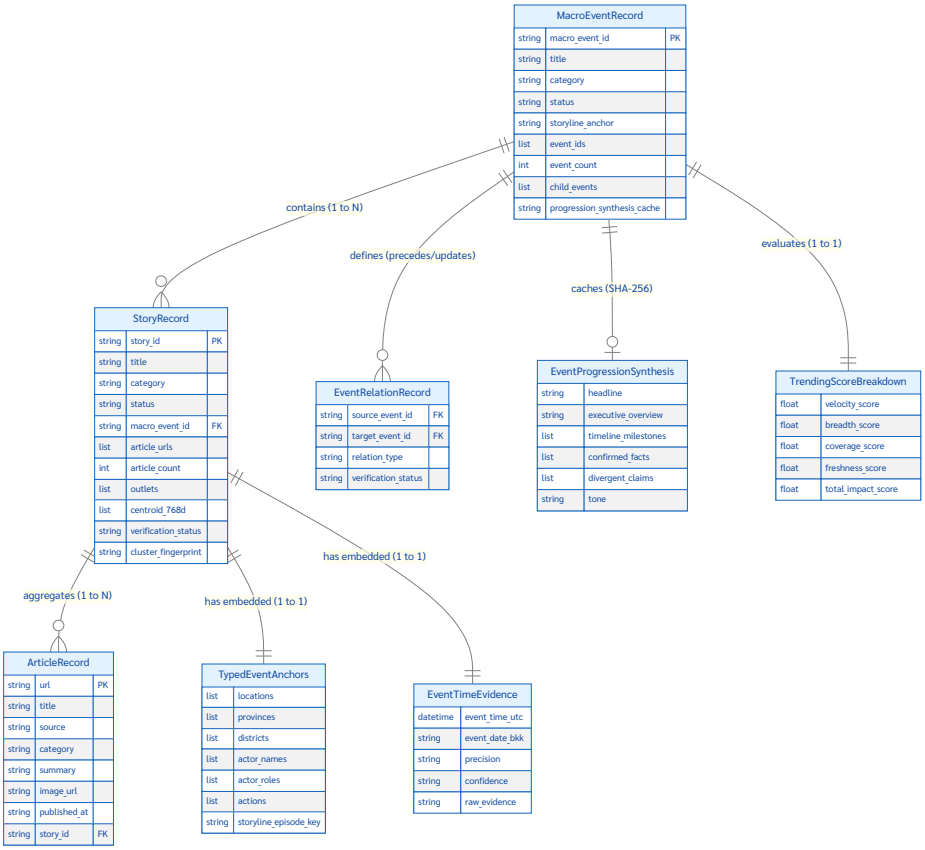
a) **โหมดระงับการสังเคราะห์ (`status = 'halted_mismatch'`)**: หากไม่มีข่าวใดผ่านเกณฑ์ความสอดคล้องเลย ระบบจะหยุดการสังเคราะห์ด้วย LLM ทันที พร้อมแสดงข้อความแจ้งเตือนว่าชุดข่าวไม่ตรงกับเหตุการณ์ เพื่อป้องกันการกุเนื้อหาเท็จ

b) **โหมดรายงานจากแหล่งข่าวเดียว (`status = 'single_source'`)**: หากมีข่าวผ่านเกณฑ์เพียง 1 สำนัก ระบบจะนำเสนอข้อมูลอย่างโปร่งใสว่าเป็นรายงานจากสำนักข่าวดังกล่าว โดยไม่แสดงข้อความอ้างว่า “ยืนยันตรงกันทุกสื่อ”

c) **โหมดสังเคราะห์หลายแหล่งข่าว (`status = 'synthesized'`)**: หากมีข่าวตั้งแต่ 2 สำนักขึ้นไปยืนยันตรงกัน ระบบจะสังเคราะห์ภาพรวม (Executive Overview) และลำดับเวลา (Chronological Timeline) พร้อมตรวจสอบรหัสอ้างอิงรายประโยค (Citation Audit) เพื่อความถูกต้องสูงสุด

4.2.2 การออกแบบฐานข้อมูลและการจัดเก็บข้อมูล

โครงสร้างข้อมูลของระบบได้รับการออกแบบตามหลักการความรับผิดชอบเดี่ยว (Single Responsibility Principle) และสถาปัตยกรรมแบบ Single Source of Truth (SST) โดยกำหนดความสัมพันธ์ระหว่างเอนทิตีในระดับต่าง ๆ ผ่านโมเดล Pydantic v2 เพื่อรองรับทั้งการจัดเก็บลงไฟล์ JSON และ MongoDB ได้อย่างยืดหยุ่น ดังแสดงในภาพที่ 8



ภาพที่ 8 แผนภาพแสดงความสัมพันธ์ของโครงสร้างข้อมูลทั้งระบบ (System Schema Entity-Relationship Diagram)

จากภาพที่ 8 โครงสร้างข้อมูลแบ่งออกเป็นระดับสำคัญดังนี้:

1) **ระดับบทความข่าว (`ArticleRecord`)**: จัดเก็บข้อมูลข่าวเดี่ยวที่สกัดได้จากสำนักข่าวต้นทาง โดยมีฟิลด์ `url` ทำหน้าที่เป็น Primary Key และเชื่อมโยงไปยังกลุ่มจุลเหตุการณ์ผ่าน `story_id`
2) **ระดับจุลเหตุการณ์ (`StoryRecord`)**: ทำหน้าที่เป็น Single Source of Truth (SST) ของเหตุการณ์ย่อย รวมบทความข่าวที่รายงานเหตุการณ์เดียวกัน ($1 : N$) มีการฝัง `TypedEventAnchors` และ `EventTimeEvidence` เพื่อใช้ในการตรวจสอบหลักฐานและความสอดคล้องเชิงพื้นที่/เวลา พร้อมทั้งบันทึก `macro_event_id` เพื่อชี้ไปยังเส้นเรื่องมหาภาค
3) **ระดับเส้นเรื่องมหาภาค (`MacroEventRecord`)**: ทำหน้าที่เป็น Dynamic Search Index สำหรับจัดกลุ่มจุลเหตุการณ์ที่ต่อเนื่องกันข้ามสัปดาห์หรือข้ามเดือน ($1 : N$) พร้อมบันทึก

ความสัมพันธ์เชิงเวลาและสาเหตุ (`EventRelationRecord`) เช่น `precedes` และ `updates`

4) **ระดับการสังเคราะห์และประเมินกระแส**

: ประกอบด้วย `EventProgressionSynthesis` สำหรับแคชผลการสังเคราะห์ไทม์ไลน์และข้อเท็จจริงยืนยัน และ `TrendingScoreBreakdown` สำหรับแจกแจงคะแนนกระแสข่าว 4 มิติ

ระบบได้รับการออกแบบโครงสร้างข้อมูลแยกเป็น 3 ส่วนหลัก ได้แก่ โครงสร้างบทความข่าวเดี่ยว (`NewsArticle` Schema ดังตารางที่ 11) โครงสร้างประเด็นข่าวสารหลายสำนัก (`StoryRecord` Schema ดังตารางที่ 12) และโครงสร้างคะแนนแจกแจงกระแสข่าว (`TrendingScoreBreakdown` Schema)

ตารางที่ 11 โครงสร้างข้อมูลบทความข่าว (`NewsArticle` Schema)

ฟิลด์ (Field)	**ชนิดข้อมูล**	**จำเป็น**	**คำอธิบาย**
`id`	String	ใช่	รหัสระบุข่าวแบบไม่ซ้ำ (Hash จาก URL)
`title`	String	ใช่	หัวข้อข่าว
`url`	String	ใช่	ลิงก์ต้นฉบับบทความข่าว
`source`	String	ใช่	ชื่อสำนักข่าวต้นทาง (เช่น ThaiPBS, Thairath, BBC)
`category`	String	ใช่	หมวดหมู่ข่าว (politics, economy, tech, etc.)
`summary`	String	ไม่ใช่	ข้อความสรุปย่อเนื้อหาข่าวจาก LLM
`key_points`	List[String]	ไม่ใช่	รายการประเด็นสำคัญของข่าว (Bullet points)
`sentiment`	String	ไม่ใช่	ค่าอารมณ์ของข่าว (positive, neutral, negative)
`image_url`	String	ไม่ใช่	ลิงก์รูปภาพหน้าปกบทความ
`published_at`	String	ใช่	วันและเวลาที่เผยแพร่ตามมาตรฐาน ISO 8601
`created_at`	String	ใช่	วันและเวลาที่ระบบนำเข้าข่าว
`story_id`	String	ไม่ใช่	รหัสกลุ่มประเด็นข่าวที่รายงานเหตุการณ์เดียวกันข้ามสำนัก
`consensus_category`	String	ไม่ใช่	หมวดหมู่ระดับกลุ่มข่าวที่ผ่านฉันทามติมติเสียงข้างมาก

ตารางที่ 12 โครงสร้างข้อมูลกลุ่มประเด็นข่าวสาร (`StoryRecord` Schema)

ฟิลด์ (Field)	ชนิดข้อมูล	จำเป็น	คำอธิบาย
`story_id`	String	ใช่	รหัสระบุประเด็นข่าวแบบคงทน (เช่น `story_0b86804a`)
`title`	String	ใช่	หัวข้อข่าวตัวแทนตั้งต้นของประเด็นข่าว
`category`	String	ใช่	หมวดหมู่หลักของประเด็นข่าว
`status`	String	ใช่	สถานะวงจรชีวิตประเด็นข่าว (`active` หรือ `dormant`)
`article_urls`	List[String]	ใช่	รายการ URL ของบทความข่าวทั้งหมดในกลุ่มประเด็น
`article_count`	Integer	ใช่	จำนวนบทความข่าวทั้งหมดที่เชื่อมโยงกับประเด็นนี้
`outlets`	List[String]	ใช่	รายชื่อสำนักข่าวอิสระที่รายงานประเด็นนี้
`outlet_count`	Integer	ใช่	จำนวนสำนักข่าวที่ไม่ซ้ำ (K)
`centroid`	List[Float]	ใช่	เวกเตอร์ศูนย์กลาง 768 มิติ ปรับปรุงด้วย Exponential Moving Average
`entities`	List[String]	ใช่	รายการเอนทิตีชื่อเฉพาะบุคคล/สถานที่/องค์กรที่สะสม
`headline`	String	ไม่ใช่	พาดหัวข่าวสังเคราะห์ภาพรวมจาก LLM
`summary`	String	ไม่ใช่	เนื้อหาสรุปสังเคราะห์ข้ามสำนักข่าวจาก LLM
`timeline`	List[Object]	ใช่	รายการพัฒนาการของเหตุการณ์ตามลำดับเวลาพร้อมลิงก์อ้างอิง

4.3 การพัฒนาระบบและการทำงานของส่วนประกอบหลัก

4.3.1 กระบวนการดึงข่าวและการเชื่อมต่อ Playwright (Scraping Pipeline)

ระบบสเกรปข่าวถูกออกแบบให้ทำงานแบบ Asynchronous ทั้งหมด โดยในแต่ละรอบการทำงาน `ScraperService` จะสร้าง Task สำหรับแต่ละแหล่งข่าวเพื่อดึงข้อมูลพร้อมกัน (Concurrent Scraping) พร้อมทั้งรองรับการดึงหน้าเว็บที่มีการป้องกันด้วย Cloudflare หรือเรนเดอร์เนื้อหาผ่าน JavaScript ผ่าน `BrowserService` โดยการลงทะเบียนแหล่งข่าวใช้ Decorator `@register_source` ดังตัวอย่าง:

โปรแกรมที่ 1 ตัวอย่างการลงทะเบียนแหล่งข่าวด้วย Decorator

```python
@register_source("ThaiPBS", "https://www.thaipbs.or.th", "#FF5722")
async def scrape_thaipbs(browser_service: BrowserService) -> list[RawNewsItem]:
    html = await browser_service.fetch_page("https://www.thaipbs.or.th/news")
    return parse_news_cards(html, source="ThaiPBS")
```

4.3.2 ระบบจำแนกหมวดหมู่และการตัดคำภาษาไทย (Thai NLP Classifier)

การจำแนกหมวดหมู่ข่าวใช้แนวทางไฮบริด (Hybrid Classification Pipeline) โดยเริ่มต้นจากการสกัดคำสำคัญจากหัวข้อข่าวด้วย PyThaiNLP (`engine="newmm"`) เพื่อเทียบกับชุดคำศัพท์เฉพาะกลุ่มทั้ง 9 หมวดหมู่หลัก โดยให้ค่าน้ำหนักตามตำแหน่งและความยาวของคำ ในกรณีที่คะแนนจากกฎคำสำคัญไม่ถึงเกณฑ์ความเชื่อมั่นที่กำหนด ระบบจะส่งเวกเตอร์ TF-IDF ของข้อความเข้าสู่โมเดล Support Vector Machine (LinearSVC) ที่ผ่านการเทรนล่วงหน้า และมีโมเดล WangchanBERTa รองรับการประมวลผลข้อความเชิงลึกสำหรับข่าวที่มีบริบทซับซ้อน

4.3.3 ระบบเปิดอ่านบทความในตัวเว็บ (In-App Reader) และการสกัดเนื้อหาบทความ

เพื่อยกระดับประสบการณ์การอ่านข่าวให้มีความต่อเนื่องและปลอดภัย ระบบได้พัฒนาหน้าต่างอ่านบทความฉบับเต็มภายในตัวเว็บ (In-App Modal Reader) สำหรับแสดงผลเนื้อหาข่าวที่ผ่านการสกัดและทำความสะอาดแล้ว โดยทำงานร่วมกับ `BrowserService` เมื่อผู้อ่านคลิกเปิดอ่านข่าว ระบบจะตรวจสอบว่ามีเนื้อหาที่ผ่านการทำความสะอาดแล้วใน `AsyncInMemoryCache` หรือไม่ หากมีจะส่งกลับทันทีภายในเวลาต่ำกว่า 10 มิลลิวินาที ในกรณีที่ยังไม่มีข้อมูลในแคช ระบบจะใช้ Trafilatura ร่วมกับ Playwright Chromium ในการดึงและแยกวิเคราะห์เนื้อหาบทความฉบับเต็ม จากนั้นระบบ Backend จะตัดโฆษณา ป้ายแบนเนอร์ แทร็กเกอร์ และองค์ประกอบตกแต่งที่ไม่จำเป็นออกทั้งหมด พร้อมขจัดสคริปต์อันตราย (Anti-XSS) เพื่อความปลอดภัย และแปลงเนื้อหาให้อยู่ในรูปแบบ Markdown สะอาด ก่อนส่งไปแสดงผลบนหน้าต่างอ่านข่าวของเบราว์เซอร์ได้อย่างราบรื่น

4.3.4 ระบบสรุปข่าวอัตโนมัติด้วยโมเดลภาษาขนาดใหญ่ (LLM Summarization Pipeline)

ระบบส่งเนื้อหาข่าวในรูปแบบ Markdown ให้กับ KKU Gen.AI API โดยออกแบบ Prompt ให้ส่งคืนผลลัพธ์เป็นโครงสร้าง JSON ประกอบด้วย บทสรุปกระชับ 2–3 ประโยค ประเด็นสำคัญ 3–5 ข้อ และการวิเคราะห์อารมณ์ของข่าว (Sentiment: Positive, Neutral, Negative) ในภาษาเดียวกับเนื้อหาต้นฉบับ

4.3.5 สถาปัตยกรรมระบุประเด็นข่าวและจัดอันดับกระแสข่าวแบบสองชั้น (Two-Layer Story Identification & Deterministic Trending)

เพื่อแก้ไขข้อจำกัดของระบบเดิมที่คำนวณการจัดกลุ่มข่าวแบบชั่วคราว (Ad-hoc Clustering) ซึ่งจำกัดกรอบเวลาแข็งตัวไว้เพียง 36–48 ชั่วโมงจนทำให้ข่าวยืดเยื้อแตกกระจาย และมีการพึ่งพา LLM ในเส้นทางการประมวลผลอันดับข่าว ระบบได้ปรับปรุงสถาปัตยกรรมใหม่เป็นแบบสองชั้นที่แยกหน้าที่กันอย่างชัดเจนตามหลักการวิศวกรรมซอฟต์แวร์ ได้แก่ ชั้นที่ 1 การระบุและติดตามประเด็นข่าวแบบออนไลน์คงทน (`StoryService`) และชั้นที่ 2 เอนจินจัดอันดับกระแสข่าวเชิงสถิติแน่นอน (`TrendingService`)

(1) การระบุประเด็นข่าวออนไลน์แบบคงทน (Persistent Online Story Identification)

ในชั้นที่ 1 เมื่อมีบทความข่าวใหม่เข้าสู่ระบบ กระบวนการระบุประเด็นข่าวจะทำงานแบบออนไลน์เชิงเพิ่มพูน (Online Incremental Assignment) ตามแนวคิด Real-Time Story Identification ของ Škvorc และคณะ [12] โดยไม่จำเป็นต้องคำนวณจัดกลุ่มข่าวใหม่ทั้งคลังข้อมูล ซึ่งประกอบด้วยขั้นตอนการทำงานสำคัญ 4 ขั้นตอน:

ขั้นตอนแรกคือ การสกัดเวกเตอร์ความหมายหนาแน่น (Dense Semantic Embeddings) โดยนำข้อความพาดหัวข่าวร่วมกับเนื้อหาย่อแปลงเป็นเวกเตอร์ขนาด 768 มิติด้วยโมเดล WangchanBERTa ผ่านการรวมแบบเฉลี่ยถ่วงน้ำหนัก (Masked Mean Pooling) และปรับให้เป็นเวกเตอร์หนึ่งหน่วย (L_2 Normalization) ทำให้ผลคูณจุด (Dot Product) มีค่าเท่ากับค่าความคล้ายคลึงโคไซน์ (Cosine Similarity) พร้อมทั้งมีระบบแคชระดับ L1 ป้องกันการเข้ารหัสข้อความซ้ำซ้อน

ขั้นตอนที่สองคือ การสกัดเอนทิตีชื่อเฉพาะ (Named Entity Recognition: NER) โดยใช้โมเดล `thainer-v2` ของ PyThaiNLP ในการสกัดชื่อบุคคล (PERSON) องค์กร (ORGANIZATION) สถานที่ (LOCATION) และสิ่งอำนวยความสะดวก (FACILITY) ออกจากบทความข่าว

ขั้นตอนที่สามคือ การสืบค้นกลุ่มข่าวผู้ท้าชิงผ่านหน้าต่างเวลา 72 ชั่วโมงแบบไม่ปิดกั้นอายุขัย (Non-capping 72-Hour Candidate Window) โดยระบบจะค้นหากลุ่มประเด็นข่าว (`StoryRecord`) ที่มีข่าวอัปเดตล่าสุดภายใน 72 ชั่วโมงก่อนเวลาของบทความใหม่ ซึ่งการกำหนดหน้าต่างเวลานี้ช่วยควบคุมขอบเขตความซับซ้อนในการคำนวณโดยไม่จำกัดอายุขัยของประเด็นข่าว ทำให้เหตุการณ์วิกฤตที่ยืดเยื้อ เช่น อุทกภัย สามารถติดตามและผูกโยงข่าวใหม่เข้ากับประเด็นเดิมได้อย่างต่อเนื่องข้ามสัปดาห์

ขั้นตอนที่สี่คือ การตัดสินใจรวมกลุ่มด้วยเกณฑ์สองระดับ (Two-Band Cosine Decision Gate) โดยคำนวณความคล้ายคลึงโคไซน์ระหว่างเวกเตอร์บทความใหม่กับจุดศูนย์กลางของกลุ่มประเด็นข่าว ($\mathbf{c}$):

$$\text{MergeDecision} = \begin{cases} \text{Direct Merge} & \text{เมื่อ } \cos(\mathbf{e}_{\text{new}}, \mathbf{c}) \geq 0.85 \\ \text{Confirmed Merge} & \text{เมื่อ } 0.74 \leq \cos(\mathbf{e}_{\text{new}}, \mathbf{c}) < 0.85 \text{ และมีเอนทิตีตรงกัน } \geq 1 \\ \text{New Story Cluster} & \text{กรณีอื่น ๆ (สร้างกลุ่มประเด็นข่าวใหม่)} \end{cases} \tag{3}$$

ในกรณีที่มีการรวมบทความเข้าสู่กลุ่มประเด็นเดิม เวกเตอร์จุดศูนย์กลางจะได้รับการปรับปรุงอย่างต่อเนื่องด้วยค่าเฉลี่ยเคลื่อนที่แบบเอกซ์โพเนนเชียล (Exponential Moving Average: EMA) ตามสมการ:

$$\mathbf{c}_{\text{new}} = \alpha \cdot \mathbf{c}_{\text{old}} + (1 - \alpha) \cdot \mathbf{e}_{\text{new}} \tag{4}$$

โดยกำหนดค่าน้ำหนัก $\alpha = 0.85$ ช่วยรักษาเสถียรภาพของแกนเรื่องเดิมไม่ให้เบี่ยงเบนเร็วเกินไป พร้อมทั้งปรับตัวรองรับพัฒนาการใหม่ของข่าวได้อย่างยืดหยุ่น นอกจากนี้ กลุ่มประเด็นข่าวจะได้รับการบริหารจัดการวงจรชีวิต (Lifecycle State) ระหว่างสถานะพร้อมทำงาน (`active`) เมื่อมีข่าวอัปเดตในรอบ 72 ชั่วโมง และสถานะพักตัว (`dormant`) เมื่อไม่มีความเคลื่อนไหวเกิน 72 ชั่วโมง เพื่อประหยัดทรัพยากรระบบ โดยสามารถฟื้นคืนสถานะสู่ `active` ได้ทันทีหากมีข่าวด่วนที่เกี่ยวข้องเกิดขึ้นในอนาคต

(2) วิวัฒนาการของแบบจำลองการคำนวณคะแนนกระแสข่าว (Evolution of Trending Scoring Models)

ในการพัฒนาระบบจัดอันดับความนิยมของข่าวสาร คณะผู้พัฒนาได้ออกแบบและปรับปรุงแบบจำลองทางคณิตศาสตร์ออกเป็น 2 ยุคสมัย เพื่อแก้ไขจุดบกพร่องที่พบจากการทดสอบในสภาวะจริง:

(2.1) แบบจำลองดั้งเดิมแบบผลคูณตัวแปรประกอบ (Legacy Multiplicative Trending Model)

ในระยะเริ่มต้นของการพัฒนา ระบบใช้แบบจำลองการจัดอันดับระดับคลัสเตอร์ข่าวแบบชั่วคราว โดยคำนวณจากผลคูณของปัจจัยเชิงปริมาณ 3 ด้าน ร่วมกับคะแนนโบนัสข่าวด่วน ตามสมการ:

$$\text{TrendingScore}_{\text{legacy}} = \Big(\text{FE} \times M(K) \times D(\Delta t)\Big) + B \tag{5}$$

โดยมีรายละเอียดของแต่ละองค์ประกอบ ดังนี้:

1) **คะแนนพฤติกรรมผู้อ่าน (Reader Engagement Factor: FE)**: คำนวณจากสถิติปฏิสัมพันธ์ $E = 1.0(\text{clicks}) + 3.0(\text{summaries}) + 5.0(\text{bookmarks})$ และแปลงสเกลด้วยลอการิทึมเพื่อป้องกันการปั่นยอด $\text{FE} = 1.0 + 2.0 \cdot \ln(1.0 + E)$

2) **ตัวคูณฉันทามติของสื่อ (Consensus Multiplier: $M(K)$)**

: ให้คะแนนทวีคูณตามจำนวนสำนักข่าวอิสระ (K) ที่รายงานเรื่องเดียวกัน $M(K) = 1.0 + 0.55 \cdot (K - 1)$

3) **อัตราลดทอนตามกาลเวลา (Time Decay: $D(\Delta t)$)**

: ใช้ฟังก์ชันเอกซ์โพเนนเชียลค่าครึ่งชีวิต 12 ชั่วโมง $D(\Delta t) = 2^{-\Delta t/12.0}$ เมื่อ Δt คือจำนวนชั่วโมงนับตั้งแต่เริ่มเผยแพร่ข่าว

4) **คะแนนโบนัสข่าวด่วน (Breaking Boost: B)**

: กำหนดค่าคงที่ $B = 4.0$ หากข่าวมีอายุไม่เกิน 3 ชั่วโมง ($\Delta t \leq 3.0$) และมีสำนักข่าวรายงานตั้งแต่ 2 แห่งขึ้นไป ($K \geq 2$) และมีค่าเป็น 0.0 ในกรณีอื่น

เกณฑ์การมอบป้ายสถานะเดิม กำหนดให้ป้าย `Breaking` เมื่อ $\Delta t \leq 3.0$ และ $K \geq 2$, ป้าย `Top Story` เมื่อ $K \geq 3$, และป้าย `Trending` เมื่อ TrendingScore ≥ 4.5

(2.2) ข้อจำกัดของแบบจำลองดั้งเดิม

: จากการทดสอบใช้งานจริงพบปัญหาสำคัญ 3 ประการ ได้แก่ (1) ปัญหาข่าวประจำวันครองหน้าหนึ่ง (Routine News Dominance) ข่าวที่เป็นวงรอบ เช่น ผลสลากกินแบ่งรัฐบาล ราคาทองคำ และสภาพอากาศ ได้คะแนนสูงผิดปกติอย่างต่อเนื่องเนื่องจากมีจำนวนสำนักข่าวรายงานพร้อมกันมากและยอดคลิกสูง บดบังข่าวด่วนสำคัญของสังคม (2) การขาดมิติอัตราเร่ง (Velocity) ทำให้ไม่สามารถแยกความแตกต่างระหว่างข่าวที่มีข่าวทยอยเข้ามาเรื่อย ๆ กับข่าววิกฤตที่กำลังปะทุขึ้นอย่างรวดเร็วได้ และ (3) ปัญหาสำนักพิมพ์ในเครือเดียวกัน (Syndication Duplication) ที่คัดลอกบทความส่งผลให้ค่า K สูงเกินจริงโดยไม่ได้สะท้อนความหลากหลายของสื่อมวลชนที่แท้จริง

(3) เอนจินจัดอันดับกระแสข่าวเชิงสถิติแน่นอน (Deterministic 6-Signal Trending Engine)

เพื่อแก้ไขข้อจำกัดของแบบจำลองดั้งเดิม ในสถาปัตยกรรมชั้นที่ 2 ปัจจุบัน ระบบได้ยกเครื่องการจัดอันดับกระแสข่าวไปประมวลผลบนกลุ่มประเด็นข่าวออนไลน์แบบคงทน (`StoryRecord`) โดยตัดการ

พึ่งพาโมเดลภาษาขนาดใหญ่ (LLM) ออกจากเส้นทางการคำนวณคะแนนอย่างสิ้นเชิง (Zero LLM in scoring path) ทำให้การจัดอันดับมีความรวดเร็วระดับเสี้ยววินาทีและได้ผลลัพธ์ที่แน่นอนเชิงคณิตศาสตร์ (Deterministic) โดยคำนวณผ่าน 6 มิติเชิงสถิติร่วมกับตัวคูณลดทอนข่าวประจำวัน:

$$\text{FinalScore} = \left(\sum_{i=1}^{6} w_i \cdot s_i \right) \times \text{RoutinePenalty} \tag{6}$$

โดยมีรายละเอียดของแต่ละมิติคะแนน ดังนี้:

1) **ปริมาณข่าวในรอบ 24 ชั่วโมง (s_1 น้ำหนัก $w_1 = 0.25$)**
   : คำนวณจาก $s_1 = \ln(1 + N_{\text{recent}})$ เพื่อสะท้อนปริมาณความสนใจของสื่อมวลชน
2) **อัตราเร่งการมาถึงของข่าว (s_2 น้ำหนัก $w_2 = 0.30$)**
   : คำนวณจากอัตราส่วนระหว่างความถี่ของข่าวในรอบ 24 ชั่วโมงล่าสุดเทียบกับช่วงเวลาฐาน 48 ชั่วโมงก่อนหน้า เพื่อตรวจจับสัญญาณข่าวด่วนที่กำลังปะทุขึ้นในสังคม (Burst Detection)
3) **ความหลากหลายของสำนักข่าว (s_3 น้ำหนัก $w_3 = 0.25$)**
   : คำนวณจากฟังก์ชันรากที่สองของจำนวนสำนักข่าวที่ไม่ซ้ำกัน $s_3 = \sqrt{N_{\text{outlets}}}$ พร้อมกลไกลดทอนกรณีสำนักพิมพ์ในเครือเดียวกัน (Syndication Discount) เพื่อให้ข่าวที่รายงานโดยสำนักข่าวอิสระหลายแห่งมีน้ำหนักสูงกว่าข่าวที่คัดลอกกันมา
4) **การลดทอนตามเวลา (s_4 น้ำหนัก $w_4 = 0.10$)**
   : คำนวณจากฟังก์ชันเอกซ์โพเนนเชียลค่าครึ่งชีวิต 12 ชั่วโมง $s_4 = 2^{-\Delta t/12}$ เพื่อเปิดทางให้ข่าวสดใหม่ขึ้นมาทดแทนข่าวเก่า
5) **ความแปลกใหม่ของประเด็น (s_5 น้ำหนัก $w_5 = 0.05$)**
   : คำนวณจากระยะห่างเชิงความหมายของจุดศูนย์กลางประเด็นเทียบกับประเด็นข่าวอื่น $s_5 = 1.0 - \max_{j \neq k} \cos(\mathbf{c}_k, \mathbf{c}_j)$
6) **คะแนนปฏิสัมพันธ์จากผู้อ่าน (s_6 น้ำหนัก $w_6 = 0.05$)**
   : คำนวณจากสถิติพฤติกรรมการอ่านข่าวแบบนิรนาม $s_6 = \ln(1 + N_{\text{clicks}} + 2N_{\text{summaries}} + 3N_{\text{bookmarks}})$

สำหรับตัวคูณลดทอนข่าวประจำวัน (Routine News Penalty) ระบบได้กำหนดกลไกตรวจจับข่าวที่เกิดขึ้นเป็นวงรอบประจำวัน เช่น ข่าวราคาน้ำมัน ราคาทองคำ พยากรณ์อากาศ และผลสลากกินแบ่งรัฐบาล โดยกำหนดตัวคูณปรับลดคะแนน $\text{RoutinePenalty} = 0.25$ (ลดทอนคะแนนลงร้อยละ 75) ในขณะที่ข่าวทั่วไปมีค่าเท่ากับ 1.0 (พร้อมข้อยกเว้นกรณีเกิดภัยพิบัติฉุกเฉินระดับชาติ Crisis Exemption) กลไกนี้ช่วยป้องกันไม่ให้ข่าวประจำวันแย่งพื้นที่ข่าวกระแสสังคมที่แท้จริง พร้อมทั้งระบบส่งคืนข้อมูลแจกแจงคะแนนครบทุกมิติ (`TrendingScoreBreakdown`) ทำให้กระบวนการจัดอันดับมีความโปร่งใสและตรวจสอบที่มาได้ทุกขั้นตอน ทั้งนี้ ระบบยังคงฟังก์ชันคำนวณแบบเดิมไว้ในระดับบริการภายในเพื่อรองรับจุดเชื่อมต่อบริการสำหรับความเข้ากันได้ย้อนหลัง (`GET /api/news/trending`) อีกด้วย

4.3.6 ส่วนนำเสนอและการสังเคราะห์เนื้อหาประเด็นรวม (Story Presentation & LLM Synthesis)

สำหรับ กลุ่ม ประเด็น ข่าว ที่ ติด อันดับ กระแส ความ นิยม สูงสุด ระบบ จะ ส่ง ต่อ ข้อมูล ให้ `StoryPresentationService` เพื่อสร้างเนื้อหานำเสนอเชิงลึก โดยอาศัยโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) ในการสังเคราะห์พาดหัวข่าวประเด็นรวม (Macro Headline) ที่เป็นกลางและครอบคลุมทุกมุมมอง การสร้างบทสรุปย่อสังเคราะห์ข้ามสำนักข่าว (Multi-Article Synthesis) และการเรียบเรียงไทม์ไลน์พัฒนาการของเหตุการณ์ตามลำดับเวลา (Chronological Timeline Events) พร้อมลิงก์อ้างอิงกลับไปยังสำนักข่าวต้นทาง โดยผลลัพธ์ทั้งหมดจะถูกบันทึกแคชลงในฐานข้อมูลประเด็นข่าวโดยตรง เพื่อลดค่าใช้จ่ายในการเรียกใช้ API ซ้ำซ้อน และหากบริการ LLM ภายนอกขัดข้องหรือไม่ตอบสนอง ระบบมีกลไกสำรองการทำงานแบบอัตโนมัติ (Heuristic Fallback) โดยสลับไปใช้พาดหัวข่าวตัวแทนหลักและเรียบเรียงไทม์ไลน์ตามเวลาเผยแพร่จริง ทำให้ระบบสามารถตอบกลับคำขอด้วยสถานะ HTTP 200 ได้อย่างมีเสถียรภาพเสมอ

4.3.7 การจัดกลุ่มมหากาพย์ประเด็นข่าวและส่วนติดต่อผู้ใช้แบบ Bento Hub

เพื่อยกระดับการติดตามข่าวสารที่มีมิติความซับซ้อนสูง ระบบได้พัฒนา `MacroEventService` สำหรับเชื่อมโยงกลุ่มประเด็นข่าวย่อย (Sub-events) ที่มีความสัมพันธ์เชิงบริบทเข้าสู่มหากาพย์ประเด็นข่าวขนาดใหญ่ (Macro Storyline) พร้อมทั้งรองรับข้อยกเว้นกรณีวิกฤต (Crisis Exemption) ที่ช่วยให้ข้อมูลภัยพิบัติหรือเหตุฉุกเฉินระดับชาติได้รับการยกเว้นการลดทอนเวลา

ในด้านส่วนต่อประสานผู้ใช้ หน้าแรกของระบบได้รับการออกแบบใหม่เป็น Macro Storyline Bento Hub ซึ่งจัดวางองค์ประกอบแบบ 3 มุมมองหลัก (3-Perspective Matrix) ได้แก่ แถบข่าวเด่นประจำวัน บัตรสรุปประเด็นข่าวพร้อมป้ายสำนักข่าวที่รายงานร่วมกัน (Publisher Filter Pills) และแถบแฮชแท็กเชิงโต้ตอบ (#Hashtags Ribbon) เพื่อให้ผู้ใช้งานสามารถคลิกสำรวจมุมมองที่หลากหลายของแต่ละสำนักข่าวได้อย่างสะดวก นอกจากนี้ ระบบยังได้จัดเตรียมหน้าต่างติดตามและศูนย์ควบคุมสถานะระบบ (`frontend/monitoring.html`) สำหรับผู้ดูแลระบบ เพื่อตรวจสอบอัตราการรับเข้าของข่าว สุขภาพของแต่ละสำนักข่าว สถิติการทำงานของแคช และความเสถียรของไปป์ไลน์แบบเรียลไทม์

4.3.8 การติดต่อสื่อสารแบบเรียลไทม์ผ่าน WebSocket

เมื่อมีข่าวใหม่ที่ผ่านการสรุปและจำแนกเรียบร้อยแล้ว `SocketManager` จะทำการกระจาย Event (`news:new`) ไปยังเบราว์เซอร์ของผู้ใช้ทุกคนที่กำลังเปิดหน้าเว็บอยู่ เพื่อให้ผู้ใช้ได้รับข่าวสารล่าสุดทันทีโดยไม่ต้องทำการรีเฟรชหน้าต่างเบราว์เซอร์

4.3.9 รายละเอียดการทำงานของจุดเชื่อมต่อบริการทั้งหมด (API Specifications)

ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติได้รับการพัฒนาจุดเชื่อมต่อบริการแบบ REST API ตามมาตรฐาน OpenAPI 3.0 โดยแบ่งแยกความรับผิดชอบออกเป็น 6 กลุ่ม Router หลัก และระบบการตรวจสอบสถานะ (System Probes) รวมทั้งสิ้น 20 จุดเชื่อมต่อบริการ ดังนี้:

กลุ่มที่ 1 จุดเชื่อมต่อบริการกลุ่มประเด็นข่าว (`StoryRouter` เส้นทางหลัก `/api/stories`) มีหน้าที่จัดการวงจรชีวิตและการเรียกดูประเด็นข่าวสารที่ผ่านการจัดกลุ่มแบบสองชั้น ประกอบด้วย: `GET /api/stories` ใช้สำหรับเรียกดูรายการประเด็นข่าวสาร รองรับพารามิเตอร์การกรองตามหมวดหมู่ (`category`) สถานะวงจรชีวิต (`status` ได้แก่ `active` หรือ `dormant`) ตลอดจนการแบ่งหน้า (`limit` ค่าเริ่มต้น 20 และ `offset`) โดยส่งคืนรายการ `StoryRecord` พร้อมรายชื่อสำนักข่าวร่วม `GET`

/api/stories/trending ใช้สำหรับเรียกดูประเด็นข่าวที่กำลังเป็นกระแสความนิยมสูงสุด โดยนำเสนอข้อมูลที่ผ่านการประมวลผลคะแนนจากเอนจินจัดอันดับแบบดีเทอร์มินิสติก (Layer 2) พร้อมรายละเอียดการแจกแจงคะแนน (TrendingScoreBreakdown) GET /api/stories/{story_id} ใช้สำหรับเรียกดูข้อมูลเชิงลึกของประเด็นข่าวรายเรื่อง ประกอบด้วยพาดหัวภาพรวม บทสรุปสังเคราะห์ รายชื่อสำนักข่าวทั้งหมด ไทม์ไลน์พัฒนาการของเหตุการณ์ และรายชื่อบทความข่าวเดี่ยวในกลุ่ม POST /api/stories/{story_id}/summarize ใช้สำหรับร้องขอการสังเคราะห์เนื้อหาภาพรวมประเด็นข่าว ไทม์ไลน์ และพาดหัวข่าวร่วมผ่านโมเดลภาษาขนาดใหญ่ (KKU Gen.AI) แบบ On-Demand โดยมีกลไกตรวจสอบแคชเพื่อป้องกันการประมวลผลซ้ำ และมีระบบสำรองแบบฮิวริสติก (Heuristic Fallback) รองรับกรณีที่โมเดลภาษาภายนอกไม่ตอบสนอง

กลุ่มที่ 2 จุดเชื่อมต่อบริการกลุ่มมหากาพย์ประเด็นข่าว (MacroEventRouter เส้นทางหลัก /api/macro-events) ทำหน้าที่บริหารจัดการประเด็นข่าวขนาดใหญ่ที่มีความเชื่อมโยงกันข้ามหมวดหมู่และยืดเยื้อ ประกอบด้วย: GET /api/macro-events ใช้สำหรับดึงรายการมหากาพย์ประเด็นข่าวทั้งหมด โดยสามารถกรองตามสถานะและข้อยกเว้นกรณีวิกฤต (crisis) GET /api/macro-events/trending ใช้สำหรับดึงมหากาพย์ข่าวที่กำลังได้รับความสนใจสูงสุดเพื่อนำไปแสดงผลบนพื้นที่เด่นของหน้าหลัก Bento Hub GET /api/macro-events/{macro_id} ใช้สำหรับดึงรายละเอียดโครงสร้างมหากาพย์ข่าว ความเชื่อมโยงระหว่างประเด็นย่อย (Sub-events) และไทม์ไลน์ภาพรวมเหตุการณ์

กลุ่มที่ 3 จุดเชื่อมต่อบริการข้อมูลข่าวสารหลัก (NewsRouter เส้นทางหลัก /api) ทำหน้าที่ให้บริการข้อมูลบทความข่าวเดี่ยวและการสกัดเนื้อหา ประกอบด้วย: GET /api/news ใช้สำหรับดึงรายการบทความข่าวสาร รองรับพารามิเตอร์การแบ่งหน้า (page, page_size) ตัวกรองหมวดหมู่ (category) ตัวกรองสำนักข่าว (source) และการค้นหาด้วยคำสำคัญ (search) โดยมีระบบแคชระดับ L1 และรองรับ HTTP 304 Not Modified ผ่านส่วนหัว ETag GET /api/news/content ใช้สำหรับสกัดเนื้อหาบทความข่าวฉบับเต็มในรูปแบบ Cleaned Markdown ผ่าน Trafilatura และ Playwright สำหรับนำไปแสดงผลบนหน้าต่าง In-App Modal Reader GET /api/categories ใช้สำหรับเรียกดูรายชื่อ 9 หมวดหมู่ข่าวภาษาไทยที่ระบบรองรับ พร้อมรหัสสีและข้อมูลสถิติ GET /api/sources ใช้สำหรับเรียกดูรายชื่อสำนักข่าวทั้งหมดที่ลงทะเบียนและเปิดใช้งานในระบบ (@register_source) GET /api/status ใช้สำหรับตรวจสอบสถานะรอบเวลาการทำงานของสเกรปเปอร์และจำนวนข่าวสะสมในระบบ GET /api/image ใช้เป็นบริการ Reverse Proxy สำหรับดึงและแคชรูปภาพหน้าปกบทความข่าว เพื่อแก้ไขปัญหาการจำกัดการเข้าถึงข้ามโดเมน (CORS) และการป้องกัน Hotlinking ของเว็บไซต์ต้นทาง

กลุ่มที่ 4 จุดเชื่อมต่อบริการนำเข้าบทความเฉพาะกิจ (CollectRouter เส้นทางหลัก /api) ประกอบด้วย: POST /api/collect-md รับข้อมูล URL ของบทความข่าวเดี่ยวจากผู้ใช้ เพื่อสั่งให้ระบบทำการดึงเนื้อหา สกัดบทความ ตัดคำ และจำแนก 9 หมวดหมู่โดยทันทีแบบ On-Demand

กลุ่มที่ 5 จุดเชื่อมต่อบริการจัดอันดับกระแสและการมีส่วนร่วม (TrendingRouter เส้นทางหลัก /api/news) ประกอบด้วย: GET /api/news/trending ใช้สำหรับเรียกดูข่าวเดี่ยวที่ติดกระแสความนิยม (คงไว้เพื่อความเข้ากันได้ย้อนหลังกับระบบเวอร์ชันเดิม) POST /api/news/engage และ POST /api/news/engagement รับข้อมูลเหตุการณ์การมีส่วนร่วมของผู้อ่านแบบนิรนาม

(click, summary_view, bookmark, share) เพื่อนำไปคำนวณเป็นคะแนนปฏิสัมพันธ์ของข่าวโดยไม่มีการเก็บข้อมูลส่วนบุคคล

กลุ่มที่ 6 จุดเชื่อมต่อบริการศูนย์ควบคุมและติดตามสถานะระบบ (MonitoringRouter เส้นทางหลัก /api/monitoring) ประกอบด้วย: POST /api/monitoring/auth ใช้สำหรับตรวจสอบรหัสผ่านลับของผู้ดูแลระบบ (admin_secret) และสร้างโทเค็นเซสชันความปลอดภัย GET /api/monitoring/verify ใช้สำหรับตรวจสอบความถูกต้องของโทเค็นเซสชันผู้ดูแลระบบ GET /api/monitoring/stats ใช้สำหรับดึงข้อมูลสถิติสุขภาพของระบบ การใช้หน่วยความจำ RAM อัตรา Throughput การทำงานของสเกรปเปอร์ และอัตราความสำเร็จของแคช (Cache Hit Ratio) POST /api/monitoring/scrape-now ใช้สำหรับส่งคำสั่งให้ระบบเริ่มรอบการสเกรปข่าวทุกสำนักทันทีแบบ Asynchronous POST /api/monitoring/clear-cache ใช้สำหรับสั่งล้างข้อมูลในแคชหน่วยความจำ แคช HTTP ETag และแคชบทสรุปประเด็นข่าว POST /api/monitoring/test-source ใช้สำหรับทดสอบการเชื่อมต่อและการแยกวิเคราะห์เนื้อหาของสำนักข่าวรายแห่งที่ระบุ

นอกจากจุดเชื่อมต่อบริการ REST API ข้างต้นแล้ว ระบบยังมีจุดเชื่อมต่อบริการสำหรับตรวจสอบสถานะระดับโครงสร้างพื้นฐาน (System Probes) ได้แก่ GET /livez (Liveness Probe ยืนยันการทำงานของโปรเซส), GET /readyz (Readiness Probe ตรวจสอบความพร้อมของระบบจัดเก็บข้อมูลและ Chromium Headless), GET /sw.js (บริการ Service Worker รองรับการแคชออฟไลน์แบบ Progressive Web App) และช่องทางการสื่อสาร WebSocket ผ่าน Socket.IO สำหรับผลักดันเหตุการณ์ข่าวใหม่ (news:new) แบบสองทิศทาง

สรุปรายละเอียดจุดเชื่อมต่อบริการสำคัญ พารามิเตอร์ และรหัสสถานะการตอบกลับแสดงดังตารางที่ 13

ตารางที่ 13 รายละเอียดข้อกำหนดจุดเชื่อมต่อบริการ REST API และ System Probes ทั้งหมดในระบบ

Method	เส้นทาง (Route)	วัตถุประสงค์และหน้าที่	พารามิเตอร์หลัก	HTTP Status
GET	/api/stories	ดึงรายการประเด็นข่าวสาร	category, status, limit	200, 304, 500
GET	/api/stories/trending	ดึงประเด็นข่าวกระแสหลัก Layer 2	–	200, 304
GET	/api/stories/{id}	ดึงรายละเอียดประเด็นและไทม์ไลน์	story_id (Path)	200, 404
POST	/api/stories/{id}/summarize	ร้องขอการสรุปสังเคราะห์ประเด็นข้ามสำนัก	story_id (Path)	200, 500
GET	/api/macro-events	ดึงรายการมหากาพย์ประเด็นข่าว	status, crisis	200, 304
GET	/api/macro-events/trending	ดึงมหากาพย์ข่าวเด่นบน Bento Hub	–	200, 304
GET	/api/macro-events/{id}	ดึงโครงสร้างมหากาพย์และประเด็นย่อย	macro_id (Path)	200, 404
GET	/api/news	ดึงรายการข่าวสารเดี่ยวแบบแบ่งหน้า	page, category, search	200, 304
GET	/api/news/content	สกัดเนื้อหาฉบับเต็ม Cleaned Markdown	url (Query)	200, 400, 500
GET	/api/categories	ดึงรายชื่อและเมทาดาตา 9 หมวดหมู่	–	200, 304
GET	/api/sources	ดึงรายชื่อสำนักข่าวและชุดสีที่ลงทะเบียน	–	200, 304
GET	/api/status	ตรวจสอบรอบสเกรปและจำนวนข่าว	–	200
GET	/api/image	บริการ Reverse Proxy และแคชรูปภาพ	url (Query)	200, 400, 502
POST	/api/collect-md	นำเข้าและสกัดเนื้อหาข่าวรายชิ้นด่วน	url (Body JSON)	200, 422
POST	/api/news/engage	บันทึกสถิติการมีส่วนร่วมแบบนิรนาม	article_id, action	200, 400
POST	/api/monitoring/auth	ยืนยันตัวตนผู้ดูแลระบบออกโทเค็น	secret (Body JSON)	200, 401
GET	/api/	ตรวจสอบสถานะโทเค็นเซสชัน	Header Bearer	200, 401

4.3.10 รายละเอียดส่วนต่อประสานและปุ่มควบคุมทั้งหมดของระบบ (Complete UI Controls & Buttons Catalog)

เพื่อ อำนวย ความ สะดวก ใน การ ใช้ งาน ของ ผู้ใช้ ทุก กลุ่ม ระบบ ได้ รับ การ ออกแบบ ส่วน ติดต่อ ผู้ใช้ เป็น 2 ส่วน หลัก ได้แก่ ส่วน ต่อ ประสาน ผู้ อ่าน ข่าว ทั่วไป (Bento Hub SPA บน ไฟล์ `frontend/index.html`) และ ศูนย์ ควบคุม และ ติดตาม สถานะ ระบบ สำหรับ ผู้ ดูแล (Ops Console บน ไฟล์ `frontend/monitoring.html`) โดย องค์ ประกอบ ของ ปุ่ม ควบคุม ตัว เลือก ปฏิสัมพันธ์ และ หน้า ต่าง โมดอล ทั้ง หมด จำแนก ได้ ดังนี้:

ใน ส่วน ต่อ ประสาน ผู้ อ่าน ข่าว Bento Hub (`frontend/index.html`): ปุ่ม แบนเนอร์ แจ้ง เตือน ข่าว ใหม่ ลอยตัว (Floating Unread Articles Banner Button) เรียก ใช้ ฟังก์ชัน `___loadUnreadArticles()` จะ ปรากฏ ขึ้น บริเวณ กึ่งกลาง ด้าน บน ของ หน้า จอ เมื่อ มี ข่าว ใหม่ เข้า มา ผ่าน WebSocket พร้อม แสดง ข้อความ จำนวน ข่าว ที่ เพิ่ง มา ถึง เมื่อ ผู้ใช้ คลิก ปุ่ม ระบบ จะ เลื่อน หน้า จอ กลับ ขึ้น สู่ ด้าน บน สุด (Smooth Scroll) และ นำ ข่าว ใหม่ เข้า สู่ ตาราง แสดง ผล ทันที โดย ไม่ ต้อง รีโหลด หน้า เว็บ ปุ่ม ปิด แบนเนอร์ ข่าว ใหม่ (Banner Dismiss Button) เรียก ใช้ ฟังก์ชัน `___dismissNewArticlesBanner()` อยู่ บริเวณ มุม ขวา ของ แบนเนอร์ ข่าว ใหม่ เพื่อ ให้ ผู้ใช้ สามารถ ปิด การ แจ้ง เตือน ได้ หาก ยัง ไม่ ต้อง การ โหลด ข่าว ใหม่ ใน ทันที ปุ่ม ตรา สัญลักษณ์ และ ชื่อ ระบบ (Brand Navigation Control) บริเวณ มุม บน ซ้าย ของ แถบ นำ ทาง เมื่อ ผู้ใช้ คลิก จะ คืน ค่า กลับ สู่ หน้า หลัก Bento Hub โดย ทำ การ ล้าง ตัว กรอง หมวด หมู่ และ คำ ค้น หา ทั้ง หมด ปุ่ม เปิด ประวัติ การ อ่าน ข่าว (Reading History Button) เรียก ใช้ ฟังก์ชัน `___showHistory()` เพื่อ เปิด หน้า ต่าง โมดอล แสดง รายการ บทความ ที่ ผู้ใช้ เคย เปิด อ่าน ซึ่ง บันทึก อยู่ บน LocalStorage ของ เบราว์เซอร์ ปุ่ม เปิด รายการ ข่าว ที่ บันทึก ไว้ (Bookmarks Button) เรียก ใช้ ฟังก์ชัน `___showBookmarks()` เพื่อ เปิด หน้า ต่าง โมดอล แสดง รายการ ข่าว ที่ ผู้ใช้ ได้ กด บันทึก คั่น หน้า ไว้ สำหรับ การ อ่าน ภายหลัง ปุ่ม เปิด การ ตั้ง ค่า และ ความ เป็น ส่วน ตัว (Settings & Privacy Button) เรียก ใช้ ฟังก์ชัน `___openSettings()` สำหรับ เปิด หน้า ต่าง โมดอล ตั้ง ค่า สิทธิ์ คุก กี้ การ ปรับ ธีม การ แสดง ผล และ การ จัด การ ข้อมูล ส่วน บุคคล ตาม มาตรฐาน PDPA แถบ ปุ่ม แท็บ หมวด หมู่ ข่าว (Category Navigation Tabs) ประกอบ ด้วย ปุ่ม สลับ หมวด หมู่ ข่าว ภาษา ไทย ทั้ง 9 หมวด หมู่ หลัก พร้อม ปุ่ม ”ทั้ง หมด (All)” เพื่อ ดู ข่าว รวม และ ปุ่ม ”สำหรับ คุณ (For You)” ซึ่ง แสดง ข่าว ที่ สอด คล้อง กับ ความ สนใจ จาก พฤติกรรม การ อ่าน แถบ ปุ่ม คัด กรอง สำนัก ข่าว (Publisher Filter Pills) เป็น ชุด ปุ่ม รูป แคปซูล แสดง รายชื่อ และ สี ประจำ สำนัก ข่าว (เช่น ThaiPBS, ไทยรัฐ, เดลินิวส์, มติชน ฯลฯ) ที่ อนุญาต ให้ ผู้ใช้ คลิก เลือก เพื่อ ดู ข่าว เฉพาะ สำนัก พิมพ์ ที่ สนใจ ได้ แถบ ปุ่ม แฮช แท็ก ประเด็น ข่าว (#Hashtags Ribbon) เป็น ปุ่ม ตัว เลือก แฮช แท็ก ของ ประเด็น ข่าว เด่น ช่วย ให้ ผู้ใช้ สามารถ คลิก สำรวจ ข่าว สาร ใน เหตุการณ์ เดียว กัน ได้ อย่าง รวดเร็ว แถบ ค้น หา และ ปุ่ม ล้าง คำ ค้น (Search Input & Clear Button) กล่อง ป้อน ข้อความ ค้น หา ข่าว แบบ Real-time พร้อม ปุ่ม กากบาท [×] สำหรับ ล้าง คำ ค้น หา เพื่อ คืน ค่า รายการ ข่าว ทั้ง หมด ปุ่ม บน การ์ด ข่าว สาร และ ประเด็น ข่าว (Card Action Controls) ซึ่ง ติด ตั้ง อยู่ บน บัตร ข่าว ทุก ใบ ประกอบ ด้วย ปุ่ม เปิด บทสรุป ผู้บริหาร AI (Executive AI Briefing Button รูป ดาว สี่ แฉก) สำหรับ เปิด โมดอล สรุป เนื้อหา สังเคราะห์ และ Sentiment, ปุ่ม เปิด อ่าน บทความ ฉบับ เต็ม ใน ตัว เว็บ (In-App Reader Modal Button) สำหรับ อ่าน เนื้อหา Cleaned Markdown แบบ เต็ม หน้า ต่าง, ปุ่ม บันทึก คั่น หน้า (Bookmark Toggle Button) สำหรับ เพิ่ม หรือ ยก เลิก การ บันทึก ข่าว, ปุ่ม แชร์ ข่าว (Share Button) สำหรับ เรียก ใช้ Web Share API ของ ระบบ ปฏิบัติการ หรือ คัด ลอก ลิงก์ ไป ยัง คลิป บอร์ด และ ปุ่ม เปิด หน้า เว็บ ข่าว ต้น ฉบับ (External Source Link Button) สำหรับ เปิด ลิงก์ ข่าว จริง ใน แท็บ ใหม่ ปุ่ม ควบคุม การ แบ่ง หน้า

(Pagination Controls) ประกอบด้วยปุ่มหน้าก่อนหน้า (Previous Page Button), ปุ่มระบุหมายเลขหน้า (Page Number Buttons) และปุ่มหน้าถัดไป (Next Page Button) สำหรับเลือกดูข่าวสารในหน้าต่าง ๆ ปุ่มควบคุมในหน้าต่างโมดอล (Modal Action Buttons) ประกอบด้วยปุ่มปิดหน้าต่างโมดอล [×], ปุ่มล้างประวัติการอ่านทั้งหมด (Clear All History Button) และปุ่มลบรายการเดี่ยวออกจากประวัติหรือบุ๊กมาร์ก ปุ่มควบคุมความเป็นส่วนตัว PDPA (Privacy & Consent Controls) ประกอบด้วยปุ่มยินยอมการใช้งานคุกกี้ (Accept Cookies Button), ปุ่มปฏิเสธคุกกี้ (Reject Button) และปุ่มล้างข้อมูลสถิติความสนใจ (Clear Preference Data Button) เพื่อให้ผู้ใช้สามารถลบประวัติความสนใจทั้งหมดออกจากเบราว์เซอร์ได้ทันที

ในส่วนศูนย์ควบคุมและติดตามสถานะระบบสำหรับผู้ดูแล(`frontend/monitoring.html`): ปุ่มสลับการแสดงผลรหัสผ่าน (Password Visibility Toggle Button) บนฟอร์มยืนยันตัวตน เพื่อสลับการแสดงผลรหัสผ่านระหว่างจุดวงกลมกับข้อความธรรมดา ปุ่มเข้าสู่ระบบคอนโซล (Admin Login Submit Button) สำหรับส่งรหัสผ่านลับของผู้ดูแลระบบไปยังเซิร์ฟเวอร์เพื่อตรวจสอบสิทธิ์และรับโทเค็น กล่องสลับการรีเฟรชข้อมูลอัตโนมัติ (Auto-refresh Toggle Checkbox) สำหรับเปิดหรือปิดการส่งคำขอดึงสถิติสุขภาพของระบบทุก 5 วินาที ปุ่มรีเฟรชสถานะด้วยตนเอง (Manual Refresh Button) สำหรับสั่งให้เบราว์เซอร์ส่งคำขอดึงสถิติล่าสุดทันทีโดยไม่ต้องรอรอบเวลา ปุ่มสั่งเริ่มรอบการสเกรปข่าวทันที (Scrape Now Button) สำหรับสั่งการให้ระบบเริ่มกระบวนการสเกรปข่าวด่วนจากทุกสำนักพร้อมกัน ปุ่มสั่งล้างแคชระบบ (Clear Cache Button) สำหรับสั่งให้เซิร์ฟเวอร์ล้างข้อมูลใน L1 Memory Cache, แคช HTTP ETag และแคชบทสรุปประเด็นข่าว ปุ่มทดสอบแหล่งข่าวรายสำนัก (Test Source Probe Buttons) ซึ่งมีอยู่ประจำแต่ละสำนักข่าว เพื่อให้ผู้ดูแลสามารถกดทดสอบการเชื่อมต่อและการสกัดข้อมูลเฉพาะสำนักข่าวนั้น ๆ พร้อมแสดงผลรหัสสถานะและจำนวนบทความที่พบ ปุ่มออกจากระบบคอนโซล (Logout Button) สำหรับทำลายโทเค็นเซสชันและนำผู้ดูแลกลับสู่หน้าจอยืนยันตัวตนอย่างปลอดภัย

รายการสรุปและคุณลักษณะของปุ่มควบคุม ปฏิสัมพันธ์ และฟังก์ชันที่ผูกโยงในระบบแสดงดังตารางที่ 14

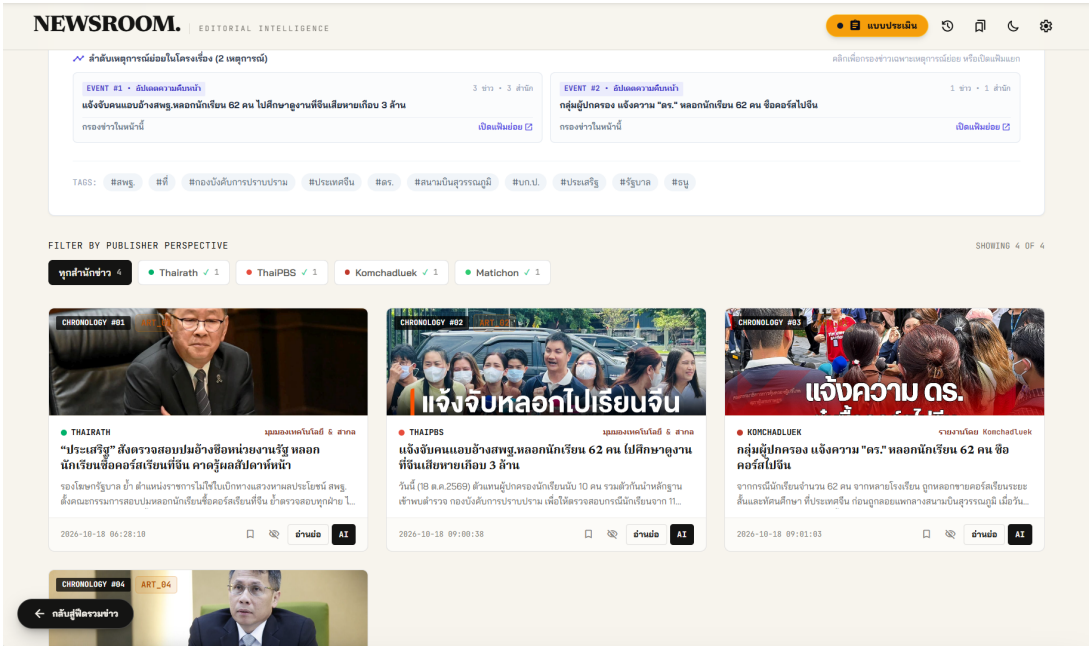
ตารางที่ 14 รายละเอียดคุณลักษณะของปุ่มควบคุมและองค์ประกอบปฏิสัมพันธ์ทั้งหมดในระบบ

ชื่อปุ่มควบคุม	ตำแหน่งบนหน้าจอ	พฤติกรรมและการตอบสนอง	ฟังก์ชัน/เหตุการณ์ที่ผูกโยง
ปุ่มแบนเนอร์ข่าวใหม่ลอยตัว	กึ่งกลางบน (Fixed)	เลื่อนจอขึ้นบนสุดและโหลดข่าวใหม่เข้าตาราง	`__loadUnreadArticles()`
ปุ่มปิดแบนเนอร์ข่าวใหม่	มุมขวาของแบนเนอร์	ซ่อนแถบแบนเนอร์แจ้งเตือนข่าวใหม่	`__dismissNewArticlesBanner`
ปุ่มตราสัญลักษณ์และชื่อระบบ	ซ้ายบนของ Navbar	คืนค่าหน้าหลักและล้างตัวกรองทั้งหมด	`window.location.hash = '#/'`
ปุ่มประวัติการอ่าน	ขวาบนของ Navbar	เปิดโมดอลแสดงประวัติบทความที่เคยอ่าน	`__showHistory()`
ปุ่มรายการคั่นหน้า	ขวาบนของ Navbar	เปิดโมดอลแสดงรายการบทความที่บันทึกไว้	`__showBookmarks()`
ปุ่มตั้งค่าและความเป็นส่วนตัว	ขวาบนของ Navbar	เปิดโมดอลตั้งค่า PDPA และธีมการแสดงผล	`__openSettings()`
ปุ่มแท็บหมวดหมู่ (9 หมวด)	แถบใต้ Navbar	สลับกรองข่าวสารตามหมวดหมู่ที่เลือก	`__filterCategory(category)`
ปุ่มตัวกรองสำนักข่าว (Pills)	แถบตัวกรอง	แสดงข่าวเฉพาะสำนักพิมพ์ที่คลิกเลือก	`__filterSource(source)`
ปุ่มแฮชแท็กประเด็นข่าว	แถบ Bento Ribbon	กรองข่าวตามแฮชแท็กสำคัญของเหตุการณ์	`__filterHashtag(tag)`
ปุ่มล้างคำค้นหา [×]	ภายในกล่องค้นหา	ล้างข้อความค้นหาและแสดงข่าวทั้งหมด	`__clearSearch()`
ปุ่มเปิดบทสรุป AI ผู้บริหาร	บนบัตรข่าว/ประเด็น	เปิดโมดอลสรุปเนื้อหาสังเคราะห์และ Sentiment	`__openStorySummary(id)`
ปุ่มอ่านข่าวฉบับเต็ม In-App	บนบัตรข่าว	เปิดหน้าต่างอ่าน Markdown สะอาด ไร้โฆษณา	`__openReader(articleUrl)`
ปุ่มบันทึกคั่นหน้า (Bookmark)	บนบัตรข่าว	สลับสถานะบันทึกลงในเบราว์เซอร์ LocalStorage	`__toggleBookmark(id)`
ปุ่มแชร์ข่าว (Share)	บนบัตรข่าว	แชร์ผ่าน Web Share API หรือคัดลอกลิงก์	`__shareArticle(url, title)`
ปุ่มลิงก์ข่าวต้นฉบับ	บนบัตรข่าว	เปิดเว็บข่าวต้นฉบับในแท็บใหม่	ลิงก์ `target="_blank"`
ปุ่มควบคุมการแบ่งหน้า	ท้ายตารางข่าว	สลับไปหน้ารายการข่าวก่อนหน้า/ถัดไป	`__changePage(pageNum)`
ปุ่มล้างประวัติ/บุ๊กมาร์ก	ภายในโมดอล	ล้างข้อมูลทั้งหมดออกจาก LocalStorage	`__clearHistory()`, `__clearAllBookmarks()`
ปุ่มล้างข้อมูลความสนใจ	โมดอลตั้งค่า/	ลบข้อมูลสถิติความสนใจและคุกกี้	`__clearPreferenceData()`

4.3.11 ตัวอย่างส่วนต่อประสานผู้ใช้และการแสดงผลจริงของระบบ (System User Interface Demonstration)

เพื่อแสดงให้เห็นถึงผลลัพธ์การทำงานจริงของระบบตามสถาปัตยกรรมระดับมหากาพย์ประเด็นข่าว (Stage B Macro Storyline Architecture) และระบบกลไกป้องกันความถูกต้อง (Grounded Synthesis Guardrails) ในหัวข้อนี้จะนำเสนอตัวอย่างส่วนต่อประสานผู้ใช้ (User Interface) ของระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติที่ผ่านการติดตั้งและประมวลผลข้อมูลจริงในสภาพแวดล้อมปฏิบัติการ โดยครอบคลุม 2 หน้าจอหลัก ดังนี้

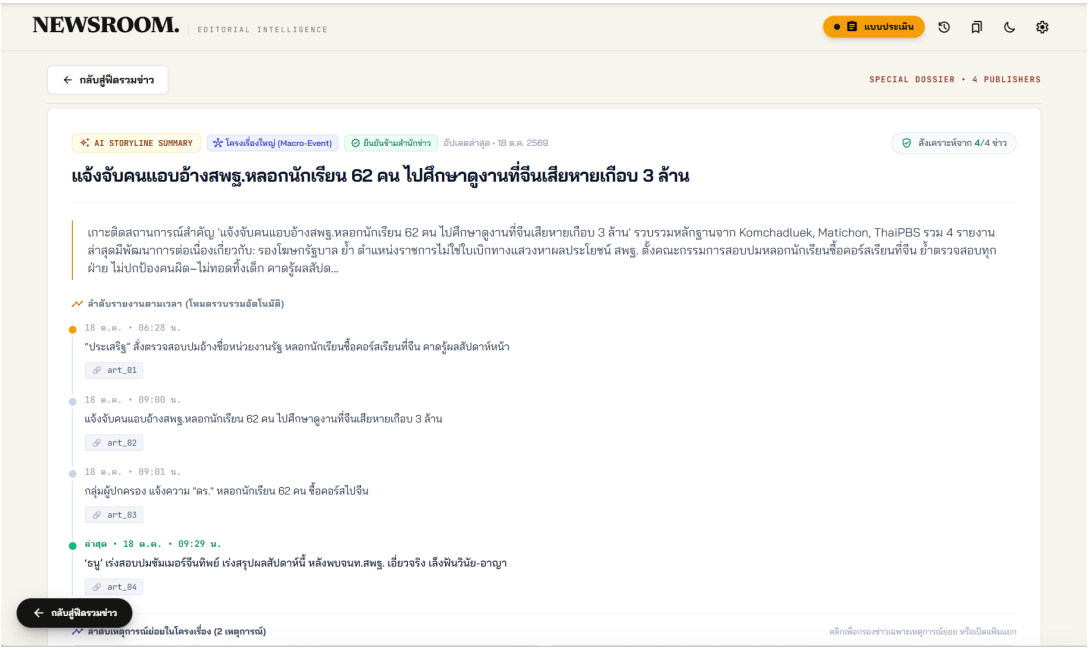
ประการแรก หน้าจอแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่ผ่านการยับยั้งการรวมกลุ่มข้ามเรื่อง (Stage B Hardened Storyline Bento Hub) ดังแสดงในภาพที่ 9 นำเสนอผลสัมฤทธิ์ของสถาปัตยกรรม Stage B หลังการบังคับใช้กฎ Province-Only Veto และการแยกประเภท Typed NER โดยแสดงประเด็นข่าวสำคัญระดับประเทศที่ผูกโยงข่าวสารเฉพาะเหตุการณ์จริงอย่างแม่นยำ พร้อมบัตรหลักฐานข่าวที่มีรหัสอ้างอิงชัดเจน ปราศจากการรั่วไหลของข่าวอุบัติเหตุหรือเหตุการณ์ทั่วไปในจังหวัดเดียวกัน และแสดงป้ายสถิติการยืนยันข้ามสำนักข่าว (Corroborated Sources) อย่างเป็นรูปธรรม



ภาพที่ 9 ภาพแสดงหน้าต่างแฟ้มเจาะลึกมหากาพย์ประเด็นข่าวที่ผ่านการยับยั้งการรวมกลุ่มข้ามเรื่อง (Stage B Hardened Storyline)

ประการที่สอง แฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาและข้อเท็จจริงยืนยันที่ผ่านเกตคัดกรองความเกี่ยวข้อง (Enforced Progression Timeline & Corroborated Evidence) ดังแสดงในภาพที่ 10 แสดงพัฒนาการของเหตุการณ์ตามลำดับเวลาจริง โดยข้อมูลทุกจุดในไทม์ไลน์และข้อเท็จจริงยืนยันถูกสกัดมาจากเฉพาะกลุ่มบทความที่ผ่านการคัดกรองความเกี่ยวข้อง (Relevant Evidence) ปราศจากการปนเปื้อนของข่าวที่

เป็นเพียงบริบทแวดล้อมหรือข่าวหลุดประเด็น ทำให้ผู้อ่านสามารถติดตามลำดับสถานการณ์และตรวจสอบย้อนกลับไปยังแหล่งข่าวต้นทางได้อย่างถูกต้องและน่าเชื่อถือ



ภาพที่ 10 ภาพแสดงแฟ้มสังเคราะห์ไทม์ไลน์พัฒนาการเหตุการณ์ตามลำดับเวลาและข้อเท็จจริงยืนยันที่ผ่านเกตคัดกรองความเกี่ยวข้อง

4.3.12 ระบบเจาะประเด็นข่าวและค้นหาเชิงวิเคราะห์ (Issue Explorer & In-depth Search)

นอกจากการสำรวจกระแสข่าวสารสดประจำวันและมหากาพย์เหตุการณ์บนหน้าจอหลักแล้ว ระบบยังได้พัฒนาส่วนต่อประสานสำหรับเจาะประเด็นข่าวเชิงลึก (Issue Explorer Workstation) ผ่านหน้าเว็บ `/issues` เพื่อรองรับการค้นคว้าและสืบค้นเชิงวิเคราะห์ของนักข่าว นักวิเคราะห์นโยบาย และผู้อ่านทั่วไปที่ต้องการติดตามพัฒนาการของประเด็นข่าวเฉพาะด้านอย่างครอบคลุม

ระบบเจาะประเด็นข่าวทำงานร่วมกับสถาปัตยกรรมอ่านอย่างเดียว (Read-Only Architecture) โดยผู้ใช้สามารถสืบค้นด้วยคำสำคัญทั่วไป หรือใช้ไวยากรณ์การค้นหาขั้นสูง เช่น การใช้เครื่องหมายไปป์ (`|`) เพื่อหาคำพ้องความหมาย การใช้เครื่องหมายลบ (`-term`) เพื่อคัดกรองข่าวกีฬาหรือบันเทิงที่ไม่เกี่ยวข้องออก และการใช้เครื่องหมายคำพูดคู่ (`"..."`) สำหรับวลีเฉพาะเจาะจง พร้อมทั้งมีระบบขยายคำย่อหน่วยงานรัฐและคำพ้องความหมายภาษาไทยโดยอัตโนมัติ

ผลลัพธ์การสืบค้นจะถูกสังเคราะห์และนำเสนอในรูปแบบสถานีทำงาน (Investigation Workstation) ประกอบด้วย 4 องค์ประกอบสำคัญ ได้แก่ แถบสรุปภาพรวมและสถิติประเด็นข่าว (Issue Executive Summary), ตารางแจกแจงมุมมองและสัดส่วนการนำเสนอของแต่ละสำนักข่าว (Publisher Perspective Breakdown) เพื่อแสดงให้เห็นว่าสื่อสำนักใดให้ความสนใจในมิติใดเป็นพิเศษ, ไทม์ไลน์ความเคลื่อนไหวของประเด็นตามลำดับเวลาจริง (Chronological Evolution Timeline) และรายการการ์ดข่าวสารที่จัดกลุ่มตามประเด็นย่อย (Issue Subclusters) โดยมีระบบคัดกรองข่าวหลุดประเด็น (Outlier Filtering) ช่วยแยกบทความที่ไม่เกี่ยวข้องออกไปอย่าง

แม่นยำ พร้อมทั้งมีระบบควบคุมอัตราคำขอแบบ Sliding Window IP Rate Limiting ช่วยรักษาความมั่นคงของเซิร์ฟเวอร์

4.3.13 การรักษาเสถียรภาพระดับโพรดักชันและการตรวจสอบก่อนส่งมอบ (Production Reliability & Pre-flight Smoke Testing)

เพื่อให้การนำระบบขึ้นสู่สภาพแวดล้อมโพรดักชันบนคลาวด์ร่วมกับ Nginx, Cloudflare CDN และ PWA มีความราบรื่นและปราศจากช่วงเวลาหยุดชะงัก (Zero Downtime) ระบบได้วางกลไกการรับประกันคุณภาพและความน่าเชื่อถือทางวิศวกรรม 3 ส่วนหลัก

ส่วนแรก การขจัดปัญหาความไม่เข้ากันของแคชบนเครือข่ายส่งมอบเนื้อหา (Edge & Client Cache Invalidation) ระบบได้กำหนดนโยบาย `NoCacheStaticFiles` บน FastAPI ส่งส่วนหัว `Cache-Control` ที่ระบุ `no-cache, must-revalidate` สำหรับไฟล์สคริปต์โมดูล JavaScript ทั้งหมด และเพิ่มตัวแปรระบุเวอร์ชัน (`?v=3.3.3`) กำกับท้ายการนำเข้าโมดูลย่อย (Sub-module Imports) ทุกไฟล์ พร้อมปรับปรุงการทำงานของ Service Worker ให้ล้างแคชเก่าทิ้งทันทีเมื่อตรวจพบเวอร์ชันใหม่ ช่วยป้องกันไม่ให้เบราว์เซอร์ของผู้ใช้ค้างที่ไฟล์สคริปต์เก่าอันเป็นสาเหตุของข้อผิดพลาดหน้าเว็บขาว

ส่วนที่สอง การจัดการความเข้ากันได้ข้ามสภาพแวดล้อม (Cross-Platform Model Loading Isolation) โดยระบบได้ปรับเปลี่ยนวิธีการโหลดโมเดลตัดคำและเวกเตอร์ภาษาไทยให้อ่านโครงสร้างจากไฟล์ `tokenizer.json` ผ่านคลาส `PreTrainedTokenizerFast` โดยตรง ช่วยให้โมเดลสามารถทำงานได้อย่างเสถียรทั้งบนสภาพแวดล้อมการพัฒนา (Windows) และสภาพแวดล้อมคอนเทนเนอร์บนโพรดักชัน (Linux Docker) โดยปราศจากปัญหาความเข้ากันไม่ได้ของ SentencePiece

ส่วนที่สาม สคริปต์ทดสอบความพร้อมก่อนขึ้นโพรดักชันอัตโนมัติ (Automated Pre-flight Smoke Test Script ผ่าน `scripts/preflight_test.py`) ซึ่งทำหน้าที่ตรวจสอบเสถียรภาพของระบบก่อนการปล่อยให้ผู้ใช้ภายนอกเข้าใช้งาน ครอบคลุมการทดสอบจุดเชื่อมต่อความพร้อมของระบบจัดเก็บข้อมูล (`/readyz`), การประมวลผลเอนจินจัดอันดับเทรนด์, การจำลองผู้ใช้จริงผ่าน Headless Chromium เพื่อยืนยันว่าไม่มีข้อผิดพลาดหลุดรอดบน Console, การตรวจสอบสถานะการเชื่อมต่อ WebSocket และความพร้อมของระบบเจาะประเด็นข่าว โดยผลการทดสอบทั้งหมดผ่านเกณฑ์ความสมบูรณ์ร้อยละ 100

4.4 การออกแบบและมาตรการความมั่นคงปลอดภัยของระบบ (System Security Design)

ความมั่นคงปลอดภัยของระบบ (System Security) และการคุ้มครองความเป็นส่วนตัวของผู้ใช้งาน (Data Privacy) เป็นปัจจัยสำคัญในการพัฒนาเว็บแอปพลิเคชันยุคใหม่ โดยระบบได้ออกแบบมาตรการรักษาความปลอดภัยครอบคลุม 4 มิติหลัก ดังนี้

4.4.1 ความมั่นคงปลอดภัยระดับเครือข่ายและเว็บเซิร์ฟเวอร์ (Network & Gateway Security)

ในระดับเครือข่าย ระบบได้ติดตั้ง Nginx Reverse Proxy ทำหน้าที่เป็น Gateway จัดการเข้ารหัสช่องทางการสื่อสาร (TLS/SSL Encryption) ทั้งในรูปแบบ HTTPS และ Secure WebSocket (WSS) เพื่อป้องกันการดักฟังข้อมูลระหว่างทาง (Man-in-the-Middle Attack) พร้อมทั้งกำหนดนโยบายจำกัดอัตราการเรียกใช้งาน (API Rate Limiting) เพื่อจำกัดจำนวนคำขอต่อหมายเลข IP ช่วยป้องกันการโจมตีแบบปฏิเสธการให้บริการ (DoS) นอกจากนี้ยังได้กำหนดนโยบายการเข้าถึงข้ามโดเมน (CORS Whitelist) เฉพาะโดเมนของระบบที่

ได้รับอนุญาต และติดตั้งส่วนหัวความปลอดภัยมาตรฐาน (HTTP Security Headers) ได้แก่ `X-Content-Type-Options: nosniff`, `X-Frame-Options: SAMEORIGIN` และ `Content-Security-Policy (CSP)` เพื่อป้องกันการโจมตีแบบ Clickjacking และ MIME Confusion

4.4.2 การป้องกันการฉีดโค้ดอันตรายและการตรวจสอบข้อมูล (Data Sanitization & Injection Defense)

ในด้านการป้องกันการโจมตีเชิงความปลอดภัยและการจัดการข้อมูลอันตราย ระบบมีมาตรการป้องกันที่ครอบคลุมหลายระดับ โดยสำหรับการป้องกัน Cross-Site Scripting (XSS) ข้อมูลเนื้อหาข่าวที่สกัดได้จากเว็บต้นทางอาจมีแท็ก HTML หรือสคริปต์อันตรายแฝงมา ระบบจึงใช้กระบวนการแปลงและกรองข้อมูล (Sanitization) เพื่อกำจัดแท็ก `<script>`, `<iframe>`, รวมถึงแอตทริบิวต์ `onload`, `onerror` ออกทั้งหมด และแปลงเนื้อหาให้อยู่ในรูป Plain Markdown ก่อนส่งไปแสดงผลบนหน้าจอ In-app Modal นอกจากนี้ เพื่อป้องกันข้อผิดพลาดจาก Malformed Input และ Parameter Tampering ระบบได้บังคับใช้การตรวจสอบโครงสร้างข้อมูลเข้มงวดด้วย Pydantic (Strict Schema Validation) ในทุกจุดรับเข้าและส่งออกของ REST API

สำหรับการป้องกัน Server-Side Request Forgery (SSRF) ส่วนงาน Scraper และ Playwright Service จะรับคำขอและดึงข้อมูลเฉพาะจากรายการสำนักข่าวที่ลงทะเบียนไว้ล่วงหน้า (Source Whitelist) เท่านั้น โดยไม่อนุญาตให้ผู้ใช้ภายนอกส่ง URL เครือข่ายภายในเข้ามาประมวลผลโดยตรง และในส่วนการประมวลผลร่วมกับโมเดลภาษาขนาดใหญ่ (LLM Safety) ระบบได้ออกแบบ System Prompt และโครงสร้าง Delimiter กั้นระหว่างคำสั่งหลักกับเนื้อหาข่าวอย่างรัดกุม เพื่อป้องกันปัญหา Indirect Prompt Injection ไม่ให้ข้อความข่าวลบล้างคำสั่งเดิม (Prompt Jailbreak) ของระบบสรุปข่าวได้

4.4.3 การคุ้มครองข้อมูลส่วนบุคคลและความปลอดภัยของคุกกี้ (Privacy & Cookie Security)

การคุ้มครองความเป็นส่วนตัวของผู้ใช้งานถูกออกแบบตามหลัก Privacy by Design & Zero PII กล่าวคือ ระบบไม่มีการจัดเก็บข้อมูลส่วนบุคคลที่สามารถระบุตัวตนได้ (Personally Identifiable Information) เช่น ชื่อ ที่อยู่อีเมล หรือหมายเลขประจำเครื่อง โดยข้อมูลพฤติกรรมความสนใจของผู้ใช้จะถูกประมวลผลเป็นเพียงคะแนนรวมแบบนิรนาม (Anonymous Aggregate Engagement) บนฐานข้อมูลเท่านั้น ในระดับเบราว์เซอร์ คุกกี้ที่ใช้ในระบบมีการกำหนดคุณสมบัติความปลอดภัยเข้มงวด ได้แก่ `SameSite=Lax` และ `Path=/` เพื่อป้องกันการโจมตีแบบ Cross-Site Request Forgery (CSRF) พร้อมกำหนดอายุการหมดอายุ (Max-Age) ที่เหมาะสม ตลอดจนติดตั้งแถบแจ้งเตือนขอความยินยอมการใช้งานคุกกี้ (Cookie Consent Banner) ตามมาตรฐาน PDPA และมีฟังก์ชันให้ผู้ใช้สามารถกดล้างสถิติพฤติกรรม (Clear Preference Data) บนเบราว์เซอร์ได้ด้วยตนเองตลอดเวลา

4.4.4 การจัดการความลับและการตั้งค่าระบบ (Secrets & Configuration Management)

API Key สำหรับเชื่อมต่อกับบริการภายนอก เช่น `LLM_API` ของ KKU Gen.AI และการตั้งค่าระบบต่าง ๆ ถูกจัดเก็บไว้ในไฟล์ `.env` และ Environment Variables ที่แยกต่างหาก โดยมีไฟล์ `.gitignore` ป้องกันการนำความลับของระบบขึ้นสู่ระบบควบคุมเวอร์ชัน (Git Repository) อย่างเข้มงวด

4.5 การทดสอบระบบ

การรับประกันคุณภาพและความน่าเชื่อถือของระบบ (Quality Assurance & Reliability) เป็นหัวใจสำคัญในการพัฒนาระบบรวบรวมและวิเคราะห์ข่าวสารอัตโนมัติ ซึ่งต้องทำงานต่อเนื่องตลอดเวลา (24/7 Continuous Operation) และประมวลผลข้อมูลจากภายนอกที่มีความผันผวนสูง โครงงานนี้จึงประยุกต์ใช้ระเบียบวิธีพัฒนาที่

ขับเคลื่อนด้วยการทดสอบ (Test-Driven Development: TDD) และสร้างชุดทดสอบอัตโนมัติที่ครอบคลุมการทำงานทุกระดับตั้งแต่การทดสอบระดับหน่วย (Unit Testing) การทดสอบการทำงานร่วมกัน (Integration Testing) การทดสอบกรณีสุดขั้วและสภาวะวิกฤต (Adversarial & Stress Testing) การทดสอบการประมวลผลพร้อมกัน (Concurrency Testing) และการทดสอบความมั่นคงปลอดภัยตามมาตรฐาน PDPA รวมทั้งสิ้น 423 กรณีทดสอบ (423 Test Cases) ครอบคลุม 39 โมดูลทดสอบบนเฟรมเวิร์ค `pytest` โดยมีผลการทดสอบผ่านสมบูรณ์ครบทั้ง 423 กรณีทดสอบ (คิดเป็นร้อยละ 100)

4.5.1 โครงสร้างและสถิติชุดทดสอบอัตโนมัติ (Automated Test Suite Structure & Statistics)

ชุดทดสอบอัตโนมัติของระบบสามารถจำแนกออกเป็น 6 มิติหลักตามขอบเขตการทำงานของสถาปัตยกรรม ดังแสดงในตารางที่ 15

ตารางที่ 15 การกระจายตัวของชุดทดสอบอัตโนมัติทั้ง 6 กลุ่มหลัก (จำนวนรวม 423 กรณีทดสอบ)

กลุ่มที่	มิติการทดสอบ	ขอบเขตและโมดูลทดสอบสำคัญ	จำนวน (ข้อ)	ผลการทดสอบ
1	การประมวลผลภาษาและการจำแนกหมวดหมู่	การตัดคำภาษาไทย, การแปลงและระงับชื่อจังหวัด (`thai_normalizer`), การจำแนก 9 หมวดหมู่ (`classifier_service`) และเวกเตอร์หนาแน่น (`wangchan_embedding`)	51	ผ่าน (100%)
2	การระบุประเด็นข่าวและวงรอบชีวิต	เกณฑ์ตัดสินใจ Two-Band, การยืนยันเอนทิตี (`story_service`), การคัดกรองมหากาพย์ P0–P2 (`macro_p0_p2_invariants`), Centroid EMA, การจัดเก็บประเด็นข่าว (`story_repo`) และการทดสอบโหลดหนัก (`layer1_stress`)	76	ผ่าน (100%)
3	เอนจินจัดอันดับกระแสและความคงทนทางสถิติ	สัญญาณคะแนน 6 มิติ, คุณสมบัติ Zero-LLM, การลดทอนข่าวประจำวัน (`trending_deterministic`) และการทดสอบกรณีสุดขั้ว (`adversarial`)	59	ผ่าน (100%)
4	การสังเคราะห์นำเสนอ มหากาพย์ข่าว และประเด็นเฉพาะทาง	การสรุปประเด็นรวม (`story_presentation`), มหากาพย์ข่าว (`macro_events`), แฟ้มหลักฐานเหตุการณ์ (`event_evidence`), การนำเสนอข่าวกีฬา (`sports_presentation`), การคัดกรองความเกี่ยวข้อง (`relevance_enforcement`) และศูนย์ควบคุมสถานะ (`monitoring`)	68	ผ่าน (100%)
5	สถาปัตยกรรมแคช ฐานข้อมูล ความปลอดภัย PDPA และการเจาะประเด็น	แคชหน่วยความจำและ HTTP 304 (`caching`, `http_cache`), การป้องกัน Cache Stampede (`summary_cache`), ฐานข้อมูล SQLite WAL และ PDPA (`storage_pdpa`), ไคลเอนต์สำรอง (`cascading_client`), แคชแบบลำดับชั้น (`tiered_cache`) และระบบเจาะประเด็นข่าว (`issue_explorer`)	136	ผ่าน (100%)

4.5.2 การทดสอบคุณสมบัติคงที่ทางวิศวกรรมและกรณีสุดขั้ว (In-Depth Technical Testing Methodologies)

เพื่อให้มั่นใจว่าระบบมีเสถียรภาพภายใต้สภาวะการทำงานจริงที่มีความซับซ้อน ชุดทดสอบได้ออกแบบกรณีทดสอบครอบคลุมคุณสมบัติคงที่ทางวิศวกรรม (Engineering Invariants) และสภาวะสุดขั้วใน 9 ด้านหลัก

ประการแรก การทดสอบความแม่นยำในการระบุประเด็นข่าวมหากาพย์และคุณสมบัติคงที่ P0–P2 (Stage B Macro Invariants & Province Veto) ได้รับการตรวจสอบอย่างเข้มงวดผ่าน `test_macro_p0_p2_invariants.py` ซึ่งครอบคลุมการทดสอบกฎยับยั้งการรวมกลุ่มเมื่อตรงกันเฉพาะชื่อจังหวัด (Province-Only Veto), การรักษาป้ายกำกับ Typed NER โดยไม่โยน Unknown Entity เป็น Actor, ทิศทางความสัมพันธ์เชิงเวลาที่เหตุการณ์ก่อนหน้าต้องชี้ไปยังเหตุการณ์ถัดไป (`precedes`), การรับประกันความสอดคล้องของการจัดเก็บข้อมูลข้ามโพรเซสผ่าน `InterProcessFileLock` ร่วมกับ `model_copy(deep=True)`, และการทดสอบขอบเขตเวลาแกนเรื่องราว (`episode_key`) ไม่ให้เกิดการเชื่อมโยงข้ามฤดูกาล

ประการที่สอง การทดสอบการคงทนของเวกเตอร์ศูนย์กลาง (Story Identification & Centroid EMA Invariants) ได้รับการตรวจสอบผ่าน `test_story_service.py` โดยทดสอบว่าบทความข่าวที่มีค่าความคล้ายคลึงโคไซน์ $\cos \geq 0.85$ จะต้องถูกรวมเข้ากลุ่มประเด็นข่าวเดิมเสมอ (Direct Merge) แม้ไม่มีเอนทิตีร่วมกัน ในขณะที่บทความในแถบก้ำกึ่ง $0.74 \leq \cos < 0.85$ จะถูกรวมก็ต่อเมื่อตรวจพบเอนทิตีบุคคล สถานที่ หรือองค์กรตรงกันอย่างน้อย 1 รายการ (Confirmed Merge) และหาก $\cos < 0.74$ ระบบจะต้องสร้างกลุ่มข่าวใหม่เสมอ แม้ว่าจะมีเอนทิตีร่วมกัน เพื่อป้องกันการรั่วไหลของคำศัพท์ที่ไม่เกี่ยวข้อง นอกจากนี้ การทดสอบคณิตศาสตร์ของ Centroid EMA ($\alpha = 0.85$) ยืนยันว่าจุดศูนย์กลางของกลุ่มข่าวสามารถรักษาสมดุลของแกนเรื่องเดิมได้อย่างมั่นคง ไม่เกิดการเบี่ยงเบนของความหมาย (Semantic Drift) แม้มีข่าวเข้ามาเสริมต่อเนื่องข้ามสัปดาห์ (`test_long_running_storyline.py`) พร้อมทดสอบการสลับสถานะของประเด็นข่าวระหว่าง Active และ Dormant และการฟื้นคืนสถานะโดยคงรหัส `story_id` เดิมอย่างคงเส้นคงวา (Idempotent Reactivation)

ประการที่สอง การทดสอบคุณสมบัติคงที่ของเอนจินจัดอันดับความนิยมแบบดีเทอร์มินิสติก (Deterministic Trending & Adversarial Invariants) ตรวจสอบผ่าน `test_trending_deterministic.py` และ `test_adversarial_layer2_layer3.py` โดยมีคุณสมบัติสำคัญที่ต้องผ่านการทดสอบ 3 ประการ คือ คุณสมบัติปลอดการเรียกใช้โมเดลภาษาขนาดใหญ่ (Zero LLM Invariant) ที่ยืนยันว่าไม่มีการเรียกใช้บริการภายนอกหรือ LLM ในกระบวนการคำนวณคะแนน ทำให้ความเร็วในการจัดอันดับคงที่ในระดับมิลลิวินาทีเสมอ คุณสมบัติความแน่นอนเชิงคณิตศาสตร์ (Strictly Deterministic Across Repeated Runs) ที่ทดสอบการคำนวณคะแนนซ้ำบนชุดข้อมูลข่าว 1,000 ข่าวแล้วได้คะแนนและลำดับเหมือนเดิมทุกประการร้อยละ 100 และการทดสอบกลไกลดทอนข่าวประจำวัน (Routine News Dampening) ที่ยืนยันว่ารายงานสภาพอากาศและผลสลากกินแบ่งรัฐบาลจะถูกคูณลดทอนคะแนนลงเหลือ 0.25 เท่าเสมอ เพื่อป้องกันไม่ให้ข่าวประจำวันบดบังข่าวด่วนที่สำคัญ นอกจากนี้ `test_trending_challenger_stress.py` ยังทดสอบการจัดการกับเวลา

ในอนาคต (Future Timestamp Clamping) และเวลาในอดีตลึกเกิน 100 วัน (Underflow Safety) เพื่อความปลอดภัยทางคณิตศาสตร์

ประการที่สาม การทดสอบการประมวลผลพร้อมกันและการป้องกันภาวะตื่นตระหนกของแคช (Concurrency & Cache Stampede Protection) ตรวจสอบผ่าน `test_summary_cache.py` และ `test_sqlite_news_repo.py` โดยระบบได้จำลองสถานการณ์ที่มีผู้ใช้งานส่งคำขอสรุปข่าวบทความเดียวกันเข้ามาพร้อมกัน 100 คำขอในเสี้ยววินาทีเดียวกัน กลไก Single-Flight Mutex Locking จะอนุญาตให้คำขอแรกเพียงคำขอเดียวส่งต่อไปยัง KKU Gen.AI API ในขณะที่อีก 99 คำขอจะรอรับผลลัพธ์จากแคชเดียวกัน ช่วยป้องกันไม่ให้โควตา API ถูกใช้สิ้นเปลืองและป้องกันการล่มของระบบเซิร์ฟเวอร์ และสำหรับการบันทึกข้อมูลแบบหลายเธรดใน SQLite โหมด Write-Ahead Logging (WAL) ได้รับการทดสอบการอ่านและเขียนพร้อมกันจำนวนมหาศาลโดยไม่เกิดข้อผิดพลาดฐานข้อมูลถูกล็อก (Database Locked Error)

ประการที่สี่ การทดสอบความมั่นคงปลอดภัยและการคุ้มครองข้อมูลส่วนบุคคล (Zero-PII Compliance & PDPA Testing) ตรวจสอบผ่าน `test_storage_pdpa.py` โดยทำการตรวจสอบยืนยันเชิงลึก (Deep Structural Assertion) ว่าในฐานข้อมูลไม่มีการบันทึกหมายเลขที่อยู่ไอพี (IP Address) ข้อมูล User Agent ข้อมูลตำแหน่งพิกัดทางภูมิศาสตร์ หรือชื่อบุคคลของผู้ใช้งานแม้แต่จุดเดียว โดยข้อมูลพฤติกรรมความสนใจจะถูกบันทึกเป็นเพียงตัวเลขคะแนนรวมแบบนิรนาม (Anonymous Aggregate Engagement) เท่านั้น ตลอดจนทดสอบฟังก์ชันการล้างข้อมูลประวัติบนเบราว์เซอร์ (Clear Data Feature) ว่าสามารถคืนสถานะความเป็นส่วนตัวของผู้ใช้ได้อย่างสมบูรณ์

ประการที่ห้า การทดสอบชุดประเมินผลเชิงประจักษ์ (Evaluation Harness Testing) ตรวจสอบผ่าน `test_evaluation_harness.py` โดยทดสอบความถูกต้องของกระบวนการคำนวณเมตริก B-cubed Precision, B-cubed Recall, B-cubed F1-score และ Pairwise Metrics กับข้อมูลข่าวจริง 111 ข่าว และ 59 เหตุการณ์อ้างอิง เพื่อให้มั่นใจว่าเครื่องมือวัดผลทางสถิติของระบบทำงานได้อย่างถูกต้อง แม่นยำ และสอดคล้องกับระเบียบวิธีวิจัยมาตรฐานสากล

ประการที่หก การทดสอบแบบจำลองหลักฐานเชิงเหตุการณ์และการตรวจจับข่าวไม่เกี่ยวข้อง (Event Evidence Intelligence & Outlier Detection Testing) ตรวจสอบผ่าน `test_event_evidence.py` โดยทดสอบ 3 มิติสำคัญ ได้แก่ การทดสอบกลไกสำรองการประมวลผลเชิงศึกษาหลักฐาน (Heuristic Corroboration Fallback) ที่จำลองกรณีไม่มีการเชื่อมต่อกับโมเดลภาษาขนาดใหญ่ โดยระบบจะต้องสกัดพัฒนาการเหตุการณ์ตามลำดับเวลาและระบุแหล่งข่าวที่ยืนยันตรงกันได้อย่างครบถ้วนสมบูรณ์โดยมีความหน่วงเวลา 0 มิลลิวินาที การทดสอบความถูกต้องของการสกัดโครงสร้างข้ออ้าง (Claim-Level Evidence Parsing) จากเนื้อหาข่าวจริงที่สามารถจำแนกหมวดหมู่ข้ออ้างและระบุรหัส `article_id` อ้างอิงได้อย่างถูกต้อง และการทดสอบระบบแคชลายนิ้วมือ SHA-256 (Fingerprint Caching) ที่รับประกันความแน่นอนเชิงผลลัพธ์ (Deterministic Replay) และป้องกันการสิ้นเปลืองโควตาการประมวลผลซ้ำ

ประการที่เจ็ด การทดสอบระบบสืบค้นเจาะประเด็นข่าวแบบอ่านอย่างเดียวและความมั่นคงปลอดภัยของตัวแยกวิเคราะห์ (Issue Explorer Read-Only & Query Safety Invariants) ตรวจสอบผ่าน `test_issue_explorer.py` (TC-08 ถึง TC-13) โดยมีคุณสมบัติสำคัญที่ต้องผ่านการทดสอบ ได้แก่ การทดสอบความถูกต้องและปลอดภัยของตัวแยกวิเคราะห์คำค้นหา (Query Parser) ที่รองรับตรรกะ AND, OR,

NOT และวลีเฉพาะเจาะจงพร้อมทั้งหลบอักขระพิเศษเพื่อป้องกันการโจมตี SQL Injection การทดสอบการันตีโหมดอ่านอย่างเดียว (Read-Only Mode Invariant ผ่าน `mode=ro`) ที่รับประกันว่าการสืบค้นข้อมูลเชิงวิเคราะห์จะไม่มีคำสั่งเขียนหรือเปลี่ยนแปลงข้อมูลในฐานข้อมูล SQLite ข่าวหลัก การทดสอบความคงทนของการรวมกลุ่มประเด็นย่อยและการคัดกรองข่าวหลุดประเด็น (Outlier Filtering Regression) ตลอดจนการทดสอบการควบคุมอัตราคำขอ (Rate Limiting) และสวิตช์ตัดการทำงานฉุกเฉิน (Kill Switch Contract)

ประการที่แปด การทดสอบความสอดคล้องของแคชระดับโพรดักชันและการตรวจสอบก่อนส่งมอบ (Production Cache Consistency & Pre-flight Invariants) ตรวจสอบผ่าน `scripts/preflight_test.py` และ `test_layer4_stress.py` เพื่อรับประกันว่าไม่มีการรั่วไหลของไฟล์สคริปต์รุ่นเก่าบน Edge Cache ของ Cloudflare CDN และ Service Worker โดยตรวจสอบว่าทุกคำขอสำหรับไฟล์สคริปต์คงที่ได้รับส่วนหัว `Cache-Control` ที่ระบุ `no-cache, must-revalidate` เสมอ พร้อมทั้งทดสอบผ่าน Headless Browser อัตโนมัติว่าไม่มีข้อผิดพลาดหลุดรอดบนหน้าจอ (Zero Console Error) และสัญญาณการเชื่อมต่อแบบเรียลไทม์เปลี่ยนสถานะเป็น LIVE อย่างสมบูรณ์ก่อนการปล่อยระบบขึ้นสู่สภาพแวดล้อมจริง

4.5.3 ผลการทดสอบการยอมรับของผู้ใช้ (User Acceptance Testing)

ผลการทดสอบระบบตามความต้องการเชิงฟังก์ชันแสดงดังตารางที่ 16

ตารางที่ 16 ผลการทดสอบระบบตามกรณีทดสอบ (User Acceptance Testing)

TC	รายการทดสอบ	ผลที่คาดหวัง	ผล
TC-01	การดึงข่าวอัตโนมัติจากหลายแหล่ง	ดึงหัวข้อ ลิงก์ รูปภาพ และเนื้อหาได้ครบถ้วน	ผ่าน
TC-02	การจำแนกหมวดหมู่ภาษาไทย 9 หมวด	จัดหมวดหมู่ข่าวได้อย่างถูกต้องตามเนื้อหา	ผ่าน
TC-03	การสรุปเนื้อหาข่าวและ Sentiment	ได้บทสรุป ประเด็นสำคัญ และ Sentiment	ผ่าน
TC-04	การแจ้งเตือนข่าวใหม่ผ่าน WebSocket	ข่าวใหม่ปรากฏบนหน้าจอทันทีโดยไม่ต้องรีเฟรช	ผ่าน
TC-05	การบันทึกความสนใจและแนะนำข่าว	แสดงแถบข่าว Trending ตามค่า Engagement	ผ่าน
TC-06	การอ่านข่าวในตัวเว็บ (In-app Reader)	เปิดอ่านบทความฉบับเต็มใน Modal ได้อย่างราบรื่น	ผ่าน
TC-07	การจัดกลุ่มประเด็นข่าวแบบสองชั้น	รวมข่าวเหตุการณ์เดียวกันข้ามวันและลดปัญหาข่าวแตกกลุ่ม	ผ่าน
TC-08	การจัดอันดับความนิยมแบบดีเทอร์มินิสติก	คำนวณคะแนนโปร่งใส ไร้ LLM ในการให้คะแนน และลดทอนข่าวประจำวัน	ผ่าน
TC-09	การจัดกลุ่มมหากาพย์ข่าวและ Bento Hub	แสดงมุมมอง 3 มิติ เชื่อมโยงไทม์ไลน์ และกรองข่าวตามสำนักพิมพ์	ผ่าน
TC-10	การบันทึกข้อมูลแบบหลายเอนจิน	สลับใช้งาน SQLite WAL และ MongoDB ได้อย่างมีเสถียรภาพ	ผ่าน
TC-11	การสกัดหลักฐานและแฟ้มวิเคราะห์ความคืบหน้า 4 มิติ	สกัด Claims, จัดกลุ่ม 4 มิติ, แจ้งเตือน Outlier และคลิกตรวจหลักฐานย้อนกลับได้	ผ่าน
TC-12	การเจาะประเด็นข่าวและการสืบค้นแบบบูลีน	สืบค้นด้วยไวยากรณ์บูลีน ขยายคำย่อ สกัดมุมมองสำนักข่าว และกรองข่าวหลุดประเด็น	ผ่าน
TC-13	การป้องกัน Stale Cache และตรวจความพร้อมโพรดักชัน	Pre-flight Smoke Test ตรวจสอบ Readyz, Trending, Zero Console Error และ WebSocket LIVE	ผ่าน

บทที่ 5
บทสรุป

5.1 สรุปผลการดำเนินโครงงาน

โครงงาน “ระบบจำแนกและวิเคราะห์ข่าวสารอัตโนมัติด้วยเทคนิคการประมวลผลภาษาธรรมชาติแบบเฉพาะประเภท” ได้ดำเนินการพัฒนาเสร็จสิ้นตามขอบเขตและข้อกำหนดที่วางไว้ โดยสามารถรวบรวมข่าวสารจากหลากหลายแหล่ง สรุปเนื้อหาและวิเคราะห์อารมณ์ของข่าวด้วย Large Language Model (KKU Gen.AI) จำแนกหมวดหมู่ข่าวภาษาไทยด้วยเทคนิค Thai NLP ระบุและจัดกลุ่มประเด็นข่าวต่อเนื่องด้วยสถาปัตยกรรมสองชั้น (Two-Layer Story Identification) จัดอันดับกระแสความนิยมด้วยเอนจินแบบดีเทอร์มินิสติก (Deterministic Multi-Signal Trending Engine) ไร้การพึ่งพา LLM ในลูปการให้คะแนน เชื่อมโยงมหากาพย์ประเด็นข่าว (Macro Storyline) พร้อมระบบจัดเก็บข้อมูลแบบหลายเอนจิน (Multi-Engine Persistence) ทั้ง SQLite WAL และ MongoDB และแสดงผลแบบเรียลไทม์ผ่าน WebSocket บนหน้าจอ Bento Hub ผลการดำเนินงานสรุปเปรียบเทียบกับวัตถุประสงค์ได้ดังตารางที่ 17

ตารางที่ 17 สรุปผลการดำเนินงานเทียบกับวัตถุประสงค์

ข้อ	วัตถุประสงค์	ผลการดำเนินงานที่ได้	สถานะ
1	เพื่อศึกษาและวิเคราะห์เทคนิคการดึงข้อมูลข่าวด้วย Web Scraping, RSS Feed และเทคนิค Thai NLP	ศึกษาและประยุกต์ใช้ Playwright สำหรับ JavaScript-rendered sites, BeautifulSoup สำหรับ HTML parsing, PyThaiNLP สำหรับการตัดคำและสกัดเอนทิตี (thainer-v2) และ WangchanBERTa สำหรับการแปลงข้อความเป็นเวกเตอร์หนาแน่น	บรรลุ
2	เพื่อออกแบบและพัฒนาระบบรวบรวม สรุป และวิเคราะห์ข่าวสารแบบ End-to-End Pipeline	พัฒนาสถาปัตยกรรมแบบแยกสองชั้น (Layer 1 Online Persistent Story Identification และ Layer 2 Deterministic Trending Engine), สถาปัตยกรรม Clean Architecture รองรับ Multi-Engine Persistence (JSON, SQLite WAL, MongoDB), ระบบ Real-time WebSocket และหน้าจอ Bento Hub ได้อย่างสมบูรณ์	บรรลุ
3	เพื่อทดสอบและประเมินประสิทธิภาพของระบบในด้านความถูกต้องและความรวดเร็ว	ผ่านการทดสอบ UAT ครบทั้ง 10 กรณีทดสอบ, ผ่านชุดทดสอบอัตโนมัติครบถ้วนทั้ง 372 กรณีทดสอบ (คิดเป็นร้อยละ 100), บรรลุผลประเมินการจัดกลุ่มประเด็นข่าวด้วย B-cubed F1-score เท่ากับ 0.7911 ซึ่งลดปัญหาข่าวแตกกลุ่มลงได้ร้อยละ 24 และตอบสนองคำขอผ่านระบบแคชได้ในเวลาเฉลี่ยต่ำกว่า 150 มิลลิวินาที	บรรลุ

จากตารางที่ 17 การดำเนินโครงงานบรรลุวัตถุประสงค์ที่ตั้งไว้ครบทั้ง 3 ข้อ

5.2 ข้อจำกัดของระบบ

5.2.1 ข้อจำกัดด้านแหล่งข้อมูลภายนอกและบริการโมเดลภาษาขนาดใหญ่

ข้อจำกัดประการแรกสืบเนื่องมาจากโครงสร้างหน้าเว็บของสำนักข่าวต้นทางอาจมีการปรับเปลี่ยนโครงสร้าง DOM (DOM Mutation) ซึ่งส่งผลให้โมดูลแยกวิเคราะห์ (Parser) ต้องได้รับการปรับปรุงให้สอดคล้อง

กับโครงสร้างหน้าเว็บใหม่อย่างต่อเนื่อง นอกจากนี้ การสังเคราะห์เนื้อหาและบทสรุปข่าวยังพึ่งพาการเชื่อมต่อกับบริการ API ภายนอก ได้แก่ KKU Gen.AI ซึ่งในกรณีที่เกิดปัญหาความล่าช้าบนเครือข่ายหรือโควตาการเรียกใช้งานหมดลง ระบบต้องปรับเปลี่ยนการทำงานเข้าสู่โหมดการแสดงผลข้อความสรุปสำรองอัตโนมัติ (Heuristic Fallback) โดยใช้พาดหัวข่าวตัวแทนหลักแทน

5.2.2 ข้อจำกัดด้านทรัพยากรการประมวลผล

ในมิติด้านทรัพยากรระบบ การเปิดใช้งาน Playwright Headless Browser เพื่อสกัดข้อมูลจากเว็บไซต์ข่าวสารที่มีระบบป้องกันบอตหรือใช้การแสดงผลฝั่งไคลเอนต์ จำเป็นต้องใช้ทรัพยากรหน่วยความจำหลักและรอบการประมวลผลของ CPU สูงกว่าการดึงข้อมูลผ่านโพรโทคอล HTTP REST API ปกติ นอกจากนี้ การประมวลผลโมเดลภาษา WangchanBERTa เพื่อสร้างเวกเตอร์หนาแน่น 768 มิติบนเครื่องคอมพิวเตอร์แม่ข่ายที่ไม่มีหน่วยประมวลผลกราฟิก (GPU) อาจใช้ระยะเวลาในการประมวลผลบทความยาวเพิ่มขึ้นเล็กน้อย

5.2.3 ข้อจำกัดด้านการรู้จำชื่อเฉพาะในบริบทภาษาไทย

โมเดลการรู้จำชื่อเฉพาะ (Named Entity Recognition: NER) อิงตามคลังศัพท์และชุดข้อมูลที่ผ่านการฝึกฝนมาล่วงหน้าของ `thainer-v2` ส่งผลให้กรณีที่มีชื่อบุคคล สถานที่ หรือศัพท์สแลงเกิดใหม่ในกระแสข่าวสารปัจจุบัน โมเดลอาจไม่สามารถสกัดเอนทิตีดังกล่าวได้อย่างสมบูรณ์ ซึ่งส่งผลต่อคะแนนความคล้ายคลึงของเอนทิตีในแถบความคล้ายคลึงระดับกลาง (Ambiguity Band) เล็กน้อย

5.3 ปัญหา อุปสรรค และแนวทางแก้ไข

ปัญหาที่พบในระหว่างการพัฒนาและแนวทางที่ใช้แก้ไขแสดงดังตารางที่ 18

ตารางที่ 18 ปัญหา อุปสรรค และแนวทางการแก้ไข

ลำดับ	ปัญหาที่พบ	แนวทางแก้ไข
1	บางเว็บไซต์ข่าวมีระบบป้องกันบอต (Cloudflare/Bot detection) ทำให้ไม่สามารถดึงข้อมูลผ่าน HTTP Client ธรรมดาได้	ใช้ Playwright Browser ควบคุมเบราว์เซอร์จริงในการเรนเดอร์หน้าเว็บและจัดการ Cookie Session
2	ค่าหน่วงเวลาและโควตาจำกัดของ LLM API ทำให้ระบบโหลดช้าและไม่สามารถใช้จัดอันดับได้	ออกแบบสถาปัตยกรรมแยกสองชั้น โดยใช้ Deterministic Trending Engine ไร้ LLM ในการให้คะแนน และใช้ Presentation Cache ร่วมกับ Heuristic Fallback สำหรับการนำเสนอ
3	ข่าวสารภาษาไทยไม่มีการเว้นวรรคระหว่างคำ และมีความคลาดเคลื่อนในการจับคู่เอนทิตี	ใช้ PyThaiNLP ในการตัดคำแบบพจนานุกรมและคัดกรอง Stop words ร่วมกับโมเดล thainer-v2 สกัดเอนทิตี และ WangchanBERTa แปลงข้อความเป็นเวกเตอร์
4	ปัญหาข่าวเรื่องเดียวกันแตกกระจายเป็นหลายกลุ่ม (Story Fragmentation) ข้ามวัน	พัฒนาระบบ Persistent Story Identification ด้วยหน้าต่างเลื่อน 72 ชั่วโมง การเปรียบเทียบความคล้ายคลึงแบบ Two-Band และการปรับ Centroid EMA
5	ข่าวประจำวัน (Routine News) เช่น พยากรณ์อากาศหรือราคาน้ำมัน ได้คะแนนความนิยมสูงเกินจริง	ติดตั้งกลไก Routine News Dampening ลดทอนคะแนนลงเหลือ 0.25 เท่า เพื่อเปิดทางให้ข่าวด่วนและประเด็นสำคัญ
6	คอขวดด้านประสิทธิภาพและการเขียนข้อมูลพร้อมกัน (Concurrency Bottlenecks) บน File Repository	พัฒนา Multi-Engine Persistence โดยรองรับทั้ง SQLite3 Write-Ahead Logging (WAL) และ MongoDB

5.4 ข้อเสนอแนะในการพัฒนาต่อไป

5.4.1 การปรับปรุงฟังก์ชันการทำงาน

สำหรับการพัฒนาฟังก์ชันการทำงานในระยะต่อไป ระบบสามารถขยายขีดความสามารถได้หลายด้าน ประการแรกคือการพัฒนาระบบตรวจสอบความสอดคล้องของข้อเท็จจริงข้ามสำนักข่าว (Cross-Source Fact Consistency Checking) เพื่อเปรียบเทียบความแตกต่างของตัวเลข สถิติ หรือแถลงการณ์ระหว่างสำนักข่าว และแจ้งเตือนจุดที่ข้อมูลขัดแย้งกันให้แก่ผู้อ่าน ประการถัดมาคือการพัฒนาระบบแจ้งเตือนข่าวด่วนเฉพาะบุคคลและการ

จัดทำจดหมายข่าวสรุปประจำวัน (Personalized Notifications & Automated Daily Digest) โดยส่งสรุปประเด็นข่าวที่ผู้ใช้ให้ความสนใจผ่านทางอีเมลหรือเว็บแอปพลิเคชัน และประการสุดท้ายคือการขยายขีดความสามารถเพื่อรองรับข้อมูลข่าวสารแบบมัลติมีเดีย (Multi-Modal News Ingestion) เช่น การแปลงเสียงในคลิปรายงานข่าวเป็นข้อความ (Speech-to-Text) เพื่อนำมาประมวลผลร่วมกับข่าวบทความ

5.4.2 การยกระดับสถาปัตยกรรมระบบสืบค้นข่าวสารแบบไฮบริด (Hybrid Search Architecture)

จากการประเมินประสิทธิภาพการสืบค้นข่าวสารในสถานการณ์จริง คณะผู้พัฒนาขอเสนอแนะสถาปัตยกรรมที่เหมาะสมที่สุดสำหรับการสืบค้นข่าวสารภาษาไทยแบบผสมผสาน (Optimal Hybrid News Search Pipeline) เพื่อแก้ไขข้อจำกัดด้านความไม่สอดคล้องของคำศัพท์ (Vocabulary Mismatch) และความคลุมเครือของชื่อเฉพาะในภาษาไทย โดยแบ่งกระบวนการทำงานออกเป็น 2 ขั้นตอนหลัก ได้แก่

1) **การเตรียมข้อมูลล่วงหน้า (Offline Preparation)**

: การสร้างและปรับปรุงคลังแผนที่คำพ้องและนามแฝงเฉพาะทาง (Custom Aliases and Synonym Map) โดยมุ่งเน้นคำเฉพาะทางในแวดวงข่าวสารภาษาไทย ได้แก่ ฉายาและชื่อย่อตำแหน่งข้าราชการระดับสูง (เช่น “ผบ.ตร.”, “ปลัด มท.”, “บิ๊กป้อม”) พรรคการเมือง (เช่น “พท.”, “ปชน.”, “ภท.”) และองค์กรอิสระหรือหน่วยงานภาครัฐ (เช่น “สตง.”, “ป.ป.ช.”, “กกต.”, “ก.ล.ต.”) เพื่อให้ระบบเข้าใจความหมายที่ตรงกันโดยไม่ต้องพึ่งพาพจนานุกรมภาษาสากลเพียงอย่างเดียว

2) **การประมวลผลคำค้นหาในเวลาจริง (Online Query Time)**

: ดำเนินการสืบค้นแบบขนานสองแกน (Two-Pronged Hybrid Retrieval) ได้แก่

a) **การสืบค้นเชิงคำศัพท์ (Lexical Search - BM25 with Query Expansion)**

: ทำการขยายคำค้นหาของผู้ใช้ด้วย Custom Synonym Map แล้วสืบค้นด้วยอัลกอริทึม BM25 บนดัชนีเนื้อหาข่าว เพื่อการันตีความแม่นยำสูง (High Precision) สำหรับชื่อเฉพาะ (Named Entities) ตัวย่อหน่วยงาน และคีย์เวิร์ดตายตัว

b) **การสืบค้นเชิงความหมาย (Dense Vector Search)**

: แปลงคำค้นหาเป็นเวกเตอร์หนาแน่น (Dense Embedding) ผ่านโมเดลภาษา (เช่น WangchanBERTa) เพื่อค้นหาความใกล้เคียงในมิติความหมาย ช่วยดึงดูดข่าวที่มีบริบทแวดล้อมเกี่ยวโยงกัน แม้จะไม่ปรากฏคำค้นหาตรงตัวก็ตาม ซึ่งช่วยเพิ่มความครอบคลุมของเนื้อหา (High Recall)

หลังจากนั้น นำผลลัพธ์จากทั้งสองกระบวนการมารวมอันดับ (Rank Fusion) ด้วยวิธี Reciprocal Rank Fusion (RRF) เพื่อรวมลำดับอย่างเป็นกลางโดยไม่ต้องปรับสเกลคะแนนดิบ หรือส่งต่อให้ Cross-Encoder Reranker ทำการคำนวณปฏิสัมพันธ์เชิงลึกระหว่างคำค้นหาและเนื้อหาข่าว ทำให้ได้ผลลัพธ์การสืบค้นที่มีทั้งความแม่นยำของชื่อเฉพาะ (Precision) และความครอบคลุมของบริบทที่เกี่ยวโยงกัน (Recall) ในระดับสูงสุดสำหรับการค้นหาข่าวจริง

5.4.3 แนวทางการวิจัยต่อยอด

ในเชิงการวิจัยต่อยอด คณะผู้พัฒนาเล็งเห็นแนวทางสำคัญ 2 ประการ ประการแรกคือการวิจัยเพื่อปรับแต่งค่าไฮเปอร์พารามิเตอร์แบบพลวัต (Dynamic Hyperparameter Optimization) สำหรับอัตราการสลาย

ตัวของเวลา (τ) และน้ำหนักของ Centroid EMA (α) ตามความเร็วเฉลี่ยของการนำเสนอข่าวในแต่ละหมวดหมู่ โดยใช้เทคนิคการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) หรือ Bayesian Optimization เพื่อให้สอดคล้องกับพฤติกรรมข่าวที่เปลี่ยนไปตามกาลเวลา และประการที่สองคือการวิจัยโมเดลจำแนกอคติและจุดยืนของสำนักข่าว (Media Bias & Stance Detection) เพื่อวิเคราะห์ความสมดุลและความเป็นกลางในการนำเสนอข่าวของสำนักข่าวต่าง ๆ ในประเทศไทยอย่างเป็นวิทยาศาสตร์

เอกสารอ้างอิง

1. Barbaresi, A. (2021). Trafilatura: A Web Scraping Library and Command-Line Tool for Text Discovery and Extraction. In H. Ji, J. C. Park, & R. Xia (Eds.). **Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations**. (pp. 122-131). Online: Association for Computational Linguistics. Retrieved from https://aclanthology.org/2021.acl-demo.15/
2. Winer, D. (2009). RSS 2.0 Specification. Accessed: 2025-01-10. Retrieved from https://www.rssboard.org/rss-specification
3. Allahyari, M., Pouriyeh, S., Assefi, M., Safaei, S., Trippe, E. D., Gutierrez, J. B., et al. (2017). Text Summarization Techniques: A Brief Survey. *arXiv preprint arXiv:1707.02268*.
4. Team, G. D. G. (2024). Gemini: A Family of Highly Capable Multimodal Models. *arXiv preprint arXiv:2312.11805*.
5. Lowphansirikul, L., Polpanumas, C., Jantrakulchai, N., & Nutanong, S. (2021). WangchanBERTa: Pretrained Language Model for Thai Language. *arXiv preprint arXiv:2101.09635*.
6. Phatthiyaphaibun, W., Chaovavanich, K., et al. (2021). PyThaiNLP: Thai Natural Language Processing in Python Framework. Accessed: 2025-01-10. Retrieved from https://doi.org/10.5281/zenodo.3519354
7. Salihefendic, A. (2010). How Reddit Ranking Algorithms Work. Accessed: 2025-01-15. Retrieved from https://amix.dk/blog/post/19588
8. Swartz, A. (2005). Rewriting Reddit: Web Development and Architecture. Accessed: 2025-01-15. Retrieved from https://aaronsw.com/weblog/001716
9. Graham, P. (2009). What I've Learned from Hacker News: Ranking and Community Dynamics. Accessed: 2025-01-15. Retrieved from http://www.paulgraham.com/hackernews.html
10. Dong, A., Zhang, R., Kolari, P., Bai, J., Diaz, F., Chang, Y., et al. (2010). Time-Sensitive Ranking in News Search: Incorporating Recency and Quality, 315-322. https://doi.org/10.1145/1835449.1835503
11. Das, A. S., Datar, M., Garg, A., & Rajaram, S. (2007). Google News Personalization: Scalable Online Collaborative Filtering and Story Clustering, 271-280. https://doi.org/10.1145/1242572.1242610
12. Škvorc, T., Ivačič, N., Hribar, S., & Robnik-Šikonja, M. (2025). Real-time News Story Identification. *arXiv preprint arXiv:2508.08272*. Retrieved from https://arxiv.org/abs/2508.08272
13. Bagga, A., & Baldwin, B. (1998). Algorithms for Scoring Coreference Chains. In **Proceedings of the First International Conference on Language Resources and Evaluation Workshop on Linguistics Coreference**. (pp. 563-566).

14. Amigó, E., Gonzalo, J., Artiles, J., & Verdejo, F. (2009). A Comparison of Extrinsic Clustering Evaluation Metrics Based on Formal Constraints. *Information Retrieval*, 12(4), 461-486.
15. Ramírez, S. (2024). FastAPI framework, high performance, easy to learn, fast to code, ready for production. Accessed: 2025-01-10. Retrieved from https://fastapi.tiangolo.com
16. Colvin, S., et al. (2024). Pydantic: Data validation using Python type hints. Accessed: 2025-01-10. Retrieved from https://docs.pydantic.dev
17. Microsoft. (2024). Playwright: Fast and reliable cross-browser testing. Accessed: 2025-01-10. Retrieved from https://playwright.dev
18. Socket.IO. (2024). Socket.IO. Accessed: 2025-01-10. Retrieved from https://socket.io
19. SQLite Development Team. (2024). Write-Ahead Logging. Accessed: 2026-10-10. Retrieved from https://www.sqlite.org/wal.html

ภาคผนวก

ภาคผนวก ก
คู่มือการติดตั้งและการใช้งานระบบ

ก.1 ข้อกำหนดเบื้องต้นของสภาพแวดล้อม (Prerequisites)

1) ระบบปฏิบัติการ: Windows 10/11, macOS หรือ Linux (Ubuntu 20.04+)
2) Python เวอร์ชัน 3.11 หรือใหม่กว่า
3) เครื่องมือจัดการสภาพแวดล้อม `uv` (Fast Python Package Installer)
4) การเชื่อมต่ออินเทอร์เน็ตสำหรับดาวน์โหลด Dependencies และเรียกใช้ KKU Gen.AI API

ก.2 ขั้นตอนการติดตั้งระบบ (Installation Steps)

1) โคลน Repository โครงการจาก GitHub:

```
git clone https://github.com/wittgenstein-byte/End-to-End_News_Collector-Summarizer.git
cd End-to-End_News_Collector-Summarizer

```

2) ติดตั้ง Dependencies ทั้งหมดผ่าน `uv`:

```
uv sync

```

3) ติดตั้ง Playwright Chromium Headless Browser:

```
uv run playwright install chromium

```

4) กำหนดค่า Environment Variables โดยคัดลอกไฟล์ตัวอย่าง:

```
copy backend\.env.example backend\.env

```

จากนั้นแก้ไขไฟล์ `backend/.env` โดยกรอก API Key สำหรับ LLM Service:

```
LLM_API=your_kku_genai_api_key_here

```

5) เริ่มต้นทำงานเซิร์ฟเวอร์ Backend:

```
uv run python backend/main.py

```

6) เปิดเว็บเบราว์เซอร์และเข้าสู่ระบบที่: http://localhost:5000

ภาคผนวก ข
ข้อกำหนด REST API และ WebSocket Events

ข.1 รายการ REST API Endpoints

ตารางที่ 19 รายละเอียด REST API สำหรับบริการข้อมูลข่าวสารและประเด็นข่าว

Method	Endpoint	คำอธิบาย	Parameters / Response
GET	/api/stories	ดึงรายการประเด็นข่าวสองชั้น	category, status, limit
GET	/api/stories/trending	ดึงประเด็นข่าวติดกระแส Layer 2	คืนค่า ScoreBreakdown
GET	/api/stories/{id}	ดึงรายละเอียดประเด็นและไทม์ไลน์	คืนค่า StoryRecord
POST	/api/stories/{id}/summarize	ร้องขอการสังเคราะห์ภาพรวมข้ามสำนัก	พาดหัวรวมและไทม์ไลน์
GET	/api/macro-events	ดึงรายการมหากาพย์ประเด็นข่าว	status, crisis
GET	/api/macro-events/trending	ดึงมหากาพย์ข่าวกระแส Bento Hub	คืนค่ารายการ Macro Events
GET	/api/macro-events/{id}	ดึงโครงสร้างมหากาพย์และประเด็นย่อย	คืนค่ารายละเอียด Macro Event
GET	/api/news	ดึงรายการข่าวสารเดี่ยวแบบแบ่งหน้า	page, category, search
GET	/api/news/content	สกัดเนื้อหาบทความฉบับเต็ม In-App	url (Query) → Cleaned MD
GET	/api/categories	ดึงรายการ 9 หมวดหมู่ภาษาไทย	คืนค่า List Category Metadata
GET	/api/sources	ดึงรายการสำนักข่าวที่ลงทะเบียน	คืนค่า List Source Metadata
GET	/api/status	ตรวจสอบสถานะรอบเวลาและจำนวนข่าว	คืนค่าสถิติจำนวนข่าวในคลัง
GET	/api/image	Reverse Proxy และแคชรูปภาพข่าว	url (Query) → Image Stream
POST	/api/collect-md	สกัดเนื้อหาข่าวด่วน On-Demand	url (Body JSON)
POST	/api/news/engage	บันทึกสถิติการมีส่วนร่วมแบบนิรนาม	article_id, action

ตารางที่ 20 รายละเอียด REST API สำหรับระบบควบคุมและโพรบโครงสร้างพื้นฐาน

Method	Endpoint	คำอธิบาย	Parameters / Response
POST	/api/monitoring/auth	ยืนยันตัวตนผู้ดูแลระบบออกโทเค็น	secret (Body JSON)
GET	/api/monitoring/verify	ตรวจสอบโทเค็นเซสชันผู้ดูแล	Bearer Token
GET	/api/monitoring/stats	ตรวจสอบสุขภาพ Throughput และ RAM	Bearer Token → Stats
POST	/api/monitoring/scrape-now	สั่งรันสเกรปข่าวด่วนทุกสำนักทันที	คืนค่า Trigger Success
POST	/api/monitoring/clear-cache	ล้างแคชในหน่วยความจำและ HTTP	คืนค่า Cache Cleared
POST	/api/monitoring/test-source	ทดสอบดึงข่าวรายสำนัก	source_name (Body JSON)
GET	/livez / /readyz	โพรบตรวจสอบความพร้อมของระบบ	ตรวจสอบโพรเซสและระบบไฟล์

ข.2 รายการ WebSocket Events (Socket.IO)

ตารางที่ 21 รายละเอียด WebSocket Events สำหรับการสื่อสารแบบ Real-time

Event Name	ทิศทาง	คำอธิบายและข้อมูลที่ส่ง (Payload)
news:new	Server → Client	ส่งข้อมูลข่าวใหม่ที่เพิ่งผ่านการประมวลผลเสร็จสิ้น เพื่อแสดงผลบนหน้าจอทันที
scraper:status	Server → Client	แจ้งสถานะความคืบหน้าของกระบวนการสเกรปข่าว (เช่น เริ่มต้น, จำนวนที่ดึงได้, เสร็จสิ้น)
news:updated	Server → Client	ส่งข้อมูลการอัปเดตบทความ เช่น เมื่อการสรุป LLM เสร็จสมบูรณ์
connect / disconnect	ทั้งสองทิศทาง	ตรวจจับการเชื่อมต่อและการตัดการเชื่อมต่อของผู้ใช้

ประวัติผู้เขียน